

Dossier Analyse de données
MASTER 1 ECAP

Analyse en composantes principales de
la mortalité due au VIH/sida en 2020

Dossier réalisé par :
Labre-Blanc Emma
Mocaër Rodolphe

Analyse en composantes principales de la mortalité due au VIH/SIDA en 2020

Résumé

La lutte contre le VIH/SIDA est encore aujourd'hui un défi majeur surtout dans certaines régions du monde. Notre étude s'attache alors à essayer de comprendre les déterminants influençant la variation du taux de mortalité du SIDA. A cette fin, nous avons d'abord mis en évidence, dans la revue de littérature, les variables susceptibles de l'influencer. Par la suite, nous avons mené une étude statistique, à l'aide de données recueillies sur des sites officiels. Notre étude comprenait, une analyse en composantes principales, une régression linéaire et une régression logistique, afin de respectivement trouver des variables latentes pour réduire les dimensionnalités. Nous permettant ainsi, d'observer l'impact de ces variables sur le taux de mortalité du SIDA. En conclusion, il est ressorti de cette étude que le niveau de développement du pays et un contexte sanitaire favorable impactent significativement le taux de mortalité du SIDA de ce même pays.

Mots clés : Mortalité du VIH/SIDA - Déterminants - ACP - Modèles de régression -R

Principal component analysis of mortality due to HIV/AIDS in 2020

Abstract

The fight against HIV/AIDS remains a major challenge, especially in certain regions of the world. Our study then focuses on trying to understand the factors influencing the variation in the AIDS mortality rate. To this end, we first highlighted in the literature review, the variables likely to influence it. Then, we conducted a statistical study, using data collected on official sites, which included principal component analysis, linear regression and logistic regression in order to respectively reduce the dimensionality by finding latent variables, then observe the impact of these variables on the mortality rate of AIDS. In conclusion, this study showed that the country's level of development and a good sanitary medical context have a significant impact on the country's AIDS mortality rate.

Keywords : HIV/AIDS Mortalité - Determinants - PCA - Regression models - R

Liste des abréviations

PIB : Produit Intérieur Brut

RNB : Revenu National Brut

SIDA : Syndrome d'ImmunoDéficiency Acquis

TAR : Traitement(s) AntiRétroviral(aux)

VIH : Virus de l'Immunodéficiency Humaine

Sommaire

I. Introduction.....	2
II. Analyse détaillée du sujet : Présentation du taux de mortalité du VIH/sida et des variables actives associées.....	5
III. Analyse en Composantes Principales ACP.....	35
IV. Corrélation entre le taux de mortalité du SIDA et les variables latentes identifiées.....	55
V. Modifications du modèle de régression.....	68
VI. Discussion des résultats.....	71
VII. Conclusions et recommandations.....	74
VIII. Annexes.....	75
IX. Bibliographie.....	111

I. Introduction

En 2020 dans le monde, 38 millions de personnes vivaient avec le VIH, 1,5 million de nouvelles infections étaient répertoriées et 680 000 décès étaient enregistrés¹. Au regard de ces chiffres, le VIH reste donc un problème de santé publique majeur même si d'importants progrès ont été accomplis au cours de ces dernières années avec notamment l'introduction et le développement des traitements antirétroviraux et la mise en place de nombreuses campagnes de prévention, de soutien et de solidarité parmi lesquelles : la journée mondiale de lutte contre le sida qui se déroule chaque année le 1er décembre². Il est néanmoins important de constater que les objectifs mondiaux formulés par les nations Unis en vue d'éradiquer cette infection n'ont pas été totalement atteints.

Le VIH, une maladie infectieuse qui a marqué l'histoire de la santé mondiale depuis sa découverte dans les années 1980. Les premiers cas inexplicables de maladies mortelles, d'abord signalés chez de jeunes hommes en bonne santé à Los Angeles, ont marqué le début d'une épidémie qui allait s'étendre à l'échelle planétaire. Au fil des décennies, des millions de vies ont été perdues, des communautés entières ont été touchées, et une série d'initiatives caritatives, telles que la Fondation Elton John contre le SIDA, l'ONUSIDA et le Fonds mondial de lutte contre le SIDA, la tuberculose et le paludisme, ont vu le jour pour lutter contre cette infection.

Dans notre étude, intitulée "Analyse en Composantes Principales (ACP) du taux de mortalité du SIDA en 2020" nous nous pencherons alors sur un aspect critique de cette pandémie : le taux de mortalité du SIDA. Plus qu'un simple indicateur statistique, il reflète le coût humain de l'épidémie. Ce projet vise alors explorer en profondeur cette variable en utilisant une approche statistique avancée.

Avant d'approfondir les détails de notre étude, il nous semblait d'abord primordial de clarifier certains termes clés associés à notre sujet.

¹ [FACT SHEET \(unaids.org\)](https://www.unaids.org/fr/fact-sheet)

² [Journée mondiale de lutte contre le sida | ONUSIDA \(unaids.org\)](https://www.unaids.org/fr/world-aids-day)

En effet, comprendre la distinction entre le VIH et le SIDA est fondamentale. Ainsi, le VIH ou Virus de l'Immunodéficience Humain est défini par l'OMS comme "une infection qui attaque le système immunitaire de l'organisme, en particulier les globules blancs appelés cellules CD4⁺. Le VIH détruit ces cellules, affaiblissant l'efficacité du système immunitaire du patient contre des infections telles que la tuberculose et certains cancers."³ Or, être infecté par le VIH ne signifie pas forcément avoir le SIDA puisque le SIDA correspond seulement au dernier stade de l'infection par le VIH, lorsque les défenses immunitaires sont tellement faibles que des maladies dites "opportunistes" peuvent se développer. C'est d'ailleurs lorsqu'une maladie opportuniste se déclare que le stade SIDA est atteint et que, sans traitement antirétroviral, l'individu finit par décéder.

Cet éclaircissement étant établi, nous pouvons alors nous interroger sur : comment les facteurs économiques, socio-démographiques, et sanitaires interagissent-ils pour influencer les taux de mortalité du SIDA dans le monde en 2020 ?

Se pencher sur ce sujet est pertinent en raison du fait que, non seulement le VIH/SIDA demeure un défi mondial de santé publique, mais également car il nous permettra de comprendre les déterminants de la mortalité liée au SIDA, ce qui est essentiel pour guider les politiques de santé publique, allouer efficacement les ressources et évaluer les progrès accomplis dans la lutte contre l'épidémie. De plus, l'année 2020, a été l'année du COVID-19 pendant laquelle, le VIH/SIDA est passé au second plan médiatique, alors que cette année est cruciale pour évaluer les progrès dans la lutte contre cette épidémie puisqu'elle marque la fin de la première décennie de l'objectif de l'ONUSIDA visant à mettre fin à l'épidémie d'ici 2010.

Dans le but de répondre à notre problématique, nous utiliserons l'analyse en composantes principales. Cette méthode nous permettra d'étudier les relations entre les variables et d'identifier des variables latentes contribuant ensuite à réaliser des régressions (linéaire et logistique). Afin d'expliquer les variations du taux de mortalité du SIDA.

³ [VIH et sida \(who.int\)](http://www.who.int)

Notre travail s'organisera autour de trois grands axes. Dans un premier temps, nous réaliserons une analyse détaillée du sujet (II) en faisant un tour d'horizon des différentes recherches menées nous permettant de sélectionner les variables pertinentes pour notre analyse. Dans un second temps, nous effectuerons une analyse en composantes principales (III) permettant de définir des variables latentes correspondant au niveau de développement du pays, au bien-être médico-social de sa population et au contexte sanitaire du pays. Ensuite, nous parviendrons à déterminer que ces variables notamment le niveau de développement et le contexte sanitaire influencent significativement le taux de mortalité du SIDA grâce à l'étude des corrélations entre le taux de mortalité et les variables latentes associées (régression linéaire et logistique) (IV). Cependant, nous chercherons dans une dernière partie à améliorer le modèle en raison de la faible proportion de variance du taux de mortalité qui est expliquée par ces modèles linéaires (V).


II. Analyse détaillée du sujet : Présentation du taux de mortalité du VIH/sida et des variables actives associées

Dans cette partie, nous allons nous intéresser au taux de mortalité du sida (A) ainsi qu'aux variables actives pouvant y être liées selon la littérature (B). Nous réaliserons également les statistiques descriptives et corrélations des variables sélectionnées (C).

A. Pertinence de la variable à expliquer : le taux de mortalité du SIDA

Le taux de mortalité dû au SIDA peut être défini comme “le rapport du nombre de décès (lié au SIDA) de l'année à la population totale moyenne de l'année”⁴. L'étude de cet indicateur nous semblait pertinente pour plusieurs raisons. En effet le VIH/SIDA a été l'une des infections les plus dévastatrices de notre époque avec un pic de mortalité en 2004 (Figure 1) et la compréhension des variations de ce taux permettrait premièrement d'évaluer l'efficacité des efforts de prévention, de traitements, de sensibilisation, de politiques de santé...déployés dans le monde.

Figure 1 : Evolution de la mortalité moyenne dans le monde due au Sida pour 1000 habitants 1990 et 2022




Source des données : [AIDSinfo | UNAIDS](#)

⁴ [Définition - Taux de mortalité | Insee](#)

De plus, même si mondialement on constate une diminution importante du taux de mortalité lié au SIDA, il est important de souligner que certaines régions du monde restent plus fortement touchées par cette maladie infectieuse notamment en Afrique centrale et en Afrique du sud (Figure 2). Ainsi, cette étude nous permettra de déterminer les raisons et les mécanismes sous-jacents expliquant ces disparités. Cette compréhension contribuera par ailleurs à proposer une réflexion sur les politiques publiques de santé à mener et sur la façon dont les décideurs politiques peuvent intervenir et allouer les ressources publiques de façon à se rapprocher du taux 0.

Figure 2 : Taux de mortalité du SIDA pour 1000 habitants en 2020 par pays



Source des données : [AIDSinfo](#) | [UNAIDS](#)

Par la suite, une étude menée par l'ONUSIDA en 1999⁵, dans le but d'expliquer les disparités de propagation de l'épidémie entre les régions de l'Afrique orientale et australe et celles de l'Afrique centrale et occidentale, a mis en évidence que les différences comportementales ne pouvaient, à elles-seules, justifier les inégalités de prévalence du VIH/sida. Les chercheurs ont alors également tenu à souligner l'importance de l'environnement dans ce contexte⁶. Ainsi, il apparaît évident que le taux de mortalité du SIDA est expliqué par l'interaction d'un grand ensemble de variables (économiques, sanitaires, démographiques, sociales, comportementales...) justifiant

⁵ Fact Sheet on differences in HIV Spread in four African Cities, UNAIDS, September 1999

⁶ Stillwagon E. (2000). HIV Transmission in Latin America : Comparisons with Africa and Policy Implications, *South African Journal of Economics*, vol. 68, December 2000.

notre intérêt pour la réalisation d'une analyse en composante principales permettant de faire émerger les principaux facteurs contributifs à ses variations.

En conclusion, cette variable est d'autant plus captivante à étudier car étant un indicateur de suivi des progrès réalisés dans la lutte contre le VIH par les pays dans le cadre des objectifs de développement durable des Nations Unies visant à endiguer l'épidémie d'ici 2030⁷.

B. Rôle des variables explicatives

Pour cette partie, nous avons choisi de présenter les variables par groupe. Nous aborderons successivement les variables économiques (1), sociodémographiques(2) et enfin sanitaires (3).

1) Variables économiques

a - Revenu National Brut annuel par habitant

À l'heure actuelle, nous savons que le VIH/SIDA, "identifying HIV/AIDS as a disease of poverty"⁸, affecte principalement les pays en développement, ce qui contraste avec l'histoire du VIH/SIDA. En effet, les premiers cas de VIH/SIDA ont été découverts dans les pays développés, mais c'est dans les nations à faible revenu que l'évolution de l'épidémie a été la plus rapide⁹. Ainsi, lors d'une épidémie, les pays à revenu élevé ont souvent été mieux à même de mettre en place des mesures de prévention, de fournir des soins médicaux adéquats et de soutenir les personnes touchées par le VIH/SIDA. Ces ressources financières, induites notamment par le revenu national brut (RNB), exercent une influence significative sur les mesures de prévention, les programmes de traitement et les conséquences sociales de l'épidémie, permettant ainsi une réduction de l'infectiosité des personnes atteintes et contribuant à une diminution du nombre de

⁷ [Objectifs de développement durable | Nations Unies](#)

⁸ Zanakis, Stelios H. & Alvarez, Cecilia & Li, Vivian, 2007. Socio-economic determinants of HIV/AIDS pandemic and nations efficiencies,"European Journal of Operational Research, Elsevier, vol. 176(3), pages 1811-1838, February.(Consulté le 02/11/2022)

⁹ <https://www.sidaction.org/chrono-vih> (Consulté le 02/11/2022)

nouvelles contaminations. Par conséquent, la disparité dans les moyens financiers et les capacités d'intervention entre les pays riches et les pays pauvres a façonné de manière significative la trajectoire de l'épidémie de VIH/SIDA et d'autres épidémies au fil du temps. Il est donc important de reconnaître cette dynamique complexe entre le VIH/SIDA et le RNB, car elle a des implications majeures pour la santé publique mondiale et la lutte contre les maladies infectieuses.

Pour étayer notre argumentation, nous pouvons prendre pour exemple les aides internationales¹⁰. Ces contributions financières importantes visent à redresser le revenu national brut (RNB) des pays en développement, tout en contribuant simultanément à la lutte contre le VIH/SIDA dans ces mêmes pays. Prenons l'exemple de la Papouasie-Nouvelle-Guinée (PNG), qui bénéficie notamment du soutien de l'Australie. En effet, cette "aide australienne représente 85 % des fonds que reçoit la PNG des donateurs, et 14.5 % de son budget"¹¹ permettant ainsi une lutte efficace contre le VIH/SIDA. De même, l'Ouganda reçoit un soutien essentiel, notamment de l'Irlande, pour la lutte contre le VIH/SIDA, avec un financement pour "la lutte contre le VIH/SIDA [15.9 millions EUR]". Ces investissements sont cruciaux pour favoriser le développement économique et, par conséquent, contribuer au redressement du RNB de ces pays.

En fin de compte, la question du revenu national et de son impact sur les épidémies est essentielle pour la santé publique mondiale et la lutte contre les maladies infectieuses. Ainsi, il était donc important de prendre en considération une variables explicative sur le revenu national brut par pays. A cet égard, nous avons donc fait le choix de sélectionner comme variable : Le revenu national brut par pays.

En résumé, nous anticipons que le revenu national brut (RNB) a un impact significatif sur les variations du taux de mortalité du SIDA par pays, en raison de la complexité de la relation entre ces deux variables. Par conséquent, il est raisonnable de s'attendre à ce qu'une augmentation du RNB contribue à réduire le taux de mortalité du SIDA, comme expliqué précédemment. Les résultats de notre analyse de corrélation

¹⁰ « Annexe D. Rapport de la visite sur le terrain en Ouganda », *Revue de l'OCDE sur le développement*, vol. 10, no. 3, 2009, pp. 105-112.(Consulté le 02/11/2022)

¹¹ « Annexe E : Le Programme d'Aide de l'Australie en Papouasie-Nouvelle-Guinée », *Revue de l'OCDE sur le développement*, vol. no6, no. 2, 2005, pp. 169-175.(Consulté le 02/11/2022)

confirment nos hypothèses en démontrant une corrélation négative entre ces deux facteurs, renforçant ainsi nos arguments.

b - La stabilité politique

A notre époque, L'État revêt une importance prépondérante dans la vie de ses citoyens. Une importance établie tant par la constitution de chaque Etat souverain que par la Charte des Nations Unies. Par conséquent, chaque État s'engage à garantir une abondance de droit incorporant à la fois le domaine de la santé : "Elle garantit à tous, notamment à l'enfant, à la mère et aux vieux travailleurs, la protection de la santé ..." ¹², le domaine de la sécurité : "Tout homme persécuté en raison de son action en faveur de la liberté a droit d'asile sur les territoires de la République." ¹¹, ... La stabilité de l'État, qui repose en grande partie sur la continuité politique, se révèle ainsi primordiale au bon déroulement des affaires nationales, notamment en ce qui concerne le secteur de la santé, en assurant la qualité des services hospitaliers, la promotion de la recherche épidémiologique, et bien d'autres aspects essentiels à la santé publique. En conséquence, nous pouvons affirmer que la stabilité politique et la santé publique et plus étroitement la santé de la population sont intrinsèquement liés.

Afin d'illustrer nos propos, nous pouvons prendre l'exemple de la pandémie de COVID-19. Il est démontré que les "Politically unstable countries are more likely to suffered significantly higher morbidity and mortality." ¹³ Cela se traduisant par une augmentation du taux de mortalité et de létalité dans certaines régions. Nous pouvons citer l'exemple de la Birmanie "many healthcare workers stopped working, a part of 'Civil Disobedience Movement' as a peaceful, non-violent protest against the military coup" ¹² entraînant donc un impact négatif sur la capacité à répondre de manière approprié à la pandémie de COVID-19. Outre, la mauvaise gestion d'une pandémie qui peut être induite par une instabilité politique cette même instabilité peut induire "la fuite des cerveaux" ¹⁴, appauvrissant toujours plus les pays et régions en difficulté. Un exemple concret de cette situation peut être observé en Afrique ou : "that the 'brain

¹² Préambule de la Constitution du 27 octobre 1946. (Consulté le 31/10/2022).

¹³ Gao, Rui, and Hai-Hong Liu. "Political stability as a major determinant of the Covid-19 pandemic outcomes." *Heliyon* vol. 9,10 e20617. 5 Oct. 2023, doi:10.1016/j.heliyon.2023.e20617 (Consulté le 31/10/2022)

¹⁴ Docquier, Frédéric. « Fuite des cerveaux et inégalités entre pays », *Revue d'économie du développement*, vol. 15, no. 2-3, 2007, pp. 49-88. (Consulté le 31/10/2022)

drain' and political instability has robbed Africa of its most talented young people, medical and science”¹⁵.

Par conséquent, il était donc important de prendre en considération la stabilité politique, dans l’optique de pouvoir appréhender et analyser les inégalités du taux de mortalité du SIDA dans le monde entre les régions. Nous avons donc décidé de prendre un indicateur de stabilité politique évaluant les perceptions de la probabilité d’instabilité politique et/ou de violence à motivation politique. Cet indice attribue un score variant de 0 correspondant au classement le plus bas à 100 au classement le plus élevé.

En somme, nous anticipons qu’une partie significative des variations du taux de mortalité du SIDA soit impactée par le niveau de stabilité politique. Ces variables étant liées et de surcroît étant corrélées positivement, ainsi elle évolue conjointement. Par conséquent, un pays instable politiquement présentera un taux de mortalité du SIDA plus élevé.

c - PIB par habitant

“Le Produit intérieur brut aux prix du marché, ou PIB, vise à mesurer la richesse créée par tous les agents, privés et publics, sur un territoire national, pendant une période donnée” selon la définition proposée par l’INSEE¹⁶. Cette mesure économique pourrait influencer de manière significative le taux de mortalité lié au VIH/SIDA pour plusieurs raisons.

Tout d’abord, les pays ayant un PIB élevé se distingueraient par un accès aux soins de santé de qualité supérieure. Ils offriraient en effet une couverture étendue et des services médicaux de pointe en raison de dépenses de santé plus importantes. En effet, il existerait une forte corrélation positive entre le PIB et les dépenses de santé : “The general consensus among researchers is that there exists a strong and positive

¹⁵ Cook CT, Kalu K. The political economy of health policy in Sub-Saharan Africa. Med Law. 2008 Mar;27(1):29-51. PMID: 18592880.(Consulté le 31/10/2022)

¹⁶ [Produit intérieur brut par habitant dans l'Union européenne | Insee](#)

correlation between healthcare expenditure and GDP (in real per capita terms) at the aggregate level”¹⁷.

D’autres études se sont attachées à liées directement le PIB avec la diminution de la mortalité associée à des maladies infectieuses. Il a par exemple été mentionné qu’en Amérique latine : “l’augmentation du PIB a eu un impact positif substantiel sur la mortalité due à la tuberculose (réduction)”¹⁸. À l’inverse, “la baisse du PIB peut agir comme un indicateur grossier de la dynamique économique ou sociale et des changements liés aux effets néfastes sur la santé, y compris la transmission du VIH dans les groupes de population marginalisés”¹⁹.

Cela s’expliquerait par le fait que les individus bénéficieraient dans ces pays d’une prise en charge précoce, incluant des tests de dépistage fréquents, les traitements antirétroviraux et un suivi médical approfondi concernant le VIH par exemple.

De plus, ces pays consacraient davantage de ressources à l’éducation, à la santé et aux prévention du VIH notamment. Leur population seraient alors davantage informées sur les modes de transmission, les pratiques sexuelles sûres, l’utilisation correcte des préservatifs et sur l’importance des dépistages réguliers. Ces connaissances, associées à la disponibilité des ressources financières substantielles, permettraient d’adopter des comportements responsables et ainsi de réduire la propagation de cette infection.

Par ailleurs, les nations dotées d’un PIB élevé pourraient mener des recherches médicales de pointe permettant d’avancer dans la découverte de traitements et de thérapies notamment concernant le sida.

¹⁷ Auster, R. L. and D. Sarachek (1969). The production of health: an exploratory study, 4, 411± 36. *Journal of Human Resources* 4: 411-447.

¹⁸ Biggs B, King L, Basu S, Stuckler D. Is wealthier always healthier? The impact of national income level, inequality, and poverty on public health in Latin America. *Soc Sci Med.* 2010;71:266–273. pmid:20471147

¹⁹ Nikolopoulos, G. K., Fotiou, A., Kanavou, E., Richardson, C., Detsis, M., Pharris, A., ... & Hatzakis, A. (2015). National income inequality and declining GDP growth rates are associated with increases in HIV diagnoses among people who inject drugs in Europe: a panel data analysis. *PloS one*, 10(4), e0122367.

Ensuite, d'autres études ont cherché à lier les notions de PIB et de qualité de vie en expliquant qu'il existerait une corrélation positive entre ces deux notions²⁰. Ainsi, les individus dans ces pays au PIB plus élevé auraient de meilleures conditions de vie avec notamment l'accès à de l'eau potable, à des installations sanitaires adéquates, à des logements salubres, à des système de gestion des déchets performants... Ces conditions favoriseraient la santé globale des personnes touchées par le VIH, réduisant les risques de contracter des infections opportunistes graves et donc réduisant de fait les taux de mortalité²¹.

Ainsi, pour reprendre les propos de Pritchett et Summers, il semblerait que "Wealthier is healthier" (plus on est riche, plus on est en bonne santé) »²². Cependant, il convient de nuancer ces propos puisque les études menées expliquent également que des fortes inégalités de revenus dans un même pays peuvent réduire cet effet²³.

Finalement, le PIB pourrait être un facteur déterminant dans l'explication des variations du taux de mortalité du VIH/sida et il pourrait exister une corrélation significative négative entre ces variables. Nous avons donc choisi d'inclure cette variable dans notre étude en utilisant les données de la Banque Mondiale sur le PIB par habitant afin de simplifier les comparaisons entre les pays.

d - L'Accès à l'électricité

Depuis les premières avancées dans le domaine de l'électricité, notamment grâce aux travaux pionniers de figures éminentes telles que William Gilbert, cette discipline occupe désormais une place centrale au sein de nos sociétés. Elle s'est affirmée comme un élément essentiel pour la qualité de nos vies, comme le souligne judicieusement

²⁰ Mpofu, R. T. (2013). Standard of living, quality of life and GDP: An Economics Peregrination. *The Business & Management Review*, 3(4), 100.

²¹ Neiderud, C. J. (2015). How urbanization affects the epidemiology of emerging infectious diseases. *Infection ecology & epidemiology*, 5(1), 27060.

²² Pritchett, L., & Summers, L. H. (1993). *Wealthier is healthier* (Vol. 1150). World Bank Publications.

²³ Biggs, B., King, L., Basu, S., & Stuckler, D. (2010). Is wealthier always healthier? The impact of national income level, inequality, and poverty on public health in Latin America. *Social science & medicine*, 71(2), 266-273.

l'assertion, "The provision of electricity has been a great benefit to society"²⁴. Elle joue également un rôle vital dans de nombreux secteurs clés, tels que l'éducation, la santé, l'industrie, et bien d'autres. L'électrification du domaine de la santé mérite une attention particulière, en permettant des avancées notables, telles que l'amélioration de la qualité des soins grâce à des équipements comme "L'éclairage des salles d'opération"²⁵. De plus, elle contribue à réduire la propagation de maladies nosocomiales au sein des établissements hospitaliers. Il est également important de souligner que cette électrification a joué un rôle significatif dans la lutte contre diverses épidémies, y compris la pandémie de COVID-19, comme indiqué par la déclaration, "It could be argued that restricted access to electricity – and therefore oxygen – worsens health emergencies, especially in LMICs"²⁶. En conséquence, cette discipline exerce une influence notable sur la gestion des épidémies, contribuant ainsi à la protection de la santé publique. Cependant, la lutte contre les épidémies ne se limite pas exclusivement au secteur de la santé. En réalité, le domaine de l'éducation demeure d'une importance cruciale pour informer la population sur l'évolution des épidémies. Ainsi, cette discipline contribue à renforcer les opportunités éducatives, en particulier dans les zones rurales ou isolées.

Pour étayer notre argumentation, nous pouvons nous référer à des études menées en Afrique et en Inde qui démontrent l'efficacité de l'électrification. Ces recherches ont montré que l'électrification était associée à des améliorations de la qualité des services de soins prénataux, des taux de vaccination, des capacités d'intervention d'urgence et des services de santé primaires. De nombreux établissements ont signalé la disponibilité d'approvisionnements en oxygène de haute qualité, fiables et continus, une réfrigération adéquate et une amélioration des chaînes d'approvisionnement médical²⁷.

²⁴ Anil Markandya, Paul Wilkinson, Electricity generation and health, The Lancet, Volume 370, Issue 9591, 2007, Pages 979-990, ISSN 0140-6736, (Consulté le 03/11/2022)

²⁵ Francis Dreyer, « Histoire de l'hôpital. L'éclairage des salles d'opération aux XIXe et XXe siècles : l'apparition du scialytique », *In Situ* [En ligne], 10 | 2009, mis en ligne le 19 mai 2009, consulté le 03 novembre 2023 (Consulté le 03/11/2022)

²⁶ Khogali, A., Ahmed, A., Ibrahim, M., Karrar, K., Elsheikh, M., Abdelraheem, E., Cluver, L., & Elmukashfi, E. (2022). Building power-ful health systems: The impacts of electrification on health outcomes in LMICs. *Psychology, Health & Medicine*, 1–14. (Consulté le 03/11/2022)

²⁷ Khogali A, Ahmed A, Ibrahim M, Karrar K, Elsheikh M, Abdelraheem E, Cluver L, Elmukashfi E. Building power-ful health systems: the impacts of electrification on health outcomes in LMICs. *Psychol Health Med*. 2022 Jan-Dec;27(sup1):124-137.

Par conséquent, l'intégration de l'électrification des pays devient un paramètre essentiel pour appréhender la lutte contre la mortalité liée au SIDA. C'est dans cette optique que nous avons choisi de prendre en compte l'accès à l'électricité des pays.

En résumé, nous anticipons que l'accès à l'électricité a un impact significatif sur les variations du taux de mortalité lié au SIDA selon les pays. Par conséquent, il est raisonnable de supposer qu'un pays bénéficiant d'un accès étendu à l'électricité contribue à réduire le taux de mortalité lié au SIDA, comme exposé précédemment. Les résultats de notre analyse de corrélation viennent appuyer nos hypothèses en mettant en évidence une corrélation négative entre ces deux variables, renforçant ainsi notre argumentaire.

2) Variables socio-démographique

a - Part de la population actives en pourcentage

De nos jours, la mise en lumière de la ventilation de l'incidence du VIH est devenue un sujet de notoriété publique, d'intérêt général et d'envergure mondiale. En effet, cette ventilation de la prévalence du VIH obtenus grâce à des enquêtes scientifique²⁸, nous permet d'identifier les groupes de population les plus vulnérables à l'infection par le VIH. Par conséquent, ces données épidémiologiques nous ont permis d'établir que la tranche d'âge la plus à risque face au VIH étant celle des 15-49ans représentant 70% des personnes infectées par le VIH, ainsi "les personnes infectées par le VIH appartiennent à des classes d'âge économiquement actives (15-49 ans)"²⁹.Egalement, il est important de noter que la seconde classe d'âge la plus à risque étant les +50 ans avec une surreprésentation dans ce groupe des 50-60ans.

Initialement, l'identification de la tranche d'âge la plus prédisposée à l'infection par le VIH est d'une importance capitale. Néanmoins, cette démarche reste incomplète tant qu'une analyse des comportements n'a pas été entreprise pour appréhender les

²⁸ UNAIDS Global AIDS Monitoring, 2023; UNAIDS epidemiological estimates, 2023 (<https://aidsinfo.unaids.org/>) (Consulté le 30/10/2022)

²⁹ <https://www.un.org/french/ageing/chap9.pdf> (Consulté le 30/10/2022)

raisons sous-jacentes de ce pic d'incidence observé chez les 15-49 ans. Dans un premier temps, ce pic peut être attribué par une lacune d'information, en effet "Pour les jeunes, le sida, c'est une maladie de vieux"³⁰. Cette lacune touchant aussi bien les pays en développement (Botswana, Niger,...) que les pays développés (Ukraine, Moldavie, ...), cela pouvant résulter aussi bien d'un manque d'information que de la persistance d'idées erronées. Dans un second temps, cette montée en flèche de l'incidence parmi les 15-49 ans peut être induite par un changement des comportements sexuels. En effet l'évolution des mœurs à changer la dynamique de la vie sexuelle au sein de la population de manière notable. Nous pouvons citer notamment, la tendance des premiers rapports sexuels qui surviennent de plus en plus tôt de nos jours³¹. Outre cette précocité, nous pouvons également observer un faible recours au préservatif chez les jeunes, ce qui crée un environnement propice à la propagation du VIH à l'échelle mondiale³².

En conséquence, il était impératif de prendre en considération les groupes les plus à risque à contracter le VIH. Dans cette optique, nous avons donc fait le choix de sélectionner comme l'une de nos variables explicatives : la part de la population active en %. En effet la population active pouvant être facilement identifiée comme étant le groupe surreprésentés dans la prévalence du VIH.

Pour conclure, nous prévoyons qu'une partie des variations du taux de mortalité du VIH par pays soit conditionnées par la part de la population active en % par pays. En conclusion, en nous basant sur notre revue de la littérature, nous pourrions envisager que la présence d'une population active importante soit associée à une augmentation de l'incidence du VIH, et par conséquent, à une augmentation intrinsèque de la mortalité liée au VIH. Toutefois, il est important de noter que nos résultats de corrélation ne confirment pas cette hypothèse car montrant une corrélation négative.

b - Pourcentage de femmes dans la société

³⁰https://www.lemonde.fr/societe/article/2019/12/01/pour-les-jeunes-le-sida-c-est-une-maladie-de-vieux-ils-ne-se-sentent-pas-vraiment-concernes_6021221_3224.html (Consulté le 30/10/2022)

³¹ https://www.unaids.org/sites/default/files/media_asset/youngpeoplehivaids_fr_0.pdf (Consulté le 30/10/2022)

³² Tsafack Temah, Chrystelle. « Les déterminants de l'épidémie du VIH/SIDA en Afrique subsaharienne », *Revue d'économie du développement*, vol. 17, no. 1-2, 2009, pp. 73-106. (Consulté le 30/10/2022)

La proportion de femmes au sein de la population pourrait avoir un impact significatif dans l'explication des variations du taux de mortalité associés au VIH/sida dans les différents pays du monde. En effet, il existerait des inégalités de vulnérabilité et de mortalité associées au VIH/sida entre les hommes et les femmes.

Par exemple, les données de l'UNAIDS en 2017 ont révélé une disparité marquée en Afrique subsaharienne : bien que les femmes représentaient 59% de la population infectée par le VIH (surreprésentation), seulement 47% des décès liés au VIH/sida étaient des décès de femmes (sous-représentation).

De plus, la réduction du nombre de décès entre 2005 et 2016, après l'apparition des traitements antirétroviraux s'est élevé chez les femmes de 15 ans et plus à 58%, tandis que chez les hommes, cette réduction s'est faite dans une moindre mesure, s'élevant à 43%³³.

Cette constatation souligne l'importance de prendre en compte les disparités de genre concernant l'exposition, la vulnérabilité et la mortalité liée au VIH/sida qui pourraient être dues à différents facteurs : épidémiologiques, biologiques, sociaux et comportementaux³⁴.

En effet, tout d'abord concernant l'exposition au risque d'infection des femmes, elles y sont notamment confrontées lors de mariages précoces et forcés, dans le cadre de l'économie informelle et du travail du sexe, avec l'utilisation des contraceptifs oraux qui augmentent le risque du vih d'environ 20% et des contraceptifs injectables qui doublent le risque. Du côté des hommes, la pratique de la circoncision permettrait de réduire les risques de transmission tandis que les comportements à risque des hommes : drogues... les augmenteraient (34).

Ensuite, pour des raisons biologiques et sociales (violences sexuelles, éducation, dépendance économique, relations de pouvoir, pas de possibilité de négociation

³³ UNAIDS. UNAIDS DATA 2017. Pour des estimations récentes sur différents indicateurs liés au sida, voir <http://aidsinfo.unaids.org/>

³⁴ Lydié, N. Garenne, M. (2001) Genre et Sida. - Paris, Centre français sur la population et le développement, 37 p. ; 24 cm. (Les Dossiers du CEPED no 67).

concernant l'utilisation des préservatifs...), les femmes seraient plus vulnérables à l'infection³⁵.

Enfin, bien que les femmes puissent être plus vulnérables à l'infection par le VIH, les données montrent également souvent que leur taux de mortalité lié au VIH/sida serait inférieur à celui des hommes. Cela s'expliquerait par : les tests de dépistage qui sont davantage effectués par les femmes (en 2015 au Zimbabwe selon l'enquête EDS, 80% de femmes de 15 à 49 ans déclaraient avoir déjà effectué un test de dépistage contre 62% des hommes³⁶), le meilleur suivi médical des femmes (avec notamment les programmes de prévention de la transmission mère-enfant³⁷), et le meilleur suivi de leur traitement qui est souvent initié plus tôt (d'après l'Onusida, leurs taux de couverture des TAR sont supérieurs de 15% en moyenne dans la majorité des pays³⁸).

Il est néanmoins important de noter que ces tendances peuvent varier en fonction des régions du monde, des groupes de population étudiés, des contextes socio-économiques...

Ainsi, nous avons choisi d'inclure cette variable dans notre étude en partant du postulat que plus la proportion de femmes est importante dans la population, plus le taux de mortalité est faible et qu'alors il existerait une corrélation négative entre ces deux variables. Les données utilisées sont issues du site de la banque mondiale.

c - Pourcentage de la population urbaine

L'urbanisation, caractérisée par une concentration croissante de la population dans les zones urbaines par rapport aux zones rurales, pourrait potentiellement exercer un impact significatif sur le taux de mortalité du VIH/sida. Dans le contexte contemporain, le phénomène de l'urbanisation a donné lieu à une transition démographique substantielle. En effet, depuis 2009, plus de la moitié de la population

³⁵ Lydié, N. Garenne, M. (2001) Genre et Sida. - Paris, Centre français sur la population et le développement,, 37 p. ; 24 cm. (Les Dossiers du CEPED no 67).

³⁶ Masquelier, B. & Reniers, G. (2018). Sida et écarts d'espérance de vie entre hommes et femmes en Afrique. *Population & Sociétés*, 554, 1-4. <https://doi.org/10.3917/popsoc.554.0001>

³⁷ Desclaux, A. Desgrées du Loû, A. « Les femmes africaines face à l'épidémie de sida », *Population et Sociétés*, 428, 4 p., 2006.

³⁸ UNAIDS. UNAIDS DATA 2017. Pour des estimations récentes sur différents indicateurs liés au sida, voir <http://aidsinfo.unaids.org/>

mondiale réside désormais dans des zones urbaines, atteignant un pourcentage de 56% en 2020³⁹.

L'urbanisation pourrait permettre de réduire le taux de mortalité lié au VIH pour diverses raisons. En effet, les zones urbaines offrent généralement un accès plus aisé aux services de santé, aux programmes de prévention, ainsi qu'à l'éducation. Les professionnels de la santé et le public dans les environnements urbains sont souvent mieux informés concernant les maladies infectieuses, dont le VIH, favorisant ainsi l'adoption de comportements plus sécuritaires, l'usage de préservatifs, l'observance des traitements antirétroviraux et la vaccination pour diminuer les risques de co-infection⁴⁰. Par ailleurs, les campagnes de sensibilisation, l'éducation à la santé et les activités de promotion sanitaire s'avèrent plus accessibles et plus efficaces en milieu urbain. L'urbanisation permet également la concentration des ressources économiques, lesquelles peuvent être investies dans la lutte contre le VIH/sida, dans les services de santé et dans les campagnes de prévention et de sensibilisation⁴¹.

Cependant, l'urbanisation pourrait également accroître le risque de mortalité associée au VIH/sida. En effet, les zones urbaines sont susceptibles de faire face à des problèmes tels que des conditions de logement insalubres, la surpopulation dans les bidonvilles, un accès limité à l'eau potable et des systèmes de gestion des déchets déficients responsables de la prolifération des rats. Ces circonstances favoriseraient la propagation des maladies infectieuses exposant ainsi les personnes infectées par le VIH/sida à un risque accru de comorbidité et de mortalité. De plus, la migration des populations depuis les zones rurales vers les zones urbaines, motivée par la recherche de meilleures opportunités économiques, pourrait entraîner des comportements à risque de cette population en raison d'une méconnaissance relative quant à des pratiques de prévention⁴².

³⁹ [Population urbaine \(% du total\) | Data \(banquemonddiale.org\)](#)

⁴⁰ Neiderud, C. J. (2015). How urbanization affects the epidemiology of emerging infectious diseases. *Infection ecology & epidemiology*, 5(1), 27060.

⁴¹ David A Leon, Cities, urbanization and health, *International Journal of Epidemiology*, Volume 37, Issue 1, February 2008, Pages 4–8, <https://doi.org/10.1093/ije/dym271>

⁴² Reyes, R., Ahn, R., Thurber, K., & Burke, T. F. (2013). Urbanization and infectious diseases: general principles, historical perspectives, and contemporary challenges. *Challenges in infectious diseases*, 123-146.

Enfin, les comportements sexuels (exemples : travail du sexe, relations sexuelles plus libres), la consommation de substances toxiques (drogues et alcool) pourrait également contribuer à une plus forte propagation du VIH dans les milieux urbain⁴³.

Dans ce contexte, l'urbanisation génère un impact complexe sur le taux de mortalité du VIH/sida, associant des aspects bénéfiques et préjudiciables. Par conséquent, il demeure difficile d'émettre une hypothèse claire quant à la nature de la relation qui pourrait exister entre cette variable et le taux de mortalité du VIH.

3) Variables sur le contexte sanitaire

a- Espérance de vie

L'espérance de vie à la naissance d'un individu représente « la durée moyenne - autrement dit l'âge moyen au décès - d'une génération fictive soumise aux conditions de mortalité de l'année » selon l'INSEE.

L'espérance de vie moyenne, au niveau mondial, n'a cessé d'augmenter depuis le milieu du 19ème siècle, mais cette augmentation n'a pas été uniforme pour tous les pays⁴⁴.

Cet indicateur revêt une importance capitale car il renseigne non seulement sur les taux de mortalité, mais également sur la santé d'une population, son niveau de développement socio-économique⁴⁵ et il constitue une mesure fondamentale du bien-être social.

En effet, des études ont corroboré une corrélation positive entre l'espérance de vie et diverses variables, notamment l'environnement naturel, l'environnement social, l'environnement économique ainsi que la qualité de la nutrition⁴⁶. Par conséquent,

⁴³ Reyes, R., Ahn, R., Thurber, K., & Burke, T. F. (2013). Urbanization and infectious diseases: general principles, historical perspectives, and contemporary challenges. *Challenges in infectious diseases*, 123-146.

⁴⁴ Cutler D., Deaton A., Lleras-Muney A. 2006 : The Determinants of Mortality, *Journal of Economic Perspectives* 20(3), 97-120.

⁴⁵ Jen M. H., Johnston R., Jones K., Harris R., Gandy A. 2010 : International variations in life expectancy : A spatio-temporal analysis, *Tijdschrift voor economische en sociale geografie* 101(1), 73-90.

⁴⁶ Gulis, G. (2000). Life expectancy as an indicator of environmental health. *European journal of epidemiology*, 16, 161-165.

l'espérance de vie peut être considérée comme un indicateur environnemental, d'où la pertinence de la prise en compte de cette variable puisque comme nous avons pu le mentionner précédemment, l'ensemble de ces variables semblent influencer les taux de mortalité associés au VIH/sida.

De plus, l'espérance de vie se révèle être un indicateur d'autant plus pertinent qu'il offre également une évaluation de l'efficacité des systèmes de santé contrairement à d'autres variables mentionnées précédemment⁴⁷. En effet, bien que certaines études laissent entrevoir un lien entre les dépenses de santé par exemple et les résultats en matière de santé⁴⁸, elles suggèrent aussi que l'allocation judicieuse des ressources peut influencer favorablement l'espérance de vie sans nécessiter des dépenses accrues. Par conséquent, l'espérance de vie peut servir de mesure de l'efficacité des systèmes de santé⁴⁹.

Or, un système de santé performant a la capacité, d'une part, de réduire les risques de transmission du VIH, tout en garantissant un accès équitable aux soins et aux traitements. Et d'autre part de prévenir les comorbidités (vaccins..), ce qui contribue à réduire les risques de mortalité liés à cette infection et, en fin de compte, à abaisser les taux de mortalité du VIH/sida.

Ainsi, comme l'espérance de vie se révèle être à la fois un indicateur environnemental et un indicateur sur l'efficacité des systèmes de santé, il nous a donc paru nécessaire d'inclure cette variable dans notre étude. Au vu des recherches menées, nous émettons également l'hypothèse que cette variable serait corrélée négativement avec les taux de mortalité du VIH/sida.

b - Accès à l'eau potable

Comme nous l'avons mentionné précédemment, les chercheurs ont souligné l'importance de l'environnement pour justifier les inégalités de prévalence du

⁴⁷ Zarulli, V., Sopina, E., Toffolutti, V., & Lenart, A. (2021). Health care system efficiency and life expectancy: A 140-country study. *PLOS one*, 16(7), e0253450.

⁴⁸ Glied, S., & Smith, P. C. (Eds.). (2013). *The Oxford handbook of health economics*. Oxford University Press.

⁴⁹ Zarulli, V., Sopina, E., Toffolutti, V., & Lenart, A. (2021). Health care system efficiency and life expectancy: A 140-country study. *PLOS one*, 16(7), e0253450.

VIH/sida⁵⁰. Par conséquent, il nous semble opportun d'examiner la question de l'accès à l'eau potable dans le cadre de notre étude, d'autant plus qu'il a été démontré que cela revêt une importance cruciale dans la lutte contre le VIH/sida et son taux de mortalité, pour diverses raisons⁵¹.

En premier lieu, il est impératif de souligner que l'eau non potable constitue l'une des principales sources d'infection en Afrique par exemple. Or, pour les individus atteints du VIH, avoir accès à une eau de qualité est essentiel pour éviter les problèmes de comorbidité qui accroissent le risque de mortalité en raison de la fragilité de leur système immunitaire. Ces maladies liées à l'eau ont été catégorisée par White (1972) en quatre types : les infections waterborne (liées à la qualité de l'eau telles que le choléra et la salmonellose), les infections water-washed (liées à la quantité d'eau disponible telles que la dermatose, l'entérite) et les infections water-based et water-related (liées à la présence et au développement de microorganismes : paludisme, dengue...) ⁵².

En second lieu, l'accès à l'eau potable favoriserait le maintien de bonnes pratiques d'hygiène, telles que le lavage des mains, réduisant ainsi le risque d'infections opportunistes et le risque de décès. De plus, une eau potable est nécessaire pour les soins à domicile des patients infectés, notamment pour la prise des médicaments, et pour les femmes enceintes atteintes du VIH, afin qu'elles puissent donner une alimentation sûre pour leur nourrisson lorsque l'allaitement n'est pas recommandé.

En outre, l'accès à l'eau potable est essentiel pour la préparation des aliments, et une nutrition adéquate peut contribuer à maintenir voire à améliorer l'état nutritionnel des personnes vivant avec le VIH, prévenant ainsi le développement de carences nutritionnelles et retardant la progression de la maladie vers le stade du sida. La malnutrition pourrait en effet exacerber les effets du VIH et accroître les risques de décès.

⁵⁰ Stillwagon E. (2000). HIV Transmission in Latin America : Comparisons with Africa and Policy Implications, *South African Journal of Economics*, vol. 68, December 2000.

⁵¹ Wegelin-Schuringa, M., & Kamminga, E. (2006). Water and sanitation in the context of HIV/AIDS: the right of access in resource-poor countries. *Health and Human Rights*, 152-172.

⁵² White G, Bradley D & White A (1972) Drawers of Water: Domestic Water Use in East Africa. University of Chicago Press, Chicago.

Enfin, de manière plus globale, l'accès à l'eau potable permettrait aux patients d'améliorer leur bien-être et leur qualité de vie, ce qui pourrait également contribuer à réduire la mortalité.

Pour toutes ces raisons, il nous a semblé pertinent d'inclure cette variable dans notre étude en posant l'hypothèse qu'elle serait négativement corrélée au taux de mortalité du VIH/sida.

c - Dépenses publiques pour la santé

De tout temps, la lutte contre les épidémies a toujours été un défi pour nos sociétés. Cependant, grâce à la découverte de la médecine hippocratique, représentant l'union d'Hygie et de Panacée⁵³, cette lutte a pu être entreprise. Par la suite, de nouvelles idéologies émergées introduites notamment par des chercheurs comme Florence Nightingale, Alexander Fleming, Hippocrate, Abdoulaye et d'autres. Néanmoins, le tournant décisif grâce à l'étatisation du domaine de la santé, notamment par le biais des politiques de santé évoqué par les travaux de Michel Foucault^{54 55} induisant une augmentation des dépenses publiques pour la santé. Ainsi "la naissance de la santé publique marque un véritable tournant"¹⁶. De cette manière, l'intervention de l'Etat dans le domaine de la santé provoquant la montée en flèche des dépenses de santé a ouvert la voie aussi bien aux financements accrus de la recherche médicale, au développement des infrastructures hospitalières, l'avènement des protections sociales et bien d'autres encore.

Pour illustrer notre propos, prenons l'exemple de l'épidémie de choléra de 1832 qui a sévi en France, en particulier à Paris⁵⁶. Cette épidémie s'est propagée principalement en raison du manque d'hygiène dans la capitale à l'époque insalubre, entraînant de nombreuses pertes en vies humaines. Cependant, c'est grâce à l'avènement de l'hygiénisme, notamment par la mise en place de lois telles que "la loi de

⁵³ Lefève, Céline. « De la philosophie de la médecine de Georges Canguilhem à la philosophie du soin médical », *Revue de métaphysique et de morale*, vol. 82, no. 2, 2014, pp. 197-221.(Consulté le 01/11/2022)

⁵⁴ Marzano, Michela. « Foucault et la santé publique », *Les Tribunes de la santé*, vol. 33, no. 4, 2011, pp. 39-43. (Consulté le 01/11/2022)

⁵⁵ Marzano, Michela. « Foucault et la santé publique », *Les Tribunes de la santé*, vol. 33, no. 4, 2011, pp. 39-43.(Consulté le 01/11/2022)

⁵⁶ Vauthier Gabriel. Le Choléra à Paris en 1832. In: *La Révolution de 1848 et les révolutions du XIXe siècle*, Tome 25, Numéro 127, Décembre 1928-janvier-février 1929. pp. 234-241.(Consulté le 01/11/2022)

Villermé sur l'inégalité sociale devant la maladie et la mort"⁵⁷ et "la seconde loi hygiéniste qui stipulait la nécessité d'empêcher les populations de boire leurs propres excréments."¹⁸ Ces mesures législatives ont permis de développer des solutions, comme le projet d'assainissement de Paris présenté par Parent-Duchâtelet, pour lutter contre l'épidémie de choléra. Cependant, il était impératif d'accroître les fonds alloués à la sécurité sanitaire de l'époque pour assurer une gestion financièrement viable de ces mesures en vue d'éradiquer la maladie.

En conséquence, il était crucial de tenir compte de l'allocation budgétaire pour la sécurité sanitaire, car elle constitue un élément central dans la lutte contre les épidémies, tant à l'époque qu'aujourd'hui. Ainsi, nous avons donc choisi de prendre comme l'une de nos variables explicatives la part du produit intérieur brut (PIB) consacrée au ministère de la Santé pour chaque pays.

Pour conclure, nous anticipons que la part du produit intérieur brut (PIB) allouée au ministère de la Santé (en %) jouera un rôle significatif dans l'explication des variations du taux de mortalité lié au VIH. Étant donné la relation entre ces deux variables, il est raisonnable de s'attendre à ce qu'un pays investissant davantage dans son ministère de la Santé présente un taux de mortalité lié au VIH plus bas. Cependant, les résultats de la corrélation ne semblent pas étayer cette hypothèse.

d - L'incidence de la tuberculose pour 100 000 personnes

En vue d'expliquer la mortalité du VIH, nous devons comprendre une autre maladie : la tuberculose. La tuberculose, une pathologie infectieuse faisant partie des 10 premières causes de mortalité induit par une maladie infectieuse dans le monde (la tuberculose occupe la 8ème place⁵⁸). Cette affection est déclenchée par une infection à *Mycobacterium tuberculosis* (une mycobactérie), provoquant dans la majorité des cas des complications pulmonaires pouvant aller jusqu'à la mort. De plus il est important de noter que " la tuberculose est la complication infectieuse la plus fréquente de l'infection

⁵⁷ Jorland, Gérard. « L'hygiène publique, fille des Lumières », *Les Tribunes de la santé*, vol. 38, no. 1, 2013, pp. 23-27.(Consulté le 01/11/2022)

⁵⁸<https://www.who.int/fr/news/item/09-12-2020-who-reveals-leading-causes-of-death-and-disability-worldwide-2000-2019> (Consulté le 22/10/2022)

VIH et le VIH est l'infection la plus souvent associée à la tuberculose ”⁵⁹Cet extrait d'un article scientifique illustre clairement l'importance de la tuberculose comme un point clé majeur dans la compréhension de la mortalité du VIH dans le monde. Également, une autre étude⁶⁰, nous manifeste la véracité de la relation complexe entre l'incidence de la tuberculose chez un patient à la mortalité du VIH. Ainsi, il est donc aisé de définir ces maladies comme intrinsèquement liées, formant ainsi l'une des co-infections les plus dangereuses. En raison de cela, la lutte de cette co-infection intègre la liste des objectifs du millénaire pour le développement⁶¹.

Afin d'avoir une meilleure perception de cette relation complexe entre l'incidence de la tuberculose et la mortalité du VIH, nous pouvons illustrer nos propos avec les tendances de l'incidence de la tuberculose (pour 100 000 personnes) dans le monde en 2020⁶². Ainsi, en 2020 nous pouvons observer que les régions les plus touchées étant l'Afrique, l'Asie du Sud-Est et la Méditerranée orientale possèdent simultanément, un taux d'incidence de la tuberculose élevée et un taux de mortalité du VIH important. Cette illustration, nous permet donc de corroborer les faits introduits par les revues scientifiques.

Par extension, il était donc primordial de prendre en considération l'évolution de la tuberculose afin d'avoir une représentation de cette co-infection. A cet égard, nous avons donc fait le choix de sélectionner comme variable : L'incidence de la tuberculose pour 100 000 personnes. De plus, cette variable explicative intègre divers paramètres, parmi lesquels figurent le taux de détection des cas de tuberculose, le taux de réussite du traitement de la tuberculose,...

Pour récapituler, nous prévoyons qu'une partie des variations du taux de mortalité du VIH par pays soient grandement conditionnées par l'incidence de la

⁵⁹ Zellweger, J. VIH et tuberculose : nouvelles perspectives de diagnostic et de traitement, *Rev Med Suisse*, Vol. -8, no. 087, 2006, pp. 2616–2619. (Consulté le 22/10/2022)

⁶⁰ Kettani, Assiya El et al. “Co-infection VIH ... du CHU Ibn Rochd-Casablanca”. *The Pan African medical journal* vol. 30 276. 16 Aug. 2018, doi:10.11604/pamj.2018.30.276.13913 (Consulté le 22/10/2022)

⁶¹

[https://www.who.int/fr/news-room/fact-sheets/detail/millennium-development-goals-\(mdgs\)](https://www.who.int/fr/news-room/fact-sheets/detail/millennium-development-goals-(mdgs)) (Consulté le 22/10/2022)

⁶² <https://www.inspq.qc.ca/en/node/927> (Consulté le 22/10/2022)

tuberculose, ces deux pathologies étant étroitement interdépendantes et de surcroît qu'elles évoluent dans le même sens notamment étayer par leurs corrélation positive.

e -Pourcentage de la population vivant sous traitements antirétroviraux (TAR)

Les traitements antirétroviraux (TAR) sont des médicaments utilisés pour traiter l'infection par le virus de l'immunodéficience humaine (VIH). Ils visent à empêcher, ou au moins, à ralentir la réplication du VIH dans l'organisme, à rendre la charge virale VIH "indéetectable", à réduire les risques de transmission et également à maintenir le système immunitaire en bon état de fonctionnement, permettant alors une survie presque similaire à celle de la population non infectée⁶³.

Ces traitements sont disponibles dans les pays développés depuis 1996 et l'OMS a œuvré en 2003 pour la généralisation de l'accès à ces médicaments à travers l'initiative "Treating 3 millions by 2005". De plus, en 2006, elle recommandait aux pays d'établir une politique visant à fournir des soins et des traitements antirétroviraux gratuitement affirmant que ces questions constituaient une priorité en terme de santé publique mondiale⁶⁴.

En effet, de nombreuses recherches ont permis de mettre en évidence que l'accès à ces Traitements (TAR) entraînerait un ralentissement de l'évolution de la maladie du sida et une réduction de la mortalité pour les personnes atteintes y ayant eu accès : "Les taux de mortalité des personnes infectées par le VIH se sont beaucoup rapprochés des taux de mortalité généraux depuis l'introduction d'un traitement rétroviral hautement actif"⁶⁵.

Les chercheurs expliquent alors que "les traitements antirétroviraux ont fait du sida une maladie chronique. Les personnes infectées par le VIH n'ont plus en permanence la menace d'une mort prochaine"⁶⁶.

⁶³ Institut national de la santé et de la recherche médicale (Inserm). VIH et sida. Site internet : Inserm. Paris ; 2018 [consulté le 30 octobre 2023]

⁶⁴ Gilks CF, Crowley S, Ekpini R, Gove S, Perriens J, Souteyrand Y, et al. The WHO public-health approach to antiretroviral treatment against HIV in resource-limited settings. *Lancet* 2006;368:505-510)

⁶⁵ Bhaskaran K, Hamouda O, Sannes M, et al. Changements dans le risque de décès après séroconversion par le VIH par rapport à la mortalité dans la population générale. *JAMA*. 2008; 300(1):51-59. doi :10.1001/jama.300.1.51

⁶⁶ LERT, France, OBADIA, Yolande, *et al.* Comment vit-on en France avec le VIH/sida?. *Population Societes*, 2004, vol. 406, no 10, p. 1-4.

De plus, à titre d'exemple, entre 2003 et 2014 au KwaZulu-Natal l'espérance de vie aurait augmenté de plus de 15 ans (selon l'observatoire de population uMkhanyakude) et 80% de cette amélioration serait liée à la réduction de la mortalité due à la tuberculose et au VIH grâce à la généralisation des traitements contre le VIH⁶⁷.

Pour ces raisons, nous avons décidé d'inclure dans notre étude la variable sur l'accès aux traitements antirétroviraux en posant l'hypothèse qu'elle aurait une importance significative dans l'explication du taux de mortalité lié au sida et qu'il existerait une corrélation négative entre ces deux variables. Les données utilisées ont été trouvées sur le site de l'UNAIDS et correspondent au pourcentage par pays du nombre de personnes vivant avec le SIDA et ayant reçu un traitement antirétroviral.

4) Autres variables

En définitive, notre étude comportera 13 variables (1 illustrative et 12 actives). Néanmoins, il convient de mentionner que nous avons envisagé d'inclure d'autres variables telles que le nombre de médecins, l'inflation, le taux de chômage ou encore le taux d'alphabétisation qui peuvent jouer un rôle quant à l'accès aux soins et aux dispositifs de prévention (en raison du prix ou du manque de connaissances et de moyens). Cependant, ces variables impactent de manière négative l'inertie de notre modèle lors de la réalisation de l'ACP notamment en raison du nombre de données manquantes. Ainsi, nous décidons de ne pas les inclure dans notre analyse.

De plus, nous avons l'intention d'intégrer dans cette étude des variables sur les pratiques sexuelles et les comportements à risque (le nombre de travailleurs du sexe, le nombre de personnes qui se droguent, la polygamie ou encore le nombre de prisonniers...), sur la prévention (taux de dépistage, nombre de campagnes de prévention menées, prix moyen des préservatifs...), ainsi que sur les inégalités économiques et sur d'autres maladies opportunistes (candidose, pneumocystis carinii,

⁶⁷ G. Reniers, S. Blom, C. Calvert, A. Martin-Onraet et al., « Trends in the burden of HIV mortality after roll-out of antiretroviral therapy in KwaZulu-Natal, South Africa: An observational community cohort study », *Lancet HIV*, 4(3), p. e113-e121, 2017

sarcome de Kaposi...). Cependant, en raison de l'absence de données pour l'année 2020, nous n'avons pas pu les prendre en compte.

C) Statistiques descriptives et corrélations entre le taux de mortalité du Sida et les variables actives

Après avoir examiné la littérature, nous sommes maintenant en mesure d'analyser les statistiques descriptives de notre modèle. Nous présenterons alors dans cette partie un tableau récapitulatif des variables utilisées (1), leurs statistiques descriptives (2) ainsi que les corrélations existantes entre elles (3).

1) Tableau récapitulatif du modèle

Tableau 1 : Tableau récapitulatif de la revue de littérature

Nom de la variable	Correspondances Rstudio	Corrélation attendue	Description	Source
L'incidence de la tuberculose pour 100 000 personnes	TUB	POSITIVE	Représente le nombre estimatif des nouveaux cas de tuberculose pulmonaire ou extra-pulmonaire à frottis positif pour 100 000 habitants.	BANQUE MONDIALE
Part de la population active en %	POPA	POSITIVE	Représente le pourcentage de population active par pays.	BANQUE MONDIALE
Stabilité politique	POL	NÉGATIVE	Les perceptions de la probabilité d'instabilité politique et/ou de violence politiquement motivée, y compris le terrorisme.	BANQUE MONDIALE
Part du produit intérieur brut (PIB) consacrée au ministère de la Santé	SANTE	NÉGATIVE	Les estimations des dépenses actuelles de santé comprennent les biens et services de soins de santé consommés chaque année	BANQUE MONDIALE
Le revenu national brut annuel	RNB	NÉGATIVE	Il s'agit du revenu national brut, converti en dollars américains au moyen de la méthode Atlas de la Banque mondiale, divisé par la population en milieu d'année.	BANQUE MONDIALE
L'accès à l'électricité	ELEC	NÉGATIVE	L'accès à l'électricité est le pourcentage de la population ayant accès à l'électricité.	BANQUE MONDIALE


Accès aux TAR	ATV	NÉGATIVE	Représente le % de personnes vivant avec le VIH et ayant reçu un traitement antirétroviral	UNAIDS
% de femmes dans la société	FEM	NÉGATIVE	Représente le % de femmes dans chaque pays	BANQUE MONDIALE
Accès à l'eau potable	EAU	NÉGATIVE	Pourcentage de la population utilisant des services d'eau potable gérés de façon sécuritaire	BANQUE MONDIALE
% de population urbaine	POPU	INCERTAIN	Représente la population urbaine en pourcentage de la population totale	BANQUE MONDIALE
PIB par habitant	PIB	NÉGATIVE	Il s'agit du PIB par habitant converti en \$ courants au moyen des taux de parité des pouvoirs d'achat.	BANQUE MONDIALE
Espérance de vie	VIE	NÉGATIVE	Mesurée en nombre d'années	BANQUE MONDIALE
Taux de mortalité du VIH/sida	VIH	X	Nombre de décès liés au sida pour 1000 habitants	UNAIDS

Source des données :auteurs

2) Analyse des statistiques descriptives et des valeurs aberrantes


a) Etude statistique du taux de mortalité du VIH

Figure 3 : Statistique descriptives et boxplot de la variable illustrative



Source des données :auteurs

Figure 4 :Représentation graphique de la distribution du taux du SIDA



Source des données :auteurs

En analysant les statistiques descriptives, nous pouvons examiner la disparité entre la moyenne et la médiane, en utilisant l'écart-type comme indicateur. Il est clair que l'écart-type présente une valeur élevée, ce qui suggère une grande variabilité dans la distribution de la variable explicative. En outre, il est évident que les valeurs aberrantes exercent une forte influence sur la moyenne, ce qui se traduit par une moyenne significativement éloignée de l'interquartile. Par exemple, des pays comme le Lesotho, avec une valeur de [2,53], ont un impact considérable sur la moyenne de la variable explicative. Par conséquent, dans nos futurs modèles de régression logistique, il sera judicieux de privilégier l'utilisation de la médiane afin de réduire l'influence des valeurs aberrantes.

b) Etude statistique des variables actives

Tableau 2 :Tableau des statistique descriptives des variables actives


Tableau statistique descriptives						
	FEM	RNB	POL	PIB	ELEC	POPA
MIN	27,35	460	2,358	895	10,87	23,36
IQ	49,74	1420	33,491	3972	76,81	36,16
MEDIAN	50,34	3610	49,528	11137	99,51	43,41
MEAN	50,02	10056	51,848	17315	84,06	42,76
3Q	50,89	7910	69,811	20317	100	49,64
MAX	53,86	79580	99,528	120010	100	74,16
VAR	10,7515	278135684	682,3971	450194365	697,3886	83,9823
SD	3,2789	16677,4004	26,1227	21217,7842	26,4081	9,1642
	POPU	VIE	EAU	SANTÉ	TUB	ATV
MIN	2,613	52,78	6,158	17,43	3,2	11
IQ	4,468	66,41	29,714	38,53	25	49
MEDIAN	6,242	71,97	56,730	58,36	69	63
MEAN	6,585	70,85	57,872	57,79	125,8	60,55
3Q	8,477	74,98	85,072	77,16	181	75
MAX	15,534	83,06	100	99,23	592	95
VAR	485,336	51,1070	896,0341	7,2112	19051,7828	419,8623
SD	22,0303	7,1489	29,9338	2,6854	138,0282	20,4905

Source des données :auteurs

Les statistiques descriptives (Tableau 2) nous permettent d'analyser les distributions de nos variables, en particulier grâce à l'écart-type, qui indique la dispersion des données par rapport à la moyenne. Ces distributions peuvent également être représentées graphiquement.

Notre tableau nous permet de constater que certaines de nos variables actives présentent des médianes et des moyennes similaires, indiquant alors une certaine symétrie dans la distribution et un faible impact des valeurs aberrantes s'il y en a. Cela suggère que la distribution des valeurs de ces variables est relativement homogène. Cependant, certaines de nos variables affichent des écarts-types élevés, ce qui signifie que des valeurs extrêmes aussi appelées valeurs atypiques vont être susceptibles d'exercer une influence sur la volatilité de ces variables. Ces distributions sont alors plus hétérogène comme nous pouvons également le constater grâce aux boîtes à moustaches (Figure 5). C'est particulièrement notable pour l'incidence de la tuberculose, le PIB, et le revenu national brut annuel ou encore l'accès à l'électricité.

Figure 5 : Boxplots des variables actives



Source des données : auteurs

Nos boîtes à moustaches (boxplots) nous permettent également de visualiser la présence de valeurs atypiques. En effet, il est fréquent de constater des valeurs atypiques lorsque la distribution d'une variable est hétérogène et que l'écart type est élevé. Ainsi, nous pouvons voir que des valeurs semblent atypiques pour les variables : espérance de vie, PIB, accès à l'électricité, population active, dépenses de santé, RNB, part de femme et tuberculose (Figure 5) et pour le taux de mortalité (Figure 4).


Il est possible de tester la présence de ces valeurs atypiques à l'aide du test de Grubbs lorsqu'on identifie qu'une seule valeur aberrante, du test de Rosner lorsqu'on en identifie entre 2 et 10 et du test ESD lorsqu'on en identifie plus de 10.

Nous avons alors mené ces tests sur les variables pour lesquelles nous avons identifié à l'aide des boxplots des valeurs atypiques. Il a donc été déterminé qu'il existait 1 outlier pour les variables population active et santé, 3 pour la variable tuberculose, 4 pour le PIB, 2 pour la part de femme, 0 pour l'électricité et plus de 10 pour le RNB et le taux de mortalité du SIDA (Annexe 1 à 9)

Nous tenons à mentionner que nous allons conserver ces valeurs pour notre analyse pour plusieurs raisons. Premièrement, les retirer pourrait nous faire perdre trop d'informations en appauvrissant notre base de données ce qui introduirait un biais dans les résultats. Ensuite, ces valeurs peuvent refléter des situations médicales réelles et légitimes en raison de facteurs ou contextes exceptionnels, il est alors important de les conserver dans notre cas d'autant plus que notre objectif est justement de refléter la diversité des situations médicales afin de comprendre les facteurs qui influencent le taux de mortalité du SIDA. Enfin, étant donné que ces valeurs aberrantes sont légitimes et ont une explication, leur suppression pourrait être perçue comme contraire à l'éthique, or, dans le domaine de la santé publique, l'éthique et la transparence sont des valeurs importantes.

3) Analyse de la corrélation entre la variable illustrative et les variables actives.

Figure 6 : Infographie des corrélations entre les variables



Source des données :auteurs

Tableau 3 : Tableau des statistique descriptives des variables actives

NOM DE LA VARIABLE	TUB	POPA	POL	SANTE	RNB	ELEC
CORRELATION ATTENDUE	POSITIVE	POSITIVE	NEGATIVE	NEGATIVE	NEGATIVE	NEGATIVE
CORRELATION OBTENUE	POSITIVE	NEGATIVE	NEGATIVE	ABSENCE	NEGATIVE	NEGATIVE
NOM DE LA VARIABLE	ATV	FEM	EAU	POPU	PIB	VIE
CORRELATION ATTENDUE	NEGATIVE	NEGATIVE	NEGATIVE	INCERTAINE	NEGATIVE	NEGATIVE
CORRELATION OBTENUE	POSITIVE	POSITIVE	NEGATIVE	NEGATIVE	NEGATIVE	NEGATIVE

Source des données :auteurs

Notre tableau de corrélations (Figure 6) ainsi que nos graphiques de corrélations (Annexe 10 à 20), qui illustrent les relations entre les variables actives et la variable illustrative, nous permettent de vérifier les hypothèses formulées dans notre revue de littérature concernant nos variables.

Ainsi, nous constatons que la plupart de nos hypothèses sont en accord avec les constatations de la littérature, notamment en ce qui concerne des variables telles que l'accès à l'électricité ou l'espérance de vie. Nous pouvons par ailleurs souligner que la corrélation entre l'espérance de vie et le taux de mortalité est fortement négative. En parallèle, l'incidence de la tuberculose et le taux de mortalité possèdent une corrélation positive importante. Ces deux variables pourraient alors contribuer à influencer le taux de mortalité du SIDA. Cette hypothèse pourra être vérifiée grâce à l'ACP et aux différentes régressions.

Cependant, il convient de noter que trois variables, à savoir le pourcentage de la population active, le pourcentage d'individus infectés par le VIH sous traitement antirétroviral (TAR), et la part de femme dans la société, ne présentent pas une corrélation conforme à ce qui a été établi dans notre revue de littérature. Nous pouvons alors chercher des explications à cela.

Tout d'abord, nous avons mentionné dans la revue de littérature une corrélation positive entre la part de la population active et le taux de mortalité du SIDA. Cependant, nous obtenons une corrélation négative. Cela ne semble pas si aberrant puisque la population active est aujourd'hui celle qui peut le plus facilement avoir accès aux soins de santé et qui est également mieux informée et sensibilisée sur le SIDA. Elle peut donc adopter pour ces raisons des comportements plus sécuritaires. Ainsi, la divergence entre nos résultats et la revue de littérature peut être due à la variabilité temporelle. En effet, à l'époque où ces recherches ont été menées, la population active pouvait être la plus touchée pour les raisons évoquées mais de nos jours ce ne serait plus le cas en raison des actions de sensibilisation qui ont été menées.

Ensuite, concernant le pourcentage de personnes infectées par le VIH sous traitements antirétroviraux, la corrélation positive avec le taux de mortalité du sida pourrait être due à des difficultés d'observance du traitement par exemple en raison de difficultés économiques ou encore à une prise en charge trop tardive des patients. Enfin, au sujet de la part de femmes dans la société, la corrélation positive observée avec le taux de mortalité du VIH pourrait être liée à la prévalence du VIH chez les femmes, à des situations de vulnérabilité plus nombreuses que pour les hommes, à des difficultés économiques et sociales rendant difficile l'accès aux soins ou à l'éducation notamment dans certaines régions du monde.

Il est néanmoins important de souligner que la plupart de ces constats vont à l'encontre de ce qui a été mentionné précédemment dans la littérature et des tendances générales observées. Ainsi, nous supposons que les résultats de ces corrélations, surtout celles concernant les variables ATV et FEM avec la variable VIH pourraient être biaisés. Cela pourrait être lié à la conservation de valeurs aberrantes. En effet, une seule valeur atypique peut considérablement influencer la corrélation et son sens en particulier si elle est très éloignée du reste de la distribution. Cette hypothèse nous semble être la plus probable pour justifier de ces différences.

Enfin, le graphique des corrélations (Figure 6) nous informe sur les relations entre les variables actives, nous aidant ainsi à expliquer les prémices des variables latentes. En effet, une corrélation positive entre des variables telles que le revenu national brut et le produit intérieur brut suggère une contribution conjointe à la création d'un même axe dans la même direction. À l'inverse, une corrélation négative peut être observée, par exemple, entre l'incidence de la tuberculose et l'espérance de vie, indiquant des relations opposées entre ces deux variables.

III. Analyse en Composantes Principales ACP

Grâce à notre revue de littérature détaillée et à notre analyse approfondie des statistiques descriptives de l'ensemble de nos variables, nous pouvons dès lors, procéder à notre Analyse en Composantes Principales (ACP). Cette méthode, utilisée pour des variables quantitatives, a été développée dans les années 1930 par Harold Hotelling, économiste et statisticien qui s'est inspiré des travaux de Karl Pearson et Charles Spearman. Elle vise à réduire la dimensionnalité d'un ensemble de variables initiales grâce à l'identification des variables les plus influentes et la définition de variables latentes permettant alors leur utilisation dans des modèles de régressions.

Notre Analyse en Composantes Principales (ACP) portera sur une base de données comprenant 73 pays après un processus de nettoyage de cette base. Cette ACP nous permettra d'une part de constater le pourcentage d'inertie du nuage de points expliqué par chacune de nos dimensions (A), cela nous aidera à savoir combien d'axes conserver afin de garder le plus d'informations possible. Ensuite, nous procéderons à l'étude de nos variables actives en identifiant notamment les plus contributives à l'explication de l'inertie (B) et en les projetant dans un cercle de corrélation (C) afin d'identifier les relations qui les lient. À partir de cette projection, nous serons alors en mesure de nommer les variables latentes, une étape essentielle pour nos futures analyses de régression (D). Enfin, nous effectuerons une projection des individus pour valider le choix de nos variables latentes (E).

A) Valeurs propre et nombre d'axes

Dans un premier temps, nous allons grâce à une diagonalisation de notre matrice de Variances-Covariances trouver les valeurs propres (ou eigenvalues). Ces mêmes valeurs propres, nous renseigneront aussi bien sur le pourcentage d'inertie du nuage de points expliqué par chaque dimension que sur le pourcentage d'inertie totale que nous pouvons espérer conserver en réduisant les dimensions aux deux ou trois premiers axes.


Figure 7 : Résultat de la diagonalisation

Eigenvalues	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5	Dim.6	Dim.7	Dim.8	Dim.9	Dim.10	Dim.11	Dim.12
Variance	5.837	1.458	1.283	0.824	0.680	0.486	0.433	0.355	0.337	0.154	0.121	0.034
% of var.	48.639	12.146	10.688	6.866	5.665	4.048	3.607	2.957	2.809	1.284	1.006	0.284
Cumulative % of var.	48.639	60.785	71.473	78.339	84.004	88.052	91.660	94.616	97.425	98.710	99.716	100.000

Source des données :auteurs

Grâce aux résultats de la diagonalisation, nous pouvons voir qu'il existe 12 axes (nommés dimensions) participant à l'explication de l'intégralité du nuage de points. Nous pouvons voir que l'axe 1 permet déjà de capturer presque la moitié de l'inertie (49%) (Figure 7). De plus, nous pouvons remarquer qu'en conservant uniquement les trois premières dimensions, nous arrivons jusqu'à l'explication de plus de 70% d'inertie. Nous allons donc conserver uniquement ces dimensions pour le reste de l'analyse d'autant plus que grâce à une modélisation du cumul de nos variances, telle qu'illustrée l'histogramme suivant (Figure 8), nous sommes en mesure d'identifier deux points cruciaux, également désignés sous le terme de points de rupture. Le premier de ces points marque la transition entre les première et deuxième dimensions. En effet, la première dimension explique déjà approximativement 50 % de l'inertie, ce qui constitue le premier point de rupture majeur en termes d'inertie. Le deuxième point de transition se produit entre les troisième et quatrième dimensions.

Figure 8 : Histogramme des pourcentage des variances




Source des données :auteurs

Cependant, comme les trois premiers axes permettent de capturer environ 75 % de l'inertie, cela signifie qu'ils capturent l'essentiel de l'information et nous nous concentrerons alors uniquement eux pour la suite de l'étude.

B) Variables : contributions, coordonnées, cosinus carrés

Nous allons dans cette partie analyser les liens qui existent entre nos différentes variables actives et les axes afin d'avoir un premier aperçu sur l'interaction et le placement des variables.

Figure 9 : Représentation de la contribution, coordonnées et cos2



Source des données : auteurs

Coordonnées :

Pour commencer, nous allons nous intéresser aux coordonnées des variables afin de connaître leurs positions dans le cercle de corrélation (numéro du cadran) et de savoir si elles contribuent à la création des axes dans leur sens positif ou négatif.

Le graphique sur les coordonnées (Figure 9a) présente les coordonnées des variables sur chacune des dimensions. Un rond est également représenté afin d'illustrer l'éloignement plus ou moins important de la variable au barycentre du cercle (largeur du rond) et du côté positif ou négatif (rouge ou bleu).

Nous pouvons alors constater que pour l'axe 1, presque toutes les variables ont des coordonnées importantes et positives, ce qui signifierait qu'elles participeraient à la création de l'axe 1 dans son sens positif, en revanche, la tuberculose, ayant également des coordonnées importantes participerait à la création de l'axe dans son sens négatif. Leur importance relative dans la création de l'axe sera ensuite vérifiée à l'aide des contributions et des cosinus carrés.

Pour l'axe 2 la variable sur la proportion de femmes à les coordonnées positives les plus éloignées du barycentre, elle participera donc certainement à la création de l'axe 2 dans son sens positif, tout comme les dépenses de santé peut être mais dans une moindre mesure et la population active et la tuberculose y participeront sans doute également mais dans la création de l'axe dans son sens négatif.

Enfin concernant l'axe 3, on constate que c'est la variable sur les traitements antirétroviraux qui a les coordonnées positives les plus importantes.

Ce graphique sur les coordonnées nous donne aussi l'occasion d'envisager le positionnement des variables dans le cercle de corrélation. Par exemple, la variable sur le PIB devrait se situer dans le cadran IV du cercle de corrélation représentant les axes 1 et 2 puisque cette variable a des coordonnées positives sur l'axe 1 mais négative sur l'axe 2. Quant à la tuberculose, elle en raison de ses deux coordonnées négatives sur l'axe 1 et 2, elle devrait se positionner dans le cadran 3. Cela pourra être vérifié grâce à la projection des variables sur le cercle de corrélation (cf partie : C. Cercle de corrélation).

Contributions :

Le graphique sur les contributions (Figure 9b) nous permet d'identifier les variables participant le plus à la création des axes de dimensions grâce à l'indication de la proportion de chaque variable sur chaque dimension et grâce au cercle plus ou moins large et rouge. La somme des contributions sur une dimension étant égale à 100, plus le pourcentage de contribution d'une variable se rapproche de ce seuil, plus cela signifie qu'elle contribue à la formation de cet axe et plus le cercle est large et rouge dans notre graphique.

Ainsi nous constatons que pour l'axe 1, aucune variable ne contribue davantage que les autres à la formation de cet axe, leurs parts respectives sont assez similaires, même si on peut noter que l'espérance de vie, le PIB, l'accès à l'eau ou encore le revenu national brut sont légèrement plus élevée que les autres (variant entre 12 et 13%).

Concernant l'axe 2, on remarque que la proportion de femmes participe à 38,64% à la création de cet axe, viennent ensuite dans une moindre proportion les dépenses de santé et la population active.

Enfin pour l'axe 3, une variable participe à plus de la moitié de la création de cet axe. Il s'agit de l'accès aux traitements antirétroviraux à hauteur de 51,62%. On trouve ensuite l'accès à l'électricité (19%) et les dépenses de santé (12%).

Ces premiers constats nous seront utiles lors de la définition de nos variables latentes.

Cosinus carrés


Enfin, s'intéresser aux cosinus carrés (Figure 9c) nous permet d'apprécier la qualité de représentation de nos variables actives par rapport aux axes. Ainsi, plus le coefficient de la variable sur la dimension sera proche de 1, mieux celle-ci sera représentée. Ainsi, on peut remarquer que 5 de nos variables sont bien représentées par l'axe 1, il s'agit de l'espérance de vie, de l'accès à l'eau, du PIB, du RNB et de la population urbaine. Pour l'axe 2 il s'agit uniquement de la proportion de femmes et pour l'axe 3, la seule variable bien représentée est le pourcentage de personnes ayant reçu un traitement antirétroviral puisque le cosinus carré est supérieur à 0,5 (0,66).

On retrouve alors ici les variables que nous avons identifiées comme contributives. Celles-ci sont donc à la fois contributives et bien représentées par les axes auxquels elles sont associées.

C) Cercle de corrélation

Après avoir réalisé une première analyse de la position et de la contribution des variables à la création des axes, nous allons désormais les projeter en deux dimensions, d'abord sur les axes 1 et 2 et ensuite sur les axes 1 et 3. Cela nous permettra notamment de vérifier les constats effectués dans la partie précédente.

Figure 10 : Projection des variables actives sur les axes 1 et 2 du cercle de corrélation



Source des données : auteurs

Nous projetons premièrement nos variables sur le plan factoriel axe 1-axe 2 puisque ces deux axes sont ceux qui permettent de capturer le plus d'informations avec une inertie de 60%.

Au regard de ce graphique (Figure 10), nous pouvons donc confirmer l'ensemble de nos constats effectués en partie précédente concernant les coordonnées, contributions et cosinus carrés. En effet, on remarque la forte contribution des variables PIB, RNB, VIE, EAU, POPU et POPA notamment à la création de l'axe 1 dans son sens positif tandis que la variable femme semble davantage contribuer à l'axe 2 dans son sens positif.

Ce graphique, ainsi que le graphique des coordonnées (figure 8a) nous permet par ailleurs de voir qu'il y a des variables (groupes de variables) qui interagissent entre elles. En effet, on remarque par exemple que le PIB semble fortement corrélé positivement au RNB et à la stabilité politique et que l'espérance de vie semble fortement corrélée positivement à l'accès à l'eau. De plus, on peut souligner que l'ensemble des variables semblent bien représentées par les axes hormis les variables ATV et SANTÉ qui elles, au vu de leur coloration, ont un cosinus carré faible ($<0,5$) sur les dimensions 1 et 2. Enfin, on peut également mentionner qu'il y a une opposition par rapport à l'axe 1 de la tuberculose et de la proportion de femme par rapport à l'ensemble des autres variables. Concernant l'axe 2, on peut voir que lui oppose les variables FEM, SANTÉ, ATV, ELEC, EAU, VIE et POPU aux variables POL, RNB, PIB, POPA et TUB.

Nous avons ensuite procédé à la projection des variables sur les axes 1 et 3 (Figure 11) :

Figure 11 : Projection des variables actives sur les axes 1 et 3 du cercle de corrélation



Source des données : auteurs

Cette deuxième projection nous permet également de vérifier les constats effectués en partie (III-B). En effet, on peut notamment relever que la variable ATV est celle qui participe le plus à la création de l'axe 3 dans son sens positif et qu'elle est bien représentée par cet axe puisque son cosinus carré est $> 0,5$ vient ensuite l'électricité qui participe à sa création dans son sens négatif mais dans une bien moindre mesure.

On remarque également que TUB et FEM sont en opposition aux autres variables par rapport à l'axe 1 et que ELEC, VIE, EAU et POPU sont en opposition aux autres variables par rapport à l'axe 3.

Enfin, on peut souligner que l'ensemble des variables semblent là aussi bien représentées par les axes sauf la proportion de femme, la tuberculose et les dépenses de santé.

D) Définition des variables latentes

Après avoir analysé la position des variables (section III-B et III-C), nous pouvons identifier nos regroupements de variables, généralement appelés variables latentes. Cette étape est cruciale pour nos futures régressions. Pour attribuer des noms appropriés à ces variables latentes, il est essentiel d'examiner comment les variables se positionnent par rapport aux axes.

Tableau 4 : Tableau d'oppositions des variables selon les axes

	+ (cos2)	- (cos2)
Axe 1	Espérance de vie (0,81) Accès à l'eau potable (0,78) PIB/habitant (0,77) Revenu National Brut (0,70) Population urbaine en % (0,65) (Stabilité politique (0,48) Accès à l'électricité (0,48))	
Axe 2	Part de femme dans la population (0,56) Dépenses courantes de santé en % du PIB (0,24) (Accès à l'électricité (0,11))	Population active (0,15) Tuberculose (0,12)
Axe 3	Accès aux traitements antirétroviraux (0,66) (Dépenses courantes de santé en % du PIB (0,16))	Accès à l'électricité (0,24)

Source des données :auteurs

Nous pouvons remarquer que l'axe 1 se caractérise par une absence d'opposition significative entre les variables, privilégiant plutôt la consolidation d'une gamme de facteurs allant de l'espérance de vie (exerçant la plus grande influence) à l'accès à l'électricité. Par conséquent, ce regroupement de variables peut être interprété comme un **indicateur du développement des pays**. L'idée que les pays développés se

caractérisent par une espérance de vie élevée, un accès à l'eau potable, un PIB élevé, et d'autres indicateurs similaires, correspond à la compréhension commune du développement. Par conséquent, un pays affichant une espérance de vie élevée, un accès privilégié à l'eau potable, un PIB élevé, est généralement classé comme un pays développé. En revanche, les pays en voie de développement présentent des indicateurs inverses tels qu'un PIB plus modeste et une espérance de vie plus basse. En outre, notre revue de littérature indique que la santé globale d'un pays est intimement liée à l'évolution du taux de mortalité du SIDA, avec des liens directs tant du point de vue économique et politique. En somme, l'axe 1 qui représente environ 50% de l'inertie totale, pourrait alors constituer une bonne représentation de notre variable principale.

Pour l'axe 2, nous pouvons nous apercevoir que des oppositions significatives entre les variables se dessinent, avec en premier lieu la part de femmes dans la population qui exerce la plus grande influence, suivie des dépenses courantes de santé en pourcentage du PIB, opposées à la population active et à l'incidence de la tuberculose. Cette opposition entre les variables peut être interprétée comme un **indicateur de bien être médico-social**. En effet, l'augmentation de la part des femmes et des dépenses de santé dans une population peut être associée à un meilleur bien être médico-social en favorisant l'éducation, la santé familiale et la participation économique tandis que la diminution des cas de tuberculose notamment indique une meilleure santé. On pourrait imaginer, au vu des corrélations et de notre revue de littérature que le taux de mortalité du Sida se positionnerait en opposition de la part des femmes et des dépenses de santé par rapport à cette axe puisque notre revue de littérature met en évidence que lorsqu'un pays présente un bien être à la fois sur le plan médical et social (lorsque la part de femmes dans la population augmente, que les dépenses de santé augmentent, et que l'incidence de la tuberculose diminue), alors il y a un faible taux de mortalité du SIDA dans le pays. Cependant, nous devons noter que si le taux de mortalité se positionne ainsi, il sera alors corrélé positivement avec la tuberculose, ce qui paraît logique mais également avec la part de la population active ce qui va dans le sens de notre revue de littérature mais pas dans le sens des corrélations simples que nous avons observées dans la partie II-C-3. Nous pouvons également noter l'opposition entre des variables telles que la part de femmes dans la population et la population active. En effet, il est établi que la majorité de la population active est composée d'hommes, et les

pays du monde mettent en place divers programmes visant à favoriser l'intégration des femmes sur le marché du travail. Par conséquent, lorsque la part de femmes augmente dans un pays, la population active a tendance à diminuer dans la plupart des cas⁶⁸.

Finalement, il est raisonnable de conclure que cet axe 2 sur le bien-être médico-social est également susceptible de constituer une représentation possible de notre variable principale.

Pour finir, nous pouvons remarquer que pour l'axe 3 une opposition significative entre les variables se dessine. En effet, on constate que les variables sur l'accès aux traitements antirétroviraux et sur les dépenses courantes de santé en % du PIB (même si cette dernière variable ne semble pas très bien représentée par l'axe) sont opposées à l'accès à l'électricité. Cette opposition entre les variables peut être interprétée comme un indicateur de **vulnérabilité sanitaire**. En effet, l'accès à l'électricité peut être considéré comme un indicateur de développement tandis que les dépenses de santé, en particulier pour le traitement du VIH ou d'autres épidémies dévastatrices peuvent être perçue comme un défi de santé urgent nécessitant la mobilisation rapide de fonds financiers et peut donc davantage concerner les populations vulnérables. Ainsi, on pourrait imaginer que le taux de mortalité du sida soit corrélé positivement avec les variables ATV et dépenses de santé témoignant du caractère urgent de faire face à l'épidémie et concernant alors aujourd'hui davantage les populations vulnérables. Ainsi, une augmentation de personnes vivant avec un TAR, une augmentation des dépenses de santé et une diminution de l'accès à l'électricité correspondrait à une augmentation du taux de mortalité du SIDA. Cela semble aller en contradiction avec ce qui a été évoqué dans la revue de littérature mais peut s'expliquer comme nous venons de le faire. Ce troisième axe semble diverger de ce que nous avons identifié dans notre revue de littérature en ce qui concerne les deux variables qui présentent une corrélation positive avec cet axe. Toutefois, une analyse plus approfondie basée sur d'autres études nous permet de mieux comprendre cette apparente contradiction. En effet, il est important de noter que l'augmentation des dépenses de santé est généralement associée à une baisse de la mortalité des maladies induites par des épidémies, comme nous l'avons exposé dans notre revue de littérature. Cependant, il existe des situations exceptionnelles,


⁶⁸ « Chapitre 2. Évolutions dans les pays membres de l'OCDE et dans certaines économies non membres », *Perspectives économiques de l'OCDE*, vol. 82, no. 2, 2007, pp. 73-199.

notamment en période de crises mondiales, qui nécessitent une analyse plus nuancée. Un exemple pertinent est la crise du COVID-19, une épidémie fulgurante et mal connue, qui a imposé une augmentation significative des dépenses de santé pour lutter contre cette épidémie⁶⁹. Malheureusement, malgré ces dépenses, l'épidémie continue de faire des ravages. Ce cas particulier du COVID-19 reflète une exception à la règle générale. Nous pouvons transposer cette exception observée pour le COVID-19 à d'autres comme l'épidémie du VIH/SIDA. Par conséquent, en approfondissant notre revue de littérature scientifique et en prenant en compte des situations exceptionnelles, telles que l'épidémie de VIH/SIDA. L'axe 3 semble émerger comme une possible représentation de notre variable principale, bien que sa robustesse soit la moins prononcée parmi les axes.. En résumé, nous supposons, d'après la littérature et l'analyse du tableau d'opposition des variables (Tableau 4), que le taux de mortalité du VIH/SIDA devrait être corrélé négativement aux variables latentes 1 (l'indicateur du développement) et 2 (bien être médico-social) et corrélé positivement à la variable latente 3 (l'indicateur de vulnérabilité sanitaire).

Dans le but de vérifier la véracité de nos affirmations, nous pouvons analyser les cercles de corrélation en tenant compte de la place de notre variable illustrative : le taux de mortalité du SIDA.

Figure 12 : Projection de la variable illustrative SIDA sur les axes 1 et 2 du cercle de corrélation


⁶⁹ Mrozovski JM. Les dépenses de santé en temps de pandémie [Health costs in times of pandemic]. Actual Pharm. 2021 Jul;60(608):40-43. French. doi: 10.1016/j.actpha.2021.06.011. Epub 2021 Aug 26. PMID: 36339324; PMCID: PMC9617797.



Source des données : auteurs

Nous pouvons observer, grâce au cercle de corrélation (Figure 12) de l'axe 1 (niveau de développement) et l'axe 2 (bien être médico-social), que notre variable illustrative est négativement corrélée avec ces deux mêmes axes, confirmant ainsi la véracité de nos hypothèses de départ et de nos suppositions précédentes. De plus, nous pouvons remarquer que le taux de mortalité du SIDA tend à se rapprocher davantage de l'axe 1, nous suggérant une plus grande dépendance à l'axe 1 et donc à l'indicateur du niveau de développement qui jouerait un rôle plus significatif dans notre modèle. Tandis que l'angle formé avec l'axe 2 semble davantage se rapprocher de 90 degrés ce qui indiquerait une moindre dépendance entre notre variable illustrative et l'axe 2.

Figure 13 : Projection de la variable illustrative SIDA sur les axes 1 et 3 du cercle de corrélation



Source des données : auteurs

No ire).


E) Projection des individus sur le plan factoriel, interprétation

1) Projections de tous les individus


Après avoir analysé les résultats de notre Analyse en Composantes Principales (ACP) et projeté nos variables sur nos cercles de corrélation, nous sommes en mesure de projeter les individus, ce qui nous permettra de confirmer nos choix de noms pour les variables latentes, nous concentrons essentiellement notre analyse sur la projections des individus sur les axes 1 et 2.

Figure 14 : Représentation des variables latentes en fonctions des cadrans

a) Variables latentes 1 et 2




b) Variables latentes 1 et 3



Source des données :auteurs


Il est important de noter que les caractéristiques des individus, telles que les coordonnées, les contributions et les $\cos^2$, sont similaires à celles expliquées pour les variables. Ainsi, les coordonnées nous permettront de positionner les individus dans les cadrans (Figure 15), les contributions représentent le poids de chaque individu dans la création des axes ainsi un individus proche du barycentre aura une faible contribution (Cercle rouge dans les Figure 15 et Figure 16), et enfin les $\cos^2$ permettent de déterminer la qualité de la représentation de chaque individu par rapport à l'axe. Ces caractéristique nous permettront de réaliser notre projections des individus (Figure 15 et Figure 15)

Figure 15 : Projections des individus sur les axes 1 et 2



Source des données :auteurs

Figure 16 : Projections des individus sur les axes 1 et 3




Source des données :auteurs

Grâce à ces projections, nous pouvons voir la répartition des individus dans les cadrans, en accordant une attention particulière à leurs oppositions. Par exemple, nous pouvons observer que le pays 60, correspondant au Qatar, semble être l'un des individus participant le plus à la construction du plan. Afin d'avoir une analyse plus fine, nous allons par la suite exclure les observations proches du barycentre, les moins contributives.

2) Projections des 15 individus les plus contributifs

Pour notre analyse plus approfondie, nous décidons de projeter uniquement les 15 individus les plus contributifs à l'explication de nos variables latentes. Cela nous permet de construire un tableau d'opposition (similaire à celui créé pour les variables latentes) afin de vérifier la cohérence des noms des variables latentes par rapport aux pays projetés.


Figure 17 : Projections des 15 individus les plus contributifs sur les axes 1 et 2



Source des données : auteurs

Cette projections des 15 individus, nous permet ainsi de représenter les pays dans notre tableau d’opposition pour les axes 1 et 2 (Tableau 5).

Figure 18 : Projections des 15 individus les plus contributifs sur les axes 1 et 3



Source des données :auteurs

De même, Cette projections des 15 individus, nous permet ainsi de représenter les pays dans notre tableau d’opposition pour l’axe 3. (Tableau 5)

Tableau 5 : Représentation des 15 individus les plus contributifs en fonctions des cadrans représentant l’axe 1 et l’axe 2

CADRAN II : AFGHANISTAN(1)	CADRAN I : FRANCE (22) ESPAGNE(19)
CADRAN III : RDC(10) TCHAD(66) CENTRAFRIQUE(8)	CADRAN IV : QATAR(60) OMAN(55)

Source des données :auteurs

En assimilant la représentation des individus en fonction des cadrans (Tableau 5) à la représentation de nos variables par cadran (Figure 14), nous pouvons confirmer notre hypothèse concernant la variable latente 1. En effet, les cadrans I et IV illustrent de manière significative les pays développés, notamment en représentant les nations du Golfe et d'Europe, en contraste avec les cadrans II et III qui dépeignent des pays en développement, principalement localisés en Afrique et en Asie centrale.

L'évaluation de notre hypothèse sur la variable latente 2 révèle une vérification fragmentaire. En effet, les cadrans III et IV représentent des pays présentant un mauvais bien être médico-social, tels que les nations africaines et celles du Golfe, en opposition aux cadrans I et II, où prédominent les pays européens caractérisés par un fort bien être médico-social. Cependant, il est important de noter des anomalies sur cet axe, notamment la présence de l'Afghanistan dans le cadran II. Cette divergence peut s'expliquer par le régime politique totalitaire du pays, entraînant une opacité dans la transmission des informations et influençant ainsi son positionnement dans le cadran II.

Tableau 6 : Représentation des 15 individus les plus contributifs en fonctions des cadrans représentant l'axe 1 et l'axe 3

CADRAN II : LESOTHO(38) MALAWI(49) CENTRAFRIQUE (8)	CADRAN I : DANEMARK (15) ISLANDE (32) LUXEMBOURG (40)
CADRAN III : PAKISTAN (56)	CADRAN IV : QATAR(60)

Source des données :auteurs

Nous pouvons observer que la représentation des 15 individus les plus contributifs semble toujours cohérente pour l'axe 1, en effet le cadran I et IV représentent toujours les pays d'Europe et du golf. Néanmoins pour l'axe 3, cette représentation des individus semble biaisée. Cela pourrait être lié à la conservation de nos valeurs aberrantes qui peuvent impacter la représentation des individus dans

l'espace et ainsi introduire des biais. Cela pourrait aussi être lié à l'hétérogénéité des individus comme nous avons pu le constater dans la partie Analyse des statistiques et des valeurs aberrantes (II-C.2).

IV. Corrélation entre le taux de mortalité du SIDA et les variables latentes identifiées

Après avoir identifié les variables latentes pouvant contribuer à l'explication de notre variable illustrative, nous allons à présent nous intéresser à l'impact que celles-ci pourraient avoir sur le taux de mortalité du SIDA. Pour se faire, nous réaliserons dans un premier temps une régression linéaire (A). Puis nous effectuerons une régression logistique (B), utile pour la classification.

A) Régression linéaire multiple

Dans cette partie nous allons réaliser trois régressions linéaires multiples, sur les dimensions 1 et 2 (1), sur les dimensions 1 et 3 (2) et sur les variables identifiées comme les plus contributives lors de l'ACP (3). Ensuite nous effectuerons les tests des résidus de chacun des modèles (4) avant de les comparer (5).

1) Résultats de la régression linéaire multiple effectuée avec les variables latentes des axes 1 et 2

Dans ce premier cas effectué sur les variables latentes 1 et 2, l'équation de régression linéaire peut s'écrire de la façon suivante selon nos hypothèses :

Taux de mortalité du SIDA = $\beta_0 - \beta_1 \text{ * Niveau de développement} - \beta_2 \text{ * Niveau de bien être médico-social} + \epsilon_i$

En réalisant la régression sur R nous obtenons alors les résultats suivants :
(Figure 19)

Figure 19 : Modèle 1 : Résultats de la régression linéaire multiple effectuée avec les variables latentes des axes 1 et 2

```

call:
lm(formula = VIH$SIDA ~ res.pca$ind$coord[, 1] + res.pca2$ind$coord[,
  2])

Residuals:
    Min       1Q   Median       3Q      Max
-0.36848 -0.17879 -0.04950  0.07363  2.08365

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    0.17986    0.04063   4.426 3.45e-05 ***
res.pca$ind$coord[, 1] -0.07253    0.01682  -4.312 5.19e-05 ***
res.pca2$ind$coord[, 2] -0.06471    0.03366  -1.922  0.0586 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3472 on 70 degrees of freedom
Multiple R-squared:  0.2415,    Adjusted R-squared:  0.2199
F-statistic: 11.15 on 2 and 70 DF,  p-value: 6.278e-05

```

Source des données :auteurs

Premièrement, au regard de la figure 19, nous pouvons constater qu'il existe au moins une de nos deux variables latentes qui soit statistiquement significative. En effet, la p-value associée au test Fisher Snedecor qui permet de vérifier cette hypothèse est inférieur à 5%. Lorsqu'on regarde les p-values du test de Student on peut remarquer qu'une seule de nos deux dimensions est significative dans l'explication du taux de mortalité du SIDA au seuil de 0,1%. En effet, il s'agit de la dimension 1 sur le niveau de développement. En revanche, le niveau de bien être médico-social n'est pas significatif au seuil de risque de 5%. Cela confirme nos constats effectués lors de la projection de la variable illustrative sur le plan de dimension 1 et 2.

En raison de la significativité de l'axe 1, nous pouvons alors réécrire l'équation en remplaçant son bêta par sa valeurs associée :

$$\text{Taux de mortalité du SIDA} = 0,180 - 0,073 \cdot \text{Niveau de développement} + \epsilon_i$$

Grâce à cette équation, nous pouvons constater que la dimension 1 sur le niveau de développement impacte négativement le taux de mortalité du SIDA comme nous avons pu le supposer précédemment.

Ainsi, cela signifie que si l'indicateur du niveau de développement augmente d'un point, alors le taux de mortalité du sida pour 1000 habitants diminuera de 0,073 points toute chose égale par ailleurs. Enfin, nous pouvons relever que le R2 du modèle est de 0,24, ce qui signifie que seulement 24% des variations du taux de mortalité du SIDA peuvent être expliquées par cette première modélisation. Nous devons également nous assurer de la normalité des résidus afin de valider ces interprétations (IV-A.4).

2) Résultats de la régression linéaire multiple effectuée avec les variables latentes des axes 1 et 3

Dans ce deuxième cas, l'équation de régression linéaire peut s'écrire de la façon suivante selon nos hypothèses :

$$\text{Taux de mortalité du SIDA} = \beta_0 - \beta_1 * \text{Niveau de développement} + \beta_2 * \text{Niveau de vulnérabilité sanitaire} + \epsilon_i$$

En réalisant la régression sur R nous obtenons alors les résultats suivants : (Figure 20)

Figure 20 : Modèle 2 : Résultats de la régression linéaire multiple effectuée avec les variables latentes des axes 1 et 3

```
> summary(reg2)

Call:
lm(formula = VIH$SIDA ~ res.pca$ind$coord[, 1] + res.pca$ind$coord[,
  3])

Residuals:
    Min       1Q   Median       3Q      Max
-0.48980 -0.13231 -0.05133  0.05218  1.79773

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    0.17986    0.03808   4.724 1.16e-05 ***
res.pca$ind$coord[, 1] -0.07253    0.01576  -4.602 1.82e-05 ***
res.pca$ind$coord[, 3]  0.12548    0.03362   3.732 0.000383 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3253 on 70 degrees of freedom
Multiple R-squared:  0.334,    Adjusted R-squared:  0.315
F-statistic: 17.55 on 2 and 70 DF,  p-value: 6.632e-07
```

Source des données :auteurs

Nous pouvons tout d'abord relever que dans ce modèle les deux axes sont significatifs (selon la statistique de Fisher et la p-value du test de student) à hauteur de 0,1% de risque. On peut alors interpréter les coefficients associés à chacune de ces variables latentes sachant que le modèle s'écrit :

$$\text{Taux de mortalité du SIDA} = 0,180 - 0,073 \cdot \text{Niveau de développement} + 0,13 \cdot \text{Niveau de vulnérabilité sanitaire} + \epsilon_i$$

Au vu de cette équation, nous pouvons dire que le niveau de développement impact toujours de la même façon le taux de mortalité du SIDA et que le niveau de vulnérabilité impact positivement le taux de mortalité du sida à hauteur de 0,13 points pour une variation de 1 point de cette variable. Nous constatons également que le R² est de 0,33 ce qui signifie que ce modèle explique les variations du taux de mortalité du SIDA à hauteur de 33%.

3) Régression à l'aide des variables les plus contributives identifiées lors de l'ACP

Pour ce dernier modèle nous avons essayé d'incorporer seulement les variables identifiées comme contributives sur les dimensions 1 et 3 puisque selon les précédentes régressions, ce sont ces deux dimensions qui paraissent significatives dans l'explication de notre variable dépendante. Cependant, comme nous pouvons le constater (Figure 21), une seule variable est significative dans l'explication du taux de mortalité au seuil de risque de 0,1% selon la p-value du test de student. Il s'agit de l'espérance de vie qui impacte alors négativement le taux de mortalité du SIDA. Cela signifie qu'une augmentation d'1 point de l'espérance de vie fait diminuer le taux de mortalité du SIDA de 0.054 points. Ce modèle selon le R² permettrait d'expliquer 44% des variations du taux de mortalité du SIDA. Cette augmentation du R² par rapport aux autres modèles est liée à la conservation des variables les plus contributives selon l'ACP.

Figure 21 : Modèle 3 : régression linéaire à l'aide des variables les plus contributives sur les axes 1 et 3 identifiées lors de l'ACP

```
> summary(reg5)

Call:
lm(formula = VIH$SIDA ~ VIH$VIE + VIH$EAU + VIH$PIB + VIH$RNB +
    VIH$POPU + VIH$ATV)

Residuals:
    Min       1Q   Median       3Q      Max
-0.73490 -0.11977 -0.03062  0.05828  1.58607

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  3.505e+00  5.900e-01   5.942 1.17e-07 ***
VIH$VIE      -5.359e-02  9.791e-03  -5.474 7.35e-07 ***
VIH$EAU       3.450e-03  2.487e-03   1.387  0.170
VIH$PIB      -3.512e-06  6.202e-06  -0.566  0.573
VIH$RNB       7.917e-06  7.528e-06   1.052  0.297
VIH$POPU      1.283e-03  2.543e-03   0.504  0.616
VIH$ATV       2.953e-03  1.938e-03   1.524  0.132
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3071 on 66 degrees of freedom
Multiple R-squared:  0.4404,    Adjusted R-squared:  0.3895
F-statistic: 8.656 on 6 and 66 DF,  p-value: 5.96e-07

Source des données :auteurs
```

4) tests des modèles

Tableau 7 : Tableau des résultats des tests des modèles

	Descriptions du modèle	Skewness	Kurtosis	Hétéroscédasticité	Kolmogorov-smirov
Modèle 1	Axes 1 et 2	3.7	21.4	0.58316	0.008402
Modèle 2	Axes 1 et 3	3.3	17.33	0.9494	0.002297
Modèle 3	Variables les plus contributifs	2.6	15.18	0.901030	0.01203


Afin d'avoir les prémices d'une vérification de nos interprétation de nos variables, nous pouvons nous appuyer sur la représentation des résidus pour chaque modèle (Annexe 22 à 25) , néanmoins pour s'assure de la véracité de nos interprétations

sur la significativité de nos variables, nous devons prendre en compte la normalité des résidus. Ainsi, nous utiliserons les tests de skewness et kurtosis. Le test de skewness teste la symétrie de la distribution des résidus, tandis que la kurtosis s'intéresse à l'aplatissement de cette distribution. L'hypothèse H_0 correspond à une distribution symétrique et aplatie telle qu'une loi gaussienne.

Nous pouvons dès lors analyser, les résultats de nos tests paramétriques (Tableau 7 et Annexe 25 à 31). Nous pouvons constater que ces modèles ne valident ni le test de skewness ni celui de kurtosis au seuil de 5%. Néanmoins le test d'hétéroscédasticité est validé au seuil de 5%


Cependant, nous pouvons tout de même analyser les résultats. Ainsi, nous observons que nos trois modèles présentent une skewness strictement positive, différente de zéro, signifiant un décalage à droite de la médiane et donc une queue de distribution étalée vers la gauche (Figure 22). Nous notons également que les kurtosis sont positives et strictement différentes de 0, indiquant une distribution des résidus de manière leptokurtique par rapport à la loi gaussienne (Figure 23). De plus, l'acceptation du test d'hétéroscédasticité nous permet d'appliquer les MCO, suggérant ainsi que notre modèle est de bonne qualité et permet une interprétation adéquate."

Figure 22 : Comparaison d'une distribution d'une loi Gaussienne par rapport à une loi possédant une Skewness positive



Source des données : auteurs

Figure 23 : Comparaison d'une distribution d'une loi Gaussienne par rapport à une loi possédant une Kurtosis positive



Source des données :auteurs

Puisque la distribution des trois modèles ne semble pas correspondre à celle d'une loi gaussienne selon les tests paramétriques, le test non paramétrique que nous allons utiliser ne se base pas sur la distribution statistique mais sur les rangs. De plus, étant donné la nature de notre échantillon, nous appliquerons le test de KOLMOGOROV-SMIRNOV afin de vérifier la normalité des résidus. Pour ce test, l'hypothèse nulle (H_0) affirme la normalité des résidus au seuil de 5%.

Grâce au tableau des résultats des tests (Tableau 7), nous pouvons constater que, également au test paramétrique, le test de KOLMOGOROV-SMIRNOV est rejeté au seuil de 5% pour les 3 modèles. Néanmoins au seuil de 1% le test est presque accepté. Nous pouvons donc conclure que le modèle qui se rapproche le plus d'une distribution gaussienne est le modèle 1 néanmoins la distribution normale ne correspond à aucun de nos modèles.

5) Choix du modèle le plus performant

À la lumière des régressions effectuées et des tests réalisés, il est évident que le modèle 3 affiche la plus grande précision parmi les trois modèles. Cependant, le modèle 2 se distingue par la significativité de ses deux variables latentes, tandis que le modèle 1 présente une plus grande proximité avec une distribution normale, comme en témoigne la quasi-acceptation du test non paramétrique de Kolmogorov-Smirnov au seuil de 1% (cf. Tableau 8). Chaque modèle présente des avantages distincts, il serait donc plus judicieux d'apporter des modifications à notre modèle pour le rendre plus adapté à nos régressions, peut-être en appliquant une transformation logarithmique, par exemple.

Tableau 8 : Tableau des résultats des tests des modèles (p-value)

	variables significatives	R2 ajusté	p-value Skewness	p-value Kurtosis	p-value Homoscédasticité	p-value Kolmogorov- Smirnov
Modèle 1	Niveau de développement	0.22	0	0	0.58	0.0084
Modèle 2	Niveau de développement et Vulnérabilité sanitaire	0.31	0	0	0.94	0.0023
Modèle 3	Espérance de vie	0.39	0	0	0.90	0.0053


Source des données :auteurs

B) Relation entre la variable illustrative observée et prédite par RLM

Comme nous avons pu le voir précédemment, Tous chacun des modèles présente des avantages et inconvénients, cependant, afin de réaliser notre prédiction, nous allons utiliser le modèle 1 puisqu'il s'agit de celui qui a des résidus qui se rapprochent le plus d'une distribution normale. Ainsi, nous allons réaliser la prédiction uniquement sur ce modèle, proposant d'expliquer le taux de mortalité du SIDA grâce au niveau de développement d'un pays et à son niveau de bien-être médico-social, cela nous assurera les résultats de prédiction les plus fiables possibles par rapport aux autres modèles.

Tout d'abord nous pouvons remarquer que notre modèle prédit en majorité des taux de mortalité entre 0 et 0,05 pour les pays (Figure 24).

Figure 24 : Classement des prédictions effectuées :




Source des données : auteurs

Ensuite, grâce au graphique ci-dessous (Figure 25) nous pouvons avoir un meilleur aperçu concernant la qualité des prédictions réalisées à l'aide du modèle de régression 1. La droite rouge trace la situation pour laquelle les valeurs prédites seraient égales aux valeurs observées et donc là où la prédiction serait parfaite.

Ainsi, on peut constater que la prédiction semble correcte pour certains individus ayant un taux de mortalité du SIDA de 0 ou proche de 0. Cependant, on remarque que plus on s'éloigne de la valeur 0, plus la prédiction se détériore. Trois individus semblent par ailleurs avoir une prédiction très éloignée de leur valeur réelle, il s'agit des individus 38, 73 et 11 pour lesquels les prédictions sont 0,45 ; 0,38 et 0,42 (Annexe 32) alors que les valeurs observées sont respectivement 2,53 ; 1,40 ; 1,38. Il est intéressant de noter que les trois individus pour lesquels la prédiction est la plus mauvaise correspondent aux trois individus atypiques ayant un taux de mortalité du SIDA très élevé. Cela expliquerait leur moins bonne prédiction.

Finalement, les problèmes de prédiction peuvent être liés à des biais dans le modèle dus par exemple à la conservation de nos valeurs aberrantes ou à la forme fonctionnelle choisie qui peut ne pas être la bonne.

Figure 25 : Représentation des prédictions en fonction des observations



Source des données :auteurs

C) Régression logistique binaire

Suite à nos régression linéaire multiples, nous pouvons exécuter une autre régression, la régression logistique binaire, dans le but d'effectuer des classifications. La régression logistique binaire vise à convertir notre variable illustrative quantitative en variables binaire. Dans ce contexte, une valeur de 1 sera assignée aux individus dépassant un seuil spécifique sur la variable illustrative, et 0 sera attribué sinon. La détermination du seuil est une étape cruciale. En effet, le choix de la moyenne et de la médiane reste crucial pour le choix de prendre un seuil optimal. Afin de choisir le seuil nous nous appuierons sur la revue de littérature⁷⁰. Le choix de la médiane est donc privilégié. En effet, cette mesure possède de nombreux atouts, tels qu'une robustesse face aux valeurs atypiques là où nous savons que les nôtres peuvent poser problème. De plus, elle assure une représentation plus équilibrée de la distribution des individus en classifiant de manière équilibrée. Enfin, ce choix de la médiane permet une interprétation intuitive. Ainsi en choisissant la médiane, nous obtenons un seuil à 0,03 pour le taux de mortalité du SIDA (Figure 3).

1) Régression log 1 : Régression logistique sur les axes 1 et 2

Modèle 1: Résultats de la régression logistique effectuée avec les variables latentes des axes 1 et 2

```
Deviance Residuals:
    Min       1Q   Median       3Q      Max
-1.9328  -0.7555  -0.2173   0.5966   2.0761

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   -0.05235    0.30626  -0.171   0.8643
res.pca$ind$coord[, 1] -0.74208    0.17856  -4.156 3.24e-05 ***
res.pca$ind$coord[, 2] -0.62090    0.24040  -2.583  0.0098 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 101.186  on 72  degrees of freedom
Residual deviance:  65.917  on 70  degrees of freedom
AIC: 71.917

Number of Fisher Scoring iterations: 5
```

Source des données :auteurs

⁷⁰ Kleinbaum, D.G.; Klein, M. Logistic Regression for Correlated Data. In *Logistic Regression. Statistics for Biology and Health*; Springer: New York, NY, USA, 2010.

Dans un premier temps, nous procédons à la vérification de la classification binaire des observations. Prenons l'exemple du Danemark, ce pays affiche un taux de VIH inférieur à la médiane, et le modèle le binarise correctement en lui attribuant la valeur "0". Nous pouvons alors analyser les résultats de cette régression et remarquer que nos deux variables latentes sont significatives au seuil de 5% . De plus, l'AIC équivaut à 71,917.

2) Régression log 2 : Régression logistique sur les axes 1 et 3

Modèle 2 : Résultats de la régression logistique effectuée avec les variables latentes des axes 1 et 3

```
Deviance Residuals:
    Min       1Q   Median       3Q      Max
-1.9454  -0.8243  -0.1125   0.7265   1.9773

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)    -0.04285    0.31542  -0.136    0.892
res.pca$ind$coord[, 1] -0.74947    0.18587  -4.032 5.53e-05 ***
res.pca$ind$coord[, 3]  0.33240    0.31571   1.053   0.292
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 101.186  on 72  degrees of freedom
Residual deviance:  70.359  on 70  degrees of freedom
AIC: 76.359

Number of Fisher scoring iterations: 5

Source des données :auteurs
```

En premier lieu, nous procédons à la vérification de la classification binaire des observations. Prenons l'exemple du Malawi, ce pays affiche un taux de VIH supérieur à la médiane, et le modèle le binarise correctement en lui attribuant la valeur "1". Ainsi, nous pouvons analyser ce modèle. Nous pouvons remarquer que ces résultats révèlent toujours une signification pour l'axe 1. Cependant l'axe 3 ne présente pas de significativité. L'AIC équivaut pour ce modèle à 76,359.

3) Choix du meilleur modèle logistique.

Il est important de noter que l'AIC, nous permettra de choisir le modèle optimal entre nos 2 régressions. Ainsi notre Régression log 1 (Modèle 1) affiche un AIC inférieur au Régression log 2 (Modèle 2) démontrant donc une meilleure qualité du modèle 1, nous avons fait le choix de sélectionner la Régression log 1 (Modèle 1) comme régression logistique optimale. Il convient néanmoins de noter que le coefficient de la constante dans ce modèle n'est pas significatif. Suite au choix de notre modèle optimal nous pouvons ainsi interpréter les coefficients de régressions associés à nos variables latentes. Afin d'interpréter ces deux coefficients, nous devons les passer en exponentielle. Nous obtenons donc $\exp(\beta_1) = 0,48$ et $\exp(\beta_2) = 0,54$ en notant que β_1 et β_2 possèdent un coefficient négatif, cela signifie que la probabilité d'obtenir une mortalité élevée (classée 1 car plus grande que 0,03) augmentera lorsque ces variables diminueront.

Grâce à l'interprétation de nos coefficients (β_1 et β_2), nous pouvons expliquer notre modèle. Ainsi, la probabilité pour un pays d'obtenir un taux de mortalité supérieur à 0,03 sera 0,48 fois inférieur pour un pays ayant un bon développement tout chose égale par ailleurs. Cette probabilité sera 0,54 fois inférieure pour un pays ayant un fort bien être médico-social.

V. Modifications du modèle de régression

Comme nous avons pu le mentionner dans la partie précédente, les modélisations que nous avons effectuées ne se sont pas avérées très satisfaisantes, nous avons alors émis l'hypothèse que cela pourrait être lié au choix de la forme fonctionnelle linéaire qui pourrait ne pas être la bonne pour modéliser les facteurs influençant le taux de mortalité du SIDA. En effet, lorsqu'on regarde les graphiques de corrélation entre notre variable dépendante et chacune des autres variables, aucune relation linéaire ne peut vraiment être constatée. Ainsi dans cette partie nous avons décidé d'effectuer des tests afin de vérifier si la forme fonctionnelle linéaire est adaptée ou non (A) puis nous procéderons à la modification du modèle en un modèle log-linéaire (B).

Tests de Ramsey

Le test de Ramsey ou test d'erreur de spécification d'équation de régression permet de vérifier si la régression linéaire est adaptée pour la modélisation que l'on souhaite réaliser. Nous avons donc décidé de pratiquer ce test sur nos trois modèles afin de voir s'il est possible d'améliorer notre modèle grâce à un autre type de modélisation.

Ainsi, nous avons trouvé que les p-values de ce test associées à chacun de nos 3 modèles étaient inférieures à 0,05 (Annexe 33). Or, cela signifie que la forme fonctionnelle linéaire du modèle spécifié ne peut pas être acceptée au seuil de 5%. Nous avons donc décidé de pratiquer une transformation du modèle en modèle log-linéaire.

Modification de la forme fonctionnelle du modèle

Au vu de nos résultats de régression comportant à chaque fois la modification de la variable taux de mortalité en log, il semblerait que ces modélisations soient meilleures que celles que nous avons effectuées auparavant. En effet, pour chacune d'entre elles le R² a nettement augmenté, dépassant les 50% et elles ont permis à la variable latente 2 (bien être médico-social) d'être significative dans le modèle 1 reliant le taux de mortalité avec le niveau de développement et le bien être médico-social (Annexe 34 à 36).

Tableau 9 : Tableau récapitulatif des modèles

	Description s du modèle	Variables significative s	R2 ajustée	F-statistique	Residual Standard Error
Modèle 1	Axes 1 et 2	Axes 1 et 2	0.5137	39.03	1.071
Modèle 2	Axes 1 et 3	Axes 1 et 3	0.5275	41.19	1.056
Modèle 3	Variables les plus contributifs	VIE (1%)	0.641	22.43	0.9202

Source des données :auteurs

Afin d'orienter notre choix parmi les trois modèles, notre analyse repose sur divers critères répertoriés dans le Tableau 9. En premier lieu, nous évaluons la significativité des variables, conduisant à une préférence pour les modèles 1 ou 2 en raison de la signification de leurs variables latentes, contrairement au modèle 3 qui ne présente qu'une variable significative, à savoir l'espérance de vie. En deuxième lieu, nous nous appuyons sur le critère du R2 ajusté, indiquant une meilleure adéquation du modèle aux données. C'est ainsi que nous choisissons le modèle 3, affichant le R2 ajusté le plus élevé (0.641). En troisième lieu, la F-statistique est considérée, offrant des insights sur l'aptitude globale du modèle. Le constat est que le modèle 2 détient la F-statistique la plus élevée (41.19), suggérant une meilleure aptitude globale que les autres. Enfin, l'analyse des Residual Standard Error, mesurant la précision du modèle, révèle que le modèle 3 présente la plus petite erreur résiduelle (0.9202).

En conclusion, notre analyse repose précisément sur l'examen minutieux des variables, tout en tenant compte de la performance globale du modèle. Dans cette perspective, le modèle 2 est privilégié par rapport aux autres, le considérant comme le choix optimal, nous obtenons alors :

$$\text{Log (SIDA)} = -3,04 - 0,43\text{Variable latente 1} + 0,37 \text{ Variable latente 3}$$

$$\text{SIDA} = \exp(-3,04) + \exp(- 0,43\text{Variable latente 1}) + \exp(0,37 \text{ Variable latente 3})$$

Ainsi, nous procédons à l'analyse des coefficients du modèle optimal, à savoir le modèle 2. L'intercept, évalué à $\exp(-3,04)$, offre une vision de la valeur relative attendue lorsque toutes les variables latentes sont égales à zéro. Par la suite, le coefficient de la variable latente 1, $\exp(-0,43)$, exprime le facteur multiplicatif lié à un changement d'une unité dans la variable latente 1, en maintenant constantes toutes les autres variables. Enfin, la variable latente 2, évaluée à $\exp(0,37)$, représente le facteur multiplicatif associé à un changement d'une unité dans la variable latente 3, en maintenant constantes toutes les autres variables. Afin d'illustrer nos propos, nous pouvons affirmer que lorsqu'il y a un changement de 1 unité pour la variable latente 1, cela influencera négativement le taux de mortalité du SIDA. En revanche, pour la variable latente 3, un changement d'une unité aura une influence positive sur le taux de mortalité du SIDA.

VI. Discussion des résultats

A l'issue de l'ensemble de ces analyses, nous devons mentionner que la modélisation du taux de mortalité du SIDA s'est avérée compliquée. En effet, les modèles linéaires ne respectaient pas les hypothèses des moindres carrés ordinaires notamment concernant la normalité des résidus et les résultats obtenus n'étaient pas très satisfaisants en particulier concernant le R². Ainsi, nos résultats contiennent très probablement des biais.

Ces biais et résultats peuvent être expliqués par plusieurs raisons : des problèmes concernant l'échantillon des données (A), des problèmes concernant les variables sélectionnées (B) ou encore des problèmes concernant le choix du modèle (C).

A. Problèmes d'échantillon

Tout d'abord nous devons mentionner que notre échantillon est assez petit puisqu'il ne contient que 73 pays après le retrait des pays pour lesquels il nous manquait des données. Cela peut conduire à certains problèmes comme la diminution de la puissance statistique de l'analyse, une instabilité des estimations, une prédiction moins fiable ou encore à une plus grande difficulté à détecter des relations significatives.

Ensuite, au-delà du problème de la taille de notre échantillon, nous avons constaté grâce aux tests de Grubbs, Rosner et ESD que certains individus pouvaient avoir des valeurs aberrantes sur certaines variables. Or, comme nous avons fait le choix de ne pas les retirer pour ne pas perdre de l'information, ils ont pu contribuer à biaiser nos résultats et impacter l'ensemble de nos analyses en commençant par les corrélations. En effet, nous avons trouvé des corrélations suspectes entre le taux de mortalité du SIDA et certaines de nos variables actives. Là où nous aurions dû obtenir une corrélation positive entre la population active et le taux de mortalité, nous avons obtenu une corrélation négative et inversement pour les variables sur les traitements antirétroviraux et le pourcentage de femme. De plus, aucune corrélation n'a été observée entre les dépenses de santé et notre variable illustrative. Nous avons essayé d'expliquer ces différences de résultats par rapport à la littérature mais ils seraient en fait en partie liés à la conservation des valeurs aberrantes. En effet, on s'est aperçu qu'en

retirant de notre base de données les trois valeurs les plus aberrantes concernant les taux de mortalité, l'ensemble des corrélations obtenues correspondaient toutes à celles décrites dans la littérature sauf pour le pourcentage de personnes sous traitements antirétroviraux parmi la population infectée où il a été noté une absence de corrélation avec le taux de mortalité (Annexe 37).

Ces outliers ont également pu impacter la représentation des variables et des individus dans l'espace lors de l'ACP et fortement influencer les coefficients de nos régressions linéaires et logistiques et donc biaiser nos résultats. Cela expliquerait en partie l'incohérence de certains de nos résultats.

B. Problèmes de variables

Trois autres problèmes que nous pouvons relever concernent nos variables. En effet comme nous avons pu le mentionner, plusieurs des variables auxquelles nous avons pensé n'ont pas pu être incluses dans notre modèle en raison de l'indisponibilité des données. Cette omission involontaire impacte très certainement la qualité de notre modèle et explique que notre R^2 ne soit pas très élevé.

De plus, pour les variables que nous avons utilisées, les chiffres peuvent ne pas correspondre à la réalité. En effet, certains pays peuvent chercher pour des raisons politiques notamment à gonfler ou à faire baisser leurs chiffres selon ce qui les arrange.

Enfin, nous pouvons également nous questionner sur la pertinence du choix de certaines variables. Par exemple, pour inclure dans notre modèle une variable sur les dépenses de santé, nous avons fait le choix d'une variable sur les dépenses de santé en % du PIB. Cependant, un même pourcentage entre deux pays ne signifie pas que le même montant est alloué pour la santé. Donc cette variable ne rend pas forcément bien compte des disparités de budget octroyé pour la santé. Nous aurions peut-être dû simplement prendre en compte les dépenses de santé en \$.

C. Problèmes de modélisation

Enfin, le dernier problème que nous pouvons mentionner concerne nos choix de modélisation. Tout d'abord, le choix de l'ACP est pertinent lorsqu'une variable peut être impactée par une multitude de facteurs puisque cette méthode vise à réduire la dimensionnalité des données. Cependant, cela peut entraîner une perte d'information et peut donc affecter le modèle. De plus, cette méthode peut contribuer à faire baisser les problèmes de multicollinéarité entre les variables biaisant les coefficients de régression mais certains peuvent persister.

Pour finir, nous avons utilisé une régression linéaire pour modéliser les variations du taux de mortalité en fonction des variables identifiées lors de l'ACP, cependant, lorsque nous avons effectué les graphiques de corrélations (Annexe 10 à 20), aucune relation linéaire n'a pu réellement être observée. Ainsi, nous avons souhaité vérifier par des tests la pertinence de cette modélisation et avons constaté que la forme fonctionnelle linéaire ne convenait pas. Nous avons alors essayé de la modifier (V) et avons pu constater que la modification en forme log-linéaire permettait de faire augmenter le R^2 donc la qualité du modèle.

VII. Conclusions et recommandations

Pour conclure, nous pouvons dire, au regard de nos différents résultats et notamment du modèle final que nous sommes parvenu à réaliser, que le taux de mortalité du SIDA est une variable complexe dont l'explication fait intervenir une multitude de facteurs. Nous avons pu trouver que le niveau de développement du pays impactait négativement ce taux, là où le niveau de vulnérabilité sanitaire l'impactait positivement.

Selon cette modélisation, cela signifierait que plus un pays aurait un niveau de développement élevé et un contexte sanitaire favorable, plus le taux de mortalité serait bas. Cela rejoint les hypothèses émises dans notre revue de littérature.

Cependant, il convient de rester prudent quant à la validité de cette étude compte tenu des nombreuses limites qu'elle présente et que nous avons mentionnées. Il est alors nécessaire d'adopter une approche critique à l'égard de ces résultats.

Finalement, dans le prolongement de cette étude, il pourrait être intéressant à l'avenir de mener une étude plus approfondie sur le sujet en incluant notamment une plus grande diversité de variables et d'individus. Il pourrait également être pertinent de mener une analyse temporelle concernant l'évolution de la mortalité du VIH/SIDA dans différentes régions du monde. L'utilisation de données de panels pourrait alors être privilégiée. Cela permettrait de constater les disparités entre les pays par exemple concernant l'évolution de la mortalité du VIH/sida dans le temps.

VIII. Annexes

A) Tableaux et graphiques supplémentaires

Annexe 1 : Résultat du grubbs test sur la population actives

```
> grubbs.test(VIH$POPA)
```

```
Grubbs test for one outlier
```

```
data: VIH$POPA
```

```
G = 3.42727, U = 0.83459, p-value = 0.013
```

```
alternative hypothesis: highest value 74.16465 is an outlier
```

Source des données :auteurs

Annexe 2 : Résultat du grubbs test sur les dépenses courantes de santé

```
> grubbs.test(VIH$SANTE)
```

```
Grubbs test for one outlier
```

```
data: VIH$SANTE
```

```
G = 3.33227, U = 0.84364, p-value = 0.01953
```

```
alternative hypothesis: highest value 15.53361392 is an outlier
```

Source des données :auteurs

Annexe 3 : Résultat du grubbs test sur l'espérance de vie

```
> grubbs.test(VIH$VIE)
```

```
Grubbs test for one outlier
```

```
data: VIH$VIE
```

```
G = 2.52819, U = 0.90999, p-value = 0.3619
```

```
alternative hypothesis: lowest value 52.777 is an outlier
```

Source des données :auteurs

Annexe 4 : Résultat du ROSNER test sur l'incidence de la tuberculose

```
Number of Outliers Detected:      3
```

	i	Mean.i	SD.i	value	Obs.Num	R.i+1	lambda.i+1	Outlier
1	0	125.78767	138.02820	592	38	3.377660	3.273006	TRUE
2	1	119.31250	127.34314	540	8	3.303574	3.267957	TRUE
3	2	113.38732	117.83069	533	58	3.561149	3.262821	TRUE
4	3	107.39286	107.22419	428	48	2.990064	3.257596	FALSE

Source des données :auteurs

Annexe 5 : Résultat du ROSNER test sur le PIB / habitant

Number of Outliers Detected: 4

	i	Mean.i	SD.i	Value	Obs.Num	R.i+1	lambda.i+1	Outlier
1	0	17314.97	21217.784	120010.21	40	4.840055	3.273006	TRUE
2	1	15888.65	17490.926	94005.36	60	4.466128	3.267957	TRUE
3	2	14788.42	14896.327	60832.16	15	3.090946	3.262821	TRUE
4	3	14130.65	13926.686	59822.95	52	3.280918	3.257596	TRUE
5	4	13468.44	12870.785	54303.90	32	3.172725	3.252277	FALSE

Source des données :auteurs

Annexe 6 : Résultat du ROSNER test sur la part des femmes dans la population

Number of Outliers Detected: 2

	i	Mean.i	SD.i	Value	Obs.Num	R.i+1	lambda.i+1	Outlier
1	0	50.02491	3.2789450	27.35104	60	6.914989	3.273006	TRUE
2	1	50.33982	1.8871769	37.91465	55	6.583997	3.267957	TRUE
3	2	50.51482	1.1729254	47.00274	7	2.994293	3.262821	FALSE

Source des données :auteurs

Annexe 7 : Résultat du ROSNER test sur l'accès à l'électricité

Number of Outliers Detected: 0

	i	Mean.i	SD.i	Value	Obs.Num	R.i+1	lambda.i+1	Outlier
1	0	84.05920	26.40812	10.86568	66	2.771630	3.273006	FALSE
2	1	85.07578	25.11390	11.50000	49	2.929683	3.267957	FALSE
3	2	86.11206	23.69166	15.40571	8	2.984440	3.262821	FALSE

Source des données :auteurs

Annexe 8 : Résultat de l'ESD test sur le RNB

	i	Mean.i	SD.i	Value	Obs.Num	R.i+1	lambda.i+1	Outlier
1	0	10056.438	16677.400	79580	40	4.168729	3.273006	TRUE
2	1	9090.833	14595.538	62710	15	3.673668	3.267957	TRUE
3	2	8335.634	13206.926	62110	32	4.071679	3.262821	TRUE
4	3	7567.429	11594.983	58420	60	4.385739	3.257596	TRUE
5	4	6830.435	9891.432	50170	52	4.381526	3.252277	TRUE
6	5	6193.088	8417.474	41590	54	4.205171	3.246863	TRUE
7	6	5664.776	7256.728	39440	22	4.654332	3.241349	TRUE
8	7	5153.030	5971.106	27130	19	3.680553	3.235733	TRUE
9	8	4814.923	5343.072	26610	14	4.079128	3.230010	TRUE
10	9	4474.375	4619.921	19670	39	3.289153	3.224177	TRUE

Source des données :auteurs


Annexe 9 : Résultat de l'ESD test sur la mortalité du SIDA

```
names(newdf)=c("No. Outliers","Test Stat.", "Critical val.")
newdf
```

No. Outliers	Test Stat.	Critical val.
1	5.978871	3.273006
2	4.491083	3.267957
3	5.275201	3.262821
4	4.002898	3.257596
5	3.625936	3.252277
6	3.869007	3.246863
7	3.662800	3.241349
8	3.627865	3.235733
9	3.719420	3.230010
10	3.813812	3.224177
11	4.150033	3.218230
12	4.226058	3.212165
13	4.746224	3.205977
14	3.325657	3.199662
15	3.255264	3.193214
16	3.352576	3.186628
17	3.138949	3.179900
18	2.787559	3.173022
19	2.661473	3.165989
20	2.626725	3.158794
21	2.337282	3.151430
22	1.992415	3.143890
23	2.037263	3.136165
24	1.716138	3.128247
25	2.152785	3.120128
26	NaN	3.111796
27	NA	3.103243
28	NA	3.094456


Source des données :auteurs

Annexe 10 : Représentation de la corrélation entre le taux de mortalité et l'espérance de vie




Source des données :auteurs

Annexe 11 : Représentation de la corrélation entre le taux de mortalité et le PIB par habitant




Source des données :auteurs

Annexe 12 : Représentation de la corrélation entre le taux de mortalité et l'accès à l'électricité




Source des données :auteurs

Annexe 13 : Représentation de la corrélation entre le taux de mortalité et la population active




Source des données :auteurs

Annexe 14 : Représentation de la corrélation entre le taux de mortalité et le pourcentage de personne infectés sous traitement ATV




Source des données :auteurs

Annexe 15 : Représentation de la corrélation entre le taux de mortalité et les dépenses de santé courante




Source des données :auteurs

Annexe 16 : Représentation de la corrélation entre le taux de mortalité et la population urbaine




Source des données :auteurs

Annexe 17 : Représentation de la corrélation entre le taux de mortalité et l'incidence de la tuberculose.




Source des données :auteurs

Annexe 18 : Représentation de la corrélation entre le taux de mortalité et le pourcentage de femme dans la population




Source des données :auteurs

Annexe 19 : Représentation de la corrélation entre le taux de mortalité et l'indice de la stabilité politique




Source des données :auteurs

Annexe 20 : Représentation de la corrélation entre le taux de mortalité et le RNB




Source des données :auteurs

Annexe 22 : Représentation graphique de la distribution des résidus du modèle 1




Source des données :auteurs

Annexe 23 : Représentation graphique de la distribution des résidus du modèle 2



Source des données :auteurs

Annexe 24 : Représentation graphique de la distribution des résidus du modèle 3



Source des données :auteurs

Annexe 25 : Résultat des tests Skewness, Kurtosis, Hétéroscédasticité, ... du modèle 1

```
> gvlma(reg1)
```

```
Call:
lm(formula = VIH$SIDA ~ res.pca$ind$coord[, 1] + res.pca2$ind$coord[,
  2])

Coefficients:
      (Intercept)  res.pca$ind$coord[, 1]  res.pca2$ind$coord[, 2]
          0.17986                -0.07253                 -0.06471
```

```
ASSESSMENT OF THE LINEAR MODEL ASSUMPTIONS
USING THE GLOBAL TEST ON 4 DEGREES-OF-FREEDOM:
Level of significance = 0.05
```

```
Call:
gvlma(x = reg1)
```

	value	p-value	Decision
Global stat	1210.1362	0.00000	Assumptions NOT satisfied!
Skewness	167.9005	0.00000	Assumptions NOT satisfied!
Kurtosis	1035.6886	0.00000	Assumptions NOT satisfied!
Link Function	6.2461	0.01245	Assumptions NOT satisfied!
Heteroscedasticity	0.3011	0.58316	Assumptions acceptable.

Source des données :auteurs

Annexe 26 : Résultat des tests Skewness, Kurtosis, Hétéroscédasticité, ... du modèle 2

```
> gvlma(reg2)

Call:
lm(formula = VIH$SIDA ~ res.pca$ind$coord[, 1] + res.pca$ind$coord[,
  3])

Coefficients:
      (Intercept)  res.pca$ind$coord[, 1]  res.pca$ind$coord[, 3]
           0.17986                -0.07253                0.12548
```

ASSESSMENT OF THE LINEAR MODEL ASSUMPTIONS
USING THE GLOBAL TEST ON 4 DEGREES-OF-FREEDOM:
Level of Significance = 0.05

```
Call:
gvlma(x = reg2)
```

	value	p-value	Decision
Global stat	7.629e+02	0.0000	Assumptions NOT satisfied!
Skewness	1.296e+02	0.0000	Assumptions NOT satisfied!
Kurtosis	6.237e+02	0.0000	Assumptions NOT satisfied!
Link Function	9.644e+00	0.0019	Assumptions NOT satisfied!
Heteroscedasticity	4.028e-03	0.9494	Assumptions acceptable.

Source des données :auteurs

Annexe 27 : Résultat des tests Skewness, Kurtosis, Hétéroscédasticité, ... du modèle 3

```
> gvlma(reg5)

Call:
lm(formula = VIH$SIDA ~ VIH$VIE + VIH$EAU + VIH$PIB + VIH$RNB +
  VIH$POPU + VIH$ATV)

Coefficients:
      (Intercept)      VIH$VIE      VIH$EAU      VIH$PIB      VIH$RNB      VIH$POPU
           3.505e+00          -5.359e-02          3.450e-03          -3.512e-06          7.917e-06          1.283e-03
           VIH$ATV
           2.953e-03
```

ASSESSMENT OF THE LINEAR MODEL ASSUMPTIONS
USING THE GLOBAL TEST ON 4 DEGREES-OF-FREEDOM:
Level of Significance = 0.05

```
Call:
gvlma(x = reg5)
```

	value	p-value	Decision
Global Stat	536.38206	0.000000	Assumptions NOT satisfied!
Skewness	82.35031	0.000000	Assumptions NOT satisfied!
Kurtosis	445.62305	0.000000	Assumptions NOT satisfied!
Link Function	8.39323	0.003766	Assumptions NOT satisfied!
Heteroscedasticity	0.01547	0.901030	Assumptions acceptable.

Source des données :auteurs

Annexe 28 : Résultat du test de Kolmogorov-smirnov du modèle 1

Asymptotic one-sample Kolmogorov-Smirnov test

```
data: VIH$residu
D = 0.1936, p-value = 0.008402
alternative hypothesis: two-sided
```

Source des données :auteurs

Annexe 29 : Résultat du test de Kolmogorov-smirnov du modèle 2

Asymptotic one-sample Kolmogorov-Smirnov test

```
data: VIH$residu2
D = 0.21532, p-value = 0.002297
alternative hypothesis: two-sided
```

Source des données :auteurs

Annexe 30 : Résultat du test de Kolmogorov-smirnov du modèle 3

Asymptotic one-sample Kolmogorov-Smirnov test

```
data: VIH$residu5
D = 0.18715, p-value = 0.01203
alternative hypothesis: two-sided
```

Source des données :auteurs

Annexe 31 : Résultat de kurtosis et Skewness des trois modèles

```
> # modele 1
> skewness(VIH$residu)
[1] 3.711916
> kurtosis(VIH$residu)
[1] 21.41389
>
> # modele 2
> skewness(VIH$residu2)
[1] 3.265991
> kurtosis(VIH$residu2)
[1] 17.33782
>
> # modele 3
> skewness(VIH$residu5)
[1] 2.615112
> kurtosis(VIH$residu5)
[1] 15.17884
```

Source des données :auteurs

Annexe 32 : Prédiction des individus grâce au modèle 1

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
0.25	0.18	0.30	0.00	0.02	0.00	0.23	0.56	0.35	0.52	0.42	0.03	0.00	0.00	0.00	0.14
17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32
0.10	0.08	0.00	0.42	0.23	0.00	0.07	0.28	0.35	0.44	0.00	0.14	0.12	0.34	0.10	0.00
33	34	35	36	37	38	39	40	41	42	43	44	45	46	47	48
0.18	0.28	0.31	0.05	0.19	0.45	0.00	0.00	0.00	0.12	0.13	0.48	0.13	0.35	0.00	0.28
49	50	51	52	53	54	55	56	57	58	59	60	61	62	63	64
0.43	0.09	0.14	0.00	0.31	0.00	0.14	0.38	0.13	0.35	0.10	0.16	0.05	0.29	0.44	0.03
65	66	67	68	69	70	71	72	73							
0.21	0.53	0.34	0.19	0.11	0.42	0.44	0.19	0.38							

Source des données :auteurs

Annexe 33 : Résultat du test de Ramsey

```
> reset(reg1)
```

```
RESET test
```

```
data: reg1
```

```
RESET = 3.3546, df1 = 2, df2 = 68, p-value = 0.04079
```

```
> reset(reg2)
```

```
RESET test
```

```
data: reg2
```

```
RESET = 7.2244, df1 = 2, df2 = 68, p-value = 0.001429
```

```
> reset(reg4)
```

```
RESET test
```

```
data: reg4
```

```
RESET = 4.5567, df1 = 2, df2 = 64, p-value = 0.01412
```

```
> reset(reg5)
```

```
RESET test
```

```
data: reg5
```

```
RESET = 4.1753, df1 = 2, df2 = 64, p-value = 0.01975
```

Source des données :auteurs

Annexe 34 : Résultat de la modification du modèle 1

```
Call:
lm(formula = VIH$lnSIDA ~ res.pca2$ind$coord[, 1] + res.pca2$ind$coord[,
  2])

Residuals:
    Min       1Q   Median       3Q      Max
-2.53771 -0.66491 -0.06874  0.64606  2.43951

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   -3.04947    0.12535  -24.327  < 2e-16 ***
res.pca2$ind$coord[, 1] -0.43052    0.05189   -8.297  5.18e-12 ***
res.pca2$ind$coord[, 2] -0.31524    0.10383   -3.036  0.00336 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.071 on 70 degrees of freedom
Multiple R-squared:  0.5272,    Adjusted R-squared:  0.5137
F-statistic: 39.03 on 2 and 70 DF,  p-value: 4.101e-12
```

Source des données :auteurs

Annexe 35 : Résultat de la modification du modèle 2

```
Call:
lm(formula = VIH$lnSIDA ~ res.pca2$ind$coord[, 1] + res.pca2$ind$coord[,
  3])

Residuals:
    Min       1Q   Median       3Q      Max
-2.02628 -0.66984  0.01758  0.57165  2.78095

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   -3.04947    0.12357  -24.679  < 2e-16 ***
res.pca2$ind$coord[, 1] -0.43052    0.05115   -8.417  3.11e-12 ***
res.pca2$ind$coord[, 3]  0.37044    0.10911    3.395  0.00113 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.056 on 70 degrees of freedom
Multiple R-squared:  0.5406,    Adjusted R-squared:  0.5275
F-statistic: 41.19 on 2 and 70 DF,  p-value: 1.5e-12
```

Source des données :auteurs

Annexe 36 : Résultat de la modification du modèle 3

```
Call:
lm(formula = VIH$lnSIDA ~ VIH$VIE + VIH$EAU + VIH$PIB + VIH$RNB +
    VIH$POPU + VIH$FEM)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-2.13424 -0.53174 -0.00972  0.58778  1.83872
```


```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  7.730e+00  2.438e+00   3.171  0.00231 **
VIH$VIE      -1.880e-01  2.942e-02  -6.390  1.94e-08 ***
VIH$EAU      -6.121e-03  7.490e-03  -0.817  0.41680
VIH$PIB      -1.324e-05  1.913e-05  -0.692  0.49135
VIH$RNB       2.397e-05  2.164e-05   1.108  0.27206
VIH$POPU      1.459e-02  7.700e-03   1.895  0.06250 .
VIH$FEM       4.079e-02  3.781e-02   1.079  0.28461
```

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.9202 on 66 degrees of freedom
Multiple R-squared:  0.6709,    Adjusted R-squared:  0.641
F-statistic: 22.43 on 6 and 66 DF,  p-value: 3.246e-14
```

Source des données :auteurs

Annexe 37 : Corrélations sans les trois valeurs aberrantes les plus prononcées sur le taux de mortalité



B. Base de données nettoyée

	Country Code	TAUX DE MORTALITE DU VIH	PIB/HABITANT	ESPERANCE DE VIE	ACCES A L'ELECTRICITE	STABILITE POLITIQUE	% POP ACTIVE	ACCES AUX TRAITEMENTS ANTIRETROVIRAUX	DEPENSE COURANTE DE SANTE (EN % DU PIB)	% DE LA POPULATION URBAINE	INCIDENCE DE LA TUBERCULOSE POUR 1000 PERSONNES	% DE FEMME DANS LA POPULATION	ACCES A L'EAU POTABLE	REVENUE NATIONAL BRUTE ANNUEL MOYEN
1	AFG	0.02	2078.5951	62.57500	97.70000	2.358490	23.36467	11	15.533614	26.026	189.0	49.47094	28.402505	500
2	AZE	0.01	14495.6570	66.86800	100.00000	30.660378	51.17753	55	4.606765	56.397	58.0	50.62599	70.673310	4480
3	BGO	0.01	5904.5674	71.96000	96.20000	25.943396	42.37224	30	2.628010	38.177	221.0	50.38631	58.655998	2300
4	BGR	0.01	25296.0709	73.65854	99.70000	72.641510	47.76243	58	8.520638	75.686	19.0	51.45457	95.967076	9530
5	BLR	0.03	20317.2319	72.45722	100.00000	26.886793	52.57558	68	6.406072	79.483	28.0	53.85993	92.937111	6400
6	BRA	0.07	14900.1042	74.00900	99.70271	44.811321	47.20623	71	10.312917	87.073	45.0	50.85314	85.921618	7910
7	BTN	0.05	11137.8310	71.60900	100.00000	96.698112	46.49608	39	4.371745	42.316	164.0	47.00274	69.137159	2040
8	CAF	0.85	895.2515	54.60400	15.40571	4.716981	36.16191	60	9.402068	42.198	540.0	49.88933	6.183318	460
9	CIV	0.40	5377.3844	59.03200	69.87833	23.584506	37.08659	73	3.722458	51.706	132.0	49.47140	43.641641	2290
10	COG	0.16	1102.5535	59.73900	20.07378	10.377358	34.94321	70	4.050926	45.638	319.0	50.38836	11.185666	540
11	COG	1.38	3574.2414	63.78500	48.67913	33.490566	39.18537	22	4.467622	67.829	372.0	50.06199	45.896896	1760
12	COL	0.03	15103.0738	74.76900	99.72176	36.320755	48.95468	69	8.992428	81.425	34.0	50.63958	73.413231	5800
13	CRI	0.03	21693.6728	79.27700	99.90000	91.509438	47.95016	58	7.855371	80.771	9.7	49.94009	80.516047	11500
14	CYP	0.01	43425.9258	81.39100	100.00000	69.811317	52.66428	81	8.093478	66.821	3.2	49.90598	99.765172	26610
15	DNK	0.01	60832.1583	81.60244	100.00000	94.339622	51.93007	87	10.528175	88.116	4.1	50.26674	99.918824	62710
16	DOM	0.20	17707.6879	72.88900	100.00000	64.150940	43.67930	49	4.940005	82.540	41.0	49.74862	44.778786	7170
17	DZA	0.01	11452.2266	74.45300	99.71877	30.188679	27.28968	80	6.321180	73.733	58.0	49.06318	72.248147	3610
18	ECU	0.02	10937.1068	72.15300	98.85000	50.943398	44.17218	74	8.476771	64.166	44.0	50.02360	66.826665	5570
19	ESP	0.01	37988.0295	82.33171	100.00000	72.641510	48.21666	86	10.713750	80.810	7.2	50.99056	99.561480	27130
20	ETH	0.13	2379.4479	65.37100	51.14460	10.377358	47.63127	78	3.480963	21.695	129.0	49.73454	12.336203	880
21	FJI	0.05	11581.2233	67.92400	97.12664	89.622643	39.90050	39	3.749846	57.247	66.0	49.81878	41.610649	4680
22	FRA	0.01	48134.9598	82.17561	100.00000	69.811317	44.95881	85	12.205050	80.975	8.3	51.64989	99.509781	39440
23	GEO	0.02	14748.6321	72.76500	100.00000	47.169811	50.14452	71	7.604871	59.453	69.0	52.86082	68.623393	4260
24	GHA	0.46	5558.3563	64.11400	85.44057	64.622643	42.67982	61	3.990300	57.349	140.0	50.12094	42.335456	2230
25	GMB	0.56	2157.0350	62.61200	62.23400	67.924530	33.79731	32	2.612936	62.582	153.0	50.27057	46.495303	700
26	GNB	0.69	1904.6586	59.99900	33.37447	36.320755	32.71003	44	8.409786	44.196	361.0	50.66018	23.516802	740
27	GRC	0.01	28416.5239	81.28780	100.00000	61.792454	43.40565	70	9.508207	79.715	4.2	51.00006	98.930442	17960
28	GTM	0.03	8859.0117	71.79700	96.64747	47.169811	37.98642	69	6.468714	51.836	25.0	50.47850	55.768237	4490
29	HND	0.07	5309.7902	71.46200	93.08770	44.811321	41.55968	54	9.035098	58.359	30.0	49.48528	64.391295	2150
30	IDN	0.10	12160.7168	68.80800	96.95000	45.754719	50.06544	26	3.414330	56.641	301.0	49.63268	29.713916	3900
31	IRN	0.03	15240.7729	74.83200	100.00000	10.377358	31.12508	28	5.338800	75.874	12.0	49.43890	93.952661	3280
32	ISL	0.01	54303.9042	83.06341	100.00000	99.528035	59.72390	91	9.557963	93.898	3.8	48.70387	100.000000	62110
33	KGZ	0.03	4990.9284	71.80000	99.86512	44.339622	38.90886	46	5.259337	36.856	108.0	50.89270	76.338537	1180
34	KHM	0.08	4515.7095	70.41600	86.40000	52.358490	53.00393	83	7.505270	24.232	280.0	50.50561	27.903767	1530
35	LAO	0.05	8198.8365	68.49700	99.31136	89.150940	40.44454	55	2.694761	36.290	149.0	49.58842	17.681904	2470
36	LBN	0.01	14563.7705	77.80400	99.98307	11.320755	32.17835	64	7.953658	88.925	13.0	51.46881	47.700000	6400
37	LKA	0.01	13664.2267	76.39300	99.97410	55.660378	39.32890	60	4.065850	18.713	63.0	51.80222	47.591424	3880
38	LSO	2.53	2413.0787	54.69300	47.49701	52.358490	42.18912	80	11.784286	29.028	592.0	50.65946	27.521684	1210
39	LTU	0.02	40176.4600	74.97805	100.00000	94.339622	53.17460	36	7.538444	68.046	28.0	53.15341	94.923793	19670
40	LUX	0.01	120010.2083	82.14390	100.00000	98.584908	51.08364	72	5.767456	91.453	5.8	49.68234	99.520065	79580
41	LVA	0.04	33018.6242	75.18537	100.00000	74.056602	52.01850	41	7.446630	68.315	20.0	53.76458	96.539961	18240
42	MAR	0.01	7968.6743	73.92000	100.00000	48.113209	31.68305	74	5.993161	63.532	96.0	49.64411	73.912180	3250
43	MDA	0.15	12512.6004	70.16600	100.00000	48.113209	32.39741	45	6.779331	42.849	78.0	52.49440	74.495938	4360
44	MDG	0.11	1516.6542	65.18200	32.00000	41.981133	51.06529	11	3.879584	38.534	233.0	49.87303	20.763533	460
45	MEX	0.04	18522.0022	70.13300	99.40000	27.358490	42.16529	57	6.242148	80.731	23.0	51.12041	42.892102	8750
46	MMR	0.10	5224.1991	66.79700	70.41574	12.735849	45.03815	74	4.624120	31.141	311.0	50.19734	56.771026	1370
47	MNE	0.01	20510.8253	75.93171	99.85311	57.075470	43.63695	58	11.421776	67.488	15.0	51.25714	85.072200	7900
48	MNG	0.01	12320.2793	72.14100	99.50217	89.622643	41.27543	37	4.944511	68.657	428.0	50.33614	37.387381	3720
49	MWI	0.66	1573.0395	63.71700	11.50000	55.660378	38.41708	87	5.344000	17.427	138.0	51.39223	16.486405	570
50	MYS	0.07	27277.8623	75.93800	100.00000	60.377357	50.08011	54	4.124418	77.160	90.0	48.83682	93.818220	10320
51	NIC	0.04	5523.5446	71.79500	86.00330	40.566036	44.44520	53	8.628546	59.012	42.0	50.71938	55.515917	1760
52	NLD	0.01	59822.9543	81.35854	100.00000	93.867928	54.48003	88	11.135927	92.236	4.1	50.31749	99.970258	50170
53	NPL	0.02	3972.5153	69.24600	89.90000	52.358490	27.81877	67	5.173518	20.576	230.0	52.36423	17.707118	1180
54	NZL	0.01	45554.9329	82.25610	100.00000	99.528035	56.84651	81	10.028587	86.699	7.2	50.44878	99.104288	41590
55	OMN	0.01	34952.1635	74.75700	100.00000	72.641510	48.50798	60	5.325734	86.276	7.9	37.91465	90.557164	17110
56	PAK	0.04	5284.6646	66.26900	94.48528	10.377358	32.06009	12	2.953904	37.165	255.0	49.46422	48.546834	1420
57	PER	0.03	11813.9884	73.66500	96.20000	47.169811	50.53568	76	6.304161	78.297	117.0	50.45923	51.406210	6000
58	PHL	0.01	8208.6694	72.11900	96.39029	33.490566	37.80971	39	5.112740	47.408	533.0	49.24017	47.428127	3350
59	PRY	0.05	14063.2737	73.18200	99.70000	57.547169	49.63995	62	7.577043	62.183	45.0	49.77886	64.084221	5540
60	QAT	0.01	94005.3583	79.09900	100.00000	88.679245	74.16465	49	4.183039	99.235	36.0	27.35104	96.642933	58420
61	ROU	0.01	33336.1811	74.25366	99.95522	76.886795	46.20402	65	6.272362	54.194	43.0	51.62110	81.988832	12710
62	SEN	0.07	3574.0169	68.00600	64.30000	54.245281	29.09953	76	5.151192	48.122	115.0	50.85868	26.060347	1460
63	SLE	0.35	1675.2126	59.76300	26.31068	49.528301	32.09330	50	8.756371	42.923	292.0	49.90549	9.714313	490
64	SRB	0.01	19557.5764	74.47805	100.00000	53.301888	46.65421	63	8.731617	56.446	14.0	52.06172	75.005947	7440
65	STP	0.10	4286.0154	67.78500	76.81361	77.830185	31.79367	95	4.906713	74.354	115.0	50.09490	35.866379	2100
66	TCO	0.20	1572.6016	52.77700	10.86568	18.396227	30.95251	70	5.407488	23.520	141.0	49.80363	6.157883	660
67	TGO	0.33	2179.7566	61.03500	54.12760	26.415094	34.09712	75	5.963011	42.800	35.0	49.74210	18.841017	880
68	TJK	0.01	3856.5015	67.99400	99.50574	44.339622	25.79470	63	8.176978	27.506	80.0	49.68683	55.236865	1050
69	TUN	0.03	10602.5213	75.29200	99.90000	41.509434	33.43775	28	6.364348	69.568	36.0	50.55941	73.906925	3220
70	TZA	0.50	2694.4263	66.40800	39.90000	45.754719	45.11698	83	3.746598	35.227	222.0	50.61066	10.708382	1050
71	UGA	0.42	2365.9884	62.85100	42.13948	32.075470	37.67180	81	3.9					

C. Code R

Une partie du code R :

```
library(readxl)
library(FactoMineR)
install.packages("EnvStats")
library(EnvStats)
install.packages("outliers")
library(outliers)
library(gvlma)
library(moments)
install.packages("questionr")
library(questionr)
library(RColorBrewer)
library(factoextra)
library(corrplot)

#### Base de données ####
SIDA <- read_xlsx(file.choose())
SIDA

#### Mise en forme de la base initiale ####
Z = c(2:14)
SIDA[,Z] = apply(SIDA[,Z], 2, as.numeric)
VIH = na.omit(SIDA[,])
VIH <- rename.variable(VIH, "TAUX DE MORTALITE DU VIH", "SIDA")
VIH <- rename.variable(VIH, "PIB/HABITANT", "PIB")
VIH <- rename.variable(VIH, "ESPERANCE DE VIE", "VIE")
VIH <- rename.variable(VIH, "ACCES A L'ELECTRICITE", "ELEC")
VIH <- rename.variable(VIH, "STABILITE POLITIQUE", "POL")
VIH <- rename.variable(VIH, "% POP ACTIVE", "POPA")
VIH <- rename.variable(VIH, "ACCES AUX TRAITEMENTS ANTIRETROVIRAUX", "ATV")
VIH <- rename.variable(VIH, "DEPENSE COURANTE DE SANTE (EN % DU PIB)",
"SANTE")
VIH <- rename.variable(VIH, "% DE LA POPULATION URBAINE", "POPU")
VIH <- rename.variable(VIH, "INCIDENCE DE LA TUBERCULOSE POUR 1000
PERSONNES", "TUB")
VIH <- rename.variable(VIH, "% DE FEMME DANS LA POPULATION", "FEM")
VIH <- rename.variable(VIH, "ACCES A L'EAU POTABLE", "EAU")
VIH <- rename.variable(VIH, "REVENUE NATIONAL BRUTE ANNUEL MOYEN", "RNB")
names(VIH)
VIH

#####Statistiques descriptives#####
summary(VIH)
```

```
round(sapply(VIH,mean), 2)
round(sapply(VIH,sd), 2)
```

```
## Analyse des valeurs atypiques ##
par(mfrow=c(1,1))
boxplot(VIH$SIDA, xlab = "SIDA",col="#990000")
boxplot(VIH$VIE, xlab = "VIE",col="#990000")
boxplot(VIH$PIB, xlab = "PIB",col="#990000")
boxplot(VIH$FEM, xlab = "FEM",col="#990000")
boxplot(VIH$TUB, xlab = "TUB",col="#990000")
boxplot(VIH$ELEC, xlab = "ELEC",col="#990000")
boxplot(VIH$POPA, xlab = "POPA",col="#990000")
boxplot(VIH$RNB, xlab = "RNB",col="#990000")
boxplot(VIH$ATV, xlab = "ATV",col="#990000")
boxplot(VIH$POL, xlab = "POL",col="#990000")
boxplot(VIH$POPU, xlab = "POPU",col="#990000")
boxplot(VIH$EAU, xlab = "EAU",col="#990000")
boxplot(VIH$SANTE, xlab = "SANTE",col="#990000")
```

```
## Tests pour vérifier s'il y a des valeurs atypiques ##
grubbs.test(VIH$POPA)
grubbs.test(VIH$SANTE)
grubbs.test(VIH$VIE)
rosnerTest(VIH$TUB, k=10, alpha=0.05)
```

```
# TEST ESD QUAND +10 VALEURS ABBERANTES A TESTER#
```

```
# SIDA
```

```
y = VIH$SIDA
```

```
rval = function(y){
  ares = abs(y - mean(y))/sd(y)
  df = data.frame(y, ares)
  r = max(df$ares)
  list(r, df)}
n = length(y)
alpha = 0.05
lam = c(1:50)
R = c(1:50)
for (i in 1:50){
  if(i==1){
    rt = rval(y)
    R[i] = unlist(rt[1])
    df = data.frame(rt[2])
    newdf = df[df$ares!=max(df$ares),]}
```



```

else if(i!=1){
  rt = rval(newdf$y)
  R[i] = unlist(rt[1])
  df = data.frame(rt[2])
  newdf = df[df$ares!=max(df$ares),]
  p = 1 - alpha/(2*(n-i+1))
  t = qt(p,(n-i-1))
  lam[i] = t*(n-i) / sqrt((n-i-1+t**2)*(n-i+1))
}
newdf = data.frame(c(1:50),R,lam)
names(newdf)=c("No. Outliers","Test Stat.", "Critical Val.")
newdf

```

```
rosnerTest(VIH$SIDA, k = 10, alpha = 0.05)
```

```

sort(VIH$SIDA)
order(VIH$SIDA)

```

```
# PIB
```

```
y = VIH$PIB
```

```

rval = function(y){
  ares = abs(y - mean(y))/sd(y)
  df = data.frame(y, ares)
  r = max(df$ares)
  list(r, df)}
n = length(y)
alpha = 0.05
lam = c(1:50)
R = c(1:50)
for (i in 1:50){
  if(i==1){
    rt = rval(y)
    R[i] = unlist(rt[1])
    df = data.frame(rt[2])
    newdf = df[df$ares!=max(df$ares),]}
  else if(i!=1){
    rt = rval(newdf$y)
    R[i] = unlist(rt[1])
    df = data.frame(rt[2])
    newdf = df[df$ares!=max(df$ares),]}
  p = 1 - alpha/(2*(n-i+1))
  t = qt(p,(n-i-1))
  lam[i] = t*(n-i) / sqrt((n-i-1+t**2)*(n-i+1))
}
newdf1 = data.frame(c(1:50),R,lam)
names(newdf1)=c("No. Outliers","Test Stat.", "Critical Val.")

```

```

newdf

rosnerTest(VIH$PIB, k = 10, alpha = 0.05)

sort(VIH$PIB)
order(VIH$PIB)

# FEM

y = VIH$FEM

rval = function(y){
  ares = abs(y - mean(y))/sd(y)
  df = data.frame(y, ares)
  r = max(df$ares)
  list(r, df)}
n = length(y)
alpha = 0.05
lam = c(1:50)
R = c(1:50)
for (i in 1:50){
  if(i==1){
    rt = rval(y)
    R[i] = unlist(rt[1])
    df = data.frame(rt[2])
    newdf = df[df$ares!=max(df$ares),]}
  else if(i!=1){
    rt = rval(newdf$y)
    R[i] = unlist(rt[1])
    df = data.frame(rt[2])
    newdf = df[df$ares!=max(df$ares),]}
  p = 1 - alpha/(2*(n-i+1))
  t = qt(p,(n-i-1))
  lam[i] = t*(n-i) / sqrt((n-i-1+t**2)*(n-i+1))
}
newdf2 = data.frame(c(1:50),R,lam)
names(newdf2)=c("No. Outliers","Test Stat.", "Critical Val.")
newdf

rosnerTest(VIH$FEM, k = 10, alpha = 0.05)

sort(VIH$FEM)
order(VIH$FEM)

# ELEC

y = VIH$ELEC

```

```

rval = function(y){
  ares = abs(y - mean(y))/sd(y)
  df = data.frame(y, ares)
  r = max(df$ares)
  list(r, df)}
n = length(y)
alpha = 0.05
lam = c(1:50)
R = c(1:50)
for (i in 1:50){
  if(i==1){
    rt = rval(y)
    R[i] = unlist(rt[1])
    df = data.frame(rt[2])
    newdf = df[df$ares!=max(df$ares),]}
  else if(i!=1){
    rt = rval(newdf$y)
    R[i] = unlist(rt[1])
    df = data.frame(rt[2])
    newdf = df[df$ares!=max(df$ares),]}
  p = 1 - alpha/(2*(n-i+1))
  t = qt(p,(n-i-1))
  lam[i] = t*(n-i) / sqrt((n-i-1+t**2)*(n-i+1))
}
newdf3 = data.frame(c(1:50),R,lam)
names(newdf3)=c("No. Outliers","Test Stat.", "Critical Val.")
newdf

```

```

rosnerTest(VIH$ELEC, k = 10, alpha = 0.05)

```

```

sort(VIH$ELEC)
order(VIH$ELEC)

```

```

# RNB

```

```

y = VIH$RNB

```

```

rval = function(y){
  ares = abs(y - mean(y))/sd(y)
  df = data.frame(y, ares)
  r = max(df$ares)
  list(r, df)}
n = length(y)
alpha = 0.05
lam = c(1:50)
R = c(1:50)
for (i in 1:50){

```

```

if(i==1){
  rt = rval(y)
  R[i] = unlist(rt[1])
  df = data.frame(rt[2])
  newdf = df[df$ares!=max(df$ares),]}
else if(i!=1){
  rt = rval(newdf$y)
  R[i] = unlist(rt[1])
  df = data.frame(rt[2])
  newdf = df[df$ares!=max(df$ares),]}
p = 1 - alpha/(2*(n-i+1))
t = qt(p,(n-i-1))
lam[i] = t*(n-i) / sqrt((n-i-1+t**2)*(n-i+1))
}
newdf4 = data.frame(c(1:50),R,lam)
names(newdf4)=c("No. Outliers", "Test Stat.", "Critical Val.")
newdf

```

```
rosnerTest(VIH$RNB, k = 10, alpha = 0.05)
```

```

sort(VIH$RNB)
order(VIH$RNB)

```

Skewness et Kurtosis avec les valeurs atypiques

```

skewness(VIH$SIDA)
kurtosis(VIH$SIDA)

```

Analyse des valeurs atypiques

```

par(mfrow=c(1,1))
boxplot(VIH$SIDA, xlab = "SIDA",col="#990000")
boxplot(VIH$VIE, xlab = "VIE",col="#990000")
boxplot(VIH$PIB, xlab = "PIB",col="#990000")
boxplot(VIH$FEM, xlab = "FEM",col="#990000")
boxplot(VIH$TUB, xlab = "TUB",col="#990000")
boxplot(VIH$ELEC, xlab = "ELEC",col="#990000")
boxplot(VIH$POPA, xlab = "POPA",col="#990000")
boxplot(VIH$RNB, xlab = "RNB",col="#990000")
boxplot(VIH$ATV, xlab = "ATV",col="#990000")
boxplot(VIH$POL, xlab = "POL",col="#990000")
boxplot(VIH$POPU, xlab = "POPU",col="#990000")
boxplot(VIH$EAU, xlab = "EAU",col="#990000")
boxplot(VIH$SANTE, xlab = "SANTE",col="#990000")

```

CORRELATION

Corr lation entre les variables actives et la variable illustrative

```
plot(VIH$PIB, VIH$SIDA, type = "p", main="Corr lation entre le PIB et le taux de
mortalit ", xlab = "PIB", ylab = "Taux de mortalit ")
abline(lm(VIH$SIDA ~ VIH$PIB), col="red", lwd=2)
```

```
plot(VIH$VIE, VIH$SIDA, type = "p", main="Corr lation entre l'ESPERANCE DE VIE et le
taux de mortalit ", xlab = "PIB", ylab = "Taux de mortalit ")
abline(lm(VIH$SIDA ~ VIH$VIE), col="red", lwd=2)
```

```
plot(VIH$ELEC, VIH$SIDA, type = "p", main="Corr lation entre ELEC et le taux de
mortalit ", xlab = "PIB", ylab = "Taux de mortalit ")
abline(lm(VIH$SIDA ~ VIH$ELEC), col="red", lwd=2)
```

```
plot(VIH$POL, VIH$SIDA, type = "p", main="Corr lation entre POL et le taux de
mortalit ", xlab = "PIB", ylab = "Taux de mortalit ")
abline(lm(VIH$SIDA ~ VIH$POL), col="red", lwd=2)
```

```
plot(VIH$POPA, VIH$SIDA, type = "p", main="Corr lation entre POPA et le taux de
mortalit ", xlab = "PIB", ylab = "Taux de mortalit ")
abline(lm(VIH$SIDA ~ VIH$POPA), col="red", lwd=2)
```

```
plot(VIH$ATV, VIH$SIDA, type = "p", main="Corr lation entre ATV et le taux de
mortalit ", xlab = "PIB", ylab = "Taux de mortalit ")
abline(lm(VIH$SIDA ~ VIH$ATV), col="red", lwd=2)
```

```
plot(VIH$SANTE, VIH$SIDA, type = "p", main="Corr lation entre SANTE et le taux de
mortalit ", xlab = "PIB", ylab = "Taux de mortalit ")
abline(lm(VIH$SIDA ~ VIH$SANTE), col="red", lwd=2)
```

```
plot(VIH$POPU, VIH$SIDA, type = "p", main="Corr lation entre POPU et le taux de
mortalit ", xlab = "PIB", ylab = "Taux de mortalit ")
abline(lm(VIH$SIDA ~ VIH$POPU), col="red", lwd=2)
```

```
plot(VIH$TUB, VIH$SIDA, type = "p", main="Corr lation entre TUB et le taux de
mortalit ", xlab = "PIB", ylab = "Taux de mortalit ")
abline(lm(VIH$SIDA ~ VIH$TUB), col="red", lwd=2)
```

```
plot(VIH$FEM, VIH$SIDA, type = "p", main="Corr lation entre FEM et le taux de
mortalit ", xlab = "PIB", ylab = "Taux de mortalit ")
abline(lm(VIH$SIDA ~ VIH$FEM), col="red", lwd=2)
```

```
plot(VIH$EAU, VIH$SIDA, type = "p", main="Corr lation entre EAU et le taux de
mortalit ", xlab = "PIB", ylab = "Taux de mortalit ")
abline(lm(VIH$SIDA ~ VIH$EAU), col="red", lwd=2)
```

```
plot(VIH$RNB, VIH$SIDA, type = "p", main="Corr lation entre RNB et le taux de
mortalit ", xlab = "PIB", ylab = "Taux de mortalit ")
abline(lm(VIH$SIDA ~ VIH$RNB), col="red", lwd=2)
```

```
#### Analyse des corr lations ####
```

```
V = VIH
```

```
new_names =
```

```
c("CODE","VIH","PIB","VIE","ELEC","POL","POPA","ATV","SANTE","POPU","TUB","FEM","E  
AU","RNB")
```

```
colnames(V) = new_names
```

```
VIH_cor = cor(V[,Z])
```

```
couleur_noms_variables = "#3399CC"
```

```
corrplot(VIH_cor, order = 'AOE', tl.col = couleur_noms_variables)
```

```
#### ACP ####
```

```
res.pca<- PCA(VIH[,3:14],axes = c(1,2))
```

```
res.pca<- PCA(VIH[,3:14], axes = c(1,3))
```

```
round(res.pca$eig, 2)
```

```
round(res.pca$var$contrib, 2)
```

```
round(res.pca$var$cos2, 2)
```

```
#### Graphiques des cercles de corr lations en ACP ####
```

```
## Sans la variable illustrative ##
```

```
fviz_pca_var(res.pca, axes = c(1,2), col.var="cos2") +  
  scale_color_gradient2(low="#00AFBB", mid="#E7B800",  
    high="#B40707", midpoint=0.65, space = "Lab")
```

```
fviz_pca_var(res.pca, axes = c(1,3), col.var="cos2") +  
  scale_color_gradient2(low="#00AFBB", mid="#E7B800",  
    high="#B40707", midpoint=0.65, space = "Lab")
```

```
## Avec la variable illustrative ##
```

```
res.pca<- PCA(VIH[,c(2:14)], quanti.sup = 1)
```

```
fviz_pca_var(res.pca, axes = c(1,2), col.var="cos2", col.quanti.sup = "black") +  
  scale_color_gradient2(low="#00AFBB", mid="#E7B800",  
    high="#B40707", midpoint=0.65, space = "Lab")
```

```
fviz_pca_var(res.pca, axes = c(1,3), col.var="cos2", col.quanti.sup = "black") +  
  scale_color_gradient2(low="#00AFBB", mid="#E7B800",  
    high="#B40707", midpoint=0.65, space = "Lab")
```

```
##### Projection des individus #####
```

```
coordIND<- round(res.pca$ind$coord, 2)
```

```
head(coordIND)
```

```
contribIND<- round(res.pca$ind$contrib, 2)
```

```
head(contribIND)
```

```

cos2IND <- round(res.pca$ind$cos2, 2)
head(cos2IND)
fviz_pca_ind(res.pca, col.ind="cos2", gradient.cols=c("#00AFBB", "#E7B800", "#FC4E07"),
repel=TRUE,
            title="projection des individus sur l'axe 1 et 2")
fviz_pca_ind(res.pca, axes=c(1,3), col.ind="cos2", gradient.cols=c("#00AFBB", "#E7B800",
"#FC4E07"),
            repel=TRUE, title="projection des individus sur l'axe 1 et 3")

plot(res.pca, title = "20 pays les plus contributifs", select = "contrib15")
plot(res.pca, title = "20 pays les plus contributifs", select = "contrib15", axes = c(1,3))

res.pca = PCA(VIH[,3:14])

#### RLM ####
reg1=lm(VIH$SIDA ~ res.pca$ind$coord[,1]+res.pca$ind$coord[,2])
reg2=lm(VIH$SIDA ~ res.pca$ind$coord[,1]+res.pca$ind$coord[,3])
reg4=lm(VIH$SIDA ~ VIH$VIE+VIH$EAU+VIH$PIB+VIH$RNB+VIH$POPU+VIH$FEM)
reg5=lm(VIH$SIDA ~ VIH$VIE+VIH$EAU+VIH$PIB+VIH$RNB+VIH$POPU+VIH$ATV)
summary(reg1)
summary(reg2)
summary(reg4)
summary(reg5)

#### Graphiques sur les rÃ©sidus pour chaque modÃ©le ####

VIH$residu=round(residuals(reg1),2)
VIH$residu2=round(residuals(reg2),2)
VIH$residu4=round(residuals(reg4),2)
VIH$residu5=round(residuals(reg5),2)

par(mfrow=c(1,3))
boxplot(VIH$residu, main="Boxplot des rÃ©sidus", col="red")
hist(VIH$residu, xlab="RÃ©sidus", ylab="Nombre d'individus", main="Histogramme des
rÃ©sidus",
     freq=TRUE, col="red")
qqnorm(VIH$residu)
qqline(VIH$residu, col="red")

boxplot(VIH$residu2, main="Boxplot des rÃ©sidus", col="red")
hist(VIH$residu2, xlab="RÃ©sidus", ylab="Nombre d'individus", main="Histogramme des
rÃ©sidus",
     freq=TRUE, col="red")
qqnorm(VIH$residu2)
qqline(VIH$residu2, col="red")

boxplot(VIH$residu4, main="Boxplot des rÃ©sidus", col="red")

```

```
hist(VIH$residu4, xlab="RÃ©sidus", ylab="Nombre d'individus", main="Histogramme des
rÃ©sidus",
      freq=TRUE, col="red")
qqnorm(VIH$residu4)
qqline(VIH$residu4, col="red")
```

```
boxplot(VIH$residu5, main="Boxplot des rÃ©sidus", col="red")
hist(VIH$residu5, xlab="RÃ©sidus", ylab="Nombre d'individus", main="Histogramme des
rÃ©sidus",
      freq=TRUE, col="red")
qqnorm(VIH$residu5)
qqline(VIH$residu5, col="red")
```

```
# modele 1
skewness(VIH$residu)
kurtosis(VIH$residu)
```

```
# modele 2
skewness(VIH$residu2)
kurtosis(VIH$residu2)
```

```
# modele 3
skewness(VIH$residu5)
kurtosis(VIH$residu5)
```

```
#### Kolmogorov-Smirnov ####
ks.test(VIH$residu, "pnorm", mean(VIH$residu), sd(VIH$residu))
ks.test(VIH$residu2, "pnorm", mean(VIH$residu2), sd(VIH$residu2))
ks.test(VIH$residu4, "pnorm", mean(VIH$residu4), sd(VIH$residu4))
ks.test(VIH$residu5, "pnorm", mean(VIH$residu5), sd(VIH$residu5))
```

```
#### Skewness et Kurtosis ####
gvlma(reg1)
gvlma(reg2)
gvlma(reg4)
gvlma(reg5)
```

```
## CrÃ©ation des variables predict et residu ##
VIH$predict = round(predict(reg1), 2)
VIH$residu = round(residuals(reg1), 2)
VIH$predict
VIH$residu
```

```
VIH$predict = round(predict(reg2), 2)
VIH$residu = round(residuals(reg2), 2)
VIH$predict
```



```
VIH$residu
```

```
VIH$predict = round(predict(reg4), 2)
VIH$residu = round(residuals(reg4), 2)
VIH$predict
VIH$residu
```

```
VIH$predict = round(predict(reg5), 2)
VIH$residu = round(residuals(reg5), 2)
VIH$predict
VIH$residu
```

```
### PrÃ©dictions ###
par(mfrow=c(1,1))
VIH$predict3
VIH$SIDA
round(VIH$predict3, 2)
plot(VIH$predict3, VIH$SIDA, xlab="Taux de mortalitÃ© prÃ©dits", ylab="Taux de mortalitÃ©
observÃ©s", col=0, main = "Taux de mortalitÃ© du SIDA prÃ©dits et observÃ©s", abline(a=0,
b=1,
col="red", lty=1))
```

```
# Forme fonctionnelle
install.packages("lmtest")
library(lmtest)
reset(reg1)
reset(reg2)
reset(reg4)
reset(reg5)
reset(reg6)
```

```
# p-value du test Ramsey < 0,05 -> Hypoth?se H0 est refus?e au seuil de 5 %
# la Forme fonctionnelle lin?aire du mod?le sp?cifi? ne peut pas ?tre accept?e au seuil de
5%, elle n'est pas bonne
```

```
res.pca2 = PCA(VIH[,3:14])
```

```
VIH$lnSIDA <- log(VIH$SIDA)
```

```
modele2<-lm(VIH$lnSIDA~res.pca2$ind$coord[,1]+res.pca2$ind$coord[,3])
summary(modele2)
```

```
reset(modele2)
```

```
modele3<-lm(VIH$lnSIDA~res.pca2$ind$coord[,1]+res.pca2$ind$coord[,2])
summary(modele3)
```

```
reset(modele2)
```

```

reset(modele3)

modele4<-lm(VIH$lnSIDA ~
VIH$VIE+VIH$EAU+VIH$PIB+VIH$RNB+VIH$POPU+VIH$FEM)
summary(modele4)
reset(modele4)
modele5<-lm(VIH$SIDA ~ VIH$VIE+VIH$EAU+VIH$PIB+VIH$RNB+VIH$POPU+VIH$ATV)
summary(modele5)
reset(modele5)

modele6<-lm(VIH$lnSIDA ~VIH$VIE)
summary(modele6)
reset(modele6)

### PrÃ©dictions ###
Predic <- predict(reg1)
Predic
VIH$Predic <- round(Predic, 2)
VIH$Predic <- pmax(VIH$Predic, 0)
VIH`TAUX DE MORTALITE DU VIH`
VIH$Predic
plot(VIH$Predic, VIH$`SIDA`,
      xlab = "PrÃ©diction tx de mortalitÃ© du SIDA",
      ylab = "Tx de mortalitÃ© du SIDA observÃ©s",
      col = 0)
abline(a = 0, b = 1, col = "red", lty = 1)
text(VIH$Predic, VIH$`SIDA`, labels = row.names(VIH), cex = 0.7)

hist(VIH$Predic,col = "#990000", xlab="Taux de mortalitÃ© du SIDA prÃ©dit", ylab =
"FrÃ©quence", ylim = c(0,50))
col="red", lty=1))
VIH

# reg logistique

VIH$SIDAbis[VIH$SIDA >.03]="1"
VIH$SIDAbis[VIH$SIDA <=.03]="0"
VIH$SIDAbis
VIH

VIH$SIDAbisN=as.numeric(VIH$SIDAbis)

model=glm(VIH$SIDAbisN~res.pca$ind$coord[,1]+res.pca$ind$coord[,2],family=binomial)
summary(model)

model2=glm(VIH$SIDAbisN~res.pca$ind$coord[,1]+res.pca$ind$coord[,3],family=binomial)
summary(model2)

```

```
exp(-0.74208)
exp(-0.62090)
```

```
### Corr lations sans les valeurs aberrantes
```

```
VIH <- VIH[-c(38, 73,11), ]
```

```
## Histogrammes repr sentant la distribution des variables sans les valeurs atypiques ##
```

```
par(mfrow=c(1,1))
hist(VIH$SIDA, main="TAUX MORTA", xlab="SIDA", ylab="Fr quences",
     col=brewer.pal(n=7, name="YlGnBu"))
```

```
## Corr lations sans les valeurs atypiques ##
```

```
summary(VIH)
cor(VIH[,c(2:14)], use="complete.obs", method =c ("pearson"))
```

```
V = VIH
new_names =
c("CODE","VIH","PIB","VIE","ELEC","POL","POPA","ATV","SANTE","POPU","TUB","FEM","E
AU","RNB")
colnames(V) = new_names
VIH_cor = cor(V[,Z])
couleur_noms_variables = "#3399CC"
corrplot(VIH_cor, order = 'AOE',tl.col = couleur_noms_variables)
```

Autre partie

```
#LIBRAIRIE#
```

```
library(readxl)
library(FactoMineR)
library(tidyverse)
library(questionr)
library(lmtest)
library(corrplot)
library(ggplot2)
library(factoextra)
library(RColorBrewer)
library(EnvStats)
library(gvlma)
library(purrr)
```

```
#ACP VIH#
```

```

#IMPORTATION VIH#
VIH = read_excel("/Users/rododo/Desktop/ECAP/AD/VIH/export copie.xlsx")
Z = c(2:14)
VIH[,Z] = apply(VIH[,Z], 2, as.numeric)
VIH_propre = na.omit(VIH[,])
VIH_propre1 = VIH_propre
#STATISTIQUE DEESCRPTIVES#
summary(VIH_propre)
sd = round(sapply(VIH_propre[,Z],sd),4)
sd = format(sd , scientific = FALSE)
sd
var = round(sapply(VIH_propre[,Z],var),4)
var = format(var, scientific = FALSE)
var

#CORRELATION#
#GENERALE#
V = VIH_propre
new_names =
c("CODE","VIH","PIB","VIE","ELEC","POL","POPA","ATV","SANTE","POPU","TUB","FEM","E
AU","RNB")
colnames(V) = new_names
VIH_cor = cor(V[,Z])
couleur_noms_variables = "#3399CC"
corrplot(VIH_cor, order = 'AOE',tl.col = couleur_noms_variables)

#ENTRE LA VARIABLE ILLUSTRATIVE ET EXPLICATIVES#
par(mfrow=c(1,1))
plot(V$PIB, V$VIH, type = "p", main="Corrélation entre le taux de mortalité du SIDA et le
PIB/Habitant", xlab = "Le PIB/Habitant", ylab = "Le taux de mortalité du SIDA",
cex.main=0.80)
abline(lm(V$VIH ~ V$PIB), col="red", lwd=2)
plot(V$VIE, V$VIH, type = "p", main="Corrélation entre le taux de mortalité du SIDA et
l'espérance de vie à la naissance", xlab = "l'espérance de vie à la naissance", ylab = "Le
taux de mortalité du SIDA", cex.main=0.80)
abline(lm(V$VIH ~ V$VIE), col="red", lwd=2)
plot(V$ELEC, V$VIH, type = "p", main="Corrélation entre le taux de mortalité du SIDA et
l'accès à l'électricité", xlab = "L'accès à l'électricité en %", ylab = "Le taux de mortalité du
SIDA", cex.main=0.80)
abline(lm(V$VIH ~ V$ELEC), col="red", lwd=2)
plot(V$POL, V$VIH, type = "p", main="Corrélation entre le taux de mortalité du SIDA et
l'indicateur de la stabilité politique", xlab = "stabilité politique", ylab = "Le taux de mortalité du
SIDA", cex.main=0.80)
abline(lm(V$VIH ~ V$POL), col="red", lwd=2)
plot(V$POPA, V$VIH, type = "p", main="Corrélation entre le taux de mortalité du SIDA et la
population active", xlab = "La population active en %", ylab = "Le taux de mortalité du SIDA",
cex.main=0.80)

```

```

abline(lm(V$VIH ~ V$POPA), col="red", lwd=2)
plot(V$ATV, V$VIH, type = "p", main="Corrélation entre le taux de mortalité du SIDA et
l'accès au traitement antirétroviraux", xlab = "Accès au traitement antirétroviraux en %", ylab
= "Le taux de mortalité du SIDA", cex.main=0.80)
abline(lm(V$VIH ~ V$ATV), col="red", lwd=2)
plot(V$SANTE, V$VIH, type = "p", main="Corrélation entre le taux de mortalité du SIDA et
les dépenses de santé courante", xlab = "Dépenses de santé courante en % du PIB", ylab =
"Le taux de mortalité du SIDA", cex.main=0.80)
abline(lm(V$VIH ~ V$SANTE), col="red", lwd=2)
plot(V$POPU, V$VIH, type = "p", main="Corrélation entre le taux de mortalité du SIDA et la
population urbaine", xlab = "Population urbaine en %", ylab = "Le taux de mortalité du SIDA",
cex.main=0.80)
abline(lm(V$VIH ~ V$POPU), col="red", lwd=2)
plot(V$TUB, V$VIH, type = "p", main="Corrélation entre le taux de mortalité du SIDA et
l'incidence de la tuberculose", xlab = "Incidence de la tuberculose pour 100 000", ylab = "Le
taux de mortalité du SIDA", cex.main=0.80)
abline(lm(V$VIH ~ V$TUB), col="red", lwd=2)
plot(V$FEM, V$VIH, type = "p", main="Corrélation entre le taux de mortalité du SIDA et la
parts des femmes dans la population", xlab = "% de la part des femmes dans la population",
ylab = "Le taux de mortalité du SIDA", cex.main=0.80)
abline(lm(V$VIH ~ V$FEM), col="red", lwd=2)
plot(V$EAU, V$VIH, type = "p", main="Corrélation entre le taux de mortalité du SIDA et
l'accès à l'eau", xlab = "L'accès à l'eau en %", ylab = "Le taux de mortalité du SIDA",
cex.main=0.80)
abline(lm(V$VIH ~ V$EAU), col="red", lwd=2)
plot(V$RNB, V$VIH, type = "p", main="Corrélation entre le taux de mortalité du SIDA et du
RNB", xlab = "Revenu national brut annuel", ylab = "Le taux de mortalité du SIDA",
cex.main=0.80)
abline(lm(V$VIH ~ V$RNB), col="red", lwd=2)

```

#BOXPLOT#

```

par(mfrow = c(3,4))
A = boxplot(VIH_propre1[,c(2)],main = "Boxplot du taux de mortalité du SIDA", ylab = "Taux
de mortalité du SIDA")
points(x = rep(1, length(A$out)), y = A$out, col = "#990000", pch = 19)
B = boxplot(VIH_propre1[,c(3)],main = "Boxplot du PIB/Habitant", ylab = "PIB/Habitant")
points(x = rep(1, length(B$out)), y = B$out, col = "#990000", pch = 19)
C = boxplot(VIH_propre1[,c(4)],main = "Boxplot de l'espérance de vie à la naissance", ylab =
"L'espérance de vie à la naissance")
points(x = rep(1, length(C$out)), y = C$out, col = "#990000", pch = 19)
D = boxplot(VIH_propre1[,c(5)],main = "Boxplot de l'accès à l'électricité", ylab = "L'accès à
l'électricité en %")
points(x = rep(1, length(D$out)), y = D$out, col = "#990000", pch = 19)
O = boxplot(VIH_propre1[,c(6)],main = "Boxplot de la stabilité politique", ylab = "Stabilité
politique")
points(x = rep(1, length(O$out)), y = O$out, col = "#990000", pch = 19)
E = boxplot(VIH_propre1[,c(7)],main = "Boxplot de la population active ", ylab = "La
population active en %")

```

```

points(x = rep(1, length(E$out)), y = E$out, col = "#990000", pch = 19)
G = boxplot(VIH_propre1[,c(8)],main = "Boxplot de l'accès au traitement antirétroviraux",
ylab = "Accès au traitement antirétroviraux en %")
points(x = rep(1, length(G$out)), y = G$out, col = "#990000", pch = 19)
H = boxplot(VIH_propre1[,c(9)],main = "Boxplot des dépenses de santé courante", ylab =
"Dépenses de santé courante en % du PIB")
points(x = rep(1, length(H$out)), y = H$out, col = "#990000", pch = 19)
I = boxplot(VIH_propre1[,c(10)],main = "Boxplot de la population urbaine", ylab = "Population
urbaine en %")
points(x = rep(1, length(I$out)), y = I$out, col = "#990000", pch = 19)
J = boxplot(VIH_propre1[,c(11)],main = "Boxplot de l'incidence de la tuberculose", ylab =
"Incidence de la tuberculose pour 100 000")
points(x = rep(1, length(J$out)), y = J$out, col = "#990000", pch = 19)
K = boxplot(VIH_propre1[,c(12)],main = "Boxplot de la parts des femmes dans la
population", ylab = "% de la part des femmes dans les pays")
points(x = rep(1, length(K$out)), y = K$out, col = "#990000", pch = 19)
L = boxplot(VIH_propre1[,c(13)],main = "Boxplot de l'accès à l'eau", ylab = "L'accès à l'eau
en %")
points(x = rep(1, length(L$out)), y = L$out, col = "#990000", pch = 19)
M = boxplot(VIH_propre1[,c(14)],main = "Boxplot du RNB", ylab = "Revenue national brut
annuel")
points(x = rep(1, length(M$out)), y = M$out, col = "#990000", pch = 19)

```

#NUAGE DE POINTS#

```

hist_data = hist(VIH_propre1$`TAUX DE MORTALITE DU VIH`, col = "#990000", main =
"Représentation graphique de la distribution du taux de mortalité du SIDA",
  xlab="Taux de mortalité du SIDA", ylab = "Fréquence", ylim = c(0,80))
intervalles <- cut(VIH_propre1$`TAUX DE MORTALITE DU VIH`, breaks = hist_data$breaks,
right = TRUE)
table_intervalles <- table(intervalles)
percentages <- round((table_intervalles / sum(table_intervalles)) * 100, 1)
text(hist_data$mids, hist_data$counts, labels = percentages, pos = 3)

```

#ACP#

```

VIH_propre
new_names =
c("CODE","SIDA","PIB","VIE","ELEC","POL","POPA","ATV","SANTE","POPU","TUB","FEM","
EAU","RNB")
colnames(VIH_propre) = new_names
library(FactoMineR)
numerique_data <- VIH_propre[, 3:14]
standardise_data <- scale(numerique_data)
pca_resulta <- PCA(standardise_data, graph = FALSE)
summary(pca_resulta)

```

#ACP SIMPLISTE#

```

numerique_data2 <- VIH_propre[, 2:14]

```

```

standardise_data2 <- scale(numerique_data2)
pca_resulta2 <- PCA(standardise_data2, graph = FALSE)
summary(pca_resulta2)

#REPRESENTATION DANS L'ESPACE#
round(pca_resulta$var$contrib,2)
round(pca_resulta$var$cos2,2)
round(pca_resulta$var$coord,2)

coordo<-round(pca_resulta$var$coord,2)
corrplot(coordo, is.corr=FALSE, method="circle", tl.srt=45,
tl.col="#004400",col=brewer.pal(n=9, name="RdYlBu"), addCoef.col="black")
contribution<-round(pca_resulta$var$contrib,2)
corrplot(contribution, is.corr=FALSE, method="circle", tl.srt=45, tl.col="#003300",
col=brewer.pal(n=9,name="OrRd"), addCoef.col="black")
cosinus<-round(pca_resulta$var$cos2,2)
corrplot(cosinus, is.corr=FALSE, method="circle", tl.srt=45, tl.col="#004400",
col=brewer.pal(n=9, name="PiYG"), addCoef.col="black")

#HISTOGRAMME INERTIE#
fviz_eig(pca_resulta, addlabels = TRUE, ylim = c(0, 50), main = "")

#REPRESENTATION DES INDIVIDUS#
#TOUS#
coordIND = round(pca_resulta$ind$coord, 2)
cos2IND = round(pca_resulta$ind$cos2, 2)
contribIND = round(pca_resulta$ind$contrib, 2)
fviz_pca_ind(pca_resulta, col.ind="cos2", gradient.cols=c("#00AFBB", "#E7B800",
"#FC4E07"), repel=TRUE, title="projection des individus sur l'axe 1 et 2")
fviz_pca_ind(pca_resulta, axes=c(1,3), col.ind="cos2", gradient.cols=c("#00AFBB",
"#E7B800", "#FC4E07"), repel=TRUE, title="projection des individus sur l'axe 1 et 3")

#LES 15 LES PLUS CONTRIBUTIFS#
plot(pca_resulta,title = "15 pays les plus contributifs",select = "contrib15")
plot(pca_resulta,title = "15 pays les plus contributifs",select = "contrib15", axes = c(1,3))

#REPRESENTATION DES VARIABLES AVEC LE SIDA#
fviz_pca_var(pca_resulta, axes = c(1, 2), col.var="cos2") +
  scale_color_gradient2(low="skyblue", mid="orange",high="red", midpoint=0.65, space =
"Lab")
fviz_pca_var(pca_resulta, axes = c(1, 3), col.var="cos2") +
  scale_color_gradient2(low="skyblue", mid="orange",high="red", midpoint=0.65, space =
"Lab")

#REPRESENTATION DES VARIABLES SANS LE SIDA#
res.pca<- PCA(V[,c(2:14)], quanti.sup = 1)

```

```
fviz_pca_var(res.pca, axes = c(1,2), col.var="cos2", col.quanti.sup = "black") +
scale_color_gradient2(low="#00AFBB", mid="#E7B800",
                        high="#B40707",
midpoint=0.65, space = "Lab")
fviz_pca_var(res.pca, axes = c(1,3), col.var="cos2", col.quanti.sup = "black") +
scale_color_gradient2(low="#00AFBB", mid="#E7B800",
                        high="#B40707",
midpoint=0.65, space = "Lab")
```

#REGRESSION MULTIPLES#

#REGRESSION AVEC LES VARIABLES LATENTES 1 ET 2#

```
lm = lm(VIH_propre$`SIDA` ~ pca_resulta$ind$coord[,1]+
        pca_resulta$ind$coord[,2])
summary(lm)
VIH_propre$predict = round(predict(lm), 2)
VIH_propre$residu = round(residuals(lm), 2)
gvlma(lm)
ks.test(VIH_propre$residu, "pnorm", mean(VIH_propre$residu), sd(VIH_propre$residu))
skewness(VIH_propre$residu)
kurtosis(VIH_propre$residu)
```

#REGRESSION AVEC LES VARIABLES LATENTES 1 ET 3#

```
lm2 = lm(VIH_propre$`SIDA` ~ pca_resulta$ind$coord[,1]+
        pca_resulta$ind$coord[,3])
summary(lm2)
VIH_propre$predict2 = round(predict(lm2), 2)
VIH_propre$residu2 = round(residuals(lm2), 2)
gvlma(lm2)
ks.test(VIH_propre$residu2, "pnorm", mean(VIH_propre$residu2), sd(VIH_propre$residu2))
skewness(VIH_propre$residu2)
kurtosis(VIH_propre$residu2)
```

#REGRESSION AVEC LES VARIABLES LES PLUS CONTRIBUTIFS#

```
lm3 = lm(V$VIH ~ V$VIE + V$PIB + V$FEM + V$POPU + V$RNB)
summary(lm3)
VIH_propre$predict3 = round(predict(lm3), 2)
VIH_propre$residu3 = round(residuals(lm3), 2)
gvlma(lm3)
ks.test(VIH_propre$residu3, "pnorm", mean(VIH_propre$residu3), sd(VIH_propre$residu3))
skewness(VIH_propre$residu3)
kurtosis(VIH_propre$residu3)
```

#REGRESSION LOGIT#

#BINARISATION DE LA VARIABLE ILLUSTRATIVE#

#MEDIANE#

V\$VIH[V\$VIH > 0.03] = "1"

V\$VIH[V\$VIH <= 0.03] = "0"


```

V$VIH
V$VIH = as.numeric(V$VIH)
model = glm(V$VIH~pca_resulta$ind$coord[,1]+pca_resulta$ind$coord[,2],family=binomial)
summary(model)

#MOYENNE#
V$VIH[V$VIH > 0.5] = "1"
V$VIH[V$VIH <= 0.5] = "0"
V$VIH = as.numeric(V$VIH)
model = glm(V$VIH~pca_resulta$ind$coord[,1]+pca_resulta$ind$coord[,2],family=binomial)
summary(model)

#PREDICTION#
Predic <- predict(model)
VIH_propre$Predic <- round(Predic, 2)
VIH_propre$Predic <- pmax(VIH_propre$Predic, 0)
VIH_propre$`TAUX DE MORTALITE DU VIH`
VIH_propre$Predic
plot(VIH_propre$Predic, VIH_propre$`SIDA`,
     xlab = "Prédiction tx de mortalité du SIDA",
     ylab = "Tx de mortalité du SIDA observés",
     col = 0)
abline(a = 0, b = 1, col = "red", lty = 1)
text(VIH_propre$Predic, VIH_propre$`SIDA`, labels = row.names(VIH_propre), cex = 0.7)

hist(VIH_propre$Predic,col = "#990000",main="",
     xlab="Taux de mortalité du SIDA prédit", ylab = "Fréquence", ylim = c(0,50))
#LES RESIDUS#
VIH_propre$residu = round(residuals(lm),2)
VIH_propre
BOX = boxplot(VIH_propre$residu, main = "Résidu du modèle multiple")
points(x = rep(1, length(BOX$out)), y = BOX$out, col = "#990000", pch = 19)
hist(VIH_propre$residu,ylab="Nombre de pays", main = "Histogramme du modèle
multiple",freq = TRUE,col = "#CC0000",cex.main=0.8)
qqnorm(VIH_propre$residu,col = "#CC0000")
qqline(VIH_propre$residu,col = "#CC0000")

#LES TESTES#
VIH2 = VIH_propre[-c(11,38,73),]
VIH2$residu = round(residuals(lm),2)
VIH2
boxplot(VIH2$residu, main = "Résidu du modèle multiple")
hist(VIH2$residu,ylab="Nombre de pays", main = "Histogramme du modèle multiple",freq =
TRUE,col = "#CC0000",cex.main=0.8)
qqnorm(VIH2$residu,col = "#CC0000")
qqline(VIH2$residu,col = "#CC0000")

gvlma(lm3)

```

```

skewness(VIH_propre1$residu)
kurtosis(VIH$residu)
shapiro.test(VIH2$residu)
ks.test(VIH2$residu, "pnorm", mean(VIH2$residu), sd(VIH2$residu))

```

#COMPARAISON D'UNE DISTRIBUTION GAUSIENNE ET D'UNE DISTRIBUTION AVEC SKEWNESS POSITIVE#

```

data_normal <- rnorm(1000, mean = 0, sd = 1)
data_skewed <- rlnorm(1000, meanlog = 0, sdlog = 0.6)
df_normal <- data.frame(value = data_normal, distribution = "Gausienne")
df_skewed <- data.frame(value = data_skewed, distribution = "Skewed")
df_combined <- rbind(df_normal, df_skewed)
ggplot(df_combined, aes(x = value, fill = distribution, color = distribution)) +
  geom_density(alpha = 0.5) +
  theme_minimal() +
  labs(title = "Comparaison de la distribution normale et d'une distribution skewness
positive",
       x = "Valeur", y = "Densité")

```

#COMPARAISON D'UNE DISTRIBUTION GAUSIENNE ET D'UNE DISTRIBUTION AVEC KURSTOSIS POSITIVE#

```

data_high_kurt1 <- rnorm(1000, mean = 0, sd = sqrt(19.8))
data_high_kurt2 <- rnorm(1000, mean = 0, sd = sqrt(15.46))
data_high_kurt3 <- rnorm(1000, mean = 0, sd = sqrt(15.46))
data_normal <- rnorm(1000, mean = 0, sd = sqrt(50))

df1 <- data.frame(value = data_high_kurt1, set = "Modèle 1")
df2 <- data.frame(value = data_high_kurt2, set = "Modèle 2")
df3 <- data.frame(value = data_high_kurt3, set = "Modèle 3")
df4 <- data.frame(value = data_normal, set = "Gaussienne")
df_combined <- rbind(df1, df2, df3, df4)

ggplot(df_combined, aes(x = value, color = set)) +
  geom_density(size = 1) +
  theme_minimal() +
  labs(title = "Combinaison des distributions avec Kurtosis et Skewness spécifiques",
       x = "Valeur", y = "Densité")

```

IX. Bibliographie

« Annexe D. Rapport de la visite sur le terrain en Ouganda », *Revue de l'OCDE sur le développement*, vol. 10, no. 3, 2009, pp. 105-112.(Consulté le 02/11/2022)

« Annexe E : Le Programme d'Aide de l'Australie en Papouasie-Nouvelle-Guinée », *Revue de l'OCDE sur le développement*, vol. no6, no. 2, 2005, pp. 169-175.(Consulté le 02/11/2022)

Auster, R. L. and D. Sarachek (1969). The production of health: an exploratory study, 4, 411± 36. *Journal of Human Resources* 4: 411-447.

Bhaskaran K, Hamouda O, Sannes M, et al. Changements dans le risque de décès après séroconversion par le VIH par rapport à la mortalité dans la population générale. *JAMA*. 2008; 300(1):51–59. doi :10.1001/jama.300.1.51

Biggs B, King L, Basu S, Stuckler D. Is wealthier always healthier? The impact of national income level, inequality, and poverty on public health in Latin America. *Soc Sci Med*. 2010;71:266–273. pmid:20471147

Cook CT, Kalu K. The political economy of health policy in Sub-Saharan Africa. *Med Law*. 2008 Mar;27(1):29-51. PMID: 18592880.(Consulté le 31/10/2022)

Cutler D., Deaton A., Lleras-Muney A. 2006 : The Determinants of Mortality, *Journal of Economic Perspectives* 20(3), 97-120.

David A Leon, Cities, urbanization and health, *International Journal of Epidemiology*, Volume 37, Issue 1, February 2008, Pages 4–8, <https://doi.org/10.1093/ije/dym271>

Desclaux, A. Desgrées du Loû, A. « Les femmes africaines face à l'épidémie de sida », *Population et Sociétés*, 428, 4 p., 2006.

Drayer Francis, « Histoire de l'hôpital. L'éclairage des salles d'opération aux XIXe et XXe siècles : l'apparition du scialytique », *In Situ* [En ligne], 10 | 2009, mis en ligne le 19 mai 2009, consulté le 03 novembre 2023 (Consulté le 03/11/2022)

Docquier, Frédéric. « Fuite des cerveaux et inégalités entre pays », *Revue d'économie du développement*, vol. 15, no. 2-3, 2007, pp. 49-88. (Consulté le 31/10/2022)

Fact Sheet on differences in HIV Spread in four African Cities, UNAIDS, September 1999

Gao, Rui, and Hai-Hong Liu. "Political stability as a major determinant of the Covid-19 pandemic outcomes." *Heliyon* vol. 9,10 e20617. 5 Oct. 2023, doi:10.1016/j.heliyon.2023.e20617 (Consulté le 31/10/2022)

Gilks CF, Crowley S, Ekpini R, Gove S, Perriens J, Souteyrand Y, et al. The WHO public-health approach to antiretroviral treatment against HIV in resource-limited settings. *Lancet* 2006;368:505–510)

Glied, S., & Smith, P. C. (Eds.). (2013). *The Oxford handbook of health economics*. Oxford University Press.

Gulis, G. (2000). Life expectancy as an indicator of environmental health. *European journal of epidemiology*, 16, 161-165.

Institut national de la santé et de la recherche médicale (Inserm). VIH et sida. Site internet : Inserm. Paris ; 2018 [consulté le 30 octobre 2023]

Jen M. H., Johnston R., Jones K., Harris R., Gandy A. 2010 : International variations in life expectancy : A spatio-temporal analysis, *Tijdschrift voor economische en sociale geografie* 101(1), 73-90.

Jorland, Gérard. « L'hygiène publique, fille des Lumières », *Les Tribunes de la santé*, vol. 38, no. 1, 2013, pp. 23-27.(Consulté le 01/11/2022)

Kettani, Assiya El et al. "Co-infection VIH ... du CHU Ibn Rochd-Casablanca". *The Pan African medical journal* vol. 30 276. 16 Aug. 2018, doi:10.11604/pamj.2018.30.276.13913 (Consulté le 22/10/2022)

Khogali, A., Ahmed, A., Ibrahim, M., Karrar, K., Elsheikh, M., Abdelraheem, E., Cluver, L., & Elmukashfi, E. (2022). Building power-ful health systems: The impacts of electrification on health outcomes in LMICs. *Psychology, Health & Medicine*, 1–14.(Consulté le 03/11/2022)

Kleinbaum, D.G.; Klein, M. Logistic Regression for Correlated Data. In *Logistic Regression. Statistics for Biology and Health*; Springer: New York, NY, USA, 2010.

Lefève, Céline. « De la philosophie de la médecine de Georges Canguilhem à la philosophie du soin médical », *Revue de métaphysique et de morale*, vol. 82, no. 2, 2014, pp. 197-221.(Consulté le 01/11/2022)

Lert, France, OBADIA, Yolande, *et al.* Comment vit-on en France avec le VIH/sida?. *Population Societes*, 2004, vol. 406, no 10, p. 1-4.

Lydié, N. Garenne, M. (2001) Genre et Sida. - Paris, Centre français sur la population et le développement,, 37 p. ; 24 cm. (Les Dossiers du CEPED no 67).

Markandya A., Paul Wilkinson,Electricity generation and health,The Lancet,Volume 370, Issue 9591,2007,Pages 979-990,ISSN 0140-6736,(Consulté le 03/11/2022)

Marzano, Michela. « Foucault et la santé publique », *Les Tribunes de la santé*, vol. 33, no. 4, 2011, pp. 39-43. (Consulté le 01/11/2022)

Masquelier, B. & Reniers, G. (2018). Sida et écarts d'espérance de vie entre hommes et femmes en Afrique. *Population & Sociétés*, 554, 1-4.
<https://doi.org/10.3917/popsoc.554.0001>

Mpofu, R. T. (2013). Standard of living, quality of life and GDP: An Economics Peregrination. *The Business & Management Review*, 3(4), 100.

Mrozovski JM. Les dépenses de santé en temps de pandémie [Health costs in times of pandemic]. *Actual Pharm.* 2021 Jul;60(608):40-43. French. doi: 10.1016/j.actpha.2021.06.011. Epub 2021 Aug 26. PMID: 36339324; PMCID: PMC9617797.

Neiderud, C. J. (2015). How urbanization affects the epidemiology of emerging infectious diseases. *Infection ecology & epidemiology*, 5(1), 27060.

Nikolopoulos, G. K., Fotiou, A., Kanavou, E., Richardson, C., Detsis, M., Pharris, A., ... & Hatzakis, A. (2015). National income inequality and declining GDP growth rates are associated with increases in HIV diagnoses among people who inject drugs in Europe: a panel data analysis. *PloS one*, 10(4), e0122367.

OCDE, « Chapitre 2. Évolutions dans les pays membres de l'OCDE et dans certaines économies non membres », *Perspectives économiques de l'OCDE*, vol. 82, no. 2, 2007, pp. 73-199.

Préambule de la Constitution du 27 octobre 1946. (Consulté le 31/10/2022).

Pritchett, L., & Summers, L. H. (1993). *Wealthier is healthier* (Vol. 1150). World Bank Publications.

Reniers G., Blom S., Calvert C., A. Martin-Onraet et al., « Trends in the burden of HIV mortality after roll-out of antiretroviral therapy in KwaZulu-Natal, South Africa: An observational community cohort study », *Lancet HIV*, 4(3), p. e113–e121, 2017

Reyes, R., Ahn, R., Thurber, K., & Burke, T. F. (2013). Urbanization and infectious diseases: general principles, historical perspectives, and contemporary challenges. *Challenges in infectious diseases*, 123-146.

Stillwagon E. (2000). HIV Transmission in Latin America : Comparisons with Africa and Policy Implications, *South African Journal of Economics*, vol. 68, December 2000.

Tsafack Temah, Chrystelle. « Les déterminants de l'épidémie du VIH/SIDA en Afrique subsaharienne », *Revue d'économie du développement*, vol. 17, no. 1-2, 2009, pp. 73-106.(Consulté le 30/10/2022)

UNAIDS. UNAIDS DATA 2017. Pour des estimations récentes sur différents indicateurs liés au sida, voir <http://aidsinfo.unaids.org/>

UNAIDS Global AIDS Monitoring, 2023; UNAIDS epidemiological estimates, 2023 (<https://aidsinfo.unaids.org/>) (Consulté le 30/10/2022)

Vauthier Gabriel. Le Choléra à Paris en 1832. In: *La Révolution de 1848 et les révolutions du XIXe siècle*, Tome 25, Numéro 127, Décembre 1928-janvier-février 1929. pp. 234-241.(Consulté le 01/11/2022)

Wegelin-Schuringa, M., & Kamminga, E. (2006). Water and sanitation in the context of HIV/AIDS: the right of access in resource-poor countries. *Health and Human Rights*, 152-172.

White G, Bradley D & White A (1972)Drawers of Water:Domestic Water Use in East Africa. University of ChicagoPress, Chicago.

Zanakis, Stelios H. & Alvarez, Cecilia & Li, Vivian, 2007.Socio-economic determinants of HIV/AIDS pandemic and nations efficiencies,"European Journal of Operational Research, Elsevier, vol. 176(3), pages 1811-1838, February.(Consulté le 02/11/2022)

Zarulli, V., Sopina, E., Toffolutti, V., & Lenart, A. (2021). Health care system efficiency and life expectancy: A 140-country study. *PLOS one*, 16(7), e0253450.

Zellweger, J. VIH et tuberculose : nouvelles perspectives de diagnostic et de traitement, *Rev Med Suisse*, Vol. -8, no. 087, 2006, pp. 2616–2619. (Consulté le 22/10/2022)

Sitographie :

[Journée mondiale de lutte contre le sida | ONUSIDA \(unaids.org\)](https://www.unaids.org/fr/journee-mondiale-de-lutte-contre-le-sida)

[FACT SHEET \(unaids.org\)](https://www.unaids.org/fr/fact-sheet)

[VIH et sida \(who.int\)](https://www.who.int/fr/news-room/fact-sheets/detail/hiv-aids)

[Définition - Taux de mortalité | Insee](https://www.insee.fr/fr/statistiques/1212121?geo=FRANCE&geo2=FRANCE&geo3=FRANCE&geo4=FRANCE&geo5=FRANCE&geo6=FRANCE&geo7=FRANCE&geo8=FRANCE&geo9=FRANCE&geo10=FRANCE&geo11=FRANCE&geo12=FRANCE&geo13=FRANCE&geo14=FRANCE&geo15=FRANCE&geo16=FRANCE&geo17=FRANCE&geo18=FRANCE&geo19=FRANCE&geo20=FRANCE&geo21=FRANCE&geo22=FRANCE&geo23=FRANCE&geo24=FRANCE&geo25=FRANCE&geo26=FRANCE&geo27=FRANCE&geo28=FRANCE&geo29=FRANCE&geo30=FRANCE&geo31=FRANCE&geo32=FRANCE&geo33=FRANCE&geo34=FRANCE&geo35=FRANCE&geo36=FRANCE&geo37=FRANCE&geo38=FRANCE&geo39=FRANCE&geo40=FRANCE&geo41=FRANCE&geo42=FRANCE&geo43=FRANCE&geo44=FRANCE&geo45=FRANCE&geo46=FRANCE&geo47=FRANCE&geo48=FRANCE&geo49=FRANCE&geo50=FRANCE&geo51=FRANCE&geo52=FRANCE&geo53=FRANCE&geo54=FRANCE&geo55=FRANCE&geo56=FRANCE&geo57=FRANCE&geo58=FRANCE&geo59=FRANCE&geo60=FRANCE&geo61=FRANCE&geo62=FRANCE&geo63=FRANCE&geo64=FRANCE&geo65=FRANCE&geo66=FRANCE&geo67=FRANCE&geo68=FRANCE&geo69=FRANCE&geo70=FRANCE&geo71=FRANCE&geo72=FRANCE&geo73=FRANCE&geo74=FRANCE&geo75=FRANCE&geo76=FRANCE&geo77=FRANCE&geo78=FRANCE&geo79=FRANCE&geo80=FRANCE&geo81=FRANCE&geo82=FRANCE&geo83=FRANCE&geo84=FRANCE&geo85=FRANCE&geo86=FRANCE&geo87=FRANCE&geo88=FRANCE&geo89=FRANCE&geo90=FRANCE&geo91=FRANCE&geo92=FRANCE&geo93=FRANCE&geo94=FRANCE&geo95=FRANCE&geo96=FRANCE&geo97=FRANCE&geo98=FRANCE&geo99=FRANCE&geo100=FRANCE)

[AIDSinfo | UNAIDS](https://aidsinfo.unaids.org/)

[Population urbaine \(% du total\) | Data \(banquemondiale.org\)](https://data.banquemondiale.org/indicators/SV.UO.DS.CV?locations=FR)

[Objectifs de développement durable | Nations Unies](https://www.un.org/fr/development/durable/)

[Produit intérieur brut par habitant dans l'Union européenne | Insee](https://www.insee.fr/fr/statistiques/1212121?geo=FRANCE&geo2=FRANCE&geo3=FRANCE&geo4=FRANCE&geo5=FRANCE&geo6=FRANCE&geo7=FRANCE&geo8=FRANCE&geo9=FRANCE&geo10=FRANCE&geo11=FRANCE&geo12=FRANCE&geo13=FRANCE&geo14=FRANCE&geo15=FRANCE&geo16=FRANCE&geo17=FRANCE&geo18=FRANCE&geo19=FRANCE&geo20=FRANCE&geo21=FRANCE&geo22=FRANCE&geo23=FRANCE&geo24=FRANCE&geo25=FRANCE&geo26=FRANCE&geo27=FRANCE&geo28=FRANCE&geo29=FRANCE&geo30=FRANCE&geo31=FRANCE&geo32=FRANCE&geo33=FRANCE&geo34=FRANCE&geo35=FRANCE&geo36=FRANCE&geo37=FRANCE&geo38=FRANCE&geo39=FRANCE&geo40=FRANCE&geo41=FRANCE&geo42=FRANCE&geo43=FRANCE&geo44=FRANCE&geo45=FRANCE&geo46=FRANCE&geo47=FRANCE&geo48=FRANCE&geo49=FRANCE&geo50=FRANCE&geo51=FRANCE&geo52=FRANCE&geo53=FRANCE&geo54=FRANCE&geo55=FRANCE&geo56=FRANCE&geo57=FRANCE&geo58=FRANCE&geo59=FRANCE&geo60=FRANCE&geo61=FRANCE&geo62=FRANCE&geo63=FRANCE&geo64=FRANCE&geo65=FRANCE&geo66=FRANCE&geo67=FRANCE&geo68=FRANCE&geo69=FRANCE&geo70=FRANCE&geo71=FRANCE&geo72=FRANCE&geo73=FRANCE&geo74=FRANCE&geo75=FRANCE&geo76=FRANCE&geo77=FRANCE&geo78=FRANCE&geo79=FRANCE&geo80=FRANCE&geo81=FRANCE&geo82=FRANCE&geo83=FRANCE&geo84=FRANCE&geo85=FRANCE&geo86=FRANCE&geo87=FRANCE&geo88=FRANCE&geo89=FRANCE&geo90=FRANCE&geo91=FRANCE&geo92=FRANCE&geo93=FRANCE&geo94=FRANCE&geo95=FRANCE&geo96=FRANCE&geo97=FRANCE&geo98=FRANCE&geo99=FRANCE&geo100=FRANCE)

<https://www.sidaction.org/chrono-vih> (Consulté le 02/11/2022)

<https://www.un.org/fr/development/durable/> (Consulté le 30/10/2022)

https://www.lemonde.fr/societe/article/2019/12/01/pour-les-jeunes-le-sida-c-est-un-e-maladie-de-vieux-ils-ne-se-sentent-pas-vraiment-concernes_6021221_3224.html
(Consulté le 30/10/2022)

https://www.unaids.org/sites/default/files/media_asset/youngpeoplehivaids_fr_0.pdf
(Consulté le 30/10/2022)

<https://www.who.int/fr/news/item/09-12-2020-who-reveals-leading-causes-of-death-and-disability-worldwide-2000-2019> (Consulté le 22/10/2022)

[https://www.who.int/fr/news-room/fact-sheets/detail/millennium-development-goals-\(mdgs\)](https://www.who.int/fr/news-room/fact-sheets/detail/millennium-development-goals-(mdgs)) (Consulté le 22/10/2022)

<https://www.inspq.qc.ca/en/node/927> (Consulté le 22/10/2022)

Table des matières

Sommaire.....	1
I. Introduction.....	2
II. Analyse détaillée du sujet : Présentation du taux de mortalité du VIH/sida et des variables actives associées.....	5
A. Pertinence de la variable à expliquer : le taux de mortalité du SIDA.....	5
B. Rôle des variables explicatives.....	7
1) Variables économiques.....	7
a - Revenu National Brut annuel par habitant.....	7
b - La stabilité politique.....	9
c - PIB par habitant.....	10
d - L' Accès à l'électricité.....	12
2) Variables socio-démographique.....	14
a - Part de la population actives en pourcentage.....	14
b - Pourcentage de femmes dans la société.....	16
c - Pourcentage de la population urbaine.....	17
3) Variables sur le contexte sanitaire.....	19
a- Espérance de vie.....	19
b - Accès à l'eau potable.....	20
c - Dépenses publiques pour la santé.....	22
d - L'incidence de la tuberculose pour 100 000 personnes.....	23
e -Pourcentage de la population vivant sous traitements antirétroviraux (TAR).....	25
4) Autres variables.....	26
C) Statistiques descriptives et corrélations entre le taux de mortalité du Sida et les variables actives.....	27
1) Tableau récapitulatif du modèle.....	27
2) Analyse des statistiques descriptives et des valeurs aberrantes.....	28
a) Etude statistique du taux de mortalité du VIH.....	28
b) Etude statistique des variables actives.....	29
3) Analyse de la corrélation entre la variable illustrative et les variables actives.....	32
III. Analyse en Composantes Principales ACP.....	35
A) Valeurs propre et nombre d'axes.....	35
B) Variables : contributions, coordonnées, cosinus carrés.....	37
C) Cercle de corrélation.....	40
D) Définition des variables latentes.....	43
E) Projection des individus sur le plan factoriel, interprétation.....	48
1) Projections de tous les individus.....	48
2) Projections des 15 individus les plus contributifs.....	51
IV. Corrélation entre le taux de mortalité du SIDA et les variables latentes identifiées.....	55
A) Régression linéaire multiple.....	55

1) Résultats de la régression linéaire multiple effectuée avec les variables latentes des axes 1 et 2.....	55
2) Résultats de la régression linéaire multiple effectuée avec les variables latentes des axes 1 et 3.....	57
3) Régression à l'aide des variables les plus contributives identifiées lors de l'ACP.....	58
4) tests des modèles.....	59
5) Choix du modèle le plus performant.....	62
B) Relation entre la variable illustrative observée et prédite par RLM.....	62
C) Régression logistique binaire.....	65
1) Régression log 1 : Régression logistique sur les axes 1 et 2.....	65
2) Régression log 2 : Régression logistique sur les axes 1 et 3.....	66
3) Choix du meilleur modèle logistique.....	67
V. Modifications du modèle de régression.....	68
Tests de Ramsey.....	68
Modification de la forme fonctionnelle du modèle.....	68
VI. Discussion des résultats.....	71
A. Problèmes d'échantillon.....	71
B. Problèmes de variables.....	72
C. Problèmes de modélisation.....	73
VII. Conclusions et recommandations.....	74
VIII. Annexes.....	75
A. Tableaux et graphiques supplémentaires.....	75
B. Base de données nettoyée.....	90
C. Code R.....	91
IX. Bibliographie.....	111
Table des matières.....	117
Table des figures, tableaux et modèles.....	119

Table des figures, tableaux et modèles

Figures :

Figure 1 : Evolution de la mortalité moyenne dans le monde due au Sida pour 1000 habitants 1990 et 2022

Figure 2 : Taux de mortalité du SIDA pour 1000 habitants en 2020 par pays

Figure 3 : Statistique descriptives et boxplot de la variable illustrative

Figure 4 : Représentation graphique de la distribution du taux du SIDA

Figure 5 : Boxplots des variables actives

Figure 6 : Infographie des corrélations entre les variables

Figure 7 : Résultat de la diagonalisation

Figure 8 : Histogramme des pourcentage des variances

Figure 9 : Représentation de la contribution, coordonnées et $\cos^2$

Figure 10 : Projection des variables actives sur les axes 1 et 2 du cercle de corrélation

Figure 11 : Projection des variables actives sur les axes 1 et 3 du cercle de corrélation

Figure 12 : Projection de la variable illustrative SIDA sur les axes 1 et 2 du cercle de corrélation

Figure 13 : Projection de la variable illustrative SIDA sur les axes 1 et 3 du cercle de corrélation

Figure 14 : Représentation des variables latentes en fonctions des cadrans

Figure 15 : Projections des individus sur les axes 1 et 2

Figure 16 : Projections des individus sur les axes 1 et 3

Figure 17 : Projections des 15 individus les plus contributifs sur les axes 1 et 2

Figure 18 : Projections des 15 individus les plus contributifs sur les axes 1 et 3

Figure 19 : Modèle 1 : Résultats de la régression linéaire multiple effectuée avec les variables latentes des axes 1 et 2

Figure 20 : Modèle 2 : Résultats de la régression linéaire multiple effectuée avec les variables latentes des axes 1 et 3

Figure 21 : Modèle 3 : régression linéaire à l'aide des variables les plus contributives sur les axes 1 et 3 identifiées lors de l'ACP

Figure 22 : Comparaison d'une distribution d'une loi Gaussienne par rapport à une loi possédant une Skewness positive

Figure 23 : Comparaison d'une distribution d'une loi Gaussienne par rapport à une loi possédant une Kurtosis positive

Figure 24 : Classement des prédictions effectuées :

Figure 25 : Représentation des prédictions en fonction des observations

Tableaux :

Tableau 1 : Tableau récapitulatif de la revue de littérature

Tableau 2 : Tableau des statistique descriptives des variables actives

Tableau 3 : Tableau des statistique descriptives des variables actives

Tableau 4 : Tableau d'oppositions des variables selon les axes

Tableau 5 : Représentation des 15 individus les plus contributifs en fonctions des cadrans représentant l'axe 1 et l'axe 2

Tableau 6 : Représentation des 15 individus les plus contributifs en fonctions des cadrans représentant l'axe 1 et l'axe 3

Tableau 7 : Tableau des résultats des tests des modèles

Tableau 8 : Tableau des résultats des tests des modèles (p-value)

Tableau 9 : Tableau récapitulatif des modèles

Modèles :

Modèle 1: Résultats de la régression logistique effectuée avec les variables latentes des axes 1 et 2

Modèle 2 : Résultats de la régression logistique effectuée avec les variables latentes des axes 1 et 3