

Dossier d'Économétrie spatiale
MASTER 2 ECAP

Analyse et modélisation des causes et facteurs susceptibles
d'impacter la disparité sur l'implantation des laboratoires en
France métropolitaine en 2020

Dossier réalisé par :

Gestin Ugo

Mocaër Rodolphe

Sous la direction de Muriel Travers et Fabien Morineau

Année universitaire 2024-2025

Analyse et modélisation des causes et facteurs potentiellement susceptibles d'impacter la disparité sur l'implantation des laboratoires en France métropolitaine en 2020.

Résumé

L'analyse économétrique des différents facteurs influençant la disparité de l'implantation des laboratoires en France métropolitaine en 2020 est un enjeu clé pour la santé publique, afin de limiter au mieux les zones sans laboratoire. L'étude des relations spatiales s'avère donc essentielle dans cette analyse. L'application du modèle SDM avec la matrice Reine nous a permis de mettre en évidence le rôle déterminant de la natalité dans la répartition des laboratoires. Afin de compléter l'étude, l'intégration de variables supplémentaires, telles que la densité de population, pourrait apporter des résultats complémentaires.

Mots clés : Densité de laboratoire, facteurs, Relation spatiale, Modèle SDM

Analysis and modeling of the causes and factors potentially likely to impact disparities in the distribution of laboratories in metropolitan France in 2020.

Abstract

The econometric analysis of the various factors influencing the disparity in laboratory distribution in metropolitan France in 2020 is a key issue for public health, aiming to minimize areas without laboratories as much as possible. The study of spatial relationships is therefore essential in this analysis. The application of the SDM model with the Queen matrix has allowed us to highlight the determining role of birth rates in the distribution of laboratories. To complete the study, the integration of additional variables, such as population density, could provide complementary results.

Keywords : Laboratory density, factors, Spatial relationship, SDM model

Sommaire

Résumé.....	I
Abstract.....	II
Sommaire.....	III
I - Introduction.....	1
II - Analyse exploratoire & descriptives.....	3
III - Relation spatiale.....	13
IV - Estimation et résultats des modèles.....	18
V - Conclusion & Discussion.....	25
VI - Bibliographie.....	26
VII - Annexe.....	27
IX - Table des Figures & Tableau.....	32
IX - Table des matières.....	34

I - Introduction

L'implantation des laboratoires en France métropolitaine soulève des enjeux cruciaux dans le cadre de la politique de santé publique et de la lutte contre les inégalités d'accès aux soins. En dépit des efforts déployés pour assurer une couverture homogène sur l'ensemble du territoire, avec le plan d'accès aux soins, présenté en octobre 2017¹ ainsi que la stratégie Ma Santé 2022², une concentration des infrastructures de santé, y compris des laboratoires, reste observée dans certaines régions au détriment d'autres. Cette disparité géographique, qui donne naissance à de véritables "déserts diagnostiques"³ peut avoir des conséquences majeures, non seulement sur la qualité des soins dispensés, mais aussi sur la répartition équitable des ressources médicales et la gestion des flux de patients. En effet, dans des zones rurales ou périphériques, l'accès aux services de santé, et en particulier aux laboratoires, peut être limité, voire inexistant, ce qui augmente les inégalités sociales de santé.

L'objectif de cette étude est d'analyser les facteurs susceptibles d'impacter la répartition géographique des laboratoires en France, en prenant en compte la complexité des dynamiques territoriales. L'analyse économétrique spatiale permet d'évaluer la façon dont différentes caractéristiques socio-économiques, géographiques et démographiques peuvent influencer l'implantation des laboratoires. Par ailleurs, cette approche permet de comprendre les effets de voisinage, c'est-à-dire comment les choix d'implantation dans une zone donnée peuvent affecter les zones environnantes. Au-delà de la simple cartographie de la répartition, l'enjeu réside dans la compréhension des mécanismes sous-jacents à cette répartition inégale. En identifiant les facteurs déterminants de la présence des laboratoires, cette étude se veut un outil d'aide à la décision pour les acteurs publics et privés, afin de repenser les stratégies d'implantation, de développer une offre de soins plus équitable et d'améliorer l'accessibilité des services de santé à tous, peu importe la localisation géographique.

Dans ce contexte, cette étude vise à éclairer les décideurs sur les leviers à actionner pour réduire les disparités dans l'implantation des laboratoires et, plus

¹<https://sante.gouv.fr/archives/archives-presse/archives-breves/article/presentation-du-plan-pour-l-ega-l-acces-aux-soins-dans-les-territoires>

²<https://sante.gouv.fr/archives/masante2022/>

³<https://www.lequotidiendumedecin.fr/sante-societe/demographie/la-biologie-hors-les-murs-solution-a-ux-inegalites-de-sante>

largement, améliorer la performance du système de santé français, en contribuant à une répartition plus équilibrée et rationnelle des infrastructures de santé. Ainsi, dans un premier temps, nous étudierons les données mises à contribution dans notre étude, en passant aussi bien par l'analyse de la corrélation que par celle des distributions. Par la suite, nous analyserons les relations spatiales, tant globales que locales, permettant ainsi de mettre en évidence la direction et l'intensité de la dépendance spatiale sur l'ensemble du territoire étudié. Enfin, nous pourrions estimer et analyser les résultats du modèle soigneusement choisi, ce qui nous permettra de répondre à notre question initiale et de proposer des pistes de solution.

II - Analyse exploratoire & descriptives

Afin de commencer l'étude de manière optimale, il est primordial de réaliser une analyse exploratoire regroupant l'étude des statistiques descriptives, la répartition spatiale, la corrélation et les distributions, dans le but de comprendre au mieux les facteurs étudiés et utilisés dans notre analyse.

A) Statistique descriptives

Nous pouvons, dès lors analyser les statistiques descriptives de l'ensemble de nos facteurs afin de mieux comprendre aussi bien les tendances centrales, leurs distribution et leurs dispersion.

1) Variable dépendante

Nous décidons de débiter notre étude par l'analyse de notre variables dépendantes seule, étant la "Densité de laboratoire" en France métropolitaine en 2020.

Tableau 1 : Récapitulatifs des statistiques descriptif de la variable d'intérêt

Statistiques descriptives							
Variable	Min	1Q	Median	Moyenne	3Q	Max	Var
Densité de laboratoire	1,300	3,975	4,700	5,168	6,150	12,500	3,358

sources : Auteurs, Rstudio

En étudiant le tableau 1, nous pouvons remarquer que la moyenne est légèrement plus élevée que la médiane, de 0,4 point, ce qui pourrait indiquer l'influence des "valeurs extrêmes", telles que le maximum de notre échantillon, représenté notamment par les "Bouches-du-Rhône". Par la suite, nous observons que la densité des laboratoires présente une plage de données limitée, validée par la variance de 3,358. Néanmoins, l'indice multiplicateur entre le minimum et le maximum, égal à 9,6, reste cependant préoccupant, suggérant une surreprésentation dans certains départements par rapport à d'autres, comme la différence entre les "Bouches-du-Rhône"(Maximum) et le "Puy-de-Dôme"(Minimum). Ainsi, les résultats de cette analyse nous permettraient de conclure à l'existence d'une tendance centrale dans nos données, que nous allons

vérifier notamment par la représentation de la distribution de l'ensemble de nos variables.

2) Variables indépendantes

Une fois l'analyse de nos variables dépendantes effectuée, nous pouvons passer à l'étude des statistiques descriptives de nos variables indépendantes, à savoir le "salaire net", le "nombre de naissances", le "taux de chômage" et la part de résidences secondaires, qui sont autant de facteurs représentatifs de la France en 2020, par département.

Tableau 2 : Récapitulatifs des statistiques descriptif des variables explicatives

Statistiques descriptives							
Variable	Min	1Q	Médiane	Moyenne	3Q	Max	Var
Salaire net	12,69	13,85	14,27	14,90	15,25	26,90	4,927
Nombre de naissance	525	2560	5124	7243	9409	30145	46.10 ⁶
Taux de chômage	4,300	6,500	7,300	7,552	8,225	12,300	2,160
Part de résidence secondaire	1,113	4,628	7,856	11,465	16,528	45,540	92,707

sources : Auteurs, Rstudio

En examinant le tableau 2, nous pouvons remarquer deux sous-groupes dans nos variables indépendantes, chacun présentant des propriétés statistiques différentes. Le premier est constitué des variables telles que le salaire net et le taux de chômage, pour lesquelles nous observons que les valeurs extrêmes n'impactent que légèrement la moyenne, comme le montre une moyenne juste au-dessus de la médiane, mais aussi la possible présence d'une tendance centrale, confirmée par une variance faible et une plage de données limitée. En revanche, le second groupe, composé des variables telles

que le nombre de naissances et la part de résidences secondaires, présente une moyenne beaucoup plus impactée par les valeurs extrêmes, ce qui entraîne une moyenne différente de la médiane. De plus, la variance étant élevée et la plage de données étant étendue, il est peu probable d'y retrouver une tendance centrale. Enfin, il est important de noter que, bien que le nombre de naissances et la part de résidences secondaires puissent être analysées simultanément, la variable "nombre de naissances" possède probablement une distribution beaucoup plus fortement asymétrique et non-gaussienne que la variable "part de résidences secondaires".


B) Répartition spatiale

Une fois l'étude des statistiques descriptives effectuée, nous pouvons passer à la visualisation de la répartition spatiale de nos données, ce qui nous permettra de consolider notre analyse et d'étudier au préalable s'il existe déjà des schémas de répartition pour chacune de nos variables.

1) Variable dépendante

Nous commençons notre analyse avec la répartition spatiale de notre variable d'intérêt, à savoir la densité de laboratoire d'analyse par département.

Carte 1 : Répartition de la densité de laboratoire d'analyse en France
Métropolitaine par département (2020)




La carte 1 met en évidence une disparité marquée dans la densité des laboratoires d'analyse par département en France en 2020. Les zones urbaines comme Paris ou la Côte d'Azur présentent une densité élevée, liée à une forte demande et à une concentration de population, tandis que les régions rurales du centre et du nord affichent une densité nettement plus faible. Ainsi, nous pouvons observer la situation du Puy de Dôme marquée par une densité de laboratoires particulièrement faible. La Corse, malgré sa faible population, se démarque avec une densité notable, probablement liée à sa spécificité insulaire.

2) Variable indépendante

Intéressons nous maintenant aux répartitions spatiales de nos variables dépendantes.

Carte 2 : Répartition du taux de chômage en France Métropolitaine par département


Taux de chômage par département (2020)



La carte 2 révèle une grande hétérogénéité territoriale. Les taux de chômage les plus élevés se concentrent dans les régions du sud, comme l'Occitanie et la Provence-Alpes-Côte d'Azur, ainsi que dans certains départements du nord. À l'inverse, les taux les plus faibles se retrouvent principalement dans les départements de l'ouest et du centre de la France, qui bénéficient de dynamiques économiques plus favorables.

Carte 3 : Distribution des part des résidences secondaires en France
Métropolitaine par département

Part de résidences secondaires par département (2020)




sources : Auteurs, Rstudio

La carte 3 met en évidence une concentration élevée dans certaines zones spécifiques, notamment dans les régions touristiques. Les départements des Alpes, de la côte méditerranéenne et de la Corse affichent les pourcentages les plus élevés, dépassant les 30 %, ce qui peut être lié à leur attractivité pour les résidences de vacances. À l'inverse, les départements de l'intérieur et ceux historiquement moins touristiques, notamment dans le nord et l'est, présentent une proportion nettement plus faible, souvent inférieure à 10 %.

Carte 4 : Distribution du salaire net horaire moyen répartie en 5 classes
(quantiles) en France Métropolitaine par département

Salaire net horaire moyen par département en fonction de 5 classes (2020)




sources : Auteurs, Rstudio

La carte 4 montre la répartition du salaire net horaire moyen par département en 2020. Les données sont classées en cinq intervalles à l'aide de la méthode des quantiles. Cette approche a permis de répartir équitablement les départements entre les différentes classes et de mieux visualiser les disparités territoriales, atténuant l'effet des salaires très élevés de Paris. Les départements avec les salaires les plus élevés (15,3 à 26,9 €) se situent principalement en Île-de-France, tandis que les zones rurales ou économiquement moins dynamiques, notamment dans le centre et le nord-ouest, présentent les salaires les plus bas (12,7 à 13,7 €).

Carte 5 : Répartition du nombre de naissance en France Métropolitaine par département en 2020

Nombre de naissances par département (2020)




sources : Auteurs, Rstudio

Pour finir, la carte 5 permet d'observer une forte concentration des naissances dans les départements les plus peuplés, notamment en Île-de-France et dans les Bouches-du-Rhône, où les valeurs atteignent jusqu'à 30 000 naissances en 2020. À l'inverse, les départements ruraux ou moins densément peuplés, comme ceux du Massif central et de la Corse, enregistrent des chiffres beaucoup plus bas, souvent inférieurs à 10 000 naissances.

C) Etude de corrélation

L'étude de la répartition spatiale de nos variables étant réalisée, nous pouvons passer à l'analyse de la corrélation, ce qui nous permettra de postuler la présence, ou non, de différents liens dans notre base de données. Il est important de préciser que nous nous focaliserons principalement sur les corrélations entre la densité de laboratoires et les variables indépendantes.

Figure 1 : Matrice de corrélation




sources : Auteurs, Rstudio

En analysant la figure X, nous pouvons remarquer qu'il existe principalement des relations faibles et modérées, ce qui indique l'absence de multicollinéarité. En effet, aucune des corrélations ne dépasse 0,7, le maximum étant la corrélation de 0,66 entre le nombre de naissances et le salaire net horaire. De plus, il est important de noter que la majorité des corrélations sont positives, ce qui suggère une tendance générale où l'augmentation d'une variable est associée à l'augmentation de l'autre. En revanche, les corrélations négatives, bien que faiblement représentées, peuvent être interprétées comme une tendance où l'augmentation d'une variable est associée à une diminution de l'autre. En ce qui concerne notre variable dépendante, elle présente uniquement des corrélations positives, avec une corrélation maximale avec le nombre de naissances. Cela peut être interprété comme le fait que l'augmentation de la densité de laboratoires dans un département en France est associée à une augmentation du nombre de naissances, ce qui semble logique.

D) Étude des distributions

Figure 2 : Distributions des variables quantitatives



sources :

Auteurs, Géoda

Le taux de chômage présente une distribution légèrement asymétrique à droite : la plupart des départements se situent entre 6,6 % et 8,9 %, tandis que très peu dépassent 11 %, indiquant une certaine homogénéité dans les niveaux de chômage entre départements. Le salaire net horaire, quant à lui, montre une asymétrie marquée à droite, la grande majorité des départements affichant des valeurs comprises entre 12,7 € et 16,8 €. Des salaires horaires élevés, supérieurs à 20 €, restent rares et concernent les zones économiquement dynamiques. La densité de laboratoires présente une concentration de départements ayant entre 2,9 et 7,7 laboratoires pour 100 000 habitants. Les départements très bien équipés, dépassant 9 laboratoires, sont en minorité, ce qui pourrait refléter une centralisation des infrastructures de recherche. Le nombre de naissances, lui, présente une asymétrie extrême à droite. La majorité des départements enregistrent moins de 9 000 naissances, tandis que quelques zones fortement urbanisées, comme l'Île-de-France ou le Rhône, comptent plus de 17 000 naissances, révélant d'importantes disparités démographiques. Enfin, le taux de résidences secondaires illustre une prédominance de résidences principales dans la majorité des départements, avec des taux inférieurs à 13,8 %. Cependant, certains

départements dépassent 32,8 %, soulignant leur attractivité touristique ou leur caractère rural.

III - Relation spatiale

Une fois notre analyse exploratoire effectuée, nous permettant de mieux comprendre l'ensemble des caractéristiques de nos variables et des relations inter-variables, nous pourrions dès lors passer à l'analyse d'une étape primordiale : l'étude de l'autocorrélation spatiale, tant globale que locale. Cette étude nous permettra alors d'examiner au mieux la présence ou non d'interactions entre les départements. Notre analyse se concentrera principalement sur le principe selon lequel la densité de laboratoires d'un département peut impacter la densité des départements voisins. Pour ce faire, nous utiliserons un ensemble de quatre relations spatiales entre les individus. Ce large panel est rendu possible par la matrice de poids. Il sera constitué de l'hypothèse de la tour, de la reine, du plus proche voisin (PPV1) et des trois plus proches voisins (PPV3).

A) Autocorrélation spatiale globale

Nous débuterons notre analyse par l'étude de l'autocorrélation spatiale, en nous concentrant notamment sur l'ensemble des résultats produits par le test statistique de l'indice de Moran, comprenant une approche analytique et une approche dite de "Monte-Carlo". Ce test nous permettra ainsi de conclure sur le signe (positif ou négatif) ainsi que sur la présence d'autocorrélation spatiale globale entre les départements dans notre étude, puis nous poursuivrons notre analyse à l'aide des diagrammes de Moran nous permettant alors de visualiser au mieux les relations d'autocorrélation globale.

1) Statistique de Moran

Il est important de noter que nous interprétons la statistique de Moran uniquement si l'hypothèse nulle est rejetée au seuil de risque de 5 %, c'est-à-dire si la valeur de la p-value est inférieure à 0.05.

Tableau 3 : Résultats des différentes statistiques de Moran

Hypothèses	Approche analytique		Approche Monte-Carlo	
	Statistique	p-value	Statistique	p-value

Tour	0,43	$1,35.10^{-11}$	0,43	0,001
Reine	0,43	$1,35.10^{-11}$	0,43	0,001
PPV1	0,44	$1,82.10^{-4}$	0,44	0,001
PPV3	0,44	$8,17.10^{-10}$	0,44	0,001

sources : Auteurs, Rstudio, Annexe 1 à 4

En analysant le tableau 3, nous observons que l'ensemble des hypothèses de relations spatiales rejette l'hypothèse nulle au seuil de risque de 1 % du test statistique de Moran, car elles possèdent une p-value inférieure à 0,01. Cela nous permet de conclure à la présence d'une autocorrélation spatiale globale entre les départements dans notre étude, mais également d'examiner le signe des statistiques, tant pour l'approche analytique que pour celle de "Monte-Carlo", pour chaque hypothèse de relation spatiale. Ainsi, nous remarquons que nous obtenons les mêmes résultats pour les deux approches, pour chaque hypothèse de relation spatiale, c'est-à-dire des valeurs supérieures à 0 et comprises entre 0,40 et 0,45. Cela nous permet alors de conclure à une autocorrélation spatiale globale positive dans nos données pour l'ensemble de nos hypothèses, ce qui peut être interprété ainsi : la densité de laboratoire d'un département en France métropolitaine est positivement influencée par la densité de laboratoire des départements voisins.

2) Diagramme de Moran


Nous pouvons dès lors passer à l'étude des diagrammes de Moran correspondant à nos différentes hypothèses, réparties en deux groupes : le premier regroupant les hypothèses de matrices Reine et Tour, et le second incluant PPV1 et PPV3. Cette visualisation permettra d'analyser, pour chaque hypothèse, la densité des laboratoires par département en la comparant à la moyenne des densités des laboratoires des départements voisins. Au préalable, il convient de souligner que, pour l'ensemble de nos hypothèses, l'interprétation des cadrans reste similaire. Ainsi :

- **Cadran I (en haut à droite)** : regroupe les régions présentant une densité élevée de laboratoires, entourées par des régions également caractérisées par une densité élevée.

- **Cadran III (en bas à gauche)** : regroupe les régions à faible densité, entourées par des régions également faiblement denses.
- **Cadran II (en haut à gauche)** : représente les régions à faible densité, entourées par des régions à forte densité.
- **Cadran IV (en bas à droite)** : représente les régions à forte densité, entourées par des régions à faible densité.

Pour chaque Figure (Figure x et X), nous analyserons un seul diagramme de Moran par hypothèse, étant donné que les caractéristiques principales (comme la pente de la droite de régression) sont similaires d'un diagramme à l'autre.

Figure 3 : Diagramme de Moran (A)



sources : Auteurs, Rstudio

En étudiant le graphique X constitué du diagramme de Moran de la matrice Reine et Tour (nous analyserons essentiellement la matrice Tour), nous remarquons que la droite de régression présente une pente positive, indiquant une corrélation globale positive. Cela signifie que les régions avec une densité élevée (ou faible) de laboratoires ont tendance à être entourées de régions présentant des densités similaires. Par ailleurs, certains points spécifiques, identifiés par les noms des départements, peuvent être regroupés en deux ensembles distincts. Le premier groupe correspond aux départements situés dans le cadran I, tels que **les Bouches-du-Rhône, le Var et les Alpes-Maritimes**. Ces départements suggèrent l'existence d'un cluster caractérisé par

Figure 4 : Diagramme de Moran (B)




16

dans le cadran IV, méritent une attention particulière pour mieux comprendre ces spécificités locales.

B) Autocorrélation spatiale local

Carte 6 : LISA et significativité pour la matrice Reine



sources : Auteurs , GéoDa

La carte LISA met en évidence des clusters spatiaux de la densité des laboratoires d'analyse en France en 2020. On observe des concentrations élevées de laboratoires dans les départements du sud-est (PACA), du Haut-Rhin et des Pyrénées-Atlantiques (High-High), où la forte densité urbaine et les besoins sanitaires justifient cette présence. À l'inverse, des régions rurales comme la Bretagne et le centre-ouest présentent une faible densité homogène (Low-Low), probablement en raison d'une dispersion de la population et d'un moindre besoin en infrastructures médicales. Certains départements isolés, caractérisés par une forte densité mais entourés de zones

à faible densité (High-Low), peuvent correspondre à des pôles médicaux spécifiques ou des villes universitaires. La majorité des départements n'affiche pas de structure spatiale significative. Ces résultats soulignent une concentration des laboratoires en zones urbaines et touristiques, tandis que les zones rurales peuvent faire face à un accès limité, ce qui pourrait nécessiter des mesures pour améliorer l'égalité d'accès aux analyses médicales.

IV - Estimation et résultats des modèles

Une fois l'étude des relations spatiales faite, nous permettant ainsi de comprendre au mieux les différentes relations aussi bien global que local de nos études, nous pouvons dès lors passer à l'application de différents modèles et notamment des différents modèles d'estimations spatiales en introduisant nos divers variables explicatives cruciales dans la bonne compréhension et analyse sans biais de notre étude dans un contexte socio-économique suite à l'introduction de variables explicatives.

Figure 5 : Modèle des MCO

$$\begin{aligned} Dens_{labo} = & - 2,938 + 1,362.10^{-1}Tx_{chomage} + 2,408.10^{-2}Tx_{res_sec} \\ & + 8,323.10^{-02}Salaire_{net_horaire} + 5,430.10^{-05}Nbre_{naissance} \end{aligned}$$

sources : Auteurs, Rstudio

Dans un premier temps, nous décidons d'effectuer un modèle MCO (Figure X), ce qui nous permet d'évaluer la présence ou non de multicolinéarité dans notre modèle à l'aide du VIF. Nous constatons l'absence de multicolinéarité entre nos différentes variables, comme le démontre l'ensemble des valeurs du VIF, qui sont toutes inférieures au seuil (c'est-à-dire 10). Par la suite, afin de vérifier l'utilité et l'adaptabilité de l'application des MCO dans notre contexte d'étude, il est important de prendre en considération la présence ou non de corrélation spatiale des résidus. De ce fait, nous décidons d'analyser l'indice de Moran.

Tableau 4: Résultat des indices de Moran sur les MCO

Approche analytique		
Hypothèses	Statistique	p-value
Tour	0,41	$2,58.10^{-11}$
Reine	0,41	$2,58.10^{-11}$
PPV1	0,39	0,00074
PPV3	0,40	$7,761.10^{-09}$

sources : Auteurs, Rstudio

En étudiant le Tableau 4, nous pouvons observer que, pour un seuil de risque de 1%, les résidus présentent une corrélation spatiale. Nous démontrons ainsi la non-adaptabilité des MCO dans ce contexte d'étude. De ce fait, l'utilisation de modèles spatiaux devient nécessaire, et une approche méthodologique visant à déterminer le modèle le plus optimal est essentielle pour une analyse sans biais.

A) Approche ascendante "Le Gallo"

Une fois les indices de Moran et le modèle des MCO analysés, nous montrons alors l'importance d'utiliser des modèles spatiaux permettant de prendre en considération la corrélation spatiale. Il est primordial de déterminer quel modèle est le plus adéquat à utiliser en fonction de nos données. Dans cette optique, nous appliquons la méthode ascendante dite de "Le Gallo", nous permettant d'identifier le meilleur modèle spatial pour chaque matrice de pondération. Cette méthode se base sur le test de Lagrange et un schéma méthodique (voir annexe 7) afin de choisir au mieux les modèles en fonction de la significativité des résultats.

Tableau 5 : Résultats des test de Lagrange

Modèles	Tour	Reine	PPV1	PPV3
LMerr	$2,946.10^{-09}$	$2,946.10^{-09}$	0,002267	$3,386.10^{-07}$
LMlag	$6,485.10^{-08}$	$6,485.10^{-08}$	0,009012	$3,294.10^{-05}$
RLMerr	0,01341	0.01341	0,09525	0,002667
RLMlag	0,7434	0.7434	0,594	0,6195

sources : Auteurs , Rstudio

En étudiant le tableau 5 des résultats obtenus au test de Lagrange pour chaque matrice de pondération, nous pouvons déterminer quel modèle est le plus adéquat dans chaque situation. Pour la matrice PPV1, nous observons une significativité au seuil de 1 % pour les tests LM-Lag et LM-Err diagnostiques, tandis que pour les deux tests Robust LM-Lag et Robust LM-Err, aucune significativité n'est observée au seuil de 10 %. Cela indique qu'il n'existe pas de preuve solide en faveur d'un processus de retard spatial ou d'erreur spatiale exclusivement. Par conséquent, nous décidons d'appliquer le modèle **SLX**, qui semble être le plus approprié pour cette matrice de pondération. Pour les trois

autres matrices de pondération, nous observons des caractéristiques similaires : une significativité au seuil de 1 % pour les tests LM-Lag et LM-Err diagnostiques, ainsi qu’une significativité au seuil de 5 % pour le test Robust LM-Err, mais non retrouvée pour le test Robust LM-Lag. Ces résultats indiquent que l’hypothèse d’autocorrélation spatiale dans les résidus n’est pas robuste après contrôle de la dépendance spatiale dans la variable dépendante. Ainsi, l’application d’un modèle **SEM** est jugée la plus adéquate dans ces cas. Il est important de préciser avant d’examiner au mieux les différents modèles proposés nous complétons notre analyse avec une nouvelle approche permettant d’affirmer ou non les choix proposés par cette méthode.

B) Approche mixte : “Elhorst”

Une fois la méthode “Le Gallo” effectuée, nous pouvons étudier la méthode “Elhorst”. Cette approche se base également sur le test de Lagrange, permettant ainsi à l’application de différents schéma d’application reposant au départ sur la significativité obtenus des différents tests de Lagrange (Voir Annexe 8) et d’un choix final sur le critère d’AIC. Ainsi, pour la matrice de pondération PPV1, nous observons aucune significativité comme dit précédemment pour les deux test robust (LM-Lag et Robust LM-Err), nous amenant alors à appliquer le premier chemin qui consiste à l’utilisation préalable d’un modèle SLX poursuivi par une comparaison avec un modèle SDM afin de déterminer le modèle le plus adéquate. Par la suite, pour les 3 autres matrice de pondération (Tour, Reine, PPV3), nous retrouvons une significativité au seuil de 5% pour le LM-Err, nous amenant alors l’application initiale d’un modèle SDM qui sera ensuite comparé à l’aide du même ration qu’évoqué précédemment au modèle SAR et SEM.

Tableau 6 : Récapitulatif des différentes AIC et des Ratios de chaque matrice de pondération

	AIC				Ratio		
	SDM	SAR	SEM	SLX	SDM-SAR	SDM-SEM	SLX -SDM
Type Tour	216	229	219	x	< 0,05	< 0,05	x
Type Reine	216	229	219	x	< 0,05	< 0,05	x

Type PPV1	240	x	x	254	x	x	< 0,05
Type PPV3	224	235	220	x	< 0,05	< 0,05	x

sources : Auteurs , Rstudio

En analysant le tableau 6, nous pouvons déterminer, dans un premier temps, à l'aide des différents résultats obtenus dans la colonne "ratio", s'il existe des différences significatives entre les différents modèles utilisés. Ainsi, nous observons que l'ensemble des ratios est significatif au seuil de risque de 5 %. Cela démontre, par exemple, que pour la matrice de pondération PPV1, il existe une différence significative entre le modèle SLX et le modèle SDM. De même, pour la matrice de pondération Reine, il existe une différence significative aussi bien entre le modèle SDM et le modèle SAR, qu'entre le modèle SDM et le modèle SEM. La sélection des différents modèles se fait donc essentiellement sur les critères d'AIC. Ainsi, le modèle possédant le plus petit critère d'AIC sera sélectionné. De ce fait, pour les matrices de pondération utilisées dans cette approche, il est préférable d'utiliser un modèle SDM, tandis que pour le modèle PPV3, il est préférable d'utiliser un modèle SEM.

C) Interprétation du meilleur modèle

Suite à l'application des différentes approches, nous pouvons dès lors passer au choix aussi bien du meilleurs modèles à interpréter que du choix de la matrice de pondération.

Tableau 7 : Résultats des différentes approches

Choix du meilleur modèle		
	"Le Gallo"	"Elhorst"
Type Tour	SEM	SDM
Type Reine	SEM	SDM
Type PPV1	SLX	SDM
Type PPV3	SEM	SEM

sources : Auteurs , Rstudio

Dans un souci de rigueur, nous avons fait le choix de sélectionner le modèle et la matrice de pondération possédant le critère d'AIC le plus optimal, c'est-à-dire le plus faible. De ce fait, nous avons choisi d'interpréter le modèle SDM avec la matrice de pondération Reine. Il est important de noter que, bien que la matrice de pondération Reine et la matrice de pondération Tour possèdent le même AIC, nous avons opté pour l'analyse de la matrice Reine, car elle permet une meilleure modélisation des relations spatiales immédiates. De plus, afin d'analyser au mieux les effets du modèle SDM, il est essentiel de calculer les effets directs et indirects, en raison de la présence de variables décalées.

Tableau 8 : Résultats statistiques du meilleur modèle

Résultat du modèle SDM de type Reine				
	Estimateur	Std. Error	Value	Pr(> z)
Constante	-3.2247	1.5978	-2.0182	0.0435723
Chômage	3.2085	$6.5920 \cdot 10^{-02}$	0.4867	0.6264595
Résidence 2nd	-6.2626	$1.1627 \cdot 10^{-02}$	-0.5386	0.5901358
Salaire	9.0189	$5.1271 \cdot 10^{-02}$	1.7591	0.0785658
Naissance	6.1636	$1.5966 \cdot 10^{-05}$	3.8605	0.0001132
L.Chômage	1.2201	$1.0337 \cdot 10^{-01}$	1.1803	0.2378960
L.Résidence 2nd	2.9580	$1.6917 \cdot 10^{-02}$	1.7486	0.0803682
L.Salaire	3.8725	$1.0854 \cdot 10^{-01}$	0.3568	0.7212446
L.Naissance	-7.7113	$3.6058 \cdot 10^{-05}$	-2.1386	0.0324692

Rho: 0.55286, p-value: 4.1532e-07

Asymptotic standard error: 0.09711, p-value: 1.2471e-08

Wald statistic: 32.412, p-value: 1.2471e-08

Log likelihood: -97.2397 ML residual variance : 0.40868

sources : Auteurs , Rstudio

En analysant les résultats du modèle SDM de la matrice Reine, nous pouvons tirer plusieurs conclusions. Tout d'abord, nous observons une p-value inférieure au seuil de

risque de 1 %, ce qui indique le rejet de l'hypothèse nulle. Cela confirme ainsi l'existence d'une variation spatiale significative dans le modèle SDM pour la matrice Reine. Par la suite, nous pouvons analyser la significativité des différentes variables. Au seuil de risque de 1 %, seule la variable "Naissance" est significative. Pour un seuil de 5 %, une variable supplémentaire, "L.Naissance", devient significative. Enfin, au seuil de 10 %, quatre variables supplémentaires deviennent significatives : "L.Naissance", "Salaire", et "L.Résidence 2nd", en plus de la constante.

Dans notre étude, nous choisissons d'analyser uniquement les variables significatives au seuil de 5 %. Ainsi, nous identifions trois variables significatives, dont deux non retardées et une retardée, que nous pouvons examiner plus en détail. Nous constatons qu'une augmentation d'un point de la variable "Naissance" dans un département est associée à une hausse de 6.1636 points de pourcentage de la densité de laboratoires dans ce département. En ce qui concerne la variable retardée, une augmentation d'un point de la variable "L.Naissance" entraîne une diminution de 7.7113 points de pourcentage de la densité de laboratoires dans les départements voisins du département concerné. Ces coefficients pourraient se traduire par le fait que plus de naissances attirent plus de laboratoires localement, mais si un département voisin a déjà une forte croissance des naissances, il capte potentiellement les infrastructures, ce qui réduit la densité de laboratoires dans le département étudié.

Une fois l'analyse des estimateurs faite, nous pouvons dès lors passer à l'étude des différents effets, qu'ils soient directs ou indirects, du modèle SDM de la matrice Reine, afin de compléter notre analyse.

Tableau 9 : Résultats des différents effets du modèle SDM

	Différents effets		
	Direct	Indirect	Total
Chômage	0.0565493147	$2.880716.10^{-01}$	$3.446209.10^{-01}$
Résidence 2nd	-0.0016903879	$5.383790.10^{-02}$	$5.214751.10^{-02}$
Salaire	0.1056978685	$1.826129.10^{-01}$	$2.883108.10^{-01}$
Naissance	0.0000541016	$-8.871511.10^{-05}$	$-3.461351.10^{-05}$

En étudiant les différents effets récoltés dans le tableau 9, nous pouvons dès lors conclure aussi bien sur l'influence moyenne de la variable explicative sur la variable à expliquer, grâce à l'effet direct, que sur l'impact moyen de la variable sur les zones voisines du département en question, représenté notamment par l'effet indirect. Cela nous permet ainsi de mieux visualiser l'effet total. Ainsi, dans un premier temps, nous pouvons constater que les effets, et notamment les effets indirects, impactent très peu la densité de laboratoires, aussi bien dans leur département que dans les départements voisins, comme le démontrent les faibles coefficients. Il est important de noter que, les analyses étant similaires pour l'ensemble des variables, nous étudierons seulement la variable avec l'impact le plus fort, représenté notamment par la variable avec les coefficients les plus importants.

Dans le cas de la variable "Chômage", nous observons que l'effet direct est positif et s'élève à 0,057, indiquant ainsi qu'une augmentation d'une unité entraîne une hausse d'environ 0,057 point de pourcentage de la densité de laboratoires en France. Concernant l'effet indirect, celui-ci est de 0,288, signalant une augmentation de ce taux dans les zones voisines, due à l'influence indirecte d'autres variables du modèle. Enfin, l'impact total de cette variable est de 0,34. Cette analyse peut être appliquée aux autres variables. Sur l'ensemble de nos variables, seule "Naissance" présente un effet négatif au niveau total. Toutefois, cet effet reste marginal. En dehors de "Chômage", seule la variable "Salaire" présente une dynamique similaire.

V - Conclusion & Discussion

L'objectif de cette étude repose sur l'analyse économétrique des différents facteurs pouvant impacter la disparité sur l'implémentation des laboratoires en France métropolitaine en 2020. De ce fait, nous avons mené une analyse exploratoire approfondie pour comprendre aux mieux les différentes caractéristiques de la densité de laboratoire en France mais également de nos variables explicatives compléter par la suite de l'analyse de relation spatiale aussi bien au niveau global que local. Ainsi, l'essentiel de notre étude, s'est donc concentré sur la détermination du meilleur modèle afin de comprendre au mieux cette disparité.

Au vu des différents résultats obtenus lors de la détermination du meilleur modèle, établi notamment grâce à différentes approches telles que "Elhorst" et "Le Gallo", c'est le modèle SDM avec la matrice Reine qui a été sélectionné. Cela nous permet d'interpréter de manière optimale les différentes relations et interactions entre nos variables explicatives et notre variable dépendante.

Ainsi, nous avons pu observer que seule la variable "Naissance", ainsi que sa variable retardée, présentent un effet significatif, respectivement positif et négatif, sur la variable dépendante. Cela démontre qu'un boom des naissances impacte directement le département en augmentant la densité de laboratoires, tout en réduisant cette densité dans les départements adjacents, révélant ainsi un effet de centralisation des laboratoires. L'analyse des effets nous a également montré que, bien que l'ensemble des variables ait un effet total, celui-ci reste marginal. Cette conclusion met en évidence que les facteurs sociaux, notamment la natalité, influencent davantage la densité de laboratoires que les facteurs économiques, comme le salaire. Cependant, au vu des effets marginaux obtenus dans notre étude, il apparaît essentiel d'introduire d'autres variables afin de mieux capter les effets non mis en lumière. Ainsi, des variables telles que la densité de population, l'âge ou encore différents facteurs de santé pourraient être intéressantes à intégrer à notre étude afin de compléter et affiner nos conclusions déjà rigoureuses.

VI - Bibliographie

- <https://sante.gouv.fr/archives/archives-presse/archives-breves/article/presentation-du-plan-pour-l-egal-acces-aux-soins-dans-les-territoires>
- <https://sante.gouv.fr/archives/masante2022/>
- <https://www.lequotidiendumedecin.fr/sante-societe/demographie/la-biologie-hors-les-murs-solution-aux-inegalites-de-sante>

VII - Annexe

Annexe 1 : Résultats des statistiques de Moran de la matrice de poids de type

Tour par 2 approches

Moran I test under randomisation

```
data: shp_labo$Dens_labo_2020
weights: WT
```

```
Moran I statistic standard deviate = 6.6621, p-value = 1.35e-11
alternative hypothesis: greater
sample estimates:
Moran I statistic      Expectation      Variance
      0.434357985      -0.010526316      0.004459361
```

Monte-Carlo simulation of Moran I

```
data: shp_labo$Dens_labo_2020
weights: WT
number of simulations + 1: 1000
```

```
statistic = 0.43436, observed rank = 1000, p-value = 0.001
alternative hypothesis: greater
```

— |

sources : Auteurs, Rstudio

Annexe 2 : Résultats des statistiques de Moran de la matrice de poids de type

Reine par 2 approches

Moran I test under randomisation

```
data: shp_labo$Dens_labo_2020
weights: WR
```

```
Moran I statistic standard deviate = 6.6621, p-value = 1.35e-11
alternative hypothesis: greater
sample estimates:
Moran I statistic      Expectation      Variance
      0.434357985      -0.010526316      0.004459361
```


Monte-Carlo simulation of Moran I

```
data: shp_labo$Dens_labo_2020
weights: WR
number of simulations + 1: 1000
```

```
statistic = 0.43436, observed rank = 1000, p-value = 0.001
alternative hypothesis: greater
```

sources : Auteurs, Rstudio

Annexe 3 : Résultats des statistiques de Moran de la matrice de poids de type PPV1 par 2 approches

Moran I test under randomisation

```
data: shp_labo$Dens_labo_2020
weights: PPV1
```

```
Moran I statistic standard deviate = 3.5647, p-value =
0.0001821
```

```
alternative hypothesis: greater
```

```
sample estimates:
```

Moran I statistic	Expectation	Variance
0.43726344	-0.01052632	0.01577948

Monte-Carlo simulation of Moran I

```
data: shp_labo$Dens_labo_2020
weights: PPV1
number of simulations + 1: 1000
```

```
statistic = 0.43726, observed rank = 999, p-value = 0.001
alternative hypothesis: greater
```

sources : Auteurs, Rstudio

Annexe 4 : Résultats des statistiques de Moran de la matrice de poids de type

PPV3 par 2 approches

Moran I test under randomisation

```
data: shp_labo$Dens_labo_2020
weights: PPV3
```

Moran I statistic standard deviate = 6.0306, p-value = 8.167e-10

alternative hypothesis: greater

sample estimates:

Moran I statistic	Expectation	Variance
0.444210931	-0.010526316	0.005685892

Monte-Carlo simulation of Moran I

```
data: shp_labo$Dens_labo_2020
weights: PPV3
number of simulations + 1: 1000
```

statistic = 0.44421, observed rank = 1000, p-value = 0.001

alternative hypothesis: greater


sources : Auteurs, Rstudio

Annexe 5 : Procédure GéoDa

Pour réaliser la carte des LISA sur GeoDa, nous avons d'abord chargé le fichier SHP contenant les limites administratives et les données associées dans un fichier séparé, que nous avons joint via un identifiant commun. Ensuite, nous avons créé une matrice de voisinage en utilisant une pondération de contiguïté de type Reine et défini l'ordre de contiguïté (1 pour les voisins directs). Nous avons ensuite calculé les poids spatiaux et appliqué le test de Moran local (LISA). Enfin, nous avons affiché la carte des clusters LISA, mettant en évidence les zones significatives avec les catégories High-High, Low-Low, High-Low et Low-High, afin d'analyser la répartition spatiale de la densité des laboratoires.

Annexe 6 : Carte des LISA et significativité pour la matrice des 3 plus proches voisins

LISA et significativité pour la matrice des 3 plus proches voisins



sources : Auteurs, QGIS

Annexe 7 : Résultats de l'estimation des MCO

Call:

```
lm(formula = Dens_labo_2020 ~ Tx_chomage_2020 + Tx_res_sec_2020 +  
    Salaire_net_horaire + Nbre_naissances, data = shp_labo)
```

Residuals:

Min	1Q	Median	3Q	Max
-1.9502	-0.5382	-0.1135	0.2168	2.8855

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-2.938e+00	1.017e+00	-2.890	0.00482	**
Tx_chomage_2020	1.362e-01	6.364e-02	2.139	0.03508	*
Tx_res_sec_2020	2.408e-02	1.002e-02	2.402	0.01834	*
Salaire_net_horaire	8.323e-02	5.769e-02	1.443	0.15251	
Nbre_naissances	5.430e-05	1.975e-05	2.749	0.00721	**

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.865 on 91 degrees of freedom

Multiple R-squared: 0.2832, Adjusted R-squared: 0.2517

F-statistic: 8.99 on 4 and 91 DF, p-value: 3.649e-06


sources : Auteurs, Rstudio

Annexe 8 : Schéma méthodologique de la méthode “Le Gallo”



sources : Cours Chapitre 3 : Econométrie spatiale

Annexe 9 : Schéma méthodologique de la méthode "Elhorst"



sources : Cours Chapitre 3 : Econométrie spatiale

IX - Table des Figures & Tableau

Tableau :

- Tableau 1 : Récapitulatifs des statistiques descriptif de la variable d'intérêt
- Tableau 2 : Récapitulatifs des statistiques descriptif des variables explicatives
- Tableau 3 : Résultats des différentes statistiques de Moran
- Tableau 4: Résultat des indices de Moran sur les MCO
- Tableau 5 : Résultats des test de Lagrange
- Tableau 6 : Récapitulatif des différentes AIC et des Ratios de chaque matrice de pondération
- Tableau 7 : Résultats des différentes approches
- Tableau 8 : Résultats statistiques du meilleur modèle
- Tableau 9 : Résultats des différents effets du modèle SDM

Carte :

- Carte 1 : Répartition de la densité de laboratoire d'analyse en France Métropolitaine par département (2020)
- Carte 2 : Répartition du taux de chômage en France Métropolitaine par département
- Carte 3 : Distribution des part des résidences secondaires en France Métropolitaine par département
- Carte 4 : Distribution du salaire net horaire moyen répartie en 5 classes (quantiles) en France Métropolitaine par département
- Carte 5 : Répartition du nombre de naissance en France Métropolitaine par département en 2020
- Carte 6 : LISA et significativité pour la matrice Reine

Figure :

- Figure 1 : Matrice de corrélation
- Figure 2 : Distributions des variables quantitatives
- Figure 3 : Diagramme de Moran (A)
- Figure 4 : Diagramme de Moran (B)
- Figure 5 : Modèle des MCO

IX - Table des matières

Résumé.....	I
Abstract.....	II
Sommaire.....	III
I - Introduction.....	1
II - Analyse exploratoire & descriptives.....	3
A) Statistique descriptives.....	3
1) Variable dépendante.....	3
2) Variables indépendantes.....	4
B) Répartition spatiale.....	5
1) Variable dépendante.....	5
2) Variable indépendante.....	6
C) Etude de corrélation.....	9
D) Étude des distributions.....	10
III - Relation spatiale.....	13
A) Autocorrélation spatiale globale.....	13
1) Statistique de Moran.....	13
2) Diagramme de Moran.....	14
B) Autocorrélation spatiale local.....	17
IV - Estimation et résultats des modèles.....	18
A) Approche ascendante “Le Gallo”.....	19
B) Approche mixte : “Elhorst”.....	20
C) Interprétation du meilleur modèle.....	21
V - Conclusion & Discussion.....	25
VI - Bibliographie.....	26
VII - Annexe.....	27
IX - Table des Figures & Tableau.....	31
IX - Table des matières.....	33