


Dossier Modélisation avec des variables latentes
MASTER 1 ECAP

**Etudes de cas : Apprentissage supervisé par une approche
PLS pour la discrimination des saumons
suivant leur provenance et leur mode de
production sur la base de données des
caractérisation chimique.**



Dossier réalisé par :
SINEAU Angel
MOCAËR Rodolphe

Année universitaire 2023-2024

Sommaire

<u>I - Introduction.....</u>	<u>1</u>
<u>II - Restructurations du jeu de donnée et analyse descriptives du jeu de données.....</u>	<u>2</u>
A) Préparation du jeu de données.....	2
B) Analyse descriptive du jeu de données.....	2
<u>IV - Analyse exploratoire supervisé.....</u>	<u>4</u>
A) Découpage du jeu de données.....	4
B) Ajustement d'un modèle PLS-DA.....	4
1) Visualisation préliminaire.....	5
2) Choix optimale du nombre de composante.....	5
3) Sélection des variables significative.....	6
C) Vérification de la performance du modèle.....	7
1) Le ROC.....	7
2) La matrice de confusion.....	7
<u>V - Conclusion & Discussion.....</u>	<u>8</u>

I - Introduction

Dans le contexte actuel de l'industrie alimentaire, l'authenticité des produits est d'une importance capitale pour les consommateurs ainsi que pour les organes de réglementation. C'est pourquoi un grand nombre de recherches sont menées pour développer des systèmes garantissant l'intégrité des produits alimentaires. Dans cette optique, notre étude de cas se penchera sur une publication scientifique qui propose une méthode de traçabilité de l'origine des saumons. Cette recherche, intitulée "Fusion de données et analyse multivariée pour l'authenticité des aliments", a été publiée dans Nature Communications et rédigée par Hong, Y., Birse, N., Quinn, B., Li, Y., Jia, W., McCarron, P., ... & Elliott, C. T. (2023). Elle met à disposition une base de données comprenant les caractéristiques chimiques obtenues par spectrométrie de masse à plasma couplée à une source d'induction (ICP-MS), permettant ainsi de mettre en lumière les profils chimiques des échantillons. Ces profils chimiques identifient la présence et la teneur de 38 éléments chimiques différents pour 521 échantillons de saumon issus de quatre pays distincts : l'Alaska, l'Écosse, la Norvège et l'Islande.

Dans cette optique, nous examinerons la possibilité de déterminer l'origine du saumon à partir de son profil chimique. Nous commencerons par restructurer la présentation de la base de données, puis nous procéderons à une analyse exploratoire supervisée permettant de définir correctement les paramètres de notre modèle final. Pour conclure nous procéderons à une vérification de la prévision de notre modèle final.

II - Restructurations du jeu de donnée et analyse descriptives du jeu de données


A) Préparation du jeu de données.

Afin de garantir la qualité, la fiabilité et la pertinence de nos résultats d'analyse, nous avons pris la décision de restreindre notre sélection à 20 éléments chimiques parmi les 38 initialement disponibles. Cette démarche vise à optimiser notre approche analytique. Parallèlement, nous avons appliqué une normalisation min-max pour assurer une comparaison équitable et impartiale entre les variables, tout en éliminant les biais liés aux différences d'échelle. Cette méthode contribue à améliorer la précision et la performance de nos analyses statistiques.

B) Analyse descriptive du jeu de données.

Grâce à cette restructuration du jeu de données nous avons pu procéder à l'analyse descriptive du jeu de données.

Graphique 1 : Statistique descriptives de notre base de données



sources : auteurs

Dans un premier temps, il est important de noter que certains éléments chimiques présentent une plus grande variabilité que d'autres, et que la majorité des variables ont une moyenne proche de la médiane, indiquant une distribution symétrique de l'échantillon. Dans un second temps, Nous pouvons classer nos variables en trois catégories distinctes en fonction de leur fréquence dans le profil chimique. la première avec une présence "faible" ($\text{moyenne} \leq 0.10$) tel que le Nickel (Ni), la deuxième

avec une présence “modéré” ($0.10 < \text{moyenne} \leq 0.20$) tel que le Molybdène (Mo) et enfin une troisième catégorie comprenant les éléments les plus fréquemment observés ($\text{moyenne} > 0.30$) comme le Zinc (Zn) c’est à dire une présence “forte”. Enfin, Il convient de souligner que cette analyse ne prend pas en compte les valeurs aberrantes (points observés en dehors des moustaches).

IV - Analyse exploratoire supervisé

Suite à une analyse succincte mais approfondie de nos statistiques descriptives nous permettant de mieux comprendre la structure de nos données, nous sommes désormais prêts à entreprendre une analyse exploratoire supervisée. Dans ce cadre, nous allons appliquer la PLS-DA à nos données pour une meilleure compréhension et interprétation de nos résultats.

A) Découpage du jeu de données

Il est essentiel de noter qu'avant d'appliquer la méthode PLS-DA, il est recommandé de diviser les données en deux ensembles distincts : un ensemble de "test" et un ensemble d'"apprentissage". Cette séparation des échantillons est cruciale pour évaluer l'efficacité de notre modèle.

Tableau 1 : Fréquences des classes (Pays) dans nos échantillons

	Alaskan	Iceland-F	Iceland-W	Norway	Scotland
Test	0.184466	0.106796	0.174757	0.194175	0.339806
Apprentissage	0.191388	0.105263	0.172249	0.191388	0.339713

sources : auteurs


Dans un souci de vérification, nous nous assurons que les deux ensembles de données présentent des répartitions similaires afin d'éviter tout biais potentiel. À cet effet, nous constatons à partir du Tableau 1 que les classes sont réparties de manière approximativement équivalente entre les différents échantillons, ce qui nous permet de progresser vers la prochaine étape, l'application de la PLS-DA.

B) Ajustement d'un modèle PLS-DA

Pour choisir le meilleur modèle et optimiser ses paramètres, nous suivrons un processus en plusieurs étapes. Tout d'abord, nous effectuerons une visualisation initiale des données. Ensuite, nous sélectionnons le nombre optimal de composantes. Enfin, nous identifierons les éléments chimiques les plus influents pour le modèle.

1) Visualisation préliminaire

Graphique 2 : Répartitions des individus en fonction de leurs classes




sources : auteurs

En se référant au graphique 2, nous sommes en mesure de discerner les tendances de distribution des profils chimiques de nos saumons en fonction de leurs origines géographiques ou classes, notamment grâce aux ellipses de confiance. Nous remarquons ainsi un chevauchement significatif entre les classes, en particulier pour "Iceland-F", ce qui suggère l'absence éventuelle d'un profil chimique distinctif pour cette région. De plus, ces chevauchements suggèrent une similitude ou une confusion entre les différentes classes.

2) Choix optimale du nombre de composante

Pour sélectionner judicieusement le nombre de composantes, nous effectuons une évaluation de la performance à l'aide d'une validation croisée. Nous avons choisi de visualiser cette évaluation afin d'identifier de manière préalable et visuelle le nombre optimal de composantes pour notre modèle.

Graphique 3 : Graphique de performance



sources : auteurs

En observant le graphique de performance (graphique 3), nous constatons une diminution significative du taux d'erreurs global de 1 à 4 composantes, suivi d'une stabilisation après 6 composantes. En conséquence, nous envisageons la sélection de 6 composantes pour notre modèle final. Toutefois, une analyse supplémentaire avec des tests T est nécessaire pour déterminer de manière plus précise le nombre optimal de composantes.

Tableau 2 : Tableau résultat de sélection optimale du nombre de composante


	max.dist	centroids.dist	mahalanobis.dist
overall	6	6	9
BER	6	6	9

sources : auteurs

D'après le Tableau 2, prenant en compte trois méthodes de calcul (max.dist, centroids.dist, ...), le nombre optimal de composantes à sélectionner est de 6, ce qui valide notre hypothèse initiale. Par conséquent, pour notre modèle final, nous avons déterminé que le nombre optimal de composantes est de 6. Nous pouvons maintenant passer à l'étape suivante, qui consiste à sélectionner les variables significatives.

3) Sélection des variables significative

Graphique 4 : Graphique de significativité des variables




sources : auteurs

Ce graphique soulignant la significativité des éléments chimiques dans la classification des groupes révèle que seuls 9 éléments sur 20 sont pertinents dans le profil chimique des saumons pour leur classification : le Lithium (Li), le Bore (B), le Cobalt (Co), le Zinc (Zn), l'Arsenic (As), le Sélénium (Se), le Rubidium (Rb), le Cadmium (Cd) et le Calcium (Ca). Cette importance peut être attribuée à leur rôle dans les processus biologiques et métaboliques des organismes, comme celui du lithium dans divers processus biologiques et physiologiques. De plus, il est notable que les éléments chimiques significatifs étaient principalement classés dans la catégorie "forte" lors de l'analyse descriptive, avec une moyenne supérieure à 0,30.

4) Qualité du modèle

Dans un souci de validation, nous entreprenons une analyse de performance de notre modèle en utilisant la courbe ROC (Receiver Operating Characteristic), qui met en évidence la relation entre sensibilité et spécificité.

Graphique 5 : Graphique de significativité des variables



En se référant au Graphique 5, nous examinons les valeurs AUC, qui décrivent la probabilité de succès de notre modèle dans la classification correcte de chaque individu. Nous remarquons que la classe présentant la plus petite valeur est "Scotland", ce qui indique que notre modèle éprouve plus de difficultés à classer correctement ces individus. Cependant, avec une valeur minimale de 0,9751, nous pouvons conclure que notre modèle affiche une performance très élevée dans la distinction des classes pour chaque origine.

C) Prévision grâce aux modèle final

L'ensemble du processus nous a permis de mettre en évidence notre modèle optimal comprenant 6 composantes. Cependant, il est essentiel de vérifier son efficacité en utilisant le jeu de données "test" préalablement dissocié.

Tableau 3 : Qualité du modèle PLS-DA

	Taux de Sensibilité (Vrai positif)	Taux de Spécificité (Faux négatif)	Taux de Précisions
Test	0.9436364	0.9736842	0.961165

sources : auteurs

En examinant le Tableau 3, qui représente la qualité du modèle PLS-DA, nous constatons qu'il s'agit d'un modèle prédictif efficace, avec des taux supérieurs à 94%, démontrant ainsi son efficacité. Le taux de précision s'élève à 0.96, ce qui indique que le modèle a correctement classé 96% des observations. La sensibilité est de 0.94, ce qui signifie que le modèle a identifié correctement 94% des vrais positifs, tandis que la spécificité atteint 0.97, indiquant que le modèle a correctement identifié 97% des vrais négatifs. En conclusion, nous pouvons affirmer que c'est un modèle robuste, doté d'une grande précision.

V - Conclusion & Discussion

Dans un premier temps, nous avons procédé à la restructuration des données, allant de la sélection des éléments chimiques désirés à la normalisation des données, afin de permettre une comparaison précise de nos éléments chimiques et d'éviter tout biais. Ensuite, nous avons appliqué une analyse exploratoire supervisée, en particulier la méthode PLS-DA, dans le but de déterminer le modèle optimal pour la prédiction des classes de nos individus.

Dans notre première partie, nous avons exploré notre jeu de données en visualisant la répartition de nos éléments chimiques. Cette analyse a révélé une corrélation surprenante entre la classification des éléments chimiques en forte ou faible présence dans le profil des saumons et ceux définis comme significatifs ultérieurement.

Dans notre seconde partie, nous avons effectué une analyse PLS-DA, en mettant l'accent sur la mise en évidence des paramètres de notre modèle optimal, notamment le nombre de composantes le plus adéquat. Cependant, par mesure de vérification, nous avons entrepris plusieurs tests, incluant le calcul des taux, afin de valider la précision de la classification des individus par notre modèle final. Tous les tests se sont révélés concluants, ce qui témoigne de sa robustesse et de sa qualité.

En résumé, cette étude a mis en lumière une solution prometteuse pour relever le défi de l'identification et de l'authentification des produits de consommation, en particulier dans le domaine de l'agro-alimentaire. L'application de notre modèle à d'autres espèces de poissons que le saumon pourrait offrir des perspectives intéressantes pour élargir la portée de cette méthode. Il serait donc pertinent de poursuivre cette étude afin d'explorer davantage les possibilités d'identification des produits alimentaires, contribuant ainsi à renforcer la transparence et la confiance des consommateurs.