



UNIVERSITÉ DE NANTES



Dossier Arbres de décision

Master 2 ECAP

LABRE-BLANC EMMA

MOCAËR RODOLPHE

I - Introduction

Notre étude vise à identifier les liens entre les caractéristiques visuelles (silhouettes) de bouteilles et les préférences des consommateurs en matière de design. À partir d'un jeu de données issu d'un test de préférence réalisé auprès de 26 participants, qui ont noté 49 silhouettes de bouteilles sur une échelle de 1 à 9, où 1 représente une appréciation très mauvaise et 9 une appréciation excellente (bien que 9 n'ait jamais été attribué), nous nous pencherons sur deux questions principales : peut-on prédire la note d'appréciation en fonction des paramètres visuels des bouteilles? Et quels sont les facteurs déterminants dans l'évaluation des consommateurs ? Pour y répondre, nous avons utilisé deux approches : un arbre de régression CART, suivi d'une analyse par forêt aléatoire..

II - Modifications majeures


Étant donné que notre variable dépendante "liking" est quantitative, nous avons dû adapter les méthodes et indicateurs utilisés. Nous avons alors remplacé, dans la fonction *rpart*, le critère "class" par "anova" pour indiquer l'utilisation d'un modèle de régression. De même, pour les prédictions (fonction *predict*), le type "vector" a été utilisé au lieu de "class". Concernant la forêt aléatoire, nous avons ajusté l'indicateur de performance en remplaçant "Accuracy" par "RMSE" dans la fonction *train*. Enfin, nous avons abandonné la matrice de confusion au profit d'indicateurs tels que le MSE, le RMSE, et le Pseudo R^2 pour évaluer nos modèles.

III - Analyse des différentes approches

A) Arbre de régression

L'arbre de régression que nous avons construit cherche à optimiser la segmentation des observations en minimisant la variance intra-nœud et en maximisant la variance inter-nœud. L'arbre final, élagué avec un paramètre de complexité (cp) de 0,02365 (**Figure 1**), se compose de 2 nœuds et 3 feuilles, offrant ainsi un bon compromis entre simplicité et performance, conformément à la règle du 1-SE.

Figure 1 : Choix du critère cp




sources : Rstudio, Auteurs

L'analyse de l'arbre révèle que les variables lid.width (largeur du bouchon) et skewness (asymétrie de la distribution des silhouettes des bouteilles) sont les principales variables discriminantes, comme l'indiquait également l'analyse descriptive (**Annexe 1**). La largeur du bouchon est la première variable discriminante : si elle est supérieure à 360, les bouteilles se voient attribuer les notes les plus faibles. En revanche, si elle est inférieure à 360, une nouvelle segmentation s'effectue selon skewness : une skewness supérieure à -2,735 conduit aux meilleures notes, tandis qu'une skewness inférieure entraîne des notes moyennes (**Figure 2**).

Concernant la classification finale, les tailles des feuilles varient entre 20 et 255 observations. Les médianes des distributions des boxplots associés aux différentes feuilles sont situées à des niveaux légèrement distincts, ce qui indique que l'arbre parvient à capturer certaines différences entre les groupes. Cependant, certains individus sont mal classés, reflétant des zones d'imperfection dans la segmentation. Les performances du modèle, avec un MSE de 1.040, un RMSE de 1.020 et un pseudo R^2 de 0.459, sont relativement insatisfaisantes. Ces résultats suggèrent que le modèle présente une variabilité significative dans ses prédictions, renforçant l'idée que l'instabilité inhérente aux arbres de décision pourrait être améliorée par des approches alternatives, comme une forêt aléatoire, qui pourraient offrir une meilleure robustesse et fiabilité des résultats.

Figure 2 : Arbre de régression optimal selon le critère cp




sources : Rstudio, Auteurs

B) Forêt aléatoire

La forêt aléatoire a été composée de 200 arbres, un nombre suffisant pour stabiliser les performances du modèle. Le paramètre `mtry`, correspondant au nombre de variables sélectionnées à chaque division d'arbre, a été fixé à 4, après avoir testé plusieurs valeurs. Bien que les performances aient été similaires entre les différents `mtry` (de 1 à 10), nous avons retenu `mtry=4`, car il offrait un léger avantage en termes de RMSE (**Figure 3**).


Figure 3 : Choix des paramètres ntree et mtry



sources : Rstudio, Auteurs

Le critère du mean decrease in accuracy (MDA) a mis en avant “Lid.Width” comme la variable la plus importante pour la prédiction de la note d'appréciation, suivie de “Kurtosis” et “Skewness” (**Figure 4**). Ce résultat fait écho à l'arbre de régression, où “Lid.Width” et “Skewness” avaient également été utilisées comme premières variables discriminantes.


Figure 4 : Importance des variables selon les critères MDA et MDI



sources : Rstudio, Auteurs

Les prédictions du modèle restent cependant limitées, comme en témoignent les critères MSE (0.95), RMSE (0.97) et pseudo R^2 (0.51). Le graphique (**Figure 5**) révèle que les notes extrêmes, comme 1 et 8, sont mal prédites, probablement en raison du faible nombre d'observations correspondantes dans le jeu d'entraînement (4 observations pour la note 1 et 5 pour la note 8). De plus, la note 9 est complètement absente de la base de données, ce qui empêche toute prédiction sur cette classe.

Figure 5 : Comparaison entre les notes d'appréciation prédites et observées



sources : Rstudio, Auteurs

IV - Comparaison des modèles

Suite à l'évaluation de l'ensemble de nos méthodes, nous pouvons dès lors les comparer à l'aide des indicateurs statistiques calculé suivants (**Tableau 1**) :

Tableau 1 : Comparatif des différentes méthodes de prévision


Modèles	Nombre de variables	Complexité du modèle	MSE	RMSE	Pseudo R ²
Arbre de régression	11	3 noeuds terminaux	1.040147	1.019876	0.4589153
Forêt aléatoire	11	x	0.9457696	0.9725069	0.5080106

sources : Rstudio, Auteurs

En comparant les performances des deux modèles, la forêt aléatoire montre une meilleure capacité prédictive que l'arbre de régression, avec un MSE de 0,95 et un RMSE de 0,97, contre 1,04 et 1,02 pour les deux indicateurs dans le cas de l'arbre. Le pseudo R² de 0,51 pour la forêt aléatoire est également supérieur à celui de l'arbre (0,46), indiquant qu'elle explique mieux la variance. Toutefois, ces résultats restent insuffisants, le modèle ne capturant que 51 % de la variance, ce qui suggère un potentiel d'amélioration. Enfin, les variables clés qui émergent de nos deux modèles, et qui pourraient contribuer à obtenir de meilleures notes pour le design des bouteilles, sont Lid.Width, Skewness et Kurtosis, qui correspondent respectivement à la largeur du bouchon, l'asymétrie et l'aplatissement caractérisant la transformation des silhouettes du corps de la bouteille en une distribution de probabilité.

V - Annexe

Annexe 1 : Comparaison des caractéristiques visuelles des bouteilles selon la note attribuée.



sources : Rstudio, Auteurs