



UNIVERSITÉ DE NANTES



IAE NANTES
ÉCONOMIE & MANAGEMENT

Dossier Régression pénalisées et sélection de variables

Master 2 ECAP

**Analyse et sélection de variables de la production
industrielle en Grande-Bretagne de 1998 à 2024**

DUPAS BROUSSE SIMON

MOCAËR RODOLPHE

Sous la direction de Darne Olivier

Sommaire

Sommaire.....	I
Résumé.....	II
Abstract.....	III
Liste de Sigles.....	IV
Chapitre I - Introduction.....	1
Chapitre II - Analyse exploratoire.....	3
Chapitre III - Sélection des variables.....	15
Chapitre IV - Conclusion.....	27
Annexe.....	28
Liste des titres des tableaux & graphiques & figures & modélisations.....	40
Bibliographie & Sitographie.....	41
Tables des matières.....	42

Analyse et sélection de la production industrielle au Royaume-Uni de 1998 à 2024

Résumé

Ce projet a pour objectif de modéliser l'évolution de la production industrielle au Royaume-Uni de 1998 à 2024. Après une analyse exploratoire et la sélection de variables optimales sur une base de données volumineuse, nous avons appliqué plusieurs méthodes de régression pénalisée (Ridge, Adaptive Lasso, SCAD), avec et sans réduction de dimension via la méthode SIS. L'analyse montre que les variables les plus pertinentes sont liées à la production industrielle, notamment dans les secteurs manufacturier, énergétique et des biens intermédiaires. Ces résultats ouvrent la voie à des recherches futures centrées sur une analyse ciblée des variables de production et une évaluation prédictive des performances des modèles.

Mots clés : Production industrielle, Régression pénalisée, RStudio, Sélection de variables

Analysis and Selection of Industrial Production in the United Kingdom from 1998 to 2024

Abstract

This project aims to model the evolution of industrial production in the United Kingdom from 1998 to 2024. After conducting exploratory analysis and selecting optimal variables from a large dataset, we applied several penalized regression methods (Ridge, Adaptive Lasso, SCAD), both with and without dimension reduction using the SIS method. The analysis shows that the most relevant variables are related to industrial production, particularly in the manufacturing, energy, and intermediate goods sectors. These results pave the way for future research focused on a targeted analysis of production variables and predictive evaluation of model performance.

Keywords: Industrial Production, Penalized Regression, RStudio, Variable Selection

Liste de Sigles

GB : Grande-Bretagne

TC : Temporary Change

AO : Additive outliers

ADF : Dickey-Fuller Augmenté

PP : Philips-Perron

KPSS : Kwiatkowski-Philips-Schmidt-Shin

Chapitre I - Introduction

Depuis l'Antiquité, les secteurs de la manufacture, de l'artisanat et de l'extraction de ressources ont constitué des éléments fondamentaux de la production, jouant un rôle crucial dans la vitalité économique des sociétés. Toutefois, c'est à partir de 1760, avec l'émergence de la Révolution industrielle en Grande-Bretagne, que la production industrielle commence à émerger de manière significative. Cette période, marquée par des avancées technologiques, s'étendant jusqu'au XXe siècle, où la production industrielle atteint son apogée. Dès lors, la production industrielle s'affirme donc comme l'un des piliers majeurs des nos sociétés modernes, impactant divers domaines : social, technologique, écologique et économique. Tel que l'urbanisation, l'augmentation des niveaux de vie et des innovations technologiques, les inégalités sociales et les crises environnementales. Cependant, au XXIe siècle, nous assistons à une diminution de la production industrielle, largement influencée par l'émergence d'alertes écologiques et sociétales à l'échelle mondiale¹. Malgré cette tendance, il est important de souligner que la production industrielle représente une part significative du PIB mondial, atteignant 26,7 % en 2023. témoignant dès lors de l'importance continue de l'industrie comme indicateur de croissance et de santé économique des pays vis-à-vis de leur secteur industriel².

Ce schéma évolutif se retrouve de manière exemplaire au Royaume-Uni, berceau de la Révolution industrielle, où l'essor industriel a non seulement transformé la société britannique, mais a également façonné l'économie mondiale en posant les bases de l'industrialisation moderne³. Bien que le pays ait progressivement évolué vers une économie de services, il maintient une part significative de son secteur industriel, représentant 17 % de son PIB actuellement. Ce maintien repose sur des industries stratégiques telles que la sidérurgie, l'automobile, la chimie et le textile. Privilégiant dès lors, les produits à haute valeur ajoutée et à forte intensité technologique. Cette stratégie permet donc au Royaume-Uni de préserver une industrie performante, essentielle à sa stabilité économique et à son influence sur la scène géopolitique mondiale. Ainsi l'analyse, la prévision et l'étude de

¹ Hérouville, Hubert D. "Marché commun et production industrielle mondiale." *Economie et Statistique* 13.2 (1958): 157-166.

² Michalet, Charles-Albert. *Le capitalisme mondial*. FeniXX, 1984.

³ Bairoch, Paul. "Commerce international et genèse de la révolution industrielle anglais." *Annales. Histoire, Sciences Sociales*. Vol. 28. No. 2. Cambridge University Press, 1973.

cet indicateurs à l'aide d'autres facteurs sont essentielles pour comprendre les dynamiques contemporaines et anticiper les évolutions futures⁴.

À l'ère actuelle, l'essor du big data et la croissance exponentielle de la collecte de données transforment profondément notre société⁵. Cette révolution des données permet aujourd'hui de prédire et d'analyser un large éventail de phénomènes plurisectoriels. Cependant, cette surabondance d'informations met également en lumière les limites des modèles traditionnels, souvent rendus obsolètes par des problèmes tels que la violation de certaines hypothèses fondamentales ou les coûts algorithmiques élevés. Cela impose une réflexion stratégique visant à identifier les variables essentielles et pertinentes. À cet égard, le machine learning se révèle être une solution clé, offrant des réponses adaptées pour surmonter ces défis complexes.

C'est dans ce contexte que nous avons choisi de modéliser l'évolution de la production industrielle de la Grande-Bretagne de 1998 à 2024. Notre étude se composera dans un premier temps d'une analyse exploratoire, suivie de la sélection de variables, produites ou non par des méthodes de machine learning. Enfin, nous effectuerons une régression pénalisée pour conclure par une comparaison des différentes approches des méthodes de sélection.

⁴ Hashemi, Arman. "Review of the UK housing history in relation to system building." *ALAM CIPTA, International Journal of Sustainable Tropical Design Research and Practice* 6.1 (2013): 47-58.

⁵ Beckouche, Pierre. "La révolution numérique est-elle un tournant anthropologique?" *Le débat* 193.1 (2017): 153-166.

Chapitre II - Analyse exploratoire

Avant tout, il est essentiel de souligner que notre étude comparative repose sur une base de données élaborée par l'institut économique national⁶, comprenant 110 variables que nous avons décidé d'organiser en 12 groupes (Voir annexe X), tels que les variables liées aux indices de prix, aux indicateurs de l'emploi, etc. Par ailleurs, cette base inclut une variable indépendante, la production industrielle (désignée : "IOP_PROD"). Il nous est également important de préciser que cette base de données est initialement considérée comme stationnaire et ne présente pas de valeurs manquantes. Cependant, par souci de rigueur scientifique et dans le respect d'un protocole strict, nous décidons de réaliser une analyse approfondie des valeurs manquantes ainsi que divers tests de stationnarité, afin de valider les hypothèses avancées par la plateforme.

Dans le cadre de notre analyse exploratoire, nous adopterons une méthodologie structurée pour nettoyer et analyser cette base de données de manière optimale. Cette approche débutera par une analyse des valeurs manquantes, suivie de l'identification des outliers. Ensuite, nous évaluerons la stationnarité et procéderons à l'analyse des statistiques descriptives de la variable dépendante. Enfin, nous conclurons par une classification en clusters des variables et l'analyse de leurs corrélations. Ce processus complet et méthodique nous permet de garantir un protocole rigoureux pour l'analyse préalable de notre base de données.

Section I - Analyse des valeurs manquantes

Dans le cadre de notre analyse exploratoire de notre base de données, nous procédons à l'examen des valeurs manquantes. Tout d'abord, il convient de préciser que cette base, débutant en janvier 1998, est supposée ne présenter aucune donnée manquante. Cependant, la visualisation graphique (voir annexe X) nous révèle l'absence de trois valeurs dans la variable 'Libor3month'(taux d'intérêt auquel les grandes banques se prêtent des fonds entre elles sur le marché interbancaire de Londres.). Afin de remédier à cette situation, nous optons alors pour la méthode de lissage de Kalman, qui exploite les données observées pour estimer les valeurs


⁶ Goulet Coulombe, Philippe, Massimiliano Marcellino, and Dalibor Stevanović, 'CAN MACHINE LEARNING CATCH THE COVID-19 RECESSION?', National Institute Economic Review, 256 (2021), 71–109 <<http://dx.doi.org/10.1017/nie.2021.10>>

manquantes. Cette approche nous permet de conserver la variable concernée et de poursuivre l'analyse exploratoire sans perte d'information.

Section II - Analyse des outliers : détection et correction

Suite à la correction de notre base de données, nous pouvons procéder à l'étude des points atypiques de notre variable dépendante. L'examen du graphique X, nous révèle la présence de sept points atypiques, principalement concentrés sur l'année 2020. Ces points reflètent d'une fluctuation inhabituelle de la production industrielle en Grande-Bretagne, possiblement liée à des événements économiques majeurs du passé entraînant une variation positive ou négative de cette dernière. Par exemple, la crise du Covid-19⁷, la grande récession de 2007-2008⁸ ou le krach boursier de 2001-2002⁹, ont probablement contribué à une forte contraction de la production industrielle au plus fort des crises, suivie d'une reprise marquée dans le cadre des efforts de relance économique

Graphique X : Représentation des points atypiques de la production industrielle au Royaume-Uni



source : R studio, Auteurs

⁷ Rabassa, Valérie. "Pandémie de la COVID-19 et supply chains mondiales: repenser une stratégie de gestion de crise." *Outre-Terre* 57.2 (2019): 47-54.

⁸ GUILLOU, Sarah et al. « La crise de 2008 et la productivité totale des facteurs des entreprises françaises ». *Revue de l'OFCE*, 2015/6 N° 142, 2015. p.55-74. CAIRN.INFO, shs.cairn.info/revue-de-l-ofce-2015-6-page-55?lang=fr.

⁹ Kim, Dong Won, Young Soo Lee, and Kyung Suh Park. "Credit crunch and shocks to firms: Korean experience under the Asian financial crisis." *Emerging Markets Review* 3.2 (2002): 195-210.

Outre l'analyse littéraire de ces fluctuations, nous pouvons également étudier le type des points atypiques. Deux catégories se distinguent : le premier, “Temporary Change” (changement temporaire), correspond à un effet temporaire sur la série qui s'atténue progressivement sans perturbation de la tendance sous-jacente. À l'inverse, le type “Additive Outlier” (outlier additif) désigne une observation exceptionnelle susceptible de ne pas se résorber de façon exponentielle et d’avoir un impact plus durable sur la série temporelle. L’étude nous atteste de la présence de quatre points atypiques de type AO et trois de type TC (voir annexe X). Nous décidons de corriger l'ensemble des outliers pour garantir la qualité de notre étude.

Section III - Analyse de la stationnarité

Suite à la correction effectuée, nous allons procéder à l’analyse de la stationnarité de notre série dépendante, une étape cruciale pour garantir l’intégrité de nos résultats. Il convient de souligner que l’évolution de la production industrielle est censée être initialement stationnaire. Cependant, nous décidons d’appliquer tout de même les différents tests, tels que ADF, PP et KPSS à un modèle prenant en compte l’autocorrélation avec un retard de 1, c'est-à-dire un modèle AR(1).

Tableau 1 : Résultat des différents tests de stationnarité

AR(1)	Test	ADF	PP	KPSS
- 0,2981	p - value	0.01	0.01	0.1


sources : R Studio, Auteurs

En analysant le tableau X, nous pouvons observer les différentes p-values des tests. Pour les tests ADF et PP, l’hypothèse nulle stipule que la série n’est pas stationnaire. Cette hypothèse est rejetée si la p-value est inférieure à 5 %. Dans notre cas, la p-value est inférieure à 5 % (0,01), nous pouvons donc rejeter l’hypothèse nulle et conclure à la stationnarité de la variable dépendante selon les tests ADF et PP. Par la suite, le test KPSS postule que l’hypothèse nulle est que la série est stationnaire autour d’une tendance déterministe, avec une p-value supérieure à 5 %. Dans notre cas, la p-value est supérieure à 5 % (0,1), nous acceptons donc l’hypothèse nulle et pouvons affirmer que la série est stationnaire autour d’une tendance déterministe. Cette batterie de tests confirme donc la stationnarité de notre série dépendante.

Section IV - Analyse descriptives

Nous pouvons dès à présent visualiser l'évolution de la production industrielle en Grande-Bretagne de 1998 à 2024, en confirmant qu'elle est stationnaire et exempte d'outliers.

Graphique 1 : Evolution de la production industrielle au Royaume-Uni de 1998 à 2024



sources : R Studio, Auteurs

Nous pouvons remarquer que notre variable dépendante manifeste une convergence vers sa moyenne, compte tenu de la stationnarité de notre série. Néanmoins, nous observons deux perturbations marquées, l'une en 2002 et l'autre en 2020, qui entraînent des fluctuations notables, comme expliqué précédemment dans l'analyse des outliers. Cependant, une analyse visuelle de notre série ne peut suffire, c'est donc dans ces conditions que nous procédons à une analyse supplémentaire des différentes statistiques et indicateurs descriptifs de notre série, présentée dans le tableau X.

Tableau 2 : Résultats des statistique descriptives de notre variable dépendante

Statistique	Valeurs
Min	-0.0528347
1Q	-0.0054083
Moyenne	0.0005119
Médiane	0.0009723
3Q	0.0069445
Max	0.0331738
Variance	0.0001079905
Ecart-type	0.01039185
Skewness	-0.3311376
Kurtosis	5.12261
Jarque-Bera (p-value)	> 0.01
Shapiro (p-value)	> 0.01

sources : R Studio, Auteurs

L'analyse du tableau X révèle que la moyenne et la médiane sont proches, tout comme les valeurs minimale et maximale, ce qui indique une faible étendue des données, inférieure à 1. Cette faible dispersion est également confirmée par un écart-type et une variance réduits, suggérant une distribution relativement symétrique. Les indicateurs de skewness et de kurtosis permettent d'affiner cette caractérisation. Ainsi, la skewness négative montre que la distribution présente une asymétrie avec une queue orientée vers la gauche, tandis que la kurtosis positive souligne le caractère leptokurtique de la distribution, c'est-à-dire la présence de queues épaisses. De plus, notre série de données indépendantes ne semble pas suivre une distribution normale. C'est dans ce contexte que nous avons décidé d'appliquer différents tests afin d'examiner si notre série suit bien une loi gaussienne. Nous avons donc utilisé le test de Shapiro-Wilk et le test de Jarque-Bera. Ces deux tests, dont l'hypothèse nulle est celle de la normalité de la distribution, ont tous deux été rejetés, comme l'indiquent les p-values inférieures à 0,01, et ce rejet est également illustré graphiquement dans l'annexe X.

Section V - Classification

Suite à l'analyse rigoureuse de notre variable dépendante, il est alors primordiale d'exercer une analyse exploratoire pour le reste de nos données. Cependant au regard de la taille importante de notre base de données composée de 110 variables, nous ne pouvons appliquer les mêmes méthodes de visualisation telles que l'analyse des statistiques descriptives et visuelles. Ainsi nous décidons donc d'appliquer des méthodes de simplification d'analyse exploratoire telles que la clusterisation et l'analyse en composante principale que nous utiliserons en synergie. Dans un premier temps, nous appliquerons la méthode de clusterisation basée sur l'algorithme K-means, ce qui nous permettra d'identifier des sous-groupes au sein des données et de révéler des tendances significatives dans la segmentation des variables. Par la suite, nous utiliserons l'Analyse en Composantes Principales (ACP) sur les différents clusters, en appliquant un seuil de $\cos^2$ de 0,75. Cela nous permettra de ne visualiser que les variables les plus importantes, réduisant ainsi la dimensionnalité tout en préservant l'information essentielle. Cette approche facilitera l'identification des variables qui contribuent le plus à la variance des données.

Tableau 3 : Variables les plus importantes pour chaque cluster :

Cluster 1	Cluster 2	Cluster 3
IOS PRODUCTION DE SERVICE	CPIH_ALL INDICES DE PRIX À LA CONSOMMATION	FTSE_ALL MARCHÉ FINANCIER
AVG_WEEK_RETAIL_S ALE_NON_FOOD PRODUCTION	CPI_ALL INDICES DE PRIX A LA CONSOMMATION	UK_focused_equity MARCHÉ FINANCIER
IOS_G PRODUCTION DE SERVICE	RPI_ALL INDICES DE PRIX À LA CONSOMMATION	FTSE250 MARCHÉ FINANCIER


sources : Auteurs

Ainsi, nous obtenons un nombre optimal de trois clusters distincts. Nous choisissons de ne montrer que les variables les plus importantes pour chaque secteur. Dès lors, nous pouvons observer que, pour le premier cluster, les variables prises en considération semblent être celles liées à la production, tant dans la production générale que dans celle de services. Pour

le cluster numéro deux, ce sont les indices de prix, tels que le CPI_ALL (Indice des Prix à la Consommation, mesurant les variations des prix des biens et services consommés par les ménages) et le RPI_ALL (un autre indice de l'inflation), qui dominent. Enfin, pour le troisième cluster, les indices financiers, comme le FTSE (indices boursiers de la Bourse de Londres), prédominent. Cette segmentation nous permet ainsi de mieux visualiser les sous-groupes de variables suivant une tendance commune.

Cependant, afin d'avoir une analyse complète, nous décidons d'effectuer une analyse en composantes principales (ACP) pour chaque cluster. Il est à noter que nous avons décidé de n'afficher dans la visualisation de l'ACP que les variables possédant un $\cos^2$ supérieur à 0,75 afin de mieux visualiser les variables importantes. De plus, nous analyserons uniquement le cluster 3, étant donné que les analyses sont similaires pour les trois clusters.

Figure 1 : Analyse en Composante Principale du cluster 3 :



sources : R Studio, Auteurs

En étudiant la figure X, nous pouvons d'abord remarquer que l'inertie totale est d'environ 50 %, exactement 49,4 %, ce qui nous indique que les deux premières composantes captent à elles seules la moitié de la variance des données. Il est important de rappeler que chaque flèche représente une variable, et que sa direction et sa longueur indiquent son

association avec les dimensions principales. Plus la flèche est longue et proche du bord du cercle, plus la variable est bien représentée dans le plan. Enfin, les variables proches les unes des autres sont fortement corrélées, tandis que les variables opposées sont négativement corrélées. Ainsi, nous pouvons distinguer deux groupes distincts : le premier regroupe les indices boursiers américains et britanniques, corrélés entre eux, en opposition à la variable représentant un indice mesurant la valeur de la livre sterling par rapport à un panier de devises internationales. Cette relation inverse est logique et reflète une combinaison de facteurs économiques, de politique monétaire et de structure du marché boursier britannique. Enfin, nous pouvons noter que l'ensemble des variables visualisées est bien représenté dans ce plan, quelle que soit leur direction, car toutes possèdent un $\cos^2$ d'au moins 0,75 (induit notamment par notre choix de sélection de représentation).

Nous pouvons appliquer cette même logique d'analyse pour les deux premiers clusters des ACP. En étudiant les annexes X et X, nous remarquons que l'ACP du deuxième cluster (46,9 %) possède une inertie totale sensiblement similaire à celle du troisième cluster, contrairement à celle du premier cluster, qui présente une inertie totale plus faible (35,5 %), démontrant une difficulté à expliquer l'ensemble de la variabilité des variables dans ce cluster. Néanmoins, nous décidons quand même d'analyser les différents axes de chaque cluster. Ainsi, pour le deuxième cluster, il s'agit de comprendre que l'axe 1 représente la mesure générale de l'inflation et de la variation des prix, induite notamment par le regroupement de plusieurs indices de prix et d'inflation. En revanche, l'axe 2 signale les taux d'intérêt et les conditions des marchés financiers, indépendamment des indices de prix. Tandis que pour le premier cluster, cette analyse doit être considérée avec précaution, car elle comporte énormément de variables. Cependant, nous pouvons quand même définir les différents axes : le premier étant un indice de la productivité et de la santé du marché de l'emploi et le deuxième représentant des indicateurs de conditions économiques inverses au marché de l'emploi.

Section VI - Corrélation


La clustering de notre base de données nous a permis de mettre en lumière les sous-groupes de cette dernière, c'est-à-dire les variables possédant des tendances communes. Il est nécessaire d'appliquer les méthodes de corrélation afin de vérifier la véracité de notre analyse effectuée dans la partie classification. Il est important de noter que nous étudierons au

préalable les corrélations les plus fortes, qu'elles soient corrélées ou anti-corrélées, entre nos variables dépendantes et nos variables indépendantes. Ensuite, nous analyserons les corrélations des variables indépendantes entre elles pour chaque cluster.

1§ - Corrélation entre la variable dépendantes et les variables indépendantes

Nous commençons dès lors notre analyse des corrélations entre la production industrielle et les variables indépendantes. Il est important de noter au préalable les échelles de corrélation. Nous savons qu'une corrélation forte est représentée par un coefficient $\in [0,3 ; 0,5]$, une corrélation moyenne $\in [0,3 ; 0,5]$, une corrélation faible $\in [0,1 ; 0,3]$, et enfin, une absence de corrélation correspond à un coefficient $\in [0 ; 0,1]$.

Graphique 2 : Les 10 variables les plus corrélés positivement (à notre Y) :




sources : R Studio, Auteurs

En étudiant le graphique X, nous constatons qu'il n'existe que quatre variables corrélées très fortement à la production industrielle, avec un maximum de 0,8 pour le coefficient de la variable "IOP_MANU", représentant la production industrielle dans le secteur manufacturier. Les autres variables présentent une corrélation faible ou moyenne. Ainsi, lorsque la production industrielle du Royaume-Uni varie, les variables dépendantes fluctuent de manière pondérée selon leurs coefficients de corrélation, c'est-à-dire dans le

même sens et de façon positive. Nous pouvons également noter que presque toutes les dix variables les plus corrélées positivement avec notre variable dépendante sont majoritairement liées à la production industrielle, aisément identifiables grâce au préfixe IOP. Les deux seules variables qui ne relèvent pas du groupe de production concernent les exportations, établissant néanmoins un lien évident avec la production industrielle d'un pays. Par conséquent, ces corrélations apparaissent très cohérentes. Nous pouvons appliquer cette analyse pour les.

Graphique 3 : Les 10 variables les plus corrélées négativement (à notre Y) :



sources : R Studio, Auteurs


Nous remarquons dès lors, grâce au graphique X, qu'aucune variable indépendante n'est fortement anti-corrélée. En effet, "PPI_MOTOR" est la variable la plus anti-corrélée, ne possédant qu'un coefficient négatif de 0,18, signifiant une faible corrélation. Cela indique dès lors une évolution dans le sens opposé de notre variable dépendante, la production industrielle.

Ainsi, nous avons plus de variables corrélées et fortement corrélées que de variables indépendantes anti-corrélées à la production industrielle, comme l'a démontré la visualisation graphique des variables les plus corrélées et anti-corrélées, ainsi que l'annexe X.

2§ - Corrélation entre les variables indépendantes

Enfin, nous pouvons nous intéresser aux corrélations inter-variables, ce qui nous permet de confirmer ou non les sous-groupes proposés lors de l'étape de clustering. Il est important de noter que nous étudierons principalement le troisième cluster, étant donné que la démarche à suivre est similaire pour l'ensemble des clusters. De plus, il est essentiel de préciser que nous avons décidé de séparer le premier cluster en trois groupes, en raison de l'importance des variables. Cette segmentation du cluster s'est faite sans logique préalable. Enfin, notons que dans un souci de concision et d'efficacité, nous nous concentrerons sur l'analyse des corrélations entre les variables uniquement pour le cluster 3.

Figure 2 : Corrélation entre les variables indépendantes du cluster 3 :



sources : R Studio, Auteurs

En étudiant le graphique X, nous pouvons remarquer que les variables fortement corrélées entre elles représentent sensiblement les mêmes sous-groupes que ceux que nous avons trouvés dans la visualisation de l'ACP (sans filtre par le $\cos^2$) par cluster. Ainsi, pour le troisième cluster, nous retrouvons le groupe des indices boursiers américains et britanniques

ainsi que le groupe de “GBP” (la valeur de la livre sterling par rapport à un panier de devises internationales), tous deux présents dans le graphique X. Cependant, nous trouvons également d’autres groupes possédant des corrélations communes, telles que celles des variables M1, M2, M3 et M4. De plus, il est important de noter que, majoritairement, les variables sont corrélées et non anti-corrélées entre elles, sauf pour la relation entre PPI_MOTOR et GBP_EUR. Nous pouvons dès lors appliquer cette même méthode aux graphiques de corrélation des annexes X à X.

Chapitre III - Sélection des variables

Suite à l'analyse exploratoire de notre base de données importante, nous pouvons dès lors passer aux différentes méthodes de sélection de variables, telles que la méthode GETS, les régressions pénalisées avec et sans filtrage, les méthodes de réduction de dimension, ainsi que d'autres méthodes non linéaires, telles que le gradient boosting avec et sans filtrage SIS. Cela nous permettra d'évaluer au mieux l'efficacité de chaque méthode et d'en conclure sur la plus efficace à l'aide d'un tableau comparatif final. Il est important de noter que nous appliquons un retard à l'ensemble de nos variables indépendantes et quatre retards pour notre variable dépendante, c'est-à-dire la production industrielle au Royaume-Uni.

Section I - Approche économétrique : GETS

Dans un premier temps, nous utilisons la méthode GETS. La méthode GETS (General-to-Specific) est une approche de sélection de variables qui commence par un modèle général incluant toutes les variables potentielles, puis élimine progressivement les variables non significatives. Ce processus se base sur des tests statistiques pour réduire le modèle tout en conservant les variables les plus pertinentes. L'objectif est d'obtenir un modèle plus simple, mais toujours robuste et conforme aux données. Cette méthode devient inefficace avec un grand nombre de variables (221 X et Y dans notre cas) car elle effectue des tests successifs pour chaque variable, ce qui alourdit le processus et augmente le risque d'erreurs statistiques (surajustement). De plus, le temps de calcul devient prohibitif à mesure que le nombre de variables augmente. Enfin, avec trop de variables, il devient difficile de détecter les relations significatives, réduisant la pertinence des résultats. Ainsi, la méthode GETS est inefficace dans ce cas ; nous devons donc soit réduire la dimensionnalité de notre base de données, soit utiliser d'autres approches économétriques.

Section II - Régression pénalisées

En conséquence de la non-application de la méthode économétrique GETS, nous décidons d'appliquer un ensemble de régressions pénalisées, passant du Ridge au SCAD.

1§ - Ridge

Dans une optique de régression pénalisée, la régression Ridge introduit une contrainte qui réduit la taille des coefficients pour éviter qu'ils ne deviennent trop grands. Cette pénalisation aide à améliorer la généralisation du modèle, en particulier lorsque les données présentent des corrélations entre les variables ou un grand nombre de variables par rapport aux observations. Ridge minimise ainsi le surajustement tout en conservant l'ensemble des variables dans le modèle. Elle n'est pas une méthode de sélection de variables, car elle conserve toutes les variables dans le modèle, même si leurs coefficients sont réduits.

Tableau 4 : Résultats Ridge

λ	Variables sélectionnées
0.04132012	221

sources : R Studio, Auteurs

Le tableau ci-dessus valide notre hypothèse. En effet, le λ (lambda) est de 0,04. Selon la théorie, un λ faible indique une régularisation modérée, ce qui entraîne la conservation d'un grand nombre de variables, se rapprochant du nombre initial de variables (ici, toutes les variables explicatives, soit : 223 moins la date et Y, ce qui donne 221). Cela signifie que la méthode Ridge inclut presque toutes les variables dans le modèle, ce qui est cohérent avec le fait qu'elle ne procède pas à la sélection de variables.

2§ - Lasso

La méthode Lasso (Least Absolute Shrinkage and Selection Operator) est une technique de régression qui pénalise la somme des valeurs absolues des coefficients (pénalisation L1) pour éviter le surajustement. Elle permet à la fois la réduction des coefficients et la sélection automatique des variables en les amenant à zéro. Cela rend le modèle plus simple et plus interprétable (principe de parcimonie), en conservant uniquement les variables significatives.

Tableau 5 : Résultats Lasso

λ	Variables sélectionnées
0.03430469	4

sources : R Studio, Auteurs

Avec un λ faible (0,03) la méthode adapte une pénalité assez faible et donc le nombre de variables sélectionnées devrait être assez élevé. Or ce n'est pas le cas avec la sélection d'uniquement 4 variables. L'une des raisons pouvant expliquer ce phénomène est qu'il est possible que seules quelques variables aient une relation forte avec la variable dépendante. Dans ce cas, même avec une pénalisation faible, Lasso identifiera et conservera uniquement ces variables pertinentes.

3§ - Elastic-Net Fixé a Priori

La méthode Elastic Net est une technique de régression pénalisée qui combine les avantages des régularisations Lasso (L1) et Ridge (L2). En ajustant un paramètre α , Elastic Net permet de contrôler la balance entre ces deux types de pénalisation. En fixant $\alpha = 0.5$, Elastic Net combine les forces de Lasso et Ridge de manière égale, offrant un bon compromis entre sélection de variables et gestion des corrélations.

Tableau 6 : Résultats EN Fixé a Priori

λ	Variables sélectionnées
0.04977024	10

sources : R Studio, Auteurs

Elastic Net avec $\alpha = 0.5$ se distingue en sélectionnant 10 variables avec un λ de 0,04, un compromis équilibré entre Lasso, qui simplifie le modèle de manière stricte en ne gardant que 4 variables, et Ridge, qui conserve toutes les 221 variables. Elastic Net semble ainsi plus flexible et mieux adapté aux situations où certaines variables sont redondantes, mais où il est également important d'en conserver plusieurs pour éviter une perte excessive d'information.

4§ - Elastic-Net Grid search

L'Elastic Net Grid Search est une méthode utilisée pour optimiser les hyperparamètres du modèle, notamment α (qui équilibre Lasso et Ridge) et λ (qui contrôle la force de la pénalisation). Cette technique consiste à générer un ensemble de valeurs uniformément espacées pour chaque hyperparamètre dans une grille prédéfinie. Ensuite, pour chaque combinaison de α et λ , le modèle est entraîné plusieurs fois en utilisant la validation croisée (cross-validation) afin d'évaluer les performances. La meilleure combinaison d'hyperparamètres est celle qui minimise l'erreur de validation, garantissant ainsi un modèle performant et bien régularisé.

Tableau 7 : Résultats EN Grid search

λ	Variables sélectionnées
0.1261857	5

sources : R Studio, Auteurs

Les résultats nous indiquent que l'alpha utilisé par ce modèle est de 0.6, ce qui signifie que le modèle a mis plus de poids sur la méthode Lasso (60%) par rapport à Ridge (40%). Cette approche a permis de réduire le modèle à 5 variables soit moitié moins qu'en fixant $\alpha = 0.5$.

5§ - Elastic-Net Random search (Caret)

La méthode utilisée avec Caret applique des principes de grid search tout en offrant une interface simplifiée et automatisée pour évaluer les hyperparamètres. Cette automatisation permet de gagner du temps, réduit les erreurs et facilite l'interprétation des résultats.

Tableau 8 : Résultats EN Random search

λ	Variables sélectionnées
0.0125606	16

sources : R Studio, Auteurs

Les résultats nous indiquent que l'alpha utilisé par ce modèle est de 1, ce qui signifie que le modèle a mis tout le poids sur la méthode Lasso. Cependant, la valeur faible de λ (0,01) et la sélection de 16 variables contredisent cette observation, suggérant que cette méthode n'est pas appropriée pour notre base de données.

6§ - SCAD

La méthode SCAD (Smoothly Clipped Absolute Deviation) est une technique de régularisation qui vise à améliorer la sélection de variables tout en atténuant certains des inconvénients des méthodes traditionnelles comme Lasso et Ridge.

Tableau 9 : Résultats SCAD

λ	Variables sélectionnées
0.02056516	5

sources : R Studio, Auteurs

Cette approche a permis la sélection de 5 variables pertinentes parmi l'ensemble des données. A la façon de la méthode EN Grid search qui a aussi sélectionné 5 variables, cette fonction est moins contraignante que la pénalisation Lasso, mais plus stricte que la pénalisation Ridge.

7§ - Adaptive Lasso

L'Adaptive Lasso est une variante du Lasso qui ajuste dynamiquement la pénalisation des coefficients en fonction de poids adaptatifs, améliorant ainsi la sélection des variables et réduisant les biais. Il surmonte les limitations du Lasso classique, notamment en présence de corrélation entre variables.

Tableau 10 : Résultats Adaptive Lasso

λ	Variables sélectionnées
0.1081535	2

sources : R Studio, Auteurs

Cette méthode a sélectionné moins de variables que le Lasso classique. Les variables moins importantes ou bruitées ont été davantage pénalisées, ce qui a probablement conduit à leur exclusion du modèle.

Section III - Régression pénalisées avec l'approche SIS

La méthode de filtrage Sure Independence Screening (SIS) est une approche de sélection de variables utilisée dans des contextes à haute dimension, où le nombre de variables (ou prédicteurs) est beaucoup plus grand que le nombre d'observations. SIS simplifie le modèle en effectuant une présélection des variables avant d'appliquer des méthodes plus sophistiquées, comme Lasso ou Elastic-Net. Le principe clé de SIS est de mesurer l'importance de chaque variable indépendamment du reste du modèle, souvent à l'aide de la corrélation entre chaque variable explicative et la variable dépendante. Les variables avec les corrélations les plus fortes sont ensuite retenues pour l'étape suivante. Cette

méthode est particulièrement utile pour réduire la dimensionnalité initiale du problème, en évitant le surajustement et en améliorant l'efficacité computationnelle dans les grandes bases de données.

Nous réutiliserons les mêmes méthodes de régression pénalisées que précédemment, cette fois appliquées à une base de données réduite à 66 variables. Les méthodes demeurant inchangées, l'ensemble des résultats obtenus sera consolidé dans le tableau comparatif final. Seule exception, la méthode Gets, que nous examinerons immédiatement, cette analyse n'ayant pas pu être effectuée dans les étapes précédentes.

1§ - Approche GETS

Tableau 11 : Résultats GETS

Variables sélectionnées	Variables importantes	Coef
15	IOP_MANU IOP_ENER	0.71 0.17


sources : R Studio, Auteurs

Une fois la base de données réduite, notamment grâce à la méthode SIS, l'application de la méthode GETS devient possible. En appliquant cette méthode, nous obtenons une sélection de 15 variables, parmi lesquelles les deux plus significatives sont "IOP_MANU" et "IOP_ENER". La variable "IOP_MANU" présente un coefficient de 0,71, tandis que "IOP_ENER" affiche un coefficient de 0,17. Cela signifie qu'une augmentation d'une unité de "IOP_MANU" entraîne une hausse de 0,71 unité de notre variable dépendante, qui représente la production industrielle. De manière similaire, une augmentation d'une unité de "IOP_ENER" se traduit par une augmentation de 0,17 unité de la production industrielle. Ces coefficients suggèrent que "IOP_MANU" a un impact plus fort sur la production industrielle que "IOP_ENER". Cela peut refléter une dépendance plus marquée de l'industrie vis-à-vis des activités manufacturières par rapport au secteur énergétique dans le contexte de cette analyse.

Section IV - Méthode de sélection de variables non linéaire : Gradient Boosting

Suite à l'application de l'ensemble des régressions pénalisées et de la méthode économétrique GETS, avec et sans l'approche SIS, nous pouvons dès lors passer à l'application du Gradient Boosting. Le Gradient Boosting construit des arbres de décision successifs, où chaque nouvel arbre vise à corriger les erreurs des arbres précédents. Certains hyperparamètres doivent être soigneusement ajustés, car ils jouent un rôle essentiel dans la performance du modèle. Par exemple, le paramètre de shrinkage régule l'ampleur de la correction apportée par chaque nouvel arbre, en limitant l'impact de chaque arbre sur le modèle final.

Graphique 4 : Choix du meilleur taux de shrinkage



sources : R Studio, Auteurs


Pour les deux approches (avec/sans SIS), le shrinkage de 0,05 (courbe rouge) semble offrir le meilleur compromis entre performance et nombre d'arbres nécessaires, car l'erreur de validation croisée est minimale et stable à partir de 1000 à 1500 arbres. Ainsi, nous

appliquerons le shrinkage de 5 % dans la méthode de sélection de variables non linéaires, dans un premier temps sans le filtrage SIS, puis avec.

1§ - Gradient Boosting sans le filtrage SIS

Étant donné le nombre élevé de variables retenues, nous avons choisi de ne conserver que celles ayant une influence relative supérieure à 4 sur le modèle, ce qui semble être un seuil cohérent compte tenu de nos données.

Figure & Tableau 3 : Influence relative des variables au modèle (>4%) & variables retenues sans approche SIS




sources : R Studio, Auteurs

2§ - Gradient Boosting avec le filtrage SIS

La même méthode de filtrage SIS est utilisée pour réduire le nombre de variables et pouvoir utiliser le Gradient Boosting sur une base allégée.

Figure & Tableau 4 : Influence relative des variables au modèle (>4%) & variables retenues avec approche SIS



Variables retenues	Contribution au modèle
IOP_MANU	59.12%
IOP_INT_GOOD	8.38%
IOP_ENER	7.96%
IOP_GOOD	4.88%

sources : R Studio, Auteurs

Le modèle de Gradient Boosting accorde une importance très élevée à la variable “IOP_MANU”, ce qui suggère qu'elle joue un rôle crucial dans les prédictions et ce, peu importe le filtrage SIS. Les variables retenues dans le modèle de Gradient Boosting, bien que moins influentes que “IOP_MANU”, font toutes partie du groupe de variables “IOP” (Index of Production), qui représentent différentes catégories d'industries dans l'économie : IOP_INT_GOOD : Représente les biens intermédiaires. Ces biens sont des produits utilisés dans le processus de production d'autres biens, souvent essentiels pour comprendre les dynamiques de la chaîne d'approvisionnement et la performance industrielle. “IOP_ENER” : Se rapporte au secteur de l'énergie, qui est un moteur essentiel de l'économie industrielle. Les fluctuations dans ce secteur peuvent avoir un impact direct sur la production et la consommation dans les autres industries. “IOP_GOOD” : Couvre les biens de consommation, une catégorie clé pour mesurer la demande des ménages et l'impact de la consommation sur l'économie. Ces variables sont toutes des indicateurs importants du secteur industriel global et jouent des rôles complémentaires dans l'explication de la production (“IOP_PROD”). Leur inclusion dans le modèle montre que l'évolution de la production dépend en premier lieu du niveau de production des industries manufacturières (“IOP_MANU”) ainsi que des biens de consommation, mais aussi de l'énergie et des biens intermédiaires, qui sont des intrants pour d'autres secteurs économiques.

Section V - Comparaison des différentes approches

Une fois l'ensemble de nos modèles appliqués et analysés, nous pouvons procéder à leur comparaison de leurs paramètres mais également des coefficients des variables choisies afin de distinguer clairement les caractéristiques de chacune de nos approches.

1§ - Comparaison des différents résultats des modèles

Nous débutons ainsi, notre étude comparative par l'analyse du nombre de variables choisies et leurs paramètres λ . Il est de noter que nous avons choisi d'inclure les méthodes GETS et Gradient Boosting, même si ces dernières ne disposent pas de paramètres λ

Tableau 12 :Résultat des méthodes de régression pénalisé

Méthodes	SANS SIS			AVEC SIS	
	Nb variable	λ		Nb variable	λ
Gets	x	x		15	x
Ridge	221	0.0413		66	0.0112
Lasso	4	0.0343		5	0.0285
Elastic-Net [fixé]	10	0.0497		10	0.0413
Elastic-Net [Grid]	5	0.1261		14	0.0599
Elastic-Net [Caret]	16	0.0125		11	0.0126
SCAD	5	0.0205		5	0.0192
aLasso	2	0.1081		2	0.0154
Gradient Boosting [Var > 4%]	5	x		4	x

sources : R Studio, Auteurs

En étudiant le tableau X, nous remarquons que la méthode Ridge ne réalise pas de sélection de variables, que ce soit avec ou sans l'application de la méthode SIS. Ce manque de sélectivité rend accessoire l'examen du paramètre λ , ce qui la rend moins adaptée pour des modèles nécessitant une forte parcimonie. En revanche, elle reste pertinente pour les modèles

où la stabilité, la complexité (en conservant un grand nombre de variables) et la robustesse sont essentielles. D'autre part, la méthode la moins sélective, avec le plus faible λ , est **Elastic-Net [Caret]** ($\lambda : 0.0125$), qui sélectionne 16 variables. Cette méthode conserve donc une grande diversité de variables, même en présence de pénalités. À l'opposé, parmi les méthodes les plus sélectives, **Elastic-Net [Grid]** présente un λ élevé ($\lambda : 0.1261$), ce qui conduit à une sélection plus stricte, avec seulement 5 variables. Cependant, la méthode la plus sélective, théoriquement et en pratique, reste **Adaptive Lasso**. Bien que son λ soit moins élevé, cette méthode est unique en appliquant des pénalités adaptatives, ce qui lui permet de réduire le nombre de variables de manière ciblée en conservant uniquement celles qui ont le plus d'impact sur le modèle.

Cette même méthode peut également s'appliquer aux modèles obtenus suite à l'application de la méthode SIS. Ainsi, après SIS, la méthode la moins sélective est **Elastic-Net [Grid]** ($\lambda : 0.0599$), avec une sélection de 14 variables. À l'inverse, **Elastic-Net [Caret]** ($\lambda : 0.0126$), avec le plus faible λ , sélectionne 11 variables. Cependant, comme précédemment, **Adaptive Lasso** ($\lambda : 0.0154$) reste la méthode la plus sélective, ne conservant que 2 variables, tant avec SIS que sans SIS.

En ce qui concerne les méthodes ne possédant pas de paramètre λ . Il est important de noter que la méthode économétrique **GETS** est la moins efficace pour la sélection de variables, car elle discrimine peu entre les variables. À l'opposé, **Gradient Boosting** semble beaucoup plus performant en termes de discrimination, que ce soit avec ou sans l'application de la méthode SIS. En effet, Gradient Boosting se révèle plus efficace pour identifier et conserver les variables les plus pertinentes, assurant une meilleure capacité de sélection dans des modèles exigeant une forte précision et une optimisation de la parcimonie.

2§ - Comparaisons des estimations des Beta

Après avoir étudié la sélectivité de l'ensemble des méthodes économétriques appliquées dans cette analyse, nous pouvons désormais passer à l'analyse des estimateurs β des variables sélectionnées. Il est important de noter que nous avons décidé de ne représenter que les variables sélectionnées le plus fréquemment. Ainsi, sans l'application de la méthode SIS, nous obtenons 10 variables (voir Annexe X), contre seulement 6 après l'application de la méthode SIS. Enfin, étant donné que l'analyse des coefficients est similaire avec ou sans la

méthode SIS, nous avons choisi d'interpréter uniquement les coefficients des estimateurs après l'application de la méthode SIS.

Tableau 13 :Ensemble des estimateurs β AVEC SIS

Variables	RLM	GETS	RIDGE	LASSO	EN [0.5]	EN GS	EN RS	aLASSO	SCAD
IOP_MANU	0.553	0.714	0.376	0.889	0.568	0.394	0.879	0.841	0.584
IOP_ENER	0.181	0.175	0.238	0.232	0.230	0.226	0.242	0.151	0.263
IOP_INT_GOOD	0.091	0.034	0.259	0.037	0.176	0.238	0.058	x	0.181
IOP_MINE	x	x	x	x	x	x	x	x	x
IOP_CAP_GOOD	0.052	x	0.263	x	0.119	0.190	0.023	x	0.165
IOP_GOOD	0.070	x	0.197	0.005	0.116	0.180	x	x	0.143
IOP_NON_DUR	x	x	x	x	x	x	x	x	x
IOS_PNDS	0.076	0.050	0.028	x	0.016	0.026	x	x	x
TOT_HOUSE_APP	x	x	x	x	x	x	x	x	x
IOP_DUR	-0.015	x	-0.067	x	x	-0.019	-0.009	x	-0.057

sources : R Studio, Auteurs

Le tableau présente les coefficients estimés de diverses variables selon plusieurs méthodes de sélection, en intégrant une réduction préalable avec l'approche SIS. Globalement, **IOP_MANU** émerge comme la variable ayant l'influence la plus forte sur la production industrielle. Elle est retenue par toutes les méthodes et présente les coefficients les plus élevés, en particulier avec le Lasso et l'Adaptive Lasso, confirmant son rôle déterminant. **IOP_ENER**, bien que moins influente, est également sélectionnée par toutes les méthodes avec des coefficients stables et relativement similaires, indiquant une influence secondaire mais cohérente. **IOP_INT_GOOD** présente une importance plus variable selon les méthodes : certaines, comme Ridge et Elastic-Net Grid Search, la sélectionnent avec un coefficient notable, tandis que d'autres la pondèrent faiblement ou ne la retiennent pas. Enfin, des

variables comme **IOP_MINE**, **TOT_HOUSE**, et **IOP_NON_DUR** ne sont pas retenues par l'approche SIS alors qu'elles l'étaient avec (d'où le manque de coefficient pour ridge et RLM qui ne sont pas des techniques de sélection) , indiquant un impact limité sur le modèle.

Chapitre IV - Conclusion

L'objectif de cette étude était de modéliser au mieux l'évolution de la production industrielle au Royaume-Uni de 1998 à 2024. Pour cela, nous avons mené une analyse exploratoire approfondie afin de mieux comprendre les relations entre les différentes variables, ainsi que l'évolution temporelle de notre variable dépendante. La taille conséquente de la base de données (Big Data) a constitué un défi majeur, nécessitant une sélection optimale des variables pour aboutir à des modèles robustes et complexes, mais avec un nombre minimal de variables. L'essentiel de notre travail s'est donc concentré sur l'application de diverses méthodes économétriques de sélection de variables, à la fois avec et sans réduction de dimension (méthode SIS), et sur l'intégration de méthodes non linéaires telles que le Gradient-Boosting.

Nous avons ainsi appliqué des méthodes de régression linéaires, comme Ridge, Adaptive Lasso, et SCAD, ainsi que des méthodes non linéaires telles que le Gradient Boosting, d'abord sans filtrage par SIS, puis avec SIS. Cette approche nous a permis de comparer les résultats de manière rigoureuse. Tous ces modèles ont conduit à des modèles de régression pénalisée, ce qui nous a permis de mieux appréhender l'importance des variables sélectionnées, notamment grâce aux différents estimateurs. L'étude des paramètres de chaque méthode a également constitué un moment crucial de cette analyse, pour mieux interpréter les modèles obtenus.

En conclusion, l'analyse révèle que la majorité des variables sélectionnées appartiennent à la catégorie "production", avec en particulier "IOP_MANU" (indice de production dans le secteur manufacturier), "IOP_ENER" (indice de production dans le secteur de l'énergie) et "IOP_INT_GOOD" (indice de production des biens intermédiaires). Ces variables se révèlent particulièrement pertinentes pour étudier l'évolution de la production industrielle. Il serait pertinent de poursuivre cette recherche en focalisant l'analyse exclusivement sur les variables du secteur de la production, afin de tester la robustesse et la cohérence des résultats finaux dans le contexte de la dynamique industrielle. Par ailleurs, intégrer des prédictions pourrait offrir une évaluation précise des performances de chaque modèle de régression pénalisée, permettant ainsi d'identifier celui qui se distingue par son efficacité optimale.


Annexe

Annexe 1 : Récapitulatif des variables

Catégorie de variable	Nombre de variables
Production	19
Emploi & Chômage	16
Salaire & Rémunération	6
Vacances & Congés	3
Indices des prix à la consommation	13
Commerce international	14
Taux de change & Prix du pétrol	6
Crédit & Hypothèques & Taux d'intérêt	12
Obligation & Marchés financiers	9
Indices de confiance	3
Indices de prix à la production	5
Autres	4

sources : Auteurs

Annexe 2 : Représentation graphique des valeurs manquantes :




sources : R Studio, Auteurs

Annexe 3 : Tableau des valeurs atypiques :

Date	Type	Coefficient	t-stat
Juillet 2002	AO	0.04898	4.995
Novembre 2008	AO	-0.04276	-4.493
Février 2020	TC	-0.07510	-7.562
Avril 2020	AO	-0.11327	-8.196
Mai 2020	TC	0.10587	11.483
Juin 2020	AO	0.05709	4.343
Décembre 2020	TC	-0.03437	-5.888


sources : RStudio, Auteurs

Annexe 4 : Distribution de la variables dépendantes :




sources : RStudio, Auteurs

Annexe 5 : Dispersion de la variable dépendante :




sources : RStudio, Auteurs

Annexe 6 : Dendrogramme de nos variables indépendantes :




sources : RStudio, Auteurs

Annexe 7 : Analyse en Composante Principale du cluster 1 :




sources : RStudio, Auteurs

Annexe 8 : Analyse en Composante Principale du cluster 2 :




sources : RStudio, Auteurs

Annexe 9 : Analyse en Composante Principale du cluster 3 :




sources : RStudio, Auteurs

Annexe 10 : Analyse en Composante Principale du cluster 1 avec sélection de $\cos^2 > 0.75$:




sources : RStudio, Auteurs

Annexe 11 : Analyse en Composante Principale du cluster 2 avec sélection de $\cos^2 > 0.75$:




sources : RStudio, Auteurs

Annexe 12 : Corrélation de spearman entre notre variable dépendante et indépendantes:




sources : RStudio, Auteurs

Annexe 13 : Corrélation entre les variables indépendantes du cluster 1 groupe A:




sources : RStudio, Auteurs

Annexe 14 : Corrélation entre les variables indépendantes du cluster 1 groupe B:




sources : RStudio, Auteurs

Annexe 15 : Corrélation entre les variables indépendantes du cluster 1 groupe C:




sources : RStudio, Auteurs

Annexe 16 : Corrélation entre les variables indépendantes du cluster 2:




sources : RStudio, Auteurs

Annexe 17 – Évolution du λ en fonction de mean-squared error et du nombre de variables pour la méthode Ridge




sources : RStudio, Auteurs

Annexe 18 – Évolution du λ en fonction de mean-squared error et du nombre de variables pour la méthode Lasso




sources : RStudio, Auteurs

Annexe 19 – Évolution du λ en fonction de mean-squared error et du nombre de variables
pour la méthode EN fixé a priori




sources : RStudio, Auteurs

Annexe 20 – Évolution du λ en fonction de mean-squared error et du nombre de variables
pour la méthode EN Grid search




sources : RStudio, Auteurs

Annexe 21 – Évolution du $\log(\lambda)$ en fonction de la cross-validation error et du nombre de variables pour la méthode SCAD



sources : RStudio, Auteurs

Annexe 22 – Évolution du λ en fonction de mean-squared error et du nombre de variables pour la méthode aLasso



sources : RStudio, Auteurs

Annexe 23 :Ensemble des estimateurs β SANS SIS

Variables	RLM	GETS	RIDGE	LASSO	EN [0.5]	EN GS	EN RS	aLASSO	SCAD
IOP_MANU	0.616	x	0.288	0.893	0.473	0.879	0.878	0.811	x
IOP_ENER	0.183	x	0.220	0.224	0.221	0.204	0.054	0.121	0.263
IOP_INT_GOOD	0.072	x	0.263	0.030	0.206	0.017	0.020	x	0.409
IOP_MINE	0.061	x	0.032	0.007	0.017	x	-0.009	x	x
IOP_CAP_GOOD	0.031	x	0.242	x	0.187	x	0.238	x	0.493
IOP_GOOD	0.193	x	0.100	x	0.063	x	0.009	x	x
IOP_NON_DUR	-0.106	x	0.112	x	0.078	x	0.006	x	0.296
IOS_PNDS	0.287	x	0.045	x	0.011	x	0.004	x	x
TOT_HOUSE_APP	0.017	x	0.036	x	0.009	x	0.004	x	x
IOP_DUR	-0.043	x	0.008	x	x	x	0.010	x	x

sources : R Studio, Auteurs

Liste des titres des tableaux & graphiques & figures & modélisations

Figures :

- Figure 1 : Analyse en Composante Principale du cluster 3 :
- Figure 2 : Corrélation entre les variables indépendantes du cluster 3 :
- Figure & Tableau 3 : Influence relative des variables au modèle (>4%) & variables retenues sans approche SIS
- Figure & Tableau 4 : Influence relative des variables au modèle (>4%) & variables retenues avec approche SIS

Graphiques :

- Graphique 1 : Représentation des points atypiques de la production industrielle au Royaume-Uni
- Graphique 2 : Evolution de la production industrielle au Royaume-Uni de 1998 à 2024
- Graphique 3 : Les 10 variables les plus corrélés positivement (à notre Y) :
- Graphique 4 : Les 10 variables les plus corrélés négativement (à notre Y) :
- Graphique 5 : Choix du meilleur taux de shrinkage

Tableaux :

- Tableau 1 : Résultat des différents tests de stationnarité
- Tableau 2 : Résultats des statistique descriptives de notre variable dépendante
- Tableau 3 : Variables les plus importantes pour chaque cluster :
- Tableau 4 : Résultats Ridge
- Tableau 5 : Résultats Lasso
- Tableau 6 : Résultats EN Fixé a Priori
- Tableau 7 : Résultats EN Grid search
- Tableau 8 : Résultats EN Random search
- Tableau 9 : Résultats SCAD
- Tableau 10 : Résultats Adaptive Lasso
- Tableau 11 : Résultats GETS
- Tableau 12 : Résultat des méthodes de régression pénalisé
- Tableau 13 : Ensemble des estimateurs β SANS SIS

Bibliographie

Bibliographie:

- Bairoch, Paul. "Commerce international et genèse de la révolution industrielle anglaise." *Annales. Histoire, Sciences Sociales*. Vol. 28. No. 2. Cambridge University Press, 1973.
- Beckouche, Pierre. "La révolution numérique est-elle un tournant anthropologique?" *Le débat* 193.1 (2017): 153-166.
- Goulet Coulombe, Philippe, Massimiliano Marcellino, and Dalibor Stevanović, 'CAN MACHINE LEARNING CATCH THE COVID-19 RECESSION?', *National Institute Economic Review*, 256 (2021), 71–109
- GUILLOU, Sarah et al. « La crise de 2008 et la productivité totale des facteurs des entreprises françaises ». *Revue de l'OFCE*, 2015/6 N° 142, 2015. p.55-74. CAIRN.INFO, shs.cairn.info/revue-de-l-ofce-2015-6-page-55?lang=fr.
- Hashemi, Arman. "Review of the UK housing history in relation to system building." *ALAM CIPTA, International Journal of Sustainable Tropical Design Research and Practice* 6.1 (2013): 47-58.
- Hérouville, Hubert D. "Marché commun et production industrielle mondiale." *Economie et Statistique* 13.2 (1958): 157-166.
- Kim, Dong Won, Young Soo Lee, and Kyung Suh Park. "Credit crunch and shocks to firms: Korean experience under the Asian financial crisis." *Emerging Markets Review* 3.2 (2002): 195-210.
- Michalet, Charles-Albert. *Le capitalisme mondial*. FeniXX, 1984.
- Rabassa, Valérie. "Pandémie de la COVID-19 et supply chains mondiales: repenser une stratégie de gestion de crise." *Oltre-Terre* 57.2 (2019): 47-54.

Tables des matières

Sommaire.....	I
Résumé.....	II
Abstract.....	III
Liste de Sigles.....	IV
Chapitre I - Introduction.....	1
Chapitre II - Analyse exploratoire.....	3
Section I - Analyse des valeurs manquantes.....	3
Section II - Analyse des outliers : détection et correction.....	4
Section III - Analyse de la stationnarité.....	5
Section IV - Analyse descriptives.....	6
Section V - Classification.....	8
Section VI - Corrélation.....	10
1§ - Corrélation entre la variable dépendantes et les variables indépendantes.....	11
2§ - Corrélation entre les variables indépendantes.....	13
Chapitre III - Sélection des variables.....	15
Section I - Approche économétrique : GETS.....	15
Section II - Régression pénalisées.....	15
1§ - Ridge.....	16
2§ - Lasso.....	16
3§ - Elastic-Net Fixé a Priori.....	17
4§ - Elastic-Net Grid search.....	17
5§ - Elastic-Net Random search (Caret).....	18
6§ - SCAD.....	18
7§ - Adaptive Lasso.....	19
Section III - Régression pénalisées avec l'approche SIS.....	19
1§ - Approche GETS.....	20
Section IV - Méthode de sélection de variables non linéaire : Gradient Boosting.....	21
1§ - Gradient Boosting sans le filtrage SIS.....	22
2§ - Gradient Boosting avec le filtrage SIS.....	22
Section V - Comparaison des différentes approches.....	24
1§ - Comparaison des différents résultats des modèles.....	24
2§ - Comparaisons des estimations des Beta.....	25
Chapitre IV - Conclusion.....	28
Annexe.....	29
Liste des titres des tableaux & graphiques & figures & modélisations.....	41
Bibliographie.....	42
Tables des matières.....	43