

Dossier de Natural Language Processing
MASTER 2 ECAP

NLP et Classification d'Articles de Presse : Étude sur le
Dataset BBC

Dossier réalisé par :

Gestin Ugo

Gottardini Valentin

Mocaër Rodolphe

Touman Niamiti Bethel

NLP et Classification d'Articles de Presse : Étude sur le Dataset BBC

Résumé

Ce projet applique des techniques de traitement du langage naturel pour classifier automatiquement des articles de presse issus du *BBC Articles Dataset*. Après une analyse exploratoire, les textes ont été vectorisés, thématisés (LDA), et analysés émotionnellement (VADER). Deux modèles supervisés (régression logistique et forêt aléatoire) ont été entraînés, atteignant une précision de 98 %. Ce travail démontre l'efficacité du NLP pour extraire du sens à partir de données textuelles journalistiques.

Mots clés : traitement du langage naturel, classification de texte, analyse de sentiments, LDA, TF-IDF, machine learning, articles de presse.

NLP and Press Article Classification: Study on the BBC Dataset

Abstract

This project uses Natural Language Processing techniques to automatically classify BBC news articles. Following exploratory analysis, texts were vectorized, thematically modeled (LDA), and sentiment-analyzed (VADER). Two supervised models (logistic regression and random forest) were trained, reaching 98% accuracy. The study confirms the value of NLP in extracting structured insights from unstructured journalistic content.

Keywords: natural language processing, text classification, sentiment analysis, LDA, TF-IDF, machine learning, news articles.

Sommaire

Résumé.....	I
Abstract.....	II
Sommaire.....	III
I - Introduction.....	1
II - Analyse exploratoire.....	3
III - Traitement des données textuelle.....	5
V - Classification automatique.....	11
VI - Conclusion.....	14
VII - Discussion.....	15
VIII - Bibliographie.....	16
IX - Annexes.....	17
X - Table des matières.....	19

I - Introduction

Dans un monde de plus en plus connecté, la quantité de données générées chaque jour est phénoménale. Parmi ces données, les textes, qu'ils soient issus d'articles de presse, de publications sur les réseaux sociaux ou de commentaires en ligne, représentent une source d'information précieuse. L'analyse de ces données textuelles est devenue essentielle pour extraire des connaissances et identifier des tendances. Ce projet s'inscrit dans ce contexte, en se concentrant sur la classification d'articles dans différentes catégories.

L'objectif principal est donc de développer un modèle capable de prédire la catégorie d'un article en fonction de son contenu. Pour ce faire, nous avons choisi d'utiliser des techniques de traitement du langage naturel (NLP) et des algorithmes de machine learning. Ces méthodes nous permettront non seulement de classer les articles, mais aussi d'explorer les mots et les caractéristiques qui influencent le plus les décisions du modèle. Les données utilisées dans ce projet proviennent d'un ensemble de données disponible sur Kaggle, intitulé "BBC Articles Dataset"¹. La base de données contient un large éventail d'articles de la BBC, classés en cinq catégories : business, politics, entertainment, sport, et tech. Chaque article est accompagné d'un titre et d'un contenu, offrant ainsi une richesse d'informations textuelles pour notre analyse. La diversité des catégories et la qualité des articles nous offrent une opportunité unique d'explorer les techniques de classification et d'évaluer leur efficacité. Dans un contexte où l'information est omniprésente, la capacité à classer et à analyser ces données textuelles devient cruciale pour les entreprises, les chercheurs et les journalistes. En effet, la classification automatique des articles peut aider à filtrer l'information pertinente, à améliorer les recommandations de contenu et à faciliter la recherche d'informations spécifiques.

Le dossier se déroulera en plusieurs étapes. Dans la première section, nous procéderons à une analyse exploratoire des données, où nous examinerons la structure, la distribution et les caractéristiques des articles. Cette étape est cruciale pour

¹ <https://www.kaggle.com/datasets/jacopoferretti/bbc-articles-dataset>

comprendre les données et identifier les éventuels problèmes à résoudre avant de passer à l'étape suivante. Ensuite, nous aborderons le traitement des données textuelles. Cette étape inclura la vectorisation des textes, l'élimination des mots inutiles (stop words), et d'autres techniques de prétraitement qui permettront de préparer les données pour l'analyse. Le traitement des données textuelles est fondamental, car la qualité des données d'entrée influence directement la performance des modèles de classification. Après le traitement des données, nous passerons à l'analyse et aux résultats. Nous évaluerons les performances des modèles de classification que nous avons développés, en utilisant des métriques telles que le F1-score, l'accuracy et la perplexité. Cette section mettra en lumière les forces et les faiblesses des modèles, ainsi que les insights que nous pourrions tirer des résultats obtenus. Nous introduirons également la modélisation avec LDA (Latent Dirichlet Allocation), une technique de modélisation thématique qui nous permettra d'explorer les thèmes sous-jacents dans les articles. LDA est particulièrement utile pour découvrir des structures cachées dans les données textuelles et peut compléter notre analyse de classification. Enfin, nous conclurons notre dossier par une synthèse des résultats et des discussions sur les implications de notre travail. Nous aborderons les limites de notre étude et proposerons des pistes pour des recherches futures. La bibliographie présentera les sources et les références utilisées tout au long du projet, tandis que les annexes fourniront des informations supplémentaires et des détails techniques. Ce projet représente donc une opportunité pour nous d'appliquer des techniques avancées d'analyse de données textuelles dans un contexte pratique, tout en contribuant à la compréhension des défis et des opportunités liés à l'analyse des données dans le domaine du journalisme et de l'information.

II - Analyse exploratoire

A) Présentation de la base

La base de données BBC Articles Dataset, disponible sur Kaggle, constitue une ressource précieuse pour l'analyse et la classification de contenus médiatiques. Ce jeu de données contient un ensemble de 2 225 articles provenant de la BBC, classés en cinq catégories distinctes : business, politics, entertainment, sport, et tech. Chaque article est accompagné d'un titre et d'un contenu, offrant ainsi une richesse d'informations textuelles pour l'analyse. Rédigés dans un style journalistique, ces articles sont particulièrement adaptés pour des études sur le traitement du langage naturel (NLP) et la classification de texte.

B) Description générale des labels (longueur moyenne des articles)

Une fois la présentation de la base de données effectuée, nous pouvons désormais passer à l'analyse descriptive des labels, en examinant à la fois la distribution des articles selon les catégories et les statistiques descriptives relatives à la longueur des textes.

Tableau 1 : Distribution des articles selon les thématiques journalistiques

Catégorie (Label)	Nombre d'articles
Business	505
Entertainment	503
Politics	403
Sport	369
Tech	347

sources : Auteurs, Python

Tableau 2 : Statistiques descriptives sur la longueur des textes des articles

Label	Moyenne du score de sentiment
Moyenne	2263.98 caractères
Ecart-type	1381.68
Minimum	502
1er quartile	1439.5
Médiane	1958
3e quartile	2802
Maximum	25484

sources : Auteurs, Python

La description générale des labels dans notre jeu de données met en lumière plusieurs aspects intéressants concernant la longueur des articles. Avec un total de 2 127 articles, les données sont réparties entre cinq catégories principales : sport (505 articles), business (503 articles), politics (403 articles), entertainment (369 articles) et tech (347 articles). Cette répartition indique une couverture relativement équilibrée, bien que le domaine du sport soit légèrement plus représenté. En ce qui concerne la longueur des articles, la moyenne s'établit à 2 263,98 mots, avec un écart type de 1 381,68 mots. Cela suggère une diversité significative dans la longueur des articles, allant de 502 mots pour les plus courts à un impressionnant 25 484 mots pour les plus longs.

La distribution des longueurs révèle que 25 % des articles ont moins de 1 439,5 mots, tandis que la médiane se situe à 1 958 mots, ce qui indique que la moitié des articles sont relativement longs. De plus, 75 % des articles dépassent 2 802 mots, ce qui souligne la présence d'analyses approfondies dans certaines catégories. Cette variabilité pourrait être attribuée à la nature des sujets traités. Par exemple, les articles de business et de politics peuvent nécessiter des explications détaillées et des analyses complexes, tandis que ceux de sport et entertainment peuvent se concentrer sur des événements récents ou des nouvelles plus succinctes.

III - Traitement des données textuelle

A) Modélisation thématique avec LDA

Dans la continuité de notre étude sur le corpus d'articles de presse, nous avons choisi d'approfondir notre compréhension des textes par le biais d'une modélisation thématique. Pour cela, nous avons mobilisé l'algorithme Latent Dirichlet Allocation (LDA). Ce dernier permet d'identifier de manière automatique les thèmes récurrents présents dans un ensemble de documents, sans avoir besoin d'étiquettes préalables. C'est un atout majeur pour faire émerger des structures thématiques sous-jacentes et mieux cerner les grandes lignes éditoriales des articles. Au préalable de l'application de LDA, une étape de préparation a été nécessaire. En effet, nous avons procédé à la vectorisation des textes nettoyés à l'aide de la méthode CountVectorizer, en restreignant le vocabulaire aux 5000 termes les plus fréquents. De ce fait, ce choix permet de réduire la complexité du modèle tout en préservant l'essentiel de l'information lexicale. Une fois la matrice terme-document obtenue, le modèle LDA a été entraîné avec cinq composantes, en cohérence avec les cinq grandes catégories présentes dans le jeu de données : business, entertainment, politics, sport et tech. Chaque thème généré par LDA se distingue par une combinaison de mots caractéristiques, qui reflètent le contenu dominant des articles concernés.

Tableau 3 : Moyenne des sentiments par label

Thèmes	Mots les plus fréquents	Mots traduit	Interprétation
Sujet 1	'sale', 'firm', 'market', 'company', 'year'	'vente', 'entreprise', 'marché', 'société', 'année'	Thématique économique et commerciale
Sujet 2	match', 'game', 'england', 'win', 'play'	match', 'jeu', 'angleterre', 'gagner', 'jouer'	Actualités sportives, compétitions
Sujet 3	'election', 'labour', 'government', 'minister', 'blair'	'élection', 'travailliste', 'gouvernement', 'ministre', 'blair'	Politique intérieure britannique
Sujet 4	'court', 'drug', 'russian', 'claim', 'yukos'	'tribunal', 'drogue', 'russe', 'réclamation', 'yukos'	Justice, affaires judiciaires et géopolitique

Sujet 5	music', 'award', 'film', 'star', 'play'	'musique, récompense, film, star, pièce de théâtre	Culture, divertissement et médias
---------	---	--	-----------------------------------

sources : Auteurs, Python

En étudiant le tableau 3, il apparaît clairement que la modélisation thématique réalisée à l'aide de l'algorithme LDA permet de dégager cinq sujets cohérents, chacun étant associé à un ensemble de mots caractéristiques qui reflètent fidèlement les grandes thématiques du corpus. Ces sujets présentent des degrés de clarté variables, certains étant immédiatement identifiables, d'autres nécessitant une interprétation plus fine :

Le Sujet 1, par exemple, est dominé par des termes tels que "sale", "firm" ou "market", qui évoquent une dynamique économique tournée vers les entreprises, les marchés financiers et les activités commerciales. L'interprétation de ce sujet comme relevant d'une thématique économique et commerciale s'impose donc de manière logique.

Le Sujet 2 fait émerger un vocabulaire sans équivoque lié au domaine sportif, à travers des mots comme "match", "game" ou "win", qui renvoient clairement à l'univers des compétitions, du jeu et de la performance sportive.

Les Sujets 3 et 4 présentent des thématiques relativement proches, mais qu'il est néanmoins possible de distinguer. Le Sujet 3 met en évidence un lexique explicitement politique avec des mots tels que "election", "labour", "government" ou "blair". Ces termes renvoient à la sphère institutionnelle britannique, et plus précisément aux enjeux électoraux. On notera la présence du mot "labour", qui fait référence au principal parti politique travailliste au Royaume-Uni, ainsi que "blair", nom de l'ancien Premier ministre Tony Blair, ce qui confirme le caractère politique du sujet. En revanche, le Sujet 4 s'oriente davantage vers une dimension juridique et géopolitique, comme le suggèrent les termes "court", "claim", "russian" ou "yukos". Ceux-ci font allusion à des contentieux juridiques internationaux et à des affaires liées à la Russie, notamment autour de l'entreprise pétrolière Yukos.

Enfin, le Sujet 5 révèle une orientation clairement culturelle et médiatique, à travers des mots tels que "music", "award", "film" et "star", qui traduisent l'univers du divertissement, de la production artistique et des célébrités.

Dans l'ensemble, cette répartition thématique souligne la pertinence de la modélisation par LDA, en montrant sa capacité à extraire de manière automatique des structures sémantiques significatives à partir d'un corpus textuel non annoté. Elle renforce également la validité des futures étapes de classification supervisée.

B) Occurrence des mots

Dans l'objectif de compléter notre étude et de mieux comprendre les termes les plus utilisés dans les différents labels (ou classes) regroupant les articles, nous avons choisi d'appliquer l'outil VADER. Cette approche nous a permis de générer cinq nuages de mots distincts, chacun représentant visuellement la fréquence et l'importance des mots les plus récurrents dans les articles appartenant à une catégorie spécifique. Ces visualisations offrent une perspective synthétique et intuitive sur le vocabulaire dominant propre à chaque thématique éditoriale.

Figures 1 : Nuages de Point



sources : Auteurs, Python

En analysant les figures 1, nous pouvons aisément observer que les nuages de mots générés pour chaque label confirment la cohérence thématique des articles. Pour la catégorie business, les termes dominants tels que "company", "market" ou "firm" renvoient clairement à des sujets économiques, illustrant une forte présence de thématiques liées aux entreprises, aux marchés financiers et à la croissance. Du côté du label entertainment, on observe une

forte récurrence des mots "music", "film", "award" et "play", qui traduisent l'univers du divertissement, des arts et des productions culturelles. Le nuage de mots associé à la catégorie politics met en avant des termes tels que "government", "election", "party", ou encore "Blair", ce qui reflète des discussions centrées sur les institutions, les partis politiques et les figures majeures de la scène britannique. Pour le label sport, les mots comme "game", "win", "match" ou "player" soulignent la forte présence de contenus liés aux compétitions sportives et à la performance. Enfin, dans la catégorie tech, les termes récurrents tels que "technology", "users", "games" ou "computer" montrent une orientation marquée vers les innovations numériques, les logiciels et les usages informatiques.

Ces visualisations confirment ainsi la pertinence de la classification thématique et offrent un aperçu synthétique et intuitif des champs lexicaux dominants propres à chaque catégorie d'articles.

C) Analyse des sentiments

Passons maintenant à l'analyse de sentiments, une étape cruciale pour notre projet. Cette analyse nous permettra d'évaluer les émotions et les opinions exprimées dans les articles de la BBC, en identifiant si le ton est positif, négatif ou neutre. En examinant les scores de sentiment associés à chaque article, nous pourrions mieux comprendre comment les différentes catégories, telles que le business, le sport ou la politique, influencent le ton des contenus. L'analyse de sentiments enrichit notre compréhension des articles en révélant des tendances émotionnelles spécifiques à chaque thème. Par exemple, les articles de divertissement pourraient afficher des scores de sentiment plus élevés, tandis que ceux sur la politique pourraient être plus nuancés. En intégrant ces insights dans notre modèle de classification, nous pourrions non seulement améliorer la précision des prédictions, mais aussi offrir des recommandations plus pertinentes. Cette approche nous permettra également d'analyser l'impact émotionnel des contenus médiatiques sur le public, ce qui est essentiel dans un paysage d'information en constante évolution.


Tableau 4 : Moyenne des sentiments par label

Label	Moyenne du score de sentiment
Business	0.059707
Entertainment	0.146567
Politics	0.068787
Sport	0.112700
Tech	0.103772

sources : Auteurs, Python

L'analyse des résultats montre des variations significatives dans les scores de sentiment selon les différentes catégories d'articles. Le label Entertainment affiche la moyenne la plus élevée avec un score de 0.146567, ce qui indique que les articles de divertissement tendent à véhiculer des émotions plus positives. En revanche, le label Business présente le score le plus bas à 0.059707, suggérant que les articles dans ce domaine sont souvent plus neutres ou moins émotionnels. Les catégories Politics et Sport affichent des scores intermédiaires de 0.068787 et 0.112700 respectivement, ce qui pourrait refléter la nature souvent nuancée des discussions politiques et l'engagement émotionnel associé aux événements sportifs. Enfin, le label Tech avec un score de 0.103772 montre également une tendance positive, mais moins marquée que dans le domaine du divertissement.

Figure 2 : Analyse de Sentiment des Articles par Catégorie en graphique en barres empilées



sources : Auteurs, Python

Le graphique illustre la répartition des sentiments (positif, neutre, négatif) dans différentes catégories d'articles. On observe que la majorité des articles, quel que soit le label, sont classés comme neutres, indiquant une tonalité équilibrée dans la couverture médiatique. Les articles de Business, Politics, Sport et Tech affichent une proportion notable de sentiments négatifs, ce qui pourrait refléter des préoccupations ou des critiques fréquentes dans ces domaines. En revanche, le label Entertainment se distingue par une plus grande prévalence de sentiments positifs, soulignant l'attrait émotionnel des contenus de divertissement. Cette analyse met en lumière les différences de tonalité entre les catégories, ce qui peut influencer la perception du public et la manière dont les informations sont reçues.

V - Classification automatique

A)Présentation de la méthodologie

Cette section expose le rendu sur les différentes méthodes de classification utilisées pour labelliser nos différents articles en l'occurrence une régression logistique et un modèle Machine Learning de type Forêt aléatoire.

Nous avons eu recours à une technique de vectorisation qui est le TF-IDF plus précisément Term Frequency - Inverse Document Frequency qui permet de quantifier l'importance relative des mots dans les documents en tenant compte de leur fréquence dans l'ensemble du corpus. Le résultat de cette vectorisation constitue ainsi notre lot de variables explicatives qui sera par la suite scinder avec la variable cible dans les proportions de 80% et 20% pour les jeux d'entraînement soit 1702 articles contre 425 articles. Notons que la vectorisation des articles lemmatisés permet de faciliter l'utilisation de telles données dans des modèles de type Machine learning et garantit un meilleur apprentissage. Le modèle de régression logistique permettra de classer les différents articles dans des labels en fonction de probabilité d'événement tandis que la forêt aléatoire se basera sur des arbres de décision avec des règles spécifiques à chaque nœud.

B) Comparaison des modèles

Les deux approches ont permis d'obtenir des résultats satisfaisants comme peuvent le témoigner les métriques d'accuracy et de f1-score dans le tableau suivant.

Tableau 5 : Comparaison des performances globales des modèles


Label	Accuracy	F1-score	Perplexity
Logistic Regression	0.98	0.98	1.49
Random Forest	0.97	0.97	1.49

sources : Auteurs, Python

Les modèles enregistrent de très bonnes performances sur le jeu de test avec des précisions très élevées. La régression logistique atteint une accuracy et un F1-score de

0.98, ce qui indique une très bonne capacité à prédire correctement les classes et à équilibrer précision et rappel. Le Random Forest quant à lui présente de très bons résultats, avec une accuracy et un F1-score légèrement inférieurs, à 0.97. Ces scores témoignent d'un bon apprentissage du signal utile dans les textes, sans surapprentissage visible. Et, cela peut être soutenu par un score de perplexité qui reflète généralement une mesure de la "surprise" du modèle face aux données dans les modèles de langages génératifs. Nous présentons ici les différentes matrices de confusion afin d'observer les différentes erreurs faites par les modèles.

Figure 3 : Matrice de confusion des modèles



sources : Auteurs, Python

Les deux matrices de confusion présentées par la figure 3 permettent de montrer une répartition quasi-parfaite des articles parmi les différents labels. On observe une forte concentration des prédictions sur la diagonale, ce qui indique que les classes sont, dans l'ensemble, bien distinguées. Par exemple, la classe business est correctement identifiée dans plus de 100 cas par les deux modèles avec seulement quelques rares confusions avec politics et tech. De même, les catégories "sport" et "tech" présentent une reconnaissance quasi parfaite, avec très peu de confusion vers d'autres classes. Les erreurs sont peu fréquentes et réparties de façon marginale, sans qu'une classe ne soit systématiquement confondue avec une autre. Cela suggère que le modèle a bien appris les spécificités lexicales propres à chaque catégorie, renforcé par l'efficacité de la vectorisation TF-IDF. Toutefois, les confusions légères entre "business" et "politics" ou "tech" peuvent être interprétées comme des chevauchements thématiques ou lexicaux.

VI - Conclusion

Au terme de ce projet, nous avons pu démontrer l'intérêt et l'efficacité des méthodes de traitement automatique du langage naturel (NLP) pour la classification d'articles de presse. En partant d'un jeu de données riche et structuré le BBC Articles Dataset notre objectif principal était de concevoir un modèle capable d'attribuer automatiquement une catégorie (business, politics, entertainment, sport ou tech) à un article en fonction de son contenu textuel. Ce projet s'inscrit dans un contexte où la gestion et l'exploitation des données textuelles deviennent essentielles pour trier, comprendre et valoriser l'information dans des volumes toujours croissants. Notre démarche a débuté par une analyse exploratoire approfondie, qui nous a permis de mieux comprendre la structure du corpus, la distribution des catégories et les caractéristiques statistiques des textes (longueur, fréquence des mots, tonalité). Ensuite, nous avons mis en place plusieurs étapes de prétraitement indispensables : nettoyage des textes, lemmatisation, suppression des mots vides, puis vectorisation des données via la méthode TF-IDF, afin de transformer les documents textuels en vecteurs exploitables par des algorithmes de machine learning. Nous avons enrichi cette approche par une modélisation thématique non supervisée (LDA), qui a révélé cinq grands thèmes cohérents, correspondant de manière pertinente aux catégories du dataset. Cela nous a permis de valider la structure implicite des données et de mieux comprendre les champs lexicaux dominants dans chaque classe. Une analyse de sentiment, via l'outil VADER, a également été menée pour examiner la tonalité émotionnelle des articles, apportant un éclairage complémentaire sur la nature des contenus journalistiques selon les thématiques. Sur le plan prédictif, deux modèles de classification supervisée ont été implémentés : une régression logistique et un modèle Random Forest. Les résultats obtenus sont très satisfaisants, avec des scores de précision (accuracy) et de F1 atteignant jusqu'à 0,98, ce qui reflète une excellente capacité de généralisation des modèles. Les matrices de confusion montrent une différenciation très nette entre les catégories, avec peu de confusions, principalement entre des thématiques proches comme business et politics. Ces performances attestent de la robustesse de notre pipeline de traitement et du bon équilibre entre complexité des modèles et qualité des données. En définitive, notre étude met en évidence la puissance des techniques de NLP combinées à des modèles d'apprentissage automatique pour l'analyse automatique de textes journalistiques. Elle ouvre la voie à des applications concrètes comme le filtrage intelligent de l'information, la recommandation de contenu, ou encore l'analyse de discours médiatique à grande échelle.

VII - Discussion

Bien que les résultats obtenus soient très satisfaisants, plusieurs pistes d'amélioration pourraient être envisagées pour approfondir l'étude. Tout d'abord, l'utilisation de modèles de deep learning plus avancés, tels que BERT ou RoBERTa, permettrait de mieux capter les relations contextuelles entre les mots. Contrairement aux approches fondées sur la fréquence comme TF-IDF, ces modèles pré-entraînés intègrent une compréhension plus fine du langage naturel et pourraient améliorer la gestion des cas ambigus ou des chevauchements thématiques. Par ailleurs, l'ajout de métadonnées comme la date de publication, l'auteur ou encore la section d'origine de l'article offrirait une richesse supplémentaire dans la phase de classification. Ces informations contextuelles pourraient jouer un rôle non négligeable, notamment pour mieux différencier des textes au contenu lexical similaire mais publiés dans des cadres différents.


D'autres axes méritent aussi d'être explorés, comme l'adaptation du modèle à des corpus multilingues ou issus de sources journalistiques variées. Cela permettrait d'évaluer la robustesse du pipeline au-delà du dataset BBC, qui reste relativement homogène. Enfin, une analyse plus poussée des aspects subjectifs et des éventuels biais médiatiques, ou encore une étude de l'évolution thématique dans le temps, ouvrirait la voie à une compréhension plus globale des dynamiques éditoriales. Ces perspectives témoignent du potentiel encore large des approches NLP pour l'analyse automatisée de contenus médiatiques, à condition de continuer à enrichir les modèles et à diversifier les jeux de données.

VIII - Bibliographie

- <https://www.kaggle.com/datasets/jacopoferretti/bbc-articles-dataset>


IX - Annexes

Annexe 1 : Analyse de Sentiment des Articles par Catégorie en boxplot




sources : Auteurs, Python

Annexe 2 : Importance des mots pour le Random Forest



sources : Auteurs, Python

Annexe 3 : Importance des mots pour la Régression linéaire



sources : Auteurs, Python

X - Table des matières

Résumé.....	I
Abstract.....	II
Sommaire.....	III
I - Introduction.....	1
II - Analyse exploratoire.....	3
A) Présentation de la base.....	3
B) Description générale des labels (longueur moyenne des articles).....	3
III - Traitement des données textuelle.....	5
A) Modélisation thématique avec LDA.....	5
B) Occurrence des mots.....	7
C) Analyse des sentiments.....	8
V - Classification automatique.....	11
A) Présentation de la méthodologie.....	11
B) Comparaison des modèles.....	11
VI - Conclusion.....	14
VII - Discussion.....	15
VIII - Bibliographie.....	16
IX - Annexes.....	17
X - Table des matières.....	19