

Dossier de Prévision et de conjoncture
MASTER 1 ECAP

Etude prévisionnel de l'incidence quotidienne du Covid-19
en France sur la période janvier 2021 à décembre 2022

Dossier réalisé par :
Gottardini Valentin
Mocaër Rodolphe
Gestin Ugo

Résumé

La pandémie de Covid-19 a profondément perturbé le monde en 2019, en particulier le domaine de l'épidémiologie. Tous les moyens ont été mobilisés pour prédire avec précision et limiter les conséquences de cette épidémie. Notre étude vise à anticiper au mieux l'évolution de la pandémie de Covid-19. Pour ce faire, nous utilisons divers modèles de prévision, allant des méthodes univariées telles que la méthode de lissage exponentiel à des modèles plus complexes comme ARMAX. Bien que notre recherche ait permis d'identifier des modèles efficaces, il est important de noter que les prévisions restent souvent éloignées de la réalité. Néanmoins, cette étude contribue à approfondir nos méthodes de prévision afin de mieux soutenir les efforts de santé publique dans la gestion et la réponse aux pandémies.

Mots clés : Covid-19, Prévision, ARMAX, Série temporelle

Abstract

The Covid-19 pandemic profoundly disrupted the world in 2019, particularly the field of epidemiology. All means were mobilized to predict accurately and mitigate the consequences of this epidemic. Our study aims to anticipate the evolution of the Covid-19 pandemic as effectively as possible. To achieve this, we employ various forecasting models, ranging from univariate methods such as exponential smoothing to more complex models like ARMAX. While our research has identified effective models, it is important to note that forecasts often diverge from reality. Nonetheless, this study contributes to deepening our forecasting methods to better support public health efforts in pandemic management and response.

Keywords : Covid-19, Forecasting, ARMAX, Time Series

Sommaire

I - Introduction.....	1
II - Analyse exploratrice.....	1
II - Sélection des variables.....	3
III - Prévvision.....	7
IV - Conclusion.....	8
V - Discussion.....	9
VI - Bibliographie.....	10
VII - Annexe.....	11
VIII - Table des matières.....	12

I - Introduction

Au cœur d'une période historique définie par la pandémie de COVID-19, s'étendant de début 2021 à fin 2022, notre étude offre une analyse exhaustive de l'impact de cette crise sanitaire mondiale et des réponses sociétales qu'elle a engendrées. Elle capture l'évolution de la pandémie à travers des indicateurs épidémiologiques clés tels que le taux d'incidence, les nouvelles hospitalisations, les admissions en réanimation, les sorties d'hôpital et les décès hospitaliers liés à la COVID-19, révélant la pression considérable exercée sur les infrastructures médicales¹ et l'effet dévastateur du virus sur les individus².

Parallèlement, elle documente la mobilisation sans précédent autour de la campagne de vaccination, à travers les données sur les premières, deuxièmes et troisièmes doses de vaccin administrées³, illustrant l'ampleur des efforts pour protéger la population et adapter la stratégie vaccinale face à l'émergence de nouveaux variants et à l'immunité décroissante⁴. Cette étude ne se contente pas de dresser le bilan d'une lutte contre un ennemi invisible, elle sert également de guide pour l'amélioration des réponses aux pandémies futures, témoignant de la résilience, de l'ingéniosité, et de la capacité d'adaptation de l'humanité face à une menace commune. Elle encapsule ainsi les leçons d'une des périodes les plus tumultueuses de l'histoire récente, offrant une perspective précieuse pour les générations futures sur la gestion de crise et la planification en santé publique.

Notre étude débute par une introduction qui établit le cadre et les objectifs, suivie d'une analyse exploratoire approfondie, incluant une revue de la littérature, la correction des données pour les anomalies, la vérification de leur stationnarité, et un résumé statistique descriptif. Nous procéderons ensuite à la sélection des variables explicatives, en utilisant des méthodes de sélection rigoureuses comme le Best Subset et le Gets pour affiner nos modèles. La phase de modélisation consolide notre approche en

¹ Gelly, Maud, and Alexis Spire. "Soigner sans compter. Les agents de l'hôpital public face à l'épidémie de Covid-19." *Revue française des affaires sociales* 4 (2021): 15-34.

²Organisation Mondiale de la Santé. (2022). Rapports de situation sur le COVID-19. <https://www.who.int/emergencies/diseases/novel-coronavirus-2019/situation-reports/>

³Centers for Disease Control and Prevention. "COVID Data Tracker." *Centers for Disease Control and Prevention*, 2022, <https://covid.cdc.gov/covid-data-tracker>.

⁴Commission européenne. "Une Union de la santé européenne: renforcer la résilience des systèmes de santé." *Commission européenne*, 2021, https://ec.europa.eu/health/future_eu_fr.


construisant des modèles basés sur les variables sélectionnées. La partie prévisionnelle testera l'efficacité des méthodes ARX/ARMAX, évaluera la qualité des prévisions et sélectionnera le modèle le plus performant. La conclusion synthétise nos découvertes, suivie d'une discussion critique sur les implications, les limites de l'étude, et les suggestions pour les recherches futures.

II - Analyse exploratrice

A) Revue de littérature

Le taux d'incidence est une mesure clé de l'activité épidémique⁵. Il est défini comme le nombre de personnes testées positives au COVID-19 par RT-PCR ou test antigénique pour la première fois depuis plus de 60 jours, par rapport à la taille de la population. Ce calcul, effectué pour 100 000 habitants, permet une évaluation standardisée de l'intensité de la circulation du virus au sein d'une population donnée sur une période déterminée. Cet indicateur est essentiel pour évaluer l'impact des interventions de santé publique, ajuster les mesures de contrôle et guider la politique sanitaire. Un taux d'incidence élevé peut indiquer la nécessité d'un renforcement des mesures de prévention, tandis qu'un taux en baisse peut signifier que les efforts déployés pour contrôler la pandémie portent leurs fruits.

Graphique 1 : Représentation du taux de l'incidence du covid de 2021 à 2023 en France.



sources : Auteurs, Rstudio

⁵ Jagadeesan M, Parasuraman Ganeshkumar, Prabhdeep Kaur... "Epidemiology of COVID-19 and effect of public health interventions, Chennai, India, March-October 2020: an analysis of COVID-19 surveillance system, BMJ Open".

Au début de 2021, on observe un taux d'incidence relativement modéré qui augmente légèrement puis décroît, ce qui pourrait coïncider avec les mesures de confinement (du 3 avril au 3 mai 2021 non inclus) et la mise en place initiale de la campagne de vaccination (indiquée par la première ligne pointillée verticale violette). La "5ème vague" indiquée sur le graphique coïncide avec un pic très prononcé, ce qui suggère une augmentation substantielle des cas de COVID-19 pendant cette période. Ce pic est immédiatement suivi par une chute rapide, qui pourrait être associée à la réponse des mesures de santé publique, telles que l'intensification de la vaccination ou la mise en œuvre du pass sanitaire (indiqué par la deuxième ligne pointillée rouge). La ligne pointillée rouge verticale finale, qui indique "Levée des restrictions", semble précéder une période où le taux d'incidence reste relativement bas et stable, suggérant une maîtrise de l'épidémie dans le pays. Cela pourrait être dû à une combinaison de l'immunité collective partielle atteinte grâce à la vaccination, des mesures de précaution qui continuent d'être observées par le public, ou de la saisonnalité du virus.

B) Vérification de la stationnarisation

Suite à la discussion des fluctuations de l'incidence des cas de covid-19 sur la période janvier 2021 à décembre 2023, nous pouvons dès lors analyser la stationnarité de notre série temporelle journalière par le biais de l'utilisation du test de Dickey-Fuller Augmenté (ADF). Cependant, il nous est primordial de souligner que l'étude des points atypiques est négligeable dans notre démarche. En effet, la correction des anomalies ou des valeurs aberrantes dans notre série peut être négligeable pour plusieurs raisons. Tout d'abord, la fréquence élevée de nos données (730 observations) nous permet de considérer l'impact de ces valeurs comme minime. De plus, ces points atypiques peuvent être interprétés comme du bruit ou des fluctuations aléatoires qui n'affectent pas de manière significative nos résultats globaux. Nous pouvons à présent passer à l'application du test sur notre série.

Tableau 1 : Résultat du test ADF pour notre série brute.

	Statistique du test	Retards	$P_{critique}$
Série Y	-4,3418	8	0,01

sources : Auteurs, Rstudio, Annexe 1


En examinant le Tableau 1, nous pouvons remarquer que les résultats du test ADF nous procurent une valeur critique de 0,01, nous indiquant la stationnarité ($P_{critique} < 0,05$) de notre série brute sans différenciation (Y_t). Par conséquent, notre série possède un ordre d'intégration d'ordre 0.

Cette stationnarisation sans différenciation nous conforte dans notre décision de mésestimer l'analyse des valeurs atypiques. En effet, une stationnarisation d'ordre 0 nous indique l'absence de tendance ou de structures temporelles significatives évoluant au fil du temps. Par conséquent, les variations observées dans notre série sont principalement attribuables à des facteurs aléatoires ou stochastiques. Nous pouvons alors considérer les anomalies comme des fluctuations aléatoires, comme mentionné précédemment.

C) Statistique descriptives

Suite à la vérification de la stationnarité de la moyenne, nous pouvons dès à présent analyser les statistiques descriptives de notre série Y_t afin de mieux comprendre ses tendances centrales, sa distribution et sa dispersion.

Graphique 2 : Boite à moustache de notre série Y_t



sources : Auteurs, Rstudio

La prévisualisation de notre série Y_t à l'aide d'un boxplot nous permet de mettre en évidence la dispersion de nos données et de les analyser en profondeur. L'examen du figure 2, nous révèle une présence significative de valeurs atypiques, essentiellement situées au-dessus du troisième quartile. Par conséquent, cette distribution pourrait influencer positivement notre moyenne. Cependant, nous soulignons que cette distribution semble standards lors de pandémie unique, en effet les pics épidémiques se manifestent comme des valeurs atypiques, logiquement plus élevées que les autres données. Cette figure nous à permis de préexaminer la dispersion de notre série mais une analyse plus approfondie s'avère nécessaire pour apprécier au mieux les tendances centrales et la dispersion des données.

Tableau 2 : Statistique descriptive de notre série Y_t .

	Min	Q1	Median	Moyenne	Q3	Max	Variance	ecart-type
Série Y	17.22	158.64	248.74	490.86	560.15	3565.66	412647.2	642.3762

sources : Auteurs, Rstudio, Annexe 2

Le tableau 2 nous permet d'examiner au mieux notre série. Dans un premier temps, nous pouvons analyser la distribution ; nous remarquons que l'écart-type est

plus élevé que la moyenne. Mise en évidence également par la plage des données s'étendant de 17,22 à 3565,66 pour le taux d'incidence du covid-19. Ainsi, dans un second temps, nous pouvons remarquer que notre série Y_t possède une moyenne médiane éloignée, confirmant ainsi notre première analyse de l'influence des valeurs atypiques. Par conséquent, notre série pourrait posséder une distribution non uniforme, non-normale. De ce fait, il nous est donc crucial de comprendre la loi statistique qui pourrait le mieux représenter la distribution de nos données.

Nous examinons à présent des paramètres essentiels dans l'appréhension de la distribution de notre série temporelle, tels que la skewness et la kurtosis. De plus, dans le but de confirmer notre hypothèse de non-distribution normale de notre série Y_t , nous appliquons le test de Shapiro.


Tableau 3 : Indicateur et test de notre série Y

	Skewness	Kurtosis	Statistique de test Shapiro	P-value associé au test
Série Y	2.823929	11.56595	0.64226	< 2.2e-16

sources : Auteurs, Rstudio, Annexe 3

L'étude du tableau 2 nous permet dès lors de saisir la distribution de notre série Y_t . La skewness de 2,8 souligne une asymétrie positive des données, suggérant une queue de distribution à droite plus longue. La kurtosis positive élevée met en lumière la leptokurticité de Y_t . De ce fait, nos valeurs sont fortement concentrées à gauche avec une queue de distribution étendue à droite. Ces deux paramètres semblent confirmer la distribution non normale de nos valeurs ; néanmoins, nous appliquons le test de Shapiro afin de vérifier cette hypothèse. La P_{value} associée au test étant fortement inférieure à 0,05, cela nous démontre alors la non-normalité de la distribution de notre série. Par conséquent, nous par une visualisation de nos la distribution de nos données de définir la loi sous-jacente à notre distribution.

Graphique 3 : Comparaison de la distribution de Y_t avec plusieurs lois de distributions statistiques



sources : Auteurs, Rstudio

En examinant, le graphique 3, il nous est aisé de mettre en évidence la possible loi sous-jacente de notre série temporelle Y_t . Cependant, préalablement de l'étude du graphique 3, nous devons souligner que nous avons normalisé les données afin de pouvoir comparer un grand nombre de lois de distribution. Le graphique 3, nous démontre dans un premier temps la dissimilitude avec la loi normale tandis qu'elle nous révèle une analogie à distribution exponentielle.


En résumé, notre série temporelle présente une asymétrie positive, comme indiqué par les mesures de tendance centrale. De plus, elle présente une dispersion importante. Enfin, sa distribution sous-jacente peut être approximée par une loi exponentielle.

II - Sélection des variables

A) Présentation des variables explicative

La variable 'incid_hosp' représente le nombre de nouveaux patients hospitalisés au cours des dernières 24 heures. C'est un indicateur clé de l'impact actuel de l'épidémie sur les systèmes de santé et permet aux hôpitaux et aux autorités sanitaires d'évaluer et de planifier les ressources nécessaires pour traiter les patients gravement atteints. Une augmentation de 'incid_hosp' peut signaler une pression croissante sur les capacités hospitalières et peut être le précurseur d'une situation de crise sanitaire si la tendance se maintient. En revanche, une diminution pourrait indiquer une amélioration de la situation ou l'efficacité des mesures de contrôle de la pandémie. Cette variable est essentielle pour la prise de décision en santé publique et la gestion des services hospitaliers.⁶

Graphique 1 : Représentation graphique de la distribution de X1




sources : Auteurs, Rstudio

La variable 'incid_rea' représente le nombre de nouveaux patients admis en unités de soins intensifs ou en réanimation au cours des dernières 24 heures. Cet

⁶ Gretchen Berlin, Shubham Singhal, Meredith Lapointe, and John Schulz, "Challenges emerge for the US healthcare system as COVID-19 cases rise", November 25, 2020 | Article, <https://www.mckinsey.com/industries/healthcare/our-insights/challenges-emerge-for-the-us-healthcare-system-as-covid-19-cases-rise>

indicateur est particulièrement crucial car il renseigne sur le nombre de cas graves nécessitant des soins médicaux avancés et de haute technicité, souvent associés à des taux de mortalité plus élevés et à une consommation importante de ressources hospitalières. Une hausse dans cette variable est un signe alarmant qui peut indiquer une augmentation de la gravité de l'épidémie et nécessiter une réponse rapide pour augmenter les capacités de réanimation. Une baisse, en revanche, peut indiquer une amélioration de la situation épidémique ou l'efficacité des interventions de santé publique. La surveillance de 'incid_rea' est essentielle pour l'ajustement des stratégies d'intervention et la planification des ressources de soins critiques.

Graphique 2 : Représentation graphique de la distribution de X2




sources : Auteurs, Rstudio

La variable 'incid_rad' est une métrique sanitaire qui quantifie le nombre de patients qui sont retournés à leur domicile au cours des dernières 24 heures après une hospitalisation. Cette donnée est encourageante, car elle indique la part des patients qui se sont suffisamment rétablis pour quitter l'hôpital. Cela peut refléter l'efficacité des traitements et la capacité de récupération des patients, ainsi que soulager la pression sur les ressources hospitalières. Une augmentation de 'incid_rad' suggère une amélioration dans la gestion des cas de COVID-19 et peut être un signe que les pressions sur le système de santé se relâchent. En revanche, une baisse pourrait indiquer que

moins de patients se rétablissent au point de pouvoir être déchargés, ce qui pourrait être un indicateur de la gravité accrue de la maladie.


Graphique 3 : Représentation graphique de la distribution de X3



sources : Auteurs, Rstudio

La variable 'incid_dhosp' représente le nombre de nouveaux décès parmi les patients hospitalisés dans les dernières 24 heures. Cet indicateur est d'une importance cruciale pour évaluer la létalité de l'épidémie et l'impact général sur la santé publique. Une hausse de 'incid_dhosp' peut indiquer une aggravation de la crise sanitaire et exige souvent des mesures de santé publique plus strictes pour contrôler la propagation du virus. À l'inverse, une baisse pourrait signifier que l'épidémie devient moins létale ou que les traitements s'améliorent. Ce chiffre aide les autorités sanitaires à comprendre l'évolution de la gravité de la maladie et à ajuster les réponses en conséquence.

Graphique 4 : Représentation graphique de la distribution de X4




sources : Auteurs, Rstudio

La variable dose 1 de vaccin contre la COVID correspondrait au nombre de personnes ayant reçu la première dose d'un vaccin COVID-19 au cours des dernières 24h. Cet indicateur est essentiel pour suivre les progrès des campagnes de vaccination⁷ et est souvent utilisé pour évaluer le pourcentage de la population ayant commencé le processus de vaccination. Cela permet d'estimer la couverture vaccinale partielle dans la population, ce qui est un pas important vers l'immunité collective. L'évolution de cette variable est étroitement surveillée par les autorités sanitaires, car elle peut influencer les décisions concernant les mesures de santé publique et les restrictions. Une augmentation constante de la proportion de la population ayant reçu au moins une dose est généralement interprétée comme positive, indiquant une meilleure protection contre le virus.

Graphique 5 : Représentation graphique de la distribution de X5


⁷ Kim Bouillon,1 Bérangère Baricault,1 Jérémie Botton,1 Marie-Joëlle Jabagi,1 Marion Bertrand,1 Laura Semenzato, 1 Stéphane Le Vu, 1 Jérôme Drouin,1 Rosemary Dray-Spira,1 Alain Weill,1 Mahmoud Zureik1,"Estimation de l'impact de la vaccination chez les personnes âgées de 75 ans et plus sur le risque de formes graves de Covid-19 en France à partir des données du Système National des Données de Santé (SNDS) – actualisation jusqu'au 20 juillet 2021",epi-phare,https://www.epi-phare.fr/app/uploads/2021/10/epi-phare_rapport_vaccination_reduction-des-risques_75ans-et-plus.pdf



sources : Auteurs, Rstudio

La variable dose 2 de vaccin contre la COVID désigne le nombre de personnes ayant reçu la deuxième dose d'un vaccin COVID-19 au cours des dernières 24h, complétant ainsi leur schéma vaccinal initial. Cette donnée est un indicateur clé de la couverture vaccinale complète au sein de la population, essentielle pour atteindre l'immunité collective et réduire significativement la transmission du virus. Le suivi de cette variable permet d'évaluer l'efficacité des efforts de vaccination et d'identifier les groupes de population qui restent non vaccinés ou partiellement vaccinés. Une augmentation de la couverture vaccinale complète est associée à une diminution des cas graves, des hospitalisations et des décès dus à la COVID-19, soulignant l'importance des campagnes de vaccination dans la lutte contre la pandémie.


Graphique 6 : Représentation graphique de la distribution de X6



sources : Auteurs, Rstudio


La dose 3 de vaccin contre la COVID fait référence au nombre total de personnes ayant reçu une dose de rappel ou une troisième dose d'un vaccin contre le COVID-19 au cours des dernières 24h. Cette dose supplémentaire vise à renforcer l'immunité, offrant une protection améliorée contre le virus, y compris ses variants. L'administration d'une dose de rappel est particulièrement importante dans le contexte de l'émergence de variants plus transmissibles ou potentiellement résistants aux vaccins initiaux. La surveillance de l'administration de cette troisième dose est cruciale pour évaluer et maintenir l'efficacité de la couverture vaccinale à long terme, surtout parmi les populations à risque élevé ou ceux dont l'immunité pourrait diminuer avec le temps. L'augmentation du nombre de personnes recevant la dose de rappel est un indicateur positif des efforts pour renforcer la protection de la population contre la COVID-19 et minimiser l'impact de la pandémie.

Graphique 7 : Représentation graphique de la distribution de X7



sources : Auteurs, Rstudio

Graphique 8 : Représentation graphique de la distribution de X5,X6,X7



La ligne rouge, étiquetée "dose1", montre une augmentation rapide qui atteint un sommet autour d'avril 2021, puis elle diminue progressivement en formant une série de pics moins élevés, indiquant des vagues de vaccination successives ou des réponses à des rappels intermittents. La ligne bleue, correspondant à "dose2", montre un modèle similaire à "dose1", mais avec son pic le plus élevé survenant légèrement plus tard, autour de mai 2021. Elle présente également une série de pics subséquents, bien que

ceux-ci soient moins prononcés que pour la première dose. La ligne verte, marquée "dose3", culmine beaucoup plus tard, avec un pic très marqué et pointu aux alentours de décembre 2021, suggérant l'administration massive d'une troisième dose ou d'une dose de rappel. Après ce pic, il y a une diminution rapide, suivie d'une activité de vaccination quasiment plate à partir de mi-2022. L'intervalle entre les pics pourrait refléter le temps recommandé entre les doses ou la réponse à des vagues d'infections. L'ensemble du graphique montre une campagne de vaccination initiale agressive suivie d'une série de rappels et finalement une stabilisation des activités de vaccination.

B) Corrélation

Tableau 4 : Tableau des corrélations entre la variable Y et nos X

Variable	Corrélation avec tx_incid
incid_hosp	0,61
incid_rea	0,26
incid_rad	0,51
incid_dchosp	0,25
dose1	-0,27
dose2	-0,21
dose3	0,39

sources : Auteurs, Rstudio, Annexe 4

Il existe une corrélation positive modérée entre tx_incid et incid_hosp, ce qui signifie que lorsque le taux d'incidence augmente, le nombre d'admissions à l'hôpital tend également à augmenter, et vice versa. La corrélation positive faible à modérée indique qu'une augmentation du taux d'incidence est légèrement associée à une augmentation des admissions en réanimation, bien que cette association soit moins forte que celle avec les admissions à l'hôpital en général. Une corrélation positive modérée suggère que des taux d'incidence plus élevés sont relativement bien associés à une augmentation des retours à domicile après hospitalisation, ce qui pourrait indiquer que plus de personnes sont déchargées à mesure que les cas augmentent. La corrélation positive faible signifie qu'il y a une légère tendance à avoir plus de décès à l'hôpital à

mesure que le taux d'incidence augmente. La corrélation négative faible à modérée indique que lorsque le taux d'incidence augmente, il y a une légère tendance à la baisse dans l'administration de la première dose de vaccin. Cela pourrait être interprété de diverses manières, par exemple, que les efforts de vaccination pourraient être ralentis pendant les pics d'incidence ou que moins de premières doses sont nécessaires à mesure que la population devient plus immunisée. Cette corrélation négative faible suggère une association légèrement négative entre le taux d'incidence et l'administration de la deuxième dose de vaccin, similaire à la première dose, bien que l'association soit un peu plus faible. Il existe une corrélation positive modérée entre le taux d'incidence et l'administration de la troisième dose de vaccin, ce qui pourrait indiquer que les campagnes de rappel de vaccination sont intensifiées en réponse à une augmentation des taux d'incidence.

C) Vérification de la stationnarité de nos séries indépendantes

Suite à l'analyse descriptive et aux corrélations de nos variables indépendantes, nous pouvons dès à présent passer à l'étape de vérification de la stationnarité de nos séries indépendantes. En effet, dans un souci de rigueur scientifique et dans le but d'appliquer méticuleusement les méthodes de sélection de nos variables grâce à l'approche Best SubSet et Gets, nous devons au préalable vérifier la stationnarité de nos séries indépendantes. Nous appliquerons alors le test ADF à nos séries brutes dans un premier temps.

Tableau 5 : Résultats des tests ADF pour nos séries indépendantes brutes.

Nom	Statistique du test	$P_{critique}$
Incid_hosp	-1,797504	0,6640229
Incid_rea	-1,585388	0,7538093
Incid_rad	-1,580527	0,7558670
Incid_dchosp	-1,410151	0,8279852
Dose 1	-2,885942	0,2032986
Dose 2	-2,159105	0,5109610

Dose 3	-2,133320	0,5218757
--------	-----------	-----------

sources : Auteurs, Rstudio, Annexe 5

En analysant le Tableau 5, nous pouvons constater que l'ensemble de nos séries brutes explicatives ne sont pas stationnaires, démontré notamment par le fait que $P_{critique} > 0,05$. Néanmoins par construction de nos séries dans la suite de notre dossier, nous admettons que nos séries indépendantes sont belles et bien stationnaire au opposition aux résultats des Test-ADF. De ce fait, aucune méthode de différenciation ne sera appliquée à nos séries explicatives. Nous pouvons alors procéder à la prochaine étape étant la sélection de variables grâce à l'utilisation de plusieurs approches

D) Sélection des variables indépendantes

Suite à l'introduction de nos différentes variables explicatives et à leur stationnarisation, il nous est alors possible de sélectionner celles nous permettant par la suite d'obtenir le meilleur modèle. Pour ce faire, nous utiliserons plusieurs approches, notamment les approches Best SubSet et Gets.

1) Approche Best SubSet

Dans cette partie, nous utiliserons l'approche Best Subset. Cette méthode est une technique nous permettant de sélectionner au mieux nos variables indépendantes. Elle consiste à évaluer toutes les combinaisons possibles de variables indépendantes pour un modèle donné, puis à sélectionner la combinaison qui optimise l'ensemble de nos critères.

Modélisation 1 : Résultat de l'approche Best SubSet

	R^2	$R^2_{ajustée}$	Fisher	AIC
Modélisation 1	0,6509	0,6479	$2,2e^{-16}$	3728,988

sources : Auteurs, Rstudio, Annexe 8 & 9

Grâce à l'application de cette technique à notre modèle de régression linéaire, nous avons pu mettre en évidence les variables importantes dans la construction du modèle le plus performant. Nous obtenons dès lors un modèle comportant 6 variables significatives, au seuil de risque de 5%, tout en incluant une constante qui cependant

n'est pas significative. Les variables pertinentes identifiées étant : Incid_hosp, Incid_rea, Incid_rad, Incid_dhosp, dose1 et dose2. Par ailleurs, il est important de souligner que notre modèle présente une bonne qualité explicative, capable d'expliquer environ 65% de la variance des données. Néanmoins, avant de sélectionner ce modèle pour les prévisions, nous décidons d'appliquer une autre approche afin de pouvoir déterminer si nous obtenons un modèle plus ou moins efficace.

2) Approche Gets

Le modèle GETS est une approche séquentielle dans la sélection de modèle. Elle commence par un modèle contenant un grand nombre de variables explicatives potentielles. À travers une série de tests statistiques, les variables moins significatives sont progressivement éliminées, réduisant ainsi la complexité du modèle. Cette méthode vise à simplifier le modèle initial en conservant uniquement les variables qui ont une influence statistiquement significative sur la variable dépendante. Le processus continue jusqu'à ce qu'un modèle plus spécifique et simplifié soit obtenu.

Lors de l'application de la méthode, la console nous indique "GUM does not pass one or more diagnostic checks". Ce message indique l'échec d'un ou plusieurs contrôles diagnostiques dans le contexte du GUM (Mesure d'Incertitude Générale) entraînant des problèmes dans l'estimation de l'incertitude des mesures.

E) Choix des variables indépendantes

Tableau 7 : Récapitulatif des modélisations

	R^2	$R^2_{ajustée}$	$Fisher - p_{value}$	AIC
Modélisation 1	0,02116	0,01551	0,005046	3875,376
Modélisation 2	/	/	/	/

sources : Auteurs, Rstudio, Modélisation 1

La sélection des variables indépendantes par l'approche GETS n'aboutissent pas, comme expliqué précédemment, nous sélectionnons donc comme modèle le plus performant et pertinent pour la suite de notre dossier le modèle obtenu par l'approche Best SubSet. Nous choisissons donc le modèle :

$$\begin{aligned}
Tx_{incid} = & 28,82 + 1,37Incid_{hosp}^{***} - 3,98Incid_{rea}^{***} - 0,27Incid_{rad}^{***} \\
& - 1,25Incid_{dhosp}^{***} + 3,5e^{-4}Dose1^* + 1,14e^{-3}Dose2^{***}
\end{aligned}$$

III - Prévision

Suite aux processus de sélection des variables, nous pouvons dès lors passer à la prévision du mois de décembre de l'incidence du covid-19 en 2022. Pour cela, nous utiliserons plusieurs méthodes de prévision qu'elles soient aussi bien multivariées que univariées. Par la suite, nous étudierons la qualité de ces prévisions dans le but de choisir le meilleur modèle nous permettant d'appliquer une méthode de prévision pas à pas.

A) Méthode de prévision

Nous pouvons dès lors passer à la prévision de nos données. Dans un premier temps, nous utiliserons des méthodes multivariées et dans un second temps des méthodes univariées.

1) Méthode de prévision ARX et ARMAX (méthode multivariées)

La structure de nos données ne nous permet pas de réaliser un modèle ARX. En effet, nous avons vu lors de la sélection des variables par la méthode GETS que cette n'aboutissait pas. Or, dans le cadre de cette méthode, la sélection s'effectue par un modèle ARX. Nous laissons donc cette méthode de côté et nous intéresserons plutôt à ARMAX.

Nous rencontrons également un problème pour notre modèle ARMAX avec l'utilisation d'une approche automatique pour l'ajuster. Nous avons donc réalisé le modèle ARMAX spécifié manuellement. Initialement, un modèle ARMAX(1,0,0) a été utilisé, incorporant six variables exogènes précédemment sélectionnées. L'évaluation de ce modèle s'est faite via les statistiques t des coefficients, permettant de juger de leur significativité. Les variables dont les valeurs absolues de la statistique t étaient inférieures à 1,64 ont été progressivement éliminées pour affiner le modèle. Finalement, notre modèle retient deux variables exogènes : l'incidence des hospitalisations (incid_hosp) et le nombre de patients qui sont retournés à leur domicile au cours des dernières 24 heures après une hospitalisation (incid_rad). Le coefficient pour incid_hosp est de 0.0231, indiquant un impact positif sur le taux d'incidence du virus. Cela signifie que les augmentations dans le nombre d'hospitalisations sont

directement corrélées à des augmentations dans le taux d'incidence. D'autre part, incid_rad présente un coefficient de -0.0186, suggérant une relation inverse avec le taux d'incidence. Ce modèle est également caractérisé par une forte composante autorégressive (coefficient de 0.9981), reflétant une grande persistance des valeurs jour après jour.

2) Méthode de prévision univariées


Suite à l'application de méthodes de prévision multivariées, nous pouvons passer dès à présent à l'application de méthodes de prévision univariées, comme par exemple les méthodes de lissage exponentiel.

a) Méthode de lissage exponentiel : ETS et BATS

Dans un premier temps, nous utilisons les méthodes de lissage exponentiel telles que ETS (Erreur, Tendance et Saisonnalité) et TBATS (Trigonométrie seasonality, Box-Cox transformation, ARIMA errors, Trends component et Seasonal component) afin de prédire pour le mois de décembre 2022. Nous examinerons les résultats de chacune afin de pouvoir par la suite les comparer.

Nous appliquons dans un premier temps la méthode de lissage exponentiel TBATS. En étudiant les résultats de cette méthode (Voir annexe 11), nous pouvons constater que le modèle a subi une transformation Box-Cox ($\frac{Y_t^\lambda - 1}{\lambda}$), démontrée notamment par son lambda proche de 0 mais différent de celui-ci. De plus, nous pouvons remarquer qu'il n'y a aucune composante autorégressive ou de moyenne mobile dans notre modèle, démontrée en fait par {0,0}. De plus, nous pouvons remarquer qu'il n'y a pas de composante de bruit supplémentaire."


Graphique 9 : Décomposition par la méthode TBATS



sources : Auteurs, Rstudio

Nous utilisons dès à présent la méthode de lissage par la méthode ETS. En examinant les résultats obtenue (Voir annexe 12), nous pouvons observer que nous obtenons un modèle Holt-Winters avec une modélisation de la tendance de manière multiplicative(M), celle de la saisonnalité de manière additives (Ad) et enfin qu'il n'y à la présence de composante de bruit supplémentaire (N). Par la suite, nous pouvons analyser les coefficient de lissage. Dans un premier temps, nous pouvons remarquer que la composante de niveau est de 0.8076, signifiant tendance forte et croissante dans les données. Dans un second temps, le coefficient de tendance valant 0.2932, nous indiquant alors une souplesse dans les prévisions. Enfin, Le coefficient de lissage pour la composante de bruit étant de 0.9283, nous décrit une grande variabilité résiduelle dans les données. En résumé, les coefficients de lissage pour la tendance et la saisonnalité sont relativement élevés, ce qui signifie que les prévisions sont influencées de manière significative par les observations récentes et les tendances récentes. Cependant, le coefficient de bruit plus élevé suggère que malgré la prise en compte de la tendance et de la saisonnalité, une certaine variabilité résiduelle subsiste dans les données.

Graphique 10 : Décomposition par la méthode ETS



sources : Auteurs, Rstudio

b) Méthode ADAM avec spécification ARIMA

Nous pouvons dès lors passer à l'étude des résultats des méthodes avec spécification ARIMA. En examinant les résultats de ces méthodes, nous remarquons que nous obtenons les mêmes résultats pour nos deux prévisions, malgré une spécification ARIMA différente (Voir annexe 13). En analysant les résultats, nous constatons qu'ils utilisent la méthode ETS expliquée précédemment avec une modélisation de la tendance et de la saisonnalité de manière multiplicative, ainsi que l'absence de composante de bruit supplémentaire. Ainsi, nous pouvons analyser les coefficients de lissage. La composante de niveau étant de 0,9998, nous démontre une tendance forte et croissante des données. Par la suite, le coefficient de tendance valant 0,7149, nous indique alors une rigidité dans les prévisions.

c) Méthodes CES

Nous passons dès lors à l'analyse de la méthode de lissage exponentiel complexe. En étudiant les résultats (Voir annexe 14), nous pouvons constater l'absence de saisonnalité démontrée notamment par le paramètre (n). De plus, ces résultats nous permettent de mettre en évidence les coefficients des paramètres représentant les relations entre les variables d'entrée (intrant) et les variables de sortie (production). Nous obtenons dès lors un modèle de type :

$$a_0 + a_1 i \Rightarrow 2,0011 + 1,0005i$$

d) Méthode SARIMA & SSARIMA

Nous pouvons dès lors terminer notre analyse avec les méthodes SARIMA et SSARIMA.


Dans un premier temps, la méthode SARIMA nous a permis de mettre en évidence le modèle le plus optimal. Ce modèle, étant $ARIMA(5,1,0)(0,0,0)$ (Voir annexe 15), possède donc une différenciation intégrée d'ordre 1, 5 composantes autorégressives, décrivant ainsi l'inclusion des 5 dernières valeurs pour prédire les valeurs actuelles, et enfin, il n'y a aucune composante de moyenne mobile. De plus, nous pouvons observer que les conditions d'inversibilité et de stationnarité (voir annexe 16) sont respectées, nous permettant dès lors d'analyser les coefficients. Ainsi, une augmentation d'une unité de la valeur précédente entraîne une augmentation de 0,2861 unité de la valeur actuelle, tandis qu'une augmentation d'une unité de la valeur deux périodes auparavant entraîne une diminution de 0,1865 unité de la valeur actuelle. Cette même logique sera appliquée pour expliquer les autres coefficients autorégressifs.

Enfin, la méthode SSARIMA nous présente un autre modèle optimal. Ce modèle, $ARIMA(0,2,3)$ (Voir annexe 17), implique une différenciation d'ordre 2, trois composantes de moyenne mobile et aucune composante autorégressive. De plus, ce modèle satisfait pleinement aux conditions d'inversibilité et de stationnarité, tout comme le précédent, ce qui nous permet d'analyser ses coefficients. Ainsi, le coefficient associé à $MA(1)$ est de -0,92, ce qui indique une corrélation négative entre les valeurs actuelles de la série temporelle et les erreurs de prédiction de la période précédente. En d'autres termes, lorsque l'erreur de prédiction de la période précédente est élevée (positive), la valeur actuelle de la série a tendance à être plus faible, et vice versa. La même logique s'applique à $MA(2)$ où le coefficient est négatif, tandis qu'une logique inverse est appliquée à $MA(3)$ où le coefficient est positif. Cela signifie que lorsque les erreurs de prédiction des trois périodes précédentes sont élevées (positives), la valeur actuelle de la série a tendance à être plus élevée, et vice versa.

B) Evolution de prévision des différents modèles

Suite à l'application de toutes ces méthodes nous permettant de mettre en évidence des modèles optimaux pour la prévision, nous pouvons comparer graphiquement les résultats obtenus de chaque modèle.

Graphique 11 : Evolution de prévision de tous nos modèles et des valeurs réelles



sources : Auteurs, Rstudio

En étudiant le graphique 11, nous pouvons remarquer que la prévision de la méthode ARMAX semble être la plus proche des valeurs observées. Cependant, pour des exigences scientifiques rigoureuses, nous ne pouvons pas nous baser uniquement sur une analyse graphique. Ainsi, nous appliquons des tests et des indicateurs de qualité de prévision spécifiques à chaque méthode afin de pouvoir déterminer la meilleure.

C) Qualité et test de précision des prévisions

1) Qualité des prévisions

Le Tableau 8 sert à évaluer la performance de différents modèles prédictifs en utilisant quatre métriques clés. Le MSE mesure la précision des prévisions en calculant la moyenne des carrés des erreurs, où un score plus bas indique une plus grande précision. Le CSSDE est similaire mais somme ces erreurs de façon cumulative. Le R^2 OOS, avec des valeurs souvent négatives ici, compare la capacité de prédiction des modèles par rapport à un modèle simple de référence, avec des valeurs plus proches de zéro indiquant une meilleure performance. Enfin, l'AIC équilibre la complexité du modèle avec la qualité de l'ajustement, où un chiffre inférieur est préférable. En combinant ces indicateurs, on peut discerner non seulement la précision des prévisions mais aussi la robustesse et l'efficacité de chaque modèle. Par exemple, bien que le modèle "ETS" présente un MSE relativement élevé, il ne peut pas être directement qualifié de sous-performant sans considérer les autres métriques. Pour une évaluation complète, il est essentiel de considérer toutes les métriques en tandem, tout en prenant en compte les spécificités de la série temporelle analysée et l'objectif de la modélisation.

Tableau 8 : Comparaison des indicateur de qualité des prévisions


	MSE	CSSDE	R^2_{OOS}	AIC
ETS	79843,48	2475148	-4,2406	8200,570
TBATS	195838,50	6070933	-11,8540	8162,509
ADAM & ARIMA 1	529517,70	164150449	-33,7553	4971,923
ADAM & ARIMA 2	540639,10	16759812	-34,4953	4971,923
CES	17360,57	538177	-0,1395	7193,332
SARIMA	110434,00	3423454	-6,2484	6653,45
SSARIMA	331396,70	10273297	-20,7515	6676,471
ARMAX	13047,32	404467	0,1436	7189,69

sources : Auteurs, Rstudio, Annexe 18

L'analyse comparative des modèles dans le Tableau 8 suggère que le modèle ARMAX est potentiellement le meilleur parmi ceux présentés, basé sur l'ensemble des critères évalués. Avec le MSE le plus faible à 13047,32, il indique le niveau d'erreur le

moins élevé dans les prévisions produites, ce qui est un aspect fondamental de l'évaluation d'un modèle prédictif. Sa valeur R^2 OOS positive de 0,1436 est particulièrement notable car elle contraste avec les valeurs négatives des autres modèles, impliquant que contrairement aux autres modèles, ARMAX a une meilleure capacité de prédiction que le modèle de référence utilisé pour le calcul de cet indicateur. Son AIC relativement bas de 7189,69 soutient également son efficacité, montrant qu'il a un bon équilibre entre la simplicité du modèle et l'ajustement aux données observées. Les modèles ADAM & ARIMA 1 et 2, bien qu'ils présentent les valeurs les plus basses de l'AIC, qui signale une qualité de modèle supérieure en termes de pénalité pour la complexité, souffrent d'un R^2 OOS très négatif, ce qui soulève des préoccupations sur leur performance hors échantillon. Cela pourrait indiquer que, bien qu'ils soient bien ajustés aux données avec lesquelles ils ont été construits, leur capacité à généraliser pourrait être mise en question.

Graphique 12 : Comparaison de l'évolution de l'indicateur MSE de chaque modèle



sources : Auteurs, Rstudio

Le Graphique 12 met en évidence l'évolution du Mean Squared Error (MSE) de divers modèles de prévision sur une période de 30 jours, offrant un aperçu de leur précision dans le temps. À l'initiation du suivi, tous les modèles commencent avec des valeurs de MSE basses, signalant une précision initiale similaire. Cependant, au fil des jours, des différences significatives émergent. Les modèles TBATS et ETS démontrent une croissance rapide de l'erreur, indiquant une perte de précision notable avec le temps, ce

qui pourrait refléter une adaptation insuffisante aux variations des données. Les variantes de modèles ARIMA et le modèle ADAM_CES, cependant, montrent une augmentation plus maîtrisée du MSE, suggérant une robustesse et une fiabilité supérieures sur l'horizon temporel considéré. Le modèle ARMAX se distingue particulièrement par son erreur quadratique faible et constante, ce qui le positionne comme le plus précis sur la période étudiée. Le SSARIMA affiche une performance intermédiaire, avec une croissance modérée de l'erreur (voir Annexe 19 pour le calcul du MSE).

2) Test de précision des prévisions R

Suite à l'analyse approfondie de divers indicateurs visant à identifier un modèle de prédiction particulièrement qualitatif, nous avons opté pour l'application du test de Diebold-Mariano. Ce test nous permettra de confirmer ou de réfuter le choix du meilleur modèle de prévision. Le test de Diebold-Mariano est utilisé pour évaluer si les performances prédictives d'un modèle sont significativement différentes de celles d'autres modèles ou de méthodes de prévision de base. L'hypothèse nulle de ce test stipule qu'il n'y a pas de différence significative entre les performances des deux modèles comparés. Nous procédons d'abord à la comparaison de nos différents modèles avec une prévision naïve, puis avec la prévision de base AR(1).

Tableau 9 : Comparaison des résultats du test de Diebold-Mariano

	ETS	TBATS	ADAM1	ADAM2	CES	SARIMA	SSARIMA	ARMAX
Prédiction naïve	8.535e-05	3.539e-05	0.00023	0.00029	0.01199	4.85e-05	4.888e-05	0.0205
Prédiction AR(1)	9.054e-05	3.633e-05	0.00023	0.00029	0.012	5.078e-05	4.957e-05	0.02199

sources : Auteurs, Rstudio

En examinant les résultats du test de Diebold-Mariano présentés dans le tableau 9, il apparaît que tous les modèles se distinguent de manière significative aussi bien de la prévision naïve que de celle intégrant une composante AR(1) au seuil de risque de 5%. Par conséquent, nous pouvons conclure que les performances prédictives des modèles sont significativement soit supérieures soit inférieures à celles de la prévision

naïve ou de la prévision AR(1) avec un risque de 5%. Ainsi, ce test de précision ne nous apporte aucune information supplémentaire pour confirmer le choix du meilleur modèle.

D) Prévision pas à pas

Afin de réaliser une prévision pas-à-pas, nous utiliserons notre modèle univarié le plus fiable. Cette prévision consiste à utiliser un modèle pour prédire la prochaine valeur de notre série temporelle, puis à réintégrer cette valeur prédite dans ce dernier pour la prédiction suivante, actualisant ainsi le modèle étape par étape. Ainsi, nous appliquerons cette méthode à notre modèle CES. Les résultats de la prévision découlant de cette démarche sont présentés par l'Annexe 20 et semblent illogiques. En effet, dès la deuxième période, la valeur de la prévision chute et gravite autour de 0 jusqu'à la fin de la période. La méthode de prévision pas-à-pas peut rencontrer des problèmes dans certains cas. Effectivement, chaque ajout de nouvelles données peut changer significativement les prévisions futures, parfois de manière instable si les nouvelles observations sont très différentes des données historiques. De plus, cette méthode peut accumuler des erreurs de prévision, car chaque nouvelle prévision s'appuie sur les précédentes, et toute erreur initiale peut donc se propager et s'amplifier. C'est pourquoi, nous laisserons cette méthode de côté, et conserverons les résultats établis précédemment.

IV - Conclusion

Pour conclure, ce dossier sur l'étude prévisionnelle de l'incidence quotidienne du Covid-19 en France entre janvier 2021 et décembre 2022 met en lumière l'efficacité des méthodes de modélisation avancées telles que ARMAX et SARIMA. Grâce à une sélection rigoureuse des variables et à des ajustements minutieux, ces modèles ont prédit avec précision les fluctuations de l'incidence, jouant un rôle crucial dans la planification des interventions de santé publique. L'analyse a non seulement confirmé la stationnarité des séries temporelles, mais a également permis d'identifier des relations significatives entre les taux d'hospitalisation, les admissions en réanimation, et les données de vaccination, enrichissant ainsi notre compréhension de la dynamique de la pandémie. Cependant, l'étude a également mis en lumière des défis persistants, tels que la nécessité d'adapter les modèles aux nouvelles données sur les variants du virus et de maintenir une flexibilité dans les méthodes prédictives face à un virus en mutation. En conclusion, ce travail de recherche a non seulement approfondi notre compréhension des enjeux sanitaires liés à la pandémie de Covid-19 en France, mais a également établi une base solide pour des études futures, visant à optimiser les réponses aux crises sanitaires émergentes et illustrant une approche exhaustive de la recherche en santé publique en temps de crise.

V - Discussion

La discussion de notre étude souligne plusieurs aspects cruciaux de la modélisation prévisionnelle de l'incidence du COVID-19 en France. Premièrement, l'adoption de diverses méthodes statistiques a permis une compréhension approfondie des tendances de l'épidémie, mais elle a également révélé des limites, notamment la sensibilité des modèles aux choix des variables et la qualité des données initiales. L'efficacité des modèles ARX/ARMAX suggère une bonne adaptation aux données épidémiologiques, toutefois, l'introduction de données supplémentaires comme les facteurs socio-économiques ou les informations sur le comportement des populations aurait pu enrichir significativement nos prévisions. De plus, l'analyse a montré que les prévisions sont fortement influencées par les nouveaux variants du virus, nécessitant une adaptation continue des modèles. Pour les recherches futures, il serait bénéfique d'intégrer des modèles dynamiques qui peuvent incorporer des changements rapides dans les données, tels que ceux induits par les nouvelles politiques de santé publique ou l'apparition de nouveaux variants, afin de renforcer la précision des prévisions et la réponse stratégique aux pandémies. En outre, notre méthode de prévision pas à pas n'a finalement pas été retenue en raison de sa tendance à accumuler des erreurs au fur et à mesure des prédictions, ce qui compromettrait la fiabilité à long terme des résultats. Enfin, une limite dans nos prévisions pourrait résulter du fait que notre série ne suit pas une distribution normale, ce qui suggère que d'autres approches statistiques pourraient être plus appropriées.

VI - Bibliographie

- Centers for Disease Control and Prevention. "COVID Data Tracker." *Centers for Disease Control and Prevention*, 2022, <https://covid.cdc.gov/covid-data-tracker>.
- Commission européenne. "Une Union de la santé européenne: renforcer la résilience des systèmes de santé." *Commission européenne*, 2021, https://ec.europa.eu/health/future_eu_fr.
- Gelly, Maud, and Alexis Spire. "Soigner sans compter. Les agents de l'hôpital public face à l'épidémie de Covid-19." *Revue française des affaires sociales* 4 (2021): 15-34.
- Gretchen Berlin, Shubham Singhal, Meredith Lapointe, and John Schulz, "Challenges emerge for the US healthcare system as COVID-19 cases rise", November 25, 2020 | Article, <https://www.mckinsey.com/industries/healthcare/our-insights/challenges-emerge-for-the-us-healthcare-system-as-covid-19-cases-rise>
- Jagadeesan M, Parasuraman Ganeshkumar, Prabhdeep Kaur... "Epidemiology of COVID-19 and effect of public health interventions, Chennai, India, March-October 2020: an analysis of COVID-19 surveillance system, BMJ Open".
- Kim Bouillon,1 Bérangère Baricault,1 Jérémie Botton,1 Marie-Joëlle Jabagi,1 Marion Bertrand,1 Laura Semenzato, 1 Stéphane Le Vu, 1 Jérôme Drouin,1 Rosemary Dray-Spira,1 Alain Weill,1 Mahmoud Zureik1,"Estimation de l'impact de la vaccination chez les personnes âgées de 75 ans et plus sur le risque de formes graves de Covid-19 en France à partir des données du Système National des Données de Santé (SNDS) – actualisation jusqu'au 20 juillet 2021",epi-phare,https://www.epi-phare.fr/app/uploads/2021/10/epi-phare_rapport_vaccination_reduction-des-risques_75ans-et-plus.pdf
- Organisation Mondiale de la Santé. (2022). Rapports de situation sur le COVID-19. <https://www.who.int/emergencies/diseases/novel-coronavirus-2019/situation-reports/>

VII - Annexe

Annexe 1 : Résultat du test ADF sur notre série Y

Augmented Dickey-Fuller Test

```
data: y
Dickey-Fuller = -4.3418, Lag order = 8, p-value = 0.01
alternative hypothesis: stationary
```

sources : Auteurs, Rstudio

Annexe 2 : Sortie Rstudio des statistique descriptives de notre série Y

Table: Résumé statistique de la variable y

Statistique	Valeur
Minimum	17.2185148514851
1er quartile	158.643292079208
Médiane	248.734603960396
Moyenne	490.862531262715
3ème quartile	560.152376237624
Maximum	3565.65851485149
Écart-type	642.376192204736
Variance	412647.172311456

sources : Auteurs, Rstudio


Annexe 3 : Sortie Rstudio des indicateurs et test de notre série Y

Table: Résultats des statistiques de kurtosis, skewness et test de normalité Shapiro-Wilk pour la variable y

Statistique	Valeur
Kurtosis	11.5659521
Skewness	2.8239291
Shapiro-Wilk stat value	0.6422646
Shapiro-Wilk p-value	0.0000000

sources : Auteurs, Rstudio

Annexe 4 : Matrice de corrélation



sources : Auteurs, Rstudio

Annexe 5 : Résultats des tests ADF sur nos séries brutes indépendantes

	P_Value	Val_stat
incid_hosp	0.6640229	-1.797504
incid_rea	0.7538093	-1.585388
incid_rad	0.7558670	-1.580527
incid_dchosp	0.8279852	-1.410151
dose1	0.2032986	-2.885942
dose2	0.5109610	-2.159105
dose3	0.5218757	-2.133320

sources : Auteurs, Rstudio

Annexe 6 : Résultats des tests ADF pour nos séries indépendantes différenciées.

Nom	Statistique du test	$P_{critique}$
Incid_hosp	-7,750113	0,01
Incid_rea	-9,028271	0,01
Incid_rad	-10,140542	0,01
Incid_dchosp	-10,192229	0,01
Dose 1	-7,180660	0,01
Dose 2	-7,364996	0,01
Dose 3	-8,138851	0,01

sources : Auteurs, Rstudio, Annexe 7

Annexe 7 : Résultats des tests ADF sur nos séries différenciés indépendantes

```

|          | P_Value | Val_stat |
|:-----|:-----:|:-----:|
|incid_hosp |    0.01 | -7.750113|
|incid_rea  |    0.01 | -9.028271|
|incid_rad  |    0.01 | -10.140542|
|incid_dchosp |    0.01 | -10.192229|
|ldose1     |    0.01 | -7.180660|
|ldose2     |    0.01 | -7.364996|
|ldose3     |    0.01 | -8.138851|

```

sources : Auteurs, Rstudio

Annexe 8 : Sortie rstudio du meilleur modèles d'après l'approche Best SubSet


```

Call:
lm(formula = ys ~ xbest, weights = weights)

Residuals:
    Min       1Q   Median       3Q      Max
-965.9 -174.6  -26.0   102.9  2746.3

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 28.8129507  27.0968952   1.063 0.288003
xbest1       1.3746252   0.0697897  19.697 < 2e-16 ***
xbest2      -3.9752122   0.3517782 -11.300 < 2e-16 ***
xbest3      -0.2718170   0.0630025  -4.314 1.83e-05 ***
xbest4      -1.2471119   0.3352803  -3.720 0.000216 ***
xbest5       0.0003465   0.0001599   2.167 0.030582 *
xbest6       0.0011374   0.0001310   8.679 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 389.2 on 692 degrees of freedom
Multiple R-squared:  0.6509,    Adjusted R-squared:  0.6479
F-statistic: 215.1 on 6 and 692 DF,  p-value: < 2.2e-16

```

sources : Auteurs, Rstudio

Annexe 9 : Calcule de l'AIC du modèle obtenue avec Best SubSet

$$AIC = 692 \times \log\left(\frac{389.2^2}{692}\right) + 2 \times 7$$

$$\Leftrightarrow AIC \simeq 3728,988$$

sources : Auteurs

Annexe 10 : Sortie Rstudio de la sélection des variables selon la méthode GETS

```

SPECIFIC mean equation:

              coef std.error t-stat p-value
ar1          0.2946969  0.0368231  8.0030 4.888e-15 ***
ar2          0.1800523  0.0380094  4.7370 2.615e-06 ***
ar3          0.1588066  0.0381456  4.1632 3.520e-05 ***
ar4          0.1397734  0.0379474  3.6833 0.0002475 ***
ar5          0.0922301  0.0368470  2.5031 0.0125340 *
incid_hosp   0.0188610  0.0046843  4.0265 6.265e-05 ***
incid_rad   -0.0173591  0.0051079 -3.3985 0.0007150 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Diagnostics and fit:

              Chi-sq df  p-value
Ljung-Box AR(6)  5.4933  6    0.4823
Ljung-Box ARCH(1) 58.0385  1 2.576e-14 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

SE of regression  27.59659
R-squared         0.54827
Log-lik.(n=724) -3425.82066

```

```

$method
[1] "aic"

$n
[1] 724

$k
[1] 7

$value
[1] 9.48293

> names
[1] "incid_hosp" "incid_rad"

```

sources : Auteurs, Rstudio

Annexe 11 : Paramètres du obtenue avec la méthode TBATS

```
BATS(0.057, {0,0}, 0.954, -)
```

```
Call: tbats(y = yy)
```

```
Parameters
```

```
Lambda: 0.056909
```

```
Alpha: 0.8543946
```

```
Beta: 0.2479004
```

```
Damping Parameter: 0.953765
```

```
Seed States:
```

```
      [,1]
```

```
[1,] 5.78363427
```

```
[2,] 0.02065694
```

```
attr(,"lambda")
```

```
[1] 0.05690858
```

```
Sigma: 0.06704856
```

```
AIC: 8162.509
```

sources : Auteurs, Rstudio

Annexe 12 : Paramètres du obtenue avec la méthode ETS

```
ETS(M,Ad,N)
```

```
Call:
```

```
ets(y = y)
```

```
Smoothing parameters:
```

```
alpha = 0.8076
```

```
beta  = 0.2932
```

```
phi   = 0.9283
```

```
Initial states:
```

```
l = 131.074
```

```
b = 5.3042
```

```
sigma: 0.0506
```

AIC	AICc	BIC
8200.570	8200.692	8227.868

sources : Auteurs, Rstudio

Annexe 13 : Paramètres du obtenue avec la méthode ADAM1 & ADAM2

ADAM1

Time elapsed: 44.46 seconds
Model estimated using auto.adam() function: ETS(MMnN)
Distribution assumed in the model: S
Loss function type: likelihood; Loss function value: 2479.962
Persistence vector g:
 alpha beta
0.9998 0.7149
Damping parameter: 0.8965
Sample size: 699
Number of estimated parameters: 6
Number of degrees of freedom: 693
Information criteria:
 AIC AICc BIC BICc
4971.923 4972.045 4999.221 4999.619

ADAM2

Time elapsed: 7.62 seconds
Model estimated using auto.adam() function: ETS(MMnN)
Distribution assumed in the model: S
Loss function type: likelihood; Loss function value: 2479.962
Persistence vector g:
 alpha beta
0.9998 0.7149
Damping parameter: 0.8965
Sample size: 699
Number of estimated parameters: 6
Number of degrees of freedom: 693
Information criteria:
 AIC AICc BIC BICc
4971.923 4972.045 4999.221 4999.619

sources : Auteurs, Rstudio

Annexe 14 : Paramètres du obtenue avec la méthode CES

Time elapsed: 0.4 seconds
Model estimated: CES(n)
a0 + ia1: 2.0011+1.0005i
Initial values were produced using backcasting.

Loss function type: likelihood; Loss function value: 3593.6659
Error standard deviation: 41.4449
Sample size: 699
Number of estimated parameters: 3
Number of degrees of freedom: 696
Information criteria:
 AIC AICc BIC BICc
7193.332 7193.366 7206.981 7207.094

sources : Auteurs, Rstudio

Annexe 15 : Paramètres du obtenue avec la méthode SARIMA

Series: y
ARIMA(5,1,0)

Coefficients:

	ar1	ar2	ar3	ar4	ar5
	0.2861	0.1865	0.1638	0.1417	0.0875
s.e.	0.0376	0.0388	0.0389	0.0388	0.0376

sigma^2 = 798.5: log likelihood = -3320.73
AIC=6653.45 AICc=6653.58 BIC=6680.74

sources : Auteurs, Rstudio

Annexe 16 : Condition d'inversibilité et de Stationnaire

- La condition de stationnarité, AR(p) :

$$\left| \sum_{i=1}^p \varphi_i \right| < 1 \text{ avec } p \in \mathbb{N} \text{ avec } \varphi_i \text{ les coefficient ar}(p)$$

- La condition d'inversibilité, MA(q) :

$$\left| \sum_{i=1}^q \theta_i \right| < 1 \text{ avec } q \in \mathbb{N} \text{ avec } \theta_i \text{ les coefficient ma}(q)$$

sources : Auteurs

Annexe 17 : Paramètres du obtenue avec la méthode SSARIMA

Time elapsed: 3.88 seconds
Model estimated: ARIMA(0,2,3)
Matrix of MA terms:

Lag 1
MA(1) -0.6983
MA(2) -0.0078
MA(3) 0.1068

Initial values were produced using backcasting.

Loss function type: likelihood; Loss function value: 3334.2354
Error standard deviation: 28.6152
Sample size: 699
Number of estimated parameters: 4
Number of degrees of freedom: 695
Information criteria:
AIC AICc BIC BICc
6676.471 6676.528 6694.669 6694.858

sources : Auteurs, Rstudio

Annexe 18 : Résultats du calcul des différents indicateurs

Table: CSSDE de chaque méthode

ETS	TBATS	ARIMA	ADAM_ETS_ARIMA_1	ADAM_ETS_ARIMA_2	ADAM_CES	SSARIMA	ARMAX_CSSDE
2475148	6070993	3423454	15989261	16584979	538177.6	10273297	404467
ETS_R200S	TBATS_R200S	ARIMA_R200S	ADAM_ETS_ARIMA_1_R200S	ADAM_ETS_ARIMA_2_R200S	ADAM_CES_R200S	SSARIMA_R200S	ARMAX_R200S
-4.2406	-11.85404	-6.248435	-32.85386	-34.11517	-0.1394766	-20.75152	0.1436271
ETS	TBATS	ARIMA	ADAM_ETS_ARIMA_1	ADAM_ETS_ARIMA_2	ADAM_CES	SSARIMA	ARMAX
79843.48	195838.5	110434	515782.6	534999.3	17360.57	331396.7	13047.32

sources : Auteurs, Rstudio

Annexe 19 : Calcul des indicateurs de qualité :

Calcul des MSE :

$$\frac{1}{n} \times \sum_{t=1}^n (y_t - \hat{y}_t)^2$$

Calcul des CSSDE :

$$\sum_{t=1}^n (y_t - \hat{y}_t)^2$$

Calcul des $R^2 OOS$:

$$1 - \frac{\sum_{t=1}^n (y_t - \hat{y}_t)^2}{\sum_{t=1}^n (y_t - \bar{y})^2}$$


avec :

- n : nombre de période / observation de la série temporelle.
- y_t : la valeur observée.
- $\hat{y}_t$: la valeur prédite.
- $\bar{y}$: la moyenne des valeurs observées.
- $y_t - \hat{y}_t$: le carré d'erreur pour la période t

sources : Auteurs

Annexe 20 : Résultat de la prévision pas-à-pas pour le modèle CES

[,1]
[1,] 540.77084004
[2,] 1.12318975
[3,] -2.20022370
[4,] 2.19018746
[5,] -2.17807153
[6,] 2.16609511
[7,] -2.12950836
[8,] 3.24426341
[9,] -1.19012276
[10,] 3.24054574
[11,] -1.29135386
[12,] 1.37217807
[13,] -2.69778821
[14,] 3.18947767
[15,] -2.54804155
[16,] 2.94018508
[17,] -3.04420698
[18,] 3.14904099
[19,] -3.14735209
[20,] 3.07232987
[21,] -0.09053669
[22,] 3.11263604
[23,] -1.13041473
[24,] 2.96676298
[25,] -1.96076172
[26,] 2.76330752
[27,] -2.35900052
[28,] 1.37646069
[29,] -1.57168070
[30,] 3.03136356
[31,] -0.48071660



VIII - Table des matières

I - Introduction.....	1
II - Analyse exploratrice.....	3
A) Revue de littérature.....	3
B) Vérification de la stationnarisation.....	5
C) Statistique descriptives.....	6
II - Sélection des variables.....	9
A) Présentation des variables explicative.....	9
B) Corrélation.....	16
C) Vérification de la stationnarité de nos séries indépendantes.....	17
D) Sélection des variables indépendantes.....	18
1) Approche Best SubSet.....	18
2) Approche Gets.....	19
E) Choix des variables indépendantes.....	19
III - Prévission.....	21
A) Méthode de prévision.....	21
1) Méthode de prévision ARX et ARMAX (méthode multivariées).....	21
2) Méthode de prévision univariées.....	22
a) Méthode de lissage exponentiel : ETS et BATS.....	22
b) Méthode ADAM avec spécification ARIMA.....	24
c) Méthodes CES.....	24
d) Méthode SARIMA & SSARIMA.....	25
B) Evolution de prévision des différents modèles.....	26
C) Qualité et test de précision des prévisions.....	27
1) Qualité des prévisions.....	27
2) Test de précision des prévisions R.....	29
D) Prévission pas à pas.....	30
IV - Conclusion.....	31
V - Discussion.....	32
VI - Bibliographie.....	33
VII - Annexe.....	34
VIII - Table des matières.....	43