



UNIVERSITÉ DE NANTES



IAE NANTES
ÉCONOMIE & MANAGEMENT

Dossier d'Économétrie financière avancée

MASTER 2 ECAP

**Étude comparative des méthodes de prévision de la
volatilité du NASDAQ 100 pour l'année 2023**

DUPAS-BROUSSE SIMON

MOCAËR RODOLPHE

Sous la direction de Darne Olivier

Année universitaire 2024-2025

Étude comparative des méthodes de prévision de la volatilité du NASDAQ 100 pour l'année 2023

Résumé

La prévision du NASDAQ 100, et plus précisément de sa rentabilité, est un enjeu majeur pour l'anticipation de la santé économique mondiale. Cependant, en raison des caractéristiques statistiques complexes de cette série, l'utilisation de modèles avancés tels que les ARCH/GARCH est nécessaire. Cette étude repose sur la comparaison et la prévision de l'indice NASDAQ 100 pour l'année 2023. Nos résultats montrent que le modèle IGARCH est le plus adapté et offre la meilleure précision des prévisions, permettant ainsi de mieux comprendre les fluctuations futures.

Mots clés : Rentabilité, NASDAQ 100, Modèles ARCH/GARCH, Prévision, Économétrie financière

Comparative study of NASDAQ 100 volatility forecasting methods for 2023

Abstract

The forecasting of the NASDAQ 100, particularly its returns, is a key challenge in anticipating global economic health. However, due to the complex statistical characteristics of this time series, advanced models such as ARCH/GARCH are required. This study focuses on comparing and forecasting the NASDAQ 100 index for the year 2023. Our results show that the IGARCH model is the most suitable and provides the highest prediction accuracy, allowing for a better understanding of future fluctuations.

Keywords: Returns, NASDAQ 100, ARCH/GARCH Models, Forecasting, Financial Econometrics

Sommaire

Résumé.....	I
Abstract.....	II
Sommaire.....	III
I - Introduction.....	1
II - Analyse exploratoire.....	2
III - Estimation des modèles de volatilités de 2018 à 2022.....	11
IV - Prévion de la volatilité du NASDAQ 100 pour l'année 2023.....	15
V - Conclusion.....	18
VI - Bibliographie.....	19
VII - Annexes.....	20
VIII - Table des matières.....	21

I - Introduction

Dans un monde financier marqué par une incertitude croissante, la volatilité des marchés boursiers constitue un enjeu majeur pour les investisseurs, les analystes et les régulateurs. Parmi les indices les plus scrutés, le NASDAQ 100 se distingue par sa forte sensibilité aux fluctuations macroéconomiques et aux cycles d'innovation technologique. L'anticipation de sa volatilité représente ainsi un défi central pour l'élaboration de stratégies d'investissement et de gestion des risques.

L'évolution récente des marchés financiers illustre à quel point la volatilité peut être influencée par des événements exogènes, tels que la pandémie de COVID-19, les tensions géopolitiques ou encore les politiques monétaires des banques centrales. Selon Bhowmik et Wang (2020)¹, la volatilité des marchés boursiers est non seulement un indicateur clé du risque financier, mais elle joue également un rôle crucial dans la prise de décision des investisseurs et l'allocation des actifs. Leur revue systématique met en évidence la diversité des approches utilisées pour modéliser et prévoir la volatilité, soulignant ainsi l'importance d'une évaluation comparative des modèles pour améliorer la précision des prévisions.

L'objectif de cette recherche est d'analyser et de comparer différentes approches économétriques et statistiques de prévision de la volatilité, en mettant en lumière leurs forces et leurs limites. Nous examinerons notamment les modèles ARCH et GARCH, largement utilisés pour capturer l'hétéroscédasticité des rendements financiers, ainsi que des méthodes plus récentes intégrant des distributions alternatives et des techniques d'apprentissage automatique. Cette étude vise ainsi à identifier le modèle le plus robuste pour anticiper la volatilité du NASDAQ 100 en 2023, en tenant compte des critères de performance et de stabilité des prévisions.

¹ Bhowmik, R., & Wang, S. (2020). Stock market volatility and return analysis: A systematic literature review. *Entropy*, 22(5), 522.

II - Analyse exploratoire

Au préalable de l'analyse exploratoire de notre actif financier, il est important de le décrire en premier lieu. Notre étude repose sur l'actif du NASDAQ 100, qui regroupe les 100 plus grandes entreprises non financières des États-Unis, comprenant notamment APPLE, EBAY, NETFLIX, etc. De ce fait, cet indice est primordial dans le suivi des secteurs technologiques et de croissance des États-Unis. En effet, son intérêt se reflète dans sa forte volatilité et son rôle clé en tant qu'indicateur de la performance du secteur technologique américain. Cette volatilité, influencée par divers facteurs macroéconomiques et événements de marché, nécessite une étude approfondie pour mieux comprendre ses dynamiques. Notre étude de cas portera sur l'analyse de la rentabilité du NASDAQ 100 du 1er janvier 2018 au 31 décembre 2022. Ces données quotidiennes seront recueillies sur Yahoo Finance. Afin d'obtenir une analyse exploratoire rigoureuse, il est crucial d'examiner l'ensemble des caractéristiques de notre actif financier. Ainsi, nous analyserons les outliers, la distribution des rendements bruts et corrigés, ainsi que les corrélogrammes des rendements et des rendements au carré, les statistiques descriptives et de distribution. Cet ensemble d'analyses nous permettra par la suite d'affiner l'estimation de la volatilité et d'identifier les principaux moteurs des fluctuations de l'indice.

A) Descriptif de l'actif

Le NASDAQ 100, ou National Association of Securities Dealers Automated Quotations 100, est aujourd'hui l'un des indices boursiers les plus suivis à l'échelle mondiale. Cet indice est devenu le baromètre de l'innovation technologique et, par extension, de la santé économique mondiale, cet indice dynamique suit la performance des 100 plus grandes entreprises non financières cotées sur le NASDAQ. Il est pionnier dans l'informatisation des marchés financiers dès sa création en 1971, le NASDAQ a révolutionné le monde de la finance en offrant une plateforme d'échange électronique pour les actions. Cette transformation du marché boursier a permis le développement d'un ensemble d'avantages tel que la rapidité, l'efficacité et la transparence des transactions boursières. L'ensemble des entreprises composant cet indice reflète ainsi au mieux la vitalité du secteur technologique et les tendances de l'économie mondiale dans son ensemble. C'est donc devenue l'un des indices de référence mondial. Ainsi, le NASDAQ représente au mieux le monde technologique révélant alors l'évolution rapide de ce secteur les tendances émergentes

et les nouvelles entreprises. Ce marché liquide et accessible est soumis à la forte volatilité. Ainsi l'étude du NASDAQ 100 présente de nombreux intérêts. En effet sa prévision permettrait aussi bien de comprendre les tendances technologiques, qu'analyser l'économie américaine future.

Graphique 1 : Cours du titre NASDAQ 100 de la série brute




sources : Auteurs, Rstudio

En étudiant le graphique 1, nous pouvons rendre compte de l'évolution de l'indice du NASDAQ 100. En effet, nous pouvons remarquer trois périodes spécifiques, chacune possédant une tendance sous-jacente. La première, s'étalant de janvier 2018 à mars 2020, représente une tendance haussière légère de l'indice du NASDAQ, brutalement rupturé par la pandémie de COVID-19. Une fois la pandémie passée, nous observons une tendance haussière de l'indice beaucoup plus forte que précédemment, jusqu'au point de bascule en janvier 2023, où cette même tendance s'inverse pour devenir baissière. Ce point de rupture peut être identifié comme étant lié aux inquiétudes persistantes des acteurs économiques concernant l'inflation, la hausse des taux d'intérêt et la possibilité d'une récession mondiale. De ce fait, cette analyse graphique nous démontre bien qu'il s'agit d'un marché liquide et avec une forte volatilité, pouvant être affecté par un ensemble de facteurs aussi bien économiques que sociaux.

B) Détection des outliers

Une fois la présentation de l'actif faite, nous passons désormais à la seconde étape de notre analyse exploratoire : la détection et la correction des outliers. Pour ce faire, nous utilisons la méthode Boudt, qui nous permet ensuite de mieux visualiser les différents groupes de clusters

Graphique 2 : Rendements brutes et corrigées de l'actif NASDAQ 100



sources : Auteurs, Rstudio

En étudiant le graphique 2, nous observons plusieurs clusters de volatilité. En effet, nous identifions des regroupements de valeurs aberrantes, visualisées en vert. Plus précisément, trois grands clusters se distinguent en 2018, 2020 et 2022, avec celui de 2020 étant le plus important. Ces ensembles de clusters de volatilité sont influencés par divers événements économiques, tels que des guerres ou des pandémies, qui ont impacté le NASDAQ 100. Il apparaît donc essentiel de les analyser et de les corriger.

Tableau 1 : Descriptif des outliers

Outliers		
Date / période	Nombre	Rentabilité la plus importante
Décembre 2018	2	0.06678547
Février 2020	1	-0.05282337
Mars 2020	6	-0.10842308

Avril 2020	1	0.06739557
Septembre 2022	1	-0.05527540
Novembre 2022	1	0.07400226


source : Auteurs, Rstudio, Annexe 1

En étudiant le tableau 1, nous pouvons identifier les différents clusters de volatilité par mois et par année. Ces fluctuations s'expliquent par divers facteurs économiques impactant le NASDAQ 100. Ainsi, en 2018, ces variations peuvent être attribuées à la chute des marchés liée aux craintes d'un ralentissement économique. En effet, les tensions commerciales entre les États-Unis et la Chine, ainsi que les hausses de taux de la Fed, ont entraîné une forte baisse des marchés. En 2020, la rentabilité a été fortement influencée par la pandémie de COVID-19, provoquant une chute brutale du NASDAQ. Toutefois, en avril, les marchés ont rebondi grâce aux mesures de relance mises en place par les banques centrales et les gouvernements. Enfin, en 2022, ces variations s'expliquent par la baisse des marchés en septembre, due aux craintes de récession et à la politique monétaire restrictive de la Fed. En novembre, un espoir de ralentissement des hausses de taux a favorisé un rebond des marchés.

C) Graphique des rentabilités

Une fois la visualisation des différents outils et leur correction, nous pouvons dès lors analyser et visualiser la série corrigée et nettoyée des outils que nous utiliserons pour la suite de notre étude et notamment la rentabilité au carré des futurs NASDAQ 100 agissant comme un proxy pour cette mesure.

Graphique 3 : Rentabilités au carré des futures Nasdaq 100




sources : Auteurs, Rstudio

Le graphique 3, nous permet d'observer des de volatilité entre 2018 et 2022. Un pic majeur est observable début 2020, en lien avec la crise du COVID-19, traduisant une explosion de l'instabilité des marchés. Avant cette période, la volatilité reste modérée, tandis qu'une recrudescence est visible en 2022, probablement due aux incertitudes macroéconomiques comme l'inflation et les tensions géopolitiques. Ce proxy de volatilité permet ainsi d'identifier les périodes de stress financier et constitue un outil clé pour affiner notre analyse des dynamiques des rendements du NASDAQ 100.

D) Corrélogrammes

Nous pouvons dès lors analyser l'autocorrélation des rentabilités et des rentabilités au carré de notre série de notre série nettoyés à l'aide de corrélogrammes et notamment des FAC (fonction d'auto-corrélation) et FACP (fonction d'auto-corrélation partielle).

Figure 1 : FAC et FACP des rendabilités et des rendabilités au carré du NASDAQ 100



sources : Auteurs, Rstudio

En étudiant la Figure 1, nous pouvons mettre en évidence l'autocorrélation aussi bien des rendements que des rendements au carré du NASDAQ 100. Nous analyserons dans un premier temps le rendement simple. Ainsi, la FAC des rendements indique un pic important et significatif au lag 1, suggérant que les rendements ne présentent pas de dépendance temporelle forte et donc une faible autocorrélation à long terme. En ce qui concerne la FACP, elle présente un pic important et significatif au lag 1, ainsi que des pics significatifs supplémentaires à certains lags (comme autour de 5, 10 et 15). Cependant, ces derniers restent d'amplitude relativement faible, indiquant une faible persistance de la dépendance temporelle, mais avec une structure non clairement identifiable. En ce qui concerne les rendements au carré, nous observons plusieurs lags significatifs et une décroissance lente des coefficients dans la FAC, montrant une dépendance à long terme. De plus, quant à la FACP, plusieurs pics significatifs au-delà du premier lag suggèrent que les chocs passés ont un effet durable sur la volatilité.

De ce fait, cette analyse confirme que les rendements eux-mêmes ne sont pas fortement autocorrélés, mais que leur variance présente une dépendance temporelle importante, nous conduisant ainsi à privilégier des modèles ARCH/GARCH.

E) Statistique descriptives du NASDAQ 100

Une fois la présentation de notre actif faite et l'analyse de sa rentabilité et des corrélogrammes, nous pouvons, dès lors, passer à l'étude des différentes statistiques aussi bien descriptives que de distribution. Au préalable, il est important de notifier que l'ensemble des statistiques descriptives est en pourcentage.

Tableau 2 : Statistiques descriptives et de distribution de l'actif NASDAQ 100

Statistiques descriptives							
	Mean	Median	Min	Max	σ	Q1	Q3
NASDAQ 100	0.0555	0.1286	-10.84	9.709	1.652	-0.688	0.923
CAC 40	0.0279	0.0859	-4.4261	4.4688	1.1797	-0.5060	0.6456
Statistiques distributions							
	Skewness				Kurtosis		
NASDAQ 100	-0.3424				7.9282		

sources : Auteurs, Rstudio

En étudiant le tableau 2 et notamment les statistiques descriptives sur notre plage de données s'étalant du 2 janvier 2018 au 30 décembre 2022, la rentabilité moyenne a été de 0,0555 %, avec un pic de performance de 9,709 % aux environs de janvier 2023 (voir Graphique X) et un creux de performance de -10,84 % en janvier 2019 (voir Graphique X). Cependant, outre ces valeurs extrêmes, cet actif, le NASDAQ 100, possède une bonne stabilité, démontrée notamment par un écart-type de 0,01652. Afin de comprendre au mieux les différentes mesures statistiques, nous décidons de le comparer au CAC40. Ainsi, nous remarquons que le NASDAQ 100 présente une moyenne et une médiane proches mais un écart-type beaucoup plus élevé, indiquant une plus grande variabilité des données. En opposition au CAC 40 possédant une moyenne et plus proche une médiane et un écart-type plus faible, suggérant une distribution plus stable.

En ce qui concerne les statistiques de distribution, nous pouvons remarquer une skewness proche de 0 mais négative, indiquant ainsi une symétrie dans la distribution de nos données avec, cependant, une queue de distribution plus épaisse à gauche. De plus, la kurtosis

égale à 7,9282 nous indique une distribution leptokurtique (hypernormale) de nos données. Ainsi, il est fortement probable que notre série ne suive pas une loi normale.

F) Caractéristique de distribution du NASDAQ 100

Il est important de noter que nous appliquons les différents tests, tels que le test de Jarque-Bera permettant de conclure à la distribution normale d'une série, uniquement à notre série de rentabilité du NASDAQ 100 et non à la série au carré.

Tableau 3 : Statistiques descriptives et de distribution de l'actif NASDAQ 100

Résultat des test			
Test	Statistique	P-value	Conclusion
Jarque-Bera	1298.7	$< 2.2 \times 10^{-16}$	Distribution non normal
Ljung-Box	124.49	$< 2.2 \times 10^{-16}$	Auto-corrélation
LM-Arch (5 retards)	315.55	$< 2.2 \times 10^{-16}$	Hétéroscédasticité conditionnelle
LM-Arch (10 retards)	352.14	$< 2.2 \times 10^{-16}$	Hétéroscédasticité conditionnelle

sources : Auteurs, Rstudio

Le tableau 3, nous permet de révéler plusieurs caractéristique importante de notre série, le NASDAQ 100

Dans un premier temps, les résultats du test de Jarque-Bera nous permettent de conclure sur la normalité de la distribution de notre série. Ainsi, nous observons que la p-value associée à ce test est inférieure à 0,01, ce qui suggère que la distribution des rentabilités n'est pas normale, mais qu'elle est soumise à une autre loi. Cette non-normalité peut impacter l'application de certains modèles statistiques qui supposent une distribution normale des données. Dans un second temps, les résultats du test de Ljung-Box, permettant de détecter l'autocorrélation, nous permettent de conclure à la présence d'autocorrélation dans notre série. En effet, la p-value, inférieure à 0,01, le démontre bien. Ainsi, cette corrélation présente dans nos données suggère que les valeurs passées de la rentabilité du

NASDAQ 100 influencent les valeurs présentes, ce qui pourrait introduire des biais dans l'analyse et la modélisation de la série. Pour finir, le test LM-ARCH nous permet de vérifier la présence d'hétéroscédasticité conditionnelle des résidus. Il est important de noter que nous appliquons ce test pour 5 et 10 retards. Nous remarquons qu'une fois encore, la p-value est inférieure à 0,01 pour les deux tests, indiquant ainsi la présence d'hétéroscédasticité conditionnelle des résidus dans la série des rentabilités du NASDAQ 100. De ce fait, la variance de notre série n'est pas constante mais dépend des valeurs passées. De plus, cette hétéroscédasticité peut impacter la précision des estimations des différents paramètres dans le modèle économétrique.

L'ensemble des résultats tels que la non-normalité, l'autocorrélation et l'hétéroscédasticité, nous impose donc d'utiliser des modèles tels que les modèles ARCH / GARCH dans le but d'obtenir une meilleure robustesse et précision pour notre analyse et prévisions financières.

III - Estimation des modèles de volatilités de 2018 à 2022

A) Loi de distribution Normale

Le tableau ci-dessous récapitule les performances des différents modèles ainsi que les critères de comparaison utilisés. Ces modèles sont évalués en appliquant une distribution normale dans la procédure de maximisation de la vraisemblance. Il est crucial de s'assurer que les conditions de validité de chaque modèle sont respectées.

Tableau 4 : Modèles selon la distribution normale

	Coefficient		t-value > 1.64	persistance	half-life	log-likelihood	Akaike	HQ
GARCH	omega > 0	0.000007	0.20458	0.981	36.932	3611.328	-5.7305	-5.7243
	alpha ≥ 0	0.172514	1.762630					
	beta ≥ 0	0.808893	5.122670					
	alpha + beta < 1	0.981407						
GJR-GARCH	omega > 0	0.000007	4.892800	0.972	24.611	3625.722	-5.751700	-5.744100
	alpha	0.044343	2.764000					
	beta ≥ 0	0.837528	38.297300					
	gamma	0.180716	3.614100					
	alpha + gamma ≥ 0	0.225059						
	alpha + beta + (gamma/2) < 1	0.972229						
IGARCH	omega > 0	0.000006	1.565400			3610.349000	-5.730500	-5.725900
	alpha ≥ 0	0.193428	4.861500					
	beta	0.806572						
Riskmetrics	alpha	0.060000				3573.440000	-5.675000	
	beta	0.940000						

sources : Auteurs, Excel, Rstudio

Nous observons que tous les modèles testés respectent les critères de validité établis, ce qui témoigne de leur adéquation à l'analyse. Cependant, une attention particulière doit être portée au paramètre omega, qui n'est pas significatif pour le modèle GARCH, suggérant une possible absence de persistance dans les effets de volatilité. De plus, pour le modèle IGARCH, omega se trouve à la limite de la significativité, ce qui pourrait indiquer une certaine incertitude quant à la présence d'une volatilité persistante sur le long terme. L'examen de la log-vraisemblance maximale, indique que le modèle GJR-GARCH se distingue comme le plus performant. En effet, ce modèle présente les meilleurs résultats en termes de minimisation de ces critères, suggérant qu'il est le mieux adapté aux données et qu'il offre un compromis optimal entre ajustement et complexité.

B) Loi de Distribution de Student

Nous allons désormais présenter le tableau récapitulatif basé sur la distribution de Student.

Tableau 5 : Modèles selon la distribution de student

	Coefficient		t-value > 1.64	persistance	half-life	log-likelihood	Akaike	HQ
GARCH	Cst(V) > 0	0.000004	0.859590	0.999	690.354	3636.425	-5.7687	-5.7611
	alpha $\geq$ 0	0.172625	5.647270					
	beta $\geq$ 0	0.826371	24.856480					
	alpha + beta < 1	0.998996						
GJR-GARCH	Cst(V) > 0	0.000005	0.186081	0.981	36.273	3650.717	-5.7899	-5.7807
	alpha	0.015526	0.170638					
	beta $\geq$ 0	0.855796	0.068693					
	gamma	0.219500	0.817439					
	alpha + gamma $\geq$ 0	0.235026						
	alpha + beta + (gamma/2) < 1	0.981072						
IGARCH	Cst(V) > 0	0.000004	1.013200			3636.425	-5.7703	-5.7642
	alpha $\geq$ 0	0.173588	5.198200					
	beta	0.826412						
Riskmetrics	alpha	0.060000				3613.061	-5.7364	-5.7333
	beta	0.940000						

sources : Auteurs, Excel, Rstudio

Tous les modèles analysés, à l'exception du modèle GJR-GARCH, respectent les critères de validation établis (sauf pour omega). Plus précisément, pour les modèles GARCH, IGARCH et Riskmetrics, les valeurs des tests t sont inférieures au seuil critique de 1,64, ce qui indique qu'ils sont statistiquement significatifs et donc valides dans le cadre de cette analyse. Cela signifie que ces modèles montrent une capacité d'ajustement adéquate aux données et peuvent être utilisés pour des prévisions avec un certain degré de confiance. En revanche, le modèle GJR-GARCH ne répond pas aux critères requis, ce qui suggère qu'il ne présente pas une performance statistique suffisante pour être retenu avec cette distribution.

En résumé, il est difficile de départager les modèles validés en se basant uniquement sur les critères d'évaluation disponibles. Par conséquent, il devient indispensable de réaliser des prévisions afin de déterminer quel modèle est le plus adapté à nos données.

C) Diagnostic des résidus

Une fois les différentes estimations effectuées, nous pouvons dès lors passer à l'analyse des résidus grâce à un ensemble de tests nous révélant ainsi la robustesse de chaque

estimation. Il est important de préciser que nous appliquerons uniquement les tests de Ljung-Box sur les résidus et les résidus aux carrés et le LM-ARCH avec 5 retards.

Tableau 6 : Diagnostic des résidus sur les modèles valides

Loi de distribution	Loi Normale				Loi Student		
Test	GARCH	GJR-GARCH	IGARCH	Riskmetrics	GARCH	IGARCH	Riskmetrics
Statistique							
Ljung-Box	1.872	1.498	1.599	2.322	1.642	1.629	2.261
Ljung-Box ²	5.339	3.832	6.183	26.872	6.285	6.330	27.223
LM-Arch (5)	5.201	3.689	5.953	25.324	6.090	6.131	25.473
P-value							
Ljung-Box	0.866	0.913	0.901	0.802	0.896	0.897	0.811
Ljung-Box ²	0.375	0.573	0.288	0.00006	0.279	0.275	0.00005
LM-Arch (5)	0.391	0.594	0.310	0.00012	0.297	0.293	0.0001

sources : Auteurs, Rstudio

En étudiant le tableau 6, nous pouvons conclure que les modèles fournissent une estimation appropriée de la volatilité de rendements financiers.

Dans un premier temps, nous pouvons observer que pour l'ensemble des test d'autocorrélation que les valeurs-p du test de Ljung-Box sur les résidus simples dépassent le seuil de 0.05 pour l'ensemble des modèles signifiant alors qu'il n'y a pas de preuve d'autocorrélation significative des résidus au seuil de 5%. Nous retrouvons exactement les mêmes résultats pour le test de Ljung-Box sur les résidus au carrés excepté pour le modèle riskmetrics aussi bien avec une loi de distribution Normale ou de Student. Ainsi l'ensemble des modèles captent bien la volatilité conditionnelle sans laisser d'auto-corrélation résiduelle excepté pour le modèle riskmetrics. En ce qui concerne le test de LM-Arch(5) qui nous permet de révéler de la preuve de l'effet ARCH, permettant d'accepter l'hypothèse

d'homoscédasticité conditionnelle, nous retrouvons le même schéma de validation que pour le test de Ljung-Box des résidus au carrés, en effet l'ensemble modèle est valide l'homoscédasticité des modèles excepté pour les modèles riskmetrics aussi bien pour la loi Normale et de Student.

En somme, les résultats nous indiquent que les modèles fournissent une estimation appropriée de la volatilité des rendements financiers, excepté pour les modèles Riskmetrics, quelle que soit la loi de distribution.

D) Analyse du meilleur modèle

Une fois l'ensemble des estimations de faites et au vu des différents résultats obtenus à l'aide aussi bien des différents indicateurs statistiques tels que le log-like et le critère d'Akaike et des diagnostic des résidus, nous pouvons dès lors sélectionner le meilleur modèle. Nous décidons de sélectionner le modèle qui minimise au mieux le log-like tout en maximisant le critère d'Akaike sous-contrainte de la validation des différents tests sur les résidus, de ce fait, le meilleur modèle de l'ensemble des nos estimations est le modèle IGARCH.

Il est important de préciser au préalable que le modèle IGARCH permet de modéliser la volatilité de notre actif en prenant en compte sa forte persistance. Il est essentiel de noter que ce modèle intègre la volatilité passée dans la prévision de la volatilité actuelle. De plus, la volatilité est donc non stationnaire, signifiant que les chocs de volatilité ne disparaissent jamais complètement. Au vu des différents résultats obtenus, nous constatons que la constante est positive et statistiquement significative au seuil de 10% ($|t\text{-value}| > 1.64$), ce qui suggère un niveau de volatilité de long terme non nul. Par ailleurs, le coefficient alpha est positif et statistiquement significatif, indiquant que la volatilité réagit aux nouvelles informations. Enfin, le coefficient bêta est également positif et très proche de 1, ce qui confirme la forte persistance de la volatilité. Soulignons que la somme des coefficients alpha et bêta est égale à 1, une caractéristique propre au modèle IGARCH qui valide la non-stationnarité de la volatilité. Ainsi, ce modèle suggère que la volatilité des rendements financiers présente une forte inertie : les périodes de forte volatilité tendent à être suivies par d'autres périodes de forte volatilité, et inversement. Cela reflète la dynamique des marchés financiers, où les chocs de volatilité ont un impact durable sur l'évolution future de la volatilité.

IV - Pr vision de la volatilit  du NASDAQ 100 pour l'ann e 2023

Nous allons r aliser des pr visions pour l'ann e 2023 en nous appuyant sur nos diff rents mod les valid s. Pour cela, nous devons pr dire 251 observations. Dans un premier temps, nous  tablirons un tableau r capitulatif des performances de nos pr visions,  valu es   l'aide des indicateurs MSE et R^2OOS . Puis, nous analyserons les r sultats des tests de comparaison de pr cision, notamment les tests DM et MCS.

A) Comparaison des mod les

Tableau 7 : Performance des diff rents mod les

Loi de distribution	Loi Normale				Loi Student		
Indicateur de performance	GARCH	GJR-GARCH	IGARCH	Riskmetrics	GARCH	IGARCH	Riskmetrics
MSE	3.37e-05	3.27e-05	3.46e-05	3.19e-05	3.38e-05	3.40e-05	3.18e-05
R2oos	-0.0593	-0.0257	-0.0851	0	-0.0593	-0.0647	0.0015

sources : Auteurs, Rstudio

Premi rement, l'analyse des erreurs quadratiques moyennes (MSE) met en  vidence des diff rences de pr cision entre les mod les. Le mod le Riskmetrics pr sente la plus faible MSE (3.18e-05), indiquant ainsi une meilleure pr cision pr visionnelle par rapport aux autres mod les.   l'inverse, le mod le iGARCH sous la loi normale affiche la MSE la plus  lev e (3.46e-05), sugg rant une pr cision moindre dans ses pr visions.

Concernant le coefficient de d termination hors  chantillon (R^2OOS), le mod le Riskmetrics sous la loi normale est utilis  comme r f rence, ce qui explique son R^2OOS de 0. Les autres mod les affichent majoritairement des valeurs n gatives, ce qui signifie qu'aucun d'eux ne surpasse Riskmetrics en termes de performances pr visionnelles. Un point notable est que le mod le Riskmetrics sous loi Student pr sente un R^2OOS l g rement positif (0.0015), sugg rant qu'il pourrait  tre une alternative viable au mod le de r f rence.

B) test de précision

Une fois la comparaison des modèles effectuée à l'aide d'un ensemble d'indicateurs de performance, nous pouvons dès lors passer à l'analyse de la précision des estimations. De ce fait, nous allons déterminer si les prévisions d'un modèle sont statistiquement différentes de notre modèle de référence, le modèle RiskMetrics loi normale. Pour ce faire, nous allons utiliser un test d'égalité de capacité prédictive, complété par la suite par un test de capacité prédictive supérieure sans modèle de référence.

Tableau 8 : Test de Diebold Mariano

Loi de distribution	Loi Normale			Loi Student		
	GARCH	GJR-GARCH	IGARCH	GARCH	IGARCH	Riskmetrics
Riskmetrics	1	0.37	0.005	1	0.008	1

sources : Auteurs, Rstudio

Au préalable de l'analyse des résultats, il est important de rappeler l'hypothèse H_0 . Ainsi, l'hypothèse H_0 du modèle suppose une égalité prédictive entre deux modèles. En étudiant le tableau 8, nous remarquons que, pour la majorité des modèles, il n'y a pas de différence significative avec le modèle de référence en termes de performance de prévision, excepté pour les modèles IGARCH, qui suivent aussi bien une loi normale qu'une loi de Student. De ce fait, les modèles IGARCH rejettent l'hypothèse nulle au seuil de 5 %, nous indiquant alors que ces modèles apportent une meilleure performance de prévision, renforçant ainsi le choix du meilleur modèle fait par nos soins au préalable.

Afin d'identifier les modèles les plus performants, nous avons appliqué l'approche Model Confidence Set (MCS). Cette méthode permet de sélectionner un ensemble de modèles statistiquement similaires, qui ne peuvent être distingués de manière significative les uns des autres en termes de performance prédictive. L'analyse repose sur les valeurs de MCS, qui indiquent la probabilité d'inclusion de chaque modèle dans cet ensemble.

Tableau 9 : Performance des différents modèles

Loi de distribution	Loi Normale				Loi Student		
Indicateur de performance	GARCH	GJR-GARCH	IGARCH	Riskmetrics	GARCH	IGARCH	Riskmetrics
MCS	1	0.54	1	0.122	0.019	1	1

sources : Auteurs, Rstudio

Dans un premier temps, nous observons que certains modèles affichent une valeur de MCS égale à 1, notamment GARCH sous loi normale, IGARCH sous loi Student et Riskmetrics sous loi Student. Cela signifie que ces modèles ont une forte probabilité d'appartenir à l'ensemble des modèles les plus performants. Leur inclusion dans cet ensemble suggère qu'ils sont statistiquement robustes et qu'ils fournissent des performances prédictives satisfaisantes par rapport aux autres modèles testés.

À l'inverse, certains modèles présentent des valeurs de MCS nettement plus faibles, indiquant une moindre probabilité d'appartenance à l'ensemble des modèles performants. Par exemple, Riskmetrics sous loi normale affiche une valeur de 0.122, suggérant une incertitude quant à sa capacité à offrir une performance équivalente aux modèles les plus fiables. De même, IGARCH sous loi normale et GARCH sous loi Student, avec des valeurs respectives de 0.122 et 0.019, semblent être les modèles les moins performants selon cette approche.

V - Conclusion

L'objectif de cette étude était de prédire au mieux la volatilité de l'indice boursier du NASDAQ 100 pour l'année 2023. Pour ce faire nous avons mené une analyse exploratoire approfondie pour comprendre aux mieux les différentes caractéristiques de notre série nous permettant une sélection optimale des différents modèles de volatilité. Ainsi, l'essentiel de notre étude, s'est donc concentré sur l'application de diverses méthodes économétriques de prédiction de la volatilité suivant aussi bien une Loi de distribution Normale ou de Student.

Au vu des différents résultats obtenus lors de l'analyse exploratoire, nous avons fait le choix d'appliquer des modèles tels que les modèles ARCH/GARCH, suivant aussi bien une loi de distribution normale que de Student. Cet ensemble d'estimations, nous amenant à un total final de sept modèles, nous a poussés à comparer ces modèles à l'aide de différents indicateurs statistiques, de diagnostics des résidus, etc. De ce fait, notre meilleur modèle est le modèle **IGARCH**, une extension du modèle GARCH.

En conclusion, nous avons fait le choix de prédire l'année 2023 du NASDAQ 100 pour chaque modèle (c'est-à-dire les sept modèles), nous permettant d'informer ou non notre choix du meilleur modèle. Ainsi, à l'aide des différents tests de précision et de comparaison des prévisions, nous confirmons que le modèle IGARCH avec la loi normale est notre modèle de prévision le plus performant. De ce fait, cela nous indique que ce modèle offre une meilleure capacité prédictive et une stabilité accrue par rapport aux autres modèles testés. Cette conclusion renforce la pertinence de l'approche adoptée et souligne l'importance du choix des hypothèses de distribution dans l'évaluation des modèles de prévision. Dans une perspective future, il serait intéressant d'explorer d'autres extensions des modèles GARCH, d'incorporer des techniques d'apprentissage automatique, ou encore d'intégrer des facteurs macroéconomiques afin d'affiner davantage la qualité des prévisions.

VI - Bibliographie

- Bhowmik, R., & Wang, S. (2020). Stock market volatility and return analysis: A systematic literature review. *Entropy*, 22(5), 522.


VII - Annexes

Annexe 1 : Descriptif des outliers

	Date	daily.returns	daily.returns.1
1	2018-12-24	-0.05837229	Outlier négatif
2	2018-12-26	0.06678547	Outlier positif
3	2020-02-27	-0.05282337	Outlier négatif
4	2020-03-09	-0.06488695	Outlier négatif
5	2020-03-12	-0.09848816	Outlier négatif
6	2020-03-13	0.09708603	Outlier positif
7	2020-03-16	-0.10842308	Outlier négatif
8	2020-03-23	-0.05843639	Outlier négatif
9	2020-03-24	0.08164507	Outlier positif
10	2020-04-06	0.06739557	Outlier positif
11	2022-09-13	-0.05527540	Outlier négatif
12	2022-11-10	0.07400226	Outlier positif

sources : Auteurs, Rstudio

Annexe 2 : Distribution des rendements brutes corrigées non corrigées de l'actif NASDAQ



sources : Auteurs, Rstudio

VIII - Table des matières

Résumé.....	I
Abstract.....	II
Sommaire.....	III
I - Introduction.....	1
II - Analyse exploratoire.....	2
A) Descriptif de l'actif.....	2
B) Détection des outliers.....	4
C) Graphique des rentabilités.....	5
D) Corrélogrammes.....	6
E) Statistique descriptives du NASDAQ 100.....	8
F) Caractéristique de distribution du NASDAQ 100.....	9
III - Estimation des modèles de volatilités de 2018 à 2022.....	11
A) Loi de distribution Normale.....	11
B) Loi de Distribution de Student.....	12
C) Diagnostic des résidus.....	12
D) Analyse du meilleur modèle.....	14
IV - Prévion de la volatilité du NASDAQ 100 pour l'année 2023.....	15
A) Comparaison des modèles.....	15
B) test de précision.....	16
V - Conclusion.....	18
VI - Bibliographie.....	19
VII - Annexes.....	20
VIII - Table des matières.....	21