



UNIVERSITÉ DE NANTES



**IAE NANTES**  
ÉCONOMIE & MANAGEMENT

**Master Econométrie et Statistiques, parcours Econométrie Appliquée**

**Document annexe du mémoire de Master 1**

**Explication des différents paramètres de chaque modèles  
utilisé dans l' étude comparative et analyse critique des  
modèles de prévision des symptômes grippaux aux  
Etats-Unis d'Amérique pour l'année 2023**

**MOCAER RODOLPHE**

Sous la direction de Darne Olivier

## **Sommaire**

|                                                                            |           |
|----------------------------------------------------------------------------|-----------|
| <b>Sommaire.....</b>                                                       | <b>I</b>  |
| <b>Chapitre I - Introduction.....</b>                                      | <b>1</b>  |
| <b>Chapitre II - Explication approfondie des modèles sélectionnés.....</b> | <b>2</b>  |
| <b>Chapitre III - Conclusion.....</b>                                      | <b>15</b> |
| <b>Annexe.....</b>                                                         | <b>16</b> |
| <b>Liste des titres des tableaux et graphique.....</b>                     | <b>23</b> |
| <b>Tables des matières.....</b>                                            | <b>24</b> |

## **Chapitre I - Introduction**

Dans notre étude comparative sur les différents modèles de prévision, il n'est pas essentiel d'analyser en détail chaque modèle pour une compréhension approfondie de notre travail. Cependant, par souci de rigueur scientifique, nous avons jugé nécessaire de fournir un document annexe détaillant les divers modèles utilisés. Ceci a pour but d'éviter d'alourdir notre étude principale. Il convient de noter que nous nous concentrons principalement sur l'explication des méthodes de prévision compartimentales et des séries temporelles, tandis que les méthodes analogues sont exclues. Cette décision découle de la simplicité de ces modèles, qui ne nécessitent pas une explication détaillée de leurs paramètres. Ainsi, nous entamons notre analyse en détaillant les paramètres des modèles compartimentaux, puis nous passerons à l'explication des modèles des méthodes de prévision univariées et multivariées.

## **Chapitre II - Explication approfondie des modèles sélectionnés**

Nous pouvons dès lors passer à l'explication et à l'analyse des différents paramètres de chaque modèle. Nous expliquerons dans un premier temps les différents modèles utilisés dans les méthodes compartimentales puis, nous expliquerons l'ensemble des modèles appliqués pour les méthodes de prévision aussi bien univariées que multivariées.

### **Section I - Méthodes compartimentales**

Dans le contexte évoqué, il est notoire que les modèles compartimentaux requièrent une multitude de paramètres essentiels pour garantir la précision des prévisions épidémiologiques. Le nombre de ces paramètres fluctue selon le nombre de compartiments. Toutefois, il convient de souligner que la compréhension des modèles ne réside pas dans l'examen isolé de ces paramètres, mais dans leur intégration dans des équations. C'est cette démarche qui nous permettra d'identifier de nouveaux paramètres, tels que le R0 ou la durée d'infection (D), favorisant ainsi une meilleure appréhension des modèles. Cette analyse comparative entre les paramètres déduits et ceux observés concrètement sera alors cruciale.

Tableau 1 : Récapitulatifs des paramètres des modèles compartimentales

| Test   | Beta   | Gamma - 1 | Zeta | Rho   | Gamma - 2 | Alpha | Kappa | R0   |
|--------|--------|-----------|------|-------|-----------|-------|-------|------|
| SIR    | 0.5141 | 0.485     | x    | x     | x         | x     | x     | 1.07 |
| SEIRD  | 0.75   | 0.674     | 0.5  | 0.073 | 0.601     | x     | x     | 1.13 |
| SEIRDV | 0.75   | 0.35      | 0.5  | 0.03  | 0.32      | 0.5   | 0.002 | 2.17 |

sources : Auteur, Canva, Annexe 1 à 3

Nous posons comme équations :

$$- R0 = \frac{\beta}{\gamma_1}$$

Le nombre de reproductions.

$$- D = \frac{1}{\gamma_1}$$

La durée d'infection

L'examen du tableau 1 et la comparaison des données avec les valeurs réelles du virus de la grippe révèlent d'importantes divergences. Nous connaissons le  $R_0$  moyen de la grippe, qui est de 2, ainsi que la durée moyenne d'infection de 7 jours, aboutissant à un  $\gamma_1$  de  $1/7$ , soit 0,1429. Il est alors frappant de constater que l'ensemble des modèles présente des écarts considérables par rapport à cette valeur. De plus, le  $R_0$  est nettement sous-estimé dans les modèles SEIRD et SIR. En revanche, dans le cas du modèle SEIRDV, le  $R_0$  se rapproche davantage du  $R_0$  observé. Ces écarts entre les valeurs estimées par les modèles et les données réelles soulignent la complexité de la modélisation des épidémies et mettent en évidence la nécessité d'un calibrage précis des paramètres. De plus, le modèle SEIRDV, défini comme étant le plus factuel, suggère l'importance d'inclure des compartiments tels que la vaccination dans les modèles épidémiologiques. Cela souligne autant la nécessité d'adapter en permanence nos modèles pour refléter au mieux la réalité évolutive des épidémies que d'améliorer notre capacité à anticiper et à répondre efficacement aux crises sanitaires.

## Section II - Les méthodes de séries temporelles


Suite à l'analyse des modèles compartimentaux, nous pouvons dès lors analyser les modèles des méthodes de prévision de séries temporelles. Nous étudierons dans un premier temps les séries temporelles univariées, en passant aussi bien par les méthodes de lissage que par les méthodes ARIMA. Puis nous analyserons les méthodes de prévision multivariées."

### 1§ - Les méthodes de séries temporelles univariées

#### *A) Méthodes de lissage exponentielle*

Nous débutons notre analyse des modèles de prévision univariés en étudiant les modèles de prévision de lissage exponentiel. Ainsi, nous expliquerons les modèles ADAM, ETS (Erreur, Tendence et Saisonnalité), HW (Holt-Winters), CES (Complex Exponential Smoothing) et enfin TBATS (Trigonometric seasonality, Box-Cox transformation, ARIMA errors, Trend component et Seasonal component)."

#### Graphique 1 : Modélisation de la prévision ADAM




sources : Auteur, Rstudio

En étudiant les paramètres du modèle **ADAM** (voir annexe 4), nous pouvons observer que ce modèle combine des composants multiplicatifs pour les erreurs avec des composants additifs pour la tendance et la saisonnalité (ETS(MAdM) avec dérive). De plus, nous pouvons remarquer que ce modèle accorde un poids très élevé aux observations récentes pour déterminer le niveau actuel ( $\alpha = 0,9902$ ), contrairement à la composante saisonnière et aux tendances qui sont moins prises en compte ( $\gamma = 0,005$  et  $\beta = 0,0314$ ). Ainsi, ce modèle capture les variations des séries temporelles avec une composante de tendance

linéaire et des effets saisonniers, tout en accordant une importance majeure aux observations les plus récentes.


Graphique 2 : Modélisation de la prévision ETS



sources : Auteur, Rstudio

Nous observons dès lors les paramètres du modèle de **lissage exponentiel triple** (Voir annexe 5). Nous pouvons identifier qu'il utilise des composantes multiplicatives pour l'erreur et la saisonnalité, et ne tient pas compte de la tendance. De plus, nous pouvons aisément observer que ce modèle accorde un poids important aux observations récentes pour déterminer le niveau ( $\alpha = 0,9395$ ) en opposition à la composante saisonnière ( $\gamma = 0,0605$ ). De ce fait, ce modèle capture les variations de l'incidence des symptômes grippaux grâce aux effets saisonniers multiplicatifs et une forte importance accordée aux observations récentes, sans tenir compte des tendances linéaires.


Graphique 3 : Modélisation de la prévision HW



sources : Auteur, Rstudio

En analysant les paramètres du modèle **HW** (voir annexe 6), nous pouvons remarquer qu'il possède un paramètre alpha et gamma égaux à 1 et un paramètre bêta égal à 0, nous démontrant ainsi que le modèle accorde un poids total aux observations les plus récentes et à la composante saisonnière, mais ne tient pas compte des tendances. De plus, nous pouvons également observer que les coefficients saisonniers montrent une variation significative, indiquant des effets saisonniers forts.

Graphique 4 : Modélisation de la prévision CES




sources : Auteur, Rstudio

Nous pouvons dès lors passer à l'analyse du modèle **CES**. En analysant les paramètres obtenus (voir annexe 7), nous pouvons remarquer que ce modèle est composé d'une composante autorégressive avec un coefficient de 2 pour  $a_0$  et d'une composante autorégressive avec un coefficient de 1 pour  $a_1$ . De plus, nous pouvons observer que dans ce modèle, il n'y a pas de tendance ( $b = 0$ ). Ainsi, c'est donc un modèle d'analyse de séries temporelles avec une composante autorégressive et sans tendance.



### Graphique 5 : Modélisation de la prévision TBATS




sources : Auteur, Rstudio

Nous nous penchons maintenant sur le dernier modèle de lissage exponentiel, le modèle **TBATS** (voir annexe 8). Ce modèle offre la capacité de modéliser plusieurs composantes de saisonnalité et des tendances complexes. Il intègre une transformation Box-Jenkins légère pour stabiliser les données. De plus, il utilise des coefficients de lissage pour les niveaux, avec un  $\alpha$  de 0,088, ce qui suggère une importance modérée accordée aux observations récentes. Les coefficients de lissage pour les saisons ( $\gamma_1$  et  $\gamma_2$ ) sont faibles, indiquant ainsi que les saisons sont relativement bien lissées. Les termes autorégressifs (AR) révèlent une dépendance positive entre les observations actuelles et passées, tandis que les termes moyens mobiles (MA) indiquent les effets positifs/négatifs des erreurs passées sur les observations actuelles.

#### *B) Méthodes de prévision ARIMA*

Suite à l'analyse de l'ensemble des modèles de lissage exponentiel, nous pouvons passer à l'étude des modèles ARIMA. Nous examinerons dans cet ordre les modèles ETS - SARIMA, SSARIMA et enfin ADAM SARIMA."


### Graphique 6 : Modélisation de la prévision ETS - SARIMA



sources : Auteur, Rstudio

Commençons notre analyse avec le modèle **ETS - SARIMA**. En étudiant ces paramètres (voir annexe 9), nous notons qu'il s'agit d'une fusion entre une méthode de lissage exponentiel, utilisant une combinaison de tendance additive et de saisonnalité multiplicative sans cycle, et un modèle ARIMA saisonnier, comprenant une composante autorégressive (AR) d'ordre 1, une saisonnalité avec un premier et un deuxième lag, ainsi qu'une périodicité annuelle. De plus, ce modèle prend modérément en compte les observations réelles ( $\alpha = 0,5343$ ), et présente une dépendance positive entre les observations actuelles et passées, surtout aux lags saisonniers, comme le démontrent les coefficients des  $\phi$ . Nous remarquons également une tendance générale à la croissance, illustrée par un drift de 1,01. Ainsi, ce modèle combine le lissage exponentiel avec un modèle SARIMA pour saisir à la fois les tendances et les saisonnalités complexes de la série temporelle, tout en tenant compte de la dérive et d'autres paramètres spécifiques.

### Graphique 7 : Modélisation de la prévision SSARIMA



sources : Auteur, Rstudio

Nous pouvons maintenant examiner le modèle **SARIMA(0,1,3)[1](3,0,0)[12]** et ses paramètres (voir annexe 10). Ce modèle se compose de trois composantes AR correspondant

à des retards de 12 mois, avec des coefficients respectifs de 0.2515, 0.1324 et 0.2222, ainsi que de trois composantes MA correspondant à des retards de 1 mois, avec des coefficients respectifs de 0.2471, -0.5713 et -0.3932. De plus, la périodicité saisonnière est de 12 mois, indiquant une saisonnalité annuelle. Ainsi, ce modèle SARIMA combine des composantes autorégressives, de moyenne mobile et saisonnières pour modéliser les variations temporelles des données, avec une périodicité annuelle.

Nous passons ensuite à l'analyse des paramètres du modèle **X13** (voir annexe 11). Ce modèle se divise en deux parties distinctes : une composante de régression et une composante ARIMA. La première comprend une moyenne, mais exclut les effets des jours de transaction, des années bissextiles, de Pâques et des valeurs aberrantes. La seconde partie comprend une composante AR ainsi que deux composantes MA, l'une saisonnière et l'autre classique. Cette structure de modèle permet de saisir les dynamiques des données temporelles, tout en prenant en compte une transformation logarithmique pour stabiliser la variance. Ainsi, ce modèle offre une méthode efficace pour la prévision des séries temporelles présentant une structure complexe et des tendances saisonnières.


Pour conclure, notre analyse des modèles combinant la **Régression et ARIMA(1, 0, 1)(0, 1, 1)**, nous pouvons désormais étudier les différents paramètres de ce dernier (voir annexe 12). Nous remarquons que ce modèle n'inclut pas de composante moyenne, ni d'effet des jours de transaction, d'effet des années bissextiles, ni d'effet de Pâques, et aucun effet aberrant n'est pris en compte dans ce modèle. Pour la partie ARIMA, elle inclut un paramètre d'autorégression (AR) d'ordre 1 (Phi) avec un coefficient estimé de -0.76404, indiquant une forte corrélation négative avec la valeur précédente. De plus, un paramètre de moyenne mobile (MA) d'ordre 1 (Theta) avec un coefficient estimé de 0.58583 suggère une corrélation positive avec l'erreur précédente. Enfin, le modèle MA saisonnier (Theta) avec un décalage saisonnier d'ordre 1 (Theta) a un coefficient estimé de -0.53317, indiquant une forte corrélation négative avec la saisonnalité. Ainsi, ce modèle combine une régression avec un modèle ARIMA pour capturer les tendances et la saisonnalité dans la série temporelle.

### *C) Méthodes de prévision diverses*

Nous terminons notre analyse des modèles de prévision univariées en examinant les différents modèles restants qui ne peuvent être classés dans les deux catégories précédentes. Ainsi, nous expliquerons les modèles Naïves, Bagged (Bootstrap Aggregating), STS

(Seasonal and Trend decomposition using Loess), STL (Seasonal and Trend decomposition using Loess) et enfin le modèle X13."


Graphique 8 : Modélisation de la prévision Naïve



sources : Auteur, Rstudio

Nous débutons notre analyse par l'étude des paramètres du modèle **naïf** (voir annexe 13). Ce modèle de prévision est une approche simple où les valeurs futures sont supposées être égales à la dernière valeur observée. Cette modélisation simpliste peut être efficace notamment pour les séries temporelles sans tendance ni saisonnalité marquée. Étant donné la structure de nos données, cette prévision est moins performante et sera utilisée essentiellement comme point de référence pour comparer la performance des modèles plus complexes.


Graphique 9 : Modélisation de la prévision Bagged



sources : Auteur, Rstudio

Nous pouvons maintenant étudier le modèle de prévision "**baggedModel**". Cette méthode consiste à générer plusieurs sous-échantillons de la série temporelle d'origine, à entraîner des modèles distincts sur chacun de ces sous-échantillons, puis à agréger les prévisions de ces modèles pour obtenir une prévision finale plus stable et plus robuste. Cela nous permet d'obtenir un modèle capable de gérer les variabilités et les incertitudes inhérentes aux données.


### Graphique 10 : Modélisation de la prévision STS



sources : Auteur, Rstudio

Nous nous interrogeons dès lors sur l'analyse des paramètres du modèle **STS** (voir annexe 14). Nous pouvons observer, dans un premier temps, que ce modèle utilise une décomposition structurelle pour modéliser cette prévision. Cette modélisation utilise des composantes de niveau, de pente et de saisonnalité. Dans cette modélisation, nous pouvons remarquer que la composante saisonnière est nulle, indiquant qu'elle n'est pas prise en considération dans le modèle. De plus, nous pouvons observer une variance du niveau plus élevée que celle de la pente, impliquant dès lors des variations à long terme plus prononcées. Ainsi, ce modèle est utilisé pour capturer les tendances à long terme et les variations dans les données.

### Graphique 11 : Modélisation de la prévision STL



sources : Auteur, Rstudio

Enfin, nous étudions les paramètres du modèle **STL + ETS** (voir annexe 15). Ce modèle combine une décomposition de la série temporelle en ses composantes saisonnières et de tendance avec un modèle ETS simple qui ne prend en compte que le niveau de la série. Ce modèle possède des erreurs additives. De plus, nous pouvons observer une prise en

considération importante des nouvelles observations, en donnant presque tout le poids à la dernière observation, comme le démontre l' $\alpha$  proche de 1.

## 2§ - Les méthodes de séries temporelles multivariées

Suite à l'analyse de l'ensemble des modèles de prévision de séries temporelles univariées, nous pouvons dès à présent analyser les différentes structures et paramètres des modèles utilisés dans la prévision de séries temporelles multivariées. Nous étudierons dans un premier temps les modèles obtenus par les méthodes de régression, suivis des modèles ARX, pour finir avec les modèles ARMAX.

### *A) Méthode de Régression*

Suite à la sélection des variables, nous obtenons deux modèles de régression : l'un ayant subi le processus de sélection des variables et l'autre étant complet. Nous allons principalement analyser le modèle ayant subi le processus de sélection, car cette analyse pourra être simplement transposée de la même manière pour l'autre modèle.

#### Modélisation 1 : Modèle de Régression simple 1

$$Y_t \sim \beta_0 + \beta_1 \times \text{BBKCI} + \beta_2 \times \text{BBKGDP} + \beta_3 \times \text{BBKF} + \beta_4 \times \text{Mean} + \beta_5 \times \text{Medical\_care} + \beta_6 \times \text{Terme\_santé} + \beta_7 \times \text{Sympt\_santé} + \beta_8 \times \text{Zoonose\_santé} + \beta_9 \times \text{Maladie\_conco\_santé} + \beta_{10} \times \text{Pop\_moins\_16\_ans} + \beta_{11} \times \text{Pop\_plus\_55\_ans}$$

sources : Auteur, Annexe 16

Les coefficients estimés dans le modèle (voir annexe 16) représentent les effets de chaque variable indépendante sur la variable dépendante. Par exemple, un coefficient négatif, tel que pour "Mean", signifie qu'une augmentation de cette variable est associée à une diminution de la variable dépendante, tandis qu'un coefficient positif, comme pour "Sympt\_santé", signifie qu'une augmentation de cette variable est associée à une augmentation de la variable dépendante.

Nous pouvons appliquer cette même logique afin d'expliquer l'autre modèle de régression qui possède l'ensemble des variables de notre base de données (voir annexe 17).

### *B) Méthode ArX*

Nous pouvons dès lors passer à l'analyse des modèles ARX. Il est important de souligner que ces modèles prennent comme modèle initial la modélisation 1 et ajoutent des composantes autorégressives afin de modéliser au mieux l'incidence des symptômes grippaux.

#### Modélisation 2 : Modèle ArX

*ARIMA(3, 0, 0) erreurs + Modélisation 1*

sources : Auteur, Annexe 18

Ce modèle, présenté dans la modélisation 1, est une régression linéaire avec des erreurs suivant un processus autorégressif intégré d'ordre 3. Il est également important d'analyser les coefficients de ce modèle. Les coefficients des variables exogènes sont interprétés de la même manière que pour un modèle de régression standard. Par exemple, un coefficient négatif comme celui de BBKCI suggère qu'une augmentation de cette variable est associée à une diminution de la variable dépendante ( $Y_t$ ), tandis qu'un coefficient positif, comme celui du terme santé, suggère qu'une augmentation de cette variable est associée à une augmentation de  $Y_t$ . En outre, il est essentiel d'expliquer les composantes autorégressives et leurs coefficients. Les coefficients AR1, AR2 et AR3 sont respectivement de 0.8166, -0.3082 et 0.2196. Ces coefficients indiquent la dépendance linéaire entre  $Y_t$  et ses valeurs passées. La présence de coefficients AR positifs et négatifs suggère une dépendance à court terme de  $Y_t$  par rapport à ses valeurs passées.

### C) Méthode ArmaX

Pour finir, nous pouvons analyser les différents modèles obtenus par la méthode ARMAX. L'étude des paramètres de ces modélisations sera similaire à celle de l'analyse des paramètres de ARX. Il est important de souligner que nous obtenons deux modélisations différentes étant donné que nous avons utilisé deux méthodes différentes (une avec `auto.arima` et une sans).

#### Modélisation 3 : Modèle ArmaX avec `auto.arima`

*ARIMA(2, 0, 3) erreurs + Modélisation 1*

sources : Auteur, Annexe 19

#### Modélisation 4 : Modèle ArmaX sans `auto.arima`

*ARIMA(1, 0, 0) erreurs + Modélisation 1*

sources : Auteur, Annexe 20

Nous appliquons la même logique d'analyse des coefficients et du modèle pour la modélisation 4, le seul changement étant qu'il n'y a qu'une seule composante autorégressive dans ce modèle. Pour la modélisation 3, une subtilité s'ajoute en plus des coefficients des variables et des coefficients de composante autorégressive : ce modèle possède des composantes de moyenne mobile. Ainsi, ces coefficients pourraient s'expliquer de la manière suivante : une augmentation de l'erreur résiduelle à un moment donné (MA1) est associée à une augmentation de la variable dépendante à l'heure actuelle, tandis qu'une augmentation de l'erreur résiduelle à un moment précédent (MA2 et MA3) est associée à une diminution de la



variable dépendante à l'heure actuelle. La moyenne mobile explique donc comment les erreurs résiduelles passées influencent la variable dépendante à l'heure actuelle.

### **Chapitre III - Conclusion**

Cet document nous offre ainsi l'opportunité d'analyser de manière plus précise et rigoureuse chacun des modèles utilisés, en complément du meilleur modèle présenté dans notre étude comparative. Grâce à cette analyse approfondie, nous pouvons examiner en détail les caractéristiques et les performances de chaque modèle, ce qui nous permettra de mieux comprendre leur pertinence et leur efficacité dans la résolution du problème étudié. En étudiant les nuances et les spécificités de chaque modèle, nous serons en mesure de tirer des conclusions plus éclairées et d'identifier les pistes d'amélioration pour nos futures recherches.

## Annexe

### Annexe 1 : Différents Paramètres du modèle SIR

> Infecté\_symptomatique

[1] 19740263

> Retiré

[1] 26205645

> R0\_SIR

[1] 1.073299

sources : Auteur, Rtsudio

### Annexe 2 : Différents Paramètres du modèle SIERD

> R0\_SEIRD

[1] 1.130918

> Infecté\_symptomatique2

[1] 20529434

> Contaminé2

[1] 83791067

> Décédés

[1] 8753413

> Rétablis

[1] 72065774

> Retiré

[1] 26205645

sources : Auteur, Rtsudio

### Annexe 3 : Différents Paramètres du modèle SIERDV

> R0\_SEIRD

[1] 2.171429

> Infecté\_symptomatique3

[1] 26498030

> Contaminé3

[1] 55731443

> Décédés2

[1] 4259163

> Rétablis2

[1] 45431068

> Retiré2

[1] 49690230

sources : Auteur, Rtsudio

## Annexe 4 : Paramètres du modèle ADAM

Time elapsed: 0.47 seconds

Model estimated: CES(p)

a0 + ia1: 2+1i

b: 0

Initial values were produced using backcasting.

Loss function type: likelihood; Loss function value: 2415.0299

Error standard deviation: 9722.011

Sample size: 228

Number of estimated parameters: 4

Number of degrees of freedom: 224

Information criteria:

| AIC      | AICc     | BIC      | BICc     |
|----------|----------|----------|----------|
| 4838.060 | 4838.239 | 4851.777 | 4852.264 |

sources : Auteur, Rtsudio

## Annexe 5 : Paramètres du modèle ETS

Forecast method: ETS(M,N,M)

Model Information:  
ETS(M,N,M)

Call:  
ets(y = y)

Smoothing parameters:  
alpha = 0.9395  
gamma = 0.0605

Initial states:  
l = 3600.0339  
s = 1.3871 1.0533 0.8892 0.401 0.3678 0.3525  
0.4842 0.7548 0.9903 1.5463 2.2407 1.5327

sigma: 0.3251

| AIC      | AICc     | BIC      |
|----------|----------|----------|
| 4966.903 | 4969.168 | 5018.344 |

Error measures:

|              | ME        | RMSE     | MAE      | MPE       | MAPE     | MASE      | ACF1       |
|--------------|-----------|----------|----------|-----------|----------|-----------|------------|
| Training set | -327.7656 | 9529.411 | 4579.713 | -3.209848 | 22.03519 | 0.5274349 | 0.07606296 |

sources : Auteur, Rtsudio

## Annexe 6 : Paramètres du modèle HW

Forecast method: HoltWinters

Model Information:  
Holt-Winters exponential smoothing with trend and additive seasonal component.

Call:  
HoltWinters(x = y)

Smoothing parameters:  
alpha: 1  
beta: 0  
gamma: 1

Coefficients:

```
[,1]
a 139877.3438
b 169.0152
s1 5257.5021
s2 11665.0771
s3 3197.4563
s4 -1468.3187
s5 -3141.0938
s6 -4183.2729
s7 -2584.7604
s8 -3286.4021
s9 -3875.3562
s10 -1512.7146
s11 -548.0229
s12 479.9062
```

Error measures:

|              | ME       | RMSE     | MAE      | MPE       | MAPE     | MASE      | ACF1      |
|--------------|----------|----------|----------|-----------|----------|-----------|-----------|
| Training set | 461.1763 | 10326.45 | 5651.177 | -5.940628 | 32.42977 | 0.6508329 | 0.2581866 |

sources : Auteur, Rtsudio

### Annexe 7 : Paramètres du modèle CES

Time elapsed: 0.47 seconds  
Model estimated: CES(p)  
a0 + ia1: 2+1i  
b: 0  
Initial values were produced using backcasting.  
  
Loss function type: likelihood; Loss function value: 2415.0299  
Error standard deviation: 9722.011  
Sample size: 228  
Number of estimated parameters: 4  
Number of degrees of freedom: 224  
Information criteria:  
          AIC      AICc      BIC      BICc  
4838.060 4838.239 4851.777 4852.264

sources : Auteur, Rtsudio

### Annexe 8 : Paramètres du modèle TBATS

Forecast method: TBATS(0.016, {3,3}, -, {<12,5>})

Model Information:  
TBATS(0.016, {3,3}, -, {<12,5>})

Call: tbats(y = y)

Parameters  
  Lambda: 0.016217  
  Alpha: 0.08801219  
  Gamma-1 Values: -4.444396e-05  
  Gamma-2 Values: 4.916295e-05  
  AR coefficients: 0.588237 0.937011 -0.533789  
  MA coefficients: 0.617816 -0.911367 -0.640662

sources : Auteur, Rtsudio

## Annexe 9 : Paramètres du modèle ETS - SARIMA

Model estimated using `auto.adam()` function: ETS(MNN)+SARIMA(1,0,0)[1](2,0,0)[12] with drift  
Response variable: y  
Distribution used in the estimation: Generalised Normal with shape=1.1065  
Loss function type: likelihood; Loss function value: 2127.722

| Coefficients: |           |            |            |             |   |
|---------------|-----------|------------|------------|-------------|---|
|               | Estimate  | Std. Error | Lower 2.5% | Upper 97.5% |   |
| alpha         | 0.5343    | 0.0568     | 0.4223     | 0.6460      | * |
| phi1[1]       | 0.8499    | 0.0034     | 0.8431     | -0.3500     | * |
| phi1[12]      | 0.2727    | 0.0159     | 0.2413     | 0.0000      | * |
| phi2[12]      | 0.4612    | 0.0165     | 0.4285     | 0.4938      | * |
| level         | 2657.6375 | 258.3441   | 2148.1302  | 3166.3416   | * |
| ARIMASate1    | 1.9024    | 0.1021     | 1.7010     | 2.1035      | * |
| ARIMASate2    | 4.6156    | 0.1072     | 4.4042     | 4.8266      | * |
| ARIMASate3    | 2.8082    | 0.4954     | 1.8312     | 3.7838      | * |
| ARIMASate4    | 2.7369    | 0.8162     | 1.1272     | 4.3440      | * |
| ARIMASate5    | 2.1156    | 1.0243     | 0.0956     | 4.1325      | * |
| ARIMASate6    | 1.7867    | 1.0782     | -0.3397    | 3.9098      |   |
| ARIMASate7    | 1.5000    | 1.0981     | -0.6657    | 3.6623      |   |
| ARIMASate8    | 1.0396    | 0.6625     | -0.2670    | 2.3441      |   |
| ARIMASate9    | 0.8936    | 0.4542     | -0.0023    | 1.7880      |   |
| ARIMASate10   | 0.6357    | 0.1810     | 0.2788     | 0.9921      | * |
| ARIMASate11   | 1.2346    | 0.4433     | 0.3602     | 2.1075      | * |
| ARIMASate12   | 1.5659    | 0.7258     | 0.1344     | 2.9951      | * |
| ARIMASate13   | 1.6652    | 0.9783     | -0.2642    | 3.5916      |   |
| ARIMASate14   | 1.8297    | 0.2667     | 1.3036     | 2.3550      | * |
| ARIMASate15   | 9.1957    | 5.3229     | -1.3020    | 19.6770     |   |
| ARIMASate16   | 6.2311    | 6.9489     | -7.4735    | 19.9140     |   |
| ARIMASate17   | 4.0749    | 3.1606     | -2.1585    | 10.2985     |   |
| ARIMASate18   | 2.6229    | 2.1818     | -1.6801    | 6.9191      |   |
| ARIMASate19   | 1.4236    | 1.3860     | -1.3098    | 4.1527      |   |
| ARIMASate20   | 0.7992    | 0.3441     | 0.1205     | 1.4769      | * |
| ARIMASate21   | 0.4865    | 0.2387     | 0.0158     | 0.9564      | * |
| ARIMASate22   | 0.4485    | 0.0875     | 0.2759     | 0.6208      | * |
| ARIMASate23   | 1.3375    | 0.5110     | 0.3297     | 2.3437      | * |
| ARIMASate24   | 1.4740    | 0.7179     | 0.0581     | 2.8877      | * |
| ARIMASate25   | 2.1012    | 0.4379     | 1.2375     | 2.9636      | * |
| drift         | 1.0106    | 0.0022     | 1.0062     | 1.0150      | * |
| other         | 1.1065    | 0.2889     | 0.5367     | 1.6753      | * |

sources : Auteur, Rtsudio

## Annexe 10 : Paramètres du modèle SSARIMA

y = regression model + arima (1, 0, 1, 0, 1, 1)

Model: RegARIMA - TRAMO/SEATS  
Estimation span: from 1-2004 to 12-2022  
Log-transformation: yes  
Regression model: no mean, no trading days effect, no leap year effect, no Easter effect, no outliers

Coefficients:  
ARIMA:  
Estimate Std. Error T-stat Pr(>|t|)  
Phi(1) -0.76404 0.04808 -15.891 < 2e-16 \*\*\*  
Theta(1) 0.58583 0.05924 9.890 < 2e-16 \*\*\*  
BTheta(1) -0.53317 0.06397 -8.334 9.1e-15 \*\*\*  
---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2562 on 212 degrees of freedom  
Log likelihood = -15.32, aic = 4087, aicc = 4087, bic(corrected for length) = -2.649

sources : Auteur, Rtsudio

## Annexe 11 : Paramètres du modèle X13

y = regression model + arima (1, 0, 1, 0, 1, 1)

Model: RegARIMA - X13  
Estimation span: from 1-2004 to 12-2022  
Log-transformation: yes  
Regression model: mean, no trading days effect, no leap year effect, no Easter effect, no outliers

Coefficients:  
ARIMA:  
Estimate Std. Error T-stat Pr(>|t|)  
Phi(1) -0.68802 0.05464 -12.592 <2e-16 \*\*\*  
Theta(1) 0.59357 0.06067 9.784 <2e-16 \*\*\*  
BTheta(1) -0.60936 0.06089 -10.007 <2e-16 \*\*\*  
---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Regression model:  
Estimate Std. Error T-stat Pr(>|t|)  
Mean 0.15017 0.03703 4.056 6.98e-05 \*\*\*  
---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2492 on 211 degrees of freedom  
Log likelihood = -10.01, aic = 4078, aicc = 4079, bic(corrected for length) = -2.68

sources : Auteur, Rtsudio

## Annexe 12 : Paramètres du modèle Naïve

```
y = regression model + arima (1, 0, 1, 0, 1, 1)

Model: RegARIMA - TRAMO/SEATS
Estimation span: from 1-2004 to 12-2022
Log-transformation: yes
Regression model: no mean, no trading days effect, no leap year effect, no Easter effect, no outliers

Coefficients:
ARIMA:
      Estimate Std. Error  T-stat Pr(>|t|)
Phi(1)   -0.76404    0.04808  -15.891 < 2e-16 ***
Theta(1)  0.58583    0.05924   9.890 < 2e-16 ***
BTheta(1) -0.53317    0.06397   -8.334 9.1e-15 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2562 on 212 degrees of freedom
Log likelihood = -15.32, aic = 4087, aicc = 4087, bic(corrected for length) = -2.649
```

sources : Auteur, Rtsudio

## Annexe 13 : Paramètres du modèle Bagged

```
Forecast method: baggedModel

Model Information:
Series: y
Model: baggedModel
Call: baggedModel(y = y)

Error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 278.2243 9392.209 4754.287 -8.933481 24.42226 0.5475401 0.4745423
```

sources : Auteur, Rtsudio

## Annexe 14 : Paramètres du modèle STS

```
Forecast method: Basic structural model

Model Information:

Call:
StructTS(x = y)

Variances:
      level      slope      seas      epsilon
115823573      1179         0         0

Error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 566.4214 10880.57 6225.633 -7.825177 36.65297 0.7169916 0.3211649
```

sources : Auteur, Rtsudio

## Annexe 15 : Paramètres du modèle STL

```
Forecast method: STL + ETS(A,N,N)

Model Information:
ETS(A,N,N)

Call:
ets(y = x, model = etsmodel, allow.multiplicative.trend = allow.multiplicative.trend)

Smoothing parameters:
alpha = 0.9999

Initial states:
l = 2564.5587

sigma: 8724.453

      AIC      AICc      BIC
5379.574 5379.681 5389.862

Error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 513.9088 8686.104 4799.482 -1.26036 33.18252 0.5527452 0.1847326
```

sources : Auteur, Rtsudio

## Annexe 16 : Modèle lm1

```
Call:
lm(formula = ILITOTAL ~ BBKCI + BBKGDP + BBKF + Medical_care +
  Mean + Zoonose_sant  + Terme_sant  + Sympt_sant  + Maladie_conco_sant  +
  Pop_moins_16_ans + Pop_plus_55_ans, data = trainingbase)

Residuals:
    Min       1Q   Median       3Q      Max
-20911  -4403   -110    3377   52073

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   24468.219   5633.397    4.343 2.16e-05 ***
BBKCI         -3396.675    966.260   -3.515 0.000535 ***
BBKGDP         466.259    169.964    2.743 0.006594 **
BBKF          -1033.264    606.030   -1.705 0.089637 .
Medical_care   -68.449     14.234   -4.809 2.85e-06 ***
Mean          -208.729    116.883   -1.786 0.075536 .
Zoonose_sant   177.465     74.575    2.380 0.018197 *
Terme_sant     246.196     55.646    4.424 1.53e-05 ***
Sympt_sant    1645.630     95.909   17.158 < 2e-16 ***
Maladie_conco_sant  -636.045    119.452   -5.325 2.53e-07 ***
Pop_moins_16_ans  8.224      3.345    2.459 0.014722 *
Pop_plus_55_ans  8.954      5.474    1.636 0.103367
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8143 on 216 degrees of freedom
Multiple R-squared:  0.8545,    Adjusted R-squared:  0.8471
F-statistic: 115.3 on 11 and 216 DF,  p-value: < 2.2e-16
```

sources : Auteur, Rtsudio

## Annexe 17 : Mod le lm2

```
Call:
lm(formula = ILITOTAL ~ BBKCI + BBKGDP + BBKF + Medical_care +
  PRCP + Mean + Cat _sant  + Terme_sant  + Sympt_sant  +
  Zoonose_sant  + Maladie_conco_sant  + Transportation +
  M dian + Pop_plus_55_ans + Pop_moins_16_ans + Avion + Train +
  Voiture + Commun, data = df_wm)

Residuals:
    Min       1Q   Median       3Q      Max
-20446  -4064   -57    3108   52406

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   1.728e+04  7.996e+03   2.162 0.031789 *
BBKCI         -4.305e+03  1.084e+03   -3.970 9.90e-05 ***
BBKGDP         4.340e+02  1.760e+02    2.467 0.014446 *
BBKF          -1.088e+03  6.883e+02   -1.580 0.115613
Medical_care   -6.042e+01  1.717e+01   -3.518 0.000534 ***
PRCP          -6.990e+00  2.695e+01   -0.259 0.795619
Mean          -1.383e+02  1.294e+02   -1.069 0.286334
Cat _sant      1.510e+02  1.402e+02    1.077 0.282727
Terme_sant      1.685e+02  8.958e+01    1.881 0.061375 .
Sympt_sant      1.568e+03  1.172e+02   13.375 < 2e-16 ***
Zoonose_sant      1.866e+02  7.568e+01    2.466 0.014467 *
Maladie_conco_sant  -5.985e+02  1.307e+02   -4.578 8.09e-06 ***
Transportation  1.871e+02  1.693e+02    1.106 0.270173
M dian         -9.296e+02  6.701e+02   -1.387 0.166802
Pop_plus_55_ans  8.835e+00  5.571e+00    1.586 0.114293
Pop_moins_16_ans 7.158e+00  3.446e+00    2.077 0.039004 *
Avion          1.123e-04  3.440e-04    0.326 0.744437
Train          -1.779e-05  3.838e-05   -0.464 0.643433
Voiture        2.811e-02  3.985e-02    0.705 0.481373
Commun         9.480e-02  1.474e-01    0.643 0.520869
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8173 on 208 degrees of freedom
Multiple R-squared:  0.8589,    Adjusted R-squared:  0.846
F-statistic: 66.62 on 19 and 208 DF,  p-value: < 2.2e-16
```

sources : Auteur, Rtsudio



## Annexe 18 : Modèle ArX

```
Series: Yt
Regression with ARIMA(3,0,0) errors

Coefficients:
      ar1      ar2      ar3      BBKCI      BBKGDP      BBKF      Medical_care      Mean      Terme_santé      Sympt_santé      Zoonose_santé
0.8166 -0.3082 0.2196 -1418.9052 260.8202 -701.8177 -29.8584 -36.5171 130.4642 1356.479 225.1821
s.e. 0.0757 0.1060 0.0818 918.5826 163.3947 1058.9537 11.2824 117.2856 50.9826 110.419 86.5659
      Maladie_conco_santé      Pop_plus_55_ans      Pop_moins_16_ans
-263.7002 11.2634 4.6381
s.e. 115.9689 3.2547 1.9797

sigma^2 = 39709487: log likelihood = -2311.38
AIC=4652.77 AICc=4655.03 BIC=4704.21

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 48.51149 6105.013 3758.499 -0.5868795 32.29745 0.6064665 -0.005932944
```

sources : Auteur, Rtsudio

## Annexe 19 : Modèle ArmaX avec auto.arima

```
Series: Yt
Regression with ARIMA(2,0,3) errors

Coefficients:
      ar1      ar2      ma1      ma2      ma3      intercept      Terme_santé      Sympt_santé      Zoonose_santé      Maladie_conco_santé      Pop_plus_55_ans
0.5135 0.4468 0.2898 -0.5324 -0.3893 -12627.374 113.7342 1317.8565 232.6190 -203.4296 10.0791
s.e. 0.3303 0.3119 0.3138 0.0994 0.1254 4065.202 50.4314 114.3093 80.5253 106.9538 3.2844
      Pop_moins_16_ans
4.1112
s.e. 1.9803

sigma^2 = 38762744: log likelihood = -2309.93
AIC=4645.86 AICc=4647.56 BIC=4690.44

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -68.45427 6059.917 3694.88 -1.866418 31.63759 0.596201 0.007569508
```

sources : Auteur, Rtsudio

## Annexe 20 : Modèle ArmaX sans auto.arima

```
Series: Yt
Regression with ARIMA(1,0,0) errors

Coefficients:
      ar1      Medical_care      Terme_santé      Sympt_santé      Zoonose_santé      Maladie_conco_santé      Pop_plus_55_ans      Pop_moins_16_ans
0.7151 -32.0113 126.1549 1376.4079 239.3066 -239.6835 10.0063 4.6945
s.e. 0.0495 6.3160 49.3834 101.7155 83.3316 106.7193 3.5726 2.1367

sigma^2 = 40798387: log likelihood = -2317.56
AIC=4653.12 AICc=4653.94 BIC=4683.98

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 69.10994 6274.302 3829.145 1.72051 32.73992 0.6178659 0.06333638
```

sources : Auteur, Rtsudio

## **Liste des titres des tableaux et graphique**

### **Tableaux :**

- Tableau 1 : Récapitulatifs des paramètres des modèles compartimentales

### **Graphiques :**

- Graphique 1 : Modélisation de la prévision ADAM
- Graphique 2 : Modélisation de la prévision ETS
- Graphique 3 : Modélisation de la prévision HW
- Graphique 4 : Modélisation de la prévision CES
- Graphique 5 : Modélisation de la prévision TBATS
- Graphique 6 : Modélisation de la prévision ETS - SARIMA
- Graphique 7 : Modélisation de la prévision SSARIMA
- Graphique 8 : Modélisation de la prévision Naïve
- Graphique 9 : Modélisation de la prévision Bagged
- Graphique 10 : Modélisation de la prévision STS
- Graphique 11 : Modélisation de la prévision STL

### **Modélisations :**

- Modélisation 1 : Modèle de Régression simple 1
- Modélisation 2 : Modèle ArX
- Modélisation 3 : Modèle ArmaX avec auto.arima
- Modélisation 4 : Modèle ArmaX sans auto.arima

## **Tables des matières**

|                                                                            |           |
|----------------------------------------------------------------------------|-----------|
| <b>Sommaire.....</b>                                                       | <b>I</b>  |
| <b>Chapitre I - Introduction.....</b>                                      | <b>1</b>  |
| <b>Chapitre II - Explication approfondie des modèles sélectionnés.....</b> | <b>2</b>  |
| Section I - Méthodes compartimentales.....                                 | 2         |
| Section II - Les méthodes de séries temporelles.....                       | 4         |
| 1§ - Les méthodes de séries temporelles univariées.....                    | 4         |
| A) Méthodes de lissage exponentielle.....                                  | 4         |
| B) Méthodes de prévision ARIMA.....                                        | 7         |
| C) Méthodes de prévision diverses.....                                     | 9         |
| 2§ - Les méthodes de séries temporelles multivariées.....                  | 13        |
| A) Méthode de Régression.....                                              | 13        |
| B) Méthode ArX.....                                                        | 13        |
| C) Méthode ArmaX.....                                                      | 14        |
| <b>Chapitre III - Conclusion.....</b>                                      | <b>16</b> |
| <b>Annexe.....</b>                                                         | <b>17</b> |
| <b>Liste des titres des tableaux et graphique.....</b>                     | <b>24</b> |
| <b>Tables des matières.....</b>                                            | <b>25</b> |