



UNIVERSITÉ DE NANTES



IAE NANTES
ÉCONOMIE & MANAGEMENT

Master Econométrie et Statistiques, parcours Econométrie Appliquée

Mémoire de Master 1

**Etude comparative et analyse critique des modèles de
prévision des symptômes grippaux aux Etats-Unis
d'Amérique pour l'année 2023**

MOCAER RODOLPHE

Sous la direction de Darne Olivier

Remerciement

Je suis reconnaissant envers ma famille pour son soutien dans la construction et la relecture de mon mémoire.

Je tiens à exprimer ma gratitude à mes amis en général, qui ont facilité les échanges sur mon sujet et ont contribué avec de nouvelles idées ainsi que des suggestions d'amélioration ou de recherche, dans le but d'enrichir continuellement mes études.

Je remercie Darne Olivier pour avoir proposé ce sujet de mémoire.

Note générale

Au préalable de la lecture de cette étude, nous souhaitons préciser que notre étude doit être accessible à un ensemble élargi de lecteurs. Nous faisons le choix de ne pas détailler les modèles économétriques dans le corps du texte dans le but d'une lecture plus fluide et compréhensible par l'ensemble des lecteurs. Les explications des modèles économétriques appliqués, qui demandent une connaissance de base des principes économétriques, se situent dans notre document annexe. Pour toute compréhension plus approfondie, nous vous invitons à lire le document annexe. Ce choix n'impacte pas la compréhension de cette étude.

Sommaire

Sommaire.....	I
Résumé.....	II
Abstract.....	III
Liste de Sigles.....	IV
Chapitre I - Introduction.....	1
Chapitre II - Revue de littérature.....	5
Chapitre III - Caractérisation statistique et analyse des séries chronologiques.....	18
Chapitre IV - Application des modèles prédictifs.....	29
Chapitre V - Comparaison des résultats.....	48
Chapitre VI - Analyse critique.....	54
Chapitre VII - Discussion.....	56
Chapitre VIII - Conclusion.....	58
Annexe.....	60
Liste des titres des tableaux & graphiques & figures & modélisations.....	67
Tables des matières.....	71

Analyse critiques et étude comparative des modèles de prévision des symptômes grippaux aux Etats-Unis d'Amérique en 2023

Résumé

La prévision de l'incidence des symptômes grippaux représente actuellement un défi majeur dans les domaines de l'épidémiologie et de la santé publique, particulièrement aux États-Unis. Notre étude vise à explorer un large éventail de méthodes de prévision, y compris des approches compartimentales et des méthodes de séries temporelles, afin de déterminer la méthode optimale pour prédire au mieux l'incidence des symptômes grippaux. Ce travail repose sur des analyses comparatives visant à éclairer les recommandations de santé publique en phase avec l'évolution de l'épidémie, en prenant comme référence l'année 2023. Au cours de cette recherche, nous avons identifié le modèle de prévision le plus performant. Toutefois, malgré cette identification conduisant à l'établissement d'un modèle rigoureux, certaines faiblesses ont été observées dans notre étude, en contraste avec les nombreux points forts relevés. Par ailleurs, bien que la validité interne semble être assurée, la validité externe reste à être examinée.

Mots clés : Prévision, Incidence, Symptômes grippaux, Etats-Unis, Etude comparatives, Rstudio

Critical Analysis and Comparative Study of Forecasting Models for Influenza Symptoms in the United States of America in 2023

Abstract

The forecasting of influenza symptom incidence currently represents a major challenge in the fields of epidemiology and public health, particularly in the United States. Our study aims to explore a wide range of forecasting methods, including compartmental approaches and time series methods, to determine the optimal method for predicting influenza symptom incidence most accurately. This work is based on comparative analyses aimed at informing public health recommendations in line with the evolution of the epidemic, with the year 2023 serving as a reference point. During this research, we identified the most effective forecasting model. However, despite this identification leading to the establishment of a rigorous model, some weaknesses were observed in our study, contrasting with the numerous strengths identified. Furthermore, while internal validity appears to be assured, external validity remains to be examined.

Keywords : Forecasting, Incidence, Influenza Symptoms, United States, Comparative Study, Rstudio

Liste de Sigles

- OMS : Organisation Mondiale de la Santé
- PIB : Produit Intérieur Brut
- ARIMA (AutoRegressive Integrated Moving Average)
- ARX (AutoRegressive with eXternal variables)
- SIR : Susceptibles - Infectés - Retirés
- SEIRD : Susceptibles - Exposés - Infectés - Rétablis - Décédés
- SEIRDV : Susceptibles - Exposés - Infectés - Rétablis - Décédés - Vaccinés
- HO : Holt-Winters
- MAE : l'erreur absolue moyenne
- MAPE : l'erreur absolue moyenne en pourcentage
- DE : distance euclidienne
- CPS : le score de prédiction cohérent
- RGME : l'erreur de moyenne géométrique relative

Chapitre I - Introduction

Section I - Chronique du virus de la grippe

À travers les époques, la préservation de la santé des populations demeure une priorité essentielle pour toute société. La lutte contre les épidémies s'est avérée être un objectif fondamental, comme en témoignent de nombreux événements tout au long de l'histoire humaine. Tel que pendant les années sombres de 1346 à 1353, où la peste bubonique plus communément appelée peste noire a émergé dans le monde marquant dès lors les débuts de la promotion de l'hygiène comme moyen de lutte contre les épidémies¹. Cependant, cette promotion de la bonne santé notamment exacerbée par les mouvements hygiénistes² pendant la belle époque et les progrès dans le monde de la médecine passant aussi bien des vaccinations, que dans le développement des soins infirmiers modernes introduit notamment par Florence Nightingale³ n'a pas permis d'éradiquer toutes les pathologies passées et modernes. En effet, une pathologie archaïque sévit encore de nos jours, celle de la grippe.

Cette pathologie de la grippe⁴, engendrée notamment par le virus "Myxovirus influenzae", est ancienne, en effet des traces d'épidémies de gripes ont été décrites en -400 après J-C par Hippocrate⁵. Toutefois cette ancienneté de la maladie ne procure pas la peur de cette dernière en effet la grippe est de nos jours dans l'esprit collectif une maladie infectieuse bénigne, se manifestant notamment par des petites céphalées et/ou des rhumes, cependant elle peut être plus mortelle qu'on ne le pense, entraînant anorexie, pharyngites et décès et pouvant être à l'origine d'épidémies macabres et démesurées telle que l'épidémie de grippe espagnole sévissant de 1918 à 1920 conduisant à elle seule 20 à 40 millions de morts⁶. De plus, nous pouvons également citer les épidémies saisonnières causant de nos jours entre 290 000 et 650 000 décès annuel dans le monde.

¹ Kacki, Sacha, et al. « Prévention, pratiques médicales et gestion sanitaire au cours de la deuxième pandémie de peste », Alain Froment éd., Archéologie de la santé, anthropologie du soin. La Découverte, 2019, pp. 119-133. (consulté le 12/04/24)

² Cavé, Isabelle. Les médecins-législateurs et le mouvement hygiéniste, 1870-1914. Diss. Paris, EHESS, 2013.

³ Woodham-Smith, Cecil. "Florence Nightingale, 1820–1910." *AJN The American Journal of Nursing* 51.5 (1951): 354. (consulté le 12/04/24)

⁴ Beby-Defaux, A., et al. "La grippe humaine: aspects virologiques, épidémiologie et diagnostic virologique." *Médecine et maladies infectieuses* 33.3 (2003): 134-142. (consulté le 10/04/24)

⁵ Martin, Paul MV, and Estelle Martin-Granel. "2,500-year evolution of the term epidemic." *Emerging infectious diseases* 12.6 (2006): 976. (consulté le 12/04/24)

⁶ Berche, Patrick. Faut-il encore avoir peur de la grippe?: histoire des pandémies. Odile Jacob, 2012. (consulté le 04/03/24) (consulté le 12/04/24)

Néanmoins, la longévité de ce fléau a permis une meilleure compréhension du virus et notamment de ses sous-types. Cependant de nombreux facteurs entravent la création d'un vaccin durable. En premier lieu, nous pouvons citer la présence de nombreux mécanismes tels que les mutations et/ou le réassortiment génétique permettant aux virus des mutations rapides. En deuxième lieu, sa présence dans des réservoirs animaux tel que les oiseaux et les porcins⁷, permet aux agents pathogènes de prospérer et d'affecter par la suite les humains, la zoonose. Enfin, l'asymptomaticité et la similarité des symptômes avec d'autres pathologies rendent difficile la reconnaissance des patients contaminés par les médecins. Outre ces mécanismes opacifiant la compréhension du virus, de nombreux éléments ont été révélés tout au long de l'histoire. En effet, les facteurs météorologiques favorisant la grippe ont été identifiés depuis le bas Moyen-Âge, cette pathologie nommée "influenza di freddo" ("la grippe du froid")⁸ démontre alors les caractères météorologiques de la grippe et dans un second temps, la mise en évidence des moyens de transmission et des sous-populations les plus à risques. Ainsi, cette identification des facteurs et la compréhension plus approfondie de la structure génétique du virus ont conduit à une meilleure réponse épidémique qu'auparavant, en proposant des vaccinations potentiellement efficaces, ainsi que des recommandations de politique de santé publique⁹.

De ce fait, le suivi épidémiologique passant par des méthodes de prévisions épidémiologiques reste le moyen le plus efficace afin d'adapter au mieux les réponses et recommandations de politique de santé publique dans le but de limiter la propagation des symptômes grippaux.

⁷ Vagneron, Frédéric. "Surveiller et s'unir?. Le rôle de l'OMS dans les premières mobilisations internationales autour d'un réservoir animal de la grippe." *Revue d'anthropologie des connaissances* 9.9-2 (2015). (consulté le 13/04/24)

⁸ Buisson, Yves, Elisabeth Nicand, and Pierre Saliou. *La grippe en face*. Xavier Montauban SA, 2007. (consulté le 13/04/24)

⁹ World Health Organization. *Préparation et action en cas de grippe pandémique: document d'orientation de l'OMS*. Organisation mondiale de la Santé, 2009. (consulté le 13/04/24)

Section II - Objectif de l'étude comparative et de l'analyse critique

Ainsi, nous nous demanderons quelle méthode de prévision offre une meilleure précision et efficacité parmi celles analysées pour anticiper les fluctuations de l'incidence des symptômes grippaux en 2023 aux États-Unis ? De ce fait afin de répondre à cette problématique, nous décidons donc d'effectuer une analyse critique et une étude comparative des méthodes sélectionnées au préalable par nous-même, passant aussi bien des méthodes de prévisions stochastiques univariées que multivariées à des méthodes de prévisions déterministes univariées que multivariées. C'est dans ces conditions, que nous avons fait le choix de sélectionner comme variables dépendantes¹⁰ l'incidence mensuelle des symptômes grippaux et non la mortalité, la létalité ou la prévalence, car en effet, l'incidence est l'indicateur le plus adéquat dans le suivi des épidémies, il représente ainsi le “nombre de nouveaux cas d'une maladie, pendant une période donnée et pour une population déterminée.”¹¹. Outre cette variable dépendante, nous sélectionnons également des variables indépendantes¹²¹³ présentées ultérieurement, nous permettant dès lors d'appliquer des méthodes de prévisions multivariées. De plus, il nous est important de souligner que nos méthodes de prévisions appliquées dans ce mémoire se baseront sur des données possédant comme période temporelle des observations allant de janvier 2004 à décembre 2022 et comme zone géographique des observations des Etats-unis d'Amérique à un niveau national.

Suite à cette présentation du contexte historique du virus de la grippe et de l'exposition aussi bien de la problématique que de l'objectif de notre étude, il est important de souligner les étapes de notre mémoire. Dans un premier temps, nous exposerons grâce à une revue de littérature les différentes variables indépendantes sélectionnées ainsi que les différentes méthodes appliquées dans notre étude. Dans un second temps, nous étudierons les différentes caractéristiques statistiques et les corrélations de l'ensemble de nos variables. Dans un troisième temps, nous appliquerons les différentes méthodes de prévisions présentées au préalable. Dans un quatrième temps, nous comparerons les différents résultats des méthodes de prévisions grâce à de nombreux indicateurs et tests. Dans un cinquième temps, nous procéderons à l'analyse critique de notre étude, nous permettant ainsi de mettre

¹⁰ <https://gis.cdc.gov/grasp/fluview/fluportaldashboard.html> (consulté le 13/04/24)

¹¹ <https://www.e-cancer.fr/Dictionnaire/I/incidence> (consulté le 13/04/24)

¹² <https://www.ncei.noaa.gov/access/search/data-search/daily-summaries?dataTypes=AWND&dataTypes=PRCP&dataTypes=RHAV&dataTypes=TAVG&pageNum=6> (consulté le 13/04/24)

¹³ <https://fred.stlouisfed.org/categories> (consulté le 13/04/24)

en lumière les différentes forces et faiblesses de notre étude. Dans un sixième temps, nous discuterons de nos résultats, en les interprétant et nous indiquant dès lors des recommandations dans la lutte contre les épidémies. Pour finir, nous conclurons de nos principaux résultats en les résumant.

Chapitre II - Revue de littérature

Dans une rigueur scientifique, nous expliquerons au préalable aussi bien l'importance des variables étudiées (dépendante et indépendantes) que les méthodes de prévisions exploitées dans notre étude.

Section I - Variables étudiées

Dans un premier temps, nous présenterons notre variable dépendante, ce qui nous permettra d'appliquer l'ensemble de nos méthodes univariées. Ensuite, nous passerons à l'explication des variables indépendantes, nécessaires pour pouvoir appliquer les méthodes de prévisions multivariées.

1§ -Variable dépendante / L'incidence des symptômes grippaux

L'incidence est un indicateur décisif dans le domaine de l'épidémiologie. En effet, cet indicateur calculant le nombre de nouveaux cas d'une maladie dans une population donnée pendant une période donnée comme expliqué au préalable. Elle est primordiale dans le suivi des pathologies infectieuses. De ce fait, elle permet d'identifier les tendances émergentes et dès lors d'adapter les stratégies de santé publique en conséquence. Ainsi, la collecte systématique des données d'incidence joue un rôle essentiel dans la mise en place de mesures proactives pour atténuer l'impact des maladies infectieuses¹⁴. Ainsi, l'importance de l'incidence dans le domaine de l'épidémiologie a poussé en 1947 l'OMS (Organisation Mondiale de la Santé) à institutionnaliser le suivi épidémiologique de certaines pathologies infectieuses¹⁵ grâce à la mise en place d'un programme de surveillance virologique telle que le suivi de la grippe¹⁶.

Cependant, qualifier cela de suivi épidémiologique de la grippe est inexact. En effet, des recherches ont établi que la majorité des cas de grippe sont asymptomatiques, comme en témoigne une étude révélant qu'environ 77 % des cas de grippe ne présentent pas de

¹⁴Berche, Patrick. Une histoire des microbes. Montrouge: John Libbey Eurotext, 2007. Print. (consulté le 14/04/24)

¹⁵<https://www.who.int/fr/campaigns/75-years-of-improving-public-health/milestones#year-1945> (consulté le 14/04/24)

¹⁶ <https://gis.cdc.gov/grasp/fluview/fluportaldashboard.html> (consulté le 7/04/24)

symptômes grippaux¹⁷. Par conséquent, il semble difficile de surveiller efficacement la grippe sans effectuer de tests généralisés permettant de détecter ces cas asymptomatiques et contagieux. Le système de surveillance sanitaire aux États-Unis plus communément appelé le “Center for Disease Control and prevention” repose sur quatre principes fondamentaux visant à suivre au mieux l'évolution de la grippe. Ces principes comprenant un suivi virologique des patients pour classifier les différentes souches virales de la grippe, un suivi par groupe d'âge des visites en ambulatoire chez les prestataires de soins de santé pour les cas potentiels de grippe, un suivi hospitalier de la grippe et enfin un suivi de la mortalité liée à la grippe. C'est grâce à la combinaison de ces différents types de surveillance que le suivi épidémiologique de l'évolution de la grippe peut être efficace¹⁸.

L'établissement de ce réseau de suivi épidémiologique de la pathologie de la grippe, nous offre la possibilité de suivre l'incidence des symptômes grippaux grâce notamment au suivi par groupe d'âge des visites en ambulatoire chez les prestataires de soins de santé pour les cas potentiels de grippe expliqué plus tôt. Cette approche nous permettra d'effectuer une analyse approfondie ainsi que des prévisions des données épidémiologiques. Ainsi, notre référence pour l'incidence des symptômes grippaux repose sur ce système national de surveillance de la grippe aux États-Unis.

2§ - Variables indépendantes

Suite à l'introduction de notre variable dépendante, l'incidence des symptômes grippaux, nous pouvons alors introduire et mettre en lumière l'importance des variables indépendantes sélectionnées.

A) Les variables démographiques


Depuis le 19^e siècle, la population américaine n'a cessé de croître de manière soutenu, passant de plus de 5 millions en 1800 à 341,5 millions en 2024, multipliant sa population par 68 en à peine 200 ans¹⁹.

¹⁷Hayward, Andrew C., et al. "Comparative community burden and severity of seasonal and pandemic influenza: results of the Flu Watch cohort study." *The Lancet Respiratory Medicine* 2.6 (2014): 445-454. (consulté le 14/04/24)

¹⁸Centers for Disease Control and Prevention. "US Influenza surveillance: purpose and methods." *US Influenza Surveillance: Purpose and Methods* | CDC (2022). (consulté le 14/04/24)

¹⁹Portes, Jacques. *Histoire des États-Unis depuis 1945*. FeniXX, 1992. (consulté le 15/04/24)

Graphique 1 : Evolution et projection de la population américaine de 1800 à 2100



sources : Auteur, Canva, Our World in data²⁰

Cette croissance démographique significative a inexorablement conduit à de nombreux phénomènes tant démographiques que sociétaux. Parmi ceux-ci, nous pouvons mentionner la centralisation des activités économiques et politiques, l'augmentation des déplacements de populations, qu'ils soient irréguliers ou réguliers, la concentration de la population dans les zones urbaines, l'intensification des contacts sociaux et de la densité de population. Bien que ces phénomènes au premier abord puissent sembler positifs pour toutes nations, ils présentent également des risques pour le monde de la santé et notamment celui de l'émergence de pathologie²¹. En effet, l'ensemble des événements socio-démographiques cités plus tôt ne font qu'accroître le risque de transmissibilité de pathologie infectieuse dont notamment la transmissibilité de la grippe dû à la centralisation des populations²².

Outre l'accroissement général de la population aux États-Unis, la répartition des classes d'âge de la population a également été fortement modifiée (voir graphique 1). En effet, depuis le 20^e siècle, l'espérance de vie et le taux de natalité ont inversement évolué, l'augmentation de l'espérance de vie et la diminution du taux de natalité ont donc entraîné un vieillissement de la population mais également un non renouvellement de la population²³, conduisant alors à l'augmentation de la classe d'âge des 70 ans et plus (passant de 5,7% en 1960 à 10,6% en 2018 de la représentation de la population) et à la diminution de la classe

²⁰<https://ourworldindata.org/grapher/population-long-run-with-projections?time=1800..2100&showSelectionOnlyInTable=1&country=~USA> (consulté le 15/04/24)


²¹ Ledrut, Raymond. Sociologie urbaine. FeniXX, 1979. (consulté le 15/04/24)

²² Gautier, A., and C. Jestin. "De la grippe saisonnière à la grippe pandémique." Gautier A, Jauffret-Roustide M, Jestin C.(sous la dir.) Enquête Nicolle (2006): 167-81.(consulté le 15/04/24)

²³ AHLBURG, Dennis. "La population des États-Unis: un vieillissement démographique en dépit d'une croissance continue." La population du monde: géants démographiques et défis internationaux 149 (2002): 197. (consulté le 15/04/24)

d'âge des 10 ans et moins (passant de 21,4% en 1960 à 12,3% en 2018 de la représentation de la population). Néanmoins ces classes d'âge mises en commun représentent toujours une part importante de la population des Etats-Unis mais de surcroît une part importante de la population plus à risque face à de nombreuses pathologies infectieuses telle que la grippe²⁴. Ainsi la protection de ces classes d'âge en constante augmentation est donc nécessaire afin d'éviter toutes épidémies grippales meurtrières.

Graphique 2 : Evolution des classes d'âges de la population américaine de 1960 à 2018



sources : Auteur, Canva, Perspective Monde²⁵

Afin de mieux comprendre l'évolution de l'incidence des symptômes grippaux, il nous est donc primordial de prendre en considération des indicateurs démographiques tels que l'évolution de la population générale des États-Unis, mais également l'évolution des populations à risque comme les populations "jeunes" (16 ans et moins) et "âgées" (55 ans et plus). Nous devons souligner que le choix de la délimitation de ces classes d'âge est motivé par la disponibilité des données et non par nos propres motivations.

B) Les variables météorologique

L'origine du terme "grippe" est étroitement liée à l'expression italienne du XIIe siècle "influenza di freddo", traduite littéralement par "influence du froid". Cette expression ancestrale témoigne ainsi de la relation entre la saisonnalité et la prévalence du virus de la grippe à des températures plus basses, bien que cette corrélation ne soit plus pleinement corroborée. Cependant, d'autres hypothèses, prenant en considération des variables météorologiques en plus de la température, s'efforcent d'expliquer la récurrence saisonnière des épidémies de grippe. Parmi celles-ci, la diminution de l'ensoleillement entraînant une réduction de la synthèse de vitamine D²⁶ et la baisse de l'humidité atmosphérique

²⁴ [https://www.who.int/fr/news-room/fact-sheets/detail/influenza-\(seasonal\)](https://www.who.int/fr/news-room/fact-sheets/detail/influenza-(seasonal)) (consulté le 15/04/24)

²⁵ <https://perspective.usherbrooke.ca/bilan/servlet/BMPPagePyramide/USA/1989/> (consulté le 15/04/24)

²⁶ Lofgren, Eric et al. "Influenza seasonality: underlying causes and modeling theories." *Journal of virology* vol. 81,11 (2007): 5429-36. doi:10.1128/JVI.01680-06 (consulté le 16/03/24)

(hygrométrie) augmentent possiblement toutes deux le risque de contamination et de transmission du virus de la grippe²⁷.

Ainsi, cette mise en lumière de nouveaux facteurs météorologiques pouvant expliquer la saisonnalité des épidémies de grippe, nous incite donc à prendre en considération en plus de la température une des deux nouvelles hypothèses exposées précédemment. Nous décidons d'intégrer essentiellement l'hygrométrie²⁸ au dépend de l'ensoleillement car se basant sur des bases scientifiques plus solides.

C) Les variables de transport

Les relations biotiques entre différents organismes, qu'ils relèvent du règne animal ou végétal, et les virus peuvent être classifiées sous différentes formes. Elles peuvent être de nature amensalisme, mutualisme, neutralisme, etc. Dans notre étude, nous nous intéresserons principalement aux relations de nature parasitaire entre l'Homme et les virus²⁹. Cette relation peut être décrite ainsi : un individu A (organisme hôte) subit la relation en opposition à un individu B (organisme parasite) qui en profite. Nous pouvons alors citer comme exemple de relation parasitaire connue la relation entre l'Homme et *Yersinia pestis*, ou encore celle entre l'Homme et le *Myxovirus influenzae*, et plus généralement la relation entre le règne animal et le *Myxovirus influenzae*³⁰. Ces relations sont classifiées comme parasites car en fournissant un milieu de reproduction, un accroissement de la longévité et une possibilité d'accroissement de la propagation grâce au mouvement des populations présent, passé et futur, intensifié par les différents types de transport de nos jours, les organismes hôtes reçoivent essentiellement des symptômes pouvant aller jusqu'à la mort. Ainsi, ce sont donc les transports (aérien, maritime, routier) qui propagent les virus, pouvant transformer des épidémies en pandémies.

²⁷ Lowen AC, Mubareka S *et al.* « Influenza virus transmission is dependent on relative humidity and temperature » *PLoS Pathog.* 2007 octobre 19;3(10):1470-6 (consulté le 16/03/24)

²⁸ Vabret, A *et al.* "La grippe saisonnière" [Seasonal flu]. *Pathologie-biologie* vol. 58,2 (2010): e51-7. doi:10.1016/j.patbio.2010.01.009 (consulté le 16/03/24)

²⁹ Roger, Annie. "Etude de la relation parasitaire initiale entre un virus du groupe L 1 de Gourel et une population cellulaire d'*Acholeplasma laidlawii*." *Canadian Journal of Microbiology* 23.3 (1977): 224-229. (consulté le 17/03/24)

³⁰ Brugère-Picoux, Jeanne, Jean-Pierre Vaillancourt, and Jean-Claude Manuguerra. "Les virus influenza animaux et les pandémies de grippe humaine." *Les maladies infectieuses exotiques* (2010): 133. (consulté le 17/03/24)

Afin d'illustrer nos propos, nous pouvons prendre l'exemple de la peste noire. La propagation de ce virus, apparu en 1346 en Asie centrale, a été drastiquement amplifiée grâce à l'homme et notamment aux routes commerciales terrestres (caravanes le long de la route de la soie) et maritimes. En effet, c'est à cause des flux commerciaux en plein essor à cette époque que *Yersinia pestis* a pu entraîner 75 à 200 millions de morts au XIV^e siècle³¹.

La mise en évidence de l'importance des flux humains, notamment des transports de passagers, nous amène donc à prendre en considération les transports aérien, routier, ferroviaire et commun aux États-Unis, car ils peuvent être des facteurs d'explications importants dans nos futurs modèles.

D) Les variables économiques

De nos jours, la santé économique d'un pays peut être représentée comme le reflet de la santé de sa population. Cette corrélation, démontrée par de nombreux articles scientifiques, peut s'expliquer par le fait qu'un pays "riche"³², possédant une économie florissante, puisse allouer une plus grande partie de ses revenus à des domaines qui peuvent être considérés comme secondaires, tels que l'éducation, la santé³³ et la recherche. Cette favorisation de ces domaines permet de nombreuses actions dans la lutte contre les épidémies, notamment celles contre les épidémies saisonnières de grippe. Nous pouvons ainsi citer des actions d'éducation de la population aux gestes barrières, des actions de promotion de la bonne santé multifactorielle passant aussi bien par la prévention, le dépistage et la vaccination. Enfin, nous pouvons citer les actions de recherche visant à minimiser voire à éradiquer les symptômes des pathologies étudiées³⁴.

Outre la santé économique générale d'un pays, le niveau de revenu individuel joue également un rôle crucial dans cet équilibre³⁵. En effet, nous savons qu'aux États-Unis, depuis les années 1986, l'indicateur d'inégalité des revenus (GINI) ne fait qu'augmenter, passant de 37,7 points en 1986 à 41 points en 2013, favorisant ainsi les personnes déjà les

³¹ Vitaux, Jean. Histoire de la peste. PUF, 2015. (consulté le 18/03/24)

³² Geloso, Vincent. "Pourquoi la croissance économique est bonne pour la santé." (2023). (consulté le 18/03/24)


³³ <https://fr.statista.com/statistiques/558805/gouvernement-americain-depenses-du-departement-de-la-sante-et-de-s-services-sociaux/#:~:text=Ainsi%2C%20le%20minist%C3%A8re%20de%20la,billions%20de%20dollars%20en%202020.> (consulté le 18/03/24)

³⁴ Absil, Gaëtan, Chantal Vandoorne, and Michel Demarteau. "Bronfenbrenner, écologie du développement humain. Réflexion et action pour la promotion de la santé." (2012) (consulté le 18/03/24)

³⁵ Atkinson, Tony. "La distribution des revenus dans les pays de l'OCDE au vingtième siècle." *Revue française d'économie* 17.1 (2002): 3-31. (consulté le 18/03/24)

plus démunies. Cette inégalité accroît donc le nombre de personnes les plus à risque face aux épidémies de toutes sortes, notamment la grippe. Il n'est plus à démontrer qu'une personne en situation économique défavorable aura également un risque accru de situations de santé déplorables³⁶. Néanmoins, cette inégalité dans les revenus n'est pas le seul facteur, les indices de prix le sont aussi. Certes, l'augmentation des prix dans le monde de la santé (prix des médicaments, des transports, etc.) jouera donc un rôle défavorable pour les personnes les plus démunies et accroîtra ainsi le risque de contracter des maladies, notamment la grippe.

Graphique 3 : Evolution de l'indice GINI entre 1986 et 2013



sources :Perspective Monde³⁷

La mise en lumière d'une économie florissante au sein d'une nation, conjuguée à une égalité de revenu dans le pays ainsi qu'à la garantie de prix juste dans le domaine de la santé, favorise la lutte contre certaines épidémies telles que la grippe et prévient des pics épidémiques trop élevés. Dans ces conditions, il est donc primordial de prendre en considération des facteurs économiques globaux tels que les indicateurs de croissance économique, de développement, ainsi que les tendances économiques futures du pays, mais également les indicateurs de prix dans les secteurs des transports et de la santé.

E) Les variables informationnel

Depuis les années 1940 et l'avènement d'Internet avec George Stibitz de Bell³⁸, une abondance d'informations dans divers domaines tels que l'économie, la santé, la démographie, etc., est désormais aisément accessible à tous. Par conséquent, la nécessité de posséder des ouvrages ou de consulter des documents ou des spécialistes sur des sujets particuliers n'est

³⁶ Rochaix, Lise, et Sandy Tubeuf. « Mesures de l'équité en santé. Fondements éthiques et implications », *Revue économique*, vol. 60, no. 2, 2009, pp. 325-344. (consulté le 18/03/24)

³⁷<https://perspective.usherbrooke.ca/bilan/servlet/BMTendanceStatPays?codePays=USA&codeStat=PMQUAN&DL.GINI.V1&codeTheme=2> (consulté le 18/03/24)

³⁸ Flichy, Patrice. *L'imaginaire d'Internet. La découverte*, 2012.(consulté le 19/03/24)

plus aussi impérative. De nos jours, la recherche d'information se fait principalement en ligne, ce qui est devenu un réflexe commun. Cette tendance s'applique également au domaine de la santé. Par exemple, si un individu présente des symptômes de rhume, de toux ou de douleurs musculaires, la première réaction est désormais de chercher en ligne plutôt que de consulter immédiatement un médecin³⁹. Ainsi, pour toute pathologie, nous commençons par enquêter sur Internet sur les causes de ces symptômes avant d'envisager de consulter un professionnel de santé^{40,41}.

Dans ce contexte, nous avons entrepris d'analyser les tendances de recherche afin d'évaluer la possibilité de prédire à l'avance l'incidence des symptômes grippaux. Pour ce faire, nous avons examiné cinq types de recherches en ligne. Ces catégories comprennent : les individus ayant manifesté un intérêt pour les sujets ou catégories liés aux gripes et aux rhumes ; ceux ayant manifesté un intérêt pour les termes « Flu » et « Influenza » ensemble (« flu + influenza ») ; ceux ayant manifesté un intérêt pour les symptômes de la grippe (« fièvre + toux + mal de gorge + douleurs + maux de tête + nez qui coule ») ; ceux ayant manifesté un intérêt pour les maladies similaires à la grippe (« rhume + pneumonie + bronchite + bronchiolite + gastro-entérite virale + sinusite ») ; et enfin ceux ayant manifesté un intérêt pour les zoonoses ou la grippe animale (« h5n1 + h1n1 + h5n8 + h3n2 »). Nous tenons à souligner que toutes ces données ont été recueillies grâce au site Google Trends⁴².

³⁹ Main, Guillaume. "Google prédit les épidémies de grippe." (2009). (consulté le 19/03/24)

⁴⁰ Dugas, Andrea Freyer, et al. "Influenza forecasting with Google flu trends." *PloS one* 8.2 (2013): e56176. (consulté le 19/03/24)

⁴¹ Saporta, Gilbert. "Quelle statistique pour les Big Data?." *Statistique et Société* 5.1 (2017). (consulté le 19/03/24)

⁴² <https://trends.google.fr/trends/> (consulté le 04/03/24)

Section II - Méthodes prédictives

Après avoir brièvement exposé les variables dépendantes et indépendantes, nous pouvons maintenant introduire l'ensemble des méthodes prédictives que nous avons choisi d'évaluer dans cette étude.

1§ - Les méthodes des analogues

Le mot « analogie », venant du grec "ἀνάλογος", qui signifie "qui est en rapport avec, proportionnel", est la correspondance entre des phénomènes différents régis par des équations similaires. Ce terme et cette réflexion sur l'analogie ont permis de construire un nouveau raisonnement dans le domaine scientifique, notamment en épidémiologie : le raisonnement analogique⁴³, et notamment la méthode des analogues que nous allons utiliser dans cette étude. Cette méthode consiste en une approche prédictive reposant sur le principe de prédire l'avenir en s'appuyant sur les données historiques. Elle s'avère particulièrement efficace dans la projection de l'incidence des symptômes de la grippe⁴⁴. Nous pouvons décomposer cette méthode en trois étapes distinctes⁴⁵.

1. Identification des analogues : L'objectif de cette phase est d'identifier les épidémies présentant des similitudes avec les données historiques les plus récentes. Ces similitudes peuvent être évaluées en fonction de divers critères tels que la saisonnalité, la population touchée et la réponse publique. Pour ce faire, plusieurs mesures mathématiques peuvent être utilisées comme indicateurs de similarité afin de repérer les épidémies analogues. Notamment, la distance euclidienne est couramment employée.

2. Analyse des analogues : Une fois les épidémies similaires identifiées, l'analyse des données associées à ces épidémies est entreprise pour comprendre leur évolution. Cela peut inclure l'étude des tendances des analogues, la gravité des pics épidémiques, etc.

⁴³ Richard Taillet, Loïc Villain et Pascal Febvre, Dictionnaire de physique, Bruxelles, De Boeck, 2013, p. 25 « Analogique ». (consulté le 10/03/24)

⁴⁴ Nau, Jean-Yves. "La crise financière et l'épidémiologiste." *Thérapeutique* 179.41 (2008): 2484-2484. (consulté le 10/03/24)

⁴⁵ Viboud C, Boëlle PY, Carrat F, Valleron AJ, Flahault A. Prediction of the spread of influenza epidemics by the method of analogues. *Am J Epidemiol*. 2003 Nov 15;158(10):996-1006. doi: 10.1093/aje/kwg239. PMID: 14607808. (consulté le 10/03/24)

3. Extrapolation des analogues : En se fondant sur les données issues de l'analyse des épidémies similaires, on extrapole les résultats pour estimer la propagation et l'évolution potentielles de la maladie dans le futur. La méthode de prévision la plus simple consiste à prendre la moyenne des résultats des analogues.

Figure 1 : Schéma récapitulatif de la méthode des analogues




sources : Auteur, Canva,

2§ - Les méthodes compartimentales

Depuis 1927, et principalement grâce aux travaux d'Anderson Gray Mckendrick et de William Ogilvy Kemarch, un nouveau modèle de prévision épidémiologique a émergé : celui des modèles compartimentaux, accompagné du développement d'une nouvelle science, celle des réseaux⁴⁶. Ces modèles reposent sur des principes fondamentaux, tels que la segmentation de la population étudiée en classes épidémiques, définies notamment par les stades de développement de la maladie étudiée, ainsi que sur des règles de déplacement des populations entre les différents compartiments, représentées notamment par les différents taux (taux de mortalité, de guérison, etc.) (voir modélisation 1). De plus, dans le but de modéliser l'évaluation des épidémies, cette méthode de prévision repose sur une représentation mathématique des modèles, illustrée notamment par des équations différentielles (voir figure 2)⁴⁷. Afin d'illustrer nos propos, nous pouvons prendre comme exemple un modèle SI, c'est-à-dire susceptible infecté.

Modélisation 1 : Visualisation du modèle SI



sources : Auteur, Canva, Figure 2

⁴⁶ Toutain, P. L., and A. Bousquet-Mélou. "Les modèles compartimentaux." Cours de pharmacocinétique-ENV Toulouse(2007). (consulté le 12/03/24)

⁴⁷ Miralles, Nicolas De Ro. "Le Modele SIR: Analyse Déterministe et Stochastique." (2021). (consulté le 12/03/24)

Figure 2 : Équations différentielles et paramètres initiaux du modèle SI

$$\begin{cases} \frac{dS}{dt} = -\frac{1}{N} \times (\beta \times S \times I) \\ \frac{dI}{dt} = \frac{1}{N} \times (\beta \times S \times I) \end{cases}$$

Avec :

- S : représentant la population susceptible.
- I : représentant la population infectée, infectueuse et symptomatique.
- β : représentant le taux de transmission.

Paramètres initiaux :

$$\begin{cases} S = S_0 = N \\ I = 0 \end{cases}$$

sources : Auteur, Overleaf

Cette représentation permet dès lors de comprendre l'évolution mais également les différentes recommandations à appliquer afin de gérer au mieux les épidémies. Enfin, ce modèle se base sur différentes hypothèses initiales telles que la supposition de l'homogénéité de la population (toute la population possède les mêmes caractères biologiques tels que l'âge, le genre, etc.), l'absence de déplacement des individus et enfin l'absence de pro-activité de la population dans la lutte contre la maladie infectieuse étudiée. Il est important de souligner que ces hypothèses peuvent être levées en implémentant de nouvelles caractéristiques aux modèles compartimentaux de base.

3§ - Les méthodes de séries temporelles divers

Dans le cadre de l'évolution humaine, l'humanité a progressivement affiché un intérêt accru pour la prédiction de données variées, couvrant un large éventail de domaines tels que la météorologie, l'économie et l'épidémiologie. Cependant, ce n'est qu'au XXe siècle, avec l'avènement de l'informatique et des statistiques, que des méthodes plus formalisées ont émergé, telles que la régression linéaire et les séries temporelles. Cette évolution a engendré une gamme de techniques de prévision, comme les modèles ARIMA et le lissage exponentiel, qui ont prospéré grâce au développement des capacités informatiques permettant la mise en œuvre de modèles plus complexes⁴⁸. Ces méthodes peuvent être classées en deux catégories distinctes : d'une part, les méthodes univariées qui reposent sur l'utilisation d'une seule variable, et d'autre part, les méthodes multivariées. En combinant ces deux approches, nous sommes en mesure de comparer différents outils de prévision et de déterminer le plus efficace

⁴⁸ Meuriot, Véronique. "Histoire des concepts des séries temporelles." Histoire des concepts des séries temporelles(2012): 1-232. (consulté le 12/03/24)

pour analyser et interpréter de manière efficace les données temporelles, notamment dans le contexte des épidémies de grippe⁴⁹.

A) Les méthodes de séries temporelles univariées

Nous avons pris la décision de choisir cinq catégories bien définies, notamment en fonction de leurs approches de modélisation et de leurs principales caractéristiques en matière de méthodes de prévision univariée⁵⁰. Ainsi, nous avons retenu des méthodes de prévision de moyenne mobile et de lissage, des méthodes basées sur les modèles ARIMA, des approches reposant sur la décomposition structurelle, une méthode d'ensemble et d'agrégation, et enfin des méthodes s'appuyant sur des modèles complexes⁵¹.

1. Méthodes de moyenne mobile et de lissage : Ces méthodes se concentrent principalement sur la prise en compte des tendances et des variations saisonnières de la série étudiées en lissant les données historiques.

2. Méthodes basées sur les modèles ARIMA : Elles se basent sur la modélisation de la série temporelle à l'aide d'une combinaison linéaire de différents éléments tels que ses valeurs passées, des erreurs passées et des saisons passées.

3. Méthodes basées sur la décomposition structurelle : Elles décomposent la série temporelle en ses composantes fondamentales telles que la tendance, la saisonnalité et les composantes irrégulières.

4. Méthodes d'ensemble et d'agrégation : Ces méthodes combinent plusieurs modèles de prévision pour produire une prévision agrégée.

5. Méthodes basées sur des modèles complexes : Ces méthodes utilisent des modèles plus sophistiqués et souvent plus flexibles pour capturer les structures de données complexes telles que les changements de régime, les effets de longue mémoire ou les schémas saisonniers non standards.

⁴⁹ Grenier, Jean-Yves, and Alexandre Mathis. "Séries temporelles, structure et conjoncture: le prix du blé à l'époque moderne." *Histoire & Mesure* (1991): 51-76. (consulté le 12/03/24)

⁵⁰ Tatsa, Sylvestre. "Modélisation et prévision de la consommation horaire d'électricité au Québec: comparaison de méthodes de séries temporelles." (2014). (consulté le 12/03/24)

⁵¹ Gouriéroux, Christian, and Alain Monfort. *Séries temporelles et modèles dynamiques*. FeniXX, 1995. (consulté le 12/03/24)

B) Les méthodes de séries temporelles multivariées

Dans le but de compléter l'approche des méthodes de prévision des séries temporelles univariées, nous avons décidé de prendre en considération les méthodes de séries temporelles multivariées en tenant compte des variables indépendantes présentées précédemment. Nous avons décidé de catégoriser nos méthodes en 4 types. Ainsi, nous avons les méthodes heuristiques ou de base, les méthodes de régression, les méthodes de prévision ARIMA et enfin les méthodes de prévision ARX.

1. Méthodes de régression : Elles utilisent des techniques de régression pour modéliser la relation entre la variable cible (la série temporelle à prévoir) et un ensemble de variables explicatives.

2. Méthodes de modélisation ARIMA (AutoRegressive Integrated Moving Average) : Elles se basent sur la modélisation des composantes autoregressives et de moyenne mobile de la série temporelle, ainsi que sur l'intégration pour gérer les tendances non stationnaires.

3. Méthodes de modélisation ARX (AutoRegressive with eXternal variables) : Ces méthodes ARX sont similaires aux méthodes ARIMA mais se concentrent sur les dépendances séquentielles sans considérer la saisonnalité.

Chapitre III - Caractérisation statistique et analyse des séries chronologiques.

Suite à l'examen de la littérature et à l'explication des différents modèles exploités dans cette étude, nous sommes dès lors en mesure d'analyser les statistiques descriptives. Nous présenterons d'abord un récapitulatif des variables sélectionnées, les statistiques descriptives de la variable dépendante, puis celles des variables indépendantes, et enfin nous analyserons les corrélations.

Tableau 1 : Récapitulatif de l'ensemble de nos variables
(indépendantes et dépendante)

Nom de la variable	Correspondance Rstudio	Description	Sources	Nom de la variable	Correspondance Rstudio	Description	Sources
Incidence de la grippe	Ilitotal	Nombre de nouveau cas de grippe détecté par mois	Fluview	Population de plus de 55 ans	Pop_plus_55_ans	Population des plus de 55 ans au USA	FRED
Indicateur économique de croissance	BBKCI	Calculé à partir des indices économiques tel que l'emploi, la vente en détail, ...	FRED	Population de moins de 16 ans	Pop_moins_16_ans	Population des moins de 16 ans au USA	FRED
Indicateur de l'état économique actuel	BBKGDP	Mesure du PIB	FRED	Transport aérien	Avion	Mesure le nombre total de miles parcouru par les passagers	FRED
Tendances économique futur	BBKF	Calculé à partir d'indicateurs économiques avancés	FRED	Transport ferroviaire	Train	Mesure le nombre total de miles parcouru par les passagers	FRED
Indice de prix de santé	Medical_care	Mesure des variations de prix dans le secteur de la santé (prix soin de santé, prix pharmaceutique, ...)	FERD	Transport routier	Voiture	Mesure le nombre total de miles parcouru par les véhicules	FRED
Indice des prix Transport	Transportation	Mesure des variations de prix dans le secteur des transports (achats de voiture, essence, prix du ticket de métro, ...)	FRED	Transport public	Commun	Mesure le nombre total de passager	FRED
Indices des prix moyen	Médian	Mesure des variations de prix des biens et services pour les ménages médians	FRED	Intérêt de recherche à la catégorie grippe	Caté_santé	Intérêt de recherche pour la catégorie grippe dans le domaine de la santé	Google trends
Précipitation	PRCP	Précipitation en dixième de millimètre	NCEI	Intérêt de recherche aux termes Flu & Influenza	Terme_santé	Intérêt de recherche pour les termes : "flu, influenza"	Google trends
Température moyenne	Mean	Température en degrés Celsius	NCEI	Intérêt de recherche aux symptômes de la grippe	Sympt_santé	Intérêt de recherche pour les termes : "fever, aches, runy nose, ..."	Google trends
Population Globale	Pop_globale	Population globale des USA	FRED	Intérêt de recherche aux grippe animale	Zoonose_santé	Intérêt de recherche pour les termes : "H1N1, H5N8, ..."	Google trends
				Intérêt de recherche aux maladies similaires à la gripe	Maladie_conco_santé	Intérêt de recherche pour les termes : "pneumonia, bronchitis, sinusitis, ..."	Google trends

sources : Auteur, Canva


Nous tenons à souligner que nous avons délibérément choisi de ne pas éliminer ni altérer les valeurs extrêmes. Notre dessein est de préserver la représentativité des données et de ne pas fausser l'évolution de l'incidence des symptômes grippaux en atténuant considérablement les pics épidémiques. Ainsi, nous aspirons à conserver les informations cruciales que peuvent fournir ces points atypiques, en reconnaissant que leur préservation peut influencer les prévisions et la stabilité du système.

Section I - Analyse statistiques de l'incidence des symptômes grippaux

Au préalable de l'analyse statistique, il est primordial de débiter par une étude graphique approfondie. Cela nous permettra de mieux comprendre l'évolution de notre série dépendante, à savoir l'incidence des symptômes grippaux. En examinant attentivement le

graphique 4, nous pouvons constater une saisonnalité marquée de cette série, caractérisée par des pics épidémiques récurrents chaque année, principalement observés en janvier. Par ailleurs, une tendance générale à l'augmentation des pics épidémiques se dégage, soulignant une intensification progressive, débutant notamment à partir de 2017. Enfin, des événements significatifs se dessinent dans le graphique, notamment l'épidémie de grippe H1N1, qui se révèle comparable à celle de 2018, marquée par un pic prépondérant avant l'accroissement des pics épidémiques à partir de 2017. Par ailleurs, la période post-pandémie de la COVID-19 se distingue par une diminution des cas, tant de COVID-19 que de grippe, grâce à l'instauration de mesures de confinement et à la promotion active de la santé et de l'hygiène.

Graphique 4 : Evolution de l'incidence de la grippe au USA de 2004 à 2023 Y_t



sources : Auteur, Rstudio

1§ - Propriété de stationnarité de Y_t

Nous pouvons dès lors analyser les propriétés statistiques de l'incidence des symptômes. Pour ce faire, nous utiliserons principalement des tests statistiques, tels que le test ADF (Dickey-Fuller-Augmenté) dans le but de déterminer la stationnarité de notre série, ou bien le test de Shapiro afin de déterminer la normalité ou la non-normalité de la distribution de notre série dépendante.

Tableau 2 : Résultat du test ADF pour notre série Y_t

	Incidence de la grippe
Statistique du test	-4,329
Retards	6
Peritique	0,01


sources : Auteur, Canva, Annexe 1

En analysant les résultats du test ADF présentés dans le tableau 2, cela nous permet de statuer sur la stationnarité de notre série. Nous pouvons remarquer une valeur critique de 0,01, nous indiquant la stationnarité ($P_{critique} < 0,05$) de notre série brute sans différenciation (Y_t). Par conséquent, notre série possède un ordre d'intégration d'ordre 0. Nous pouvons alors conclure que notre série temporelle n'implique pas de tendance systématique, de variations cycliques ou de changements dans la variance au fil du temps. Nous pouvons donc étudier les statistiques descriptives de notre série stationnaire d'ordre 0 : Y_t .

2§ - Statistiques descriptives de Y_t

Suite à la vérification de la stationnarité de notre série brute, nous pouvons à présent analyser les statistiques descriptives de notre série Y_t dans le but de mieux comprendre les tendances centrales, sa distribution et sa dispersion.

Graphique 5 : Boîte à moustache de notre série Y_t



sources : Auteur, Rstudio

La visualisation de notre série Y_t sous la forme d'une boîte à moustaches nous permet de mettre en lumière la dispersion de nos données. L'examen du graphique 5 nous démontre une présence significative de valeurs extrêmes principalement situées au-dessus du troisième quartile, représentant notamment les pics épidémiques pour chaque année. Ainsi, ces valeurs sont logiquement beaucoup plus élevées que l'ensemble des autres données. Cette distribution des valeurs extrêmes pourrait influencer positivement notre moyenne. L'analyse de la boîte à moustaches nous a permis de pré-examiner la dispersion de notre série stationnaire brute ; néanmoins, une analyse plus poussée grâce à des indicateurs statistiques nous permettra de mieux appréhender les tendances centrales et la dispersion de nos données.

Tableau 3 : Statistique descriptive de notre série Y_t

	Incidence de la grippe
Min	731
Q1	5921
Médiane	11200,52
Moyenne	17635,96
Q3	205553,09
Max	157020,75
Variance	20824,7
Ecart-type	433668123,02

sources : Auteur, Canva, Annexe 2

L'examen du tableau 3 nous permet de mieux comprendre les tendances centrales de notre série Y_t . Dans un premier temps, nous pouvons remarquer que la moyenne est plus élevée que la médiane d'environ 600 points, confirmant ainsi l'analyse de l'influence des valeurs extrêmes. Dans un second temps, nous notons une très large plage de données équivalente à 156 2899. Par la suite, nous identifions des valeurs de variance et d'écart-type très élevées. Ces deux indicateurs nous indiquent une dispersion très importante dans nos

données. Par conséquent, les résultats de l'analyse des tendances et de la dispersion suggèrent que la distribution pourrait sembler non uniforme. Il est donc crucial de comprendre la loi statistique qui pourrait mieux représenter la distribution de nos données.


Tableau 4 : Indicateur et test de notre série Y_t

Test	Skewness	Kurtosis	Valeur Statistique	P-value
Y_t	3.26	14.49	0.67	0

sources : Auteur, Canva, Annexe 3

L'étude du tableau 4 nous permet dès lors de saisir la distribution de notre série Y_t . La skewness de 3,26 souligne une asymétrie positive des données, suggérant une queue de distribution plus longue à droite. La kurtosis élevée et positive (14,49) met en évidence la leptokurticité de Y_t . Dans ces conditions, nos valeurs sont donc fortement concentrées à gauche avec une queue de distribution étendue à droite par rapport à une distribution gaussienne. Ces deux indicateurs nous permettent d'appuyer l'hypothèse de non-normalité de la distribution de notre série ; néanmoins, nous décidons d'appliquer le test de Shapiro dans le but de vérifier de manière rigoureuse l'assimilation ou non de la distribution de notre série à une distribution normale. Nous observons une P_{value} associée au test de Shapiro fortement inférieure à 0,01, nous montrant ainsi la non-normalité de la distribution de notre série brute. Dans un souci de rigueur scientifique, nous nous efforcerons d'identifier la loi de distribution sous-jacente de notre série à l'aide d'une visualisation graphique. Il convient de souligner que nous avons normalisé nos observations afin de représenter un ensemble de lois de distributions sur un même graphique.

Graphique 6 : Comparaison de la distribution de Y_t avec plusieurs lois de distributions statistiques



sources : Auteur, Rstudio

En analysant le graphique 6, il est clair que notre série brute Y_t présente une grande disparité avec une distribution gaussienne, mais montre une similitude avec une distribution sous-jacente exponentielle.

Résumé :

Cette étude, nous permet de communiquer la stationnarité de notre série brute et de la non-normalité de la distribution de cette dernière. Cependant, nous choisissons de ne pas effectuer de transformation afin d'éviter toute perte d'information, complexité supplémentaire et difficulté d'interprétation.

Section II - Analyse statistiques de nos variables indépendantes

Suite à l'analyse statistique de notre série dépendante, nous pouvons désormais appliquer la même démarche à nos séries indépendantes. Ainsi, nous commencerons par étudier la stationnarité de nos séries, puis nous examinerons les statistiques descriptives de nos variables indépendantes.

1§ - Propriété de stationnarité de nos séries indépendantes

Nous décidons alors d'appliquer le test ADF à nos séries indépendantes afin de vérifier l'ordre de stationnarité de nos séries. Il est à noter que si la nécessité de différenciation se présente, nous ajouterons l'observation "décembre 2003" dans le but d'éviter de prendre une observation de l'année 2004.

Tableau 5 : Résultats du test ADF de nos séries indépendantes

	Série brute Peritique	Série différencié Peritique		Série brute Peritique	Série différencié Peritique
BKCI	0,010	x	Pop_-16ans	0,951	0,010
BKGGDP	0,010	x	Avion	0,063	0,010
BKGF	0,010	x	Train	0,344	0,010
Medical_care	0,010	x	Voiture	0,420	0,010
Transportation	0,605	0,010	Commun	0,059	0,010
Médian	0,957	0,010	Caté_santé	0,010	x
PRCP	0,010	x	Terme_santé	0,010	x
Mean	0,010	x	Sympt_santé	0,010	x
Pop_globale	0,990	0,370	Zoonose_santé	0,010	x
Pop_+55ans	0,990	0,010	Maladie_conco_santé	0,010	x

*x : variables ne subissant pas de différenciation car étant stationnaire sans.

sources : Auteur, Canva, Annexe 4 à 5

En examinant le tableau 5 et plus spécifiquement la première colonne, nous soulignons qu'il existe autant de variables brutes stationnaires (11) que non-stationnaires (9) à un ordre de 0. Toutes nos séries stationnaires d'ordre 0 sont significatives au seuil de risque de 1%. Face à ces résultats sur la stationnarité de nos séries, nous choisissons de différencier une première fois nos séries non-stationnaires. Après une différenciation, nous observons que la plupart de nos variables différenciées deviennent stationnaires au seuil de risque de 1%, à l'exception de la variable

"pop_globale". De ce fait, nous décidons d'écarter cette variable dans l'application des méthodes de prévision afin d'éviter de lui appliquer une seconde différenciation. Cet écartement ne devrait pas avoir un impact significatif sur la prévision des modèles multivariés étant donné que les variables "pop_+55ans" et "pop_-16ans" sont toujours conservées permettant ainsi maintenir des variables démographiques.

2§ - Statistiques descriptives de nos séries indépendantes

Suite à l'analyse de la stationnarité de l'ensemble de nos séries et à la différenciation de celles-ci, nous sommes désormais en mesure d'examiner de manière rigoureuse les statistiques descriptives de nos séries indépendantes.

Tableau 6 : Statistique descriptive de nos séries indépendantes

	Min	Median	Mean	Max	Var		Min	Median	Mean	Max	Var
BBKCI	-13	0	0	4	2	Pop_-16ans	-1503	5	1	819	33537
BBKGDP	-69	2	2	46	58	Avion	-47.10 ⁶	258291	112999	12.10 ⁶	2,012.10 ¹³
BBKF	-7	-1	0	3	1	Train	-27.10 ⁷	385943	-68428	103.10 ⁶	8,18.10 ¹⁴
Medical_care	326	559	450	576	4895	Voiture	-350213	1620	-805	54809	1,27.10 ⁹
Transportation	-18	1	0	12	1	Commun	-59170	-59	98	37130	4,84.10 ⁷
Médian	-3	0	0	2	1	Caté_santé	11	24	27	100	153
PRCP	0	33	36	121	435	Terme_santé	2	9	13	100	216
Mean	4	19	19	31	50	Sympt_santé	7	23	27	100	288
Pop_globale	-55	200	186	274	3491	Zoonose_santé	0	1	2	100	85
Pop_+55ans	-582	162	162	1488	13092	Maladie_conco_santé	15	34	37	100	194

sources : Auteur, Canva, Annexe 6

En analysant le tableau 6, nous pouvons conclure quant aux tendances centrales et à la distribution de chaque série. Nous pouvons identifier deux groupes au sein de nos séries indépendantes. Le premier groupe est composé des variables de transport ("Avion", "Train", "Voiture" et "Commun"), tandis que le deuxième groupe est constitué des autres variables. Dans le premier groupe, il semble ne pas y avoir de tendance centrale, comme en témoigne la grande différence entre la moyenne et la médiane. De plus, une plage de données étendue est observée, ainsi qu'une variance excessive, indiquant une forte dispersion des données. À noter que le premier groupe se distingue nettement du deuxième groupe, qui lui présente une tendance centrale plus marquée (moyenne proche de la médiane) et une dispersion moindre.


Résumé :

Cette analyse nous permet ainsi de constater que 11 de nos séries sont stationnaires, tandis que 8 autres nécessitent une différenciation. Nous soulignons que la variable "pop_globale" est exclue de cette différenciation. De plus, il est remarquable que la majorité de nos séries présentent des tendances centrales et des dispersions faibles, à l'exception d'un groupe de variables composé des variables de transport, qui se distingue par son absence de tendance centrale et sa grande dispersion.

Section III - Analyse des corrélations

Suite à l'analyse de l'ensemble de nos données, incluant la variable dépendante et les variables indépendantes, nous sommes maintenant en mesure d'analyser les corrélations entre les différentes variables, en particulier les corrélations entre l'incidence des symptômes grippaux et l'ensemble des variables indépendantes.

Figure 3 : Visualisation des corrélations obtenues



sources : Auteur, Rstudio

En consultant la figure 3, nous pouvons remarquer que la majorité des corrélations sont positives. Néanmoins, elles sont très faibles (la majorité des corrélations sont de couleur pêche), ce qui indique des liens très faibles entre les variables. Cependant, il existe également des corrélations négatives. Nous notons que la corrélation positive la plus forte est entre "Sympt_santé" et "Maladie_conco_santé" (0,9), en opposition à la corrélation négative la plus forte entre les variables "Illtotal" et "pop_globale", ainsi qu'entre "Sympt_santé" et "pop_globale" (-0,77). Cette analyse nous permet donc de mieux comprendre les relations entre l'ensemble de nos bases de données. Cependant, nous allons nous concentrer sur l'analyse des corrélations entre notre variable dépendante et les variables indépendantes dans le but de vérifier les hypothèses de corrélation énoncées dans notre revue de littérature.

Tableau 7 : Récapitulatif des corrélation Obtenues et attendues

	Corrélation attendue	Corrélation obtenue		Corrélation attendue	Corrélation obtenue
BBKCI	Négative	-0,05	Pop_-16ans	Positive	-0,33
BBKGDP	Négative	-0,03	Avion	Positive	0,17
BBKF	Négative	-0,01	Train	Positive	0,1
Medical_care	Positive	0,67	Voiture	ø	0,03
Transportation	ø	0,11	Commun	Positive	-0,05
Médian	Positive	0,02	Caté_santé	Positive	0,73
PRCP	Négative	0,18	Terme_santé	Positive	0,71
Mean	Négative	-0,52	Sympt_santé	Positive	0,88
Pop_globale	Positive	-0,77	Zoonose_santé	Positive	0,22
Pop_+55ans	Positive	-0,09	Maladie_conco_santé	Positive	0,89

*ø :aucune corrélation spécifique est attendue

sources : Auteur, Canva

En examinant le tableau 7, nous pouvons confirmer la validité de nos hypothèses de corrélation énoncées dans notre revue de littérature. Nous remarquons que la plupart de nos hypothèses sont vérifiées, à l'exception de cinq, telles que les variables démographiques, la variable de précipitation, et enfin la variable des transports en commun. Cette disparité peut être aisément expliquée pour la variable Précipitation : bien que le virus de la grippe préfère un environnement sec, il est plus actif pendant les mois d'hiver, lorsque les précipitations sont les plus fortes. Cependant, pour les autres variables, l'explication semble plus complexe. Une analyse plus approfondie de la littérature scientifique nous permettrait de comprendre cette différence.

Résumé :

Cette analyse nous a permis de confirmer la validité de la plupart de nos hypothèses de corrélation. Cependant, pour certaines variables, une étude plus approfondie de la littérature est nécessaire.

Chapitre IV - Application des modèles prédictifs

Suite à l'analyse statistique de l'ensemble de notre base de données et des corrélations, nous pouvons dès à présent appliquer nos méthodes de prévision sélectionnées. Dans un premier temps, nous utiliserons la méthode des analogues, puis les méthodes compartimentales, et enfin les méthodes de séries temporelles univariées et multivariées.

Section I - Méthodes des analogues

Nous débutons notre application de la méthode des analogues à l'identification des séries les plus similaires aux 6 derniers mois de l'année 2022. Pour ce faire, nous décidons d'utiliser la distance euclidienne afin de déterminer les analogues. Nous pouvons donc écrire mathématiquement la distance euclidienne telle que :

Figure 4 : Calcule mathématique de la distance euclidienne

$$|p' - p| = \sqrt{(x' - x)^2 + (y' - y)^2}$$


Avec : $x \in [0 : 213]$

$y \in \mathbb{N}$

sources : Auteur

Il est essentiel de souligner que les variables p et p' représentent des vecteurs de dimension 6, et non des points isolés. De plus, p contient les données des 6 derniers mois de l'année 2022, tandis que p' englobe tous les autres vecteurs potentiellement analogues de taille 6. Cette distinction nous a permis d'identifier 8 vecteurs similaires à p . Par la suite, une fois ces analogies établies, nous avons sélectionné les 12 mois suivants, que nous avons nommés séries analogues de chaque vecteur similaire, dans le but de les analyser en vue de prévoir l'année 2023. Cette analyse nous a permis d'identifier des tendances de type "chainettes" qui correspondent bien à l'évolution annuelle de l'incidence des symptômes grippaux. Sur cette base, nous avons pu prédire l'année 2023. Nous émettons l'hypothèse que ces 8 séries pourraient représenter la continuité du vecteur p . Par conséquent, nous avons décidé de calculer une moyenne des 8 séries afin de déterminer l'évolution de l'incidence des symptômes grippaux pour l'année 2023. Nous obtenons alors une prévision représentée dans le graphique 7.


Graphique 7 : Prédiction de l'incidence de la grippe pour l'année 2023 à l'aide de la méthode analogue (Prise en compte de 8 séries analogues)



sources : Auteur, Rstudio

En analysant le graphique, nous constatons que la courbe de prédiction pour l'année 2023 illustre clairement une tendance de type « chaînette ». Toutefois, durant les mois de novembre et décembre, l'incidence des symptômes grippaux demeure constante, sans évolution apparente. Cette stabilité, inhabituelle pour l'évolution de l'incidence des symptômes grippaux, nous conduit à reconsidérer notre approche en réduisant le nombre de séries analogues examinées. Ainsi, nous choisissons de ne prendre en compte que les trois meilleures séries analogues pour notre nouvelle prédiction.

Graphique 8 : Prédiction de l'incidence de la grippe pour l'année 2023 à l'aide de la méthode analogue (Prise en compte de 3 séries analogues)



sources : Auteur, Rstudio

En analysant le graphique 8 et notamment la nouvelle prédiction qui ne prend en compte que les trois meilleures séries analogues, nous pouvons toujours identifier la tendance

de type « chaînette », et nous ne retrouvons plus la constance des valeurs de l'incidence des symptômes grippaux pour la fin de l'année 2023, c'est-à-dire pour les mois de novembre et de décembre. Cette nouvelle prévision semble donc être meilleure ; néanmoins, la qualité et la fiabilité des prévisions ne seront étudiées qu'ultérieurement.

Résumé :

La méthodologie des analogues, comprenant une phase d'identification, d'analyse et de prévision, nous a permis de générer deux projections pour l'année 2023, chacune est basée respectivement sur 8 puis 3 séries analogues sélectionnées. La deuxième prévision semble être la plus réaliste.

Section II - Méthodes compartimentales

Nous sommes désormais prêts à mettre en œuvre les méthodes compartimentales. Dans un premier temps, nous opterons pour le modèle le plus basique (SIR : Susceptibles - Infecté - Retiré), puis nous le complexifierons progressivement en intégrant différents compartiments pour refléter la sophistication croissante de la grippe et de ses aspects, notamment la vaccination.

Au préalable de l'application de cette méthode, il est crucial de définir avec précision les caractéristiques des modèles utilisés, notamment leur capacité à prédire des courbes en forme de cloche. Ces méthodes prévoient en effet une augmentation progressive des cas, atteignant un sommet avant de décroître progressivement à mesure que la maladie est maîtrisée. De ce fait, il est impératif de sélectionner le point de départ en fonction de l'incidence la plus basse de l'épidémie. Ainsi, nous décidons de prendre pour point de départ le mois d'août 2022, ce qui nous permettra alors de prédire jusqu'au mois de juillet 2023. Pour les mois suivants, nous effectuerons une seconde prévision afin de déterminer les prochains mois à partir de l'incidence prédite de juillet 2023. Cette logique nous permettra de prendre en considération au mieux les caractéristiques typiques de l'évolution des épidémies de grippe, possédant des pics pour les mois de janvier et décembre. De plus, nous soulignons que nous avons décidé de rendre nos données mensuelles en quotidienne afin de pouvoir utiliser au mieux les méthodes compartimentales et que nos taux restent réalistes et cohérents avec la réalité. De ce fait, nous avons utilisé la méthode d'interpolation de Lagrange, nous permettant de répondre à notre besoin. Enfin, nous notons que ce modèle ne prend pas en compte la différence entre les infectés symptomatiques et asymptomatiques, ce qui pourrait poser des problèmes dans la modélisation de notre épidémie. Ainsi, nous décidons de transformer nos données, notamment notre incidence initiale représentant les patients symptomatiques, en y ajoutant les patients asymptomatiques, qui représentent alors 77%¹⁷ des infectés. Ensuite, nous appliquerons la transformation à nos prévisions afin de retrouver notre incidence de personnes symptomatiques. Nous intégrerons cette méthodologie dans nos modèles compartimentaux pour maintenir un niveau de rigueur scientifique élevé⁵².

⁵² <https://rpubs.com/mahdi/601181> (consulté 10/03/24)

1§ - Le modèle SIR

Au terme de l'explication des transformations et de la logique sous-jacente aux modèles compartimentaux, nous sommes désormais prêts à mettre en œuvre le modèle le plus fondamental, à savoir le modèle SIR (Modélisation 2). Ce dernier se compose de trois compartiments : les individus Susceptibles (S), les individus Infectés (I), et enfin les individus Retirés (R), englobant les personnes décédées ou ayant guéri. De surcroît, ce modèle est caractérisé par deux taux distincts : le taux de transmission (bêta), reflétant notamment la contagiosité de l'épidémie, et le taux de retrait (gamma), regroupant à lui seul les taux de guérison et de létalité. Cette modélisation, nous permettra alors de prédire de manière simpliste l'évolution de l'incidence des symptômes grippaux.


Modélisation 2 : Visualisation du modèle SIR



sources : Auteur, Canva, Annexe 7

Dans le but d'obtenir les paramètres modélisant au mieux l'évolution de notre épidémie, étant donné que nous commençons notre épidémie le 1er août 2022, nous possédons donc les observations pour les premières prévisions. Nous décidons alors, dans un premier temps, d'appliquer un modèle d'optimisation des différents taux afin de minimiser les écarts entre les valeurs prédites et les valeurs observées pour les 154 premiers jours. Néanmoins, ayant obtenu des modélisations peu fiables, nous optons pour une nouvelle approche moins fiable mais plus efficace que l'optimisation mathématique : l'ajustement des différents taux par tâtonnement et visualisation graphique. Nous obtenons alors 0.5141 pour le taux de transmission et 0.485 pour le taux de retrait comme meilleurs taux dans la minimisation de l'écart entre les 154 premières observations et les prévisions.


Graphique 9 : Comparaison graphique des données historique de fin 2022 à la prévision par la méthode SIR



sources : Auteur, Rstudio

En analysant le graphique 9, nous pouvons remarquer que l'évolution des prévisions de notre série suit de manière précise les tendances des observations. De plus, nous pouvons identifier que les deux pics épidémiques semblent très proches, ce qui démontre un potentiel de bonne prévision. Nous pouvons dès lors passer à la prévision des 5 derniers mois de 2023. Il est important de noter qu'en identifiant une tendance à long terme d'augmentation de 12%, nous avons décidé de prendre en compte cette tendance sous-jacente et donc d'augmenter de 12% la dernière incidence prédite.

Graphique 10 : Prévision de l'incidence de la grippe pour l'année 2023 à l'aide du modèle SIR




sources : Auteur, Rstudio

Ces deux prévisions, une fois additionnées et mensualisées, nous permettent d’avoir une estimation de l’incidence des symptômes de la grippe en 2023. En étudiant le graphique 10, nous remarquons l’évolution caractéristique des épidémies de grippe en forme de « chaînette », ce qui nous permet de confirmer la cohérence de cette prévision avec la réalité. Néanmoins, en dépit de cette modélisation qui semble correcte, l’évolution réelle des symptômes grippaux ne semble pas être en accord avec la modélisation du modèle SIR. Dans ces conditions, nous décidons donc de prendre en considération deux nouveaux compartiments afin de mieux refléter les évolutions de la grippe.

2§ - Le modèle SEIRD

Dans ce nouveau modèle (Modélisation 3), nous décidons d'introduire un nouveau compartiment, celui des Exposés (E), et de séparer le compartiment des Retirés en deux nouveaux compartiments : les Rétablis (R) et les Décédés (D). Cette introduction de nouveaux compartiments nous oblige donc à introduire un nouveau taux : le taux d'incubation (zeta), et à séparer le taux de retrait en taux de guérison (gamma) et le taux de mortalité (rho). Ce nouveau modèle plus complexe nous permet de prendre en considération des éléments plus susceptibles d'affecter les évolutions des pathologies, notamment celle de la grippe.

Modélisation 3 : Visualisation du modèle SEIRD




sources : Auteur, Canva, Annexe 8

Nous décidons d’appliquer la même logique de tâtonnement et de visualisation afin de déterminer au mieux les quatre différents taux du modèle. Cependant, nous fixons le taux d’incubation à 0.5, en tenant compte des données de la littérature. De plus, nous décidons de

manière objective qu'environ 9 cas sur 10 aboutissent à une guérison, étant donné que les épidémies de grippe saisonnière sont généralement moins mortelles que certaines épidémies de grippe spécifiques, comme la H1N1 en 2009-2010. Dans ce contexte, nous obtenons un taux de transmission de 0.75, un taux d'incubation de 0.5, un taux de guérison de 0.601, et enfin un taux de mortalité de 0.073.


Graphique 11 : Comparaison graphique des données historique de fin 2022 à la prévision par la méthode SEIRD



sources : Auteur, Rstudio

En analysant le graphique 11, nous observons que le nombre de personnes exposées est significativement plus élevé que celui des personnes infectées symptomatiques et que celui des observations. Cependant, le nombre de personnes infectées semble suivre de manière cohérente l'évolution des observations. De plus, nous remarquons que les pics épidémiques des personnes exposées et des personnes infectées sont très proches, ce qui peut être attribué au taux d'incubation volontairement élevé. Ces pics se rapprochant du pic épidémique observé, cela suggère la fiabilité de notre prévision. Nous procédons ensuite à la seconde prévision pour les 5 mois suivants en suivant la même approche que celle utilisée pour la modélisation SIR.

Graphique 12 : Prédiction de l'incidence de la grippe pour l'année 2023 à l'aide du modèle SIERD




sources : Auteur, Rstudio

Nous avons donc obtenu la prévision de l'année 2023 grâce à la modélisation SEIRD. Nous avons organisé cette prévision en tenant compte de la nature saisonnière de la grippe, afin de garantir sa pertinence. Cependant, bien que la prévision semble être précise, nous avons décidé d'introduire un nouveau compartiment pour rendre la modélisation encore plus réaliste.

3§ - Le modèle SEIRDV

Dans ce dernier modèle (Modélisation 4), nous avons pris en considération un élément crucial lors des épidémies : la vaccination. Nous avons donc introduit un nouveau compartiment pour les individus vaccinés. Bien que la vaccination ne soit pas efficace à 100 %, le taux de transmission persiste. Néanmoins, la vaccination accrue, notamment aux États-Unis, contribue considérablement à réduire la contagion et la sévérité des symptômes grippaux. L'ajout de ce compartiment implique l'introduction de deux nouveaux paramètres : le taux de vaccination (α), représentant le nombre de nouvelles personnes vaccinées, et le multiplicateur (κ) du taux de transmission, qui diminue de manière significative les cas de contamination, induisant ainsi une diminution de ce taux.


Modélisation 4 : Visualisation du modèle SEIRDV



sources : Auteur, Canva, Annexe 9

Nous appliquons la même méthode que celle utilisée pour la méthode SEIRD, mais cette fois-ci nous décidons de l'appliquer également aux taux d'incubation, de guérison et de mortalité. En outre, nous optons pour un taux de vaccination relativement bas, étant donné le manque de prise de conscience quant à la dangerosité de la maladie. Enfin, nous décidons objectivement que la vaccination réduit de moitié le taux de transmission. Ainsi, nous obtenons les valeurs suivantes : 0.75 pour le taux de transmission, 0.5 pour le taux d'incubation, 0.32 pour le taux de guérison, 0.03 pour le taux de mortalité, 0.5 pour le taux de vaccination, et enfin 0.002 pour le multiplicateur du taux de transmission.

Graphique 13 : Comparaison graphique des données historique de fin 2022 à la prévision par la méthode SEIRDV




sources : Auteur, Rstudio

L'analyse du graphique 13 révèle que la tendance générale du compartiment des personnes infectées semble être conforme. Cependant, la diminution semble être retardée,

possiblement due à la complexité accrue du modèle et de la méthode employée pour optimiser les paramètres. Malgré cela, les pics épidémiques semblent être proches, pouvant nous confirmer le potentiel du modèle dans la prévision de l'incidence des symptômes grippaux. Par la suite, nous pouvons modéliser les 5 derniers mois.

Graphique 14 : Prévision de l'incidence de la grippe pour l'année 2023 à l'aide du modèle SIERD



sources : Auteur, Rstudio

En réunissant les prévisions du modèle SEIRDV, nous obtenons dès lors les prévisions de l'année 2023 qui sont structurellement correctes, mais avec une phase épidémique beaucoup plus forte en janvier qu'en décembre.

Résumé :

Les méthodes compartimentales étudiées telles que SIR, SEIRD et SEIRDV nous ont permis de modéliser de manière plus complexe et réaliste les véritables rouages de l'évolution d'une épidémie, en prenant notamment en compte la vaccination dans le dernier modèle. De plus, nous pouvons affirmer la bonne structure des prévisions pour les 3 modèles.

Section III - Les méthodes de séries temporelles

Dans l'objectif de compléter l'application des méthodes de prévision, nous abordons désormais la dernière méthode, celle des séries temporelles. Nous entamerons notre analyse pour les méthodes de séries temporelles univariées en vérifiant la présence ou non de tendances saisonnières dans notre série. Ensuite, nous pourrions appliquer les différentes méthodes de prévision univariées.

1§ - Les méthodes de séries temporelles univariées

A) Saisonnalité & décomposition

Nous procédons à la vérification de la saisonnalité de notre série à l'aide de plusieurs tests, chacun ayant pour hypothèse nulle l'absence de saisonnalité dans notre série temporelle. Les résultats de ces tests nous permettront de décider quant à la nécessité d'application d'une décomposition saisonnière pour examiner la tendance sous-jacente. Cependant, étant donné notre objectif de prédire l'incidence de la grippe, nous privilégions le maintien de notre série de données brute pour améliorer la précision de nos prévisions. Ainsi, nous utilisons ces tests principalement pour mieux appréhender l'évolution générale de notre série temporelle.


Tableau 8 : Résultat des test de saisonnalité

Test	Valeur Statistique	P-value
Seasonnal - Dummies	3,746	$6,5.10^{-5}$
Friedman	104,709	0
Kruskal - Wallis	98.419	0
QS - test	1	$4,5.10^{-6}$
QS - test robuste	NA	0,0127
Koenker - Basset	NA	0

sources : Auteur, Canva, Annexe 10

En étudiant les résultats des tests dans le tableau 8, nous observons que tous nos tests de saisonnalité rejettent l'hypothèse nulle au seuil de risque de 1%, à l'exception du QS-test robuste qui la rejette au seuil de risque de 5%. Néanmoins, tous les tests concordent pour souligner l'importance d'appliquer une désaisonnalisation afin d'analyser les tendances sous-jacentes de notre série temporelle.


Graphique 15 : Schéma de décomposition de l'incidence des symptôme grippaux



sources : Auteur, Rstudio

Suite à la désaisonnalisation, nous obtenons un schéma de décomposition de l'incidence des symptômes grippaux, ce qui nous permet de mieux comprendre les évolutions et caractéristiques de notre série. De plus, cela nous offre une vérification de l'analyse effectuée lors des statistiques descriptives. L'analyse du graphique 15 nous permet d'apercevoir que notre série possède une tendance sous-jacente ascendante et des cycles saisonniers annuels très forts. De plus, nous pouvons également remarquer que l'année 2009-2010 a été atypique, notamment par son pic d'irrégularité marqué. Cette atypicité peut s'expliquer notamment par l'épidémie de grippe H1N1.

Graphique 16 : Comparaison d'avant et après la désaisonnalisation




sources : Auteur, Rstudio

Nous pouvons également comparer les données ajustées et brutes, ce qui nous permet d'obtenir un nouveau moyen de confirmation du schéma de décomposition. Ainsi, en considérant le graphique 16, nous pouvons confirmer la tendance ascendante et l'atypicité notable de l'année 2009-2010, ainsi qu'une irrégularité depuis les années 2020.

B) Prédiction de méthode divers

Suite à l'analyse de la saisonnalité qui nous a permis de mieux comprendre notre série déjà bien comprise, nous pouvons dès lors appliquer diverses méthodes de prédiction. Nous notons que nous utilisons les observations brutes mensuelles, étant donné que les observations ajustées nous permettent essentiellement de comprendre les tendances sous-jacentes et non l'évolution saisonnière de l'incidence des symptômes grippaux. Dans un premier temps, nous appliquons les méthodes de prédiction en dehors des méthodes de lissage exponentiel.

Graphique 17 : Prédiction de 2023 de l'incidence des symptômes grippaux aux USA à l'aide de méthode divers sans désaisonnalisation




sources : Auteur, Rstudio

À partir de l'analyse du graphique 17, il apparaît que la majorité des prévisions semblent suivre la structure caractéristique de l'évolution saisonnière des épidémies de grippe, à l'exception notable de la prévision naïve et STS. Par ailleurs, il est à noter que la méthode bagged présente le pire scénario en soumettant des prévisions de l'incidence des symptômes grippaux au-dessus des autres, tandis que la méthode X-13 prévoit un scénario d'évolution moins agressif.

C) Prédiction de méthode de lissage exponentiel et ARIMA

Nous pouvons dès lors appliquer l'ensemble des méthodes de lissage exponentiel ainsi que les modèles ARIMA pour finaliser notre étude des prévisions univariées.

Graphique 18 : Prédiction de 2023 de l'incidence des symptômes grippaux aux USA à l'aide de méthode de lissage exponentiel sans désaisonnalisation



sources : Auteur, Rstudio

L'examen du graphique 18 révèle que l'ensemble des prévisions issues des méthodes de lissage exponentiel et ARIMA suit de manière plus ou moins proche la structure saisonnière caractéristique de l'évolution de l'incidence des symptômes grippaux, présentée sous forme de "chaînette". Par ailleurs, nous soulignons que la méthode HO (Holt-Winters) propose le scénario le plus pessimiste, en opposition au modèle SSARIMA qui offre une perspective plus optimiste. Enfin, nous remarquons la présence de scénarios plus stables, notamment avec les méthodes ETS ou CES, prédisant ainsi une évolution constante de l'incidence des symptômes grippaux.

2§ - Les méthodes de séries temporelles multivariées

Suite à l'application des méthodes de prévision univariée, nous pouvons alors utiliser les méthodes de prévision multivariée afin de conclure l'utilisation des méthodes de séries temporelles.

A) Pré - Sélection des variables

Notre modèle comporte 22 variables présentées dans notre revue de littérature, incluant à la fois des variables météorologiques et économiques. Ainsi, pour obtenir le

meilleur modèle, nous décidons d'utiliser des méthodes de sélection de variables afin de choisir les plus pertinentes pour expliquer et prévoir l'incidence des symptômes grippaux aux États-Unis. À cet effet, nous optons pour l'application de 4 méthodes de sélection de variables : "Both", "Forward", "Backward" et BeSS".

Tableau 9 : Comparaison des résultats des différents type de sélection

	RSE	Ddl	R ²	R ² ajustée	F-statistique	P-value Fstatistique	Nbr variables	Interceps
Both	8143	216	0.8545	0.8471	115.3	< 2.2e-16	11	Oui
Forward	8173	208	0.8589	0.846	66.62	< 2.2e-16	18	Oui
Backward	8143	216	0.8545	0.8471	115.3	< 2.2e-16	11	Oui
BeSS	8109	212	0.8584	0.8484	85.66	< 2.2e-16	15	Oui

sources : Auteur, Canva, Annexe 13 à 14

En analysant le tableau 9, nous constatons que l'ensemble des méthodes possède un bon ajustement des modèles, démontré notamment par les valeurs élevées de R² et de R² ajustées, supérieures à 0,84. De plus, nous pouvons observer que l'ensemble des modèles de prévision proposés rejettent l'hypothèse nulle selon laquelle tous les coefficients du modèle sont nuls. Par conséquent, nous concluons que l'ensemble de ces modèles sélectionnés par les différentes méthodes de sélection de variables sont statistiquement significatifs. Néanmoins, en raison de la qualité et de l'ajustement supérieurs des modèles, nous avons décidé de ne considérer essentiellement le modèle de prévision proposé par la méthode BeSS (Modélisation 5), car il présente les meilleurs indicateurs statistiques, même si faiblement.

Modélisation 5 : Modèle multivariées sélectionné

$$Y_t \sim \beta_0 + \beta_1 \times \text{BBKCI} + \beta_2 \times \text{BBKGDP} + \beta_3 \times \text{BBKF} + \beta_4 \times \text{Mean} + \beta_5 \times \text{Medical_care} + \beta_6 \times \text{Caté_santé} + \beta_7 \times \text{Terme_santé} + \beta_8 \times \text{Sympt_santé} + \beta_9 \times \text{Zoonose_santé} + \beta_{10} \times \text{Maladie_conco_santé} + \beta_{11} \times \text{Transportation} + \beta_{12} \times \text{Median} + \beta_{13} \times \text{Pop_moins_16_ans} + \beta_{14} \times \text{Pop_plus_55_ans} + \beta_{15} \times \text{Voiture}$$

sources : Auteur


Nous obtenons ainsi différents modèles, dont un modèle comprenant 15 variables, réparties comme suit : 6 variables liées à l'économie, 1 à la météorologie, 5 à l'information, 2 à la démographie et enfin 1 aux transports. Cependant, nous ne sélectionnons pas ce modèle comme le modèle final. En

effet, nous appliquons une nouvelle méthode de sélection de variables afin de vérifier s'il s'agit bien du meilleur modèle de prévision.

B) Sélection des variables

Nous décidons dès lors d'appliquer la méthode Leaps, nous permettant de sélectionner le meilleur modèle grâce aux indicateurs tels que le R^2 , le BIC et le CP. Nous appliquons cette méthode de sélection aux modèles déjà pré-sélectionnés par la méthode BeSS.

Graphique 19 : Résultats des différents modèles par la sélection Leaps



sources : Auteur, Rstudio

En étudiant le graphique 19, nous pouvons remarquer que le meilleur modèle, présentant un équilibre optimal entre ajustement et surajustement, est celui comprenant 11 variables. Ainsi, nous décidons de prendre en considération ce modèle pour nos prévisions basées sur les méthodes de prévision multivariées.

Modélisation 6 : Modèle multivariées sélectionné suite à la méthode leaps

$$Y_t \sim \beta_0 + \beta_1 \times \text{BBKCI} + \beta_2 \times \text{BBKGDP} + \beta_3 \times \text{BBKF} + \beta_4 \times \text{Mean} + \beta_5 \times \text{Medical_care} + \beta_6 \times \text{Terme_santé} + \beta_7 \times \text{Sympt_santé} + \beta_8 \times \text{Zoonose_santé} + \beta_9 \times \text{Maladie_conco_santé} + \beta_{10} \times \text{Pop_moins_16_ans} + \beta_{11} \times \text{Pop_plus_55_ans}$$


sources : Auteur, Annexe

Nous obtenons dès lors un modèle composé de 11 variables, comprenant ainsi 4 variables économiques, 1 météorologique, 4 informationnelles et enfin 2 démographiques. Ainsi, ce modèle est donc le plus pertinent et performant dans la prévision de l'incidence des symptômes grippaux.

C) Prévision

Suite à la sélection des variables indépendantes par de nombreuses méthodes de sélection de variables, nous avons obtenu un modèle performant. Ainsi, nous pouvons dès lors appliquer ce modèle sélectionné afin de prédire l'incidence des symptômes grippaux pour l'année 2023 par différentes méthodes de prévision univariées.

Graphique 20 : Prévision de 2023 de l'incidence des symptômes grippaux aux USA à l'aide de méthode multivariées sans désaisonnalisation



sources : Auteur, Rstudio

En étudiant le graphique 20, nous remarquons que l'ensemble semble prédire la même évolution de l'incidence. De plus, nous pouvons remarquer que l'ensemble respecte les caractéristiques structurelles de l'évolution des épidémies de grippe. Par ailleurs, nous notons que la méthode lm1 (prévisions faites avec le modèle sélectionné) propose des prévisions beaucoup plus optimistes, contrairement à lm2 (prévision faite avec l'ensemble des variables) qui propose une évolution de l'incidence plus pessimiste. Cependant, nous observons que pour toutes nos prévisions, l'incidence semble stagner au mois de décembre, ce qui pourrait paraître étrange dans l'évolution de la grippe. Malgré ce point négatif, les prévisions semblent correctes.

Résumé :

La vérification de la saisonnalité de notre série a renforcé les conclusions tirées de l'analyse statistique. Tant les méthodes de séries temporelles univariées que multivariées offrent des prévisions cohérentes avec les tendances observées dans les données historiques sur la grippe, à l'exception du mois de décembre pour les méthodes de prévision multivariées.


Chapitre V - Comparaison des résultats

Une fois que toutes les méthodes de prévision ont été appliquées, nous pouvons alors les analyser et les comparer afin de déterminer la meilleure méthode de prévision sélectionnée dans cette étude. Pour ce faire, nous utiliserons plusieurs méthodes de comparaison. Tout d'abord, nous comparerons nos résultats de manière graphique avec les observations réelles de l'incidence des symptômes grippaux en 2023 aux États-Unis. Ensuite, nous utiliserons des indicateurs statistiques, et enfin, nous ferons usage de tests. Cet ensemble de méthodes nous permettra alors de sélectionner la meilleure méthode.

Section I - Visualisation graphiques

Nous débutons notre étude comparative en utilisant une méthode graphique consistant à examiner de manière détaillée chaque prévision à travers une représentation graphique exhaustive. Cette approche nous permet d'obtenir une vue d'ensemble complète des différentes projections et nous offre la possibilité d'évaluer rapidement et précisément la qualité intrinsèque de chacune d'elles dès le premier regard.

Graphique 21 : Ensemble de prévisions et observation pour l'année 2023




sources : Auteur, Rstudio

En étudiant le graphique 21, nous pouvons immédiatement remarquer que les prévisions constantes notamment proposées par les méthodes de prévision NAIVE, CES, HO ne sont aucunement cohérentes avec l'évolution de l'incidence des symptômes grippaux.

Cependant, pour l'analyse des autres méthodes de prévision, nous décidons de séparer ce graphique en quatre groupes comprenant notamment les quatre grands types de méthodes étudiés dans notre étude, tels que les méthodes analogues, compartimentales, univariées et multivariées.

Graphique 22 : Ensemble de prévisions différencié par méthodes et observation pour l'année 2023



sources : Auteur, Rstudio, Canva

Cette séparation des graphiques nous permet dès lors une analyse plus rigoureuse de chaque méthode de prévision. En examinant les méthodes de prévision analogues, nous pouvons constater que tant la méthode analogique basée sur 8 séries que celle basée sur 3 sous-estiment toutes deux l'incidence de l'épidémie de grippe pour l'année 2023 aux États-Unis. En revanche, pour les méthodes compartimentales, nous observons une surestimation initiale jusqu'au mois de mars, suivie d'une période de sous-estimation jusqu'au mois d'octobre. Par la suite, nous constatons des prévisions plus fidèles à la réalité. Bien que ces deux méthodes suivent la tendance générale des épidémies de grippe, elles ne semblent pas fidèles aux données observées. Ensuite, la méthode univariée présente un bilan plus mitigé. Outre les méthodes NAIVE, CES, HO, qui proposent des évolutions linéaires en désaccord total avec l'évolution historique des grippe, la majorité des méthodes de prévision proposent des scénarios plus pessimistes que la réalité, notamment ETS et Bagged. Seules

deux ou trois méthodes proposent des scénarios plus en accord avec l'évolution réelle de l'incidence des symptômes grippaux en 2023. Enfin, les méthodes de prévisions multivariées proposent les prévisions les plus en accord avec les observations faites en 2023 des symptômes grippaux, à l'exception du mois de février où tous les modèles sous-estiment l'incidence. Néanmoins, ces modèles semblent très performants.

Cette analyse graphique nous a permis de mettre en évidence les modèles nous semblant les plus performants et ceux les moins en accord avec les observations de 2023. Cependant, afin de suivre une rigueur scientifique, nous allons appuyer notre analyse graphique grâce à des indicateurs statistiques nous permettant de confirmer la sélection de la meilleure méthode de prévision dans le contexte de notre étude.

Section II - Indicateurs statistique

Afin de confirmer l'hypothèse selon laquelle les méthodes de prévision multivariées sont les plus efficaces, nous allons nous appuyer sur différentes mesures statistiques telles que l'erreur absolue moyenne (MAE), l'erreur absolue moyenne en pourcentage (MAPE), la distance euclidienne (DE), le score de prédiction cohérent (CPS) et enfin l'erreur de moyenne géométrique relative (RGME) (Voir annexe 15 à 20) Nous tenons à souligner que la qualité des prévisions est évaluée en fonction de la proximité du chiffre à 0 pour les quatre premiers indicateurs, tandis que pour le dernier, un chiffre plus élevé est préférable.

Tableau 10 : Indicateur statistique de qualité des prévisions des différents modèles


	MAE	MAPE	DE	CPS	RGME
Analogie 3	30994	46,24	35824	0,77	0,40
Analogie 8	33359	49,78	25653	0,92	0,43
SIR	13431	50,73	67916	- 1,88	0,30
SEIRD	11093	59,85	126506	- 2,40	0,30
SEIRDV	4230	73,94	183252	- 4,82	0,49
X13	4812	13,06	19244	0,43	0,94
BAGGED	78024	116,43	178124	0,25	2,20
NAIVE	81028	122,03	73341	1,00	2,63
STL	60464	91,34	72681	0,95	2,23
STS	82361	123,43	74240	0,99	2,65

	MAE	MAPE	DE	CPS	RGME
ADAM_SARIMA	35662	53,21	33502	0,78	1,74
ADAM	3956	39,28	64133	- 0,59	0,97
BATS	7899	29,97	57922	- 0,19	1,08
CES	72644	109,52	77208	0,99	2,47
ETS	38427	58,43	89649	0,0023	1,59
HO	81647	122,45	78288	0,998	2,64
SARIMA	13390	23,18	12873	0,66	0,79
SSARIMA	13468	32,21	18727	0,86	1,34
Lm1	2109	17,17	1942	0,26	0,98
Lm2	1821	17,28	360	0,31	0,99
ARMAX1	3350	18,40	27496	0,45	1,11
ARMAX2	5700	22,57	14389	0,47	1,55
ARX	3556	18,63	16810	0,54	1,12

sources : Auteur, Canva, Rstudio

En analysant le tableau 10, nous pouvons dès lors étudier la qualité des différentes méthodes. Dans un souci de rigueur scientifique, nous décidons de ne sélectionner que les méthodes affichant des valeurs inférieures à 5000 comme étant de bonne qualité. Ainsi, nous identifions 7 méthodes efficaces, principalement des méthodes de prévision multivariées telles que ARX, ARMAX1, lm1 et lm2. De plus, nous retrouvons X13, SEIRD et ADAMN parmi celles-ci. Ce premier indicateur confirme donc l'inefficacité des méthodes analogues dans nos conditions. En examinant les autres indicateurs, nous constatons une prédominance des méthodes de prévision univariées, notamment lm2, qui affiche un indice de 360 pour la distance euclidienne et un indice de 0,99 pour le RGME. Cette analyse nous incite donc à privilégier initialement les méthodes de prévision univariées, en particulier les méthodes de régression linéaire, pour prédire au mieux l'incidence des symptômes grippaux. Néanmoins, avant de confirmer que lm2 est le meilleur modèle, nous entreprenons de classer l'ensemble de ces méthodes afin de vérifier la validité de notre hypothèse.

Graphique 23 : Classement des meilleurs méthodes de prévision en fonction d'indicateurs statistique



sources : Auteur, Rstudio

Cette visualisation graphique du classement des méthodes de prévision en fonction d'indicateurs statistiques tels que le MAE ou le MAPE nous permet donc de définir le top 5. Ainsi, nous obtenons alors en 5ème position la méthode ARMAX2, puis ARMAX1, suivies

de ARX et de lm1, et en première position lm2. Ce graphique confirme donc notre hypothèse selon laquelle les méthodes de prévision multivariées, notamment la régression linéaire avec l'ensemble des variables, sont les meilleures. Cependant, nous optons pour la rétention du modèle de régression avec les variables sélectionnées, en accord avec le principe de parcimonie. Celui-ci postule qu'un modèle est d'autant plus efficace et compréhensible qu'il est moins complexe.

Section III - Analyse du meilleur modèle

C'est donc dans cette logique que nous pouvons analyser le meilleur modèle de notre étude comparative dans le contexte de la prévision de l'incidence des symptômes grippaux pour l'année 2023 au Etats-Unis.

Figure 5 : Modélisation du meilleur modèle



sources : Auteur, Miro, Annexe 21

En étudiant la Figure 5, nous pouvons observer que, sur l'ensemble des 20 variables exogènes, seules 11 impactent de manière significative la variable dépendante. De plus, nous observons qu'aucune variable de la catégorie transport n'impacte de manière significative la variable dépendante. Dans cet ensemble de 11 variables, nous retrouvons donc des variables économiques, démographiques, informationnelles et météorologiques, avec une constante. Cependant, ce groupe de variables indépendantes n'impacte pas de manière similaire la variable expliquée. En effet, certaines variables comme Mean (la température) impactent négativement la variable expliquée, contrairement à Pop + 16 qui impacte positivement. Cela peut s'expliquer par le fait qu'une augmentation de 1 unité de Mean conduira à une diminution de Beta-Mean, l'incidence des symptômes grippaux, et

inversement pour les variables positives. Ainsi, ce modèle nous permet de formuler des recommandations pour lutter contre ce virus. En effet, selon ce modèle, il serait pertinent de réduire les coûts des prix dans le domaine de la santé, car toutes les autres variables influençant notre variable dépendante sont inhérentes à l'action humaine ou posent des problèmes éthiques lorsqu'il s'agit d'agir sur certaines d'entre elles, comme les variables démographiques. Par conséquent, les politiques de santé déjà en place, telles que la vaccination et la promotion de la santé, demeurent des recommandations majeures dans la lutte contre les épidémies de grippe.

Résumé :

Cette visualisation graphique et l'analyse des indicateurs statistiques nous permettent de définir les méthodes de prévision multivariées comme la meilleure technique de prévision dans notre contexte, celui de la prévision de l'incidence des symptômes grippaux pour l'année 2023. De plus, il nous permet d'émettre des recommandations grâce aux modèles trouvés.

Chapitre VI - Analyse critique

En procédant à une analyse critique de nos études, nous pouvons aisément retrouver les forces mais également les faiblesses de cette dernière.

Pour les forces, nous pouvons en citer plusieurs. Notamment la richesse de notre base de données, nous permettant de capturer au mieux la réalité de la vie des Américains en prenant en compte un nombre important de variables. Cette diversité est primordiale pour comprendre les différents facteurs pouvant influencer l'évolution des symptômes grippaux. De plus, nous pouvons citer l'important nombre de méthodes de prévision, nous permettant non seulement de comparer les résultats obtenus, mais aussi de déterminer la méthode la plus efficace. Également, nous pouvons citer notre étude des statistiques descriptives rigoureuses qui nous ont permis d'appréhender au mieux l'évolution de l'incidence des symptômes grippaux, mais également les relations entre cette dernière et l'ensemble des variables sélectionnées. L'application d'un processus rigoureux pour la sélection d'un modèle optimal pour les méthodes de prévision multivariées. De même, nous pouvons citer la cohérence de la majorité des prévisions avec la structure et les tendances réelles de l'incidence des symptômes grippaux, validant la pertinence des modèles utilisés et la fiabilité des prévisions. Pareillement, la double vérification pour la comparaison des modèles aussi bien graphique que mathématique de notre assure une validation croisée des résultats, augmentant ainsi la crédibilité et la robustesse des conclusions. Enfin, nous pouvons citer la documentation annexe nous permettant de détailler au mieux l'ensemble des méthodes utilisées, permettant alors la reproductibilité de notre étude. Ainsi, cet ensemble de forces nous a permis de renforcer la pertinence et la prévision, mais également d'assurer des conclusions robustes et fiables de notre étude.

Cependant, outre les nombreuses forces repérées, nous pouvons avancer des potentielles faiblesses à notre étude. Tout d'abord, la non-suppression des points atypiques afin de préserver l'évolution brute de l'incidence peut introduire des biais. Les outliers peuvent influencer de manière disproportionnée les résultats et les prévisions. Néanmoins, ce choix de non-élimination des points extrêmes a été fait de manière réfléchiée et justifiée. Par la suite, nous pouvons citer la méthode des analogues avec une prévision basée sur une simple moyenne qui pourrait être améliorée. D'autres types de prévisions, plus sophistiquées,

pourraient être utilisées. Enfin, l'absence de tests statistiques pour comparer les modèles entre eux pourrait aider à définir le meilleur modèle.

Malgré quelques faiblesses identifiées, l'étude semble crédible et de qualité, avec des résultats valides permettant une conclusion solide et une réponse pertinente à la problématique posée. Ainsi, la validité interne semble bonne grâce à une analyse rigoureuse. Néanmoins, la validité externe reste à vérifier avec d'autres analyses suivant la même méthodologie, mais pour d'autres pays afin de confirmer la généralisation des résultats. Enfin, étant un projet effectué seul, certains biais, tels que le biais de l'observateur, peuvent impacter les résultats. Il serait bénéfique de répéter l'étude avec une équipe de chercheurs pour minimiser ces biais et renforcer les conclusions.

Chapitre VII - Discussion

La démonstration de l'efficacité de la méthode de prévision multivariée, notamment la méthode de régression, comme étant la plus performante, souligne l'importance cruciale de prendre en compte l'intégralité des facteurs socio-économiques, démographiques et environnementaux pour anticiper de manière précise l'incidence des symptômes grippaux aux États-Unis. Cette conclusion met en lumière la nécessité d'établir un système de surveillance exhaustif englobant tous les indicateurs pertinents de ces facteurs. Cette surveillance permettrait une anticipation plus précise de l'évolution des épidémies, offrant ainsi la possibilité de mettre en place des réponses sanitaires efficaces à travers des politiques de santé publique. L'objectif ultime serait de réduire au minimum les pics épidémiques et leurs conséquences sur la santé publique.

Cependant, il convient de noter que cette précision de la prévision pourrait être améliorée en tenant compte d'autres facteurs non abordés dans l'étude, ce qui pourrait éventuellement conduire à des résultats plus probants. En outre, bien que cette méthode de prévision se soit révélée efficace pour prédire l'incidence des symptômes grippaux aux États-Unis, il est possible que son application ne puisse pas être généralisée à l'échelle mondiale. Par conséquent, il serait judicieux d'envisager l'ajout ou la suppression d'autres variables dans la base de données, étant donné les diverses évolutions des épidémies de grippe selon les régions géographiques, les niveaux de revenu des pays, et d'autres indicateurs socio-économiques. Cette approche permettrait d'affiner la précision des prévisions et d'adapter les stratégies de réponse aux particularités de chaque contexte, contribuant ainsi à une meilleure gestion des épidémies de grippe à l'échelle mondiale.

Il serait donc pertinent d'appliquer l'ensemble de ces méthodes à différents pays afin de vérifier la possibilité d'extrapoler les résultats de cette étude à d'autres contextes. De plus, l'ajout d'autres facteurs pourrait potentiellement améliorer les prévisions. Cette approche comparative et inclusive permettrait une analyse plus approfondie de l'efficacité des méthodes de prévision et de leur adaptabilité à diverses situations épidémiologiques. En élargissant la portée de la recherche à des contextes géographiques variés et en explorant l'incorporation de facteurs supplémentaires, nous pourrions affiner notre compréhension des dynamiques de propagation de la grippe et améliorer la pertinence des prévisions, contribuant

ainsi à renforcer les stratégies de prévention et d'intervention en santé publique à l'échelle mondiale.

Chapitre VIII - Conclusion

L'objectif principal de cette étude était de comparer les différentes méthodes de prévision sélectionnées au préalable afin d'estimer au mieux l'incidence des symptômes grippaux en 2023 aux États-Unis. Cette analyse s'appuiera sur des données recueillies sur une période s'étendant de janvier 2004 à décembre 2022.

Dans un premier lieu, à la suite d'une analyse statistique de l'incidence de la grippe et de l'ensemble des variables indépendantes, nous permettant de prendre en considération diverses propriétés statistiques de nos séries telles que la stationnarité, les tendances centrales, les corrélations, etc. Cette démarche nous a permis de mieux appréhender l'évolution structurelle de notre variable dépendante ainsi que les relations entre celles-ci. En conséquence, nous avons décidé de conserver notre série brute dépendante et de retirer une variable de notre base de données, à savoir la "pop_globale".

Suite à cette analyse, nous avons pu appliquer les différentes méthodes de prévision. La méthode des analogues nous a permis d'obtenir deux prévisions. Les méthodes compartimentales nous ont permis d'obtenir trois nouveaux modèles (SIR / SEIRD / SEIRDV), nous permettant dès lors d'obtenir trois nouvelles prévisions. Enfin, les méthodes de prévision de séries temporelles, aussi bien univariées que multivariées, nous ont permis d'obtenir 19 nouvelles prévisions. Cet ensemble de méthodes nous a permis d'obtenir un total de 23 prévisions, toutes réalistes et suivant les caractéristiques de l'évolution de l'incidence de symptômes grippaux.

Une fois les prévisions effectuées, nous avons entamé notre analyse comparative, au cœur de notre étude. Pour ce faire, nous avons pris en compte deux types d'analyses. La première consistait en une analyse graphique des résultats, démontrant une prévision bien plus réaliste avec la méthode de prévision de séries temporelles multivariées. Afin d'analyser de manière plus rigoureuse et scientifique, nous avons appliqué un ensemble d'indicateurs statistiques, tels que le MAE et le CPS, pour classer les différentes prévisions et obtenir un classement final. Les résultats finaux ont révélé une supériorité des prévisions réalisées par les méthodes multivariées, comme l'a montré notre analyse graphique. Grâce à l'identification du modèle le plus efficace pour la prévision de cette épidémie, nous avons pu

formuler certaines recommandations pour limiter son évolution, notamment en réduisant les coûts dans le domaine de la santé. De plus, ce classement nous a permis de répondre à notre problématique initiale : quelle méthode de prévision offre la meilleure précision et efficacité parmi celles analysées pour anticiper les fluctuations de l'incidence des symptômes grippaux en 2023 aux États-Unis ? Ainsi, la méthode de régression réalisée avec l'ensemble des variables de notre base de données s'est avérée être la plus précise et efficace.

Annexe

Annexe 1 : Résultats du test ADF de notre série Y_t

Table: Résultats du test ADF pour la variable y

Statistique	Valeur
Statistique du test	-4.329496
Retars	6.000000
P valeur	0.010000

sources : Auteur, Rstudio

Annexe 2 : Résultats des test statistique de notre série Y_t

Table: Résultats des statistiques de kurtosis, skewness et test de normalité Shapiro-Wilk pour la variable y

Statistique	Valeur
Kurtosis	14.4938762
Skewness	3.2597016
Shapiro-Wilk stat value Y_t	0.6681012
Shapiro-Wilk p-value Y_t	0.0000000
Shapiro-Wilk stat value $1/Y_t$	0.6101393
Shapiro-Wilk p-value $1/Y_t$	0.0000000
Shapiro-Wilk stat value $\log(Y_t)$	0.9880104
Shapiro-Wilk p-value $\log(Y_t)$	0.0535084
Shapiro-Wilk stat value $\sqrt{Y_t}$	0.9049069
Shapiro-Wilk p-value $\sqrt{Y_t}$	0.0000000

sources : Auteur, Rstudio

Annexe 3 : Résultats des statistique descriptive de notre série Y_t

Table: Résumé statistique de la variable y

Statistique	Valeur
Minimum	731
1er quartile	5921
Médiane	11200.52
Moyenne	17635.96
3ème quartile	20553.09
Maximum	157020.75
Écart-type	20824.7
Variance	433668123.02

sources : Auteur, Rstudio

Annexe 4 : Résultats du test de nos séries indépendantes brutes

	P_Value	Val_stat
:-----	-----:	-----:
BBKCI	0.0100000	-4.5069586
BBKGDP	0.0100000	-6.4652575
BBKF	0.0100000	-4.1272384
Medical_care	0.0100000	-4.3033074
Transportation	0.6048974	-1.9310322
Médian	0.9574880	-0.8330682
PRCP	0.0100000	-6.1843050
Mean	0.0100000	-11.7024600
Pop_globale	0.9900000	1.4685933
Pop_plus_55_ans	0.9900000	0.2467374
Pop_moins_16_ans	0.9511667	-0.9038661
Avion	0.0626154	-3.3573741
Train	0.3440743	-2.5519868
Voiture	0.4200337	-2.3711464
Commun	0.0585630	-3.3816884
Caté_santé	0.0100000	-6.0788054
Terme_santé	0.0100000	-5.3277859
Sympt_santé	0.0100000	-4.7116214
Zoonose_santé	0.0100000	-4.3996465
Maladie_conco_santé	0.0100000	-7.4287588

sources : Auteur, Rstudio

Annexe 5 : Résultats du test de nos séries indépendantes différenciés

	P_Value	Val_stat
:-----	-----:	-----:
Transportation	0.0100000	-6.299947
Médian	0.0100000	-6.884014
Pop_globale	0.3702553	-2.489656
Pop_plus_55_ans	0.0100000	-4.815697
Pop_moins_16_ans	0.0100000	-5.900253
Avion	0.0100000	-5.850201
Train	0.0100000	-5.352508
Voiture	0.0100000	-5.998767
Commun	0.0100000	-8.117407

sources : Auteur, Rstudio

Annexe 6 : Résultats des statistique descriptive de nos séries indépendante

	Valeur.min	Valeur.médiane	Valeur.moyenne	Valeur.max	Valeur.variance
BBKCI	-13	0	0	4	2.000000e+00
BBKGDP	-69	2	2	46	5.800000e+01
BBKF	-7	-1	0	3	1.000000e+00
Medical_care	326	449	450	576	4.895000e+03
PRCP	0	33	36	121	4.350000e+02
Mean	4	19	19	31	5.000000e+01
Caté_santé	11	24	27	100	1.530000e+02
Terme_santé	2	9	13	100	2.160000e+02
Sympt_santé	7	23	27	100	2.880000e+02
Zoonose_santé	0	1	2	100	8.500000e+01
Maladie_conco_santé	15	34	37	100	1.940000e+02
Transportation	-18	1	0	12	1.400000e+01
Médian	-3	0	0	2	1.000000e+00
Pop_plus_55_ans	-582	162	162	1488	1.309200e+04
Pop_moins_16_ans	-1503	5	1	819	3.353700e+04
Avion	-47373673	258291	112999	12448753	2.011588e+13
Train	-269665224	385943	-68428	103382118	8.184993e+14
Voiture	-350213	1620	-805	54809	1.268325e+09
Commun	-59170	-59	98	37130	4.838277e+07

sources : Auteur, Rstudio

Annexe 7 : Équations différentielles et paramètres initiaux du modèle SIR

$$\begin{cases} \frac{dS}{dt} = -\frac{1}{N} \times (\beta \times S \times I) \\ \frac{dI}{dt} = \frac{1}{N} \times (\beta \times S \times I) - \gamma \times I \\ \frac{dR}{dt} = \gamma \times I \end{cases}$$

Avec :

- S : représentant la population susceptible.
- I : représentant la population infectée, infectueuse et symptomatique.
- R : représentant la population retirée.
- β : représentant le taux de transmission.
- γ : représentant le taux de récupération.

Paramètres initiaux :

$$\begin{cases} S = S_0 = N \\ I = I_0 \\ R = 0 \end{cases}$$

sources : Auteur, Overleaf

Annexe 8 : Équations différentielles et paramètres initiaux du modèle SEIRD

$$\begin{cases} \frac{dS}{dt} = -\frac{1}{N} \times (\beta \times S \times I) \\ \frac{dE}{dt} = \frac{1}{N} \times (\beta \times S \times I) - E \times \zeta \\ \frac{dI}{dt} = \zeta \times E - I \times (\gamma + \rho) \\ \frac{dR}{dt} = \gamma \times I \\ \frac{dD}{dt} = \rho \times I \end{cases}$$

Avec les paramètres initiaux du modèles SIR et :

- E : représentant la population exposée.
- D : représentant la population infectée, infectueuse et symptomatique.
- R : représentant la population récupérée.
- ζ : représentant le taux d'incubation.
- γ : représentant le taux de guérison.
- ρ : représentant le taux de mortalité.

Paramètres initiaux :

$$\begin{cases} S = S_0 = N \\ E = E_0 = I_0 \\ I = I_0 \\ R = 0 \\ D = 0 \end{cases}$$

sources : Auteur, Overleaf

Annexe 9 : Équations différentielles et paramètres initiaux du modèle SEIRDV

$$\begin{cases} \frac{dS}{dt} = -\frac{1}{N} \times (\beta \times S \times I + \alpha \times V) \\ \frac{dV}{dt} = -\frac{1}{N} \times (-\alpha \times V + \beta \times \kappa \times V \times I) \\ \frac{dE}{dt} = \frac{\beta \times I}{N} \times (S + \kappa \times V) - E \times \zeta \\ \frac{dI}{dt} = \zeta \times E - I \times (\gamma + \rho) \\ \frac{dR}{dt} = \gamma \times I \\ \frac{dD}{dt} = \rho \times I \end{cases}$$

Avec les paramètres initiaux du modèles SIERD et :

- E : représentant la population exposée.
- D : représentant la population infectée, infectueuse et symptomatique.
- R : représentant la population récupérée.
- ζ : représentant le taux d'incubation.
- γ : représentant le taux de guérison.
- ρ : représentant le taux de mortalité.

Paramètres initiaux :

$$\begin{cases} S = S_0 = (N - V_0) \\ V = V_0 \\ E = E_0 = I_0 \\ I = I_0 \\ R = 0 \\ D = 0 \end{cases}$$

sources : Auteur, Overleaf

Annexe 10 : Résultats des test de saisonnalité

Table: Test de saisonnalité

Test	Valeur.Statistique	P.value
Seasonnal - Dummies	3.746458	0.0000650
Friedman	104.709402	0.0000000
Kruskal - Wallis	98.418784	0.0000000
QS - test	1.000000	0.0000045
QS - test robuste	NA	0.0172597
Koenker - Basset	NA	0.0000000

sources : Auteur, Rstudio

Annexe 11 : Résultats de la sélection par la méthode Both

Call:

```
lm(formula = ILITOTAL ~ BBKCI + BBKGDP + BBKF + Medical_care +  
  Mean + Terme_santé + Sympt_santé + Zoonose_santé + Maladie_conco_santé +  
  Pop_plus_55_ans + Pop_moins_16_ans, data = df_wm)
```

Residuals:

Min	1Q	Median	3Q	Max
-20911	-4403	-110	3377	52073

Residual standard error: 8143 on 216 degrees of freedom

Multiple R-squared: 0.8545, Adjusted R-squared: 0.8471

F-statistic: 115.3 on 11 and 216 DF, p-value: < 2.2e-16

sources : Auteur, Rstudio

Annexe 12 : Résultats de la sélection par la méthode Forward

Call:

```
lm(formula = ILITOTAL ~ BBKCI + BBKGDP + BBKF + Medical_care +  
  PRCP + Mean + Caté_santé + Terme_santé + Sympt_santé +  
  Zoonose_santé + Maladie_conco_santé + Transportation +  
  Médian + Pop_plus_55_ans + Pop_moins_16_ans + Avion + Train +  
  Voiture + Commun, data = df_wm)
```

Residuals:

Min	1Q	Median	3Q	Max
-20446	-4064	-57	3108	52406

Residual standard error: 8173 on 208 degrees of freedom

Multiple R-squared: 0.8589, Adjusted R-squared: 0.846

F-statistic: 66.62 on 19 and 208 DF, p-value: < 2.2e-16

sources : Auteur, Rstudio

Annexe 13 : Résultats de la sélection par la méthode Backward

Call:
lm(formula = ILITOTAL ~ BBKCI + BBKGDP + BBKF + Medical_care +
Mean + Terme_santé + Sympt_santé + Zoonose_santé + Maladie_conco_santé +
Pop_plus_55_ans + Pop_moins_16_ans, data = df_wm)

Residuals:

Min	1Q	Median	3Q	Max
-20911	-4403	-110	3377	52073

Residual standard error: 8143 on 216 degrees of freedom
Multiple R-squared: 0.8545, Adjusted R-squared: 0.8471
F-statistic: 115.3 on 11 and 216 DF, p-value: < 2.2e-16

sources : Auteur, Rstudio

Annexe 14 : Résultats de la sélection par la méthode BeSS

Call:
lm(formula = ys ~ xbest, weights = weights)

Residuals:

Min	1Q	Median	3Q	Max
-19693	-4108	-48	3009	52474

Residual standard error: 8109 on 212 degrees of freedom
Multiple R-squared: 0.8584, Adjusted R-squared: 0.8484
F-statistic: 85.66 on 15 and 212 DF, p-value: < 2.2e-16

sources : Auteur, Rstudio

Annexe 15 : Calcule mathématique de MAE

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

sources : Auteur

Annexe 16 : Calcule mathématique de MAPE

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

sources : Auteur

Annexe 17 : Calcule mathématique de DE

$$DE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

sources : Auteur

Annexe 18 : Calcule mathématique de CPS

$$CPS = 1 - \frac{\sum_{i=1}^n (y_i - \widehat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

sources : Auteur

Annexe 19 : Calcule mathématique de CPS

$$CPS = 1 - \frac{\sum_{i=1}^n (y_i - \widehat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

sources : Auteur

Annexe 20 : Calcule mathématique de RGME

$$RGME = \left(\prod_{i=1}^n \left(1 + \left| \frac{y_i - \widehat{y}_i}{y_i} \right| \right) \right)^{\frac{1}{n}} - 1$$

sources : Auteur

Annexe 21 : Résultats du modèle de régression simple

```
Call:
lm(formula = ILITOTAL ~ BBKCI + BBKGDP + BBKF + Medical_care +
  Mean + Zoonose_santé + Terme_santé + Sympt_santé + Maladie_conco_santé +
  Pop_moins_16_ans + Pop_plus_55_ans, data = trainingbase)

Residuals:
    Min       1Q   Median       3Q      Max
-20911  -4403   -110    3377   52073

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  24468.219   5633.397   4.343 2.16e-05 ***
BBKCI        -3396.675    966.260  -3.515 0.000535 ***
BBKGDP         466.259    169.964   2.743 0.006594 **
BBKF         -1033.264    606.030  -1.705 0.089637 .
Medical_care   -68.449     14.234  -4.809 2.85e-06 ***
Mean         -208.729     116.883  -1.786 0.075536 .
Zoonose_santé  177.465      74.575   2.380 0.018197 *
Terme_santé    246.196      55.646   4.424 1.53e-05 ***
Sympt_santé   1645.630     95.909  17.158 < 2e-16 ***
Maladie_conco_santé -636.045    119.452  -5.325 2.53e-07 ***
Pop_moins_16_ans  8.224       3.345   2.459 0.014722 *
Pop_plus_55_ans  8.954       5.474   1.636 0.103367
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8143 on 216 degrees of freedom
Multiple R-squared:  0.8545,    Adjusted R-squared:  0.8471
F-statistic: 115.3 on 11 and 216 DF,  p-value: < 2.2e-16
```

sources : Auteur, Rstudio

Liste des titres des tableaux & graphiques & figures & modélisations

Figures :

- Figure 1 : Schéma récapitulatif de la méthode des analogues
- Figure 2 : Équations différentielles et paramètres initiaux du modèle SI
- Figure 3 : Visualisation des corrélations obtenues
- Figure 4 : Calcul mathématique de la distance euclidienne
- Figure 5 : Modélisation du meilleur modèle

Graphiques :

- Graphique 1 : Evolution et projection de la population américaine de 1800 à 2100
- Graphique 2 : Evolution des classes d'âges de la population américaine de 1960 à 2018
- Graphique 3 : Evolution de l'indice GINI entre 1986 et 2013
- Graphique 4 : Evolution de l'incidence de la grippe au USA de 2004 à 2023 Y_t
- Graphique 5 : Boîte à moustache de notre Y_t
- Graphique 6 : Comparaison de la distribution de Y_t avec plusieurs lois de distributions statistiques
- Graphique 7 : Préviction de l'incidence de la grippe pour l'année 2023 à l'aide de la méthode analogue (Prise en compte de 8 séries analogues)
- Graphique 8 : Préviction de l'incidence de la grippe pour l'année 2023 à l'aide de la méthode analogue (Prise en compte de 8 séries analogues)
- Graphique 9 : Comparaison graphique des données historique de fin 2022 à la préviction par la méthode SIR
- Graphique 10 : Préviction de l'incidence de la grippe pour l'année 2023 à l'aide du modèle SIR
- Graphique 11 : Comparaison graphique des données historique de fin 2022 à la préviction par la méthode SEIRD
- Graphique 12 : Préviction de l'incidence de la grippe pour l'année 2023 à l'aide du modèle SIERD
- Graphique 13 : Comparaison graphique des données historique de fin 2022 à la préviction par la méthode SEIRDV
- Graphique 14 : Préviction de l'incidence de la grippe pour l'année 2023 à l'aide du modèle SIERD
- Graphique 15 : Schéma de décomposition de l'incidence des symptômes grippaux
- Graphique 16 : Comparaison d'avant et après la désaisonnalisation
- Graphique 17 : Préviction de 2023 de l'incidence des symptômes grippaux aux USA à l'aide de méthode divers sans désaisonnalisation
- Graphique 18 : Préviction de 2023 de l'incidence des symptômes grippaux aux USA à l'aide de méthode de lissage exponentiel sans désaisonnalisation
- Graphique 19 : Résultats des différents modèles par la sélection Leaps
- Graphique 20 : Préviction de 2023 de l'incidence des symptômes grippaux aux USA à l'aide de méthode multivariées sans désaisonnalisation

- Graphique 21 : Ensemble de prévisions et observation pour l'année 2023
- Graphique 22 : Ensemble de prévisions différencié par méthodes et observation pour l'année 2023
- Graphique 23 : Classement des meilleurs méthodes de prévision en fonction d'indicateurs statistique

Modélisations :

- Modélisation 1 : Visualisation du modèle SI
- Modélisation 2 : Visualisation du modèle SIR
- Modélisation 3 : Visualisation du modèle SEIRD
- Modélisation 4 : Visualisation du modèle SEIRDV
- Modélisation 5 : Modèle multivariées sélectionné
- Modélisation 6 : Modèle multivariées sélectionné suite à la méthode leaps

Tableaux :

- Tableau 1 : Récapitulatif de l'ensemble de nos variables (indépendantes et dépendantes)
- Tableau 2 : Résultat du test ADF pour notre série Y_t
- Tableau 3 : Statistique descriptive de notre série Y_t
- Tableau 4 : Indicateur et test de notre série Y_t
- Tableau 5 : Résultats du test ADF de nos séries indépendantes
- Tableau 6 : Statistique descriptive de nos séries indépendantes
- Tableau 7 : Récapitulatif des corrélation Obtenues et attendues
- Tableau 8 : Résultat des test de saisonnalité
- Tableau 9 : Comparaison des résultats des différents type de sélection
- Tableau 10 : Indicateur statistique de qualité des prévisions des différents modèles

Bibliographie / Sitographie

Bibliographie:

- Absil, Gaëtan, Chantal Vandoorne, and Michel Demarteau. "Bronfenbrenner, écologie du développement humain. Réflexion et action pour la promotion de la santé." (2012)
- AHLBURG, Dennis. "La population des États-Unis: un vieillissement démographique en dépit d'une croissance continue." *La population du monde: géants démographiques et défis internationaux* 149 (2002): 197.
- Atkinson, Tony. "La distribution des revenus dans les pays de l'OCDE au vingtième siècle." *Revue française d'économie* 17.1 (2002): 3-31.
- Beby-Defaux, A., et al. "La grippe humaine: aspects virologiques, épidémiologie et diagnostic virologique." *Médecine et maladies infectieuses* 33.3 (2003): 134-142.
- Berche, Patrick. *Faut-il encore avoir peur de la grippe?: histoire des pandémies*. Odile Jacob, 2012.
- Berche, Patrick. *Une histoire des microbes*. Montrouge: John Libbey Eurotext, 2007. Print.
- Buisson, Yves, Élisabeth Nicand, and Pierre Saliou. *La grippe en face*. Xavier Montauban SA, 2007.
- Brugère-Picoux, Jeanne, Jean-Pierre Vaillancourt, and Jean-Claude Manuguerra. "Les virus influenza animaux et les pandémies de grippe humaine." *Les maladies infectieuses exotiques* (2010): 133.
- Dugas, Andrea Freyer, et al. "Influenza forecasting with Google flu trends." *PloS one* 8.2 (2013): e56176
- Cavé, Isabelle. *Les médecins-législateurs et le mouvement hygiéniste, 1870-1914*. Diss. Paris, EHESS, 2013.
- Centers for Disease Control and Prevention. "US Influenza surveillance: purpose and methods." *US Influenza Surveillance: Purpose and Methods* | CDC (2022).
- Gautier, A., and C. Jestin. "De la grippe saisonnière à la grippe pandémique." Gautier A, Jauffret-Roustide M, Jestin C.(sous la dir.) *Enquête Nicolle* (2006): 167-81.
- Flichy, Patrice. *L'imaginaire d'Internet. La découverte*, 2012.
- Geloso, Vincent. "Pourquoi la croissance économique est bonne pour la santé." (2023).
- Hayward, Andrew C., et al. "Comparative community burden and severity of seasonal and pandemic influenza: results of the Flu Watch cohort study." *The Lancet Respiratory Medicine* 2.6 (2014): 445-454.
- Kacki, Sacha, et al. « Prévention, pratiques médicales et gestion sanitaire au cours de la deuxième pandémie de peste », Alain Froment éd., *Archéologie de la santé, anthropologie du soin. La Découverte*, 2019, pp. 119-133.
- Ledrut, Raymond. *Sociologie urbaine*. FeniXX, 1979.
- Main, Guillaume. "Google prédit les épidémies de grippe." (2009).
- Martin, Paul MV, and Estelle Martin-Granel. "2,500-year evolution of the term epidemic." *Emerging infectious diseases* 12.6 (2006): 976.
- Nau, Jean-Yves. "La crise financière et l'épidémiologiste." *Thérapeutique* 179.41 (2008): 2484-2484.
- Portes, Jacques. *Histoire des États-Unis depuis 1945*. FeniXX, 1992.

- Richard Taillet, Loïc Villain et Pascal Febvre, Dictionnaire de physique, Bruxelles, De Boeck, 2013, p. 25 « Analogique ».
- Rochaix, Lise, et Sandy Tubeuf. « Mesures de l'équité en santé. Fondements éthiques et implications », Revue économique, vol. 60, no. 2, 2009, pp. 325-344.
- Roger, Annie. "Etude de la relation parasitaire initiale entre un virus du groupe L 1 de Gourlay et une population cellulaire d'Acholeplasma laidlawii." Canadian Journal of Microbiology 23.3 (1977): 224-229.
- Saporita, Gilbert. "Quelle statistique pour les Big Data?." *Statistique et Société* 5.1 (2017).
- Vagneron, Frédéric. "Surveiller et s' unir?. Le rôle de l'OMS dans les premières mobilisations internationales autour d'un réservoir animal de la grippe." Revue d'anthropologie des connaissances 9.9-2 (2015).
- Viboud C, Boëlle PY, Carrat F, Valleron AJ, Flahault A. Prediction of the spread of influenza epidemics by the method of analogues. Am J Epidemiol. 2003 Nov 15;158(10):996-1006. doi: 10.1093/aje/kwg239. PMID: 14607808
- Vitaux, Jean. Histoire de la peste. PUF, 2015.
- Woodham-Smith, Cecil. "Florence Nightingale, 1820–1910." AJN The American Journal of Nursing 51.5 (1951): 354.
- World Health Organization. Préparation et action en cas de grippe pandémique: document d'orientation de l'OMS. Organisation mondiale de la Santé, 2009

Sitographies :

- <https://gis.cdc.gov/grasp/fluview/fluportaldashboard.html>
- <https://www.e-cancer.fr/Dictionnaire/I/incidence>
- <https://www.ncei.noaa.gov/access/search/data-search/daily-summaries?dataTypes=AWND&dataTypes=PRCP&dataTypes=RHAV&dataTypes=TAVG&pageNum=6>
- <https://fred.stlouisfed.org/categories>
- <https://www.who.int/fr/campaigns/75-years-of-improving-public-health/milestones#year-1945>
- <https://gis.cdc.gov/grasp/fluview/fluportaldashboard.html>
- <https://ourworldindata.org/grapher/population-long-run-with-projections?time=1800..2100&showSelectionOnlyInTable=1&country=~USA>
- [https://www.who.int/fr/news-room/fact-sheets/detail/influenza-\(seasonal\)](https://www.who.int/fr/news-room/fact-sheets/detail/influenza-(seasonal))
- <https://perspective.usherbrooke.ca/bilan/servlet/BMPagePyramide/USA/1989/>
- <https://fr.statista.com/statistiques/558805/gouvernement-americain-depenses-du-departement-de-la-sante-et-des-services-sociaux/#:~:text=Ainsi%2C%20le%20minist%C3%A8re%20de%20la,billions%20de%20dollars%20en%202020.>
- <https://perspective.usherbrooke.ca/bilan/servlet/BMTendanceStatPays?codePays=USA&codeStat=PMQUANDL.GINI.V1&codeTheme=2>
- <https://trends.google.fr/trends/>
- <https://rpubs.com/mahdi/601181>

Tables des matières

Sommaire.....	I
Résumé.....	II
Abstract.....	III
Liste de Sigles.....	IV
Chapitre I - Introduction.....	1
Section I - Chronique du virus de la grippe.....	1
Section II - Objectif de l'étude comparative et de l'analyse critique.....	3
Chapitre II - Revue de littérature.....	5
Section I - Variables étudiées.....	5
1§ -Variable dépendante / L'incidence des symptômes grippaux.....	5
2§ - Variables indépendantes.....	6
A) Les variables démographiques.....	6
B) Les variables météorologique.....	8
C) Les variables de transport.....	9
D) Les variables économiques.....	10
E) Les variables informationnel.....	11
Section II - Méthodes prédictives.....	13
1§ - Les méthodes des analogues.....	13
2§ - Les méthodes compartimentales.....	14
3§ - Les méthodes de séries temporelles divers.....	15
A) Les méthodes de séries temporelles univariées.....	16
B) Les méthodes de séries temporelles multivariées.....	17
Chapitre III - Caractérisation statistique et analyse des séries chronologiques.....	18
Section I - Analyse statistiques de l'incidence des symptômes grippaux.....	18
1§ - Propriété de stationnarité de Y_t	19
2§ - Statistiques descriptives de Y_t	20
Section II - Analyse statistiques de nos variables indépendantes.....	24
1§ - Propriété de stationnarité de nos séries indépendantes.....	24
2§ - Statistiques descriptives de nos séries indépendantes.....	25
Section III - Analyse des corrélations.....	27
Chapitre IV - Application des modèles prédictifs.....	29
Section I - Méthodes des analogues.....	29
Section II - Méthodes compartimentales.....	32

1§ - Le modèle SIR.....	33
2§ - Le modèle SEIRD.....	35
3§ - Le modèle SEIRDV.....	37
Section III - Les méthodes de séries temporelles.....	40
1§ - Les méthodes de séries temporelles univariées.....	40
A) Saisonnalité & décomposition.....	40
B) Préviction de méthode divers.....	42
C) Préviction de méthode de lissage exponentiel et ARIMA.....	43
2§ - Les méthodes de séries temporelles multivariées.....	43
A) Pré - Sélection des variables.....	43
B) Sélection des variables.....	45
C) Préviction.....	46
Chapitre V - Comparaison des résultats.....	48
Section I - Visualisation graphiques.....	48
Section II - Indicateurs statistique.....	50
Section III - Analyse du meilleure modèle.....	52
Chapitre VI - Analyse critique.....	54
Chapitre VII - Discussion.....	56
Chapitre VIII - Conclusion.....	58
Annexe.....	60
Liste des titres des tableaux & graphiques & figures & modélisations.....	67
Tables des matières.....	71