

Dossier de Série Temporelle
MASTER 1 ECAP

Etude relationnel entre les symptômes grippaux, l'évolution des température et
la démographie française de 1990 à 2024 en France Métropolitaine

Dossier réalisé par :
Mocaër Rodolphe

Année universitaire 2023-2024

Etude relationnel entre les symptômes grippaux, l'évolution des température et la démographie française de 1990 à 2024 en France

Résumé

À travers les âges, la lutte contre les épidémies a été une priorité constante pour la préservation de la santé publique. Malgré les progrès médicaux, la grippe persiste en raison de facteurs tels que les mutations virales et la présence de réservoirs animaux. Notre étude cherche à examiner les liens entre l'incidence de la grippe, la température et la densité de population, en utilisant la méthodologie ARIMA. Bien que des modèles prometteurs aient été identifiés pour la grippe et la température, la prédiction précise reste difficile en raison de la complexité des facteurs en jeu.

Mots clés : Grippe; Pandémie; Modèles de prédiction; ARIMA; Engle et Granger

Study of the relational link between influenza symptoms, temperature trends, and the French demographics from 1990 to 2024 in France.

Abstract

Throughout the ages, combating epidemics has been a constant priority for preserving public health. Despite medical advancements, influenza persists due to factors such as viral mutations and the presence of animal reservoirs. Our study aims to examine the links between influenza incidence, temperature, and population density, using ARIMA methodology. Although promising models have been identified for influenza and temperature, precise prediction remains challenging due to the complexity of factors involved.

Keywords : Influenza; Pandemic; Prediction models; ARIMA; Engle and Granger

Sommaire

I - Introduction.....	1
II - Revue de littérature de la grippe.....	3
III - Caractérisation statistique et analyse des séries chronologiques.....	6
IV - Présentation de la méthodologie ARIMA.....	14
V - Sélection des modèle ARIMA.....	20
VI - Test de cointégration selon Engle-Granger.....	59
VII - Conclusion.....	66
VIII - Discussion.....	67
IX - Bibliographie.....	68
X - Annexe.....	69
XII - Table des Figures.....	88
XIII - Table des matières.....	91

I - Introduction

À travers les époques, la préservation de la santé des populations demeure une priorité essentielle pour toute société. La lutte contre les épidémies s'est avérée être un objectif fondamental, comme en témoignent de nombreux événements tout au long de l'histoire humaine. Un exemple significatif est la peste bubonique survenue de 1346 à 1353, qui a marqué les débuts de la promotion de l'hygiène comme moyen de lutte contre les épidémies¹.

Cependant, en dépit des progrès tant sur le plan médical, notamment avec la vaccination, que dans les domaines de la santé publique et de l'hygiène, l'humanité n'a toujours pas réussi à éradiquer le fléau représenté par le virus de la grippe. Cette maladie, causée par le virus "Myxovirus influenzae", peut souvent être associée à une maladie infectieuse bénigne, se manifestant par des céphalées et des rhumes, mais elle peut être bien plus mortelle qu'on ne le pense, entraînant jusqu'à l'anorexie et des pharyngites, causant ainsi annuellement entre 290 000 et 650 000 décès dans le monde. Le Myxovirus influenzae existe depuis l'aube de l'humanité, ayant débuté en Chine en 2500 av. J-C et continuant de sévir aujourd'hui. Cette maladie a engendré de nombreuses pandémies, telles que la grippe espagnole (1918-1920), entraînant de 30 à 100 millions de décès, ainsi que la grippe de Hong Kong².

Néanmoins, tout au long de cette période, la compréhension de ce virus a joué un rôle crucial dans les efforts visant son éradication. Cependant, plusieurs facteurs contribuent à sa persistance. En premier lieu, de nombreux mécanismes ont un impact négatif sur la création d'un vaccin durable, tels que les mutations et/ou le réassortiment génétique. En second lieu, les symptômes de ce virus sont souvent bénins et similaires à de nombreuses autres maladies, comme les bronchites, rhumes ou rhinopharyngites, rendant difficile la reconnaissance des infectés du virus de la grippe. Enfin, la présence de ce virus dans des réservoirs animaux permet aux agents pathogènes de prospérer et

¹ Kacki, Sacha, et al. « Prévention, pratiques médicales et gestion sanitaire au cours de la deuxième pandémie de peste », Alain Froment éd., *Archéologie de la santé, anthropologie du soin*. La Découverte, 2019, pp. 119-133. (consulté le 04/03/24)

² Berche, Patrick. *Faut-il encore avoir peur de la grippe?: histoire des pandémies*. Odile Jacob, 2012. (consulté le 04/03/24)

d'affecter les humains, favorisant ainsi la zoonose. Ainsi, "la grippe connaissant de permanentes modifications antigéniques et possédant des réservoirs animaux, il sera difficile d'éviter de futures pandémies"³.

Outre ces mécanismes opacifiant la compréhension du virus, de nombreux éléments ont été révélés dans l'appréhension de la grippe. En premier lieu, des facteurs environnementaux saisonniers ont été identifiés, tels que la température et l'hygrométrie, susceptibles d'entraîner une augmentation de la diffusion de particules en cas de faibles températures et/ou d'hygrométrie. En second lieu, la proximité entre les individus favorise la propagation de cette maladie infectieuse et notamment le contact proche entre les individus. En troisième lieu, la mise en évidence d'une sous-population, notamment liés au facteur de l'âge⁴. En effet, ce virus entraînant principalement des formes graves chez les personnes âgées, les nouveau-nés et les femmes enceintes. Ainsi, cette identification des facteurs et la compréhension plus approfondie de la structure génétique du virus ont conduit à une meilleure réponse épidémique qu'auparavant, en proposant des vaccinations potentiellement efficaces, ainsi que des recommandations de sécurité sanitaire⁵.

Cependant, les mesures sanitaires préventives semblent insuffisamment efficaces pour éradiquer cette pandémie. C'est pourquoi nous entreprendrons l'identification des facteurs associés à l'incidence de la grippe, notamment en examinant l'évolution de la température et la croissance de la densité de la population française. Nous permettant ultérieurement la création d'un modèle de prédiction visant à améliorer la surveillance sanitaire. Notre analyse débutera par l'exploration des relations entre les incidences de la grippe et les deux variables explicatives mentionnées précédemment. Par la suite, nous examinerons la méthodologie de Box-Jenkins à travers le processus ARIMA. En conclusion, cette étude sera clôturée par un test de cointégration appliqué à nos couples de variables.

³ Barry, Stéphane, Luc Hessel, and Norbert Gualde. "La grippe, une menace éternelle." *Canadian Bulletin of Medical History* 24.2 (2007): 445-466. (consulté le 04/03/24)

⁴ Vallée, Jean-Pierre. "Grippe" à risque": entre croyances et connaissances." *Médecine* 9.9 (2013): 395-395. (consulté le 04/03/24)

⁵ World Health Organization. *Préparation et action en cas de grippe pandémique: document d'orientation de l'OMS*. Organisation mondiale de la Santé, 2009. (consulté le 04/03/24)

II - Revue de littérature de la grippe

A) L'incidence de la Grippe en France

L'incidence, un outil décisif dans le domaine de l'épidémiologie. En effet, l'incidence mesure le nombre de nouveaux cas d'une maladie dans une population donnée pendant une période spécifique. Le taux d'incidence permet une évaluation de la sévérité d'une épidémie, identifie les tendances émergentes et adapte les stratégies de santé publique en conséquence. Ainsi, la collecte systématique des données d'incidence joue un rôle essentiel dans la mise en place de mesures proactives pour atténuer l'impact des maladies infectieuses⁶.

Ainsi, l'importance de l'incidence dans le domaine de l'épidémiologie a poussé en 1947 l'OMS à institutionnaliser le suivi épidémiologique de la grippe grâce à la mise en place d'un programme de surveillance virologique. Toutefois, en France, cette surveillance n'a véritablement débuté qu'en 1984, avec la création du "réseau Sentinelles". Ce réseau possède trois objectifs principaux : la constitution de vastes bases de données en médecine générale et en pédiatrie à des fins de veille sanitaire et de recherche, le développement d'outils de détection et de prévision épidémique, ainsi que la mise en place d'études cliniques et épidémiologiques. Cependant, il n'est pas le seul réseau en France, et au fil des années, le pays a mis en œuvre diverses initiatives visant à améliorer le suivi épidémiologique du virus en créant d'autres initiatives afin d'enrichir les outils de surveillance du suivi de la grippe. Parmi ces initiatives, nous pouvons citer la dernière fondée en 2012, le projet "GrippeNet.fr"⁷.

L'établissement de ces réseaux, en particulier le suivi de l'incidence de la grippe, offre la possibilité d'effectuer une analyse approfondie ainsi qu'une prévision des données épidémiologiques de la grippe. Ainsi, notre référence repose sur ce système national de surveillance.

⁶ Berche, Patrick. *Une histoire des microbes*. Montrouge: John Libbey Eurotext, 2007. Print. (consulté le 05/03/24)

⁷ <http://www.grippenet.fr> (consulté le 05/03/24)

B) La température moyenne en France (En Celsius)

L'origine du terme "grippe" proviendrait de l'expression italienne "influenza di freddo"⁸, signifiant littéralement "sous l'influence du froid", démontrant ainsi que la découverte de la saisonnalité de ce virus avec une prévalence accrue pendant l'hiver est connue depuis longtemps. Néanmoins cette connaissance ancienne, il existe encore de nombreuses hypothèses afin d'élucider la récurrence saisonnière de ce virus pendant la période hivernale. Parmi ces hypothèses, nous pouvons citer une sédentarité accrue de la population en hiver, la diminution de l'ensoleillement entraînant une réduction de la vitamine D⁹. Cependant, deux hypothèses se démarquent comme étant particulièrement pertinentes : la faible humidité atmosphérique (l'hygrométrie) et les basses températures, propices à la transmission virale¹⁰.

La mise en lumière de ces facteurs déterminants nous a incités à intégrer l'un d'entre eux dans notre étude. Notre préférence s'est portée sur la température, car bien que l'hygrométrie puisse également jouer un rôle dans la transmission des virus respiratoires, les travaux de la littérature scientifique¹¹ et les recherches antérieures ont indiqué que la température exerce une influence plus directe et marquée sur la survie ainsi que sur la transmission du virus de la grippe.

Ainsi, en raison de la prédominance des données et des études existantes mettant en évidence l'impact significatif de la température sur la saisonnalité de la grippe, nous avons pris la décision de la sélectionner comme variable principale. Ainsi, nos données seront donc basées sur le système national français de suivi météorologique pour assurer une base solide à notre analyse.

⁸ Claude Chastel, Ces virus qui détruisent les hommes, Ramsay, 1996, p. 108. (consulté le 06/03/24)

⁹ Lofgren, Eric et al. "Influenza seasonality: underlying causes and modeling theories." *Journal of virology* vol. 81,11 (2007): 5429-36. doi:10.1128/JVI.01680-06 (consulté le 06/03/24)

¹⁰ Lowen AC, Mubareka S et al. « Influenza virus transmission is dependent on relative humidity and temperature » *PLoS Pathog.* 2007 octobre 19;3(10):1470-6 (consulté le 06/03/24)

¹¹ Vabret, A et al. "La grippe saisonnière" [Seasonal flu]. *Pathologie-biologie* vol. 58,2 (2010): e51-7. doi:10.1016/j.patbio.2010.01.009 (consulté le 06/03/24)

C) Densité de population française (Habitant au km²)

Depuis le 19^{ème} siècle, la population française n'a cessé de croître de manière soutenue, passant de 30 millions en 1800 à 68,3 millions en 2024, plus que doublant au fil des décennies¹². Cette croissance constante a inexorablement accru la densité de population en France, intensifiant les contacts sociaux et les interactions quotidiennes entre les individus¹³. Cependant, cette augmentation des interactions a également favorisé l'émergence de maladies transmises par contact, telles que la grippe. Cette maladie, qui se propage par des gestes simples comme éternuer, tousser ou même parler, ainsi que par le contact direct avec des surfaces contaminées, trouve dans cette augmentation des contacts un terrain propice à sa diffusion¹⁴. Ainsi, l'augmentation de la densité de population et des interactions sociales joue un rôle crucial dans la compréhension des épidémies de grippe saisonnière.

Par conséquent, nous avons opté pour la densité de la population française comme principale variable afin de mettre en lumière l'augmentation des contacts sociaux. Nos données seront ainsi fondées sur "l'Institut National de la Statistique et des Études Économiques" (INSEE).

¹² Levasseur, Émile. "La population française." *Journal de la Société de statistique de Paris* 32 (1891): 115-118. (consulté le 07/03/24)

¹³ PANDÉMIQUE, EN CAS DE GRIPPE. "PRÉPARATION DU CANADA EN CAS DE GRIPPE PANDÉMIQUE." (2019). (consulté le 07/03/24)

¹⁴ Moreau, René. "QU'EST-CE QUE LA GRIPPE?." *Revue des Deux Mondes (1829-1971)* (1955): 80-93. (consulté le 07/03/24)

III - Caractérisation statistique et analyse des séries chronologiques.

Suite à l'analyse économique de notre sujet, nous pouvons dès lors passer à l'analyse de notre base de données qui se compose de trois variables. Nous commencerons par une analyse des statistiques descriptives afin de mieux comprendre la structure de nos séries/variables, suivie d'une analyse des relations et tendances de ces mêmes séries chronologiques. Il est également important de souligner que ces analyses seront basées sur notre base de données mensuelle, couvrant la période de décembre 1990 à janvier 2024. Cette base de données comprend une variable à expliquer, l'incidence de la grippe en France, ainsi que deux variables explicatives : la température moyenne en France et la densité de population française.

A) Statistique descriptives

Cette analyse de statistiques descriptives nous offre un premier aperçu de nos séries chronologiques, mettant en lumière leurs tendances, leurs réponses à la variabilité, et leurs évolutions. Cependant, pour une compréhension plus approfondie du comportement de la série, une exploration supplémentaire est nécessaire, en particulier à travers la visualisation des données temporelles. Il est important de souligner que dans un processus de simplification nous décidons de renommer nos variables ainsi :

- L'incidence de la grippe devient : GRIPPE.
- La température moyenne en France : TEMPE.
- Densité de population moyenne française : DEMO.

Tableau 1 : Statistique descriptives de notre base de données

	GRIPPE	TEMPE	DEMO
MIN	2534	1,925	102,6
1er QUARTILE	22936	8,525	105,8
MEDIAN	69182	12,655	112
MEAN	237524	13,244	111,4
3eme QUARTILE	232038	18,244	116,6

MAX	2183756	23,640	119,9
VAR	159713959765	5,4157	5,4830
ECART-TYPE	399642	29,3293	30,0633

sources : Rstudio et auteurs

Dans un premier temps, nous pouvons observer que nos deux séries explicatives présentent de nombreuses similarités. En effet, leurs médianes sont relativement proches de leurs moyennes, suggérant ainsi une symétrie dans la distribution des données. De plus, nous constatons que la variable DEMO présente une variabilité plus faible de ses valeurs, avec une plage allant de 102,6 à 119,9, tandis que la variable TEMPE présente une légère augmentation de variabilité. Par ailleurs, il est intéressant de noter que les données de température ne semblent pas atypiques, étant donné que la France est un pays doté d'un climat tempéré, ce qui est cohérent avec une moyenne et un deuxième quartile raisonnables. Enfin, il est important de signaler que nos deux variables explicatives ont une dispersion beaucoup plus faible que celle de notre variable à expliquer.

Dans un second temps, nous procédons à l'analyse de notre variable à expliquer, l'incidence de la Grippe en France. Tout d'abord, il est notable que les données présentent une forte variabilité, comme en témoigne la plage étendue allant de 2534 à 2183756. Cette variabilité peut être attribuée au caractère saisonnier de la grippe, avec une incidence significativement plus faible pendant les mois d'été par rapport à l'hiver. De plus, nous constatons une tendance centrale marquée, comme en témoigne la moyenne étant à 237524. Également, nous pouvons voir une non proximité de la médiane et de la moyenne démontrant ainsi que la répartition de notre variable à expliquer est asymétrique pour avoir été impactée par des valeurs extrêmes (voir annexe 1). Après études, nous avons pu observer que ces valeurs extrêmes peuvent être apparentées aux "pics épidémiques".


Cette section nous a permis de mettre en évidence les variations dans nos séries et de mieux les comprendre. Toutefois, pour une analyse plus approfondie, il est essentiel de visualiser les séries, ce qui permettra une nouvelle meilleure compréhension des données.

B) Tendances des séries chronologiques

Dans cette section, notre analyse se concentrera principalement sur les tendances observées dans nos différentes séries chronologiques. L'objectif est d'acquérir une meilleure compréhension de ces séries et de leurs évolutions au fil du temps.

1 - Tendance de l'incidence de la grippe en France (Y)

Graphique 1 : Evolution de l'incidence de la grippe en France de 1990 à décembre 2023



source : auteur et Gretl

À partir de notre graphique 1, nous constatons que l'incidence de la grippe en France présente une saisonnalité, confirmant ainsi notre revue de littérature. Cependant, il est important de noter que cette saisonnalité ne semble pas avoir le même impact chaque année, ce qui suggère que chaque épidémie est unique. Cette variabilité peut être attribuée à la grande mutabilité du virus de la grippe¹⁵. Ainsi, un virus de la grippe qui ne possède qu'une très faible mutation par rapport à celui de l'année dernière impactera moins de personnes qu'un virus très fortement muté¹⁶. Néanmoins, nous observons ces dernières années une tendance à la baisse de l'impact de la grippe sur la population française, comme en témoigne la diminution des pics épidémiques au


¹⁵ Hannoun, Claude. "La grippe." *Annales de l'Institut Pasteur/Actualités*. Vol. 6. No. 1. Elsevier Masson, 1995. (consulté le 08/03/24)

¹⁶ Ballesteros, Sébastien. *Ecologie et évolution des maladies infectieuses aiguës: le cas de la grippe*. Diss. Paris 6, 2009. (consulté le 09/03/24)

fil du temps, avec des incidences en dessous de 1×10^6 . Cette diminution ne semble pas être due au hasard, mais plutôt attribuée à la pandémie de COVID-19 et notamment à la mise en place de protocoles sanitaires visant à limiter cette pandémie. Ces mesures sanitaires comprennent entre autres le port du masque, le confinement, le couvre-feu, etc. Il est intéressant de noter que ces protocoles ont également un impact sur la grippe, ce qui peut être expliqué par les similarités entre les deux virus, notamment leur mode de transmission par micro-gouttelette¹⁷. Ainsi, la mise en place du protocole contre le SARS-CoV-2 a également affecté l'incidence de la grippe¹⁸.

2 - Tendances de la température moyenne en France (X1)

Graphique 2 : Evolution de la température moyenne en France de 1990 à décembre 2023



source : auteur et Greta

En utilisant le graphique 2, nous pouvons observer une saisonnalité de la température qui est cohérente avec un pays de climat tempéré, notamment avec une prédominance d'un climat océanique, tel que celui de la France¹⁹. Nous remarquons également que la tendance globale de ces variations semble être statique, sans

¹⁷ Pollock, Allyson M., and James Lancaster. "Asymptomatic transmission of covid-19." *bmj* 371 (2020). (consulté le 09/03/24)


¹⁸ Desvaux, Édouard, and Jean-François Faucher. "Covid-19: aspects cliniques et principaux éléments de prise en charge." *Revue Francophone des Laboratoires* 2020.526 (2020): 40-47. (consulté le 09/03/24)

¹⁹ Ouzeau, G., et al. "Le climat de la France au XXIe siècle." *Scénarios régionalisés: édition* (2014). (consulté le 10/03/24)

augmentation ni diminution significative au fil des années. (Il est important de souligner que notre analyse se base sur un échantillon limité, allant de 1990 à 2023. Nous ne prétendons pas ignorer ou remettre en question le changement climatique.)

3 - Tendence de la densité de la population française (X2)

Graphique 3 : Evolution de la densité de population française de 1990 à décembre 2023



source : auteur et Gretl

Grâce au graphique 3, nous pouvons observer une tendance globale à l'augmentation de la densité de la population française, ce qui peut être expliqué par l'augmentation de la population, comme mentionné dans notre revue de littérature. Cependant, contrairement aux deux autres séries, nous ne remarquons pas de saisonnalité dans la densité de la population française²⁰.

Cette section nous a permis de mieux comprendre les tendances globales de nos séries. Cependant, pour approfondir notre analyse, il est essentiel de comprendre les différentes relations entre ces séries, en particulier entre l'incidence de la grippe et les séries explicatives.


²⁰ François, Nathalie, Pierre Frankhauser, and Denise Pumain. "Villes, densité et fractalité." *Les Annales de la recherche urbaine*. No. 67. 1995. (consulté le 10/03/24)

C) Analyse des corrélations et relation entre la série à expliquer et les séries explicatives

Dans cette partie, nous examinerons les évolutions conjointes en utilisant d'abord une visualisation des séries, suivie d'une analyse de la corrélation. L'objectif est de mettre en évidence une corrélation ou une relation entre deux variables et d'observer comment elles interagissent au fil du temps. Notre analyse se concentrera principalement sur les relations entre notre variable à expliquer et les variables explicatives.

1 - Corrélation entre l'incidence de la grippe en France et la température moyenne en France (Y et X1)

Graphique 4 : Evolution conjointe de l'incidence de la grippe et de la température en France




source : auteur et Gretl

Nous pouvons analyser le graphique 4 et observer une tendance selon laquelle une augmentation de la température semble être associée à une diminution de l'incidence de la grippe. En effet, les pics épidémiques sont plus fréquents lorsque les températures moyennes en France sont au plus bas. Cette observation visuelle semble valider notre hypothèse initiale formulée dans notre revue de littérature. Cependant, il est important de noter que les visualisations peuvent parfois être trompeuses. Par

conséquent, pour confirmer notre observation, nous avons calculé la corrélation entre la température et l'incidence de la grippe, qui s'élève à -0,56 (voir annexe 4). Cette corrélation soutient notre étude visuelle et notre revue de littérature, renforçant ainsi notre compréhension de la relation entre ces deux variables.

2 - Corrélation entre l'incidence de la grippe en France et la densité de population française. (Y et X2)

Graphique 5 : Evolution conjointe de l'incidence de la grippe et de la densité de la population française en France



source : auteur et Gretl

En analysant le graphique 5, il est évident qu'il n'y a pas de corrélation visuelle claire entre les deux séries. Cependant, nous pouvons émettre l'hypothèse que ces deux séries, bien qu'elles ne présentent pas de lien visuel fort, ont des tendances différentes. En effet, la densité de la population française semble augmenter de manière continue, tandis que la tendance globale de l'incidence de la grippe montre une faible diminution, comme en témoigne la baisse progressive des pics épidémiques dans les années 2020 à 2023. Par conséquent, il est nécessaire de calculer la corrélation entre ces deux séries pour confirmer cette hypothèse. Suite au calcul de corrélation, nous obtenons un résultat de -0,04. Cette corrélation faible confirme notre hypothèse initiale formulée lors de la visualisation des données. Cependant, il est important de noter que cette hypothèse semble en opposition avec les conclusions de la littérature scientifique.

3 - récapitulatifs des corrélations attendues et observées.

Tableau 2 : Tableau récapitulatif des corrélations attendue et observé

	Revue de littérature	Visualisation	Résultat corrélation
Y et X1	Négative	Négative	- 0,56
Y et X2	Positive	Négative	- 0,04

source : auteur, Rstudio et Annexe 4

Nous pouvons constater que l'une de nos hypothèses formulées lors de la revue de littérature a été confirmée, à savoir la relation entre l'incidence de la grippe et la température moyenne en France. Cependant, pour notre deuxième hypothèse, l'erreur peut être expliquée de deux manières différentes. Néanmoins nous pouvons expliquer ce résultats par 2 phénomènes :

- le décalage temporel : il pourrait y avoir un décalage temporel entre les changements de densité de population et les variations de l'incidence de la grippe. Ce décalage temporel peut expliquer ce résultat atypique dans la corrélation entre ces deux variables.
- la nature complexe des interactions : la complexité des interactions entre différents facteurs peut jouer un rôle. En effet, la densité de population est un indicateur des relations sociales, mais d'autres facteurs tels que les politiques de transport, de santé publique, etc., peuvent également influencer nos comportements.

Ainsi, ces deux principes peuvent contribuer à notre compréhension des résultats observés et soulignent l'importance d'une analyse approfondie des interactions complexes entre les variables.

IV - Présentation de la méthodologie ARIMA

La méthode statistique ARIMA (AutoRegressive Integrated Moving Average) a été développée dans les années 1970 par plusieurs scientifiques britanniques, notamment George Box et Gwilym Jenkins. Elle est utilisée pour modéliser et prédire des séries chronologiques. La modélisation ARIMA comprend deux processus : la partie AR (paramètre p) et la partie MA (paramètre q). La partie AR représente la composante autorégressive, qui modélise la dépendance des observations actuelles par rapport aux observations passées, en respectant la condition de stationnarité. La partie MA représente le processus de moyenne mobile, modélisant la dépendance des observations actuelles par rapport aux erreurs de prédictions passées, en respectant la condition d'inversibilité. Ainsi, plusieurs étapes sont nécessaires pour la bonne application de la méthode ARIMA. Dans notre étude, nous utiliserons cette méthode pour analyser la relation entre l'incidence de la grippe, la température moyenne en France et la densité de population française. Elle nous permettra de modéliser les séries en prenant en compte les observations passées, les tendances, les saisons et les corrélations à court terme dans les données afin de prédire les valeurs futures tout en respectant les énoncées précédemment étant :

- La condition de stationnarité, AR(p) :

$$\left| \sum_{i=1}^p \varphi_i \right| < 1 \text{ avec } p \in \mathbb{N}$$

- La condition d'inversibilité, MA(q) :

$$\left| \sum_{i=1}^q \theta_i \right| < 1 \text{ avec } q \in \mathbb{N}$$

A) Le principe de stationnarité

La stationnarité, un concept crucial dans la méthodologie ARIMA (AutoRegressive Integrated Moving Average). En effet, pour que l'ARIMA puisse être appliqué, il est impératif que les séries temporelles soient stationnaires ou rendues stationnaires par une transformation appropriée. Ainsi, toute série temporelle doit respecter trois conditions fondamentales pour être analysée :

1. Une espérance mathématique indépendante du temps (t) :

$$E[X_t] = \mu$$

où $E[X_t]$ est l'espérance de la variable aléatoire (X) à un instant donné (t), et (μ) est une constante indépendante du temps.

2. Une variance indépendante du temps (t) :

$$Var[X_t] = \sigma^2$$

où $Var[X_t]$ est la variance de la variable aléatoire (X) à un instant donné (t), et (σ^2) est une constante indépendante du temps.


3. Une covariance indépendante du temps (t) et dépendante du nombre de périodes séparant les observations :

$$Cov[X_t, X_{t+k}] = \gamma(k)$$

où $Cov[X_t, X_{t+k}]$ est la covariance entre la variable aléatoire (X) à l'instant (t) et la variable aléatoire (X) à un instant (t+k), et $\gamma(k)$ une fonction dépendant du nombre de périodes séparant les observations.

Garantir la stationnarité des séries temporelles est essentiel pour assurer la fiabilité des analyses et des prévisions réalisées avec la méthodologie ARIMA. Pour ce faire, différentes techniques sont employées pour rendre une série stationnaire, tant pour sa moyenne que pour sa variance. Dans notre étude, nous privilégions initialement la méthode de transformation (Figure 1), en particulier le passage au logarithme, pour rendre la variance stationnaire. Par la suite, pour stabiliser la moyenne, nous appliquons la méthode de différenciation (Figure 1) soit de manière classique soit de manière saisonnière, intégrant la série selon un certain ordre (d'ordre d). Cette approche implique la soustraction de chaque observation de la série temporelle par l'observation précédente, ce qui supprime toute tendance ou variation globale dans la série.

Figure 1 : Processus de stationnarisation



sources : auteur

B) Les corrélogrammes

Une fois que nous avons établi la stationnarité de nos séries, nous pouvons utiliser le corrélogramme, un outil statistique conçu pour visualiser les corrélations entre les différentes observations d'une série temporelle en fonction de leur écart de temps. Le corrélogramme nous permet d'analyser les tendances saisonnières, d'identifier les retards significatifs, d'évaluer la stationnarité et de diagnostiquer le modèle ARIMA. Cette analyse nous aide à choisir les meilleurs paramètres (AR, MA, SAR, SMA) dans la mise en place du modèle Box-Jenkins.


Dans notre étude, nous utiliserons simultanément deux formes de corrélogramme simultanément. Le premier étant le corrélogramme FAC (Fonction d'Auto-corrélation), qui nous permet d'analyser les corrélations simples entre les observations de la série temporelle à différents retards. Ainsi, nous pourrions identifier au mieux les tendances saisonnières et les retards significatifs dans les données. Le deuxième type étant le corrélogramme FACP (Fonction d'Auto-corrélation Partielle), représentant les corrélations partielles entre les observations de la série temporelle à différents retards, tout en éliminant l'effet des retards intermédiaires. Ainsi, il nous permettra de déterminer les corrélations directes entre les observations à différents retards, en tenant compte des corrélations indirectes résultant des retards intermédiaires.

Ainsi, dans notre étude, une compréhension approfondie des corrélogrammes nous permettra d'effectuer une analyse précise et rigoureuse, contribuant ainsi à la qualité et à la pertinence de nos travaux.

C) Mise en place du modèle Box-jenkins

Suite à la compréhension du principe de la stationnarité et de l'importance des corrélogrammes, nous pouvons à présent expliciter le modèle que nous allons utiliser dans notre étude : le modèle de Box-Jenkins (Figure 2), qui se compose de quatre étapes.

Figure 2 : Processus du modèle Box-Jenkins



source : auteur

1 - Identification

La première étape, appelée "L'identification", intervient après la stationnarisation de la série temporelle. Elle consiste à analyser le corrélogramme (FAC et FACP) afin de sélectionner les paramètres appropriés pour le modèle ARIMA, tout en respectant certaines règles, notamment la règle de parcimonie. Cette règle spécifie l'utilisation minimale de paramètres dans un modèle, favorisant les modèles simples qui offrent une meilleure prévision par rapport aux modèles complexes.

Plusieurs types d'identification sont possibles. En effet il en existe 3.

Le premier type d'identification concerne une composante classique, souvent repérée par la significativité des premières valeurs dans le corrélogramme. Cette identification permet de proposer un modèle AR ou MA classique, établi avec leurs paramètres respectifs. Ainsi, le modèle proposé serait un ARIMA(p,d,q), où le paramètre p représente le processus AR, q représente le processus MA, et d représente l'ordre

d'intégration de la série établie par une différenciation classique (pouvant être soit 0 soit 1).

Le deuxième type d'identification concerne une composante saisonnière, identifiée notamment par une significativité suivant un certain multiple après la partie classique (par exemple, un multiple de 12 pour les séries mensuelles). Cette identification conduira à mettre en évidence un modèle saisonnier SAR ou SMA, avec leurs paramètres respectifs. Ainsi, le modèle SARIMA(P,D,Q)_s est défini, où le paramètre P représente le processus SAR, Q représente le processus SMA, et D représente l'ordre d'intégration de la série établie par une différenciation saisonnière (pouvant être soit 0 soit 1).

Enfin, le dernier type est induit par l'identification d'une composante classique et saisonnière. Dans ce cas, cela conduit à la mise en place d'un modèle mixte ou bien nommé un modèle multiplicatifs suivant ainsi les paramètres aussi bien d'un modèle classique que d'un modèle saisonnier(p,d,q)(P,D,Q)_s.

2 - Estimation

Suite au bon processus d'identification, nous pouvons à présent passer à l'étape de l'estimation. Cette phase consiste à estimer les coefficients des paramètres, tout en analysant particulièrement la significativité de ces derniers. Il est important de souligner que seuls les paramètres significatifs doivent être inclus dans notre modèle. Néanmoins, la significativité n'est pas la seule considération ; il est également crucial de prendre en compte les conditions d'inversibilité et de stationnarité, comme nous l'avons vu précédemment. Il convient de noter que si ces conditions ne sont pas remplies, un retour à l'étape précédente est nécessaire.

3 - Vérification

Suite à l'étape d'estimation, il est primordial de vérifier nos résultats. Ainsi, la vérification passe par l'analyse des résidus du modèle, démontrant ainsi qu'ils suivent bien un processus de bruit blanc. Ensuite, l'analyse de la statistique Q issue du test de Portmanteau est effectuée, en émettant l'hypothèse H_0 d'indépendance des résidus. Cette mesure statistique nous permet notamment de vérifier la qualité de notre modèle.

En effet, une statistique supérieure à 0,05 valide l'hypothèse et démontre une qualité supérieure de notre modèle. Il est important de souligner que la validité de cette étape est nécessaire dans le but de poursuivre notre processus. Sinon, il est nécessaire de retourner à l'étape de l'identification si les résidus ne suivent pas un processus de bruit blanc.

4 - Prédiction

Pour finir, une fois que les trois étapes précédentes ont été vérifiées, nous pouvons alors passer à la dernière étape, celle de la prédiction. Cette phase s'appuiera sur notre meilleur modèle, c'est-à-dire un modèle possédant des résidus suivant un processus de bruit blanc et offrant une bonne qualité. Cette étape consiste à utiliser le modèle estimé pour prédire les valeurs futures de la série chronologique. Les prévisions seront réalisées à l'aide de nos meilleurs modèles ARIMA. Un bon modèle se traduit par des prévisions se rapprochant au maximum des valeurs réelles. Ainsi, nous pourrons comparer les erreurs de prévision de nos différents modèles afin de conclure lequel permet de mieux prédire.

V - Sélection des modèle ARIMA


Suite à l'explication de nos séries temporelles et de notre méthode utilisée dans cette étude, nous pouvons à présent appliquer le modèle Box-Jenkins sur notre dossier. Nous travaillerons sur l'incidence mensuelle de la grippe en France de janvier 1990 à janvier 2024. Ainsi, notre prédiction sera faite pour le mois de février 2024.

A) Choix du modèle pour l'incidence de la grippe en France (Yt)

1 - Stationarisation

Nous pouvons débuter notre analyse en examinant la stationnarité de notre série. L'examen de la figure 3 et notamment l'analyse du graphique, nous révèle que notre série brute ne semble être stationnaire, ni en termes de variance, où les variations ne sont pas uniformes, ni en termes de moyenne. Cette constatation est notamment confirmée par l'étude du corrélogramme. En effet, nous pouvons remarquer l'absence de bruit blanc et une forme sinusoïdale des valeurs dans la FAC (Fonction d'Auto-Corrélation) qui ne converge pas vers zéro. De plus, la majorité de nos valeurs sont significatives, démontrant ainsi une fois de plus la non-stationnarité de notre série tant en termes de moyenne que de variance. Ainsi, il est nécessaire de stationnariser notre série.


Figure 3 : Visualisation graphique et Corrélogramme de la série brut



sources : auteur et Gretl

Dans notre processus de stationnarisation de la série, en vue d'effectuer une analyse rigoureuse, nous aborderons d'abord la résolution du problème de non-stationnarité de la variance en utilisant le processus de transformation logarithmique sur notre série brute.

Figure 4 : Comparaison série logarithmique et série brute et corrélogramme de la série logarithmique




sources : auteur et Gretl

L'analyse du figure 4 nous révèle une nette amélioration de la variance de notre série après transformation logarithmique (représentée en orange) par rapport à la série brute (représentée en vert). En effet, la variabilité de notre série semble beaucoup plus uniforme, comme en témoigne l'échelle où la série transformée varie désormais entre 8 et 15 au lieu de 0 et $2.5e^6$. Cependant, malgré cette amélioration, le corrélogramme de la série transformé (Figure 4) semble montrer peu de variations. En effet, nous observons toujours l'absence de bruit blanc, une distribution sinusoïdale des valeurs sans retour rapide vers zéro, et enfin une significativité pour la majorité des valeurs, bien que leur niveau de significativité semble avoir diminué, notamment pour les valeurs présentes dans la fonction d'autocorrélation partielle (FAC). De cette manière, l'absence de changement dans le corrélogramme pourrait s'expliquer par le maintien de la non-stationnarité de la moyenne. Il nous est donc impératif de la stationnariser afin de pouvoir appliquer la méthode de Box-Jenkins."

Suite à la stationnarisation de la variance, nous procédons dès lors à la résolution de la non-stationnarité de la moyenne en utilisant notamment le processus de

différenciation, pouvant être soit classique soit saisonnier, comme précédemment expliqué.

Figure 5 : Visualisation graphique et Corrélogramme de la série logarithmique différencier de manière classique




sources : auteur et Gretl

Nous amorçons dès lors notre processus de résolution de la non-stationnarité de la moyenne en appliquant dans un premier temps une différenciation classique à notre série logarithmique. Cette différenciation classique semble être efficace à première vue. En examinant le graphique de la figure 5, nous constatons que notre série oscille autour d'une moyenne de 0, ce qui pourrait démontrer la stationnarité de notre série. Toutefois, pour confirmer la véracité de notre constat, nous analysons le corrélogramme de la série différenciée de manière classique. Malgré la différenciation, le corrélogramme indique toujours l'absence de bruit blanc, une forme sinusoïdale des valeurs sans convergence vers 0, et enfin la majorité des valeurs demeurant significatives. Dans ces conditions, nous concluons que la différenciation classique ne suffit pas à rendre notre série stationnaire. Par conséquent, il serait nécessaire d'explorer d'autres méthodes de différenciation."

Nous entreprenons dès lors une autre méthode de différenciation en utilisant la différenciation saisonnière de notre série logarithmique dans le but de résoudre toujours notre complication de non stationnarité de la moyenne.

Figure 6 : Visualisation graphique et Corrélogramme de la série logarithmique différencier de manière saisonnière



sources : auteur et Gretl

Suite à l'application de la différenciation saisonnière à notre série logarithmique, nous pouvons analyser notre série sur le graphique de la figure 6. Nous remarquons que la série différenciée de manière saisonnière oscille autour d'une moyenne de 0, suggérant la stationnarité de notre série. Cependant, une confirmation par le corrélogramme de la figure 6 s'avère nécessaire. Nous observons trois caractéristiques : l'absence de bruit blanc, nos valeurs suivant une forme sinusoïdale mais étant considérablement aplaties et notamment un retour rapide vers 0 enfin, nous remarquons qu'il y a une minorité de valeurs significatives dans notre corrélogramme, Ces valeurs se manifestent par des pics dans les premières valeurs tant pour la fonction d'autocorrélation (FAC) que pour la fonction d'autocorrélation partielle (FACP), montrant une composante classique dans notre série, et sont également présentes à des multiples de 12, montrant également une partie saisonnière de notre série. De cette manière, ces caractéristiques du corrélogramme démontrent la stationnarité de la moyenne de notre série.

Suite à la transformation en logarithme et à la différenciation saisonnière, nous avons réussi à résoudre le problème de non-stationnarité. Nous pouvons donc dès lors passer à l'étape suivante : l'identification et l'estimation de notre série.

2 - Identification & Estimation

Le critère de stationnarité de notre série démontré, nous pouvons dès lors passer à l'étape d'identification. L'analyse du corrélogramme de notre série logarithmique différenciée de manière saisonnière lors de la stationnarisation de notre série nous a permis de mettre en évidence grâce à l'étude du corrélogramme de la figure

6 et notamment de la FAC et FACP nous à permis de mettre en évidence la présence à la fois d'une composante classique et saisonnière. Dans ces conditions, l'utilisation d'un modèle mixte est primordiale afin d'aux mieux modéliser notre série.

C'est donc dans ces conditions que nous proposons, dans un premier temps, un modèle mixte possédant une composante de moyenne mobile d'ordre 1 (MA(1)) et une moyenne mobile saisonnière d'ordre 1 également (SMA(1)), prenant en compte les tendances générales et les variations saisonnières de notre série.

Modélisation 1 : Proposition d'un modèle mixte ARIMA(0,0,1)(0,1,1)




Tableau 3 : Récapitulatif du modèle ARIMA(0,0,1)(0,1,1) avec constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(0,0,1)(0,1,1)	2	2	0.647	0.681	0.014	853

sources : auteur et Gretl Annexe 5

Grâce à l'étude de la modélisation 1 et du tableau 3, nous sommes en mesure d'observer les résultats du premier modèle. Dans un premier temps, nous remarquons que nos paramètres (θ_1 et Θ_1) sont tous deux significatifs et qu'ils confirment les conditions d'inversibilité, en effet $|0,596024 - 0,924706| < 1$. Cependant, la constante, quant à elle, ne présente pas de significativité. Ainsi, il sera nécessaire de la retirer et de procéder à une nouvelle modélisation sans cette constante. Enfin, l'étude du corrélogramme de la modélisation 1, nous permet de constater que des pics significatifs persistent dans les composantes classiques de la FAC et de la FACP, suggérant ainsi une modélisation inadéquate de cette composante. De plus, la statistique Q associée au test

de portmanteau pour le dernier retard est inférieure à 0,05, ce qui nous conduit à envisager un autre modèle en raison de sa qualité insuffisante. Les pics identifiés dans la composante classique nous incitent à proposer un nouveau modèle, intégrant un nouveau paramètre AR(1).

Tableau 4 : Récapitulatif du modèle ARIMA(0,0,1)(0,1,1) sans constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(0,0,1)(0,1,1)	2	2	0.648	0.681	0.014	851

sources : auteur et Gretl annexe 6

Cette nouvelle modélisation (tableau 4) ne modifie ni la significativité de nos paramètres, ni la validité des conditions d'inversibilité, ni la forme du corrélogramme, ni la qualité globale du modèle. La statistique Q demeure en dessous de 5%, ce qui souligne toujours la nécessité de proposer un nouveau modèle. Bien que cette modélisation apporte une légère amélioration en réduisant le critère AIC de 2 points, le corrélogramme inchangé confirme la persistance des mêmes problèmes.


Ainsi, le maintien des caractéristiques du corrélogramme dans cette modélisation (modélisation 2) nous conduit à proposer la même solution que précédemment, suggérant donc l'adoption du nouveau modèle ARIMA(1,0,1)(0,1,1).

Modélisation 2 : Proposition d'un modèle mixte ARIMA(1,0,1)(0,1,1)

Évaluations de la fonction : 58
Évaluations du gradient : 17

Modèle 26: ARMA, utilisant les observations 1991:01-2024:01 (T = 397)
Estimation par AS 197 (MV exact)
Variable dépendante: sd_l_INCIDENCE
Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique
const	0.00399887	0.00997525	0.4009	0.6885
phi_1	0.415134	0.0624760	6.645	3.04e-11 ***
theta_1	0.349956	0.0586468	5.967	2.41e-09 ***
Theta_1	-0.916180	0.0328739	-27.87	6.25e-171 ***
Moyenne var. dép.	0.038085	Éc. type var. dép.	1.147023	
Moyenne innovations	0.005678	Éc. type innovations	0.653899	
R2	0.674227	R2 ajusté	0.672573	
Log de vraisemblance	-405.9249	Critère d'Akaike	821.8499	
Critère de Schwarz	841.7695	Hannan-Quinn	829.7406	
	Réel	Imaginaire	Modulo	Fréquence
AR				
Ordre 1	2.4089	0.0000	2.4089	0.0000
MA				
Ordre 1	-2.8575	0.0000	2.8575	0.5000
MM (saisonnalité)				
Ordre 1	1.0915	0.0000	1.0915	0.0000



sources : auteur et Gretl

Tableau 5 : Récapitulatif du modèle ARIMA(1,0,1)(0,1,1) avec constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(1,0,1)(0,1,1)	3	3	0.672	0.653	0.586	821

sources : auteur et Gretl annexe 7

L'étude du nouveau modèle, notamment à travers l'analyse des résultats de la modélisation 2 et du tableau 5, nous permet d'approfondir notre compréhension de ces résultats. Dans un premier temps, nous constatons que nos trois paramètres (θ_1 , θ_1 et ϕ_1) sont significatifs et qu'ils respectent à la fois les conditions d'inversibilité ($|0,34 - 0,91| < 1$) et de stationnarité ($|0,45| < 1$). Cependant, nous notons la non significativité de la constante, nous conduisant à modéliser ce modèle sans la constante. De plus, l'examen du corrélogramme révèle qu'il ne reste qu'un pic significatif dans les trois premiers retards, démontrant ainsi l'efficacité de l'introduction du paramètre AR(1) dans notre modèle. Enfin, l'analyse du tableau 5 met en évidence que la statistique Q associée au test de portmanteau pour le dernier retard est supérieure à 0,05, ce qui nous conduit à accepter le modèle en raison de sa bonne qualité.

Tableau 6 : Récapitulatif du modèle ARIMA(1,0,1)(0,1,1) sans constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(1,0,1)(0,1,1)	3	3	0.672	0.653	0.583	820

sources : auteur et Gretl annexe 8

Cette nouvelle modélisation (tableau 6) de notre modèle ARIMA sans la constante nous conduit aux mêmes conclusions que précédemment. En effet, le modèle est également accepté, il présente le même corrélogramme et apporte une légère amélioration du critère AIC. Ainsi, nous pourrions considérer notre recherche de modèle ARIMA pour modéliser notre série Y_t comme étant concluante, car nous disposons maintenant d'un modèle valide. Cependant, par souci de rigueur, nous continuerons nos recherches dans l'espoir de trouver éventuellement un modèle encore plus adapté.

Étant donné que cette modélisation (modélisation 2) présente le même corrélogramme, nous pourrions envisager l'introduction d'un nouveau paramètre AR afin d'éliminer tout pic dans la partie classique et d'obtenir un processus de bruit blanc. Ainsi, nous suggérons comme nouveau modèle ARIMA(2,0,1)(0,1,1).

Modélisation 3 : Proposition d'un modèle mixte ARIMA(2,0,1)(0,1,1)


Evaluations de la fonction : 70
Évaluations du gradient : 18

Modèle 27: ARMA, utilisant les observations 1991:01-2024:01 (T = 397)
Estimation par AS 197 (MV exact)
Variable dépendante: sd_INCIDENCE
Ecart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique	
const	0.00390925	0.00824371	0.4742	0.6354	
phi_1	0.835895	0.141423	5.911	3.41e-09	***
phi_2	-0.325270	0.0928449	-3.503	0.0005	***
theta_1	-0.0499377	0.147220	-0.3392	0.7345	
Theta_1	-0.918590	0.0342659	-26.81	2.63e-158	***

Moyenne var. dép.	0.038085	Éc. type var. dép.	1.147023
Moyenne innovations	0.007264	Éc. type innovations	0.646641
R2	0.681449	R2 ajusté	0.679017
Log de vraisemblance	-401.6891	Critère d'Akaike	815.3782
Critère de Schwarz	839.2819	Hannan-Quinn	824.8472

	Réel	Imaginaire	Modulo	Fréquence
AR				
Ordre 1	1.2849	-1.1930	1.7534	-0.1191
Ordre 2	1.2849	1.1930	1.7534	0.1191
MM				
Ordre 1	20.0250	0.0000	20.0250	0.0000
MM (saisonnalité)				
Ordre 1	1.0886	0.0000	1.0886	0.0000



sources : auteur et Gretl

Tableau 7 : Récapitulatif du modèle ARIMA avec constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(2,0,1)(0,1,1)	3	4	0.679	0.646	0.825	821

sources : auteur et Gretl Annexe 9

Suite à l'introduction d'un nouveau paramètre AR, nous pouvons maintenant analyser les résultats du troisième modèle à travers la modélisation 3 et le tableau 7. Nous constatons que la plupart de nos paramètres (θ_1, ϕ_1 et ϕ_2) sont significatifs et qu'ils respectent à la fois les conditions de stationnarisation ($|0,83 - 0,32| < 1$) et d'inversibilité ($|-0,91 - 0,049| < 1$). Cependant, nous remarquons également que la constante et le paramètre de moyenne mobile d'ordre 1 (θ_1) ne sont pas significatifs. Par la suite, l'analyse du corrélogramme dans la modélisation 3 révèle la présence de bruit blanc, avec l'absence de tout pic significatif dans la FAC et la FACP, démontrant ainsi l'efficacité notre modèle à capturer la variation temporelle des données de manière satisfaisante. Pour conclure, l'examen du tableau 7 met en évidence que la statistique Q associée au test de portmanteau pour le dernier retard est supérieure à 0,05, ce qui nous conduit à accepter le modèle tout en confirmant sa bonne qualité.

Outre l'acceptation de ce modèle, il est important de mentionner qu'une nouvelle modélisation est nécessaire en raison de la non-significativité de certains paramètres comme énoncé plus tôt. Ainsi, nous modélisons notre nouveau modèle sans la constante et la moyenne mobile d'ordre 1. Nous obtenons alors un modèle ARIMA(2,0,0)(0,1,1).

Modélisation 4 : Proposition d'un modèle mixte ARIMA(2,0,0)(0,1,1)


Évaluations de la fonction : 53
Évaluations du gradient : 14

Modèle 5: ARMA, utilisant les observations 1991:01-2024:01 (T = 397)
Estimation par AS 197 (MV exact)
Variable dépendante: sd_l_INCIDENCE
Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique	
phi_1	0.790738	0.0481052	16.44	1.03e-60	***
phi_2	-0.296999	0.0479880	-6.189	6.05e-10	***
Theta_1	-0.919296	0.0339747	-27.06	3.05e-161	***

Moyenne var. dép.	0.038085	Éc. type var. dép.	1.147023
Moyenne innovations	0.021127	Éc. type innovations	0.646838
R2	0.681552	R2 ajusté	0.679935
Log de vraisemblance	-401.8582	Critère d'Akaike	811.7165
Critère de Schwarz	827.6522	Hannan-Quinn	818.0291

	Réel	Imaginaire	Modulo	Fréquence
AR				
Ordre 1	1.3312	-1.2629	1.8349	-0.1208
Ordre 2	1.3312	1.2629	1.8349	0.1208
MM (saisonnalité)				
Ordre 1	1.0878	0.0000	1.0878	0.0000



sources : auteur et Gretl

Tableau 8 : Récapitulatif du modèle ARIMA (2,0,0)(0,1,1)

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(2,0,0)(0,1,1)	3	3	0.679	0.648	0.851	811

sources : auteur et Gretl Annexe 10

Suite à la non prise en compte des paramètres non significatifs, nous pouvons alors analyser les résultats du nouveau modèle à travers la modélisation 4 et le tableau 8. Nous observons que désormais tous nos paramètres (θ_1, ϕ_1 et ϕ_2) sont significatifs, et qu'ils respectent toujours les conditions d'inversibilité ($|-0,92| < 1$) et de stationnarité ($|0,79 - 0,296| < 1$). Par la suite, grâce à l'étude du corrélogramme de la modélisation 4, nous constatons qu'il persiste toujours du bruit blanc, démontrant ainsi que le modèle prend toujours en compte la variation temporelle des données. Enfin, le modèle est toujours accepté, car la statistique Q est supérieure à 0,05.

Grâce à tout le processus d'identification et d'estimation, nous avons pu mettre en évidence trois modèles validés par le test de portmanteau. Cependant, nous ne

sélectionnons que deux modèles : $ARIMA(1, 0, 1)(0, 1, 1)_{s=12}$ et $ARIMA(2, 0, 0)(0, 1, 1)_{s=12}$. En effet, le troisième modèle présenté ici n'est autre que le deuxième modèle sans les paramètres non significatifs et donc la règle de parcimonie nous spécifie qu'il faut utiliser le moins de paramètres possible. Ainsi, ce choix est fait en vue de la suite de notre processus de prévision.

3 - Prévision à une période

Suite à l'étape d'identification et d'estimation et la mise en évidence de deux modèles, nous pouvons passer dès lors à la prévision à une période de notre série Y_t c'est à la prévision de l'incidence de la grippe en France en février 2024. Il est important de souligner que pour cette étape nous avons au préalable retiré de manière volontaire les données de février 2024 (tableau 9) dans le but de pouvoir vérifier l'efficacité et la rigueur de nos modèles de prévision.

Tableau 9 : Valeurs des séries temporelles pour février 2024

	Incidence de la grippe	Densité de population	Température moyenne
Valeurs	648 943	119,90	9,4

sources : auteur

a - Prévision à une période du modèle $ARIMA(1, 0, 1)(0, 1, 1)_{s=12}$

Pour cette prévision, nous utiliserons le modèle $ARIMA(1, 0, 1)(0, 1, 1)_{s=12}$ en utilisant la méthode Box-jenkins, ce processus consiste à calculer les prévision $Z_t(I)$, sont calculées de manière récursive en utilisant une approche itérative (voir annexe 11). La première étape consiste à établir la prévision à l'horizon $l = 1$, puis cette valeur est utilisée pour obtenir la prévision à l'horizon $l = 2$. ainsi il est primordial au préalable de définir Z_t . Nous aurons à gauche la partie $AR(1)$ avec notamment son paramètre (ϕ_1) et Z_t représentant la série temporelle ajustée, tandis qu'à droite nous aurons la partie $MA(1)$ et $SMA(1)$ avec notamment leurs paramètres (θ_1 et Θ_1) a_t représentant le terme d'erreurs. Ainsi, l'équation peut s'écrire

$$Z_t(1 - \phi_1 B) = a_t(1 - \theta_1 B)(1 - \theta_1 B^{12})$$

$$\Leftrightarrow Z_t(1 - \phi_1 B) = a_t(1 - \theta_1 B - \theta_1 B^{12} + \theta_1 \theta_1 B B^{12})$$

Dans cette équation, nous pouvons remarquer que nous utilisons l'opérateur B^n permettant de contenir la différenciation dans le temps dans le but de factoriser Z_t et a_t . Par ailleurs, il représente également le retrait de n périodes. De plus, nous savons que B^n se simplifie en Z_{t-n} , ainsi nous pouvons simplifier l'équation et nous obtenons alors :

$$Z_t = \phi_1 Z_{t-1} + a_t - a_{t-1}\theta_1 - a_{t-12}\theta_1 + a_{t-13}\theta_1\theta_1$$

Cette équation nous permet alors d'établir mathématiquement l'équation de prévision, où nous cherchons à déterminer Z_{t+1} au lieu de Z_t . La prise en compte de divers critères tels que l'historique des données, en intégrant les termes d'erreur jusqu'à n-1 ainsi que les valeurs passées. Il est important de souligner que nous ne retrouverons a_{t+1} dans l'équation car étant inconnu. Mais en supposant un modèle avec un comportement des résidus de manière bruit-blanc, nous le considérons comme nulle. L'équation de prévision est formulée tel que :

$$Z_{t+1} = \phi_1 Z_t - a_t\theta_1 - a_{t-11}\theta_1 + a_{t-12}\theta_1\theta_1$$

Par la suite des formulations mathématiques des équations, nous pouvons passer dès lors au calcul de la prévision à une période grâce au modèle présenté précédemment en remplaçant les paramètres de l'équation. Ainsi, nous savons grâce à l'annexe 5 les coefficients des paramètres $\phi_1 = 0,416$, $\theta_1 = 0,350$ et $\theta_1 = -0,917$ et grâce au tableau 10 les valeurs du retard et de la série ajustée, ainsi nous savons $Z_t = 0,395$, $a_t = -0,045$, $a_{t-11} = 0,396$ et $a_{t-12} = -0,121$.

Tableau 10 : Valeur observé, ajusté et termes d'erreur du premier modèle

Période de l'estimation du modèle : 1991:01 - 2024:01
Écart-type de la régression = 0.653984

	sd_l_INCIDENCE	ajusté	résidu
2021:10	-0.329511	-0.550017	0.220506
2021:11	-0.061967	-0.094739	0.032772
2021:12	1.167813	1.734945	-0.567132
2022:01	1.346227	1.384267	-0.038040
2022:02	0.678898	1.776853	-1.097956
2022:03	1.704600	-0.114168	1.818768 *
2022:04	1.896551	1.091308	0.805243
2022:05	1.050296	0.650347	0.399949
2022:06	1.794853	0.778490	1.016362
2022:07	1.205504	0.431295	0.774209
2022:08	0.153359	-0.111582	0.264941
2022:09	0.866248	0.437809	0.428439
2022:10	1.013147	0.481049	0.532098
2022:11	1.019944	0.507126	0.512817
2022:12	1.668448	1.113003	0.555445
2023:01	0.380590	1.104748	-0.724157
2023:02	0.802442	0.923414	-0.120972
2023:03	-0.627612	-1.023204	0.395592
2023:04	-0.931515	-1.443149	0.511634
2023:05	-0.004332	-0.832917	0.828585
2023:06	-0.684975	-0.771499	0.086525
2023:07	-0.499241	-1.289553	0.790311
2023:08	0.614403	-0.421901	1.036305
2023:09	0.758872	0.140702	0.618171
2023:10	0.249321	-0.092815	0.342136
2023:11	0.166065	-0.416832	0.582897
2023:12	-0.358688	-0.400311	0.041623
2024:01	0.394554	0.350972	0.043582

Note : * indique un résidu supérieur à 2,5 fois l'écart-type
Statistiques sur la qualité de la prévision utilisant 397 observations

Moyenne Erreur	0.017798
Moyenne Erreur Carrée (racine)	0.65398
Moyenne Erreur Absolue	0.51438
Moyenne Pourcentage Erreur	-0.54447
Moyenne Pourcentage Erreur Absolue	256.82
U2 de Theil	0.4064

sources : auteur et Gretl

En remplaçant nos valeurs dans l'équation de prévision, nous pouvons calculer la prévision à une période, c'est-à-dire Z_{t+1} :

$$\begin{aligned}
 Z_{t+1} &= 0,416 \times 0,395 + 0,045 \times 0,350 - 0,396 \times (-0,917) - 0,121 \times 0,350 \times (-0,917) \\
 &\Leftrightarrow Z_{t+1} = 0,164 + 0,016 + 0,363 + 0,039 \\
 &\Leftrightarrow Z_{t+1} = 0,582
 \end{aligned}$$

Suite au remplacement des valeurs dans l'équation prévisionnel, nous obtenons dès lors la prévision à une période de notre modèle, soit Z_{t+1} . Ce résultat nous permettra d'estimer la valeur de notre modèle pour février 2024. Pour ce faire, nous utiliserons une simple addition entre la valeur différence à une période t+1 de la série brute soit Z_{t+1} et la valeur logarithmique de notre série soit lY_t . Puis nous appliquons l'exponentiel au résultat, nous permettant d'obtenir Y_{t+1} . Ainsi, l'équation est formalisé tel que :

$$\begin{aligned}
 lY_{t+1} &= Z_{t+1} + lY_t \\
 \Leftrightarrow Y_{t+1} &= e^{lY_{t+1}}
 \end{aligned}$$

Cependant, avant l'application de cette équation, par nous procédons au préalable par une comparaison entre les résultats de prévision (calculés manuellement

et celui de gretl). Cette démarche, nous permet ainsi de mieux évaluer la fiabilité de nos résultats. Nous remarquons ainsi que la valeur prédite par Gretl s'élève à 0,522 (voir annexe 12), tandis que celle prédite manuellement est de 0,582, représentant ainsi une différence de 11,5% (voir annexe 13). Bien que cette divergence demeure limitée, nous optons pour la prédiction de Y_{t+1} en utilisant les deux résultats afin de déterminer la meilleure prévision pour notre modèle. Par conséquent, en remplaçant les valeurs connues dans l'équation formalisée tel que $lY_t = 13,389$ (voir annexe 14) et $Z_{t+1} = 0,582$ (calculé manuellement) puis $Z_{t+1} = 0,522$ (calculé par gretl), nous obtenons :

$$lY_{t+1} = 0,582 + 13,389$$

$$\Leftrightarrow lY_{t+1} = 13,971$$

Nous pouvons dès lors obtenir Y_{t+1}

$$Y_{t+1} = e^{13,971}$$

$$\Leftrightarrow Y_{t+1} = 1\,168\,229$$

Dans une finalité de comparaison des résultats entre nos divers modèles ainsi qu'entre nos valeurs (Gretl et manuelles), nous décidons de calculer l'erreur de prévision pour chaque valeurs dans un premier temps du modèle étudié. Nous utilisons alors l'équation d'erreur de prévision :

$$\text{Erreur de prévision} = \left| \frac{1\,168\,229 - 648\,943}{648\,943} \right| \times 100$$

$$\Leftrightarrow \text{Erreur de prévision} = 80,02\%$$

L'erreur de prévision en prenant compte notre valeur manuelle tel que $Z_{t+1} = 0,582$ vaut 80,02%, cela signifiant que l'estimation manuelle diffère de 80,02% de la valeur observée. Une erreur aussi élevée peut indiquer des lacunes dans la méthode de prédiction utilisée ou des erreurs dans les données d'entrée. Nous pouvons dès lors passer à la prévision avec la valeur gretl.

Ainsi, nous appliquons la même méthode afin d'obtenir les valeurs pour les paramètres tel que l'erreur prévision, Y_{t+1} pour la valeur obtenue par Gretl (voir annexe 15)

Tableau 11 : Comparaison de prédiction avec la valeurs manuel et celle de gretl pour le modèle $ARIMA(1,0,1)(0,1,1)$

	Z_{t+1}	lY_{t+1}	Y_{t+1}	Erreur de prévision
Valeur Manuelle	0,582	13,971	1 168 229	80,02%
Valeur Gretl	0,522	13,911	1 100 197	69,53%

sources : auteur, Annexe 15

L'analyse du tableau 11 nous permet d'identifier la meilleure valeur à utiliser lors de la prévision de Y_{t+1} . Cette valeur étant Z_{t+1} , dérivée de la série brute à une période $t+1$ selon les résultats de Gretl. Elle se distingue par le taux d'erreur de prévision le plus bas, évalué à 69,53%. Toutefois, ce taux demeure élevé, suggérant éventuellement des difficultés dans la prévision de notre série. Ce problème pourrait découler du Qstat moyen, qui s'établit à 0,583, ou de la grande taille de l'échantillon. En effet, un nombre élevé d'observations peut entraîner une complexification des modèles et une augmentation de la variabilité, ayant un impact significatif sur la précision des prévisions.

Une fois Y_{t+1} et le taux d'erreur de prévision calculés pour notre modèle $ARIMA(1, 0, 1)(0, 1, 1)_{s=12}$, nous sommes en mesure de procéder à la prévision de notre prochain modèle suivant la même méthode qu'utilisée précédemment. Cette nouvelle prédiction nous permettra de comparer les modèles et de sélectionner le plus performant.

b - Prédiction à une période du modèle $ARIMA(2, 0, 0)(0, 1, 1)_{s=12}$

Nous pouvons dès lors passer à la prévision de notre deuxième modèle $ARIMA(2, 0, 0)(0, 1, 1)_{s=12}$ (voir annexe 16) en suivant la méthode Box-Jenkins expliquée précédemment dans la partie de la prévision à une période du premier

modèle. Nous définissons en premier lieu notre équation Z_t de manière mathématique. Nous aurons à gauche la partie AR(2) avec notamment ses paramètres (ϕ_1 et ϕ_2) et Z_t , tandis qu'à droite nous aurons la partie SMA(1) avec notamment son paramètre (θ_1) et a_t . Ainsi, l'équation peut s'écrire :

$$Z_t(1 - \phi_1 B - \phi_2 B^2) = a_t(1 - \theta_1 B^{12})$$

Nous rappelons que nous savons que B^n se simplifie en Z_{t-n} , alors nous simplifions l'équation et nous obtenons alors :

$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + a_t - a_{t-12} \theta_1$$

Nous pouvons dès lors obtenir l'équation de prévision Z_{t+1} , l'équation de prévision du modèle est formulée :

$$Z_{t+1} = \phi_1 Z_t + \phi_2 Z_{t-1} - a_{t-11} \theta_1$$

Par la suite des formulations mathématiques des équations, nous pouvons passer dès lors au calcul de la prévision à une période grâce au modèle présenté précédemment en remplaçant les paramètres de l'équation. Ainsi, nous savons grâce à la modélisation 4 les coefficients des paramètres $\phi_1 = 0,791$, $\phi_2 = -0,297$ et $\theta_1 = -0,919$ et grâce au tableau 12 les valeurs du retard et de la série ajustée, ainsi nous savons $Z_t = 0,395$, $Z_{t-1} = -0,359$ et $a_{t-11} = 0,495$.

Tableau 12 : Valeur observé, ajusté et termes d'erreur

Période de l'estimation du modèle : 1991:01 - 2024:01			
Écart-type de la régression = 0.646838			
	sd_l_INCIDENCE	ajusté	résidu
2021:12	1.167813	1.755035	-0.587222
2022:01	1.346227	1.348549	-0.002322
2022:02	0.678898	1.770330	-1.091432
2022:03	1.704600	-0.085139	1.789739 *
2022:04	1.896551	1.181779	0.714771
2022:05	1.050296	0.782727	0.267569
2022:06	1.794853	0.643902	1.150951
2022:07	1.205504	0.299084	0.906419
2022:08	0.153359	-0.205397	0.358755
2022:09	0.866248	0.284952	0.581296
2022:10	1.013147	0.343132	0.670015
2022:11	1.019944	0.430382	0.589562
2022:12	1.668448	1.045403	0.623045
2023:01	0.380590	1.018298	-0.637708
2023:02	0.802442	0.808440	-0.005999
2023:03	-0.627612	-1.123078	0.495466
2023:04	-0.931515	-1.391315	0.459800
2023:05	-0.004332	-0.795833	0.791500
2023:06	-0.684975	-0.784423	0.099449
2023:07	-0.499241	-1.373056	0.873814
2023:08	0.614403	-0.520675	1.135078
2023:09	0.758872	0.100111	0.658761
2023:10	0.249321	-0.197999	0.447320
2023:11	0.166065	-0.569808	0.735874
2023:12	-0.358688	-0.515239	0.156551
2024:01	0.394554	0.253133	0.141422
Note : * indique un résidu supérieur à 2,5 fois l'écart-type			
Statistiques sur la qualité de la prévision utilisant 397 observations			
Moyenne Erreur			0.021127
Moyenne Erreur Carrée (racine)			0.64684
Moyenne Erreur Absolue			0.50965
Moyenne Pourcentage Erreur			2.0566
Moyenne Pourcentage Erreur Absolue			249.68
U2 de Theil			0.38067

sources : auteur et Gretl

En remplaçant nos valeurs dans l'équation de prévision, nous pouvons calculer la prévision à une période, c'est-à-dire Z_{t+1} , il est important de souligner que nous émettons l'hypothèse que le modèle prend déjà en compte le signe négatif de grand théta. Ainsi l'équation devient donc :

$$\begin{aligned}
 Z_{t+1} &= 0,791 \times 0,395 + (-0,297) \times (-0,359) - 0,495 \times (0,919) \\
 &\Leftrightarrow Z_{t+1} = 0,312 + 0,106 - 0,455 \\
 &\Leftrightarrow Z_{t+1} = -0,037
 \end{aligned}$$

Dans la continuité de notre analyse, nous confrontons les valeurs obtenues par Gretl ($Z_{t+1} = 0,42$ (voir annexe 17)) et celles déterminées manuellement ($Z_{t+1} = -0,037$). Cette comparaison, nous révèle une disparité significative, avec une différence équivalente à 108,8 %(voir annexe 18). Ainsi, dans le but de sélectionner la meilleure prévision pour notre modèle, il est nécessaire de prédire Y_{t+1} en utilisant les deux résultats. Pour ce faire, nous remplaçons les valeurs dans l'équation utilisée précédemment pour le calcul de Y_{t+1} ainsi que l'erreur de prévision. Nous utiliserons donc les paramètres suivants : $lY_t = 13,389$ (voir annexe 14), $Z_{t+1} = -0,037$

(calculé manuellement) et $Z_{t+1} = 0,42$ (calculé par Gretl). Dans un premier temps, nous résolvons les équations en utilisant la valeur obtenue manuellement pour Z_{t+1} . Nous obtenons alors :

$$lY_{t+1} = -0,037 + 13,389$$

$$\Leftrightarrow lY_{t+1} = 13,352$$

Nous pouvons dès lors obtenir Y_{t+1}

$$Y_{t+1} = e^{13,352}$$

$$\Leftrightarrow Y_{t+1} = 629\,071$$

$$\text{Erreur de prévision} = \left| \frac{629\,071 - 648\,943}{648\,943} \right| \times 100$$

$$\Leftrightarrow \text{Erreur de prévision} = 3,06\%$$

L'erreur de prévision en prenant en compte notre valeur manuelle tel que $Z_{t+1} = -0,037$ vaut 3,06%, cela signifiant que l'estimation manuelle diffère de 3,06% de la valeur observée. démontrant ainsi une bonne prévision de notre modèle $ARIMA(2, 0, 0)(0, 1, 1)_{s=12}$ avec la valeur manuelle. Ainsi, nous pouvons dès lors passer à la prévision avec la valeur gretl.

Par conséquence, nous appliquons la même méthode afin d'obtenir les valeurs pour les paramètre tel que l'erreur prévision, Y_{t+1} pour la valeur obtenue par Gretl (voir annexe 15)

Tableau 13 : Comparaison de prédiction avec la valeurs manuel et celle de gretl pour le modèle $ARIMA(2,0,0)(0,1,1)$

	Z_{t+1}	lY_{t+1}	Y_{t+1}	Erreur de prévision
Valeur Manuelle	-0,037	13,352	629 071	3,06%
Valeur Gretl	0,42	13,809	993 510	53,09%

sources : auteur, Annexe 19

En étudiant le tableau 13, nous pouvons définir la valeur privilégiée à prendre pour la prévision. Nous pouvons remarquer, que la différence dans l'erreur de prévision entre les deux valeurs est notable. En effet, la valeur Gretl est environ 17 fois plus importante que celle obtenue manuellement. Par conséquent, il nous est donc préférable d'opter pour la valeur manuelle afin d'obtenir l'erreur de prévisions la plus faible. Pour finir, il est important de souligner que nous semble en mesure d'expliquer cette différence si marquante entre les 2 valeurs.

Suite au calcul des prévisions et des erreurs de prévision, nous pouvons désormais comparer nos deux modèles et sélectionner le meilleur dans la prochaine partie. Cependant, il convient de noter que, pour la comparaison des modèles, nous utilisons les valeurs de Gretl, même si notre analyse montre que la valeur manuelle est meilleure pour notre deuxième modèle. Ce choix est justifié par le fait que la valeur de Gretl est prédite de manière informatique, ce qui réduit l'impact des erreurs humaines.

4 - Choix du meilleur modèle

Suite à la stationnarisation de notre série, à l'identification et à l'estimation d'un modèle ARIMA valide, ainsi qu'à la prévision à une période, nous pouvons alors sélectionner notre meilleur modèle. Il est primordial de mettre en évidence les principaux critères à prendre en compte pour le choix du modèle optimal. Ainsi, dans un objectif de rigueur, nous examinerons la performance de prévision, le nombre de paramètres significatifs, la qualité du modèle (l'AIC) et enfin le Qstat afin de définir le meilleur modèle.

Tableau 14 : Synthèse des modèles sélectionnés pour la prévision

MODÈLE	PARA SIGN	PARA	R^2	σ	Q-stat	AIC	Prévision	Erreur de prévision	N°
(1,0,1)(0,1,1)	3	3	0.672	0.653	0.586	821	1 100 197	69,53%	1
(2,0,0)(0,1,1)	3	3	0.679	0.646	0.852	813	993 510	53,09%	2

sources : auteur et Gretl

En étudiant le tableau 14, nous observons que c'est le modèle N°2 qui possède la meilleure erreur de prévision. Cette erreur étant de 53,09%, soit 0,7 fois plus petite que l'erreur de prévision du modèle N°1. Par la suite, nous ne pouvons sélectionner ces modèles par leur nombre de paramètres en utilisant notamment la règle de parcimonie car ces deux modèles possèdent le même nombre de paramètres. Ainsi, l'analyse de l'AIC est nécessaire. Par conséquent, nous pouvons remarquer que le modèle N°2 possède la meilleure AIC. Nous pouvons également remarquer que le modèle N°2 ne possède pas seulement le meilleur AIC, mais il possède également le meilleur R^2 , σ et Q-stat. Par conséquent, nous pouvons sans difficulté avancer que le meilleur modèle est le modèle $ARIMA(2, 0, 0)(0, 1, 1)_{s=12}$.

Résumé :

Une différenciation saisonnière et l'ajout d'un logarithme ont été suffisants pour respectivement la stationnarisation de la moyenne et de la variance de notre série Y_t . Par la suite, nous avons identifié deux modèles répondant à tous les critères de prévision à une période et respectant la règle de parcimonie. Ces modèles étant : $AR(1)MA(1)SMA(1)$ et $AR(2)SMA(1)$. Suite à la prévision à une période pour chaque modèle, nous avons conclu que le modèle $AR(2)SMA(1)$ est le plus performant.


B) Choix du modèle pour la température moyenne en France (X_1)

Dans une mesure de logique et de rigueur scientifique, nous décidons d'appliquer la même méthode de Box-Jenkins afin de déterminer à notre série temporelle X_1 , soit la température moyenne en France. Nous suivrons les mêmes étapes que pour Y_t afin de déterminer au mieux un modèle ARIMA pour notre série temporelle.

1 - Stationnarisation

Nous pouvons dès à présent débiter notre analyse de la stationnarité de notre série X_1 . Nous remarquons grâce à la Figure 7 que notre série ne présente pas de caractère stationnaire, ni pour la moyenne ni pour la variance. En effet, en étudiant la variabilité de notre série, nous pouvons remarquer une non-uniformité des variations, nous indiquant alors la non-stationnarité de la variance. Dans un second temps, en examinant le corrélogramme de la Figure 7, nous pouvons observer une forme sinusoïdale avec un retour non rapide vers 0 dans la fonction d'autocorrélation (FAC), mais également une abondance de valeurs significatives aussi bien dans la FAC que dans la fonction d'autocorrélation partielle (FACP), nous démontrant la non-stationnarité de la moyenne de notre série. Dans le but de continuer l'analyse, il nous est donc impératif de stationnariser la série.


Figure 7 : Visualisation graphique et Corrélogramme de la série brut



sources : auteur et Gretl

Nous décidons dans un premier temps de transformer notre série brute en série logarithmique dans le but de stationnariser la variance.

Figure 8 : Comparaison de la série brute et de la série avec logarithme et Corrélogramme de la série logarithmique




sources : auteur et Gretl

L'analyse de la figure 8 nous révèle une amélioration de la variabilité de notre série logarithmique (en orange) par rapport à notre série brute (en vert). En effet, nous pouvons remarquer que l'amplitude des valeurs de notre série logarithmique est de 0 à 3, en opposition à une plage plus large pour notre série brute allant de 2 à 24. De plus, nous pouvons observer grâce à l'étude du corrélogramme (Figure 8) qu'il n'a guère de changement par rapport à celui de la série brute (Figure 7), nous indiquant alors que notre série logarithmique n'est toujours pas stationnaire pour la moyenne. Par conséquent, la transformation logarithmique nous a permis de stationnariser la variance mais non la moyenne.

Suite à la stationnarisation de la variance par le biais d'une transformation logarithmique de notre série, nous pouvons dès à présent appliquer des différenciations dans le but de stationnariser la moyenne de notre série IX_1 . Dans un premier temps, nous utiliserons une approche classique de différenciation, suivie d'une différenciation saisonnière.

**Figure 9 : Visualisation graphique et Corrélogramme de la série logarithmique
différencier de manière classique**




sources : auteur et Gretl

En examinant le graphique (Figure 9), nous pouvons constater une oscillation des valeurs de la série autour de 0 démontrant une possible stationnarité de la moyenne. Néanmoins l'étude du corrélogramme (Figure 9) est essentielle afin de vérifier la véracité de notre analyse graphique. Le corrélogramme, nous révèle plusieurs points. Tout d'abord, nous pouvons observer que la différenciation classique a réussi à aplanir la forme sinusoïdale des valeurs dans la FAC. Néanmoins, une majorité de valeurs persiste significatives aussi bien dans la FAC que dans la FACP. De plus, nous pouvons constater l'absence de retour vers 0 des valeurs, nous confirmant ainsi la non-stationnarité de notre série lX_1 . Ainsi, l'approche classique ne nous permet pas de stationnariser la série lX_1 .

L'inefficacité de l'approche classique de différenciation nous contraint l'application d'une approche saisonnière de différenciation afin de stationnariser la moyenne de la série lX_1 .

Figure 10 : Visualisation graphique et Corrélogramme de la série logarithmique différencier de manière saisonnière



sources : auteur et Gretl

En examinant le graphique de la série logarithmique différenciée de manière saisonnière (Figure 10), nous pouvons observer une possible stationnarité de la moyenne. En effet, les valeurs de notre série $sdLX_1$ oscillent autour de 0. Néanmoins, une étude approfondie du corrélogramme est nécessaire pour confirmer la stationnarité de notre série $sdLX_1$. En étudiant le corrélogramme (Figure 10), plusieurs caractéristiques se dégagent. Ainsi, nous constatons l'absence de bruit blanc et un retour rapide vers 0 des valeurs, mais avec la présence minimale de ruptures (valeurs significatives) aussi bien dans la FAC que dans la FACP. Par conséquent, ces caractéristiques, notamment le retour rapide des valeurs vers 0, nous suggèrent la stationnarité de notre série logarithmique grâce à une différenciation saisonnière.

Grâce aux processus de transformation logarithmique et à la méthode de différenciation saisonnière, nous avons pu stationnariser notre série X_1 . Cela nous permet alors de passer à l'étape suivante : l'identification et l'estimation de notre série.

2 - Identification & Estimation & Choix du meilleur modèle

Le critère de stationnarité de notre série $sdLX_1$ démontré, nous pouvons dès à présent passer à l'étape d'identification et d'estimation. L'analyse du corrélogramme de la figure 10 lors de l'étape de stationnarisation, nous a permis de constater la présence de valeurs significatives aussi bien pour les premiers retards que pour les retards multiplicatifs de 12, aussi bien dans la FAC que dans la FACP. Cette constatation nous

permet donc de mettre en évidence la nécessité de proposer un modèle mixte afin de mieux modéliser notre série.

Dans ce contexte, nous proposons initialement un modèle mixte comprenant une composante de moyenne mobile d'ordre 1 (MA(1)) ainsi qu'une moyenne mobile saisonnière d'ordre 1 (SMA(1)), afin de prendre en considération à la fois les tendances générales et les variations saisonnières de notre série.


Modélisation 5 : Proposition du modèle mixte ARIMA(0,0,1)(0,1,1)

Évaluations de la fonction : 70
Évaluations du gradient : 17
Modèle 3: ARMA, utilisant les observations 1991:01-2024:02 (T = 398)
Estimation par AS 197 (MV exact)
Variable dépendante: sd_l_DEGRES
Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique	
const	0.00217951	0.00102923	2.118	0.0342	**
theta_1	0.206801	0.0479055	4.317	1.58e-05	***
Theta_1	-0.999999	0.0570443	-17.53	8.43e-69	***

Moyenne var. dép.	0.003733	Éc. type var. dép.	0.248447
Moyenne innovations	-0.006332	Éc. type innovations	0.170497
R2	0.532216	R2 ajusté	0.531034
Log de vraisemblance	118.1306	Critère d'Akaike	-228.2613
Critère de Schwarz	-212.3155	Hannan-Quinn	-221.9453

	Réel	Imaginaire	Modulo	Fréquence
MM				
Ordre 1	-4.8356	0.0000	4.8356	0.5000
MM (saisonnalité)				
Ordre 1	1.0000	0.0000	1.0000	0.0000



sources : auteur et Gretl

Tableau 15 : Récapitulatif du modèle ARIMA(0,0,1)(0,1,1) avec constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(0,0,1)(0,1,1)	2	2	0,5310	0,1704	0,003	-228

sources : auteur et Gretl Annexe 20

En étudiant la modélisation 5 et le tableau 15, nous pouvons remarquer que tous nos paramètres (θ_1 et Θ_1) et la constante sont bien significatifs et qu'ils vérifient bien la condition d'inversibilité, en effet $|0,206801 - 0,999999| < 1$. Cependant, nous ne pouvons pas valider ce modèle, car la statistique Q associée au test de portmanteau pour le dernier retard est inférieure à 0,05. Cette constatation nous conduit donc à envisager un autre modèle, par conséquent, l'étude du corrélogramme est nécessaire afin de proposer un meilleur modèle. En examinant le corrélogramme (Modélisation 5), nous pouvons observer la présence de valeurs significatives aussi bien dans la partie classique que dans la partie saisonnière présentée dans la FAC et la FACP. Par conséquent, nous avons la nécessité d'introduire un nouveau paramètre afin de pouvoir

modéliser au mieux la partie classique dans un premier temps. De ce fait, nous proposons l'intégration d'un nouveau paramètre AR(1).

Modélisation 6 : Proposition du modèle mixte ARIMA(1,0,1)(0,1,1)


Évaluations de la fonction : 76
Évaluations du gradient : 20

Modèle 12: ARMA, utilisant les observations 1991:01-2024:02 (T = 398)
Estimation par AS 197 (MV exact)
Variable dépendante: sd_l_DEGRES
Ecart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique	
const	0.00216613	0.00133046	1.628	0.1035	
phi_1	0.694824	0.291267	2.386	0.0171	**
theta_1	0.327478	0.353520	-1.464	0.1432	
Theta_1	-0.999999	0.0462748	-21.61	1.45e-103	***

Moyenne var. dép.	0.003733	Éc. type var. dép.	0.248447
Moyenne innovations	-0.005579	Éc. type innovations	0.169544
R2	0.537950	R2 ajusté	0.535610
Log de vraisemblance	120.3551	Critère d'Akaike	-230.7101
Critère de Schwarz	-210.7779	Hannan-Quinn	-222.8151

	Réel	Imaginaire	Modulo	Fréquence
AR				
Ordre 1	1.4392	0.0000	1.4392	0.0000
MA				
Ordre 1	1.9320	0.0000	1.9320	0.0000
MM (saisonnalité)				
Ordre 1	1.0000	0.0000	1.0000	0.0000



sources : auteur et Gretl

Tableau 16 : Récapitulatif du deuxième modèle ARIMA(1,0,1)(0,1,1) avec constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(1,0,0)(0,1,1)	2	3	0,5356	0,1695	0,046	-230

sources : auteur et Gretl Annexe 21

L'étude du nouveau modèle, suite à l'ajout d'un paramètre autorégressif 1, a drastiquement amélioré le corrélogramme. En effet, en examinant le corrélogramme (Modélisation 2), nous pouvons constater que la partie classique est correctement modélisée (aucune valeur significative dans les 3 premiers retards). De plus, nous pouvons remarquer que la statistique Q associée au test de portmanteau est grandement améliorée, étant très proche de 0,05, montrant ainsi la nécessité de l'ajout du paramètre AR(1). Cependant, en examinant de plus près les résultats de la modélisation de notre modèle $ARIMA(1, 0, 1)(0, 1, 1)_{s=12}$, nous pouvons souligner que seuls 2 paramètres sont significatifs (θ_1 et ϕ_1). La constante et (θ_1) ne l'étant pas, nous imposant donc d'envisager un nouveau modèle sans eux. Cependant, toutes les conditions de notre modèle étant respectées, notamment la condition d'inversibilité ($|0,32 - 0,99| < 1$) et de stationnarité ($|0,69| < 1$).

Tableau 17 : Récapitulatif du modèle modèle ARIMA(1,0,0)(0,1,1) sans constante


MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(1,0,0)(0,1,1)	2	2	0,5286	0,1709	0,003	-230

sources : auteur et Gretl Annexe 22

Cette nouvelle modélisation sans les paramètres non significatifs n'améliore en rien notre modélisation. En effet, dans un premier temps, en examinant le tableau 17, nous constatons que la statistique Q associée au test de portmanteau pour le dernier retard redevient nettement inférieure à 0,05. Dans un second temps, le corrélogramme associé à cette modélisation (Voir annexe 22) n'est pas amélioré, mais pire, il se dégrade. En effet, la composante classique n'est plus correctement modélisée, ce que le modèle précédent avait réussi à faire. Néanmoins les deux paramètres associés à ce modèle sont significatifs et les conditions d'inversibilité et de stationnarité sont respectées.

Dans ces conditions, nous considérons donc l'option de regagner l'ancien modèle car possédant une modélisation démontrée aussi bien par le corrélogramme (partie classique bien modéliser) que par la statistique Q et d'ajouter un nouveau paramètre saisonnier SMA(2) afin d'améliorer la modélisation de la partie saisonnière.

Modélisation 7 : Proposition du modèle mixte ARIMA(1,0,1)(0,1,2)



sources : auteur et Gretl

Tableau 18 : Récapitulatif du modèle modèle ARIMA(1,0,1)(0,1,2) avec constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(1,0,1)(0,1,2)	4	4	0,5367	0,1684	0,116	-232

sources : auteur et Gretl Annexe 23

Suite à l'ajout d'un nouveau paramètre saisonnier à moyenne mobile SMA(2) à notre modèle $ARIMA(1, 0, 1)(0, 1, 1)_{s=12}$, nous pouvons dès lors analyser ce nouveau

modèle à travers la modélisation 7 et le tableau 18. Nous pouvons constater que tous nos paramètres (θ_1 , Θ_1 , ϕ_1 et Φ_1) sont significatifs, démontrant ainsi l'utilité de chacun dans notre modélisation. Cependant, nous observons que la constante n'étant pas significative, une modélisation sans cette dernière serait donc plus appropriée. De plus, nous pouvons signaler qu'aussi bien les conditions d'inversibilité ($|0,812 + 0,111 - 1,111| < 1$) et de stationnarité ($|0,9825| < 1$) sont respectées. Par la suite, nous pouvons voir que c'est notre premier modèle validé par le test de portmanteau. En effet, la statistique Q associée au test de portmanteau est supérieure à 0,05. Cependant, en analysant le corrélogramme (Modélisation 7), nous pouvons remarquer que la partie classique de notre modélisation n'est plus aussi bien modélisée. En effet, nous observons une valeur significative pour le premier retard, tandis que pour la partie saisonnière, elle est nettement mieux modélisée que dans l'ancien modèle.

Tableau 19 : Récapitulatif du modèle modèle ARIMA(1,0,1)(1,1,1) sans constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(1,0,1)(0,1,2)	4	4	0,5350	0,1687	0,113	-233

sources : auteur et Gretl Annexe 24

Cette nouvelle modélisation (tableau 19) de notre modèle ARIMA sans la constante nous conduit aux mêmes conclusions que précédemment. En effet, le modèle est également accepté, il présente le même corrélogramme et apporte une légère amélioration du critère AIC. Ainsi, nous pourrions considérer notre recherche de modèle ARIMA pour modéliser notre série Y_t comme étant concluante, car nous disposons maintenant d'un modèle valide. Cependant, par souci de rigueur, nous continuerons nos recherches dans l'espoir de trouver éventuellement un modèle encore plus adapté mais néanmoins en respectant la règle de parcimonie afin d'éviter toute complexification de notre modèle déjà existant. De ce fait, nos prochaines modélisations posséderont au maximum 4 paramètres. Nous procédons à la même démarche que précédemment afin d'obtenir de nouveau modèle.

En suivant la même démarche, nous avons pu sélectionner deux nouveaux modèles respectivement : $ARIMA(1, 0, 1)(1, 1, 1)_{s=12}$ et $ARIMA(2, 0, 1)(0, 1, 1)_{s=12}$, tous

les deux sans constante. Ainsi, grâce à la méthode Box-Jenkins, nous avons pu mettre en évidence quatre modèles valides. Afin de choisir le meilleur modèle nous appliquerons la même logique que pour Y_t .

Tableau 20 : Synthèse des modèles valides pour la série X1

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC	N°
(1,0,1)(0,1,2) sans constante	4	4	0,5350	0,1687	0,113	-233	1
(1,0,1)(1,1,1) sans constante	4	4	0,5344	0,1689	0,110	-233	2
(2,0,1)(0,1,1) sans constante	4	4	0,5447	0,1685	0,083	-237	3

sources : auteur et Gretl Annexe 23 à 26

En examinant le tableau 20, il est clair que le modèle numéro 3 se distingue par sa qualité, comme en attestent ses valeurs AIC et R2. Cependant, en ce qui concerne la statistique Q, le modèle numéro 1 se démarque. En privilégiant davantage la valeur de la statistique Q, nous optons donc pour le modèle $ARIMA(1, 0, 1)(0, 1, 2)_{s=12}$ sans constante comme choix du meilleur modèle. De plus, il convient de souligner que les valeurs AIC et R2 du modèle numéro 1 ne sont que légèrement inférieures à celles du modèle 3, ce qui confirme une fois de plus la pertinence du choix du modèle numéro 1.

Résumé :

L'ajout d'un logarithme et une différenciation saisonnière ont été suffisants pour respectivement la stationnarisation de la variance et de la moyenne de notre série X_1 . Par la suite, nous avons identifié plusieurs modèles répondant à tous les critères de validité (conditions de d'inversibilité, de stationnarité, etc). Cependant, nous n'avons retenu que le modèle AR(1),MA(1) et SMA(2) comme étant le meilleur modèle suite à la comparaison de ses différents paramètres avec les autres modèle valides


C) Choix du modèle pour la densité de population française (X_2)

Dans la poursuite de notre étude, nous appliquons la même méthode à notre dernière série temporelle, X_2 , c'est-à-dire la densité de population française. Nous commençons donc notre analyse par la stationnarisation de notre série temporelle.

1 - Stationnarisation

Nous débutons, donc notre analyse de la stationnarité de notre série X_2 . En examinant la figure 11, il est facile de constater que notre série ne présente pas de caractère de stationnarité, notamment en ce qui concerne la moyenne. En effet, ses valeurs ne oscillent pas autour de zéro. De plus, nous remarquons graphiquement que notre série temporelle suit une tendance linéaire ($y = ax + b$), ce qui limite la variabilité de ces valeurs. Ainsi, l'analyse du corrélogramme est nécessaire pour éclairer le sujet de la stationnarité de notre série. En étudiant ce corrélogramme, il est facilement observable que notre série est non stationnaire. En effet, les retards reviennent rapidement vers zéro avec une significativité de tous les retards dans la fonction d'autocorrélation. De plus, il n'y a pas de bruit apparent. Dans ces conditions, il est aisé de conclure que notre série brute est non stationnaire.


Figure 11 : Visualisation graphique et Corrélogramme de la série brut



sources : auteur et Gretl

Nous décidons dans un premier lieu de vérifier de la stationnarité de la variance de notre série brute par une transformation logarithmique.

**Figure 12 : Comparaison de la série brute et de la série avec logarithme et
Corrélogramme de la série logarithmique**




sources : auteur et Gretl

En examinant la Figure 12, nous remarquons que notre série logarithmique (en orange) ne diffère guère de notre série brute (en vert). Ainsi, nous pouvons conclure que notre série n'a pas besoin d'une transformation logarithmique. De plus, l'étude du corrélogramme (Figure 12) révèle qu'il n'y a aucun changement dans notre série suite à l'ajout d'un logarithme. En effet, on observe toujours une absence de bruit blanc, un non retour rapide des valeurs vers zéro, et une significativité de toutes les valeurs dans la fonction d'autocorrélation. En résumé, il est donc superflu de transformer notre série en série logarithmique.

Suite à la vérification du non-besoin de transformation logarithmique de notre série pour stationnariser la variance, nous pouvons dès lors appliquer la différenciation dans le but de stationnariser la moyenne de notre série brute, X_2 . Nous utiliserons deux approches distinctes : une approche classique de différenciation, suivie d'une approche saisonnière de différenciation.

Figure 13 : Visualisation graphique et Corrélogramme de la série différencier de manière classique




sources : auteur et Gretl

En examinant la Figure 13, nous constatons que notre série n'oscille pas autour de zéro, ce qui peut indiquer une inefficacité de la différenciation classique pour stationnariser la moyenne de notre série. Ainsi, une étude du corrélogramme s'avère nécessaire. Le corrélogramme (Figure 13) confirme notre hypothèse selon laquelle la différenciation classique ne permet pas de stationnariser notre série. En effet, la majorité des valeurs de notre série sont significatives. Néanmoins, nous pouvons observer un retour plus rapide vers zéro des valeurs, bien que cela reste lent. De plus, il y a une absence de bruit blanc.

Étant donné l'inefficacité de l'approche classique de différenciation, nous sommes contraints d'appliquer une méthode de différenciation saisonnière pour stationnariser la moyenne de la série X_2 .

Figure 14 : Visualisation graphique et Corrélogramme de la série différencier de manière saisonnière




sources : auteur et Gretl

L'étude de la Figure 14 nous permet de conclure quant à la stationnarité de notre série différenciée de manière saisonnière. Ainsi, graphiquement, nous constatons une absence d'oscillation des valeurs autour de zéro, ce qui indiquerait, comme précédemment, une non-stationnarité de la moyenne de notre série différenciée de manière saisonnière. Nous examinons alors le corrélogramme (Figure 14). Nous remarquons des similarités étranges avec le corrélogramme (Figure 11 et 12), notamment pour la fonction d'autocorrélation (FAC), ce qui nous conduit aux mêmes conclusions que pour ces corrélogramme: la non-stationnarité de notre série temporelle par une approche de différenciation saisonnière.

Les deux approches à notre disposition, telles que la différenciation classique et la différenciation saisonnière, n'ont pas été en mesure de stationnariser notre série X2. Ainsi, dans ces conditions, il nous est imposé de combiner ces deux approches en proposant alors une double différenciation. Nous décidons arbitrairement de différencier notre série par une approche saisonnière dans un premier temps, car le corrélogramme montre un retour plus rapide vers 0, et par la suite nous appliquerons une différenciation classique.

Figure 15 : Visualisation graphique et Corrélogramme de la série doublement différencier



sources : auteur et Gretl

Suite à la double différenciation, nous pouvons analyser les résultats grâce à la Figure 15. Graphiquement, nous constatons que notre série doublement différenciée oscille bien autour de zéro, ce qui pourrait indiquer la stationnarité de notre série. Cette hypothèse doit toutefois être confirmée par le corrélogramme correspondant. Ainsi, en étudiant le corrélogramme (Figure 15), nous remarquons un retour vers zéro plus

rapide que ce que nous avons observé auparavant, et il n'y a pas de prédominance des valeurs significatives. De plus, nous notons l'absence de bruit blanc. Dans ces conditions, nous pouvons donc conclure à la stationnarité de notre série $dsdX_2$, soit notre série doublement différenciée.

Par le biais des différenciations, nous avons réussi à stationnariser notre série X_2 grâce à une double différenciation, nous permettant dès à présent de passer à l'étape suivante, celle de l'identification et de l'estimation d'un modèle ARIMA.

2 - Identification & Estimation & Choix du meilleur modèle

Une fois la stationnarité de notre série $dsdX_2$ établie, nous pouvons dès à présent passer à l'étape de l'identification et de l'estimation. L'étude du corrélogramme (Figure 15) révèle la présence de valeurs significatives à la fois pour les premiers retards mais également pour les retards saisonniers de 12, notamment dans la fonction d'autocorrélation partielle (FACP). Cette constatation souligne donc la nécessité de proposer un modèle mixte afin de mieux modéliser notre série.

Dans ce contexte, nous proposons initialement un modèle mixte comprenant une composante autorégressif d'ordre 1 (AR(1)) ainsi qu'une composante autorégressive saisonnier d'ordre 1 (SAR(1)), afin de prendre en considération à la fois les tendances générales et les variations saisonnières de notre série X_2 .

Modélisation 8 : Proposition du modèle mixte ARIMA(1,1,0)(1,1,0)


Évaluations de la fonction : 28
Évaluations du gradient : 6

Modèle 2: ARMA, utilisant les observations 1991:02-2024:01 (T = 396)
Estimation par AS 197 (MV exact)
Variable dépendante: d_sd_DENSITE
Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique
const	-0.000103729	0.000910848	-0.1139	0.9093
phi_1	0.758954	0.0337528	22.49	5.73e-112 ***
Phi_1	-0.527070	0.0446032	-11.82	3.19e-32 ***

Moyenne var. dép.	-0.000215	Éc. type var. dép.	0.009956
Moyenne innovations	-0.000015	Éc. type innovations	0.006652
R2	0.555433	R2 ajusté	0.554305
Log de vraisemblance	1420.806	Critère d'Akaike	-2833.613
Critère de Schwarz	-2817.687	Hannan-Quinn	-2827.303

	Réel	Imaginaire	Modulo	Fréquence
AR				
Ordre 1	1.3176	0.0000	1.3176	0.0000
AR (saisonnier)				
Ordre 1	-1.8973	0.0000	1.8973	0.5000



sources : auteur et Gretl

Tableau 21 : Récapitulatif du modèle mixte ARIMA(1,1,0)(1,1,0) avec constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(0,0,1)(0,1,1)	2	2	0,5543	0,0066	0	-2833

sources : auteur et Gretl Annexe 27

En examinant la modélisation 8 et le tableau 21, nous pouvons constater que l'ensemble de nos paramètres est significatif (ϕ_1, Φ_1), à l'exception de la constante, ce qui nous indique une modélisation sans cette dernière. De plus, nous pouvons observer que les conditions de stationnarité sont bien respectées ; en effet, $|0,758954 - 0,527070| < 1$. Néanmoins, nous ne pouvons valider ce modèle car il possède une valeur Q-stat inférieure à 0. Ainsi, une analyse du corrélogramme (Modélisation 8) est nécessaire dans le but de modéliser de manière plus juste notre modèle. En étudiant le corrélogramme, nous pouvons observer une similarité des valeurs significatives dans la FAC et FACP. Ces valeurs significatives sont présentes aussi bien dans la composante classique (3 premiers retards) que dans la composante saisonnière (retard multiple de 12). De ce fait, nous décidons subjectivement de résoudre le problème de la composante classique en décidant d'intégrer un nouveau paramètre AR(2).

Tableau 22 : Récapitulatif du modèle mixte ARIMA(1,1,0)(1,1,0) sans constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(0,0,1)(0,1,1)	2	2	0,5543	0,0066	0	-2835

sources : auteur et Gretl Annexe 28


Cette nouvelle modélisation sans la constante nous permet de constater qu'enlever cette dernière permet d'améliorer légèrement la qualité de notre modèle. En effet, l'AIC diminue. Néanmoins, ni son corrélogramme (Voir annexe 28) ni la valeur de Q-stat ne sont améliorés. De ce fait, dans ces conditions, nous considérons encore l'option d'ajouter un paramètre autorégressif d'ordre dans le but d'améliorer la modélisation de la composante classique comme énoncé précédemment.

Modélisation 9 : Proposition du modèle mixte ARIMA(2,1,0)(1,1,0)

Évaluations de la fonction : 29
Évaluations du gradient : 8

Modèle 5: ARMA, utilisant les observations 1991:02-2024:01 (T = 396)
Estimation par AS 197 (MV exact)
Variable dépendante: d_sd_DENSITE
Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique	
const	-8.30496e-05	0.00106034	-0.07832	0.9376	
phi_1	0.642883	0.0503619	12.77	2.56e-37	***
phi_2	0.156486	0.0510979	3.062	0.0022	***
Phi_1	-0.551245	0.0437695	-12.59	2.27e-36	***
Moyenne var. dép.	-0.000215	Éc. type var. dép.	0.009956		
Moyenne innovations	-0.000019	Éc. type innovations	0.006572		
R2	0.566175	R2 ajusté	0.563967		
Log de vraisemblance	1425.423	Critère d'Akaike	-2840.845		
Critère de Schwarz	-2820.938	Hannan-Quinn	-2832.959		
	Réel	Imaginaire	Modulo	Fréquence	
AR					
Ordre 1	1.2031	0.0000	1.2031	0.0000	
Ordre 2	-5.3114	0.0000	5.3114	0.5000	
AR (saisonnier)					
Ordre 1	-1.8141	0.0000	1.8141	0.5000	



sources : auteur et Gretl

Tableau 23 : Récapitulatif du modèle mixte ARIMA(2,1,0)(1,1,0) avec constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(0,0,1)(0,1,1)	3	3	0,5639	0,0066	0	-2840

sources : auteur et Gretl Annexe 29

Suite à l'ajout d'un paramètre autorégressif, nous pouvons vérifier l'amélioration de la modélisation (Modélisation 9 et Tableau 23). Dans un premier temps, nous pouvons constater que l'ensemble de nos variables est significatif (ϕ_1, ϕ_2, Φ_1). Cependant, la constante n'est toujours pas significative dans ce modèle, nous imposant dès lors de former un nouveau modèle sans elle. Dans un second temps, nous pouvons observer que toutes les conditions sont respectées, telles que la condition de stationnarité : $|0,642883 + 0,156486 - 0,551224| < 1$. Cependant, ce modèle n'est toujours pas valide (Q-stat < 0,05). De ce fait, nous analysons le corrélogramme (Modélisation 9), nous indiquant toujours des valeurs significatives pour nos deux composantes (classique et saisonnière). Par conséquent, nous décidons d'ajouter un nouveau paramètre à moyenne mobile classique MA(1) dans le but de modéliser au mieux la composante classique, dans le but par la suite de traiter au mieux la composante saisonnière.


Tableau 24 : Récapitulatif du modèle mixte ARIMA(2,1,0)(1,1,0) sans constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(0,0,1)(0,1,1)	3	3	0,5639	0,0065	0	-2842

sources : auteur et Gretl Annexe 30

Notre modélisation du précédent modèle sans la constante (Tableau 24) nous permet de constater la vacuité dans notre modélisation. En effet, la qualité du modèle est améliorée, démontrée par l'AIC notamment. Néanmoins, comme précédemment, la suppression n'améliore en rien le corrélogramme (Voir annexe 30) ainsi que la valeur du Q-stat. De ce fait, ce modèle n'est donc pas valide. Ainsi, nous procédons à l'ajout du paramètre de moyenne mobile MA(1).

Modélisation 10 : Proposition du modèle mixte ARIMA(2,1,1)(1,1,0)



sources : auteur et Gretl

Tableau 25 : Récapitulatif du modèle mixte ARIMA(2,1,1)(1,1,0) avec constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(0,0,1)(0,1,1)	4	4	0,5741	0,0064	0	-2851

sources : auteur et Gretl Annexe 31

Nous pouvons dès à présent analyser notre nouveau modèle $ARIMA(2, 1, 1)(1, 1, 0)_{s=12}$. En analysant la modélisation 10 et le tableau 25, nous pouvons remarquer que l'ensemble de nos paramètres est significatif ($\phi_1, \phi_2, \theta_1, \Phi_1$) sauf la constante, nous obligeant à modéliser un nouveau modèle sans elle. De plus, nous pouvons observer le respect de toutes les conditions, aussi bien la condition de stationnarité ($|1,32114 - 0,356850 - 0,549921| < 1$) que la condition d'inversibilité ($|-0,726178| < 1$). Cependant, nous pouvons observer que l'ajout de tous ces paramètres n'a pas permis d'augmenter le Q-stat. De ce fait, ce modèle est également non-valide. En étudiant notre corrélogramme (Modélisation 10), nous constatons que notre composante est parfaitement modélisée, démontrant ainsi l'utilité de l'ajout des

paramètres classiques. Cependant, nous pouvons observer que c'est notre composante saisonnière qui est mal modélisée, indiquée notamment par la présence de valeurs significatives. Par conséquent, il nous est donc primordial d'ajouter un paramètre saisonnier et notamment un paramètre de moyenne mobile saisonnière SMA(1) dans le but d'aborder le problème dans notre composante saisonnière.

Tableau 26 : Récapitulatif du modèle mixte ARIMA(2,1,1)(1,1,0) sans constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(0,0,1)(0,1,1)	4	4	0,5741	0,0064	0	-2853

sources : auteur et Gretl Annexe 32

Nous pouvons étudier cette nouvelle modélisation sans la constante grâce au tableau 26. Nous arrivons à la même conclusion de l'ensemble de nos analyses des modélisations sans constante non significative. En effet, le modèle est légèrement amélioré (AIC plus faible) mais il n'est toujours pas validé (Q-stat > 0,05). De plus, le corrélogramme ne change guère (Voir annexe 32), nous amenant à la même conclusion qu'aux modèles avec la constante. La nécessité de l'ajout d'un paramètre saisonnier SMA(1) est donc confirmée.

Modélisation 11 : Proposition du modèle mixte ARIMA(2,1,1)(1,1,1)


Évaluations de la fonction : 97
Évaluations du gradient : 24

Modèle 9: ARMA, utilisant les observations 1991:02-2024:01 (T = 396)
Estimation par AS 197 (MV exact)
Variable dépendante: d_sd_DENSITE
Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique
const	-0.000150326	0.00101607	-0.1479	0.8824
phi_1	1.42181	0.0798798	17.80	7.14e-71 ***
phi_2	-0.429082	0.0777042	-5.522	3.35e-08 ***
Phi_1	-0.101346	0.0611399	-1.658	0.0974 *
theta_1	-0.779360	0.0533731	-14.60	2.72e-48 ***
Theta_1	-0.871247	0.0419528	-20.77	8.56e-96 ***

Moyenne var. dép.	-0.000215	Éc. type var. dép.	0.009956
Moyenne innovations	-0.000017	Éc. type innovations	0.005577
R2	0.605440	R2 ajusté	0.602230
Log de vraisemblance	1483.690	Critère d'Akaike	-2953.380
Critère de Schwarz	-2925.510	Hannan-Quinn	-2942.339

	Réel	Imaginaire	Modulo	Fréquence
AR				
Ordre 1	1.0130	0.0000	1.0130	0.0000
Ordre 2	2.3006	0.0000	2.3006	0.0000
AR (saisonnier)				
Ordre 1	-9.8672	0.0000	9.8672	0.5000
MM				
Ordre 1	1.2831	0.0000	1.2831	0.0000
MM (saisonnalité)				
Ordre 1	1.1478	0.0000	1.1478	0.0000



sources : auteur et Gretl

Tableau 27 : Récapitulatif du modèle mixte ARIMA(2,1,1)(1,1,0) avec constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(0,0,1)(0,1,1)	5	5	0,6822	0,0055	0,022	-2953

sources : auteur et Gretl Annexe 31

En étudiant la modélisation 11 et le Tableau 27, nous sommes en mesure d'analyser le nouveau modèle suite à l'ajout d'un paramètre saisonnier. Ainsi, en analysant les résultats de la modélisation (Modélisation 11), nous pouvons remarquer la significativité de l'ensemble de nos paramètres ($\phi_1, \phi_2, \theta_1, \theta_2, \Phi_1$) excepté la constante. De ce fait, une nouvelle modélisation sera faite sans elle. De plus, nous pouvons observer que la condition de stationnarité est respectée ($|1,42181 - 0,429082 - 0,101346| < 1$). Néanmoins, la condition d'inversibilité n'est pas respectée, en effet ($|-0,779360 - 0,871247| > 1$). Nous ne pouvons alors valider ce modèle. De plus, la valeur Q-stat inférieure à 0,05 appuie sur le principe de non-validité de notre modèle. Cependant, il nous est important de souligner que cette Q-stat étant la meilleure de nos modèles à partir de maintenant. L'analyse du corrélogramme démontre encore l'efficacité de notre modèle pour la composante saisonnière. De ce fait, il serait juste d'ajouter ou de modifier les paramètres saisonniers de notre modèle dans le but de mettre en lumière un nouveau modèle passant outre aussi bien les problèmes de validité de notre modèle (Q-stat) que la condition d'inversibilité.

Tableau 28 : Récapitulatif du modèle mixte ARIMA(2,1,1)(1,1,0) sans constante

MODÈLE	PARA SIG	PARA	R^2	σ	Q-stat	AIC
(0,0,1)(0,1,1)	5	5	0,6822	0,0055	0,023	-2955

sources : auteur et Gretl Annexe 32

Nous modélisons dès à présent notre modèle sans la constante. Cependant, nous arrivons aux mêmes conclusions. En inspectant les résultats de notre modélisation (Voir annexe 32), nous concluons du non-respect de la condition d'inversibilité, d'un Q-stat inférieur à 0,05 et d'un corrélogramme similaire au précédent (Modélisation 11). Ainsi, nous appliquons les recommandations énoncées précédemment.

En appliquant les recommandations d'ajout d'un paramètre saisonnier aussi bien SMA(1) que SAR(1), nous nous rendons compte de la non-significativité de ces paramètres, nous obligeant dès lors à les enlever. De ce fait, l'ajout de nouveaux paramètres saisonniers est donc impossible. Nous procédons alors à la modification des paramètres saisonniers déjà existants. Cependant, tout modèle reste invalide, induit notamment par leurs valeurs de Q-stat inférieures à 0,05. Nous empêchant alors de

trouver un modèle valide pour cette série temporelle. En effet, le meilleur modèle que nous obtenons étant le dernier présenté, c'est-à-dire $ARIMA(2, 1, 1)(1, 1, 1)_{s=12}$ qui est malencontreusement invalide.

L'estimation d'un modèle ARIMA nous est donc épineuse pour cette série. Nous pouvons émettre quelques hypothèses afin d'expliquer cette difficulté. Dans un premier temps, la non-stationnarité initiale pourrait perturber l'estimation d'un modèle ARIMA ; en effet, la nécessité d'appliquer deux différenciations complique l'estimation du modèle ARIMA. Dans un second temps, nous pouvons également citer la complexité du processus sous-jacent ; en effet, le processus sous-jacent de notre série temporelle pouvant être fortement complexe et peut présenter des motifs ou des comportements qui ne peuvent pas être bien modélisés par un modèle ARIMA. Enfin, nous pouvons citer l'hypothèse de données bruitées ou peu informatives ; en effet, si elles sont bruitées ou ne contiennent pas suffisamment d'information, alors l'estimation du modèle ARIMA peut être difficile. Ces hypothèses permettraient ainsi d'expliquer la difficulté que nous avons rencontrée lors de l'étape d'estimation de notre série temporelle X_2 .

Résumé :

Une double différenciation a été nécessaire à l'étape de stationnarisation de la moyenne de notre série X_2 . La transformation logarithmique s'est avérée inutile pour notre analyse. Par la suite, nous avons pu démontrer un modèle valide, en effet notre meilleur modèle étant $ARIMA(2, 1, 1)(1, 1, 1)_{s=12}$ mais possédant des problèmes de Q-stat et de condition d'inversibilité. Ainsi, nous avons exposé certaines hypothèses pouvant expliquer ce problème d'estimation.

VI - Test de cointégration selon Engle-Granger

Nous pouvons dès lors passer à l'étude de la cointégration entre nos séries. Dans un premier temps, nous étudierons la cointégration entre l'incidence de la grippe et la température moyenne en France, puis l'incidence de la grippe et la densité de population. Néanmoins, avant de passer à cette étude, nous expliquerons dans un premier temps le principe de cointégration.

A) Explication théorique


La cointégration, selon Engle-Granger, constitue un pilier important de l'économétrie, développé par Robert Engle et Clive Granger dans les années 80. Cette méthode permet d'analyser la relation à long terme entre deux séries temporelles, nous permettant ainsi la possibilité de modéliser les rapports durables (à long terme) entre des variables tout en prenant en compte leurs comportements à court terme. Par conséquent, il nous est important de souligner que cette approche revêt une importance capitale dans la compréhension des dynamiques du monde d'aujourd'hui, soit économique, financière, de santé publique, etc....

Le concept sous-jacent à la cointégration indique que bien que deux séries individuelles soient non stationnaires, elles peuvent présenter des tendances à long terme. Nous démontrons par la suite une possible relation linéaire stable entre elles sur le long terme, en dépit de leurs fluctuations à court terme.

L'application de cette méthode doit suivre plusieurs étapes rigoureuses. La première étape consiste à la vérification de l'ordre d'intégration de nos séries temporelles grâce à l'application de tests tels que le test Dickey-Fuller Augmenté (ADF voir annexe 33) et le test Kwiatkowski-Phillips-Schmidt-Shin en appuie du premier (KPSS voir annexe 34), nous permettant d'estimer la relation de long terme. Dans un deuxième temps, nous procédons à la vérification de la stationnarité des résidus de long terme obtenue par une régression des moindres carrés ordinaires (MCO) entre nos séries, nous permettant de conclure de la possible cointégration de nos séries et par conséquent de la mise en oeuvre du modèle à correction d'erreur (MCE). Enfin, nous examinerons la négativité et la significativité de Δ , afin de conclure de la validité de la relation et d'estimer le retour à l'équilibre de notre série.

Dans une mesure de vulgarisation scientifique, nous avons décidé d'effectuer un schéma récapitulatif des étapes de la méthode de cointégration selon Engle-Granger(Figure 16).

Figure 16 : Schéma récapitulatif de la méthode de Engle-Granger



sources : auteur

B) Vérification de l'ordre d'intégration

Suite à l'explication théorique, nous pouvons à présent passer à la première étape, consistant en la vérification de l'ordre d'intégration de nos séries temporelles brutes, puis les différencier. Il est important de souligner que nous avons sélectionné au préalable le nombre de retards en fonction du critère AIC, afin d'appliquer de manière rigoureuse le test ADF.

Tableau 29 : Récapitulatifs de la stationnarité des séries effectués par les tests et ARIMA

	ARIMA (Stationnaire)	Valeur $P_{critique}$	ADF (Stationnaire)
Incidence	NON	0,008769	OUI
sd_l_Incidence	OUI	$1,592e^{-5}$	OUI
Degrés	NON	0,9859	NON
sd_l_Degrés	OUI	0,001643	OUI
Densité	NON	0,6455	NON
d_Densité	NON	0,4231	NON
sd_Densité	NON	0,2518	NON
d_sd_Densité	OUI	0,2022	OUI

sources : auteur, Gretl, Annexe 35 à 42

En analysant le tableau 29, nous pouvons remarquer que le test ADF dans l'ensemble confirme l'étude des corrélogrammes effectuée dans la partie de l'application de la méthode de Box-Jenkins. En effet, nous pouvons observer que l'ADF confirme la stationnarité lors de la première différenciation pour Y_t , représentant l'incidence de la grippe, et la température moyenne en France (X_1). De plus, le test ADF confirme également la nécessité d'appliquer une double différenciation pour la densité de population moyenne en France (X_2). Par conséquent, nous pouvons admettre que les séries temporelles Y_t et X_1 sont intégrées du même ordre, soit sont intégrées d'ordre 1, nous permettant ainsi d'effectuer les MCO pour ce couple. Tandis que, pour la série temporelle X_2 , étant donné qu'elle n'est pas intégrée du même ordre, alors nous ne

pourrons pas effectuer les MCO. Par conséquent, le couple Y_t & X_2 n'est pas co-intégré et est donc une relation fallacieuse.

C) Cointégration entre L'incidence de la grippe et la température moyenne (Y_t & X_1)

1 - Application des MCO

Suite à la vérification de la possession du même ordre d'intégration pour les séries temporelles formant le couple Y_t & X_1 , nous pouvons dès lors effectuer un modèle de type MCO afin de vérifier la relation linéaire simple entre ces deux variables.

Modélisation 12 : MCO pour la relation : Y_t & X_1

Modèle 5: MCO, utilisant les observations 1990:01–2024:01 (T = 409)
Variable dépendante: INCIDENCE

	coefficient	éc. type	t de Student	p. critique	
const	790437	43105.6	18.34	3.50e-55	***
DEGRES	-41720.1	3015.97	-13.83	6.08e-36	***
Moyenne var. dép.	238538.9	Éc. type var. dép.	399680.1		
Somme carrés résidus	4.43e+13	Éc. type régression	330037.7		
R2	0.319800	R2 ajusté	0.318129		
F(1, 407)	191.3537	P. critique (F)	6.08e-36		
Log de vraisemblance	-5776.491	Critère d'Akaike	11556.98		
Critère de Schwarz	11565.01	Hannan-Quinn	11560.16		
rho	0.269043	Durbin-Watson	1.435210		

sources : auteur, Gretl

Cependant, avant de pouvoir interpréter les résultats, il est nécessaire de vérifier si le couple Y_t & X_1 sont bien co-intégré. Par conséquent, nous vérifions la stationnarité des résidus de cette relation à long terme, notamment avec l'application du test ADF avec un retard de 4.

Tableau 30 : Test ADF sur les résidus à long termes de la relation : Y_t & X_1

	Valeur $P_{critique}$	Stationnarité
ADF avec constante	$4,841e^{-22}$	OUI
ADF avec constante et tendance temporelle	$2,237e^{-23}$	OUI

sources : auteur, Gretl, Annexe 43

L'étude du Tableau 30 nous permet d'observer que les résidus de cette relation à long terme sont stationnaires. En effet, H_0 est rejeté étant donné que les valeurs de $P_{critique}$ pour les deux tests (avec constante et avec constante et tendance temporelle) sont inférieures à 0,05. Par conséquent, il n'y a pas d'existence de la racine unitaire. Ainsi, le couple Y_t & X_1 est bien cointégré et la relation entre ces deux variables n'est pas fallacieuse. Nous pouvons dès à présent passer à l'application des MCE pour notre couple Y_t & X_1 .

2 - Application des MCE

Suite à la vérification de la stationnarité des résidus de la relation à long terme du couple Y_t & X_1 , nous pouvons alors passer à la dernière étape, l'application des MCE. Néanmoins, avant de pouvoir interpréter les coefficients, il est nécessaire, comme expliqué précédemment (voir Figure 16), de vérifier la négativité et la significativité de Δ .

Modélisation 13 : MCE pour la relation : Y_t & X_1

Modèle 7: MCO, utilisant les observations 1991:01–2024:01 (T = 397)
Variable dépendante: sd_l_INCIDENCE

	coefficient	éc. type	t de Student	p. critique	
const	0.0408856	0.0555746	0.7357	0.4624	
sd_l_DEGRES	-0.524563	0.223801	-2.344	0.0196	**
residu_MCO_1	8.52649e-07	1.69212e-07	5.039	7.15e-07	***
Moyenne var. dép.	0.038085	Éc. type var. dép.	1.147023		
Somme carrés résidus	483.0097	Éc. type régression	1.107210		
R2	0.072922	R2 ajusté	0.068216		
F(2, 394)	15.49560	P. critique (F)	3.33e-07		
Log de vraisemblance	-602.2445	Critère d'Akaike	1210.489		
Critère de Schwarz	1222.441	Hannan-Quinn	1215.224		
rho	0.546148	Durbin-Watson	0.898260		

sources : auteur et Gretl

En analysant la modélisation 13 des MCE, nous pouvons remarquer que Δ est bien significatif mais n'étant pas négatif nous ne pouvons interpréter les résultats des MCO et d'estimer le retour à l'équilibre de notre série temporelle, l'incidence de la grippe en France.

3 - Estimation des coefficients

Nous avons pu observer dans la partie précédente que notre Δ n'étant pas négatif, nous ne pouvons interpréter les coefficients. Néanmoins, supposons que Δ soit négatif ainsi $\Delta = -8,52649e^{-7}$, ce qui nous permettrait d'expliquer complètement la cointégration selon Engle-Granger.

L'hypothèse selon laquelle Δ est inférieur à zéro nous permet d'évaluer la vitesse d'ajustement vers l'équilibre. Ainsi, la correction de l'erreur sera de $8,52649e^{-5}\%$ chaque mois. Cette correction semble être très lente, probablement en raison de notre hypothèse volontairement erronée selon laquelle Δ est inférieur à zéro, choisie pour expliquer complètement le concept de cointégration. De plus, nous pouvons analyser les résultats des MCO grâce à l'hypothèse incorrecte que nous avons faite précédemment. Ainsi, une augmentation de 1 unité de X_1 soit une augmentation de 1°Celsius fera diminuer de $-41720,1 Y_t$ soit l'incidence de la grippe en France.

D) Cointégration entre la température moyenne et l'incidence de la grippe (X_1 & Y_t)

Dans le cadre de l'application scientifique du concept de la cointégration d'Engle-Granger, nous avons décidé de vérifier la relation inverse de l'application précédente, même si cette relation semble illogique au préalable. Autrement dit, nous vérifions donc la relation entre le couple X_1 & Y_t en suivant les mêmes étapes de la méthode.

1 - Application des MCO

Nous avons précédemment constaté que nos deux séries sont intégrées du même ordre. Par conséquent, nous pouvons procéder à un modèle de type MCO afin de vérifier la relation linéaire simple entre ces deux variables.

Modélisation 14 : MCO pour la relation : X_1 & Y_t

Modèle 8: MCO, utilisant les observations 1990:01-2024:01 (T = 409)
Variable dépendante: DEGRES

	coefficient	éc. type	t de Student	p. critique	
const	15.0571	0.257690	58.43	4.97e-200	***
INCIDENCE	-7.66538e-06	5.54134e-07	-13.83	6.08e-36	***
Moyenne var. dép.	13.22859	Éc. type var. dép.	5.417596		
Somme carrés résidus	8145.352	Éc. type régression	4.473606		
R2	0.319800	R2 ajusté	0.318129		
F(1, 407)	191.3537	P. critique (F)	6.08e-36		
Log de vraisemblance	-1192.105	Critère d'Akaike	2388.210		
Critère de Schwarz	2396.238	Hannan-Quinn	2391.386		
rho	0.624586	Durbin-Watson	0.749270		

sources : auteur et Gretl

Comme cela a été fait précédemment, avant de pouvoir appliquer les MCE, nous vérifions la stationnarité de nos résidus à l'aide du test ADF avec un délai de 24.

Tableau 31 : Test ADF sur les résidus à long termes de la relation : X_1 & Y_t

	Valeur $P_{critique}$	Stationnarité
ADF avec constante	0,2223	OUI
ADF avec constante et tendance temporelle	0,4705	OUI

sources : auteur, Gretl, Annexe 44

L'étude du tableau 31, nous démontre que nos résidus à long termes de la relation du couple X_1 & Y_t n'est pas stationnaire. Par conséquent les séries ne sont pas co-intégrées et la relation de ces deux variables est fallacieuse.

2 - Application des MCE

Dans la partie précédente, nous avons remarqué que nos résidus ne sont pas stationnaires, ce qui nous empêche de poursuivre notre démarche pour ce couple. Par conséquent, cette relation, qui semblait illogique au départ, est confirmée par le fait que la relation entre ces deux variables soit fallacieuse.

VII - Conclusion

Cette étude a eu pour objectif d'analyser les relations entre l'incidence de la grippe en France et certains indicateurs, notamment la température moyenne en France et la densité moyenne de population en France. Les données se basent sur une plage temporelle allant de 1990 à 2024. Le but final étant de prédire le mois de février 2024.

Dans un premier temps, nous avons réalisé la méthode ARIMA pour notre variable Y_t . Cette méthode nous a permis de mettre en évidence le meilleur modèle de prévision, qui est le modèle $ARIMA(2, 0, 0)(0, 1, 1)_{s=12}$. Par la suite, nous avons appliqué cette même méthode à notre série temporelle X_1 et X_2 . Néanmoins, nous n'avons pu obtenir un modèle ARIMA optimal que pour X_1 . Ce modèle est : $ARIMA(1, 0, 1)(0, 1, 2)_{s=12}$. En effet, l'étape d'estimation pour X_2 nous a permis de mettre en évidence un modèle d'estimation.

Dans un second temps, nous avons appliqué la méthode d'Engle et Granger à nos couples de variables dans le but de définir une relation à long terme. Nous avons pu appliquer cette méthode seulement aux couples possédant le même ordre, c'est-à-dire : Y_t & X_1 et X_1 & Y_t . Un seul couple a permis de mettre en évidence une relation non dilatoire, ce couple de variables étant Y_t & X_1 . En effet, nous avons pu appliquer les MCE sur ce couple car il possédait des résidus stationnaires. Néanmoins, nous n'avons pas pu estimer les coefficients de ce couple car il possédait un delta positif.

Les résultats de notre étude, bien que partiellement corrects, nécessitent toutefois une certaine nuance. En effet, bien que nous ayons obtenu des modèles corrects pour la variable Y_t , leur capacité à prédire le mois de février 2024 présente une marge d'erreur excessivement élevée. De plus, nous avons identifié une seule relation non fallacieuse dans notre analyse, mais son interprétation demeure problématique.

VIII - Discussion

Au cours de cette étude, nous avons pu nous apercevoir de certaines limites. Dans un premier temps, lors de l'analyse de corrélation, nous avons pu observer une corrélation inverse à celle attendue dans la littérature entre l'incidence de la grippe et la densité de population. Cela peut s'expliquer notamment par la pandémie de covid-19 qui nous a fait changer nos habitudes face aux épidémies, ainsi les gestes barrières imposés durant la pandémie ont sûrement perduré par la suite, faisant alors diminuer l'incidence de la grippe.

Dans un second temps, la prévision du mois de février 2024 par le modèle ARIMA possède une erreur de prévision excessivement élevée. Cela est sûrement dû aux aléas temporels exceptionnels, comme notamment l'apparition du covid, qui ont perturbé cette série temporelle. Ainsi, il serait donc intéressant de réappliquer la méthode de Box-Jenkins, en ne tenant compte que des périodes normales, afin de vérifier si notre modèle de prévision serait meilleur. Compte tenu de la taille importante de la base de données, cette exclusion de certaines périodes nous placerait quand même largement au-dessus des 60 observations nécessaires.

Enfin, nous avons réussi à définir qu'une relation non fallacieuse entre l'incidence de la grippe et la température moyenne en France ; néanmoins, nous n'avons pas pu l'interpréter. Ainsi, dans une logique scientifique, il serait intéressant de proposer de nouvelles variables, aussi bien démographiques que de déplacement de population, d'hygrométrie, d'habitudes des populations, afin de voir si la cointégration est possible et si l'interprétation est également possible.


En résumé, cette étude nous a permis d'appliquer de nouvelles techniques de prévision à des données restrictives sur une période de temps et d'espace. Il serait intéressant, une fois ces techniques de prévision bien maîtrisées, d'étendre notre étude de manière spatio-temporelle. De ce fait, nous pourrions étudier l'incidence de la grippe dans le monde sur des données temporelles plus étendues.

IX - Bibliographie

- Ballesteros, Sébastien. *Ecologie et évolution des maladies infectieuses aiguës: le cas de la grippe*. Diss. Paris 6, 2009.
- Barry, Stéphane, Luc Hessel, and Norbert Gualde. "La grippe, une menace éternelle." *Canadian Bulletin of Medical History* 24.2 (2007): 445-466.
- Berche, Patrick. *Faut-il encore avoir peur de la grippe?: histoire des pandémies*. Odile Jacob, 2012.
- Claude Chastel, *Ces virus qui détruisent les hommes*, Ramsay, 1996, p. 108.
- Desvaux, Édouard, and Jean-François Faucher. "Covid-19: aspects cliniques et principaux éléments de prise en charge." *Revue Francophone des Laboratoires* 2020.526 (2020): 40-47.
- François, Nathalie, Pierre Frankhauser, and Denise Pumain. "Villes, densité et fractalité." *Les Annales de la recherche urbaine*. No. 67. 1995.
- Hannoun, Claude. "La grippe." *Annales de l'Institut Pasteur/Actualités*. Vol. 6. No. 1. Elsevier Masson, 1995.
- Kacki, Sacha, et al. « Prévention, pratiques médicales et gestion sanitaire au cours de la deuxième pandémie de peste », Alain Froment éd., *Archéologie de la santé, anthropologie du soin*. La Découverte, 2019, pp. 119-133.
- Levasseur, Émile. "La population française." *Journal de la Société de statistique de Paris* 32 (1891): 115-118
- Lofgren, Eric et al. "Influenza seasonality: underlying causes and modeling theories." *Journal of virology* vol. 81,11 (2007): 5429-36. doi:10.1128/JVI.01680-06
- Moreau, René. "QU'EST-CE QUE LA GRIPPE?." *Revue des Deux Mondes (1829-1971)* (1955): 80-93.
- Ouzeau, G., et al. "Le climat de la France au XXIe siècle." *Scénarios régionalisés: édition* (2014).
- PANDÉMIQUE, EN CAS DE GRIPPE. "PRÉPARATION DU CANADA EN CAS DE GRIPPE PANDÉMIQUE." (2019)
- Pollock, Allyson M., and James Lancaster. "Asymptomatic transmission of covid-19." *bmj* 371 (2020).
- Vabret, A et al. "La grippe saisonnière" [Seasonal flu]. *Pathologie-biologie* vol. 58,2 (2010): e51-7. doi:10.1016/j.patbio.2010.01.009
- Vallée, Jean-Pierre. "Grippe" à risque": entre croyances et connaissances." *Médecine* 9.9 (2013): 395-395.
- World Health Organization. *Préparation et action en cas de grippe pandémique: document d'orientation de l'OMS*. Organisation mondiale de la Santé, 2009. (consulté le 04/03/24)
- <http://www.grippenet.fr>


X - Annexe

Annexe 1 : Boxplot de l'incidence de la grippe en France




sources : auteur et Rstudio

Annexe 2 : Boxplot de la densité de population française




sources : auteur et Rstudio

Annexe 3 : Boxplot de la température moyenne en France



sources : auteur et Rstudio

Annexe 4 : Matrice de corrélation de notre base de données



sources : auteur et Rstudio

Annexe 5 : Fonction d'autocorrélation résiduelle du modèle ARIMA(0,0,1)(0,1,1) avec constante

RETARD	ACF	PACF	Q	[p. critique]
1	0.1699 ***	0.1699 ***		
2	0.1963 ***	0.1724 ***		
3	-0.1387 ***	-0.2076 ***	34.7262	[0.000]
4	0.0056	0.0286	34.7389	[0.000]
5	-0.0575	0.0061	36.0755	[0.000]
6	0.0047	-0.0245	36.0844	[0.000]
7	0.0108	0.0323	36.1313	[0.000]
8	0.0660	0.0570	37.9053	[0.000]
9	0.0185	-0.0137	38.0455	[0.000]
10	-0.0341	-0.0593	38.5210	[0.000]
11	-0.0393	-0.0054	39.1540	[0.000]
12	0.0308	0.0660	39.5435	[0.000]
13	0.0072	-0.0146	39.5649	[0.000]
14	-0.0005	-0.0290	39.5650	[0.000]
15	0.0862 *	0.1188 **	42.6473	[0.000]
16	0.0519	0.0175	43.7677	[0.000]
17	0.0640	0.0058	45.4761	[0.000]
18	0.0086	0.0270	45.5070	[0.000]
19	-0.0215	-0.0327	45.7009	[0.000]
20	0.0302	0.0462	46.0832	[0.000]
21	-0.0168	-0.0191	46.2016	[0.000]
22	-0.0407	-0.0603	46.9010	[0.001]
23	0.0329	0.0771	47.3595	[0.001]
24	-0.0287	-0.0567	47.7088	[0.001]
25	0.0155	-0.0065	47.8109	[0.002]
26	-0.0557	-0.0108	49.1356	[0.002]
27	0.0004	-0.0130	49.1357	[0.003]
28	0.0210	0.0469	49.3259	[0.004]
29	0.0030	-0.0290	49.3297	[0.005]
30	0.0366	0.0314	49.9068	[0.007]
31	-0.0236	-0.0226	50.1483	[0.009]
32	0.0388	0.0071	50.8029	[0.010]
33	-0.0639	-0.0536	52.5807	[0.009]
34	0.0041	0.0233	52.5882	[0.012]
35	-0.0638	-0.0557	54.3686	[0.011]
36	-0.0208	-0.0325	54.5593	[0.014]

sources : auteur et Gretl

Annexe 6 : Résultat du modèle ARIMA(0,0,1)(0,1,1) sans constante Yt


Evaluations de la fonction : 50
Evaluations du gradient : 16

Modèle 2: ARMA, utilisant les observations 1991:01-2024:01 (T = 397)
Estimation par AS 197 (MV exact)
Variable dépendante: sd_l_INCIDENCE
Écarts-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique
theta_1	0.596183	0.0324462	18.37	2.10e-75 ***
Theta_1	-0.925527	0.0339938	-27.23	3.16e-163 ***

Moyenne var. dép.	0.038085	Éc. type var. dép.	1.147023
Moyenne innovations	0.028892	Éc. type innovations	0.681490
R2	0.649283	R2 ajusté	0.648315
Log de vraisemblance	-422.9231	Critère d'Akaike	851.8462
Critère de Schwarz	863.7981	Hannan-Quinn	856.5807

	Réel	Imaginaire	Modulo	Fréquence
MM				
Ordre 1	-1.6773	0.0000	1.6773	0.5000
MM (saisonnalité)				
Ordre 1	1.0805	0.0000	1.0805	0.0000



RETARD	ACF	PACF	Q	[p. critique]
1	0.1688 ***	0.1688 ***		
2	0.1957 ***	0.1721 ***		
3	-0.1398 ***	-0.2082 ***	34.6209	[0.000]
4	0.0050	0.0281	34.6309	[0.000]
5	-0.0584	0.0055	36.0098	[0.000]
6	0.0040	-0.0250	36.0164	[0.000]
7	0.0098	0.0316	36.0555	[0.000]
8	0.0652	0.0564	37.7864	[0.000]
9	0.0173	-0.0145	37.9090	[0.000]
10	-0.0350	-0.0598	38.4096	[0.000]
11	-0.0403	-0.0061	39.0763	[0.000]
12	0.0304	0.0658	39.4569	[0.000]
13	0.0063	-0.0153	39.4734	[0.000]
14	-0.0014	-0.0299	39.4742	[0.000]
15	0.0850 *	0.1180 **	42.4674	[0.000]
16	0.0509	0.0170	43.5424	[0.000]
17	0.0628	0.0051	45.1880	[0.000]
18	0.0076	0.0264	45.2123	[0.000]
19	-0.0228	-0.0335	45.4298	[0.000]
20	0.0290	0.0454	45.7836	[0.000]
21	-0.0183	-0.0200	45.9249	[0.001]
22	-0.0420	-0.0610	46.6696	[0.001]
23	0.0314	0.0762	47.0877	[0.001]
24	-0.0297	-0.0571	47.4620	[0.001]
25	0.0141	-0.0075	47.5468	[0.002]
26	-0.0570	-0.0116	48.9331	[0.002]
27	-0.0011	-0.0139	48.9336	[0.003]
28	0.0198	0.0462	49.1026	[0.004]
29	0.0017	-0.0296	49.1038	[0.006]
30	0.0356	0.0308	49.6498	[0.007]
31	-0.0250	-0.0234	49.9199	[0.009]
32	0.0377	0.0064	50.5368	[0.011]
33	-0.0654	-0.0544	52.4007	[0.010]
34	0.0029	0.0226	52.4044	[0.013]
35	-0.0650	-0.0562	54.2532	[0.011]
36	-0.0214	-0.0327	54.4545	[0.014]

sources : auteur et Gretl

Annexe 7 : Fonction d'autocorrélation résiduelle du modèle ARIMA(1,0,1)(0,1,1) avec constante

RETARD	ACF	PACF	Q	[p. critique]
1	0.0133	0.0133		
2	0.0145	0.0144		
3	-0.1468 ***	-0.1472 ***		
4	-0.0197	-0.0162	8.9771	[0.003]
5	-0.0177	-0.0130	9.1042	[0.011]
6	-0.0174	-0.0389	9.2274	[0.026]
7	0.0142	0.0103	9.3089	[0.054]
8	0.0658	0.0629	11.0699	[0.050]
9	0.0254	0.0150	11.3326	[0.079]
10	-0.0520	-0.0535	12.4376	[0.087]
11	-0.0467	-0.0282	13.3315	[0.101]
12	0.0472	0.0595	14.2498	[0.114]
13	-0.0064	-0.0199	14.2668	[0.161]
14	-0.0308	-0.0432	14.6579	[0.199]
15	0.0821	0.1010 **	17.4512	[0.133]
16	0.0284	0.0187	17.7860	[0.166]
17	0.0523	0.0337	18.9270	[0.168]
18	-0.0086	0.0255	18.9581	[0.216]
19	-0.0434	-0.0309	19.7482	[0.232]
20	0.0532	0.0624	20.9378	[0.229]
21	-0.0233	-0.0210	21.1673	[0.271]
22	-0.0476	-0.0529	22.1260	[0.278]
23	0.0492	0.0691	23.1503	[0.281]
24	-0.0305	-0.0550	23.5460	[0.316]
25	0.0237	0.0074	23.7861	[0.359]
26	-0.0618	-0.0321	25.4144	[0.329]
27	0.0050	-0.0104	25.4251	[0.383]
28	0.0262	0.0320	25.7205	[0.423]
29	-0.0031	-0.0219	25.7247	[0.478]
30	0.0283	0.0294	26.0709	[0.515]
31	-0.0231	-0.0110	26.3009	[0.557]
32	0.0434	0.0142	27.1176	[0.565]
33	-0.0614	-0.0532	28.7581	[0.530]
34	0.0213	0.0396	28.9570	[0.571]
35	-0.0487	-0.0618	29.9952	[0.568]
36	-0.0397	-0.0558	30.6881	[0.583]

sources : auteur et Gretl

Annexe 8 : Résultat du deuxième modèle ARIMA(1,0,1)(0,1,1) sans constante Yt

Évaluations de la fonction : 49
Évaluations du gradient : 14

Modèle 3: ARMA, utilisant les observations 1991:01-2024:01 (T = 397)
Estimation par AS 197 (MV exact)
Variable dépendante: sd_INCIDENCE
Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique	
phi_1	0.416102	0.0624129	6.667	2.61e-11	***
theta_1	0.349563	0.0586334	5.962	2.49e-09	***
Theta_1	-0.916611	0.0328062	-27.94	8.68e-172	***

Moyenne var. dép.	0.038085	Éc. type var. dép.	1.147023
Moyenne innovations	0.017798	Éc. type innovations	0.653984
R2	0.674361	R2 ajusté	0.672708
Log de vraisemblance	-406.0060	Critère d'Akaike	820.0119
Critère de Schwarz	835.9477	Hannan-Quinn	826.3245

	Réel	Imaginaire	Modulo	Fréquence
AR				
Ordre 1	2.4033	0.0000	2.4033	0.0000
MM				
Ordre 1	-2.8607	0.0000	2.8607	0.5000
MM (saisonnalité)				
Ordre 1	1.0910	0.0000	1.0910	0.0000



RETARD	ACF	PACF	Q	[p. critique]
1	0.0141	0.0141		
2	0.0153	0.0151		
3	-0.1463	***	-0.1468	***
4	-0.0195	-0.0157	8.9348	[0.003]
5	-0.0175	-0.0125	9.0588	[0.011]
6	-0.0172	-0.0385	9.1787	[0.027]
7	0.0145	0.0108	9.2640	[0.055]
8	0.0660	0.0634	11.0395	[0.051]
9	0.0258	0.0154	11.3120	[0.079]
10	-0.0515	-0.0531	12.3995	[0.088]
11	-0.0462	-0.0276	13.2763	[0.103]
12	0.0472	0.0597	14.1943	[0.116]
13	-0.0060	-0.0194	14.2093	[0.164]
14	-0.0303	-0.0426	14.5891	[0.202]
15	0.0826	0.1016	17.4199	[0.134]
16	0.0289	0.0192	17.7664	[0.167]
17	0.0528	0.0341	18.9294	[0.168]
18	-0.0082	0.0259	18.9576	[0.216]
19	-0.0429	-0.0304	19.7289	[0.233]
20	0.0536	0.0629	20.9354	[0.229]
21	-0.0227	-0.0203	21.1527	[0.272]
22	-0.0471	-0.0523	22.0890	[0.280]
23	0.0498	0.0698	23.1389	[0.282]
24	-0.0302	-0.0545	23.5253	[0.317]
25	0.0243	0.0081	23.7769	[0.359]
26	-0.0612	-0.0314	25.3764	[0.331]
27	0.0056	-0.0097	25.3897	[0.385]
28	0.0267	0.0327	25.6960	[0.424]
29	-0.0026	-0.0214	25.6991	[0.480]
30	0.0287	0.0298	26.0552	[0.516]
31	-0.0225	-0.0104	26.2743	[0.558]
32	0.0438	0.0147	27.1073	[0.566]
33	-0.0608	-0.0526	28.7149	[0.533]
34	0.0218	0.0401	28.9230	[0.573]
35	-0.0482	-0.0613	29.9417	[0.571]
36	-0.0396	-0.0555	30.6282	[0.586]

sources : auteur et Gretl

Annexe 9 : Fonction d'autocorrélation résiduelle du modèle ARIMA(2,0,1)(0,1,1) avec constante

RETARD	ACF	PACF	Q	[p. critique]
1	-0.0097	-0.0097		
2	0.0199	0.0198		
3	-0.0350	-0.0347		
4	0.0418	0.0408		
5	0.0146	0.0167	1.4792	[0.224]
6	-0.0242	-0.0268	1.7160	[0.424]
7	0.0001	0.0020	1.7160	[0.633]
8	0.0584	0.0590	3.1031	[0.541]
9	0.0246	0.0226	3.3509	[0.646]
10	-0.0521	-0.0527	4.4639	[0.614]
11	-0.0378	-0.0351	5.0502	[0.654]
12	0.0699	0.0688	7.0610	[0.530]
13	-0.0027	-0.0073	7.0639	[0.630]
14	-0.0335	-0.0342	7.5277	[0.675]
15	0.0845	0.0965	10.4876	[0.487]
16	0.0237	0.0169	10.7203	[0.553]
17	0.0541	0.0408	11.9407	[0.533]
18	-0.0036	0.0146	11.9460	[0.611]
19	-0.0413	-0.0420	12.6619	[0.628]
20	0.0679	0.0575	14.6008	[0.554]
21	-0.0251	-0.0298	14.8658	[0.605]
22	-0.0526	-0.0526	16.0357	[0.590]
23	0.0490	0.0592	17.0531	[0.586]
24	-0.0309	-0.0508	17.4587	[0.623]
25	0.0241	0.0171	17.7052	[0.668]
26	-0.0579	-0.0340	19.1378	[0.637]
27	0.0075	-0.0040	19.1620	[0.692]
28	0.0268	0.0305	19.4695	[0.727]
29	-0.0094	-0.0193	19.5079	[0.772]
30	0.0214	0.0262	19.7063	[0.805]
31	-0.0231	-0.0126	19.9375	[0.833]
32	0.0384	0.0063	20.5781	[0.842]
33	-0.0653	-0.0622	22.4317	[0.802]
34	0.0293	0.0468	22.8064	[0.823]
35	-0.0413	-0.0576	23.5512	[0.828]
36	-0.0469	-0.0528	24.5159	[0.825]


sources : auteur et Gretl

Annexe 10 : Fonction d'autocorrélation résiduelle modèle ARIMA(2,0,0)(0,1,1) sans constante

RETARD	ACF	PACF	Q	[p. critique]
1	-0.0157	-0.0157		
2	0.0271	0.0269		
3	-0.0431	-0.0423		
4	0.0327	0.0308	1.5712	[0.210]
5	0.0088	0.0119	1.6022	[0.449]
6	-0.0244	-0.0277	1.8442	[0.605]
7	0.0008	0.0023	1.8445	[0.764]
8	0.0577	0.0593	3.2015	[0.669]
9	0.0240	0.0227	3.4373	[0.752]
10	-0.0516	-0.0529	4.5274	[0.717]
11	-0.0395	-0.0371	5.1665	[0.740]
12	0.0676	0.0682	7.0474	[0.632]
13	-0.0039	-0.0070	7.0538	[0.720]
14	-0.0335	-0.0365	7.5186	[0.756]
15	0.0844	0.0960	10.4735	[0.574]
16	0.0219	0.0174	10.6737	[0.638]
17	0.0537	0.0393	11.8743	[0.616]
18	-0.0036	0.0157	11.8796	[0.688]
19	-0.0427	-0.0423	12.6441	[0.699]
20	0.0662	0.0572	14.4865	[0.632]
21	-0.0263	-0.0284	14.7778	[0.677]
22	-0.0527	-0.0541	15.9514	[0.661]
23	0.0487	0.0591	16.9551	[0.656]
24	-0.0329	-0.0512	17.4146	[0.686]
25	0.0241	0.0151	17.6627	[0.726]
26	-0.0589	-0.0342	19.1451	[0.693]
27	0.0068	-0.0057	19.1650	[0.743]
28	0.0257	0.0305	19.4489	[0.775]
29	-0.0100	-0.0198	19.4918	[0.815]
30	0.0223	0.0258	19.7071	[0.843]
31	-0.0243	-0.0128	19.9616	[0.866]
32	0.0392	0.0070	20.6275	[0.872]
33	-0.0672	-0.0634	22.5944	[0.832]
34	0.0284	0.0452	22.9470	[0.851]
35	-0.0423	-0.0569	23.7304	[0.854]
36	-0.0464	-0.0541	24.6757	[0.851]

sources : auteur et Gretl

Annexe 11 : Prévisions de l'incidence de la grippe avec le modèle ARIMA (1,0,1)(0,1,1)



sources : auteur et Gretl

Annexe 12 : Tableau de prévision de l'incidence à partir du modèle ARIMA (1,0,1)(0,1,1)

Pour l'intervalle de confiance de 95%, $z(0.025) = 1.96$

	sd_l_INCIDENCE	prédiction	éc. type	intervalle de 95%
2021:11	-0.061967	-0.094739		
2021:12	1.167813	1.734945		
2022:01	1.346227	1.384267		
2022:02	0.678898	1.776853		
2022:03	1.704600	-0.114168		
2022:04	1.896551	1.091308		
2022:05	1.050296	0.650347		
2022:06	1.794853	0.778490		
2022:07	1.205504	0.431295		
2022:08	0.153359	-0.111582		
2022:09	0.866248	0.437809		
2022:10	1.013147	0.481049		
2022:11	1.019944	0.507126		
2022:12	1.668448	1.113003		
2023:01	0.380590	1.104748		
2023:02	0.802442	0.923414		
2023:03	-0.627612	-1.023204		
2023:04	-0.931515	-1.443149		
2023:05	-0.004332	-0.832917		
2023:06	-0.684975	-0.771499		
2023:07	-0.499241	-1.289553		
2023:08	0.614403	-0.421901		
2023:09	0.758872	0.140702		
2023:10	0.249321	-0.092815		
2023:11	0.166065	-0.416832		
2023:12	-0.358688	-0.400311		
2024:01	0.394554	0.350972		
2024:02		0.522324	0.653984	-0.759462 - 1.804109

sources : auteur et Gretl

Annexe 13 : Calcule de la différence entre la prévision à la main et la prévision gretl pour le modèle ARIMA (1,0,1)(0,1,1)s=12

$$\left| \frac{0,582 - 0,522}{0,522} \right| \times 100 = 11,5\%$$

sources : auteur

Annexe 14 : Tableau des observation logarithmique de notre série Yt

	l_INCIDENCE
2022:11	12.71032
2022:12	13.59389
2023:01	12.99447
2023:02	12.69365
2023:03	12.57285
2023:04	11.85223
2023:05	11.38230
2023:06	10.70820
2023:07	10.96459
2023:08	11.43110
2023:09	12.31292
2023:10	12.53906
2023:11	12.87639
2023:12	13.23520
2024:01	13.38902
2024:02	

sources : auteur et Gretl

Annexe 15 : Calcul de Y_{t+1} et de l'erreur de prévisions pour la valeur gretl

$$lY_{t+1} = 0,522 + 13,389$$

$$\Leftrightarrow lY_{t+1} = 13,911$$

$$Y_{t+1} = e^{13,911}$$

$$\Leftrightarrow Y_{t+1} = 1\,100\,197$$


$$\text{Erreur de prévision} = \left| \frac{1\,100\,197 - 648\,943}{648\,943} \right| \times 100$$

$$\Leftrightarrow \text{Erreur de prévision} = 69,53\%$$

sources : auteur

Annexe 16 : Prévisions de l'incidence de la grippe avec le modèle ARIMA

$$(2,0,0)(0,1,1)s=12$$



sources : auteur et Gretl

Annexe 17 : Tableau de prévision de l'incidence à partir du ARIMA (2,0,0)(0,1,1)s=12

Pour l'intervalle de confiance de 95%, $z(0.025) = 1.96$

	sd_l_INCIDENCE	prédiction	éc. type	intervalle de 95%
2022:02	0.678898	1.770330		
2022:03	1.704600	-0.085139		
2022:04	1.896551	1.181779		
2022:05	1.050296	0.782727		
2022:06	1.794853	0.643902		
2022:07	1.205504	0.299084		
2022:08	0.153359	-0.205397		
2022:09	0.866248	0.284952		
2022:10	1.013147	0.343132		
2022:11	1.019944	0.430382		
2022:12	1.668448	1.045403		
2023:01	0.380590	1.018298		
2023:02	0.802442	0.808440		
2023:03	-0.627612	-1.123078		
2023:04	-0.931515	-1.391315		
2023:05	-0.004332	-0.795833		
2023:06	-0.684975	-0.784423		
2023:07	-0.499241	-1.373056		
2023:08	0.614403	-0.520675		
2023:09	0.758872	0.100111		
2023:10	0.249321	-0.197999		
2023:11	0.166065	-0.569808		
2023:12	-0.358688	-0.515239		
2024:01	0.394554	0.253133		
2024:02		0.424034	0.646838	-0.843745 - 1.691812

sources : auteur et Gretl

Annexe 18 : Calcule de la différence entre la prévision à la main et la prévision gretl pour le modèle ARIMA (2,0,0)(0,1,1)s=12

$$\left| \frac{-0,037 - 0,42}{0,42} \right| \times 100 = 108,8\%$$

sources : auteur

Annexe 19 : Calcule de Y_{t+1} et de l'erreur de prévisions pour la valeur gretl

$$lY_{t+1} = 0,42 + 13,389$$

$$\Leftrightarrow lY_{t+1} = 13,809$$

$$Y_{t+1} = e^{13,809}$$

$$\Leftrightarrow Y_{t+1} = 993\,510$$

$$\text{Erreur de prévision} = \left| \frac{993\,510 - 648\,943}{648\,943} \right| \times 100$$

$$\Leftrightarrow \text{Erreur de prévision} = 53,09\%$$

sources : auteur

Annexe 20 : Fonction d'autocorrélation résiduelle du premier modèle ARIMA(0,0,1)(0,1,1) avec constante pour X1

Fonction d'autocorrélation résiduelle
***, **, * indiquent une significativité au seuil de 1%, 5% et 10%
sur la base d'écart-type $1/T^{0.5}$

RETARD	ACF	PACF	Q	[p. critique]
1	0.0089	0.0089		
2	0.0583	0.0582		
3	0.1034 **	0.1027 **	5.7056	[0.017]
4	0.0022	-0.0023	5.7076	[0.058]
5	0.0364	0.0249	6.2452	[0.100]
6	0.0457	0.0354	7.0936	[0.131]
7	0.0600	0.0572	8.5570	[0.128]
8	0.0618	0.0520	10.1142	[0.120]
9	0.0552	0.0419	11.3617	[0.124]
10	0.0022	-0.0160	11.3637	[0.182]
11	0.1221 **	0.1068 **	17.5002	[0.041]
12	-0.0551	-0.0693	18.7503	[0.044]
13	0.1171 **	0.1051 **	24.4234	[0.011]
14	0.1414 ***	0.1202 **	32.7160	[0.001]
15	-0.0514	-0.0608	33.8134	[0.001]
16	0.0959 *	0.0550	37.6476	[0.001]
17	-0.0059	-0.0334	37.6620	[0.001]
18	0.0306	0.0239	38.0532	[0.001]
19	0.0288	0.0031	38.4005	[0.002]
20	0.0110	-0.0103	38.4518	[0.003]
21	0.0142	-0.0062	38.5364	[0.005]
22	0.0902 *	0.0590	41.9779	[0.003]
23	-0.0312	-0.0338	42.3916	[0.004]
24	-0.0090	-0.0429	42.4261	[0.006]
25	0.0788	0.0522	45.0739	[0.004]
26	-0.1022 **	-0.0073 *	49.5424	[0.002]
27	0.0295	-0.0261	49.9158	[0.002]
28	0.0422	0.0492	50.6803	[0.003]
29	0.0551	0.0584	51.9914	[0.003]
30	0.0686	0.0477	54.0248	[0.002]
31	0.0259	0.0223	54.3159	[0.003]
32	0.0068	-0.0221	54.3359	[0.004]
33	0.0109	-0.0038	54.3880	[0.006]
34	0.0157	0.0265	54.4963	[0.008]
35	-0.0442	-0.0672	55.3533	[0.009]
36	0.1118 **	0.0830 *	60.8531	[0.003]

sources : auteur et Gretl

Annexe 21 : Fonction d'autocorrélation résiduelle du premier modèle

ARIMA(1,0,1)(0,1,1) avec constante pour X1

Fonction d'autocorrélation résiduelle
***, **, * indiquent une significativité au seuil de 1%, 5% et 10%
sur la base d'écart-type $1/T^{0.5}$

RETARD	ACF	PACF	Q	[p. critique]
1	0.0239	0.0239		
2	-0.0710	-0.0716		
3	0.0315	0.0352		
4	-0.0467	-0.0539	3.5361	[0.060]
5	-0.0093	-0.0016	3.5710	[0.168]
6	0.0193	0.0112	3.7222	[0.293]
7	0.0417	0.0438	4.4311	[0.351]
8	0.0468	0.0450	5.3248	[0.378]
9	0.0304	0.0330	5.7032	[0.457]
10	-0.0075	-0.0038	5.7265	[0.572]
11	0.0054	0.0930	8.7292	[0.366]
12	-0.0771	-0.0821	11.1794	[0.264]
13	0.1027	0.1277	15.5378	[0.114]
14	0.1322	0.1057	22.7865	[0.019]
15	-0.0617	-0.0440	24.3694	[0.018]
16	0.0646	0.0729	26.1105	[0.016]
17	-0.0131	-0.0297	26.1821	[0.025]
18	0.0125	0.0372	26.2480	[0.035]
19	0.0182	0.0038	26.3870	[0.049]
20	-0.0028	-0.0074	26.3901	[0.068]
21	0.0173	0.0091	26.5163	[0.089]
22	0.0078	0.0655	29.7835	[0.055]
23	-0.0385	-0.0373	30.4111	[0.063]
24	-0.0162	-0.0257	30.5222	[0.082]
25	0.0641	0.0479	32.2741	[0.073]
26	-0.1135	-0.1043	37.7913	[0.027]
27	0.0062	-0.0275	37.8077	[0.036]
28	0.0444	0.0338	38.6549	[0.040]
29	0.0570	0.0476	40.0583	[0.039]
30	0.0058	0.0081	41.9321	[0.033]
31	0.0166	0.0245	42.0521	[0.043]
32	-0.0095	-0.0184	42.0916	[0.055]
33	-0.0016	0.0065	42.0927	[0.070]
34	-0.0110	0.0083	42.1454	[0.087]
35	-0.0613	-0.0821	43.7913	[0.080]
36	0.0961	0.0817	47.8567	[0.046]


sources : auteur et Gretl

Annexe 22 : Modélisation du modèle ARIMA(1,0,0)(0,1,1) sans constante pour X1

Évaluations de la fonction : 46
Évaluations du gradient : 14

Modèle 5: ARMA, utilisant les observations 1991:01-2024:02 (T = 398)
Estimation par AS 197 (MV exact)
Variable dépendante: sd_1_DEGRES
Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique
phi_1	0.233963	0.0489427	4.780	1.75e-06 ***
Theta_1	-0.999998	0.0905868	-11.04	2.47e-28 ***
Moyenne var. dép.	0.003733	Éc. type var. dép.	0.248447	
Moyenne innovations	0.008726	Éc. type innovations	0.170934	
R2	0.529822	R2 ajusté	0.528634	
Log de vraisemblance	117.1062	Critère d'Akaike	-228.2124	
Critère de Schwarz	-216.2530	Hannan-Quinn	-223.4754	
	Réel	Imaginaire	Modulo	Fréquence
AR				
Ordre 1	4.2742	0.0000	4.2742	0.0000
MM (saisonnalité)				
Ordre 1	1.0000	0.0000	1.0000	0.0000



Fonction d'autocorrélation résiduelle
***, **, * indiquent une significativité au seuil de 1%, 5% et 10%
sur la base d'écart-type $1/T^{0.5}$

RETARD	ACF	PACF	Q	[p. critique]
1	-0.0155	-0.0155		
2	0.0146	0.0143		
3	0.1073	0.1078	4.8246	[0.028]
4	0.0007	0.0040	4.8249	[0.090]
5	0.0339	0.0311	5.2903	[0.152]
6	0.0463	0.0362	6.1611	[0.187]
7	0.0594	0.0603	7.5976	[0.180]
8	0.0626	0.0580	9.1975	[0.163]
9	0.0515	0.0449	10.2842	[0.173]
10	0.0045	-0.0080	10.2926	[0.245]
11	0.1209	0.1077	16.3099	[0.061]
12	-0.0637	-0.0752	17.9819	[0.055]
13	0.1164	0.1091	23.5859	[0.015]
14	0.1432	0.1193	32.0079	[0.001]
15	-0.0572	-0.0513	33.4459	[0.001]
16	0.0940	0.0594	37.1248	[0.001]
17	-0.0028	-0.0346	37.1282	[0.001]
18	0.0293	0.0265	37.4887	[0.002]
19	0.0320	0.0035	37.9188	[0.003]
20	0.0086	-0.0110	37.9500	[0.004]
21	0.0166	-0.0051	38.0668	[0.006]
22	0.0949	0.0620	41.8795	[0.003]
23	-0.0333	-0.0335	42.3501	[0.004]
24	-0.0068	-0.0391	42.3698	[0.006]
25	0.0859	0.0544	45.5226	[0.003]
26	-0.1027	-0.0885	50.0342	[0.001]
27	0.0283	-0.0285	50.3774	[0.002]
28	0.0454	0.0414	51.2650	[0.002]
29	0.0532	0.0565	52.4858	[0.002]
30	0.0674	0.0517	54.4526	[0.002]
31	0.0243	0.0273	54.7095	[0.003]
32	0.0051	-0.0205	54.7207	[0.004]
33	0.0150	0.0004	54.8186	[0.005]
34	0.0144	0.0239	54.9087	[0.007]
35	-0.0484	-0.0743	55.9376	[0.008]
36	0.1083	0.0762	61.0916	[0.003]

sources : auteur et Gretl

Annexe 23 : Fonction d'autocorrélation résiduelle du modèle ARIMA(1,0,1)(0,1,2) avec constante pour X1

Fonction d'autocorrélation résiduelle
 ***, **, * indiquent une significativité au seuil de 1%, 5% et 10%
 sur la base d'écart-type $1/T^{0.5}$

RETARD	ACF	PACF	Q	[p. critique]
1	0.1345 ***	0.1345 ***		
2	-0.0232	-0.0421		
3	0.0061	0.0153		
4	-0.0735	-0.0790		
5	-0.0580	-0.0370	11.0262	[0.001]
6	-0.0320	-0.0250	11.4429	[0.003]
7	-0.0114	-0.0050	11.4960	[0.009]
8	-0.0102	-0.0143	11.5380	[0.021]
9	-0.0136	-0.0173	11.6140	[0.040]
10	-0.0401	-0.0439	12.2729	[0.056]
11	0.0475	0.0561	13.2019	[0.067]
12	0.0078	-0.0126	13.2271	[0.104]
13	0.0883 *	0.0938 *	16.4492	[0.058]
14	0.0840 *	0.0509	19.3729	[0.036]
15	-0.0795	-0.0919 *	21.9985	[0.024]
16	0.0218	0.0519	22.1961	[0.035]
17	-0.0439	-0.0518	22.9998	[0.042]
18	-0.0190	0.0181	23.1507	[0.058]
19	-0.0167	-0.0230	23.2674	[0.079]
20	-0.0374	-0.0328	23.8580	[0.093]
21	-0.0183	-0.0102	24.0001	[0.119]
22	0.0417	0.0419	24.7355	[0.132]
23	-0.0676	-0.0812	26.6739	[0.112]
24	-0.0422	-0.0269	27.4306	[0.124]
25	0.0350	0.0174	27.9522	[0.142]
26	-0.1160 **	-0.1247 **	33.7070	[0.053]
27	-0.0357	-0.0263	34.2549	[0.062]
28	0.0195	0.0230	34.4180	[0.078]
29	0.0413	0.0388	35.1528	[0.085]
30	0.0502	0.0216	36.2444	[0.087]
31	0.0024	-0.0048	36.2469	[0.110]
32	-0.0272	-0.0389	36.5690	[0.129]
33	-0.0335	-0.0195	37.0588	[0.145]
34	-0.0326	-0.0152	37.5239	[0.162]
35	-0.0713	-0.0739	39.7555	[0.135]
36	0.0671	0.0826	41.7357	[0.116]

sources : auteur et Gretl

Annexe 24 : Modélisation du modèle ARIMA(1,0,1)(0,1,2) sans constante pour X1


Évaluations de la fonction : 80
 Évaluations du gradient : 28

Modèle 7: ARMA, utilisant les observations 1991:01-2024:02 (T = 398)
 Estimation par AS 197 (MV exact)
 Variable dépendante: sd_1_DEGRES
 Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique
phi_1	0.987036	0.0322467	30.61	9.32e-206 ***
theta_1	0.824144	0.0636791	-14.32	1.55e-46 ***
Theta_1	-1.11060	0.0912277	-12.17	4.28e-34 ***
Theta_2	0.110598	0.0544321	2.032	0.0422 **

Moyenne var. dép. 0.003733 Éc. type var. dép. 0.248447
 Moyenne innovations 0.004914 Éc. type innovations 0.168754
 R2 0.538593 R2 ajusté 0.535079
 Log de vraisemblance 121.8440 Critère d'Akaike -233.6881
 Critère de Schwarz -213.7558 Hannan-Quinn -225.7931

Réel Imaginaire Modulo Fréquence



Fonction d'autocorrélation résiduelle
 ***, **, * indiquent une significativité au seuil de 1%, 5% et 10%
 sur la base d'écart-type $1/T^{0.5}$

RETARD	ACF	PACF	Q	[p. critique]
1	0.1333 ***	0.1333 ***		
2	-0.0248	-0.0434		
3	0.0050	0.0145		
4	-0.0747	-0.0801		
5	-0.0592	-0.0381	11.0595	[0.001]
6	-0.0332	-0.0262	11.5068	[0.003]
7	-0.0124	-0.0061	11.5691	[0.009]
8	-0.0110	-0.0153	11.6184	[0.020]
9	-0.0143	-0.0182	11.7022	[0.039]
10	-0.0410	-0.0451	12.3907	[0.054]
11	0.0465	0.0548	13.2816	[0.066]
12	0.0060	-0.0146	13.2963	[0.102]
13	0.0871 *	0.0929 *	16.4369	[0.058]
14	0.0832 *	0.0501	19.3079	[0.037]
15	-0.0804	-0.0925 *	21.9934	[0.024]
16	0.0212	0.0512	22.1800	[0.036]
17	-0.0444	-0.0525	23.0055	[0.042]
18	-0.0195	0.0175	23.1653	[0.058]
19	-0.0171	-0.0235	23.2875	[0.078]
20	-0.0378	-0.0333	23.8881	[0.092]
21	-0.0185	-0.0107	24.0328	[0.119]
22	0.0414	0.0413	24.7601	[0.132]
23	-0.0680	-0.0817	26.7235	[0.111]
24	-0.0427	-0.0276	27.4995	[0.122]
25	0.0349	0.0172	28.0188	[0.140]
26	-0.1164 **	-0.1253 **	33.8147	[0.051]
27	-0.0357	-0.0270	34.3626	[0.060]
28	0.0195	0.0223	34.5267	[0.076]
29	0.0413	0.0382	35.2642	[0.084]
30	0.0503	0.0212	36.3595	[0.085]
31	0.0024	-0.0053	36.3620	[0.108]
32	-0.0273	-0.0395	36.6864	[0.126]
33	-0.0335	-0.0200	37.1767	[0.142]
34	-0.0329	-0.0160	37.6504	[0.159]
35	-0.0721	-0.0753	39.9277	[0.131]
36	0.0667	0.0816	41.8867	[0.113]

sources : auteur et Gretl


Annexe 25 : Modélisation du modèle ARIMA(1,0,1)(1,1,1) sans constante pour X1

Évaluations de la fonction : 126
Évaluations du gradient : 36

Modèle 8: ARMA, utilisant les observations 1991:01-2024:02 (T = 398)
Estimation par AS 197 (MV exact)
Variable dépendante: sd_1_DEGRES
Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique	
phi_1	0.983857	0.0374989	26.24	1.01e-151 ***	
Phi_1	-0.100258	0.0514739	-1.948	0.0514 *	
theta_1	0.734120	0.0734371	-12.35	4.73e-35 ***	
Theta_1	-1.00000	0.0636553	-15.71	1.30e-55 ***	
Moyenne var. dép.	0.003733	Éc. type var. dép.	0.248447		
Moyenne innovations	0.004721	Éc. type innovations	0.168904		
R2	0.537990	R2 ajusté	0.534472		
Log de vraisemblance	121.6532	Critère d'Akaike	-233.3064		
Critère de Schwarz	-213.3741	Hannan-Quinn	-225.4114		

	Réel	Imaginaire	Modulo	Fréquence
AR				
Ordre 1	1.0164	0.0000	1.0164	0.0000
AR (saisonnier)				
Ordre 1	-9.9743	0.0000	9.9743	0.5000
MM				
Ordre 1	1.1024	0.0000	1.1024	0.0000
MM (saisonnalité)				
Ordre 1	1.0000	0.0000	1.0000	0.0000



Fonction d'autocorrélation résiduelle
***, **, * indiquent une significativité au seuil de 1%, 5% et 10% sur la base d'écart-type $1/T^{0.5}$

RETARD	ACF	PACF	Q	[p. critique]
1	0.1304 ***	0.1304 ***		
2	-0.0265	-0.0442		
3	0.0049	0.0146		
4	-0.0755	-0.0808		
5	-0.0595	-0.0386	10.8461	[0.001]
6	-0.0332	-0.0266	11.2927	[0.004]
7	-0.0112	-0.0052	11.3437	[0.010]
8	-0.0094	-0.0142	11.3799	[0.023]
9	-0.0127	-0.0171	11.4460	[0.043]
10	-0.0415	-0.0461	12.1522	[0.059]
11	0.0462	0.0546	13.0312	[0.071]
12	-0.0029	-0.0234	13.0345	[0.111]
13	0.0851 *	0.0936 *	16.0270	[0.066]
14	0.0848 *	0.0515	19.0090	[0.040]
15	-0.0788	-0.0905 *	21.5926	[0.028]
16	0.0237	0.0520	21.8258	[0.040]
17	-0.0432	-0.0522	22.6044	[0.047]
18	-0.0179	0.0188	22.7394	[0.065]
19	-0.0150	-0.0215	22.8338	[0.088]
20	-0.0352	-0.0312	23.3562	[0.105]
21	-0.0159	-0.0086	23.4636	[0.135]
22	0.0444	0.0429	24.2995	[0.145]
23	-0.0680	-0.0809	26.2647	[0.123]
24	-0.0513	-0.0359	27.3854	[0.125]
25	0.0333	0.0196	27.8585	[0.144]
26	-0.1177 **	-0.1253 **	33.7875	[0.052]
27	-0.0337	-0.0262	34.2749	[0.061]
28	0.0220	0.0234	34.4832	[0.076]
29	0.0435	0.0381	35.2998	[0.083]
30	0.0520	0.0222	36.4674	[0.083]
31	0.0035	-0.0043	36.4726	[0.105]
32	-0.0259	-0.0386	36.7639	[0.124]
33	-0.0319	-0.0189	37.2068	[0.141]
34	-0.0322	-0.0153	37.6593	[0.159]
35	-0.0724	-0.0758	39.9581	[0.130]
36	0.0687	0.0831 *	42.0365	[0.110]

sources : auteur et Gretl


Annexe 26 : Modélisation du modèle ARIMA(2,0,1)(0,1,1) sans constante pour X1

Évaluations de la fonction : 130
Évaluations du gradient : 35

Modèle 15: ARMA, utilisant les observations 1991:01-2024:02 (T = 398)
Estimation par AS 197 (MV exact)
Variable dépendante: sd_1_DEGRES
Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique	
phi_1	1.15385	0.0539252	21.40	1.42e-101 ***	
phi_2	-0.155293	0.0523127	-2.969	0.0030 ***	
theta_1	0.854232	0.0174118	-55.03	0.0000 ***	
Theta_1	-0.999999	0.0395176	-25.31	2.80e-141 ***	
Moyenne var. dép.	0.003733	Éc. type var. dép.	0.248447		
Moyenne innovations	0.006247	Éc. type innovations	0.168582		
R2	0.548220	R2 ajusté	0.544780		
Log de vraisemblance	123.9974	Critère d'Akaike	-237.9949		
Critère de Schwarz	-218.0626	Hannan-Quinn	-230.0999		

	Réel	Imaginaire	Modulo	Fréquence
AR				
Ordre 1	1.0017	0.0000	1.0017	0.0000
Ordre 2	6.4284	0.0000	6.4284	0.0000
MM				
Ordre 1	1.0436	0.0000	1.0436	0.0000
MM (saisonnalité)				
Ordre 1	1.0000	0.0000	1.0000	0.0000



Fonction d'autocorrélation résiduelle
***, **, * indiquent une significativité au seuil de 1%, 5% et 10% sur la base d'écart-type $1/T^{0.5}$

RETARD	ACF	PACF	Q	[p. critique]
1	-0.0010	-0.0010		
2	-0.0279	-0.0279		
3	0.0531	0.0531		
4	-0.0516	-0.0525		
5	-0.0209	-0.0178	2.7018	[0.100]
6	-0.0035	-0.0092	2.7068	[0.258]
7	0.0126	0.0171	2.7713	[0.428]
8	0.0167	0.0157	2.8849	[0.577]
9	0.0042	0.0037	2.8921	[0.717]
10	-0.0392	-0.0412	3.5233	[0.741]
11	0.0700	0.0706	5.5394	[0.594]
12	-0.1032 **	-0.1056 **	9.9342	[0.270]
13	0.0769	0.0905 *	12.3824	[0.193]
14	0.1052 **	0.0871 *	16.9666	[0.075]
15	-0.0924 *	-0.0761 *	20.5185	[0.039]
16	0.0489	0.0415	21.5144	[0.043]
17	-0.0411	-0.0533	22.2188	[0.052]
18	-0.0114	0.0117	22.2728	[0.073]
19	-0.0076	-0.0151	22.2972	[0.100]
20	-0.0293	-0.0277	22.6597	[0.123]
21	-0.0172	-0.0175	22.7844	[0.156]
22	0.0584	0.0446	24.2309	[0.148]
23	-0.0686	-0.0549	26.2283	[0.124]
24	-0.0438	-0.0522	27.0451	[0.134]
25	0.0447	0.0340	27.8990	[0.143]
26	-0.1377 ***	-0.1113 **	36.0137	[0.030]
27	-0.0078	-0.0407	36.0399	[0.041]
28	0.0194	0.0266	36.2017	[0.052]
29	0.0314	0.0388	36.6277	[0.063]
30	0.0450	0.0337	37.5040	[0.067]
31	-0.0014	0.0080	37.5048	[0.086]
32	-0.0247	-0.0368	37.7696	[0.103]
33	-0.0165	-0.0128	37.8885	[0.125]
34	-0.0196	0.0041	38.0560	[0.148]
35	-0.0754	-0.0878 *	40.5468	[0.117]
36	0.0835 *	0.0697	43.6116	[0.083]

sources : auteur et Gretl

Annexe 27 : Fonction d'autocorrélation résiduelle du modèle ARIMA(1,1,0)(1,1,0) avec constante pour X2

Fonction d'autocorrélation résiduelle
***, **, * indiquent une significativité au seuil de 1%, 5% et 10%
sur la base d'écart-type 1/T^{0.5}

RETARD	ACF	PACF	Q [p. critique]
1	-0.1133 **	-0.1133 **	
2	-0.0151	-0.0283	
3	0.0366	0.0321	5.7532 [0.016]
4	0.0742	0.0829	7.9641 [0.019]
5	0.0699	0.0915 *	9.9354 [0.019]
6	-0.0081	0.0133	9.9617 [0.041]
7	0.1415 ***	0.1429 ***	18.0741 [0.003]
8	0.0059	0.0299	18.0883 [0.006]
9	0.1412 ***	0.1468 ***	26.2039 [0.000]
10	0.0072	0.0305	26.2252 [0.001]
11	0.0453	0.0397	27.0662 [0.001]
12	-0.1370 ***	-0.1710 ***	34.7670 [0.000]
13	0.0850 *	0.0217	37.7373 [0.000]
14	0.2898 ***	0.1770 ***	55.8892 [0.000]
15	0.0160	0.0746	55.9948 [0.000]
16	0.0200	0.0174	56.1611 [0.000]
17	-0.0089	-0.0180	56.1944 [0.000]
18	0.0754	0.0059	58.5639 [0.000]
19	-0.0014	0.0106	58.5647 [0.000]
20	0.0653	0.0529	60.3501 [0.000]
21	0.0849 *	0.0930 *	63.3788 [0.000]
22	-0.0520	-0.0783	64.5197 [0.000]
23	0.1229 **	0.0510	70.9031 [0.000]
24	-0.2460 ***	-0.3281 ***	96.5376 [0.000]
25	0.0328	-0.0613	96.9935 [0.000]
26	-0.0063	0.0113	97.0105 [0.000]
27	-0.0081	-0.0168	97.0384 [0.000]
28	0.0154	-0.0373	97.1404 [0.000]
29	-0.0113	-0.0217	97.1948 [0.000]
30	0.0258	-0.0242	97.4809 [0.000]
31	-0.0887 *	-0.0196	100.8779 [0.000]
32	0.0262	0.0292	101.1762 [0.000]
33	-0.0492	0.0577	102.2282 [0.000]
34	0.0478	0.0101	103.2250 [0.000]
35	0.0490	0.0951 *	104.2712 [0.000]
36	-0.0189	-0.1105 **	104.4270 [0.000]

sources : auteur et Gretl

Annexe 28 : Modélisation du modèle ARIMA(1,1,0)(1,1,0) sans constante pour X2


Évaluations de la fonction : 27
Évaluations du gradient : 5

Modèle 3: ARMA, utilisant les observations 1991:02-2024:01 (T = 396)
Estimation par AS 197 (MV exact)
Variable dépendante: d_sd_DENSITE
Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique
phi_1	0.759112	0.0337250	22.51	3.40e-112 ***
Phi_1	-0.527030	0.0446015	-11.82	3.21e-32 ***

Moyenne var. dép.	-0.000215	Éc. type var. dép.	0.009956
Moyenne innovations	-0.000053	Éc. type innovations	0.006652
R2	0.555455	R2 ajusté	0.554326
Log de vraisemblance	1420.800	Critère d'Akaike	-2835.600
Critère de Schwarz	-2823.656	Hannan-Quinn	-2830.868

	Réel	Imaginaire	Modulo	Fréquence
AR				
Ordre 1	1.3173	0.0000	1.3173	0.0000
AR (saisonnier)				
Ordre 1	-1.8974	0.0000	1.8974	0.5000



Fonction d'autocorrélation résiduelle
***, **, * indiquent une significativité au seuil de 1%, 5% et 10%
sur la base d'écart-type 1/T^{0.5}

RETARD	ACF	PACF	Q [p. critique]
1	-0.1135 **	-0.1135 **	
2	-0.0153	-0.0285	
3	0.0365	0.0319	5.7661 [0.016]
4	0.0741	0.0828	7.9720 [0.019]
5	0.0698	0.0914 *	9.9382 [0.019]
6	-0.0082	0.0132	9.9652 [0.041]
7	0.1414 ***	0.1429 ***	18.0699 [0.003]
8	0.0058	0.0298	18.0837 [0.006]
9	0.1411 ***	0.1468 ***	26.1924 [0.000]
10	0.0072	0.0305	26.2134 [0.001]
11	0.0453	0.0397	27.0523 [0.001]
12	-0.1371 ***	-0.1710 ***	34.7654 [0.000]
13	0.0849 *	0.0216	37.7319 [0.000]
14	0.2097 ***	0.1770 ***	55.8818 [0.000]
15	0.0159	0.0746	55.9865 [0.000]
16	0.0200	0.0174	56.1519 [0.000]
17	-0.0090	-0.0180	56.1856 [0.000]
18	0.0753	0.0059	58.5524 [0.000]
19	-0.0014	0.0106	58.5532 [0.000]
20	0.0652	0.0529	60.3365 [0.000]
21	0.0849 *	0.0930 *	63.3634 [0.000]
22	-0.0521	-0.0783	64.5061 [0.000]
23	0.1229 **	0.0510	70.8902 [0.000]
24	-0.2460 ***	-0.3281 ***	96.5298 [0.000]
25	0.0328	-0.0614	96.9856 [0.000]
26	-0.0063	0.0113	97.0025 [0.000]
27	-0.0081	-0.0168	97.0305 [0.000]
28	0.0154	-0.0374	97.1326 [0.000]
29	-0.0113	-0.0217	97.1870 [0.000]
30	0.0258	-0.0243	97.4735 [0.000]
31	-0.0887 *	-0.0197	100.8717 [0.000]
32	0.0263	0.0292	101.1702 [0.000]
33	-0.0492	0.0576	102.2228 [0.000]
34	0.0479	0.0101	103.2198 [0.000]
35	0.0490	0.0952 *	104.2664 [0.000]
36	-0.0189	-0.1105 **	104.4223 [0.000]

sources : auteur et Gretl

Annexe 29 : Fonction d'autocorrélation résiduelle du modèle ARIMA(2,1,0)(1,1,0) avec constante pour X2

Fonction d'autocorrélation résiduelle
***, **, * indiquent une significativité au seuil de 1%, 5% et 10%
sur la base d'écart-type $1/T^{0.5}$

RETARD	ACF	PACF	Q	[p. critique]
1	-0.0199	-0.0199		
2	-0.1045 **	-0.1050 **		
3	-0.0119	-0.0164		
4	0.0453	0.0341	5.4099	[0.020]
5	0.0367	0.0361	5.9528	[0.051]
6	-0.0211	-0.0116	6.1327	[0.105]
7	0.1127 **	0.1221 **	11.2817	[0.024]
8	0.0188	0.0209	11.4258	[0.044]
9	0.1191 **	0.1450 ***	17.1999	[0.009]
10	0.0014	0.0159	17.2007	[0.016]
11	-0.0140	0.0091	17.2806	[0.027]
12	-0.1518 ***	-0.1662 ***	26.7380	[0.002]
13	0.0816	0.0689	29.4752	[0.001]
14	0.2170 ***	0.1700 ***	48.9008	[0.000]
15	0.0308	0.0607	49.2926	[0.000]
16	-0.0045	0.0196	49.3011	[0.000]
17	-0.0194	-0.0093	49.4571	[0.000]
18	0.0615	0.0240	51.0345	[0.000]
19	0.0037	0.0281	51.0402	[0.000]
20	0.0727	0.0862 *	53.2580	[0.000]
21	0.0871 *	0.0978 *	56.4460	[0.000]
22	-0.0239	-0.0472	56.6874	[0.000]
23	0.0762	0.0364	59.1379	[0.000]
24	-0.2581 ***	-0.3362 ***	87.3687	[0.000]
25	-0.0076	-0.0140	87.3935	[0.000]
26	0.0066	-0.0064	87.4121	[0.000]
27	-0.0017	-0.0347	87.4134	[0.000]
28	0.0171	-0.0463	87.5389	[0.000]
29	0.0002	-0.0341	87.5389	[0.000]
30	0.0165	-0.0383	87.6561	[0.000]
31	-0.0823	-0.0219	90.5812	[0.000]
32	0.0097	0.0304	90.6217	[0.000]
33	-0.0400	0.0413	91.3180	[0.000]
34	0.0563	0.0149	92.6981	[0.000]
35	0.0720	0.0806	94.9614	[0.000]
36	-0.0068	-0.1178 **	94.9815	[0.000]

sources : auteur et Gretl

Annexe 30 : Modélisation du modèle ARIMA(2,1,0)(1,1,0) sans constante pour X2


Évaluations de la fonction : 27
Évaluations du gradient : 6

Modèle 6: ARMA, utilisant les observations 1991:02-2024:01 (T = 396)
Estimation par AS 197 (MV exact)
Variable dépendante: d_sd_DENSITE
Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique	
phi_1	0.642955	0.0503540	12.77	2.45e-37	***
phi_2	0.156534	0.0510945	3.064	0.0022	***
Phi_1	-0.551224	0.0437680	-12.59	2.27e-36	***
Moyenne var. dép.	-0.000215	Éc. type var. dép.	0.009956		
Moyenne innovations	-0.000045	Éc. type innovations	0.006572		
R2	0.566192	R2 ajusté	0.563984		
Log de vraisemblance	1425.420	Critère d'Akaike	-2842.839		
Critère de Schwarz	-2826.913	Hannan-Quinn	-2836.530		
	Réel	Imaginaire	Modulo	Fréquence	
AR					
Ordre 1	1.2030	0.0000	1.2030	0.0000	
Ordre 2	-5.3104	0.0000	5.3104	0.5000	
AR (saisonnier)					
Ordre 1	-1.8141	0.0000	1.8141	0.5000	

Fonction d'autocorrélation résiduelle
***, **, * indiquent une significativité au seuil de 1%, 5% et 10%
sur la base d'écart-type $1/T^{0.5}$

RETARD	ACF	PACF	Q	[p. critique]
1	-0.0199	-0.0199		
2	-0.1046 **	-0.1051 **		
3	-0.0119	-0.0165		
4	0.0453	0.0340	5.4188	[0.020]
5	0.0366	0.0360	5.9598	[0.051]
6	-0.0212	-0.0116	6.1408	[0.105]
7	0.1127 **	0.1221 **	11.2853	[0.024]
8	0.0188	0.0208	11.4286	[0.044]
9	0.1190 **	0.1449 ***	17.1988	[0.009]
10	0.0013	0.0159	17.1995	[0.016]
11	-0.0140	0.0090	17.2800	[0.027]
12	-0.1519 ***	-0.1663 ***	26.7464	[0.002]
13	0.0815	0.0689	29.4814	[0.001]
14	0.2170 ***	0.1700 ***	48.9073	[0.000]
15	0.0307	0.0607	49.2983	[0.000]
16	-0.0046	0.0196	49.3070	[0.000]
17	-0.0194	-0.0092	49.4636	[0.000]
18	0.0615	0.0240	51.0395	[0.000]
19	0.0037	0.0281	51.0452	[0.000]
20	0.0727	0.0863 *	53.2618	[0.000]
21	0.0871 *	0.0978 *	56.4489	[0.000]
22	-0.0240	-0.0472	56.6907	[0.000]
23	0.0761	0.0364	59.1408	[0.000]
24	-0.2581 ***	-0.3362 ***	87.3741	[0.000]
25	-0.0076	-0.0140	87.3989	[0.000]
26	0.0066	-0.0064	87.4176	[0.000]
27	-0.0017	-0.0348	87.4189	[0.000]
28	0.0171	-0.0464	87.5445	[0.000]
29	0.0002	-0.0341	87.5446	[0.000]
30	0.0165	-0.0383	87.6618	[0.000]
31	-0.0823	-0.0219	90.5873	[0.000]
32	0.0097	0.0304	90.6278	[0.000]
33	-0.0400	0.0413	91.3241	[0.000]
34	0.0563	0.0148	92.7047	[0.000]
35	0.0720	0.0806	94.9690	[0.000]
36	-0.0068	-0.1179 **	94.9891	[0.000]



sources : auteur et Gretl

Annexe 31 : Fonction d'autocorrélation résiduelle du modèle ARIMA(2,1,1)(1,1,0) avec constante pour X2

Fonction d'autocorrélation résiduelle
***, **, * indiquent une significativité au seuil de 1%, 5% et 10%
sur la base d'écart-type $1/T^{0.5}$

RETARD	ACF	PACF	Q	[p. critique]
1	0.0036	0.0036		
2	-0.0116	-0.0116		
3	-0.0063	-0.0062		
4	0.0151	0.0150		
5	0.0094	0.0091	0.2018	[0.653]
6	-0.0535	-0.0533	1.3597	[0.507]
7	0.0829 *	0.0840 *	4.1458	[0.246]
8	-0.0232	-0.0258	4.3649	[0.359]
9	0.0828	0.0850 *	7.1547	[0.209]
10	-0.0465	-0.0472	8.0386	[0.235]
11	-0.0312	-0.0296	8.4375	[0.296]
12	-0.1644 ***	-0.1718 ***	19.5273	[0.012]
13	0.0559	0.0694	20.8147	[0.013]
14	0.1859 ***	0.1761 ***	35.0798	[0.000]
15	0.0231	0.0414	35.3012	[0.000]
16	0.0142	0.0003	35.3849	[0.000]
17	-0.0134	-0.0089	35.4590	[0.001]
18	0.0683	0.0408	37.4014	[0.001]
19	0.0100	0.0495	37.4428	[0.001]
20	0.0710	0.0858 *	39.5584	[0.001]
21	0.0793	0.0868 *	42.1997	[0.001]
22	-0.0574	-0.0930 *	43.5891	[0.001]
23	0.0541	0.0141	44.8278	[0.001]
24	-0.2853 ***	-0.3302 ***	79.3071	[0.000]
25	-0.0328	-0.0010	79.7633	[0.000]
26	-0.0414	0.0247	80.4942	[0.000]
27	-0.0314	-0.0341	80.9148	[0.000]
28	-0.0034	-0.0546	80.9197	[0.000]
29	-0.0204	-0.0370	81.0984	[0.000]
30	0.0081	-0.0347	81.1264	[0.000]
31	-0.0886 *	-0.0180	84.5143	[0.000]
32	0.0149	0.0285	84.6100	[0.000]
33	-0.0373	0.0339	85.2153	[0.000]
34	0.0566	-0.0206	86.6119	[0.000]
35	0.0639	0.0485	88.3954	[0.000]
36	-0.0075	-0.1372 ***	88.4203	[0.000]

sources : auteur et Gretl

Annexe 32 : Modélisation du modèle ARIMA(2,1,1)(1,1,0) sans constante pour X2



Évaluations de la fonction : 59
Évaluations du gradient : 17

Modèle 7: ARMA, utilisant les observations 1991:02-2024:01 (T = 396)
Estimation par AS 197 (MV exact)
Variable dépendante: d_sd_DENSITE
Écartés-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique
phi_1	1.32116	0.111710	11.83	2.84e-32 ***
phi_2	-0.356861	0.0981077	-3.637	0.0003 ***
Phi_1	-0.549915	0.0430653	-12.77	2.43e-37 ***
theta_1	-0.726188	0.0901310	-8.057	7.82e-16 ***

Moyenne var. dép. -0.000215 Éc. type var. dép. 0.009956
Moyenne innovations -0.000037 Éc. type innovations 0.006471
R2 0.577371 R2 ajusté 0.574136
Log de vraisemblance 1431.668 Critère d'Akaike -2853.335
Critère de Schwarz -2833.428 Hannan-Quinn -2845.449

	Réel	Imaginaire	Modulo	Fréquence
AR				
Ordre 1	1.0610	0.0000	1.0610	0.0000
Ordre 2	2.6412	0.0000	2.6412	0.0000
AR (saisonnier)				
Ordre 1	-1.8185	0.0000	1.8185	0.5000
MM				
Ordre 1	1.3771	0.0000	1.3771	0.0000



Fonction d'autocorrélation résiduelle
***, **, * indiquent une significativité au seuil de 1%, 5% et 10%
sur la base d'écart-type $1/T^{0.5}$

RETARD	ACF	PACF	Q	[p. critique]
1	0.0036	0.0036		
2	-0.0116	-0.0116		
3	-0.0063	-0.0062		
4	0.0151	0.0150		
5	0.0094	0.0091	0.2018	[0.653]
6	-0.0535	-0.0533	1.3601	[0.507]
7	0.0829 *	0.0840 *	4.1458	[0.246]
8	-0.0232	-0.0258	4.3651	[0.359]
9	0.0828	0.0850 *	7.1546	[0.209]
10	-0.0465	-0.0473	8.0386	[0.235]
11	-0.0312	-0.0296	8.4376	[0.296]
12	-0.1644 ***	-0.1718 ***	19.5286	[0.012]
13	0.0559	0.0694	20.8158	[0.013]
14	0.1859 ***	0.1761 ***	35.0813	[0.000]
15	0.0231	0.0414	35.3027	[0.000]
16	0.0142	0.0003	35.3864	[0.000]
17	-0.0134	-0.0089	35.4605	[0.001]
18	0.0683	0.0408	37.4029	[0.001]
19	0.0100	0.0495	37.4443	[0.001]
20	0.0710	0.0858 *	39.5598	[0.001]
21	0.0793	0.0868 *	42.2012	[0.001]
22	-0.0574	-0.0930 *	43.5907	[0.001]
23	0.0541	0.0141	44.8295	[0.001]
24	-0.2853 ***	-0.3302 ***	79.3078	[0.000]
25	-0.0328	-0.0010	79.7640	[0.000]
26	-0.0414	0.0248	80.4948	[0.000]
27	-0.0314	-0.0341	80.9154	[0.000]
28	-0.0034	-0.0546	80.9203	[0.000]
29	-0.0204	-0.0370	81.0990	[0.000]
30	0.0081	-0.0347	81.1271	[0.000]
31	-0.0886 *	-0.0180	84.5149	[0.000]
32	0.0149	0.0285	84.6106	[0.000]
33	-0.0373	0.0339	85.2159	[0.000]
34	0.0566	-0.0206	86.6126	[0.000]
35	0.0639	0.0484	88.3962	[0.000]
36	-0.0075	-0.1372 ***	88.4211	[0.000]

sources : auteur et Gretl

Annexe 33 : Fonction d'autocorrélation résiduelle du modèle ARIMA(2,1,1)(1,1,1) avec constante pour X2

Fonction d'autocorrélation résiduelle
***, **, * indiquent une significativité au seuil de 1%, 5% et 10%
sur la base d'écart-type $1/T^{0.5}$

RETARD	ACF	PACF	Q	[p. critique]
1	0.0200	0.0200		
2	-0.0519	-0.0523		
3	0.0110	0.0131		
4	0.0350	0.0319		
5	-0.0070	-0.0072		
6	-0.0957 *	-0.0925 *	5.4982	[0.019]
7	0.0346	0.0376	5.9831	[0.050]
8	0.0041	-0.0078	5.9900	[0.112]
9	0.1073 **	0.1151 **	10.6753	[0.030]
10	-0.0149	-0.0161	10.7655	[0.056]
11	0.0120	0.0213	10.8243	[0.094]
12	-0.0129	-0.0282	10.8922	[0.143]
13	0.0430	0.0484	11.6514	[0.167]
14	0.1442 ***	0.1433 ***	20.2342	[0.017]
15	0.0116	0.0321	20.2896	[0.027]
16	-0.0063	-0.0044	20.3060	[0.041]
17	-0.0308	-0.0344	20.6993	[0.055]
18	-0.0006	-0.0263	20.6994	[0.079]
19	0.0001	0.0146	20.6994	[0.110]
20	0.1031 **	0.1322 ***	25.1541	[0.048]
21	0.0671	0.0687	27.0487	[0.041]
22	-0.0548	-0.0652	28.3152	[0.041]
23	0.1227 **	0.0920 *	34.6722	[0.010]
24	-0.0130	-0.0366	34.7439	[0.015]
25	0.0170	0.0389	34.8662	[0.021]
26	-0.0716	-0.0428	37.0476	[0.017]
27	-0.0598	-0.0722	38.5727	[0.016]
28	-0.0077	-0.0565	38.5979	[0.022]
29	-0.0498	-0.0677	39.6623	[0.023]
30	-0.0230	-0.0366	39.8898	[0.030]
31	-0.0878 *	-0.0676	43.2212	[0.018]
32	0.0648	0.0369	45.0391	[0.016]
33	0.0059	-0.0141	45.0541	[0.022]
34	0.0600	0.0181	46.6193	[0.020]
35	0.0493	0.0436	47.6818	[0.021]
36	-0.0484	-0.0403	48.7079	[0.022]

sources : auteur et Gretl


Annexe 32 : Modélisation du modèle ARIMA(2,1,1)(1,1,0) sans constante pour X2

Évaluations de la fonction : 79
Évaluations du gradient : 23

Modèle 11: ARMA, utilisant les observations 1991:02-2024:01 (T = 396)
Estimation par AS 197 (MV exact)
Variable dépendante: d_sd_DENSITE
Écart-types basés sur la matrice hessienne

	coefficient	éc. type	z	p. critique
phi_1	1.42183	0.0798901	17.80	7.41e-71 ***
phi_2	-0.429057	0.0777210	-5.520	3.38e-08 ***
phi_1	-0.101369	0.0611236	-1.658	0.0972 *
theta_1	-0.779293	0.0533839	-14.60	2.90e-48 ***
Theta_1	-0.871080	0.0419111	-20.78	6.04e-96 ***
Moyenne var. dép.	-0.000215	Éc. type var. dép.	0.009956	
Moyenne innovations	-0.000058	Éc. type innovations	0.005577	
R2	0.685452	R2 ajusté	0.682235	
Log de vraisemblance	1483.679	Critère d'Akaike	-2955.358	
Critère de Schwarz	-2931.470	Hannan-Quinn	-2945.894	

	Réel	Imaginaire	Modulo	Fréquence
AR				
Ordre 1	1.0129	0.0000	1.0129	0.0000
Ordre 2	2.3009	0.0000	2.3009	0.0000
AR (saisonnier)				
Ordre 1	-9.8650	0.0000	9.8650	0.5000
MM				
Ordre 1	1.2832	0.0000	1.2832	0.0000
MM (saisonnalité)				
Ordre 1	1.1480	0.0000	1.1480	0.0000



Fonction d'autocorrélation résiduelle
***, **, * indiquent une significativité au seuil de 1%, 5% et 10%
sur la base d'écart-type $1/T^{0.5}$

RETARD	ACF	PACF	Q	[p. critique]
1	0.0199	0.0199		
2	-0.0520	-0.0524		
3	0.0108	0.0130		
4	0.0349	0.0318		
5	-0.0071	-0.0073		
6	-0.0958 *	-0.0926 *	5.5038	[0.019]
7	0.0345	0.0375	5.9870	[0.050]
8	0.0040	-0.0079	5.9935	[0.112]
9	0.1072 **	0.1150 **	10.6717	[0.031]
10	-0.0149	-0.0161	10.7629	[0.056]
11	0.0119	0.0212	10.8205	[0.094]
12	-0.0130	-0.0284	10.8903	[0.143]
13	0.0428	0.0483	11.6458	[0.168]
14	0.1442 ***	0.1433 ***	20.2272	[0.017]
15	0.0115	0.0320	20.2819	[0.027]
16	-0.0064	-0.0045	20.2986	[0.041]
17	-0.0308	-0.0344	20.6936	[0.055]
18	-0.0006	-0.0263	20.6937	[0.079]
19	0.0001	0.0146	20.6937	[0.110]
20	0.1030 **	0.1322 ***	25.1428	[0.048]
21	0.0671	0.0687	27.0332	[0.041]
22	-0.0549	-0.0653	28.3038	[0.042]
23	0.1226 **	0.0920 *	34.6532	[0.010]
24	-0.0131	-0.0366	34.7264	[0.015]
25	0.0169	0.0389	34.8475	[0.021]
26	-0.0716	-0.0428	37.0301	[0.017]
27	-0.0598	-0.0722	38.5577	[0.016]
28	-0.0077	-0.0565	38.5830	[0.022]
29	-0.0498	-0.0678	39.6491	[0.023]
30	-0.0230	-0.0366	39.8765	[0.030]
31	-0.0879 *	-0.0676	43.2104	[0.018]
32	0.0648	0.0369	45.0264	[0.016]
33	0.0058	-0.0141	45.0410	[0.022]
34	0.0599	0.0180	46.6050	[0.020]
35	0.0493	0.0436	47.6666	[0.021]
36	-0.0485	-0.0404	48.6978	[0.023]

sources : auteur et Gretl

Annexe 33 : Hypothèse du test ADF

H_0 : Existence de la racine unitaire

H_0 accepté si $P_{critique} > 0,05$ ainsi la série est non stationnaire

H_0 rejeté si $P_{critique} \leq 0,05$ ainsi la série est stationnaire

sources : auteur

Annexe 34 : Hypothèse du test KPSS

H_0 : Stationnarité de la série

H_0 accepté si $P_{critique} > 0,05$ ainsi la série est stationnaire

H_0 rejeté si $P_{critique} \leq 0,05$ ainsi la série est non stationnaire

sources : auteur

Annexe 35 : Test ADF pour la série brute Yt

Test de Dickey-Fuller augmenté pour INCIDENCE
avec 24 retards de (1-L)INCIDENCE
taille de l'échantillon 384
hypothèse nulle de racine unitaire : a = 1

avec constante et tendance temporelle
modèle: $(1-L)y = b_0 + b_1*t + (a-1)*y(-1) + \dots + e$
valeur estimée de (a - 1): -1.32904
statistique de test: tau_ct(1) = -3.99809
p. critique asymptotique 0.008769
Coeff. d'autocorrélation du 1er ordre pour e: 0.000
différences retardées: F(24, 357) = 6.276 [0.0000]

sources : auteur et Gretl

Annexe 36 : Test ADF pour la série sd l Yt

Test de Dickey-Fuller augmenté pour sd_l_INCIDENCE
avec 25 retards de (1-L)sd_l_INCIDENCE
taille de l'échantillon 371
hypothèse nulle de racine unitaire : a = 1

test avec constante
modèle: $(1-L)y = b_0 + (a-1)*y(-1) + \dots + e$
valeur estimée de (a - 1): -0.944492
statistique de test: tau_c(1) = -5.05265
p. critique asymptotique 1.591e-05
Coeff. d'autocorrélation du 1er ordre pour e: 0.003
différences retardées: F(25, 344) = 8.506 [0.0000]

sources : auteur et Gretl

Annexe 37 : Test ADF pour la série brute X1

Test de Dickey-Fuller augmenté pour DEGRES
avec 36 retards de (1-L)DEGRES
taille de l'échantillon 373
hypothèse nulle de racine unitaire : $a = 1$

avec constante et tendance temporelle
modèle: $(1-L)y = b_0 + b_1t + (a-1)y(-1) + \dots + e$
valeur estimée de $(a - 1)$: -0.0707886
statistique de test: $\tau_{ct}(1) = -0.447357$
p. critique asymptotique 0.9859
Coeff. d'autocorrélation du 1er ordre pour e: 0.004
différences retardées: $F(36, 334) = 43.613 [0.0000]$

sources : auteur et Gretl

Annexe 38 : Test ADF pour la série sd l X1

Test de Dickey-Fuller augmenté pour sd_l_DEGRES
avec 36 retards de (1-L)sd_l_DEGRES
taille de l'échantillon 361
hypothèse nulle de racine unitaire : $a = 1$

avec constante et tendance temporelle
modèle: $(1-L)y = b_0 + b_1t + (a-1)y(-1) + \dots + e$
valeur estimée de $(a - 1)$: -1.65965
statistique de test: $\tau_{ct}(1) = -4.46848$
p. critique asymptotique 0.001643
Coeff. d'autocorrélation du 1er ordre pour e: 0.004
différences retardées: $F(36, 322) = 8.128 [0.0000]$

sources : auteur et Gretl

Annexe 39 : Test ADF pour la série brute X2

Test de Dickey-Fuller augmenté pour DENSITE
avec 28 retards de (1-L)DENSITE
taille de l'échantillon 380
hypothèse nulle de racine unitaire : $a = 1$

avec constante et tendance temporelle
modèle: $(1-L)y = b_0 + b_1t + (a-1)y(-1) + \dots + e$
valeur estimée de $(a - 1)$: -0.00140172
statistique de test: $\tau_{ct}(1) = -1.91705$
p. critique asymptotique 0.6455
Coeff. d'autocorrélation du 1er ordre pour e: 0.000
différences retardées: $F(28, 349) = 101.560 [0.0000]$

sources : auteur et Gretl

Annexe 40 : Test ADF pour la série d X2

Test de Dickey-Fuller augmenté pour d_DENSITE
test à reculons à partir de 16 retards, suivant le critère AIC
taille de l'échantillon 392
hypothèse nulle de racine unitaire : $a = 1$

test avec constante
avec 15 retards de (1-L)d_DENSITE
modèle: $(1-L)y = b_0 + (a-1)y(-1) + \dots + e$
valeur estimée de $(a - 1)$: -0.0393688
statistique de test: $\tau_c(1) = -1.71609$
p. critique asymptotique 0.4231
Coeff. d'autocorrélation du 1er ordre pour e: -0.003
différences retardées: $F(15, 375) = 17.235 [0.0000]$

sources : auteur et Gretl

Annexe 41 : Test ADF pour la série sd X2

Test de Dickey-Fuller augmenté pour sd_DENSITE
test à reculons à partir de 15 retards, suivant le critère AIC
taille de l'échantillon 382
hypothèse nulle de racine unitaire : $a = 1$

test avec constante
avec 14 retards de $(1-L)sd_DENSITE$
modèle: $(1-L)y = b_0 + (a-1)*y(-1) + \dots + e$
valeur estimée de $(a - 1)$: -0.00446135
statistique de test: $\tau_c(1) = -2.08278$
p. critique asymptotique 0.2518
Coeff. d'autocorrélation du 1er ordre pour e: -0.001
différences retardées: $F(14, 366) = 40.083 [0.0000]$

sources : auteur et Gretl

Annexe 42 : Test ADF pour la série d sd X2

Test de Dickey-Fuller augmenté pour d_sd_DENSITE
test à reculons à partir de 25 retards, suivant le critère AIC
taille de l'échantillon 371
hypothèse nulle de racine unitaire : $a = 1$

test avec constante
avec 24 retards de $(1-L)d_sd_DENSITE$
modèle: $(1-L)y = b_0 + (a-1)*y(-1) + \dots + e$
valeur estimée de $(a - 1)$: -0.210575
statistique de test: $\tau_c(1) = -3.19654$
p. critique asymptotique 0.02022
Coeff. d'autocorrélation du 1er ordre pour e: -0.001
différences retardées: $F(24, 345) = 10.365 [0.0000]$

sources : auteur et Gretl

Annexe 43 : Test ADF pour les résidus des MCO de la relation : Y_t & X_1

Test de Dickey-Fuller augmenté pour residu_MCO
avec 4 retards de $(1-L)residu_MCO$
taille de l'échantillon 404
hypothèse nulle de racine unitaire : $a = 1$

test avec constante
modèle: $(1-L)y = b_0 + (a-1)*y(-1) + \dots + e$
valeur estimée de $(a - 1)$: -1.17641
statistique de test: $\tau_c(1) = -10.8766$
p. critique asymptotique 4.841e-22
Coeff. d'autocorrélation du 1er ordre pour e: 0.001
différences retardées: $F(4, 398) = 15.559 [0.0000]$

avec constante et tendance temporelle
modèle: $(1-L)y = b_0 + b_1*t + (a-1)*y(-1) + \dots + e$
valeur estimée de $(a - 1)$: -1.17651
statistique de test: $\tau_{ct}(1) = -10.8624$
p. critique asymptotique 2.237e-23
Coeff. d'autocorrélation du 1er ordre pour e: 0.001
différences retardées: $F(4, 397) = 15.521 [0.0000]$

sources : auteur et Gretl

Annexe 44 : Test ADF pour les résidus des MCO de la relation : X_1 & Y_t

```
Test de Dickey-Fuller augmenté pour residus_MCO_X1_Y
avec 24 retards de (1-L)residus_MCO_X1_Y
taille de l'échantillon 384
hypothèse nulle de racine unitaire : a = 1

test avec constante
modèle: (1-L)y = b0 + (a-1)*y(-1) + ... + e
valeur estimée de (a - 1): -0.615887
statistique de test: tau_c(1) = -2.15752
p. critique asymptotique 0.2223
Coeff. d'autocorrélation du 1er ordre pour e: -0.001
différences retardées: F(24, 358) = 12.303 [0.0000]

avec constante et tendance temporelle
modèle: (1-L)y = b0 + b1*t + (a-1)*y(-1) + ... + e
valeur estimée de (a - 1): -0.641693
statistique de test: tau_ct(1) = -2.23308
p. critique asymptotique 0.4705
Coeff. d'autocorrélation du 1er ordre pour e: -0.001
différences retardées: F(24, 357) = 12.317 [0.0000]
```

sources : auteur et Gretl

XII - Table des Figures

Figure :

- Figure 1 : Processus de stationnarisation
- Figure 2 : Processus du modèle Box-Jenkins
- Figure 3 : Visualisation graphique et Corrélogramme de la série brut
- Figure 4 : Comparaison série logarithmique et série brute et corrélogramme de la série logarithmique
- Figure 5 : Visualisation graphique et Corrélogramme de la série logarithmique différencier de manière classique
- Figure 6 : Visualisation graphique et Corrélogramme de la série logarithmique différencier de manière saisonnière
- Figure 7 : Visualisation graphique et Corrélogramme de la série brut
- Figure 8 : Comparaison de la série brute et de la série avec logarithme et Corrélogramme de la série logarithmique
- Figure 9 : Visualisation graphique et Corrélogramme de la série logarithmique différencier de manière classique
- Figure 10 : Visualisation graphique et Corrélogramme de la série logarithmique différencier de manière saisonnière
- Figure 11 : Visualisation graphique et Corrélogramme de la série brut
- Figure 12 : Comparaison de la série brute et de la série avec logarithme et Corrélogramme de la série logarithmique
- Figure 13 : Visualisation graphique et Corrélogramme de la série différencier de manière classique
- Figure 14 : Visualisation graphique et Corrélogramme de la série différencier de manière saisonnière
- Figure 15 : Visualisation graphique et Corrélogramme de la série doublement différencier
- Figure 16 : Schéma récapitulatif de la méthode de Engle-Granger

Graphique :

- Graphique 1 : Evolution de l'incidence de la grippe en France de 1990 à décembre 2023
- Graphique 2 : Evolution de la température moyenne en France de 1990 à décembre 2023
- Graphique 3 : Evolution de la densité de population française de 1990 à décembre 2023
- Graphique 4 : Evolution conjointe de l'incidence de la grippe et de la température en France
- Graphique 5 : Evolution conjointe de l'incidence de la grippe et de la densité de la population française en France

Modélisation :

- Modélisation 1 : Proposition d'un modèle mixte ARIMA(0,0,1)(0,1,1)
- Modélisation 2 : Proposition d'un modèle mixte ARIMA(1,0,1)(0,1,1)
- Modélisation 3 : Proposition d'un modèle mixte ARIMA(2,0,1)(0,1,1)

- Modélisation 4 : Proposition d'un modèle mixte ARIMA(2,0,0)(0,1,1)
- Modélisation 5 : Proposition du modèle mixte ARIMA(0,0,1)(0,1,1)
- Modélisation 6 : Proposition du modèle mixte ARIMA(1,0,1)(0,1,1)
- Modélisation 7 : Proposition du modèle mixte ARIMA(1,0,1)(0,1,2)
- Modélisation 8 : Proposition du modèle mixte ARIMA(1,1,0)(1,1,0)
- Modélisation 9 : Proposition du modèle mixte ARIMA(2,1,0)(1,1,0)
- Modélisation 10 : Proposition du modèle mixte ARIMA(2,1,1)(1,1,0)
- Modélisation 11 : Proposition du modèle mixte ARIMA(2,1,1)(1,1,1)
- Modélisation 12 : MCO pour la relation : Y_t & X_1
- Modélisation 13 : MCE pour la relation : Y_t & X_1
- Modélisation 14 : MCO pour la relation : X_1 & Y_t

Tableau :

- Tableau 1 : Statistique descriptives de notre base de données
- Tableau 2 : Tableau récapitulatif des corrélations attendue et observée
- Tableau 3 : Récapitulatif du modèle ARIMA(0,0,1)(0,1,1) avec constante
- Tableau 4 : Récapitulatif du modèle ARIMA(0,0,1)(0,1,1) sans constante
- Tableau 5 : Récapitulatif du modèle ARIMA(1,0,1)(0,1,1) avec constante
- Tableau 6 : Récapitulatif du modèle ARIMA(1,0,1)(0,1,1) sans constante
- Tableau 7 : Récapitulatif du modèle ARIMA avec constante
- Tableau 8 : Récapitulatif du modèle ARIMA (2,0,0)(0,1,1)
- Tableau 9 : Valeurs des séries temporelles pour février 2024
- Tableau 10 : Valeur observée, ajustée et termes d'erreur du premier modèle
- Tableau 11 : Comparaison de prédiction avec les valeurs manuelles et celle de gretl pour le modèle ARIMA (1,0,1)(0,1,1)
- Tableau 12 : Valeur observée, ajustée et termes d'erreur
- Tableau 13 : Comparaison de prédiction avec les valeurs manuelles et celle de gretl pour le modèle ARIMA (2,0,0)(0,1,1)
- Tableau 14 : Synthèse des modèles sélectionnés pour la prévision
- Tableau 15 : Récapitulatif du modèle ARIMA(0,0,1)(0,1,1) avec constante
- Tableau 16 : Récapitulatif du deuxième modèle ARIMA(1,0,1)(0,1,1) avec constante
- Tableau 17 : Récapitulatif du modèle modèle ARIMA(1,0,0)(0,1,1) sans constante
- Tableau 18 : Récapitulatif du modèle modèle ARIMA(1,0,1)(0,1,2) avec constante
- Tableau 19 : Récapitulatif du modèle modèle ARIMA(1,0,1)(1,1,1) sans constante
- Tableau 20 : Synthèse des modèles valides pour la série X1
- Tableau 21 : Récapitulatif du modèle mixte ARIMA(1,1,0)(1,1,0) avec constante
- Tableau 22 : Récapitulatif du modèle mixte ARIMA(1,1,0)(1,1,0) sans constante
- Tableau 23 : Récapitulatif du modèle mixte ARIMA(2,1,0)(1,1,0) avec constante
- Tableau 24 : Récapitulatif du modèle mixte ARIMA(2,1,0)(1,1,0) sans constante

- Tableau 25 : Récapitulatif du modèle mixte ARIMA(2,1,1)(1,1,0) avec constante
- Tableau 26 : Récapitulatif du modèle mixte ARIMA(2,1,1)(1,1,0) sans constante
- Tableau 27 : Récapitulatif du modèle mixte ARIMA(2,1,1)(1,1,0) avec constante
- Tableau 28 : Récapitulatif du modèle mixte ARIMA(2,1,1)(1,1,0) sans constante
- Tableau 29 : Récapitulatifs de la stationnarité des séries effectués par les tests et ARIMA
- Tableau 30 : Test ADF sur les résidus à long termes de la relation : Y_t & X_1
- Tableau 31 : Test ADF sur les résidus à long termes de la relation : X_1 & Y_t

XIII - Table des matières

I - Introduction.....	1
II - Revue de littérature de la grippe.....	3
A) L'incidence de la Grippe en France.....	3
B) La température moyenne en France (En Celsius).....	4
C) Densité de population française (Habitant au km ²).....	5
III - Caractérisation statistique et analyse des séries chronologiques.....	6
A) Statistique descriptives.....	6
B) Tendances des séries chronologiques.....	8
1 - Tendance de l'incidence de la grippe en France (Y).....	8
2 - Tendance de la température moyenne en France (X1).....	9
3 - Tendance de la densité de la population française (X2).....	10
C) Analyse des corrélations et relation entre la série à expliquer et les séries explicatives.....	11
1 - Corrélation entre l'incidence de la grippe en France et la température moyenne en France (Y et X1).....	11
2 - Corrélation entre l'incidence de la grippe en France et la densité de population française. (Y et X2).....	12
3 - récapitulatifs des corrélations attendues et observées.....	13
IV - Présentation de la méthodologie ARIMA.....	14
A) Le principe de stationnarité.....	14
B) Les corrélogrammes.....	16
C) Mise en place du modèle Box-jenkins.....	17
1 - Identification.....	17
2 - Estimation.....	18
3 - Vérification.....	18
4 - Prédiction.....	19
V - Sélection des modèle ARIMA.....	20
A) Choix du modèle pour l'incidence de la grippe en France (Yt).....	20
1 - Stationnarisation.....	20
2 - Identification & Estimation.....	23
3 - Prévision à une période.....	29
a - Prévision à une période du modèle ARIMA(1,0,1)(0,1,1) _s = 12.....	29
b - Prévision à une période du modèle ARIMA(2,0,0)(0,1,1) _s = 12.....	33
4 - Choix du meilleur modèle.....	37
B) Choix du modèle pour la température moyenne en France (X1).....	39
1 - Stationnarisation.....	39
2 - Identification & Estimation & Choix du meilleur modèle.....	42
C) Choix du modèle pour la densité de population française (X2).....	48
1 - Stationnarisation.....	48
2 - Identification & Estimation & Choix du meilleur modèle.....	52

VI - Test de cointégration selon Engle-Granger.....	59
A) Explication théorique.....	59
B) Vérification de l'ordre d'intégration.....	61
C) Cointégration entre L'incidence de la grippe et la température moyenne (Y_t & X_1)..	62
1 - Application des MCO.....	62
2 - Application des MCE.....	63
3 - Estimation des coefficients.....	64
D) Cointégration entre la température moyenne et l'incidence de la grippe(X_1 & Y_t)....	64
1 - Application des MCO.....	64
2 - Application des MCE.....	65
VII - Conclusion.....	66
VIII - Discussion.....	67
IX - Bibliographie.....	68
X - Annexe.....	69
XII - Table des Figures.....	88
XIII - Table des matières.....	91