



UNIVERSITÉ DE NANTES



IAE NANTES
ÉCONOMIE & MANAGEMENT

Master Econométrie et Statistiques, parcours Econométrie Appliquée

Rapport d'activité au sein du Crédit Mutuel Arkéa

**Rapprochement & étude du coût de consommation
de la banque et de la valeur instantanée liés aux
projets valeurs clients**

MOCAËR RODOLPHE



Sous la direction de :

- Olivier DARNE Tuteur académique
- Anne CRESPIY Tuteur d'entreprise

Publié le 2024-08-20

Remerciement

Je tiens à remercier chaleureusement Anne Crespy, qui m'a encadré durant tout mon stage et m'a permis de travailler sur des sujets passionnants. Grâce à son accompagnement, j'ai pu développer mes compétences sur des thématiques techniques et stimulantes, notamment autour de l'OAC, tout en gagnant en autonomie et en rigueur.

Je remercie également toute l'équipe Marges et notamment le responsable de l'équipe Fabien Lagadec, qui m'ont intégré avec bienveillance et m'ont offert un cadre de travail collaboratif et enrichissant.

Je tiens aussi à exprimer ma gratitude envers l'ensemble de mes collègues, aussi bien du département de modélisation financière que de la direction du pilotage financier. Leur soutien, leurs conseils et leur bonne humeur ont contribué à créer un environnement de travail à la fois stimulant, sain et convivial, ponctué de moments d'échanges et de pauses toujours enrichissantes.

Je remercie enfin Olivier Darné, mon tuteur académique, pour avoir pris le temps de répondre à toutes mes interrogations et m'avoir guidé dans ma réflexion tout au long de ce stage.

Je n'oublie pas l'ensemble des professeurs du Master ECAP, qui m'ont transmis les connaissances, les méthodes et surtout l'envie de progresser dans le domaine de la data science.

Enfin, je souhaite remercier mes camarades de classe, avec qui j'ai partagé une année riche en émotion.

Sommaire

Remerciement.....	I
Sommaire.....	II
Résumé de la partie II.....	III
Abstract of part II.....	IV
Liste de Sigle.....	V
PARTIE I - RAPPORT DE MISSION.....	1
Chapitre I - Introduction.....	2
Chapitre II - Environnement de l'entreprise.....	3
Chapitre III - Exposition des missions principales.....	9
Chapitre IV - Bilan.....	15
PARTIE II - RAPPROCHEMENT DU COÛT DE CONSOMMATION DE LA BANQUE ET DE LA VALEUR INSTANTANÉE.....	16
Chapitre I - Introduction.....	17
Chapitre II - Méthodologie d'extraction des données.....	20
Chapitre III - Analyse statistique.....	24
Chapitre IV - Conclusion.....	43
Annexe.....	45
Liste des titres des tableaux & graphiques & figures & modélisations.....	49
Bibliographie & Sitographie.....	51
Tables des matières.....	52

Résumé de la partie II

L'étude statistique a montré une forte hétérogénéité des sous-familles de produit, avec une rentabilité concentrée sur une minorité de produits. L'ACP a réduit la complexité en deux dimensions principales (rentabilité (PNB) et coût (CCB)) restituant plus de 50 % de l'information. La clusterisation K-means a identifié un cluster central homogène et plusieurs profils atypiques aux comportements extrêmes. Cette segmentation fournit des leviers stratégiques pour optimiser la gestion et cibler les actions commerciales.

Mots clé : Rapprochement, PNB, CCB, Arkéa, OAC, clusterisation

Abstract of part II

The statistical study showed a strong heterogeneity of product subfamilies, with profitability concentrated on a minority of products. The PCA reduced the complexity into two main dimensions (profitability (GNP) and cost (CCB)) restoring more than 50% of the information. K-means clustering identified a homogeneous central cluster and several atypical profiles with extreme behaviors. This segmentation provides strategic levers to optimize management and target commercial actions.

Keywords: Rapprochement, PNB, CCB, Arkéa, OAC, clusterization

Liste de Sigle

Fédération :

- ❖ CMB : Crédit Mutuel de Bretagne
- ❖ CMSO : Crédit Mutuel du Sud-Ouest

❖ noctrcctl : Numéro de contrat catalogue

Département de la DPF :

- ❖ CDG : Contrôle De Gestion
- ❖ GDB : Gestion De Bilan
- ❖ DPF : Direction du Pilotage Financier
- ❖ MOF : MOdélisation Financière

Indicateur financier :

- ❖ CCB : Coût de Consommation de la Banque
- ❖ PNB : Produit Net Bancaire
- ❖ PNBA : Produit Net Bancaire Annuel
- ❖ TCI : Taux de Cession Interne
- ❖ VI : Valeur Instantanée

Sigle statistique :

- ❖ ASD : Asymétrie à droite
- ❖ ACP : Analyse en Composantes Principales
- ❖ Dim : Dimension
- ❖ LPK : leptokurtique

Autres :

- ❖ OAC : Oracle Analytics Cloud
- ❖ PPT : Power Point
- ❖ Cdsfam : Code sous-familles

PARTIE I - RAPPORT DE MISSION

Chapitre I - Introduction

Suite à mon cursus en économétrie appliquée à l'Institut d'Administration des Entreprises de Nantes, et aux nombreux projets réalisés durant mon parcours académique sur des thématiques variées telles que la santé et la finance, j'ai progressivement affiné mon intérêt pour le secteur de la banque et de l'assurance. C'est à travers le projet DRiM Games, mené en groupe durant le premier semestre, qui portait sur "l'analyse du taux de défaillance des entreprises par secteur d'activité en France", que j'ai décidé d'orienter mon stage de fin d'études vers des problématiques plus spécifiques à ce domaine. Le monde bancaire représente un environnement à la fois complexe, stimulant et porteur de sens dans les grandes transformations économiques et technologiques actuelles. De ce fait, un stage en secteur bancaire m'a semblé particulièrement pertinent pour le développement de mes compétences en tant que futur Data Scientist et Analyst. C'est ainsi que, poussé par la motivation d'accroître mes connaissances et compétences, j'ai choisi d'effectuer mon stage au sein du groupe Crédit Mutuel Arkéa, plus précisément à la direction du pilotage financier, dans le département de modélisation financière, un domaine en adéquation avec mes objectifs.

Durant six mois, du 3 mars 2025 au 29 août 2025, j'ai intégré l'équipe Marges au sein du département de Modélisation financière. Ma mission principale consistait à établir un rapprochement entre deux indicateurs financiers : la valeur instantanée et le coût de consommation de la banque. Ce travail avait pour finalité de comprendre et de gérer les écarts entre ces deux indicateurs financiers, afin de fiabiliser le programme "Valeur client", qui permet au Crédit Mutuel Arkéa de développer un nouvel axe de connaissance client, optimisant ainsi le pilotage financier et orientant les stratégies des fédérations CMB et CMSO. Dès lors, la mise en place d'un reporting s'est révélée être la solution idéale pour éclairer ce rapprochement, tout en introduisant dans le département un nouvel outil de reporting : Oracle Analytics Cloud (OAC). Ce dernier sera par la suite complété par l'intégration de machine learning dans la prévision de ces indicateurs, ouvrant ainsi de nouveaux horizons. En parallèle de cette mission enrichissante mais exigeante, j'ai également eu l'opportunité de participer à d'autres projets, tels que la fiabilisation d'un reporting nommé "Rentimo" et l'analyse de certains écarts.

Chapitre II - Environnement de l'entreprise¹

A - Présentation du Crédit Mutuel Arkéa

Le Crédit Mutuel est l'un des plus anciens et des plus influents groupes bancaires français. Fondé à la fin du XIXe siècle, il puise son inspiration dans le mouvement coopératif initié par Friedrich Raiffeisen en Allemagne, dont l'objectif était de proposer des services financiers solidaires, accessibles à tous, notamment dans les zones rurales. En France, ce modèle mutualiste voit le jour dès 1882, porté par une volonté forte : offrir un financement éthique, simple et local, ancré dans les territoires. Depuis, le Crédit Mutuel s'est considérablement développé pour devenir un acteur majeur du paysage bancaire européen, tout en restant fidèle à ses valeurs d'origine. Ce qui distingue fondamentalement le Crédit Mutuel des banques commerciales traditionnelles, c'est son statut mutualiste. Contrairement aux banques cotées en Bourse, détenues par des actionnaires et orientées vers la maximisation du profit, les banques mutualistes appartiennent à leurs clients sociétaires. Ces derniers détiennent des parts sociales, participent aux décisions stratégiques lors des assemblées générales, et élisent leurs représentants. Ce modèle coopératif favorise un ancrage local fort et une gestion orientée vers l'intérêt général. Il se traduit souvent par une politique d'investissement plus prudente, mais également plus résiliente, comme cela a été démontré lors des différentes crises financières.

Parmi les fédérations régionales autonomes qui composent le groupe Crédit Mutuel, Crédit Mutuel Arkéa occupe une place singulière. Présente principalement en Bretagne et dans le Sud-Ouest, Arkéa réunit le Crédit Mutuel de Bretagne (CMB), le Crédit Mutuel du Sud-Ouest (CMSO), ainsi qu'une quarantaine de filiales spécialisées. Ses racines remontent à la création de l'Office central des œuvres mutuelles agricoles du Finistère en 1911, dont la mission était de moderniser les campagnes bretonnes. En 1979, sous l'impulsion de Louis Lichou, le Crédit Mutuel de Bretagne est officiellement constitué. C'est en 2002 que naît le groupe Crédit Mutuel Arkéa, regroupant le CMB, le CMSO, et plusieurs filiales afin de former une entité indépendante au sein du groupe Crédit Mutuel. Son siège, situé au Relecq-Kerhuon près de Brest, symbolise son ancrage territorial et sa volonté de piloter l'innovation depuis les régions. Le groupe se distingue par son agilité et son engagement dans la transformation digitale, en misant fortement sur les nouvelles technologies et la

¹ https://www.cm-arkea.com/arkea/banque/assurances/j_6/fr/accueil

valorisation des données. À travers des filiales comme Fortuneo (banque en ligne), Suravenir (assurance-vie), Financo (crédit à la consommation) ou encore Arkéa Banque Entreprises et Institutionnels, le groupe propose une offre bancaire complète à destination des particuliers, des professionnels, des entreprises et des collectivités. De plus, le Crédit Mutuel Arkéa incarne également une vision bancaire tournée vers l'utilité sociale et environnementale. Dès mai 2020, il est le premier groupe bancaire français à se doter officiellement d'une raison d'être, conformément à la loi Pacte de 2019. Cette raison d'être met l'accent sur l'impact environnemental et territorial de ses décisions, l'accompagnement des transitions durables de ses parties prenantes, et la promotion de coopérations locales. En mai 2022, le groupe franchit une nouvelle étape en devenant la première banque française à adopter le statut d'entreprise à mission, intégrant dans ses statuts des objectifs sociaux et environnementaux à long terme.


Aujourd'hui, Crédit Mutuel Arkéa, fort de plus de 5 millions de clients sociétaires, 11 000 collaborateurs, et 2 800 administrateurs, affiche un total de bilan supérieur à 175 milliards d'euros. Il conjugue solidité financière, croissance durable et proximité territoriale, en demeurant l'un des rares établissements bancaires français à conserver l'ensemble de ses centres de décision en région, notamment en Bretagne et en Nouvelle-Aquitaine. Sous la présidence de Julien Carmona depuis mai 2021, accompagné d'Hélène Bernicot, Directrice Générale, le groupe pilote le plan stratégique "Faire 2030". Un plan d'engagement au bénéfice exclusif de l'économie réelle, des territoires et de leurs acteurs avec l'ambition d'être un acteur majeur du développement durable des territoires. En résumé, le Crédit Mutuel Arkéa est bien plus qu'une banque : c'est un acteur engagé du développement économique local, un pionnier de la finance responsable, et un terrain d'apprentissage idéal pour toute personne souhaitant comprendre les enjeux de la donnée dans un monde bancaire en profonde transformation.

B - Présentation de la Direction du Pilotage Financier : DPF

Au sein du Crédit Mutuel Arkéa, six pôles sont structurés au 3 mars 2025, parmi lesquels figure le pôle Support au Développement (Voir annexe 1). Celui-ci intègre notamment la Direction Financière et Performance Globale, composée de six entités, dont la Direction du Pilotage Financier. Cette direction a pour mission principale de contribuer au pilotage des grands équilibres du Groupe afin d'en garantir la pérennité. Elle a pour vocation

de fournir à la Direction Générale un dispositif performant d'analyse et de projection portant sur l'activité, les résultats, la rentabilité, les risques financiers (liquidité et taux), ainsi que la solvabilité du Groupe et de ses différentes entités. Cette mission repose sur l'action coordonnée de six services répartis en trois départements (Voir Figure 1), réunissant une quarantaine de collaborateurs et intégrant également des alternants en phase de découverte des métiers.

Figure 1 : Organigramme de la Direction du Pilotage Financier



sources : Crédit Mutuel Arkéa, Auteur, Canva

La Direction du Pilotage Financier s'inscrit dans une dynamique ambitieuse visant à contribuer durablement à la performance de l'entreprise. Elle agit en faveur d'une rentabilité soutenable, en optimisant les résultats et l'allocation des ressources, tout en mobilisant un haut niveau d'expertise, dans une logique de collaboration et de transversalité. Les travaux d'analyse et de projection sont conduits dans le respect de la raison d'être de l'entreprise et de son statut d'Entreprise à mission. Par ailleurs, un haut niveau de solidité financière est recherché, par la maîtrise des équilibres et la consolidation de la confiance des parties prenantes, condition essentielle de la stabilité du Groupe.

Pour mener à bien ses objectifs, la Direction du Pilotage Financier est organisée en trois départements :


- ❖ Le département de Contrôle de Gestion (CDG),
- ❖ Le département de Gestion de Bilan (GDB),
- ❖ Le département de Modélisation Financière (MOF).

Chacun de ces départements porte des missions spécifiques tout en assurant une coordination étroite et une complémentarité des expertises. Le CDG fournit aux dirigeants des reportings réguliers permettant de suivre les indicateurs de rentabilité, élabore le Plan et les Prévisions (Groupe et globalisés), et pilote l'optimisation des performances. Le GDB veille à la pérennité financière du Groupe par la gestion de ses grands équilibres à moyen-long terme, notamment via la maîtrise des risques de liquidité, de taux, et de solvabilité.

C - Présentation du département modélisation financière (MOF)

Composé de 15 collaborateurs, le département de Modélisation Financière (MOF) constitue un support stratégique essentiel à la Direction du Pilotage Financier. Il s'appuie sur des expertises techniques pointues pour produire une vision fiable, harmonisée et réactive des marges et des indicateurs financiers prévisionnels du Groupe. Sa vocation est d'éclairer les prises de décision à travers des modélisations robustes et des projections économiques de qualité.

Figure 2 : Organigramme du département MOF



sources : Crédit Mutuel Arkéa, Auteur, Canva

Le MOF est organisé en deux services complémentaires : le service Marges et le service Simulations. Chacun développe des expertises spécifiques tout en œuvrant de manière coordonnée pour garantir la cohérence des projections financières du Groupe.

1§ - Service Marges

Le service Marges a pour mission principale de mesurer, analyser et piloter la rentabilité des actifs et passifs du Groupe, tout en assurant le suivi des marges à la fois sur les

volets économique et réglementaire. Il s'appuie sur des outils spécialisés et des modèles avancés pour suivre les comportements clients, évaluer la performance des produits et contribuer à la politique tarifaire du Groupe. Les principales missions du service sont les suivantes :

- ❖ Mesurer, analyser et projeter les marges issues des crédits, des dépôts et plus largement des actifs et passifs du Groupe.
- ❖ Calculer et piloter les Taux de Cession Internes (TCI), véritables leviers de pilotage économique.
- ❖ Assurer la gouvernance de la politique tarifaire Groupe, en lien avec les orientations stratégiques.
- ❖ Maintenir et développer les outils d'analyse de la rentabilité, tels que OMER (outil de mesure de rentabilité des crédits) et les modèles de Valeur Client (Valeur Instantanée, PNB et charges probables actualisées, Coût de Consommation de la Banque).
- ❖ Concevoir et mettre en œuvre des lois de comportements clients, incluant les remboursements anticipés et les renégociations, nécessaires aux impasses de crédits/dépôts (notamment DAT).
- ❖ Challenger, backtester et paramétrer les modèles de projection des taux clients, en veillant à leur intégration optimale dans les outils de simulation comme ARC (Outil de simulation ALM) et OSIRIS (Outil de Simulation des Indicateurs Réglementaires Internes et Stratégiques).
- ❖ Suivre les modèles financiers contribuant à la projection de l'activité, du bilan, des résultats et des principaux ratios du Groupe.

2§ - Service Simulations

Le service Simulations est chargé de la modélisation des comptes prévisionnels du Groupe à des fins budgétaires, prudentielles et réglementaires. Il joue un rôle clé dans la production des scénarios financiers prospectifs, la gestion des outils de simulation et la restitution des résultats auprès des instances internes et externes. Ses principales missions sont les suivantes :

- ❖ Piloter les outils de simulation du Groupe, notamment OSIRIS (compte de résultat, bilan, ratios) et Fusion Risk / ARC pour la simulation ALM.
- ❖ Modéliser les flux prévisionnels tels que la Marge Nette d'Intérêt, les refinancements et replacements, les encours (crédits et dépôts) et les charges (notamment les frais de personnel).

- ❖ Assurer le paramétrage des modèles dynamiques et statiques, notamment ceux liés à la gestion actif-passif.
- ❖ Produire les indicateurs ALM et réglementaires : Stress Tests, ICAAP, C-Templates, Funding Plans, reportings prudentiels, ainsi que les provisions épargne logement (EPALO) et engagements sociaux.
- ❖ Restituer les résultats aux instances concernées, que ce soit en interne (direction du Groupe, CDG, GDB) ou en externe (régulateurs, CNCM).
- ❖ Accompagner les équipes de Contrôle de Gestion et de Gestion de Bilan centralisée et dans chaque entité du groupe dans l'utilisation des outils et l'analyse des projections financières.

Chapitre III - Exposition des missions principales

A - Contexte & Objectif du Stage


Anne Crespy Responsable du Département de la Modélisation Financière est mon tuteur pendant tout le stage, la, même si mes missions étaient intégrées au service Marges. Ainsi, mon stage chez Crédit Mutuel Arkéa s'est réellement effectué au sein d'une équipe avec un alternant, 3 collaborateurs chevronnés et un responsable de service dans le département de Anne Crespy, ma tutrice.

B - Présentation des missions

1§ - Ensembles des missions

L'objectif principal de la mission de mon stage était le rapprochement de deux indicateurs financiers : la valeur instantanée (VI), calculée à partir d'une projection du produit net bancaire, et le coût de consommation de la banque (CCB). Notons que ces indicateurs financiers seront présentés plus en détail dans la partie statistique. De plus, au préalable de la compréhension de cette mission, il est important de préciser que nous avons fait le choix d'une granularité par sous-famille de produits, c'est-à-dire les sous-familles représentées dans les quatre domaines du Crédit Mutuel Arkéa : le Crédit, l'Épargne, le Service et l'Assurance. Ce rapprochement a été réalisé pour l'année 2025.

Figure 3 : Représentation des Sous-familles de produits



sources : Crédit Mutuel Arkéa, Auteur, Canva

Un rapprochement de données consiste à comparer des données, à analyser les écarts et à harmoniser leurs sources afin d'assurer la cohérence et la fiabilité des futures études. L'analyse de ces divergences peut déterminer les causes des erreurs et mettre en œuvre des corrections appropriées, garantissant ainsi l'intégrité des données. En améliorant la qualité des données, ce processus contribue non seulement à une meilleure prise de décision, mais également à la conformité réglementaire et à la transparence des opérations, renforçant ainsi la confiance des parties prenantes dans les informations fournies.

Dans notre cas, un processus de traitement, de gestion et de requêtage des données a été mis en place, complété par la documentation antérieure de ces indicateurs, permettant d'expliquer 100 % des écarts entre les indicateurs. Il est important de noter que l'ensemble des requêtes a été réalisé sous SQL (VI) et PIG (CCB), ce qui a permis de comprendre les différents écarts entre deux sources de données. Dans le but de représenter au mieux une analyse univariée de chaque indicateur, complétée par une analyse bivariée, tout en ayant une partie explicative des différents écarts, OAC (Oracle Analytic Cloud) a été choisi comme l'outil utilisé dans le groupe, ce qui permet entre autres :

- ❖ La mise en lumière d'OAC pour la modélisation financière dans la mise en place potentielle de futurs rapports/reportings.
- ❖ Une datavisualisation impactante avec plusieurs analyses, notamment des drill-downs, complétée par des visualisations réactives et dynamiques.
- ❖ Un ajout de machine learning, avec notamment une clusterisation pour l'analyse phénotypique des sous-familles de produits bancaires.

Cette visualisation a permis de présenter les résultats de ce rapprochement au Directeur du Pilotage Financier, ainsi qu'aux responsables des départements de la gestion de bilan et du contrôle de gestion.

Outre cette mission principale de rapprochement, qui m'a permis de monter en compétences sur de nouveaux logiciels tels que Hadoop, Starburst et OAC, mais également dans la datavisualisation ainsi que dans la gestion et le traitement de données, j'ai pu compléter mon expérience professionnelle avec d'autres tâches. Celles-ci m'ont permis d'améliorer mon aisance à l'oral lors de présentations d'outils et de rapports, ainsi que d'acquérir des compétences plus techniques, telles que la maîtrise du langage Pig et la transposition entre Pig et SQL. Ainsi, j'ai pu participer à des missions telles que :

- ❖ La mission de transcription du code Pig en SQL de manière manuelle, suivie d'une comparaison de l'efficacité de ChatGPT-Arkéa afin de présenter aux services simulations l'efficacité, la rapidité et les avantages de l'utilisation de Starburst (SQL) par rapport à Putty (Pig).
- ❖ La fiabilisation du reporting Rentimo, dans le but d'expliquer et de résoudre quatre points précis dans ce reporting (Seul l'écart entre la durée de vie et la maturité moyenne sera présenté) :
 - La recherche d'une méthodologie d'agrégation plus optimale.
 - La vérification du taux de clients pour les renégociations.
 - La compréhension et l'explication de l'évolution du taux d'actifs pondérés.
 - L'explication et la résolution d'un écart entre la durée de vie moyenne et la maturité moyenne.
- ❖ La présentation d'OAC aux collaborateurs du Département e Modélisation Financière, comprenant une démonstration en temps réel, complétée par un PPT permettant une bonne compréhension de l'outil et de sa gestion, en plus de la documentation déjà existante. L'exemple de prise en main est réalisé sur la base de données exploitée lors du DRiM Game.
- ❖ L'étude de la rentabilité du portefeuille viticole, avec la mise en place d'une méthodologie claire et cohérente pour l'exportation d'indicateurs financiers tels que CCB, VI et TCI pour une liste de clients donnée. Cette méthodologie a été mise en place via Gitlark, le GitHub d'Arkéa.

L'ensemble de ces missions m'a permis non seulement de compléter mes compétences déjà acquises grâce aux différents cours réalisés à l'IAE, mais aussi de découvrir d'autres domaines, tels que la gestion et le traitement de bases de données contenant des milliards de lignes, ainsi que l'importance des règles de sécurité et de fiabilisation, comme la double vérification (un processus de contrôle de qualité de la donnée consistant à faire valider un résultat par deux opérateurs dans le but de garantir la conformité et la fiabilité des résultats), pour l'étude et l'exploitation de données précises destinées aux reportings.

2§ - Mission Rentimo

En complément de la mission de rapprochement entre CCB et VI présentée dans la partie II, 'L'écart entre la durée de vie moyenne d'un contrat et sa maturité moyenne du reporting Rentimmo est à expliquer. Notamment que la durée de vie soit supérieure à la

maturité moyenne, ce qui est impossible. Trois sources potentielles d'écarts pouvaient expliquer cette situation :

- ❖ L'importation des données.
- ❖ La gestion du calcul de la durée de vie moyenne.
- ❖ La gestion du calcul de la maturité moyenne.

Suite à une analyse approfondie, il est apparu que l'importation des données, en particulier de la colonne "DuréeRestante" utilisée pour le calcul de la maturité moyenne, était erronée. Par conséquent, la modification du code Pig était nécessaire pour les reportings futurs. Il convient de noter que cette fiabilisation a été rendue possible grâce à ma maîtrise préalable de RStudio et de Pig, développée lors de mon stage au sein du Crédit Mutuel Arkéa.

C - Gestion du temps

Au cours de mon stage, une organisation rigoureuse du temps a été essentielle pour mener à bien mes missions et assurer un suivi régulier de mes activités. Un emploi du temps structuré, rythmé par différents points hebdomadaires et mensuels, m'a permis de rester aligné avec les objectifs de mon service, de solliciter un accompagnement pertinent et de suivre les évolutions des différents pôles de l'entreprise. Ces rendez-vous réguliers ont constitué des temps forts dans ma semaine, à la fois pour partager mes avancées, lever les points de blocage, et m'inscrire dans une dynamique collective.

Temps forts et rendez-vous récurrents :

- Réunion hebdomadaire d'équipe – Marge

Chaque mardi après-midi, une réunion d'équipe était organisée avec le service Marges. Ce moment d'échange collectif permettait de suivre l'état d'avancement des projets en cours, d'identifier les besoins à venir, et de prendre part à des sessions de réflexion collaborative (type brainstorming). Ces échanges favorisent une vision transversale des enjeux du service et une meilleure coordination entre les membres de l'équipe.

- Point hebdomadaire avec ma tutrice (Anne Crespy)

Tous les lundis après-midi, j'avais un point individuel avec ma tutrice. Ces échanges réguliers me permettaient de faire le bilan de la semaine écoulée, d'aborder les difficultés rencontrées, de poser des questions techniques ou méthodologiques, et de recueillir des conseils pour la suite. Ce suivi personnalisé a grandement facilité mon intégration et ma montée en compétence.

- Réunion mensuelle du département Modélisation financière

Une fois par mois, j'ai participé à une réunion rassemblant l'ensemble des équipes du département Modélisation financière. Ces temps d'échange visaient à partager l'avancement des projets, présenter des initiatives individuelles ou collectives, et faire circuler les bonnes pratiques. Dans ce cadre, j'ai eu l'opportunité de présenter l'outil OAC (Oracle Analytics Cloud) à mes collègues. Cette présentation m'a permis de valoriser une partie concrète de mon travail, en mettant en avant l'ensemble des fonctionnalités de la solution, ainsi que son potentiel d'analyse et de visualisation de données dans un contexte financier. Pour illustrer ces fonctionnalités, j'ai appuyé ma démonstration sur la base de données développée avec mes collègues autour du projet DRiM Games, un cas d'étude portant sur l'analyse du taux de défaillance, en lien direct avec les problématiques du secteur bancaire et financier. Afin de faciliter la prise en main de l'outil par mes collègues, j'ai également conçu une diapositive récapitulative présentant les principales fonctionnalités d'OAC, les étapes de connexion à la base, ainsi que quelques conseils pratiques pour une première utilisation. Ce support visait à rendre l'outil accessible à l'ensemble de l'équipe, même pour ceux peu familiers avec l'environnement Oracle. Enfin, cette présentation a aussi été l'occasion pour moi de partager mon retour d'expérience, en évoquant notamment les difficultés rencontrées au cours du développement de la base de données, ainsi que les solutions apportées. Cela a permis d'initier un échange technique enrichissant avec les autres membres du département et d'alimenter une réflexion collective sur les outils de data visualisation au service de la modélisation financière.

Figure 4 : Diapositives de la présentation d'OAC



Opération détaillée - Code couleur / Fonds / Texte

Pour un classeur spécifique, il est possible d'avoir les chartes graphiques du crédit mutuel Arkéa

Code couleur Arkéa
Cliquez sur les 3 points en haut à gauche du classeur
Sélectionner "thème ARKEA"

Fonds
Cliquez sur les 3 points en haut à gauche du classeur
Propriété de classeur
Source d'image
Importer le fonds désiré

Texte
Glissez-déposez l'onglet "Zone de texte" dans le canevas.
Attention, toutes les fonctionnalités de Google Doc ne sont pas intégrées dans OAC

Opération détaillée - Les analyses

Analyse directement via l'action flux de donnée
Cette méthode plus complexe permet une meilleure gestion des caractéristiques des prévisions ou clustering et un résultat fixe.
De plus, elle permet d'ajouter d'autres méthodes par exemple les régressions linéaires.

Méthodologie pour la prévision des données
Cliquez sur créer
Flux de données
Choisir la base de données
Choisir les colonnes spécifiques pour la prévision
Ajout de l'étape "Entraîner la prévision numérique"
Choix de "Linear Regression for model training"
Choix des caractéristiques spécifiques à la régression et de la colonne à prédire
Enregistrer le modèle puis le RUN

Allez dans la partie Machine learning
→ Résultats:
- DRIVERS
- RESIDUALS
- STATISTICS

sources : Crédit Mutuel Arkéa, Auteur

- Point mensuel Data & Architectures

J'assistais également à une réunion mensuelle dédiée aux avancées en matière de données et d'architecture. Ces points faisaient notamment état de l'évolution des outils groupe et des initiatives transversales en matière de data. Ils permettaient de mieux comprendre l'écosystème technique de l'entreprise et les orientations stratégiques associées.

- Organisation personnelle et télétravail

Enfin, j'étais en télétravail chaque vendredi matin. Cette organisation m'a permis de consacrer cette journée à des tâches nécessitant plus de concentration (analyse, documentation, développement), tout en maintenant un équilibre entre autonomie et interaction avec l'équipe.

Chapitre IV - Bilan

Ce stage au sein du Crédit Mutuel Arkéa a représenté pour moi une expérience formatrice et enrichissante, tant sur le plan professionnel que personnel. Intégré au département de Modélisation Financière, j'ai eu l'opportunité de travailler sur des missions variées, dont la principale portait sur le rapprochement entre la Valeur Instantanée et le Coût de Consommation de la Banque dont je fais une analyse statistique. Ce projet m'a permis d'explorer en profondeur des indicateurs stratégiques, de manipuler des bases de données complexes et d'appliquer des méthodes statistiques avancées, renforçant ainsi mes compétences techniques en SQL, Pig et RStudio. Outre cette mission principale, j'ai également particulièrement apprécié des missions secondaires telles que la mise en place d'un gitlark pour la mise en place d'une méthodologie d'étude de liste de clients particuliers.

Au-delà de l'aspect technique, ce stage m'a également permis de développer des compétences transversales : rigueur dans la gestion et la fiabilisation des données, autonomie dans l'organisation de mes missions, mais aussi la capacité à vulgariser et présenter des résultats auprès d'équipes pluridisciplinaires de manière claire et accessible à tous. La diversité des tâches confiées, qu'il s'agisse de la datavisualisation avec OAC, de la participation à des projets transverses comme Rentimo, ou encore de la présentation d'outils innovants, m'a offert une vision globale du rôle d'analyste financier et statistique dans un grand groupe bancaire.

Ce que j'ai particulièrement apprécié est la richesse des échanges avec les collaborateurs de l'équipe, leur disponibilité et leur volonté de partager leur expertise. Ces interactions régulières m'ont permis de mieux comprendre les enjeux stratégiques du pilotage financier et d'intégrer progressivement la culture d'entreprise d'Arkéa, fondée sur la coopération et l'innovation.

En définitive, cette expérience s'est révélée très positive. Elle a confirmé mon intérêt pour le monde de la data science appliqué à des sujets concrets tels que ceux de la finance, de la banque et de l'assurance. Le stage m'a offert l'opportunité de mettre en pratique mes connaissances théoriques, d'acquérir de nouvelles compétences, et surtout de contribuer à des projets concrets ayant une véritable valeur ajoutée pour l'entreprise.

PARTIE II - RAPPROCHEMENT DU COÛT DE CONSOMMATION DE LA BANQUE ET DE LA VALEUR INSTANTANÉE

Chapitre I - Introduction

Une fois la présentation de l'environnement général, des missions réalisées et de mon bilan chez Arkéa effectuée, passons à l'analyse statistique. Examinons le rapprochement des deux indicateurs : le coût de consommation de la banque et la valeur instantanée, indicateurs qui s'inscrivent dans un projet plus vaste, celui de la valeur client, présenté infra.


Dans un secteur bancaire soumis à une concurrence accrue, à des évolutions réglementaires constantes et à des attentes clients en mutation rapide, la maîtrise de la rentabilité et de la valeur de chaque relation commerciale est devenue un enjeu stratégique majeur. C'est dans ce contexte que le programme Valeur Client a été conçu. Celui-ci doit fournir à l'établissement une vision intégrée et objectivée de la contribution économique de chaque client et de chaque contrat au portefeuille global. Ce dispositif analytique dépasse les approches strictement comptables pour proposer une analyse dynamique, combinant données financières, charges de fonctionnement et contraintes réglementaires, sur l'ensemble du cycle de vie des produits. Il s'appuie sur la consolidation et l'exploitation d'un volume considérable de données contractuelles et transactionnelles, issues des différents domaines d'activité de la banque : épargne, crédits, services et assurances. L'objectif est de permettre aux décideurs de disposer d'indicateurs fiables, mis à jour régulièrement, afin de piloter la stratégie commerciale, d'optimiser les ressources et de renforcer la solidité financière de l'établissement.

Le programme Valeur Client repose principalement sur deux indicateurs complémentaires. Le premier, la Valeur Instantanée (VI), mesure la performance financière projetée des contrats à un instant donné. Le second, le Coût de Consommation de la Banque (CCB), évalue la charge réelle, en frais de gestion et en fonds propres, associée à chaque relation. Ensemble, ils offrent une vision complète de la rentabilité nette, tant en termes de revenus que de coûts. Cette articulation entre la Valeur Instantanée et le Coût de Consommation de la Banque confère au programme Valeur Client une portée stratégique considérable. La VI projette les revenus futurs en intégrant les aléas inhérents à la durée de vie des produits, tandis que le CCB traduit de manière précise les ressources consommées et les obligations prudentielles associées. Ensemble, ces deux indicateurs offrent une vision exhaustive de la performance financière et constituent des leviers puissants pour le pilotage stratégique, la prise de décision commerciale et la gestion optimisée des portefeuilles clients.

A - Présentation de la valeur instantanée (VI)

La Valeur Instantanée représente l'estimation, à un instant T, de la performance économique actualisée d'un contrat ou d'un client, calculée sur l'ensemble des produits détenus, sans prise en compte d'éventuelles souscriptions futures. Elle intègre des hypothèses d'attrition réalistes telles que la résiliation, le remboursement anticipé, la cessation d'activité ou le décès et peut se projeter jusqu'à trente ans pour les produits dépourvus d'échéance définie. Cet indicateur s'appuie sur le Produit Net Bancaire, qui regroupe la marge financière ainsi que l'ensemble des commissions et facturations, qu'elles proviennent du crédit, des comptes, des cartes, des services monétiques, de la gestion d'actifs ou des assurances. Les calculs sont réalisés mensuellement, dans un environnement Big Data, à partir de paramètres actualisés régulièrement et d'une cinquantaine de sources de données. Un processus rigoureux de contrôles de cohérence, de validation des variations significatives et de diffusion via des outils internes de datavisualisation garantit la fiabilité des résultats. La Valeur Instantanée se distingue par sa capacité à fournir une photographie précise de la valeur économique d'un client ou d'un contrat, ventilée par domaine produit. Elle constitue ainsi un outil essentiel pour le pilotage commercial, l'évaluation des performances et l'anticipation des tendances de rentabilité.

Figure 5 : Exemple du processus de création de l'indicateur VI




source : Crédit Mutuel Arkéa

B - Présentation du coût de consommation de la banque (CCB)

En complément de la VI, le Coût de Consommation de la Banque apporte la dimension des charges supportées par l'établissement pour maintenir et gérer ses contrats en fonction du comportement client à consommer du temps "Conseiller". Il s'agit d'un

indicateur de comptabilité analytique produits, qui ventile de manière détaillée les frais de gestion et le coût des fonds propres associés à chaque relation commerciale. Les frais de gestion sont établis à partir des charges réelles des fédérations, ventilées par domaine d'activité, puis affectées en fonction d'un catalogue de processus recensant les actes réalisés par les conseillers. Chaque acte se voit attribuer un temps unitaire, ce qui permet, grâce aux volumes observés (inducteurs), de calculer le coût global de gestion pour chaque produit. Le coût des fonds propres, quant à lui, répond aux exigences réglementaires en matière de couverture des risques, principalement le risque de crédit et le risque opérationnel. Il est déterminé en appliquant un taux réglementaire minimal aux encours pondérés par le risque, et affecté à chaque contrat sur sa durée de vie. La production du CCB suit un cycle annuel qui débute par la collecte des données de l'exercice précédent, se poursuit par les calculs et contrôles nécessaires, puis s'achève par la mise à disposition des résultats aux acteurs concernés. En intégrant à la fois les coûts opérationnels et réglementaires, cet indicateur permet d'obtenir une vision fidèle de la rentabilité nette des contrats.

Figure 6 : Exemple du processus de création de l'indicateur CCB




source : Crédit Mutuel Arkéa

Chapitre II - Méthodologie d'extraction des données

La mise en œuvre de l'analyse comparative entre la Valeur Instantanée (VI) et le Coût de Consommation de la Banque (CCB) repose sur un processus d'extraction et de traitement des données structuré, visant à garantir la fiabilité, la comparabilité et la cohérence des résultats. Cette méthodologie s'articule autour de trois étapes principales : la définition du périmètre d'étude, le requêtage des données dans les environnements techniques dédiés et la gestion des écarts identifiés entre les deux indicateurs, comme représenté dans le schéma ci-dessous.

Figure 7 : Méthodologie du Rapprochement



sources : Rstudio, Auteur

A- Mise en place du Périmètre

Dans le but d'obtenir une étude cohérente, il est primordial de définir un périmètre clair et précis, aussi bien sur le plan géographique que temporel. L'analyse a donc été réalisée sur le périmètre des deux fédérations Crédit Mutuel de Bretagne (CMB) et Crédit Mutuel du Sud-Ouest (CMSO), avec comme date de référence le 31 décembre 2024. L'ensemble des contrats analysés a été classé en sous-familles de produits, elles-mêmes regroupées en familles, puis rattachées à l'un des quatre domaines produits définis : Épargne, Services, Crédits et Assurances.

Les deux indicateurs étudiés ne partagent pas la même temporalité.

- ❖ Le CCB mesure les coûts liés à l'ensemble des actes de gestion réalisés en agence au cours d'une année antérieure.
- ❖ la VI correspond à la somme des produits projetés dans le futur sur l'ensemble de la durée de vie des contrats, pouvant varier de 1 à 360 mois.

Afin de rendre ces données comparables sur une base annuelle, et plus précisément pour l'année 2025, il a été retenu une méthode de conversion consistant à multiplier le Produit Net Bancaire mensuel de décembre 2024 par douze. Cette approche repose sur trois hypothèses : une saisonnalité uniforme, l'absence de variations mensuelles significatives et une relation linéaire dans la répartition des flux. Ce choix méthodologique permet ainsi de ramener les deux indicateurs à une même échelle temporelle.

Au-delà du périmètre géographique, produit et temporel, il convient également de préciser les environnements techniques utilisés pour l'extraction. Les données de VI ont été extraites depuis STARBURST via des requêtes SQL, tandis que les données CCB proviennent de HADOOP et sont traitées en Pig Latin. Les extractions ont été réalisées au format « sous-familles de produits », niveau de granularité jugé le plus pertinent pour garantir la cohérence des analyses tout en conservant un détail suffisant. Les jeux de données obtenus ont ensuite été rapprochés dans Excel grâce à des clés de jointure permettant de lier de manière unique les lignes communes, ce qui a facilité leur exploitation ultérieure dans l'outil de visualisation OAC.

B - Requêtage des données

L'objectif du requêtage était de produire des agrégations par catégorie, par code sous-famille de produit (Cdsfam) et par fédération (noctrctl), afin d'obtenir pour chaque périmètre la somme des indicateurs correspondants.

Dans l'environnement STARBURST, des requêtes SQL ont été développées pour distinguer trois populations de contrats :


- ❖ Ceux communs aux deux indicateurs VI et CCB.
- ❖ Ceux présents uniquement dans la base VI.
- ❖ Ceux présents uniquement dans la base CCB.

Cette étape a permis d'identifier rapidement les divergences de périmètre entre les deux sources. Du côté HADOOP, des scripts en Pig Latin ont été rédigés pour extraire les données CCB à partir des volumes d'inducteurs et des frais de gestion associés. L'utilisation simultanée de ces deux environnements distincts a nécessité un important travail de correspondance des référentiels, afin de garantir que les agrégations issues de chaque système puissent être comparées directement et sans biais méthodologique.

C - Gestion des écarts

Une fois les extractions réalisées, un travail d'analyse a été mené afin de comprendre et d'expliquer les écarts entre les deux indicateurs. Pour ce faire, un arbre d'analyse a été construit, permettant de représenter de manière visuelle et logique la répartition des contrats et les causes potentielles d'écarts.

Figure 8 : Arbre d'Analyse



sources : Canva, Auteur

La figure 8 met en évidence qu'au 31 décembre 2024, seulement 0,3 % des contrats se retrouvent simultanément dans les deux indicateurs, VI et CCB. Bien que cette intersection représente plusieurs millions de contrats, elle reste très minoritaire au regard de l'ensemble du portefeuille et fera l'objet d'une analyse complémentaire, distincte de celle menée sur la globalité des contrats. La majorité des contrats n'apparaît pas dans les deux indicateurs en même temps. Certains sont absents de la VI, souvent en raison de leur nature ou de leur périmètre fonctionnel, tandis que d'autres sont absents du CCB, par exemple à cause de limites dans la collecte des actes de gestion ou de règles spécifiques d'affectation des coûts.

L'arbre d'analyse a permis, grâce à un processus de filtrage successif, d'identifier et de classer les causes possibles de ces écarts : différences de périmètre produit, exclusions

liées à des règles métiers propres à chaque indicateur, anomalies ponctuelles dans les données sources ou encore décalages temporels dans la prise en compte des contrats. En exploitant la documentation disponible dans l'outil interne VIconfluence, il a été possible de rapprocher certains cas spécifiques. Ainsi :

- ❖ 0,45 % des contrats présents uniquement dans le CCB (sans équivalent dans la VI) s'expliquent par :
 - Un contrat clôturé ou totalement racheté.
 - Un contrat souscrit puis clôturé ou racheté dans l'année.
 - Un contrat à souscription différée, dont le PNB ne débute qu'à partir de t+1 ou t+2.
 - Un contrat à effet court, dont la date de début et de fin est inférieure à un mois.
- ❖ 99,24 % des contrats présents uniquement dans la VI (absents du CCB) s'expliquent par :
 - L'absence d'acte de gestion au 31/12/2024, mais la présence d'un acte ultérieur.
 - Une présence dans la base de rejets CCB (rejet non bloquant).
 - L'absence de numéro de contrat catalogue (noctctl), remplacé par un code cdttar.
 - L'absence totale d'acte de gestion en agence sur la période 2024.

Ce déséquilibre entre le nombre de contrats pris en compte dans la VI et dans le CCB s'explique par la différence même de nature des indicateurs : la VI est calculée sur l'ensemble des contrats en portefeuille, alors que le CCB ne prend en compte que ceux ayant fait l'objet d'un acte de gestion en agence au cours de l'année. Ainsi, la VI se rapproche davantage d'un indicateur historique de l'ensemble des contrats, tandis que le CCB se limite à un périmètre opérationnel, excluant notamment les contrats n'ayant connu aucun acte en agence ou dont la gestion s'est faite exclusivement en ligne. Ainsi, ce travail d'analyse a permis d'expliquer 100 % des écarts observés entre les deux bases, assurant ainsi la robustesse et la fiabilité des conclusions issues de cette comparaison.

Chapitre III - Analyse statistique

Une fois la méthodologie présentée, notamment la gestion des écarts, passons à l'analyse statistique, c'est-à-dire au rapprochement entre VI et CCB. Pour des raisons de confidentialité et à la demande de ma tutrice Anne Crespy, une partie de la base de données a été tronquée et certaines colonnes, telles que le nombre de contrats, le PNBA et le CCB, ont été modifiées à l'aide de valeurs aléatoires générées dans Excel. De ce fait, la base de données est fictive et certaines analyses peuvent sembler contre-intuitives. Enfin, pour certaines visualisations, les données ont été standardisées ou normalisées, ce qui permet de placer toutes les variables sur une échelle commune, d'éviter qu'une variable aux valeurs naturellement plus élevées ne domine l'analyse, de faciliter la comparaison entre indicateurs et d'améliorer la lisibilité des graphiques.

A - Objectif du Reporting

L'objectif poursuivi est de parvenir à une meilleure compréhension des indicateurs étudiés, tant de manière isolée que lors de leur rapprochement, et de mettre en évidence, grâce à une approche de type clusterisation, les sous-familles de produits présentant les plus fortes potentialités d'optimisation. L'ensemble de ce travail est intégré dans un outil interactif et réactif, qui offre une visualisation claire des données et une interprétation concise, adaptée au contexte assurantiel et bancaire.

Il convient toutefois de rappeler que ce dispositif n'a pas pour finalité d'évaluer la marge dégagée par les différentes sous-familles de produits, mais bien de fournir un outil d'analyse et de visualisation de la performance.

B - Etude statistique

Afin de garantir la rigueur de la démarche, l'étude s'articule autour d'un plan méthodologique précis. Elle débute par l'analyse des statistiques descriptives relatives aux deux indicateurs, puis s'attarde successivement sur l'étude univariée et bivariée, avant d'examiner les résultats issus de la clusterisation. La présentation finale des observations prend la forme d'une data-visualisation réalisée sous OAC.

1§ - Statistiques descriptives

Avant toute analyse approfondie, il est nécessaire d'étudier la distribution des indicateurs afin d'en comprendre les principales caractéristiques statistiques. L'examen de la kurtosis et de la skewness constitue à ce titre une étape essentielle.

Tableau 1 : Statistique de distribution

Indicateurs	Contrats Totaux				Contrats Commun			
	PNB		CCB		PNB		CCB	
	Résultat	interprétation	Résultat	interprétation	Résultat	interprétation	Résultat	interprétation
Kurtosis	1059	LPK	387	LPK	110	LPK	211	LPK
Skewness	28	ASD	18	ASD	10	ASD	13	ASD

sources : Rstudio, Annexe 2, Auteur

Les résultats du Tableau 1 montrent que, quel que soit l'échantillon considéré (l'ensemble des contrats ou la seule population des contrats communs représentant 0,3 % du total) les conclusions sont similaires. Les distributions observées se révèlent leptokurtiques et présentent une asymétrie positive, c'est-à-dire orientée vers la droite. Ce type de configuration traduit la présence plus fréquente de valeurs extrêmes que dans une distribution gaussienne. L'asymétrie à droite indique par ailleurs que la moyenne est systématiquement supérieure à la médiane, les valeurs extrêmes tirant celle-ci vers le haut.

Tableau 2 : Statistique descriptives

Indicateurs	Contrats Totaux		Contrats Commun	
	PNB	CCB	PNB	CCB
Min	-46.27.10 ⁵	0.00	-105 613.14	0.00
Q1	1.37	66.50	0.00	47.61
Médiane	156.06	307.06	37.91	3 76.58
Moyenne	52 675.56	4 731.55	11 534	11 247.80
Q3	2 957.00	1 862.49	992.40	3 176.2
Max	23.46.10 ⁶	297 840.42	21.1910 ⁵	977 798.90
Ecart-type	570 823.90	20 567.64	95 025.37	55 994.98

Variance	$32.58.10^{10}$	$90.29.10^8$	90.2910^8	$31.35.10^8$
----------	-----------------	--------------	-------------	--------------

sources : Rstudio, Annexe 3, Auteur

L'analyse des statistiques descriptives confirme cette tendance. La moyenne se révèle nettement plus élevée que la médiane, ce qui témoigne d'une forte présence de valeurs atypiques, tant pour le PNB que pour le CCB. La dispersion des données est particulièrement marquée, comme l'attestent les écarts-types élevés, en particulier pour le PNB (570 823,90). Cette amplitude importante traduit la concentration d'une part significative de la valeur dans certaines sous-familles de produits.

Ce constat demeure cohérent dans le contexte bancaire, où il n'est pas rare que certains clients disposent de volumes financiers très supérieurs à la moyenne. Ainsi, même si la distribution est marquée par des valeurs extrêmes, leur suppression ou leur correction n'est pas nécessaire. Ces observations reflètent en effet une réalité inhérente au domaine étudié et apportent un éclairage pertinent pour la compréhension des phénomènes analysés.

Tableau 3 : Statistique de corrélation

Variables	Contrats Totaux		Contrats Commun	
	PNB	CCB	PNB	CCB
PNB	1	-0.01	1	0.24
CCB	-0.01	1	0.24	1

sources : Rstudio, Annexe 4 à 5, Auteur

L'étude des corrélations met en évidence deux situations distinctes. Lorsqu'on considère l'ensemble des contrats, la corrélation entre le PNB et le CCB est quasiment nulle, de l'ordre de -0,01, ce qui traduit l'absence de relation significative entre les deux variables. Une hausse de l'un semble donc s'accompagner d'une très légère baisse de l'autre. En revanche, lorsqu'on restreint l'analyse aux contrats communs, soit 0,3 % de l'échantillon, la corrélation devient positive et atteint 0,24. Dans ce cas, une augmentation du PNB s'accompagne d'une hausse du CCB, ce qui paraît davantage cohérent. En effet, l'accroissement du produit net bancaire peut découler de la signature de nouveaux contrats, lesquels entraînent logiquement une augmentation des charges correspondantes, qu'elles soient liées à la distribution en agence ou à d'autres canaux.

La corrélation quasi nulle observée sur la base complète s'explique probablement par les traitements appliqués à la base de données dans le cadre de son anonymisation, ce qui limite en partie la portée interprétative de ce résultat.

En définitive, l'étude descriptive des données met en lumière la forte hétérogénéité de la distribution des indicateurs, caractérisée par la présence marquée de valeurs extrêmes, une moyenne systématiquement supérieure à la médiane et une dispersion très élevée. Ces résultats traduisent une structure de données conforme aux spécificités du secteur bancaire, où coexistent de faibles et de très grands volumes financiers. La corrélation entre PNB et CCB, faible sur l'ensemble des contrats mais positive et significative sur l'échantillon restreint des contrats communs, illustre également la complexité des relations entre ces deux indicateurs.


Ces constats préliminaires constituent une base solide pour approfondir l'analyse. Dans la section suivante, examinons plus en détail chaque indicateur séparément à travers une analyse univariée, afin d'identifier leurs dynamiques propres avant de les confronter dans une approche bivariée.

2§ -Analyse univariées

Dans cette section, il convient de préciser que les analyses univariées sont réalisées sur l'ensemble de la base de données, l'étude se réfère aux quatre domaines d'activités : l'épargne, le crédit, les services et l'assurance.

a - Produit Net Bancaire


Graphique 1 : Histogramme du Produit Net Bancaire par domaine d'activité



sources : OAC, Auteur

L'analyse du graphique 1 met en évidence que le domaine de l'épargne constitue le principal contributeur au Produit Net Bancaire (PNB) annuel du groupe Crédit Mutuel Arkéa, avec environ 72 millions d'euros. À l'opposé, le domaine du crédit affiche une performance négative, avec un PNB de -5 millions d'euros, ce qui en fait le secteur le moins performant. Les deux autres domaines, l'assurance et les services, présentent quant à eux des résultats intermédiaires, respectivement autour de 24 millions et 40 millions d'euros. Ce graphique offre une vision d'ensemble des différents domaines. Toutefois, l'étude des sous-familles de produits permet d'affiner l'analyse et de mieux comprendre l'hétérogénéité ou l'homogénéité de chaque domaine, d'où l'intérêt de recourir à des représentations plus détaillées comme les boîtes à moustaches. Notons que, pour des raisons de lisibilité, les noms des sous-familles ne figurent pas directement sur le graphique, mais sont bien intégrés dans la data-visualisation, renforçant ainsi la valeur ajoutée de l'approche visuelle. Enfin, il est important de souligner que la majeure partie du PNB est portée par le Crédit Mutuel de Bretagne (CMB).

Graphique 2 : Répartition des sous-familles de produit par domaine d'activité et Produit Net Bancaire standardisé




sources : OAC, Auteur

Les boîtes à moustaches du graphique 2 montrent que la majorité des sous-familles de produits se situent en dehors des boîtes et peuvent donc être considérées comme des valeurs atypiques. Certains produits, tous domaines confondus, se trouvent en dessous de la moyenne, notamment dans le crédit, tandis que d'autres affichent une nette surperformance, comme le produit au PNBA extrême dans le domaine de l'épargne. Cette représentation illustre des données standardisées : un point supérieur à 0 indique qu'une sous-famille a une moyenne plus élevée que celle de l'ensemble de la base. Si l'on exclut les valeurs atypiques, on constate que la majorité des domaines ont une moyenne inférieure à la moyenne globale.

On peut donc conclure que c'est le domaine de l'épargne qui tire cette moyenne vers le haut et constitue le principal moteur du PNB.

Graphique 3 : Distribution des sous-familles de produit en fonction du Produit Net Bancaire et du nombre de contrat



sources : OAC, Auteur

Afin d'analyser plus finement la distribution des sous-familles et de mieux cerner les objectifs stratégiques du Crédit Mutuel Arkéa, celles-ci sont réparties en fonction de leur PNB et de leur nombre de contrats. Cette classification permet de définir quatre cadrans de performance :

- Cadran I ($X > \text{médiane contrats} \ \& \ \text{médiane PNB}$) : Sous-familles à potentiel à exploiter.
- Cadran II ($\text{médiane PNB} < X < \text{médiane contrats}$) : Sous-familles en performance optimale.
- Cadran III ($X < \text{médiane contrats} \ \& \ X < \text{médiane PNB}$) : Offres d'appel.
- Cadran IV ($\text{médiane contrats} < X < \text{médiane PNB}$) : Sous-familles à risque.


Une tendance linéaire se dessine : plus le PNB est élevé, plus le nombre de contrats l'est également. Toutefois, pour optimiser sa stratégie, la banque devrait viser à positionner ses sous-familles dans le cadran II, où un nombre limité de contrats génère un PNB optimal. Cette répartition confirme également la pertinence de la loi de Pareto (20/80)² appliquée au PNB : environ 20 % des sous-familles concentrent près de 80 % de la valeur créée, soulignant ainsi l'importance d'identifier et de renforcer ces leviers stratégiques.

² Lenfant, Jean-Sébastien. "La loi de Pareto: entre équilibre social et équilibre économique." *Economies et Sociétés. CEconomia, série PE* 31.11-12 (2001): 1591-1625.

b - Coût de Consommation de la Banque

Une fois le Produit Net Bancaire Annuel analysé, nous pouvons dès lors passer à l'analyse du Coût de Consommation de la Banque.


Graphique 4 : Histogramme du Coût de Consommation de la Banque par domaine d'activité



sources : OAC, Auteur

Le graphique 4 présente la répartition du Coût de Consommation de la Banque (CCB) par domaine d'activité et par fédération (CMB et CMSO). On constate que les services représentent la charge la plus importante, avec un CCB total supérieur à 1,3 million d'euros, dont près de 1 million imputé au CMB et environ 338 000 euros pour le CMSO. Le domaine du crédit constitue également un poste de dépense significatif avec un CCB global de 1,1 million d'euros (783 k CMB et 350 k CMSO). L'assurance, un domaine moins coûteux, dépasse tout de même les 730 000 euros. Enfin, l'épargne affiche un coût quasi nul comparé aux autres domaines. Ces résultats traduisent une structure des coûts hétérogène selon les activités : certaines (comme les services et le crédit) concentrent une part prépondérante des charges, tandis que d'autres (l'épargne) demeurent marginales. Cela reflète probablement la nature opérationnelle et technique des services et crédits, plus gourmands en ressources de gestion.


Graphique 5 : Répartition des sous-familles de produit par domaine d'activité et Coût de Consommation de la Banque



sources : OAC, Auteur

Les boîtes à moustaches du graphique 5 illustrent la distribution du CCB unitaire standardisé selon les domaines d'activité. Le crédit présente une dispersion extrêmement élevée, suggérant que certaines sous-familles de produits engendrent des coûts bien supérieurs à la moyenne. L'assurance et l'épargne se caractérisent par des distributions relativement homogènes, bien que l'assurance révèle quelques points atypiques à coût très élevé (ex. : adhésion contrats, maintenance matériel). Enfin, le domaine des services se situe globalement en dessous de la moyenne globale, mais montre également plusieurs sous-familles atypiques avec des coûts nettement plus élevés. Ces résultats soulignent que la répartition des coûts n'est pas équilibrée : certaines sous-familles pèsent beaucoup plus que d'autres, renforçant l'hypothèse d'une concentration des charges sur un nombre limité de produits.

Graphique 6 : Distribution des sous-familles de produit en fonction du Coût de Consommation de la Banque et du nombre de contrat



sources : OAC, Auteur

Enfin, Le nuage de points met en évidence la relation entre le nombre de contrats et le CCB associé. Une tendance croissante apparaît : plus une sous-famille génère de contrats, plus le CCB augmente. Cette relation, bien qu'attendue, n'est pas parfaitement linéaire : certaines sous-familles, avec un nombre relativement faible de contrats, affichent néanmoins des coûts très élevés, traduisant une inefficience potentielle. Ce type de distribution illustre une dynamique proche de la loi de Pareto (20/80) : une minorité de sous-familles concentre la majorité des coûts. En d'autres termes, environ 20 % des contrats génèrent près de 80 % du CCB.

L'ensemble des analyses met en évidence une forte hétérogénéité des performances et des charges entre les différents domaines d'activité du Crédit Mutuel Arkéa. Le PNB est largement porté par l'épargne, qui constitue le moteur principal de la rentabilité, tandis que le crédit reste une activité déficitaire. Le CCB, quant à lui, est concentré sur les services et le crédit, traduisant une intensité opérationnelle et technique élevée. Dans les deux cas, la loi de Pareto se vérifie : une minorité de sous-familles concentre l'essentiel des revenus comme des coûts, ce qui plaide pour une stratégie sélective visant à renforcer les produits les plus rentables tout en rationalisant les plus coûteux. Ainsi, une allocation optimale des ressources permettrait à la banque de consolider ses points forts (épargne, assurance performante) tout en maîtrisant ses zones de fragilité (crédit déficitaire, services coûteux).


3§ - Analyse bivariées

Nous faisons le choix d'analyser uniquement les résultats obtenus à partir de la base de données intégrant l'ensemble des informations, et non pas exclusivement les 0,3 % de contrats en commun. L'analyse étant similaire dans les deux cas, les résultats spécifiques à la base « contrats en commun » sont consultables directement dans la partie « Résultats » de la datavisualisation, afin d'offrir une vision complémentaire et figée. De plus, il est important de rappeler que le calcul de la performance repose sur la formule suivante :

$$\textit{Produit Net Bancaire} - \textit{Coût de Consommation de la Banque} = \textit{Performance}$$

Graphique 7 : Histogramme de la performance par domaine

Histogramme de la performance par fédération
Performance globale total
141M




sources : OAC, Auteur

L'examen du graphique 7 permet d'appréhender de manière globale les performances par domaine, en tenant compte conjointement du produit net bancaire et des coûts de consommation de la banque. Le produit net bancaire atteint à lui seul environ 140 millions d'euros, contre seulement 4 millions d'euros de frais de gestion dans notre exemple. Dès lors, la structure de l'histogramme reste relativement similaire à celle obtenue lors de l'analyse univariée du PNB. On constate que le domaine de l'épargne concentre à lui seul la majorité du produit net bancaire, suivi par les domaines des services et de l'assurance. À l'inverse, le crédit affiche une performance négative. Cette vision agrégée souligne la nécessité d'une analyse plus fine, intra-domaine, afin de mieux comprendre l'hétérogénéité des performances. Enfin, il apparaît que le CMB représente à lui seul plus de 80 % de la performance globale du Crédit Mutuel Arkéa.

Graphique 8 : Distribution des familles de produit en fonction de leurs produit net bancaire moyen standardisé et de leurs coût de consommation de la banque moyen standardisé

Répartition des Familles de produits
Produit net bancaire moyen : 39k
Coût de consommation de la banque moyen : 892




sources : OAC, Auteur

Le graphique 8, illustrant la distribution des sous-familles de produits, permet de distinguer clairement les contrats surperformants des contrats sous-performants. La majorité des familles de produits se situent en dessous de la moyenne, à l'exception d'une dizaine. Parmi celles-ci, quatre familles se démarquent particulièrement par leurs caractéristiques : un PNB supérieur à la moyenne et un CCB inférieur à la moyenne. Ces familles sont : l'assurance vie, la part sociale, l'épargne immobilière et le bancaire. Il est intéressant de noter que l'ensemble de ces exemples appartiennent au domaine de l'épargne (voir Annexe 6). Par ailleurs, la famille supportant les frais de gestion les plus élevés est la monétique. Dans l'ensemble, la majorité des familles de produits se situent dans le cadran III, caractérisé par un CCB et un PNB inférieurs à la moyenne globale.

Zoom sur le domaine de l'épargne

Nous choisissons d'approfondir spécifiquement le domaine de l'épargne, étant donné que les constats restent similaires pour les quatre domaines étudiés.

Graphique 9 : Classification des sous-familles les plus performantes pour le domaine de l'épargne



sources : OAC, Auteur

Ce graphique met en évidence les neuf sous-familles de produits les plus performantes du domaine de l'épargne. Parmi elles, une sous-famille se distingue nettement : le compte de chèques, qui contribue de manière prépondérante aux résultats du domaine. Elle est suivie par quatre autres familles de produits ayant une contribution intermédiaire mais significative : le livret bleu, Navig Option, les parts sociales B et Prév'Option. Enfin, les quatre sous-familles restantes n'apportent qu'une contribution marginale aux résultats globaux. Cette répartition illustre une nouvelle fois l'hétérogénéité intra-domaine, où certaines familles de produits

jouent un rôle moteur, tandis que d'autres ont un poids négligeable, voire contraignent la performance globale du domaine.

L'analyse bivariée nous a permis de mettre en évidence l'hétérogénéité des performances entre et au sein des différents domaines d'activité. Nous constatons que l'épargne constitue le principal moteur du produit net bancaire, mais que cette dynamique repose essentiellement sur un nombre restreint de sous-familles, tandis que la majorité des autres produits affichent des résultats inférieurs à la moyenne. Afin d'approfondir cette compréhension, il apparaît pertinent de s'interroger sur l'existence de profils de familles de produits similaires, indépendamment de leur domaine d'appartenance. Pour cela, une approche par classification sera mobilisée, permettant de regrouper les familles de produits en clusters homogènes et d'identifier d'éventuelles proximités structurelles dans leurs performances et leur coût de consommation bancaire.

4§ - Clusterisation

Dans le but de mieux comprendre les différents phénotypes des sous-familles de produit, nous avons choisi d'appliquer une méthode de clusterisation. La clusterisation, ou classification non supervisée, est une technique de machine learning qui consiste à regrouper des individus (ici les sous-familles de produits bancaires) en classes homogènes appelées clusters. Contrairement à une approche supervisée, elle ne repose pas sur une variable cible connue à l'avance, mais identifie de manière autonome des regroupements naturels dans les données. Cette approche permet de faire émerger des profils types et de révéler des différences structurelles au sein d'un portefeuille de produits³.

Dans le cadre de notre analyse, nous avons utilisé deux approches complémentaires :


- ❖ La première repose sur OAC, qui permet une clusterisation rapide et dynamique. Cette approche ne retient que deux variables principales : le Coût de Consommation Bancaire (CCB) et le Produit Net Bancaire (PNB). Le choix de ces deux indicateurs rend la visualisation plus intuitive et offre une mise à jour automatique de la segmentation à chaque évolution de la base de données. Cette méthode constitue donc une première lecture, synthétique mais utile pour identifier des tendances globales.

³ Khalid, Sara, and Daniel Prieto-Alhambra. "Machine learning for feature selection and cluster analysis in drug utilisation research." *Current Epidemiology Reports* 6.3 (2019): 364-372.

- ❖ La seconde approche a été réalisée sous RStudio, avec une méthode plus détaillée et multidimensionnelle. En effet, cette fois-ci un ensemble élargi de variables est pris en considération. Or, traiter simultanément un grand nombre de variables peut rendre l'analyse complexe et peu lisible. C'est pourquoi nous avons recours à l'Analyse en Composantes Principales (ACP), une méthode statistique de réduction de dimensionnalité. L'ACP consiste à transformer les variables initiales en un nombre réduit de nouvelles variables (les composantes principales), qui sont des combinaisons linéaires des variables de départ et qui conservent la majorité de l'information contenue dans les données. Cette étape permet d'éviter la redondance, de réduire le bruit, et d'améliorer l'interprétation avant d'appliquer la clusterisation.

a - Clusterisation Via OAC

Graphique 10 : Clusterisation des sous-familles de produit



sources : OAC, Auteur

L'analyse de la clusterisation des sous-familles de produit met en évidence plusieurs tendances claires. La majorité des individus se concentrent dans un cluster central, que nous pouvons appeler le groupe pivot. Ce groupe regroupe des sous-familles caractérisées par un produit net bancaire inférieur à 5 millions et un coût de consommation bancaire inférieur à 100 000. Il représente ainsi la base moyenne du portefeuille, avec des produits plutôt homogènes. En contraste, un premier sous-ensemble rassemble des produits plus performants. Le premier cas concerne un cluster regroupant principalement des produits d'épargne, qui présentent un produit net bancaire compris entre 5 et 33 millions tout en


conservant des coûts de consommation faibles. Ces produits apparaissent donc comme des leviers de rentabilité particulièrement intéressants. Dans la continuité, un autre cluster, constitué uniquement de la sous-famille des comptes chèques, présente une situation atypique : un produit net bancaire particulièrement élevé pour un coût quasi nul. Cette singularité illustre un phénomène de surperformance, qui distingue ce groupe. À l'opposé, un second sous-ensemble regroupe les sous-familles les moins performantes. Il inclut d'une part un cluster composé de nombreuses sous-familles affichant à la fois un produit net bancaire faible (inférieur à 5 millions) et des coûts de consommation élevés (supérieurs à 200 000). D'autre part, un petit cluster spécifique constitué uniquement de deux sous-familles (la cotisation accès débit immédiat et l'assurance emprunteur amortissable) se distingue également par une rentabilité limitée associée à des coûts élevés.

b - Clusterisation Via Rstudio

Avant de procéder à la clusterisation avec l'algorithme K-means sous RStudio, il est essentiel d'analyser l'Analyse en Composantes Principales (ACP)⁴ réalisée sur notre jeu de données. En effet, cette étape préliminaire permet de réduire la dimensionnalité de l'information, tout en tenant compte non seulement des indicateurs classiques, mais aussi du nombre de contrats ainsi que du PNB et du CCB unitaires. L'ACP agit ainsi comme un filtre, permettant de condenser l'information en un nombre restreint de dimensions tout en limitant la perte d'information.

⁴ Guerrien, Marc. "L'intérêt de l'analyse en composantes principales (ACP) pour la recherche en sciences sociales. Présentation à partir d'une étude sur le Mexique." *Cahiers des Amériques latines* 43 (2003): 181-192.


Graphique 11 : Histogramme des valeurs propres



sources : Rstudio, Auteur

L'examen de l'histogramme des valeurs propres (graphique 11) montre que les deux premières dimensions expliquent respectivement 31,8 % et 22,4 % de la variance totale, soit un cumul de 54,2 %. En analyse factorielle, cette part de variance expliquée est appelée inertie. L'inertie représente la proportion de la variabilité des données initiales qui est restituée par les axes factoriels. Autrement dit, plus l'inertie cumulée est élevée, plus la projection en dimensions réduites reflète fidèlement la structure réelle des données. Ici, la conservation de deux axes permet de capturer plus de la moitié de l'information contenue dans le jeu de données, ce qui est satisfaisant pour simplifier l'analyse sans trop perdre en précision. L'ajout d'une troisième dimension, bien que statistiquement pertinent, alourdirait inutilement la lecture et la visualisation, d'où le choix méthodologique de retenir uniquement les deux premières dimensions.

Graphique 12 : Analyse en Composante Principale




sources : Rstudio, Auteur

L'analyse du cercle des corrélations (graphique 12) précise la contribution des variables. Deux phénomènes majeurs sont observés. Premièrement, les variables liées au nombre de contrats, qu'il s'agisse du PNB ou du CCB, se situent près du barycentre et présentent de faibles $\cos^2$ (< 0.5) signifiant qu'elles ne discriminent pas fortement les individus dans l'espace factoriel. Deuxièmement, les variables PNB et PNB unitaire se projettent fortement et positivement sur la dimension 1, tandis que le CCB et le CCB unitaire se regroupent sur la dimension 2. Ce positionnement traduit une opposition logique : la première dimension représente essentiellement la performance via le produit net bancaire, alors que la seconde illustre une orientation vers le coût de consommation bancaire. Le fait que certaines variables se dirigent dans le même sens (par exemple, PNB et PNB unitaire) traduit une forte corrélation positive entre elles, ce qui signifie que lorsque l'une augmente, l'autre a tendance à augmenter également. À l'inverse, des variables projetées en sens opposés sur un même axe traduisent une corrélation négative, marquant des comportements divergents entre elles. Enfin, plus une variable est proche du cercle, plus sa contribution à la structuration des axes est forte, alors qu'une position centrale indique une influence limitée. L'ACP permet ainsi de synthétiser la complexité du jeu de données en deux axes interprétables : la rentabilité (axe 1) et le coût (axe 2).

Une fois l'ACP réalisée, la clusterisation des individus sur les deux premières dimensions révèle cinq groupes distincts (graphique 13). Le cluster 2 domine largement avec 97,4 % des individus, traduisant un profil standard et homogène correspondant à la majorité des clients. À l'inverse, les clusters 3, 4 et 5 regroupent des profils atypiques : le cluster 3 est marqué par un PNB global négatif mais un CCB unitaire élevé, ce qui traduit un portefeuille réduit en volume mais concentré sur des contrats de forte valeur unitaire. Les clusters 4 et 5 se caractérisent par des valeurs extrêmement élevées de PNB et de CCB, confirmant leur statut de groupes extrêmes et stratégiques. Enfin, le cluster 1, quasi inexistant (un seul individu), s'apparente davantage à un outlier qu'à un groupe significatif.

Graphique 13 : Projection et classification des individus sur les dimensions 1 et 2



sources : Rstudio, Auteur

Les tableaux de synthèse confirment ces interprétations. Le tableau des centroïdes et individus représentatifs illustre la typologie de chaque cluster, tandis que le tableau détaillé des variables permet de mieux cerner leurs profils financiers. Ainsi, le cluster 2 représente le portefeuille moyen avec des valeurs modérées de PNB et de CCB, tandis que les clusters marginaux concentrent des comportements atypiques soit par excès de rentabilité, soit par structure de coûts singulière.

Tableau 4 : Profils des centroïdes & Individus les plus représentatif

Cluster	Dimension				Individus les plus représentatifs	Effectif par cluster
	Dim 1	Dim 2	Dim 3	Dim 4		
1	- 0.440	1.18	56.5	5.53	03-PART-E065-NA	1 (< 1%)
2	- 0.104	- 0.0246	- 0.003	- 0.0129	03-PRO-C075-00430D 03-PRO-S040-10452 03-PRO-E029-506	3549 (97.40%)
3	2.33	- 1.35	- 0.573	5.67	03-PRO-S069-10813 01-PRO-C054-10255 03-PRO-S070-108060	74 (2.1%)
4	3.27	13.6	- 0.488	1.37	01-PART-A001-10201 01-PART-E072-74006 01-PART-S026-30000	15 (0.41%)
5	29.5	- 3.41	0.800	- 5.92	03-PART-S010-10497 01-PART-A016-10098 01-PART-C003-10098	5 (0.14%)
Total :						3644 (100%)

sources : Rstudio, Annexe 7 à 9, Auteur

Le Tableau 5 apporte un éclairage précis sur les profils détaillés par cluster. Il montre que le cluster 2, majoritaire, se caractérise par un PNB unitaire modéré (76) et un nombre de contrats significatif (1 537), ce qui illustre un portefeuille équilibré. En revanche, le cluster 3 affiche un PNB global négatif (-82 957) mais un CCB élevé (12 954), soulignant un déséquilibre entre la rentabilité et le coût des contrats. Le cluster 4 se démarque par un PNB exceptionnellement élevé (4 042 713) et un CCB de 199 342, confirmant qu'il regroupe des clients à forte valeur stratégique. Quant au cluster 5, bien que très minoritaire, il présente également des valeurs extrêmes, avec un PNB unitaire de 28 800 et un CCB de 221, renforçant son profil atypique. Le cluster 1, pour sa part, reste négligeable au vu de sa taille et de ses valeurs singulières.

Tableau 5 : Profils détaillés des variables par cluster

Cluster	PNB			CCB		
	PNB	PNB Unitaire	Nbr contrat	CCB	CCB Unitaire	Nbr contrat
1	182 008	182 008	1	0	0	0
2	25 120	76	1 537	355	12	4
3	- 82 957	17	807	12 954	999	16
4	4 042 713	41	169 772	7 197	26	88
5	15 239	28	300	199 342	221	1 381

sources : Rstudio, Annexe 9, Auteur

En résumé, l'ACP a permis de condenser plus de la moitié de la variance des données en deux axes clairement interprétables, facilitant ainsi la lecture de la structure interne des individus. La clusterisation K-means, construite sur cette base, révèle une organisation hiérarchique dominée par un grand cluster central et des groupes périphériques atypiques, souvent associés à des valeurs extrêmes de PNB et de CCB. Cette segmentation met en lumière la coexistence de profils standards et de niches stratégiques, et fournit un cadre opérationnel pour orienter des stratégies différenciées. Les clusters majoritaires peuvent faire l'objet d'offres standardisées, tandis que les clusters atypiques, bien qu'isolés, représentent un enjeu important pour la gestion du risque, la rentabilité et la personnalisation de l'approche commerciale.

C - Résultat de la data-visualisation

Cette démarche vise à approfondir l'analyse des indicateurs de performance, tant individuellement qu'en combinaison, afin d'identifier les leviers d'optimisation les plus prometteurs. L'approche méthodologique s'appuie sur des techniques de segmentation avancées (clustering) pour révéler les sous-catégories de produits présentant le plus fort potentiel d'amélioration.

Les résultats sont intégrés dans OAC de manière interactive permettant une visualisation intuitive des données et une interprétation stratégique adaptée aux enjeux spécifiques des secteurs bancaire et assurantiel⁵.

⁵<https://oac-bi-1.s.arka.com/ui/dv/ui/project.jsp?pageid=visualAnalyzer&reportmode=presentation&reportpath=%2F%40Catalog%2Fshared%2FDPF+-+Mod%C3%A9lisation+Financi%C3%A8re%2FContenu+DV%2FRapprochement+CCB+%26+PNB%2FRapprochement+tronqu%C3%A9&bookmarkid=UNKNOWN>

Chapitre IV - Conclusion

Cette analyse statistique menée a permis d'apporter un éclairage approfondi sur la structure et la dynamique des familles de produits au sein du Crédit mutuel Arkéa. Dans un premier temps, l'étude descriptive des indicateurs financiers, à savoir le Produit Net Bancaire (PNB) et le Coût de Consommation de la Banque (CCB), a mis en évidence une forte hétérogénéité des données. Les distributions se caractérisent par une leptokurtique et une asymétrie marquée à droite, traduisant la présence de valeurs extrêmes, phénomène cohérent avec le secteur bancaire où coexistent des contrats de faible volume et des contrats de très forte valeur. Cette dispersion statistique révèle que la performance globale repose sur une minorité de sous-familles de produits, confirmant l'application de la loi de Pareto dans ce contexte.

L'analyse univariée et bivariée a montré que l'épargne constitue le moteur principal du PNB, tandis que le crédit représente un domaine déficitaire, fortement consommateur de ressources. Le CCB, quant à lui, se concentre sur les services et le crédit. L'étude conjointe du PNB et du CCB a ainsi révélé que seules certaines sous-familles de produits parviennent à combiner rentabilité élevée et coût maîtrisé, telles que l'assurance vie ou les parts sociales, constituant des leviers stratégiques pour la banque. À l'opposé, d'autres sous-familles apparaissent comme structurellement coûteuses ou peu performantes, invitant à une rationalisation.

L'Analyse en Composantes Principales (ACP) a confirmé cette hétérogénéité en réduisant la complexité du jeu de données à deux dimensions principales, expliquant plus de 50 % de l'inertie totale. La première dimension, fortement corrélée au PNB et au PNB unitaire, reflète la rentabilité économique, tandis que la seconde, construite autour du CCB et du CCB unitaire, illustre le poids des coûts de gestion. Cette représentation factorielle a permis de mettre en évidence la corrélation positive entre variables orientées dans le même sens (ex. PNB et PNB unitaire), traduisant des dynamiques communes, et l'opposition de variables en sens inverse, révélant des arbitrages potentiels entre rentabilité et coûts. L'ACP a ainsi offert un cadre analytique robuste pour interpréter la structure des données et préparer la phase de segmentation.


La clusterisation K-means, réalisée à partir de ces deux dimensions, a dégagé cinq profils distincts. Le cluster central, qui regroupe 97,4 % des individus, correspond au portefeuille standard, caractérisé par des valeurs moyennes et homogènes. À l'inverse, les clusters périphériques traduisent des profils atypiques : le cluster 3, marqué par un PNB global négatif

mais un CCB élevé, témoigne de contrats rares mais coûteux ; les clusters 4 et 5 se distinguent par des valeurs extrêmes en PNB mais faibles en CCB, confirmant leur caractère stratégique ; enfin, le cluster 1, réduit à un seul individu, peut être assimilé à un outlier. Le Tableau 5, détaillant les variables par cluster, a permis de confirmer cette typologie, en montrant par exemple la surperformance du cluster 4 (PNB très élevé) ou les déséquilibres du cluster 3.

En définitive, cette étude statistique a démontré la complémentarité entre ACP et clusterisation pour analyser un portefeuille bancaire. L'ACP a permis de réduire la dimensionnalité et de dégager deux axes interprétables, tandis que la clusterisation a révélé une segmentation opérationnelle en profils standards et atypiques. Ces résultats offrent des leviers d'action clairs : renforcer les sous-familles et clusters performants, rationaliser les produits coûteux, et adapter la stratégie commerciale selon la typologie identifiée. L'approche statistique déployée ne se limite donc pas à une photographie descriptive, mais constitue un véritable outil de pilotage stratégique pour orienter les décisions de gestion et optimiser la valeur globale du portefeuille.

Annexe

Annexe 1 : Organigramme du Crédit mutuel Arkéa



source : Crédit Mutuel Arkéa

Annexe 2 : Tableau de statistique de distribution

Table: Résultats des statistiques de kurtosis, skewness et interprétation

Statistique	Valeur	Interprétation
Kurtosis PNB total	1059.164008	Leptokurtique
Skewness PNB total	27.641702	Asymétrie à droite
Kurtosis PNB commun	387.156118	Leptokurtique
Skewness PNB commun	18.365994	Asymétrie à droite
Kurtosis CCB total	109.502794	Leptokurtique
Skewness CCB total	9.592015	Asymétrie à droite
Kurtosis CCB commun	211.722958	Leptokurtique
Skewness CCB commun	13.198440	Asymétrie à droite

source : Rstudio, Auteur

Annexe 3 : Tableau de statistiques descriptives

Table: Résumé statistique des variables PNB et CCB

	Statistique	PNB total	PNB commun	CCB total	CCB commun
Minimum.Min.	Minimum.Min.	-4.627165e+06	-105613.14	0.00	0.000000e+00
Q1.1st Qu.	Q1.1st Qu.	1.370000e+00	0.00	66.50	4.761000e+01
Médiane.Median	Médiane.Median	1.560600e+02	37.91	307.06	3.765800e+02
Moyenne.Mean	Moyenne.Mean	5.267556e+04	11534.40	4731.55	1.124780e+04
Q3.3rd Qu.	Q3.3rd Qu.	2.957500e+03	992.40	1862.49	3.176240e+03
Maximum.Max.	Maximum.Max.	2.346574e+07	2119051.01	297840.42	9.777989e+05
Écart-type	Écart-type	5.708239e+05	95025.37	20567.64	5.599498e+04
Variance	Variance	3.258399e+11	9029821818.28	423027831.04	3.135438e+09

source : Rstudio, Auteur

Annexe 4 : Tableau de corrélation des contrats totaux

Table: Corrélations Spearman - PC

	PNBA_PC	CCB(CVB)_PC
PNBA_PC	1.00	-0.01
CCB(CVB)_PC	-0.01	1.00

source : Rstudio, Auteur


Annexe 5 : Tableau de corrélation des contrats communs

Table: Corrélations Spearman - PC

	PNBA_BOTH_PC	CCB(CVB)_BOTH_PC
PNBA_BOTH_PC	1.00	0.24
CCB(CVB)_BOTH_PC	0.24	1.00

source : Rstudio, Auteur

Annexe 6 : Répartition des sous-familles de produit en fonction du produit net standardisé et du coût de consommation de la banque standardisé



sources : Rstudio, Auteur

Annexe 7 : “Phénotype” des centroïdes

```
# A tibble: 5 × 6
  clust Dim.1 Dim.2 Dim.3 Dim.4 Dim.5
  <fct> <dbl> <dbl> <dbl> <dbl> <dbl>
1 1 -0.440 1.18 56.5 5.53 1.70
2 2 -0.104 -0.0246 -0.00303 -0.117 -0.0129
3 3 2.33 -1.35 -0.573 5.67 0.147
4 4 3.27 13.6 -0.488 1.37 2.50
5 5 29.5 -3.41 0.800 -5.92 -0.866
```

sources : Rstudio, Auteur

Annexe 8 : Liste des individus les plus représentatifs

cluster	rang	client_id
1	1	03-PART-E065-NA
2	1	03-PRO-C075-00430D
2	2	03-PRO-S040-10452
2	3	03-PRO-E029-506
3	1	03-PRO-S069-10813
3	2	01-PRO-C054-10255
3	3	03-PRO-S070-10806
4	1	01-PART-A001-10201
4	2	01-PART-E072-74006
4	3	01-PART-S026-30000
5	1	03-PART-S010-10497
5	2	01-PART-A016-10098
5	3	01-PART-C003-10098


sources : Rstudio, Auteur

Annexe 9 : Profils détaillés par cluster des variables

	clust	PNBA_PC_mean	PNBA_U_PC_mean	nbctr_PNBA_PC_mean	CCB_CVB_PC_mean	CCB_CVB_U_PC_mean	nbctr_CCB_PC_mean	effectif
1	1	182008.30	182008.29835	1.000	0.0000	0.00000	0.000000	1
2	2	25119.63	75.88882	1537.491	334.5404	12.14668	3.792618	3549
3	3	-82957.23	17.08949	806.973	12954.3356	999.27476	15.513514	74
4	4	4042713.03	40.50041	169772.000	7197.3452	25.62891	88.466667	15
5	5	15239.03	27.99881	299.800	199342.3281	221.34844	1381.800000	5

sources : Rstudio, Auteur

Annexe 10 : Projection des individus sur les dimensions 1 et 2



Liste des titres des tableaux & graphiques & figures & modélisations

Figure :

Figure 1 : Organigramme de la Direction du Pilotage Financier

Figure 2 : Organigramme du département MOF

Figure 3 : Représentation des Sous-familles de produits

Figure 4 : Diapositive de la présentation d'OAC

Figure 5 : Exemple du processus de création de l'indicateur VI

Figure 6 : Exemple du processus de création de l'indicateur CCB

Figure 7 : Méthodologie du Rapprochement

Figure 8 : Arbre d'Analyse

Tableau :

Tableau 1 : Statistique de distribution

Tableau 2 : Statistique descriptives

Tableau 3 : Statistique de corrélation

Tableau 4 : Profils des centroïdes & Individus les plus représentatif

Tableau 5 : Profils détaillés des variables par cluster

Graphique :

Graphique 1 : Histogramme du Produit Net Bancaire par domaine d'activité

Graphique 2 : Répartition des sous-familles de produit par domaine d'activité et Produit Net Bancaire standardisé

Graphique 3 : Distribution des sous-familles de produit en fonction du Produit Net Bancaire et du nombre de contrat

Graphique 4 : Histogramme du Coût de Consommation de la Banque par domaine d'activité

Graphique 5 : Répartition des sous-familles de produit par domaine d'activité et Coût de Consommation de la Banque

Graphique 6 : Distribution des sous-familles de produit en fonction du Coût de Consommation de la Banque et du nombre de contrat

Graphique 7 : Histogramme de la performance par domaine

Graphique 8 : Distribution des familles de produit en fonction de leurs produit net bancaire moyen standardisé et de leurs coût de consommation de la banque moyen standardisé

Graphique 9 : Classification des sous-familles les plus performantes pour le domaine de l'épargne

Graphique 10 : Clusterisation des sous-familles de produit

Graphique 11 : Histogramme des valeurs propres

Graphique 12 : Analyse en Composante Principale

Graphique 13 : Projection et classification des individus sur les dimensions 1 et 2

Bibliographie & Sitographie

Bibliographie :

- Guerrien, Marc. "L'intérêt de l'analyse en composantes principales (ACP) pour la recherche en sciences sociales. Présentation à partir d'une étude sur le Mexique." *Cahiers des Amériques latines* 43 (2003): 181-192.
- Lenfant, Jean-Sébastien. "La loi de Pareto: entre équilibre social et équilibre économique." *Economies et Sociétés. Œconomia, série PE* 31.11-12 (2001): 1591-1625.
- Khalid, Sara, and Daniel Prieto-Alhambra. "Machine learning for feature selection and cluster analysis in drug utilisation research." *Current Epidemiology Reports* 6.3 (2019): 364-372.

Sitographie :

- https://www.cm-arkea.com/arkea/banque/assurances/j_6/fr/accueil

Tables des matières

Remerciement.....	I
Sommaire.....	II
Résumé de la partie II.....	III
Abstract of part II.....	IV
Liste de Sigle.....	V
PARTIE I - RAPPORT DE MISSION.....	1
Chapitre I - Introduction.....	2
Chapitre II - Environnement de l'entreprise.....	3
A - Présentation du Crédit Mutuel Arkéa.....	3
B - Présentation de la Direction du Pilotage Financier : DPF.....	4
C - Présentation du département modélisation financière (MOF).....	6
1§ - Service Marges.....	6
2§ - Service Simulations.....	7
Chapitre III - Exposition des missions principales.....	9
A - Contexte & Objectif du Stage.....	9
B - Présentation des missions.....	9
1§ - Ensembles des missions.....	9
2§ - Mission Rentimo.....	11
C - Gestion du temps.....	12
Chapitre IV - Bilan.....	15
PARTIE II - RAPPROCHEMENT DU COÛT DE CONSOMMATION DE LA BANQUE ET DE LA VALEUR INSTANTANÉE.....	16
Chapitre I - Introduction.....	17
A - Présentation de la valeur instantanée (VI).....	18
B - Présentation du coût de consommation de la banque (CCB).....	18
Chapitre II - Méthodologie d'extraction des données.....	20
A - Mise en place du Périmètre.....	20
B - Requêtage des données.....	21
C - Gestion des écarts.....	22
Chapitre III - Analyse statistique.....	24
A - Objectif du Reporting.....	24
B - Etude statistique.....	24
1§ - Statistiques descriptives.....	25
2§ -Analyse univariées.....	27
a - Produit Net Bancaire.....	27
b - Coût de Consommation de la Banque.....	30
3§ - Analyse bivariées.....	32
4§ - Clusterisation.....	35
a - Clusterisation Via OAC.....	36
b - Clusterisation Via Rstudio.....	37
C - Résultat de la data-visualisation.....	42

Chapitre IV - Conclusion.....	43
Annexe.....	45
Liste des titres des tableaux & graphiques & figures & modélisations.....	49
Bibliographie & Sitographie.....	51
Tables des matières.....	52